



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 东南大学

参赛队号 26102860224

1. 周泽华

队员姓名 2. 单文杰

3. 苏永强

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘要

在有限算力下，扩大参数规模、增加训练数据与改善语料质量共同占用预算，需要结合各自的收益和费用安排投入。围绕这一问题，我们从文本质量评价出发，建立投入与训练损失的关系，求解预算约束下的资源配置，并结合历史评测分析能力增长及其未来前沿。

针对问题一：考虑到 22 个指标的含义与方向不同，我们先统一评分方向，再采用熵权法逐层评价文本、语料和领域质量。列表字段按语义处理：类别 logits 取期望，quater 四维分别归一化后等权聚合，质量指标采用 1%-99% 分位数截断归一化，272,505 条记录中的 19 处缺失以中位数补齐；广告字段经原文抽查，确认“类别索引 1（列表第二项）= 无广告”，按正向处理。指标分歧从两方面判断：成对标准化得分差衡量样本内的差别，Kendall 协同系数衡量整体排序的一致性；对标记出的冲突样本，再比较综合评分与所属领域中位数作判定。计算得到，样本-指标对冲冲突比例为 21.9%，独立参照为 28.9%，但 Kendall 系数只有 0.076，可见存在共同倾向并不等于高度一致。从领域均分看，arxiv 位居首位，github 最低；中间由高到低为 stackexchange、c4、commoncrawl，随后是分数接近的 book 与 wikipedia。抽样与扩展记录的对照也较接近：arxiv 在 A1、A2/A3 中分别为 0.727、0.725，github 分别为 0.450、0.449。对于领域配比，我们保留线性岭回归用于解释，以平方根嵌入核岭改善同尺度预测。共同五折的综合折外 RMSE 从 0.5761 降至 0.2558；1M 检验的平均逐域决定系数从 0.6186 提高至 0.9454，综合 RMSE 从 0.5232 降至 0.2256。核岭直接迁移到 60M、1B 的综合 RMSE 为 1.5536、2.8676，绝对损失仍明显失配；同一加权目标下，两模型对线性有界方案的判断相反，故我们将线性方案保留为对照，改用核岭在训练配方凸包内选优，并保留固定域及配比上限。推荐的预测加权损失为 4.6444，参考配方为 4.8173，模型内下降 0.1730；其跨尺度收益仍作为条件情景。混合质量指数是领域占比的线性组合，重复加入后的决定系数仅增加 0.000098，反映的是岭惩罚随参数化改变的影响；质量投入的独立作用另行考察。

针对问题二：为量化质量提升与规模扩张的替代关系，我们利用 Pythia 轨迹拟合经典标度律，采用稳健非线性最小二乘估计参数，并留出大模型检验预测效果。在此基础上，利用半合成实验比较四种质量项形式，选择加性质量缺口项。经典拟合的决定系数为 0.9999998，广义模型在联合样本上为 0.9896；换用跨族、文献记录时，MAPE 分别为 8.8%、8.0%。在质量均为 0.6 时，模型导数给出的局部质量-参数替代率随起点明显变

化：1B 参数配 100B tokens 时为 2.844 B/单位质量，12B 参数配 300B tokens 时为 76.838 B/单位质量。对于较大的质量增量，另用完整等损失关系求解，并给出有限等效解的条件。领域之间则先比较系数的中心化余弦相似度，再在损失尺度可迁移的前提下引入配比修正。B9/B10 的 128 条匹配记录用于对照大规模估算关系；质量效应的解释范围仍由半合成实验和跨来源尺度假设限定。

针对问题三：我们以问题二的预测损失为目标，将基础训练、语料质量处理和注意力费用计入同一预算，固定配比后采用 SLSQP 求解。基准采用幂函数型质量成本、参考配比和 2048 tokens 上下文。三档预算给出的配置分属两个阶段：在 10^{19} FLOPs 下，0.225B 参数与 6.9B tokens 对应的质量仍为基线 0.549；在 10^{22} 和 10^{24} FLOPs 下，质量都达到 1.000，前者配置为 6.091B 参数、229.4B tokens，后者为 44.939B 参数、3417.8B tokens。预算扫描表明，质量投入依次经历维持基线、逐步提高和达到上界三个阶段。首次投入和首次饱和的有效网格点为 1.58×10^{19} 、 7.08×10^{19} FLOPs，后一点的质量费用份额也达到最高值 40.7%；网格只能定位阶段，不能确定精确临界值。成本公式还给出 30,000 tokens 的等费用长度。固定 10^{22} FLOPs，上下文由 2048 延长到 131072 tokens，参数配置由 6.091B 减至 2.705B，损失约上升 6.0%。更换三类质量成本后，中高预算档均达到质量上界，低预算方案却有明显差别，因而仍需结合实际成本、评分衔接和外推范围使用。

针对问题四：我们按记录时间和许可白名单整理出 2,346 条主样本，以六项评测均值度量综合能力，并分别分析预训练类、对话及微调类的变化。C6 的分层回归显示，损失与得分的 Pearson 相关为 -0.510，决定系数仅 0.26，因此只判断变化方向，不作精确换算。规模与年度回归得到：参数每扩大十倍，对应 13.84 分差异；规模相同时，两个年度标签对应的条件差异为 4.84 分。历史分解显示出时间窗口的差别：C3 对应的 2019—2025 年增量中，规模项占 51.4%，非规模项占 48.6%；2024 年 6—9 月窗口的非规模项则占 95.4%。非规模项为算术剩余，还包含样本构成等未观测影响，不能识别技术进步的因果份额。以前沿在 2025 年 3 月的位置为起点，logistic 曲线预测 12、24 个月后会为 56.3、56.6 分，条件曲线的第 5 至第 95 百分位范围依次为 53.6 至 64.5、53.8 至 66.5；若将 logistic 增长参数减半，则为 55.6、56.3 分，结构情景将非规模增速减半时则为 53.4、55.8 分。时间留出检验未显示曲线具有稳定预测优势。为进一步寻找短板，从 C8 有效解析的 1,860 个目录中取与主样本对应的 964 个目录，汇总 37 项子任务，并用 C4 观察宏观资源及字段覆盖。六维结果中，指令遵循距满分 10.0 分，研究生级问答、多步推理仍差 72.3、61.3 分，表明综合前沿上升并不意味着各项能力同步改善。

综合四问结果，我们认为质量投入的时机和份额取决于预算与处理费用，模型扩容的收益则受数据条件制约。跨来源误差和外推假设限制了数值结论的适用范围，具体配置与预测应结合这些条件使用。

关键词：大语言模型；标度律；数据质量；资源配置优化；能力前沿预测

目录

一、引言	5
1.1 问题背景	5
1.2 问题重述	6
二、总体分析	6
三、模型假设	7
四、符号说明	8
五、模型的建立与求解	10
5.1 问题一：数据质量评价与领域配比建模	10
5.1.1 具体分析	10
5.1.2 模型准备	10
5.1.3 模型建立	15
5.1.4 模型求解	19
5.2 问题二：跨维度数据融合与广义标度律	28
5.2.1 具体分析	28
5.2.2 模型准备	29
5.2.3 模型建立	30
5.2.4 模型求解	34
5.3 问题三：算力约束下的资源配置与结构性转移	41
5.3.1 问题分析与模型准备	41
5.3.2 模型建立	43
5.3.3 模型求解	46
5.4 问题四：技术演进分析与能力前沿条件预测	51
5.4.1 能力度量与数据组织	51
5.4.2 损失与评测得分的分层联系	54
5.4.3 规模关系与历史增量分解	56
5.4.4 前沿曲线与条件预测	58
5.4.5 从综合前沿到具体任务瓶颈	61
5.4.6 宏观资源证据与预测边界	63
六、模型检验与分析	64
6.1 误差分析	65
6.2 配方决策与时间外推检验	67
6.3 灵敏度分析	68
6.4 各问结果的衔接与使用条件	70

七、模型的评价	71
7.1 模型的优点	71
7.2 模型的缺点	72
八、模型的改进与推广	72
8.1 模型的改进	72
8.2 模型的推广	73
参考文献	73

一、引言

1.1 问题背景

大语言模型的训练需要大量计算，而一项训练任务能够使用的算力总是有限的。在预算 C 内，扩大参数量 N 与增加数据量 D 都会增加开销，语料质量 Q 和领域配比 p 又会改变训练效果。因此，合理配置资源需要回答：现有预算更适合用在哪一项上？标度律研究已给出规模与损失之间的经验关系，可据此比较参数和数据的投入 [1, 2]。不过，Chinchilla 参数拟合的复现研究表明，即使使用同一函数形式，数据重建与估计过程也会影响得到的配置关系 [3]。因此，本文依据题目附件重新估计参数，并区分样本内拟合与跨来源检验。

继续扩大训练还面临语料供给问题。随着数据需求增长，高质量文本是否足够，成为“数据墙”研究关注的内容 [4]。语料的组织和使用方式也会影响任务表现。Gunasekar 等以教材式文本和练习组织代码训练数据，在较小模型上取得了有竞争力的代码评测结果；这一证据针对代码任务，不能直接推广到全部能力维度 [5]。DataComp-LM 则通过受控的数据筛选、去重和混合实验，比较数据组织对下游评测的影响 [6]。这些研究为将质量和领域构成纳入资源分析提供了依据，但具体收益仍需结合本文附件估计。语料处理、模型扩容和上下文延长各有费用，最终还要放到同一预算下比较。

题目提供的质量指标、配方实验、训练日志及能力评测，为比较上述投入提供了依据。我们先分析参数、数据和质量对交叉熵损失的影响，再将损失关系与费用约束结合，求解预算内的配置；随后利用历史评测分析能力增长的来源，并预测未来前沿。

我们将收益与代价共同纳入配置分析。增加参数量可能降低损失，却也会提高处理同一批文本所需的计算量；提高文本质量需要投入筛选和处理费用，而被处理的数据越多，这部分支出越大。延长上下文则会改变注意力计算的开销。这意味着，同样的损失降幅可能对应不同的算力支出。将效果与费用共同建模后，才能比较各项投入在不同预算下的优先次序。

在组织数据时，我们将领域配比与总数据量分别处理。总数据量描述训练使用多少文本，配比描述这些文本来自哪些领域。在总量不变时调整配方，实质上是在不同来源之间重新分配训练份额；在配方不变时扩大数据量，则同时扩大各来源的使用量。质量又与二者交织：同一领域内部可以存在得分差别很大的文本，而较易预测的领域也未必具有更高的文本质量。因此，我们先按观测对象确定各组附件的用途，再通过领域映射和损失关系连接不同层面的分析。

我们还将训练损失与实际评测能力分别建模。交叉熵可以用于拟合投入的边际作用，并为预算优化提供连续目标；任务得分还取决于评价内容和评分尺度，需要借助评测记录另行分析。因而，全文既保留损失模型内部的推导，也检查其与能力指标的联系。训练方案据此由投入与损失关系确定，未来能力则依据相应的评测记录预测。

1.2 问题重述

问题 1：用 22 个质量指标构建评分 Q ，使其能够分别评价文本、语料及领域。在统一指标方向的同时，说明评价冲突的识别和处理办法，并分析 17 个训练领域的占比如何对应交叉熵损失。

问题 2：在经典标度律中补充质量 Q 和领域配比 p 的作用，得到损失关于 N 、 D 、 Q 、 p 的关系。由此计算边际效用与弹性，比较不同投入，并确定质量提升能够与参数扩张等效的条件。

问题 3：给定算力预算，求参数量 N 、数据量 D 、配比 p 及质量 Q 的配置方案；再把预算扩大若干数量级，观察资源投入的重点是否发生转移。

问题 4：利用历史记录区分能力增长中的规模扩张项与非规模技术进步项，计算各自的增量和占比；在此基础上估计开源大语言模型未来 12 至 24 个月的能力前沿。

二、总体分析

我们按“语料评价—损失建模—预算配置—能力分析”的顺序处理四问：先建立质量和配比的度量，再比较各项投入的作用，最后在费用约束下求解配置，并分析评测能力的变化。图1列出了各问使用的资料、计算方法和结果去向。




图 1 四问建模流程

对于问题一，我们采用熵权法合成质量评分；样本内部的评价差别用成对标准化得分差刻画，整体排序的一致程度另用 Kendall 协同系数衡量。领域占比与损失使用另一

组配方实验，因此另建岭回归。计算所得的质量评分 Q 、基线 Q_0 、配比系数及核岭配比损失差，将用于后两问。

对于问题二，我们在同一损失尺度上比较不同投入。我们在 Chinchilla 形式中增加质量缺口项，写成 $L(N, D, Q) = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^\gamma$ 。取 $Q = 1$ 时，新增项为零，函数回到经典形式。接着分别对参数、数据和质量求导，比较它们带来的损失降幅，并求解等损失条件下的替代关系。

对于问题三，我们将题设费用写入约束，使配置同时满足损失目标与预算限制。基础训练计为 $6ND$ ，质量处理计为 $D[g(Q) - g(Q_0)]_+$ ，注意力计算计为 ηNDL_{ctx} 。给定配比后，用 SLSQP 计算不同预算的方案，再通过预算扫描寻找质量投入发生变化的位置。上下文的影响则从费用比入手，以 $L_{\text{crit}} = 6/\eta$ 确定注意力与基础训练开销相等的长度。

对于问题四，我们先按数据可比程度分别拟合损失与得分的关系，再以含年份固定效应的记录级规模—年份回归核算历史增量，并比较 logistic 曲线与结构情景的预测。综合分数之外，C8 用于查看哪些子任务仍较薄弱，C4 用于观察宏观资源变化和记录覆盖情况。

问题三使用问题一给出的 Q_0 、配比修正 $M(\mathbf{p})$ ，以及问题二的标度律参数。问题四另检验训练损失与评测能力能否对应：两者虽大体同向改善，换算误差却较大。因此，历史分解和未来预测直接从评测得分计算，不把前三问的损失降幅直接折成能力分数。

数据在各环节中的作用。用于估计参数的记录、用于比较方法的记录和用于观察适用范围的记录，分别回答不同问题。问题一由配方与损失的关联记录估计系数，再用同尺度和跨尺度资料检查预测；问题二先从规模实验确定经典关系，再结合质量实验估计扩展项，其他来源用于对照。问题三接收前两问的估计值与题设费用函数，输出给定条件下的配置。问题四则以经过筛选的历史评测构造回归样本和能力前沿。我们据此区分参数估计、方法比较与适用范围检验，避免将不同性质的附件混入同一次拟合。

四问之间传递的量。质量评分负责概括文本信号，配比系数负责描述训练组成与损失的关系，标度律参数负责比较不同规模及质量投入，预算模型则把这些关系转化为可行方案。衔接各问时，我们保留这些量各自的取值范围和含义。例如，领域均分作为参考质量进入后续计算，并不意味着质量分数与能力得分能够直接换算；预算增大后得到的最优配置，也不等同于某个历史模型实际采用的训练方案。因此，各问共用的数值仍须连同其来源和假设一起解释。

结果的检查顺序。我们先检查模型对估计样本的拟合，再考察其在检验记录中的表现；对于优化结果，进一步核对成本是否满足预算约束，以及配置变化能否由目标函数和费用关系解释。最后，通过已有的赋权、成本和情景比较考察结论依赖哪些条件。误差、约束残差和情景范围各有用途，全文在相应位置分别报告，并在第六、节集中对照。

三、模型假设

结合附件覆盖范围与题设成本，我们作出以下假设：

- **假设 1:** 在附件 A 的训练配方范围内, 17 个领域占比的线性组合能够近似描述验证损失; 换到其他参数规模时, 允许损失的整体尺度发生变化。
- **假设 2:** B6、B7 的质量随评分提高而提高, 质量不足带来的损失可作为单独一项加到经典标度律中。其他来源须先核对评分含义和方向, 再确定用法。
- **假设 3:** 按题设将总算力分为基础训练、质量提升和长文本注意力三项; 质量费用采用附录 B 的函数, 上下文采用 C7 的给定长度, 不参与自由优化。
- **假设 4:** 观测窗口内能力前沿逐渐放缓的过程可由 logistic 函数近似; 得分中与规模和非规模技术变化有关的增量, 可用记录级规模一年份回归作近似核算。

第一项假设中, 我们采用线性近似, 是为了在已有配方范围内估计和比较领域系数, 核岭则负责预测和训练支持范围内的配方选择。跨尺度资料承担的是检验变化趋势与损失尺度的作用, 不能仅凭配方结构相同就省略尺度比较。

第二项假设将质量缺口单列为损失项, 使我们能够分别对参数、数据和质量求导, 比较各项投入的边际作用。由于质量的含义来自附件中的评分与实验设定, 模型应用范围也需要随之保留; 其他来源的记录应在核对方向后再参与解释。

第三项假设把优化问题限定在题设给出的费用体系中。参数量和数量共同决定基础训练开销, 质量费用随处理量累计, 上下文长度则作为给定情景进入注意力开销。由此得到的配置是这些条件共同作用的结果, 更换费用关系时应同时观察配置与损失的变化。

第四项假设中, 我们用记录级规模一年份回归核算已有窗口内的增量, 用前沿曲线描述高分记录随时间的变化。二者的统计对象不同, 因此分别保留其样本窗口与评分范围, 并以各自的历史关系构造未来增长情景。

四、符号说明

主要符号列于表1。问题二拟合时以十亿参数和十亿 tokens 计量规模, 问题三计算成本时转换为参数个数和 token 数。

表 1 主要符号及含义

符号	含义
N	模型包含的参数数量
D	用于模型训练的数据总量
L, E	分别表示验证交叉熵损失与参考配比下的渐近常数项
Q	数据质量评分, 分值越高则质量越好
Q_0	质量基线; 问题二说明来源间的参考水平, 问题三采用参考配比加权质量
p	各领域训练占比构成的向量, 各项非负且总和为 1

表1 主要符号及含义 (续)

符号	含义
θ, λ_k	配比核函数的距离参数与核岭正则强度
A, B	参数规模项、数据规模项的标度系数
α, β	参数规模项、数据规模项的幂指数
C, C_q	质量缺口系数, 问题三记为 C_q
γ	质量缺口的幂指数
$\varepsilon_N, \varepsilon_D, \varepsilon_Q$	损失对参数量、数据量和质量的弹性
$M(\mathbf{p})$	相对参考配比的损失平移修正
$C_{\text{train}}, C_Q, C_{\text{attn}}$	基础训练、质量提升和注意力开销
C_{budget}, C_b	总算力预算, 问题三简记为 C_b
$g(Q)$	单个 token 的质量处理成本
η	注意力开销系数; 参数个数作为计数代入成本公式
$L_{\text{ctx}}, L_{\text{crit}}$	上下文长度、注意力与训练开销相等时的长度
$\lambda(L_{\text{ctx}})$	注意力开销与基础训练开销的比值
$\tau(Q)$	质量处理成本折算的等效附加参数规模
$\Theta(C_b)$	质量提升完成度
$F(t), K$	能力前沿及 logistic 饱和上界
t, t_0	以 2019 年为原点的时间、logistic 拐点时间
r	logistic 增长率
b_P	参数量每扩大十倍对应的回归得分变化
b_t	记录级规模—年份回归的年度标签的得分差异系数
α_t	记录级规模—年份回归的年份固定效应
$\bar{B}$	Leaderboard 六维平均得分
$Q_i, Q_d, \bar{Q}(\mathbf{p})$	依次表示样本评分、领域平均评分和按训练配比加权的质量指数
$\mathbf{P}, \mathbf{L}$	分别由各组训练配比及其对应的验证损失构成的矩阵
$\mathbf{A}, \mathbf{b}$	配比回归中的系数矩阵和截距向量
λ	配比回归的岭惩罚系数, 设为 10^{-3}
τ	判断两个指标的标准化得分是否冲突的阈值, 设为 1.5
w_j, e_j	指标 j 对应的熵权系数与信息熵值
W	Kendall 协同系数, 用于衡量指标排序的一致程度
ρ_c, ρ_0	指标评价的冲突比例及指标独立条件下的参考冲突比例

表1 主要符号及含义 (续)

符号	含义
R^2	决定系数
RMSE、MAE	均方根误差、平均绝对误差
MAPE	平均绝对百分比误差

五、模型的建立与求解

本文使用腾讯 WorkBuddy 接入的 DeepSeek-V4-Flash 辅助文段相关工作，并使用 OpenAI Codex (GPT-5.6-Luna, 2026-07-09) 辅助图表展示、排版检查、程序整理、数据整理与结果复核，所用工具、模型及版本信息见各问的辅助分析说明。正文表达与段落衔接另经 OpenAI Codex 辅助润色。

5.1 问题一：数据质量评价与领域配比建模

5.1.1 具体分析

面对 22 个取值形式和评价侧重点不同的质量指标，我们先统一评分方向与尺度，再分析同一文本在各指标下的评价差异。具体采用熵权法计算文本质量并汇总语料和领域评分，以成对标准化得分差和 Kendall 协同系数分别刻画局部分歧与整体排序一致性。对于配方实验，我们采用线性岭回归解释 17 个训练领域与 13 个验证领域之间的配比-损失关系 [7]，并以平方根嵌入核岭增强同尺度预测；有界配方建议仍由线性目标给出。

图2给出了质量评价与配比建模的分析流程。质量评价以 A1-A3 为输入，依次完成缺失值填补、列表值标量化、指标同向化与归一化，再计算质量得分和冲突情况。配比建模先按索引匹配训练配方与验证损失，比较线性岭与核岭的训练五折误差，并在 1M、60M、1B 记录上检验预测；线性模型用于系数解释，核岭在训练配方支持范围内给出有界推荐，10B、70B 外推表仅作尺度对照。两部分涉及的领域分类通过映射表建立对应关系。

我们将质量评价与配比回归分别计算，是因为二者的观测单位不同：前者的一行记录对应一段文本，后者则对应一次配方实验。文本评分不能替代实验损失，领域平均损失也不能代表该领域全部文本的质量。完成两部分计算后，再通过领域映射比较文本评价与训练难度的关系。

5.1.2 模型准备




图 2 问题一分析流程

1. 数据来源与预处理

A4 与 A5 分别记录训练配方及其对应的验证损失，通过 index 关联。A4 包含 The Pile 的 17 个领域，各项占比非负，理论上每行之和为 1，附件小数舍入使训练行和最大偏差为 0.004[8]；A5 提供 13 个领域的交叉熵损失。其中，nih_exporter、enron_emails、europarl 和 philpapers 参与训练配方，但缺少对应的验证列。我们将这部分领域记为“间接影响域”：拟合时保留其占比，但不将其作为独立验证目标。

按索引匹配后，同一次实验的配方与损失逐行对应。训练领域比验证领域多，说明训练来源的覆盖范围大于评价任务的覆盖范围；缺少验证列的领域仍可能影响其他任务。因此，我们在回归中保留这些领域，在推荐模型中则固定其参考占比，以区分能够直接评价与只能间接分析的调整。

A1—A3 提供 SlimPajama 语料的 22 个质量指标 [9]。列表值先转为标量，非有限值视为缺失并按全量记录中该指标的中位数填补。设处理后的值为 x_{ij} 。对于过长或过短均不合适的长度型指标，先以稳健中心接近度作变换；其余指标保留原值：

$$u_{ij} = \begin{cases} \exp\left(-\frac{|\ell_{ij} - m_j|}{2.5(\text{MAD}_j + 10^{-9})}\right), & \text{长度型指标,} \\ x_{ij}, & \text{其余指标,} \end{cases} \quad (1)$$

其中 $\ell_{ij} = \ln(1 + \max(x_{ij}, 0))$ ， $m_j = \text{median}_i \ell_{ij}$ ， $\text{MAD}_j = \text{median}_i |\ell_{ij} - m_j|$ 。随后对每个变换后指标，取 A1—A3 全量记录的第 1 和第 99 百分位数 a_j 、 b_j ，进行分位数截断归

一化，再对负向指标取补：

$$v_{ij} = \text{clip}_{[0,1]} \left(\frac{u_{ij} - a_j}{\max(b_j - a_j, 10^{-12})} \right), \quad x'_{ij} = \begin{cases} 1 - v_{ij}, & \text{负向指标,} \\ v_{ij}, & \text{其余指标.} \end{cases} \quad (2)$$

其中 $\text{clip}_{[0,1]}(v) = \min(1, \max(0, v))$ ；分位数按相邻顺序统计量线性插值得到。长度型指标也经过这一步缩放。各指标最终均取值于 $[0, 1]$ ，且越大越好。与直接使用最小、最大值相比，分位数端点降低了极端值对缩放区间的影响，代价是端点外的差异不再保留。各领域及抽样、扩展集沿用同一组全量端点与权重，保证评分可比较。含多个有序类别的列表字段通过 softmax 将类别 logits 转为概率，再计算归一化期望级别；单元素列表直接取其数值。qurater 的四个分量分别为写作风格、所需专业知识、事实知识和教育价值，属于不同维度而非互斥等级 [9]。设其原始值为 q_{ir} ($r = 1, \dots, 4$)，各维缺失先用该维全量中位数填补，再以对应的第 1、99 百分位数 a_r^q, b_r^q 计算

$$x_{i,\text{qurater}} = \frac{1}{4} \sum_{r=1}^4 \text{clip}_{[0,1]} \left(\frac{q_{ir} - a_r^q}{\max(b_r^q - a_r^q, 10^{-12})} \right). \quad (3)$$

聚合值作为 22 个指标之一，继续参与上述外层分位数归一化。我们将四维同向、等权聚合，把知识密度与专业要求纳入广义质量；这一设定并不意味着专业要求越高就越适合所有训练任务。数据卡只规定字段含义，聚合权重属于本文的评价假设。表2列出各字段的含义、方向及权重。

表 2 质量指标的含义、评价方向及熵权

指标字段	指标含义与判向依据	类型	方向	熵权 w_j
fineweb_edu	文本用于教育的价值	列表 (1)	正向	0.0433
fluency_en	英语流畅度（索引 1= 流畅，列表 (2) 已核验）	列表 (2)	正向	0.0675
modernbert_cleanliness	文本内容的洁净程度	列表 (6)	正向	0.1420
modernbert_readability	文本的易读程度	列表 (6)	正向	0.0562
modernbert_reasoning	内容体现的推理程度	列表 (6)	正向	0.1502
modernbert_professionalism	内容的专业程度	列表 (6)	正向	0.0392
dsir_books	相对于书籍领域的重要性 权重	标量	正向	0.0081
dsir_wiki	相对于维基领域的重要性 权重	标量	正向	0.0080
dsir_math	相对于数学领域的重要性 权重	标量	正向	0.0086
qurater	四维质量：分维归一化后 等权聚合	列表 (4)	正向	0.0586

表2 质量指标的含义、评价方向及熵权（续）

指标字段	指标含义与判向依据	类型	方向	熵权 w_j
ad_en	广告含量（索引 1= “无广告”，正向；依据：原文抽查）	列表 (2)	正向	0.0071
rps_doc_word_count	文档包含的词总数	标量	长度型	0.0511
rps_doc_num_sentences	文档包含的句子总数	标量	长度型	0.0518
rps_doc_unigram_entropy	用一元词熵衡量词汇多样性	标量	正向	0.0343
rps_doc_frac_unique_words	不同词项所占比例	标量	正向	0.0533
rps_doc_frac_no_alph_words	非字母字符所占比例	标量	负向	0.0284
rps_doc_frac_chars_top_2gram	字符 2-gram 的重复程度	标量	负向	0.0128
rps_doc_frac_chars_top_3gram	字符 3-gram 的重复程度	标量	负向	0.0118
rps_lines_uppercase_letter_fraction	大写字母行所占比例	标量	负向	0.0313
rps_lines_ending_with_terminal_punctution_mark	以终止标点结束的行所占比例	标量	正向	0.0871
rps_lines_numerical_chars_fraction	含有数字的行所占比例	标量	负向	0.0124
rps_doc_mean_word_length	词项长度的平均值	标量	长度型	0.0369

在统一指标方向后，以加权和计算样本质量 Q_i ，再对同一领域内的样本取均值，得到领域质量 Q_d ：

$$Q_i = \sum_{j=1}^{22} w_j x'_{ij}, \quad Q_d = \frac{1}{n_d} \sum_{i \in \mathcal{D}_d} Q_i, \quad \sum_j w_j = 1 \quad (4)$$

表2中，推理与洁净程度对综合评分的影响较大：modernbert_reasoning 的权重为 0.150，modernbert_cleanliness 为 0.142。这里的 w_j 依据样本分布中的信息差异计算，不能直接代表指标本身的重要程度。极端左偏的分布也可能获得较高熵权，因此第6.3节将通过更换赋权方式，考察评分结果的变化。

二分类字段的类别索引从 0 开始，表中的索引 1 对应列表第二项。

字段缺失情况见表3。逐项检查后，采用对应指标的中位数填补缺失值，使填补值处于分布的中间水平，避免将缺失记录直接赋为高分或低分。

表 3 A1–A3 中 272,505 条记录的质量字段缺失统计

缺失字段	缺失情况	涉及记录数
modernbert_reasoning	该记录中此字段的 6 个分量均为 NaN	13
modernbert_professionalism	该记录中此字段的 6 个分量均为 NaN	6
其余 20 个指标	未发现缺失值	0

2. 方法选择及其依据

选择综合评分方法时，我们同时考察权重含义与计算结果。表4对熵权法、等权平均及首主成分非负载荷加权对照进行比较。评价分歧从两个层面考察：成对标准化得分差用于识别单条文本的指标分歧，Kendall 协同系数用于衡量整体排序的一致程度。配比拟合以线性岭回归为解释基线，以平方根嵌入核岭为非线性预测模型，通过共同五折检验其误差差异。

表 4 不同赋权方式下的样本得分及领域排序比较

赋权方法	与熵权得分的相关系数	领域排序相关性 Spearman 系数，参照熵权法	样本平均得分
熵权法	1.000	1.000	0.491
等权平均	0.875	0.643	0.637
首主成分非负载荷加权	0.927	0.679	0.496

表4显示，熵权与等权评分的样本相关系数为 0.875，而领域均分排序的 Spearman 系数为 0.643。两种赋权方式的总体趋势接近，但具体领域的名次有所变化。据此，我们采用熵权法，以样本中的信息差异确定权重，同时通过赋权对照保留对领域名次变化的检验。对照方案先对标准化指标矩阵取首主成分载荷，统一符号使载荷总和非负，再将负载荷截为零并归一化，最后对原归一化指标加权。因此它是首主成分非负载荷加权评分，不是标准 PCA 的投影得分；这种处理保证各项权重非负，但改变了主成分原有的方差最大化含义，本文仅将其作为赋权对照。

我们同时比较样本得分和领域名次，因为两者的稳定性并不等价。赋权改变后，多数文本的相对得分可能仍然接近，但均值相近的领域会交换名次。因此，样本相关用于判断评分的共同趋势，领域秩相关用于判断汇总排序是否保持。

配比预测的方法取舍围绕误差、解释与计算组织展开。普通最小二乘在占比和为 1 的设计中存在截距与系数不可唯一识别的问题；线性岭通过正则化保留稳定的相对系数，但难以充分表达非线性响应。平方根核岭把配方之间的距离纳入预测，在保留零占

比的同时，13 个验证域共用一套核矩阵和两个待选超参数，便于统一验证。高斯过程也能刻画非线性，并提供模型条件下的预测不确定性；若逐域采用 ARD 核，则还需分别估计各维长度尺度、核幅度及噪声，并检查边际似然优化的收敛情况。

我们既要提高同尺度领域损失的预测精度，也要为后续配置分析保留可解释的系数。因此，线性岭用于系数解释和受约束配方分析，核岭用于检验非线性响应能否改善预测。本问以点预测为主，未估计高斯过程后验区间；选择依据是共同五折及同尺度检验的实测改善、核矩阵共享的计算便利与跨问角色划分，并不意味着核岭在所有数据或不确定性估计任务中更优。

配比回归需考虑占比约束对系数估计稳定性的影响。17 项占比之和为 1，任一占比增加均需由其他占比的减少补偿，普通回归可能因此产生不稳定估计。岭回归通过引入 L_2 惩罚缓解这一问题，同时保留线性系数的可解释性。

5.1.3 模型建立

1. 综合质量评分

将预处理后的 m 条文本表示为矩阵 $\mathbf{X} = (x'_{ij})$ ，每行包含 22 项质量值。以 Shannon 信息熵 [10] 描述各列得分的分布，再用归一化熵 e_j 的信息差异确定权重 w_j ：

$$e_j = -\frac{1}{\ln m} \sum_{i=1}^m f_{ij} \ln f_{ij}, \quad f_{ij} = \frac{x'_{ij} + \varepsilon}{\sum_i (x'_{ij} + \varepsilon)}, \quad w_j = \frac{1 - e_j}{\sum_{j=1}^{22} (1 - e_j)} \quad (5)$$

式中，每列的 f_{ij} 之和为 1，表示该指标的归一化得分在样本间如何分配； ε 用来使对数项有定义。当一列在全部样本上的取值相同， $f_{ij} = 1/m$ ，代入即可得到

$$e_j = -\frac{m(1/m) \ln(1/m)}{\ln m} = 1.$$

此时该列没有区分当前样本的能力，其信息差异 $1 - e_j$ 为零。若得分更多集中于部分样本，信息熵会降低，该列在加权时获得更大份额。这个过程把权重与当前样本分布联系起来，而指标应取正向还是负向，仍须由指标含义决定。

权重非负且总和为 1，因而综合得分是各项同向评分的凸组合。高权重指标的变化会更明显地影响总分，但一项指标的高分不会自动抵消对其他指标含义的核对。领域均值则是在同一评分规则下进行第二次汇总，其作用是比较整类语料的总体位置，不能描述其中每条文本的情况。因此，我们同时报告领域均值和标准差，保留领域内部的评分差异。

除文本指标外，验证损失还可用于考察领域拟合难度。在平均配方下，损失较低的领域更易被当前模型拟合。为将这一差异与附件 B 联系起来，定义基于损失的质量代理值：

$$Q_d^{(\text{loss})} = 1 - \frac{\bar{L}_d - \min_d \bar{L}_d}{\max_d \bar{L}_d - \min_d \bar{L}_d} \quad (6)$$

$\bar{L}_d$ 为领域 d 的平均交叉熵损失。代理值的计算范围为具有损失列的 13 个领域，文本质量评价则覆盖 A1–A3 的 7 类语料。本文依据 A16 建立两套分类的对应关系，并在结果部分比较其排序，避免直接混用含义不同的评分。

这里的端点由本次参与比较的领域确定：平均损失最小者对应代理值上端，平均损失最大者对应下端。因此，代理值提供的是当前验证范围内的相对位置。它与从文本指标得到的 Q_d 都采用便于比较的数值范围，但生成过程不同。前者随验证模型和任务而变化，后者由文本信号与赋权规则决定。将二者并列展示，可以检查语料评价与训练难度是否给出相近的领域次序。

2. 质量冲突的定义与处理

同一文本在两个指标上的得分差异较大时，需进一步检查其综合评价。为保证指标差值具有可比性，先对同向指标进行标准化，再定义样本 i 在指标 j 、 k 之间的距离：

$$\delta_i(j, k) = |z_{ij} - z_{ik}|, \quad z_{ij} = \frac{x'_{ij} - \mu_j}{\sigma_j}, \quad \mathbf{1}\{\delta_i(j, k) > \tau\} \quad (7)$$

以 $\tau = 1.5$ 标记冲突，将全部样本中的指标对一并统计，得到全样本冲突率：

$$\rho_c = \frac{1}{m \binom{22}{2}} \sum_{i=1}^m \sum_{j < k} \mathbf{1}\{\delta_i(j, k) > \tau\} \quad (8)$$

为比较实际冲突比例，假定各指标为相互独立的标准正态变量，得到参照值 $\rho_0 = 2\Phi(-\tau/\sqrt{2})$ 。当 $\rho_c/\rho_0 < 1$ 时，实际冲突比例低于该参照。另将 22 个指标视为评价者、 m 条文本视为评价对象，采用 Kendall 协同系数 [11] 衡量整体排序的一致程度：

$$W = \frac{12 \sum_i (R_i - \bar{R})^2}{22^2(m^3 - m) - 22 \sum_{j=1}^{22} T_j}, \quad T_j = \sum_g (t_{jg}^3 - t_{jg}) \quad (9)$$

其中 r_{ij} 为指标 j 对样本 i 给出的平均秩， $R_i = \sum_{j=1}^{22} r_{ij}$ ； t_{jg} 为指标 j 的第 g 个并列组所含记录数。分位截断和离散取值会产生并列，故在分母中扣除相应修正项；无并列时各 $T_j = 0$ 。辅助统计量取 $\chi^2 = 22(m-1)W$ ，以自由度 $m-1$ 的卡方分布计算名义近似概率。由于记录存在重复、指标之间也可能相关，该概率不作为独立样本下的显著性证据，解释以 W 的大小为主。

遇到已标记的冲突文本时，比较加权评分 Q_i 与本领域中位数，据其高低作综合判断；这一规则汇总了各指标的加权信号，不等同于逐项计数的多数表决。冲突统计用于描述分歧程度，聚合评分仍按统一规则进入后续配比分析。

冲突率中的统计单位是“文本与指标对”的组合。对同一条文本，各指标对可以给出不同结果；把这些结果平均后，才得到总体比例。独立参照的推导也在这个层面进行：两个独立标准正态变量之差的方差为 2，将差值除以 $\sqrt{2}$ 后转为标准正态变量，双侧尾部概率便给出 ρ_0 。该参照是为便于比较而设置的理想情形，实际指标是否严格服从正态分布并不由这一公式证明。

Kendall 系数使用的是各指标对全部文本给出的排序。若两个指标的数值尺度不同、但对文本高低的排列接近，排序一致性仍可能较高；成对标准化差值则保留了每条文本偏离各指标均值的程度。两项统计量分别从局部评分差异和整体排列关系描述分歧，后续结果需要结合两者解释。

3. 领域配比的线性混合回归

将训练配方整理为矩阵 $\mathbf{P} \in [0, 1]^{n \times 17}$, 将各组对应的验证损失整理为矩阵 $\mathbf{L} \in \mathbb{R}^{n \times 13}$ 。理想配方的占比之和为 1, 附件原始份额近似满足这一约束; 线性基线沿用原始份额, 核岭则逐行闭合。对 13 个验证领域分别建立线性关系:

$$L_d(\mathbf{p}) = \sum_{k=1}^{17} a_{dk} p_k + b_d, \quad d = 1, \dots, 13 \quad (10)$$

令系数矩阵的第 k 行、第 d 列为 $A_{kd} = a_{dk}$, 其矩阵形式为

$$\hat{\mathbf{L}} = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top \quad (11)$$

在理想行和约束下, 普通回归无法唯一识别截距与配比系数; 舍入偏差虽可打破严格共线性, 仍会形成近似共线。为获得稳定估计, 对系数矩阵 $\mathbf{A} \in \mathbb{R}^{17 \times 13}$ 施加岭惩罚 [12], 并与截距 $\mathbf{b}$ 联合求解:

$$\min_{\mathbf{A}, \mathbf{b}} \|\mathbf{L} - \mathbf{P}\mathbf{A} - \mathbf{1}\mathbf{b}^\top\|_F^2 + \lambda \|\mathbf{A}\|_F^2 \quad (12)$$

相应的系数估计为

$$\begin{bmatrix} \mathbf{A} \\ \mathbf{b}^\top \end{bmatrix} = \left(\tilde{\mathbf{P}}^\top \tilde{\mathbf{P}} + \lambda \mathbf{D} \right)^{-1} \tilde{\mathbf{P}}^\top \mathbf{L} \quad (13)$$

式中, 扩展矩阵为 $\tilde{\mathbf{P}} = [\mathbf{P}, \mathbf{1}]$, 惩罚矩阵为 $\mathbf{D} = \text{diag}(1, \dots, 1, 0)$ 。最后一个对角元取零, 表示不惩罚截距; 本次计算取 $\lambda = 10^{-3}$ 。

为说明理想占比约束造成的识别问题, 记 $\mathbf{u}$ 为 17 维全 1 向量, 则 $\mathbf{P}\mathbf{u} = \mathbf{1}$ 。对任意 13 维向量 $\mathbf{v}$, 有

$$\mathbf{P}(\mathbf{A} + \mathbf{u}\mathbf{v}^\top) + \mathbf{1}(\mathbf{b} - \mathbf{v})^\top = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top.$$

也就是说, 在没有惩罚或附加约束时, 可以把同一列系数共同增加一个量, 再从相应截距中减去这个量, 而预测损失保持不变。岭惩罚通过限制系数的平方和, 从这些相同预测的表示中选择稳定估计。由于截距不受惩罚, 损失的总体水平仍可由截距承担, 配比系数主要描述构成差异。

求解式也可以由目标函数的一阶条件得到。将系数和截距合写为 $\boldsymbol{\Theta} = [\mathbf{A}^\top, \mathbf{b}^\top]^\top$, 则

$$\tilde{\mathbf{P}}^\top (\tilde{\mathbf{P}}\boldsymbol{\Theta} - \mathbf{L}) + \lambda \mathbf{D}\boldsymbol{\Theta} = \mathbf{0}.$$

移项后得到前述正规方程。这个写法还说明, 13 个验证任务共用同一配方矩阵, 但各自对应不同的损失列和系数列; 一个领域在不同验证任务上的系数可以具有不同方向。

由于占比总和受约束, 我们按完整的份额转移解释系数。设某个可行调整为 $\Delta \mathbf{p}$, 其各分量之和为零, 则预测损失变化为

$$\Delta \hat{\mathbf{L}} = (\Delta \mathbf{p})^\top \mathbf{A}.$$

将任意一列系数共同平移不会改变该变化量。因而, 中心化系数适合展示相对作用, 而具体资源转移仍须比较被增加领域与被减少领域的系数差。仅凭一个系数的正负, 无法同时确定所有验证任务上的调整收益。

4. 平方根嵌入核岭预测

线性模型便于解释领域间的份额转移，但可能遗漏配方对损失的非线性影响。核岭回归将岭惩罚与核函数结合，可用于非线性预测 [13]。为此，我们先对存在舍入误差的配方逐行闭合，再作平方根变换，在保留零占比的同时构造核函数：

$$\tilde{p}_k = \frac{p_k}{\sum_l p_l}, \quad k_\theta(\mathbf{p}, \mathbf{q}) = \exp \left[-\theta \sum_{k=1}^{17} (\sqrt{\tilde{p}_k} - \sqrt{\tilde{q}_k})^2 \right]. \quad (14)$$

平方根距离利用了比例非负的结构，无需为零占比添加伪计数；核参数 $\theta > 0$ 控制响应随配方距离变化的范围。线性基线仍按原始附件份额、固定正则系数 10^{-3} 计算，以便与系数解释及线性对照对应。

设训练核矩阵为 $\mathbf{K}$, $\mathbf{H} = \mathbf{I} - \mathbf{1}\mathbf{1}^\top/n$, 训练损失的逐域均值为 $\bar{\mathbf{L}}$ 。对核矩阵和响应同时中心化，使截距不受惩罚，求得核系数矩阵：

$$\mathbf{K}_c = \mathbf{H}\mathbf{K}\mathbf{H}, \quad \mathbf{U} = (\mathbf{K}_c + \lambda_k \mathbf{I})^{-1} \mathbf{H}\mathbf{L}, \quad \hat{\mathbf{L}}(\mathbf{p}) = \bar{\mathbf{L}} + \mathbf{k}_c(\mathbf{p})^\top \mathbf{U}. \quad (15)$$

新配方的第 i 个中心化核值为

$$[\mathbf{k}_c(\mathbf{p})]_i = k_\theta(\mathbf{p}, \mathbf{p}_i) - \frac{1}{n} \sum_j k_\theta(\mathbf{p}, \mathbf{p}_j) - \frac{1}{n} \sum_j K_{ji} + \frac{1}{n^2} \sum_{j,l} K_{jl}. \quad (16)$$

训练与预测共用训练核的均值；交叉验证时所有这些均值均只由当前训练折计算。13 个输出共享同一核矩阵，但各自具有响应均值与系数列。

固定随机种子 20260926，将 512 组训练配方分为共同的五折，折大小依次为 103、103、102、102、102。核岭在 $\theta \in \{2^{-6}, \dots, 2^2\}$ 、 $\lambda_k \in \{10^{-6}, \dots, 10^2\}$ 的 81 组预设组合中，选择综合折外 RMSE 最小者：

$$\text{RMSE}_{\text{OOF}} = \sqrt{\frac{1}{13n} \sum_{i=1}^n \sum_{d=1}^{13} (L_{id} - \hat{L}_{id}^{(-f(i))})^2}. \quad (17)$$

其中 $f(i)$ 为记录所属验证折。该指标先汇总全部折外平方误差，再开平方；不能用逐域 RMSE 的算术平均代替。最小交叉验证误差用于调参，不作为嵌套验证的无偏估计；既有检验集此前已参与方法分析，故后续结果也不称为新的盲测成绩。

5. 混合质量指数与冗余特征对照

我们先考察混合质量与领域配比之间的关系。按占比计算混合质量 $\bar{Q}(\mathbf{p}) = \sum_k p_k Q_k$ 。各 Q_k 依据 A16 确定：direct、near_direct 采用 A1–A3 中对应的领域评分，inferred 采用全局均值。将 $\bar{Q}$ 加入回归，得到

$$\hat{\mathbf{L}} = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top + (\mathbf{P}\mathbf{q})\mathbf{c}^\top \quad (18)$$

其中 $\mathbf{q} = (Q_1, \dots, Q_{17})^\top$, $\mathbf{c}$ 为 13 维质量系数向量。由于 $\mathbf{q}$ 固定， $\mathbf{P}\mathbf{q}$ 严格位于 $\mathbf{P}$ 的列空间内，上式等价于 $\mathbf{P}(\mathbf{A} + \mathbf{q}\mathbf{c}^\top) + \mathbf{1}\mathbf{b}^\top$ ，并未增加独立的解释信息。新增系数参与岭惩罚后，原有效系数所受的惩罚发生变化，故拟合值仍可能略有改变。这里仅作冗余特征加入后的拟合对照，不能据此识别质量的独立作用。问题二、三再利用质量实验考察固定配比下的质量变化。

6. 配比优化与有界推荐

参考配方先由 512 组原始份额取列均值，再闭合为 $\mathbf{p}_{\text{ref}}$ 。令 $\mathcal{M}$ 为 13 个有验证损失的领域，权重取 $w_d = p_{\text{ref},d} / \sum_{j \in \mathcal{M}} p_{\text{ref},j}$ ；它与质量指标的熵权不同。四个无对应验证损失的领域固定参考占比，其余领域仍不超过参考占比的 2.5 倍。线性目标容易把份额集中到少数有利系数上，故其有界解保留作对照；正式推荐使用已验证的核岭目标，并限制在闭合训练配方的凸包内：

$$\begin{aligned} \min_{\mathbf{a}} \quad & \sum_{d \in \mathcal{M}} w_d \hat{L}_d^K(\mathbf{p}), \\ \text{s.t.} \quad & \mathbf{p} = \sum_{i=1}^{512} a_i \tilde{\mathbf{p}}_i, \quad a_i \geq 0, \quad \sum_i a_i = 1, \\ & p_k = p_{\text{ref},k} \quad (k \notin \mathcal{M}), \\ & 0 \leq p_k \leq 2.5 p_{\text{ref},k} \quad (k \in \mathcal{M}). \end{aligned} \tag{19}$$

其中 $\hat{L}_d^K$ 为核岭预测， a_i 是训练配方的凸组合权重，与线性回归系数不同。该约束保证输出由已有训练配方组合得到，避免仅限制各域上限却进入训练凸包之外；但凸包内部仍可能观测稀疏，不能将支持范围约束当作真实训练收益证明。

我们采用四个固定初值的全校正条件梯度法求解。每步以线性规划寻找可行下降顶点，再在已选顶点的凸组合上修正权重，始终保持配比约束。方向最优性间隙小于 10^{-6} 时停止，另核对份额、上限与固定域残差。四次求解的目标在 10^{-8} 内一致，给出可重复的数值驻点；由于核岭目标并非已证明凸函数，不宣称获得全局最优解。

5.1.4 模型求解

辅助分析说明：本问的文段相关辅助参考腾讯 WorkBuddy 接入的 DeepSeek-V4-Flash (2026-07-31 公开测试)，图表展示、程序整理与复现核对使用 OpenAI Codex (GPT-5.6-Luna, 2026-07-09) [14, 15, 16]。正文表达与段落衔接另经 OpenAI Codex 辅助润色。

本问分别利用 A1–A3 和 A4–A15 开展质量评价与配比计算。质量评分包含 A1 的 51,230 条抽样记录及 A2、A3 的 221,275 条扩展记录，共计 272,505 条。按附件 ID 核对，其中有 261,086 个唯一 ID，11,419 个 ID 在不同文件中各出现两次。本文的全量熵权、领域均分和冲突率均按附件记录计权，重复 ID 的记录也分别参与计算；因此这些记录不应解释为同等数量的独立文本，抽样与扩展集之间也不是完全独立的验证。

1. 质量评分与冲突分析

图3汇总了各领域的质量均值和离散程度，柱高和误差线分别表示领域均值与标准差， n 为对应记录数。对于同时出现在抽样集与扩展集中的领域，表5进一步比较两套评分。




图 3 领域质量评分

表 5 各领域在 A1 抽样集与 A2/A3 扩展集中的质量评分

质量信号领域	训练配方对应领域	A1 评分 Q	扩展集评分 Q	评分差值
arxiv	arxiv	0.7272	0.7248	+0.0024
stackexchange	stackexchange	0.6333	—	—
c4	(配方侧无同名列)	0.6327	—	—
commoncrawl	pile_cc	0.6119	—	—
book	gutenberg_pg_19	0.5592	—	—
wikipedia	wikipedia_en	0.5450	—	—
github	github	0.4498	0.4492	+0.0006

arxiv 与 github 均包含抽样和扩展数据。表5中，两者的评分差值分别为 +0.0024、+0.0006。差值较小，说明在可直接比较的领域内，抽样集与扩展集的平均评分接近。

为解释领域内部的分数差异，我们结合原文抽查进行对照。抽查中，arxiv 的一个低分片段主要由章节格式定义和排版命令组成，评分约为 0.350；一个高分片段则以连贯语句介绍计算机实验的用途，评分约为 0.849。这一差异说明，即使同属 arxiv，文本内容也可能明显不同，不能只凭领域名称判断质量。对预训练语料而言，正文叙述与格式代码在语言信号上差异明显，综合评分会把这种差异反映到单条记录上。

网页语料中也存在可辨认的对照。c4 的一个低分片段反复出现同一家具商品短语，评分约为 0.284；另一个高分片段介绍细胞内不同细胞器的空间分工，评分约为 0.914。这些对照使我们能够从重复程度、句子组织和内容连续性解释评分差异。不过，少量抽查不能替代全量人工标注，总分也不能单独证明某一分类器的方向。

在全量领域均分中，arxiv 的 0.725 与 github 的 0.449 分别位于评分两端。stackexchange、c4、commoncrawl 依次为 0.633、0.633、0.612；book 与 wikipedia 较为接近，分别为 0.559、0.545。这一排序由 22 个质量信号加权得到。例如，rps_doc_frac_unique_words

与 rps_doc_unigram_entropy 均可能随文档长度变化。因此，网页类评分高于书籍、百科，仅表示其在本评分体系下得分较高，不能直接推断其对所有训练任务都更有利。

表6比较各集合的冲突比例和排序一致性；图4则给出分歧较多的指标对及对应的熵权分布。图4左侧展示冲突率最高的 12 对指标关系，边旁数值为冲突率，线宽与其成正比；右侧列出全部 22 项熵权。M01–M22 按表2的指标顺序编号，紫色与青绿色分别对应列表型与标量型指标。

表 6 各数据集的指标冲突比例与排序一致性

统计范围	记录数	冲突比例	独立基准 ρ_0	ρ_c/ρ_0	Kendall W
		ρ_c			
A1 抽样集	51,230	0.2219	0.2888	0.768	0.0854
A2+A3 扩展集	221,275	0.2162	0.2888	0.748	0.0718
全量	272,505	0.2190	0.2888	0.758	0.0761




图 4 指标冲突与熵权

表6显示，抽样集、扩展集及全量记录的冲突率均处于 0.216 ~ 0.222。统计集合的变化未明显改变这一比例。

全量排序经并列秩校正后的 Kendall 系数为 0.076，表明排序一致程度有限。卡方近似的名义概率为 $p < 0.001$ ，但受重复记录和指标相关性的影响，不据此作独立样本下的显著性判断。实际冲突率为 21.9%，低于独立参照的 28.9%，二者比值为 0.758。据此，我们判断指标之间存在共同倾向，但整体一致程度仍然有限。

这些分歧既来自指标含义，也来自计算尺度。rps_doc_unigram_entropy 与 rps_doc_frac_unique_words 都关注词汇多样性，却不使用同一尺度；modernbert_professionalism 对学术文本和论坛内容的反应也可能不同。另如 ad_en，长文档中的二分类概率容易靠近两端。由此，同一文本在不同指标下得到不同评价是可以预期的。

若以“至少一对指标超过阈值”标记文本，则 272,505 条记录中有 271,458 条被标记，占 99.62%；这与 21.9% 的样本-指标对冲突率不是同一口径，也说明该标记不宜直接作为剔除规则。综合裁决使用 Q_i 相对领域中位数的高低，仅记录域内相对标签；该规则不判断某一对指标孰对孰错，也没有验证具体分歧已被消除；计算领域均值时仍纳入这些记录，不删样本或降权。后两问采用聚合评分，不将该标签视为独立的质量真值。

2. 领域配比与损失的拟合及验证

配比拟合的结果依次展示训练配方构成、线性基线与核岭的验证表现、不同训练领域的相对系数，以及同尺度预测和观测损失的对应关系。

图5将前 8 组训练配方的领域占比绘为热图，仅标注占比不低于 10% 的格子；右侧按同一领域顺序列出全部 512 组配方的平均占比。




图 5 训练配方分布

图6分别展示 1M 训练与检验的决定系数，以及 60M、1B 检验的 Pearson 相关系数；连线连接同一验证领域的两个结果。

同尺度下，线性岭回归的训练与检验表现接近。1M 检验的平均 R^2 为 0.619，训练均值为 0.629，训练集各验证域介于 0.42 ~ 0.77。在这一对照中，未出现训练表现明显优于检验的现象。

平均值之外，各验证域的可预测程度仍有区别。现有检验结果中，arxiv 和 dm_mathematics 的 R^2 分别约为 0.430、0.428，pubmed_abstracts 和 pile_cc 则约为 0.788、0.771。我们比较的是配方变化对损失变异的解释程度，并不据此评价四类文本的优劣。例如，数学领域的平均损失较低，并不意味着其损失随配方变化的部分更容易由线性式解释。因此，我们分别报告损失水平、拟合优度和文本质量，避免将三者混为一谈。




图 6 线性岭配比回归检验

在相同五折下，线性基线的综合折外 RMSE 为 0.5761；核岭选择 $\theta = 0.0625$ 、 $\lambda_k = 10^{-4}$ ，对应 0.2558。表7同时列出同尺度与跨尺度结果，所有 RMSE 都在“配方 × 验证域”上汇总， R^2 则先逐域计算再平均。

表 7 线性基线与核岭的配比预测比较

检验尺度	模型	平均域 R^2	综合 RMSE	MAE
1M (256 组)	线性岭	0.6186	0.5232	0.3858
	平方根核岭	0.9454	0.2256	0.1344
60M (256 组)	线性岭	-7.9526	1.6217	1.5142
	平方根核岭	-7.3068	1.5536	1.4721
1B (64 组)	线性岭	-810.7435	3.2569	3.1900
	平方根核岭	-555.8823	2.8676	2.7952

核岭在 1M 检验上的综合误差较线性基线下降 56.9%，13 域平均排序相关由 0.8311

提高至 0.9725。图7左侧按域比较决定系数，右侧每个点对应一组配方的 13 域等权平均损失，虚线表示预测等于观测。先对 13 域取平均后，配方均值 RMSE 为 0.0733，排序相关为 0.9644；因域间误差可能抵消，这一数值不能替代综合 RMSE 0.2256。数学域 RMSE 仍为 0.5817，说明总体改善后仍有局部误差。上述计算与图表由 Codex 辅助实现和核对，运行过程使用附件原始记录及保存的预测明细 [16]。




图 7 核岭同尺度预测与逐域对照

跨尺度时，两种模型的绝对损失均有明显偏差，核岭在 60M、1B 的负 R^2 不能用较高排序相关抵消。因此，核岭用于 1M 同尺度预测及支持范围内的配方选择；系数解释和冗余特征对照仍来自线性近似。问题二、三对核岭损失差的跨来源传递是一项条件假设，而非已经验证的大模型绝对损失规律。

训练与检验表现接近，说明拟合关系在同尺度配方中具有一定稳定性；各任务的误差差异则表明，推荐结果仍依赖评价任务的组成。若应用更重视某个预测精度较低的领域，我们还需单独检查该领域的偏差，不能只依据平均指标推荐。

线性基线的跨规模比较还需考虑损失基准的变化。60M 相对 1M 的损失约为 0.68 倍，直接沿用原损失尺度会影响误差评价。因此，采用 Pearson 相关系数比较变化趋势：60M 检验均值为 0.782，1B 为 0.651。配比变化对应的部分趋势得以保留，但绝对损失预测仍需调整尺度。

我们另行报告 Pearson 相关，是为了检查跨尺度后配方变化趋势是否保留。整体平移或正比例变化可能保留较高相关，却产生较大的绝对误差。因此，趋势相似只能支持方向比较，跨尺度使用系数仍需校准损失水平。

图8以 17 个训练领域为行、13 个验证领域为列，展示全部 221 项中心化回归系数。

颜色表示系数的正负及大小，色标在 $[-1, 1]$ 内为线性映射，其余区间采用对称对数映射；每列仅标注绝对值最大的系数。




图 8 线性岭领域回归系数

图8显示，各训练领域对验证任务的作用并不相同。dm_mathematics、arxiv 等领域在部分任务上对应较低损失，pile_cc、ubuntu_irc 等领域则表现出不同方向。配比选择因而需要结合验证任务权重，不能仅看某一个系数。

图9汇总 1M 检验集的 3,328 个实测与预测数据点，六边形颜色表示分箱内记录数，上方与右侧分别为实测损失和预测损失的频数分布。




图 9 线性岭预测与实测损失

图中仍有记录偏离预测值等于实测值的参考线，因此平均检验精度接近训练精度，并不表示每条记录的预测都准确。

加入 $\bar{Q}$ 后，13 个验证域的平均 R^2 增加 9.8×10^{-5} 。这一差异反映了冗余参数化对岭惩罚的影响，不是质量提供独立信息的证据。我们据此保留原配比回归；质量投入的作用则由问题二、三结合附件 B 的半合成实验另行分析。

文本质量与损失难度并非同一个概念。图10利用 6 个可映射领域，对照 A1–A3 的熵权评分 Q 与损失代理 $Q^{(\text{loss})}$ 的排序。右侧连线连接同一领域在两套口径下的名次，名次 1 表示得分最高。




图 10 质量与损失难度

图10(A) 的评分端点由损失高低确定：dm_mathematics 为 1.000，对应 13 域中的低损失端；ubuntu_irc 为 0.000，对应高损失端。依据 A16 的 direct/near_direct 映射比较两类评分，图10(B) 中的 Spearman 系数为 0.60。arxiv、stackexchange、github 的相对位置较一致，wikipedia、book、pile_cc 则存在差异。较高的文本质量不必然对应较低的拟合难度，因此语料治理采用文本评分，损失预测则单独考虑领域难度。

领域评分在两套分类之间的衔接

A16 将配方领域与质量信号领域建立对应。现有映射中，arxiv、github、stackexchange 为直接对应；wikipedia_en 与 wikipedia、gutenberg_pg_19 与 book、pile_cc 与 commoncrawl 为近似对应。两类映射都利用已有领域评分，但近似对应还依赖语料来源与内容相近这一条件，名称相近本身并不能证明两份语料的质量分布完全相同。

其余 11 个配方领域在质量数据中没有直接对应，现有计算统一使用全局均值 0.4912。这样可以为混合质量指数提供完整的领域向量，但这些领域之间的质量差别并没有由该向量单独辨认。对它们的配比作用，仍须查看回归系数和验证损失，而不能依据相同的代入分数作高低排序。

我们只在 6 个可映射领域中比较两种质量口径的名次，因为这些领域具有明确的文

本评分来源。其余领域使用全局均值代入，若一并排序，会混合代入规则与实际观测。因此，映射后的质量参照与全部验证任务的损失结果分别展示。

混合质量指数随配方变化而变化，其信息由领域评分和占比共同决定。领域评分固定以后，改变配方才会改变该指数；在相同配方内部提升文本质量，则属于另一种投入变化，需要附件 B 的质量实验提供依据。这与前述冗余特征对照的解释一致，也解释了问题一的配比分析如何衔接到后续的质量投入模型。

3. 支持范围内的配比推荐与跨尺度分析

线性有界对照将加权损失从 5.3348 降至 5.1360，但核岭对同一方案的变化预测为 +0.1713，且该方案位于训练凸包之外。我们据此采用式(19)选择配方。核岭预测由参考配方的 4.8173 降至 4.6444，模型内损失差为 -0.1730。保存的非负凸组合权重可重建新配方，约束残差小于 10^{-10} ；表8列出主要调整。相同目标的候选排序检验见第6.2节，推荐的实际训练收益仍需另行验证。

表 8 训练支持范围内的核岭方案与参考方案

训练领域	推荐占比	参考占比	占比变化量
freelaw	0.2421	0.0968	+0.1452
uspto_backgrounds	0.1801	0.0756	+0.1045
dm_mathematics	0.0637	0.0255	+0.0382
wikipedia_en	0.0994	0.0751	+0.0243
hackernews	0.0291	0.0116	+0.0175
stackexchange	0.0640	0.0994	-0.0354
pubmed_abstracts	0.0268	0.0662	-0.0394
github	0.0591	0.1107	-0.0516
arxiv	0.0579	0.1130	-0.0551
pile_cc	0.0000	0.1195	-0.1195

表8中，法律、专利背景、数学和百科份额增加，网络爬取、学术论文与代码份额减少。这是对 13 个验证任务的加权损失所作的条件选择，不是文本质量名次：例如 arxiv 份额下降，不能据此判断学术文本质量较差。表中只列出主要变化，其余领域依约束分配；线性有界对照的完整份额也保存在相应结果表中。

核岭比较的参考配方和推荐配方均闭合为 1；线性基线保留附件原始份额，列均值之和约为 0.999881。这一舍入差异在核岭预测与推荐约束中统一处理。后续算力情景仍采用既有原始均值计算的共同质量基线 $Q_0 = 0.5487$ ，因此只考察配比损失差，不把配方变化同时解释为质量处理成本变化。

图11比较相同配方下的跨尺度损失比。60M/1M 的领域损失比均值处于 0.51 ~ 0.82；外推记录中，10B 的 est/train 因子均值为 0.338，标准差为 0.038，70B 对应的均值与标

准差分别为 0.266、0.036。10B 和 70B 没有新增实测训练记录，这些数值仅用于检查估算比例的稳定性。

图11(A) 的各领域在每个外推尺度下均包含 63 条记录，箱体对应第 25 至第 75 百分位，箱内竖线为中位数，两端须为最小值和最大值；图中比值为外推损失与同配方 1M 训练损失之比。图11(B) 的圆点与误差线分别表示同配方 60M/1M 损失比的均值和标准差。




图 11 跨尺度损失比较

通过上述分析，我们得到领域质量、配比系数及有界推荐方案，作为后续配置的输入。质量名次仍依赖指标选择，跨规模损失仍需尺度校准，这些限制随结果一并保留。

5.2 问题二：跨维度数据融合与广义标度律

5.2.1 具体分析

在参数量和数据量相同时，语料质量与领域构成仍可能影响训练损失。我们将这两类因素纳入规模关系，用以计算质量提升能替代多少参数投入。由于附件 A 主要记录配比，附件 B 主要记录规模与质量，现有资料没有同时覆盖全部变量，因此先核对评分的可比性，再明确配比结果跨来源使用的条件。

本问的计算顺序见图12。Pythia 记录用于估计规模关系，其中较大的模型另作留出检验；质量实验则用于辨别质量项应怎样写入损失函数。确定函数形式后，以弹性比较相对变化的影响，再由等损失条件换算质量与参数的投入增量。问题一的配比系数在这些关系明确之后接入，迁移时所需的条件由跨来源对照加以说明。




图 12 问题二分析流程

5.2.2 模型准备

1. 数据组织与变量口径

规模项的估计数据取自 B1，覆盖 Pythia 的 8 种模型，每种模型保留 147 次检查记录，总计 1,176 条 [17]。B6 半合成实验补充了质量维度，B7 则在剔除与 B6 重复的记录后检查扩展表现。其余附件各有用途：B2 提供另一模型族的训练轨迹，B3 检查插值轨迹与拟合关系是否一致；B4 的收敛点和 B5 的文献记录用于比较跨来源预测；B8 用于诊断质量方向；B9、B10 配对后核对大规模条件下的估算损失。

我们按各组材料能够识别的关系组织拟合。B1 中同一模型随训练推进形成的检查点，能够描述数据量增加时损失怎样下降；不同参数规模的模型则提供了估计规模项的依据。B6 在固定 (N, D) 的条件下改变质量，补充了仅靠训练轨迹无法区分的质量影响。因此，我们先用 B1 估计经典模型，再合并 B1 与 B6 估计广义模型；B2、B4、B5 等来源用于拟合之外的对照，检查跨来源使用这些参数时的偏差。

核对样本构成后，我们保留了对记录依赖关系的区分。同一模型的多个检查点共享训练过程，B3 又由已有检查点插值得到；它们能增加曲线覆盖的密度，却不能按同样数量的独立训练实验解释。B7 中与 B6 重复的部分同理。因此，我们分别报告拟合、留出和跨来源对照结果，区分样本内的贴合程度与其他条件下的预测表现。

记验证集交叉熵损失为 L ，模型变量为参数量 N 、数据量 D 和质量 Q 。本节将 N 、 D 都按十亿为单位记录，问题三计算 FLOPs 时再换回实际参数数和 token 数，即各乘 10^9 。拟合保留常数项 E ，不通过双对数变换处理，以免把不可约损失并入其他项。

统一规模单位也是复用拟合参数的前提。幂函数项中的系数随输入尺度改变，若直接把实际参数数代入以 B 为单位估计的函数，就会改变预测值。本文因此将单位换算放在数据输入与费用计算之间处理：损失预测始终沿用本节的规模单位，训练费用再使用实际数量。不同来源的记录在进入同一函数前，也先核对字段所指的是模型参数数、累计训练 token 数还是其他数量，避免把计量差异误作标度关系的差异。

2. 质量字段方向检验

我们先检验质量高分是否对应较低损失。为控制规模差异，在每个固定 (N, D) 的实验组内计算 Q_{score} 与损失的 Pearson 相关，再求组间算术平均。均值为负时，方向与本文的质量定义相符；均值为正时，则需要进一步检查。表9据此说明方向，不据此作显著性判断。

选择组内相关，是为了减少规模变化的混杂。直接合并不同规模的记录，会把模型扩容、数据增加与质量改善对应的损失变化混在一起。组内对照减少了这一混杂，但相关仍只描述给定实验设置中的共同变化，不能据此证明附件中的评分与问题一综合评分已经处于同一尺度。组间取算术平均也意味着每个有效实验组对方向摘要的作用相同，不按组内记录数再次加权。

表 9 质量评分方向与样本使用方式

数据分组	平均组内 相关系数	记录数 / 实验组数	评分解释与使用方式
B6	-0.925	360 / 45	沿用原评分； $Q = 1$ 为最优参考
B7	-0.918	450 / 45	与 B6 同向，仅新增记录用于检验
B8 校准段	+0.995	984 / 90	方向相反，翻转评分后作诊断
B8 外推段	+0.968	720 / 60	方向相反，不纳入主拟合

注：实验组固定 N, D 。B7 包含 B6 的全部 360 条记录，新增 90 条；均值只描述方向，不表示显著性。

B6、B7 的组内相关均值分别为 -0.925、-0.918，高分对应较低损失，因此保留字段原方向，取 $Q = Q_{\text{score}}$ 。记录核对同时表明，B7 收录了 B6 的全部 360 条数据，另外只有 90 条新增记录，两者不能分别计作独立证据。B8 校准段与外推段都表现为高分对应较高损失，部分记录还越过了模型所能达到的损失下限。对此仅在方向诊断中使用 $1 - Q_{\text{score}}$ 作对照，主拟合不使用 B8。


图13列出各实验组的相关系数。每个圆点为一组固定 (N, D) 的相关，菱形为组间平均；B6/B7 的点多数为负，B8 多数为正，方向差异并非个别组造成。另外，B6 与 B7 点群接近部分来自记录重复，不能把相似图形再算作一次独立验证。

确认方向后，我们进一步核对评分尺度。问题一的综合评分与附件 B 的 Q_{score} 计算方法不同，同为某个分值未必代表同等质量。因此，本节估计质量参数、解释质量增量时，统一使用附件 B 的评分尺度。

5.2.3 模型建立

1. 经典标度律

我们先固定参考质量，采用 Chinchilla 标度律 [2]，把验证损失 L 写成参数量与数据



圆点：一个 (N,D) 组；菱形：组间均值。
均为半合成数据；B7 含 B6，不构成独立证据。

图 13 质量方向检验

量的函数：

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} \quad (20)$$

当 $N, D \rightarrow \infty$ 时，两项规模损失逐渐消失，剩下的就是 E 。参数或数据增加得越多，相应幂函数项越小；下降幅度由 A 、 B 决定，快慢由 α 、 β 决定。这样，在固定参考质量的前提下，便能分别计算扩参数和加数据的收益。

2. 质量项的选择与损失修正

质量可以通过两种方式进入模型：一是改变有效参数或有效数据量，二是单列质量不足带来的损失。我们据此比较四个候选形式，使用同一组联合样本，并查看 B6 拟合、B7 新增点预测相关及残差信息评分，结果列于表10。经典模型与候选模型都保留常数和幂函数结构，参数搜索限定在给定区间内；残差经 $\text{soft-}L_1$ 处理后求和，以减轻少数大残差对估计结果的影响。

四种形式的差别在于如何解释质量不足。将质量乘入数据量，相当于认为同样多的 token 能提供多少有效训练信息取决于质量；同时乘入参数与数据量，则让两类规模收益都随质量调整。两个加性形式保留了规模项，其中 $CQ^{-\gamma}$ 在 $Q = 1$ 时仍保留常数 C ，而 $C(1 - Q)^\gamma$ 在参考质量处恰为零。我们需要在同一规模基线上比较质量增量，因此后者的参考点更便于解释；最终仍以同样本拟合和扩展表现作为选择依据。

表10中，四种质量项形式对 B7 新增点的相关都达到 0.983 以上，单看相关很难取舍。进一步比较联合样本与 B6 的 R^2 后，我们发现加性质量缺口形式均为最高，因而采用该形式。相关系数之外，再用 RMSE、MAPE 衡量预测值的偏差。

辅助比较量记为 $I_{\text{RSS}} = n \ln(\text{RSS}/n) + 2k$ ， n 表示样本数， k 表示参数数。估计采用 $\text{soft-}L_1$ ，并非高斯极大似然，因此不将该值严格解释为 AIC，只在相同样本之间比较。此外，B7 新增点参与过模型形式选择，其扩展检查仍属于开发阶段验证，不是完全独立的最终测试。

参数估计的目标与约束。为统一各候选形式的比较，我们记第 i 条记录的残差为

表 10 不同质量作用形式的拟合与扩展检验指标

比较指标	加性质量缺口 $C(1-Q)^\gamma$	质量同时乘 N 与 D	加性质量亏损 $CQ^{-\gamma}$	质量作为 有效数据乘子
联合样本 R^2	0.9896	0.9882	0.9848	0.9745
B6 样本 R^2	0.9556	0.9495	0.9349	0.8905
B7 新增点 r	0.991	0.991	0.991	0.983
待估参数个数	7	7	7	6
残差信息评分 I_{RSS}	-10236	-10042	-9660	-8866

注：相关系数保留三位小数；加粗的最优指标按未舍入值确定。 I_{RSS} 越小越优，仅用于同样本比较。

$r_i(\boldsymbol{\theta}) = \hat{L}_i(\boldsymbol{\theta}) - L_i$, $\boldsymbol{\theta}$ 为相应形式的待估参数。现有计算所用目标可写为

$$\min_{\boldsymbol{\theta} \in \Theta} \frac{s^2}{2} \sum_{i=1}^n \rho\left(\frac{r_i(\boldsymbol{\theta})^2}{s^2}\right), \quad \rho(z) = 2(\sqrt{1+z} - 1), \quad s = 0.05. \quad (21)$$

残差较小时，该目标近似平方损失；残差较大时，其增长接近线性，因而不会按残差平方的速度持续放大单条记录的影响。其中 s 为求解时设定的残差尺度，不表示验证损失的标准差或置信水平。联合拟合对 B1 与 B6 的记录逐条使用同一目标，没有另外按来源重新加权；各来源的记录数因此仍会影响其在拟合中的作用。结果解释同时保留 B6 单独的评价指标，便于看到加入质量项后质量实验本身的拟合情况。

对选定的加性质量缺口形式， $\boldsymbol{\theta} = (E, A, \alpha, B, \beta, C, \gamma)$ ，已有搜索范围为

$$\begin{aligned} 0 \leq E \leq 5, \quad 10^{-8} \leq A, B \leq 10^3, \quad 0.01 \leq \alpha, \beta \leq 2, \\ 10^{-8} \leq C \leq 50, \quad 0.05 \leq \gamma \leq 10. \end{aligned} \quad (22)$$

正系数与正指数使参数项、数据项随各自规模增加而减小，也使质量缺口项在 $0 \leq Q \leq 1$ 内保持非负。上界用于限定数值搜索，不能当作观测得出的参数区间。广义模型以经典拟合的五个参数为起点，再为 C, γ 赋初值；这提供了从规模基线进入联合估计的衔接方式，并不把经典参数固定下来。最终仍以整个联合样本重新估计七个参数。

将选定的质量缺口项加入规模基线后，损失关系写为：

$$L(N, D, Q) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} + C(1-Q)^\gamma, \quad C > 0, \gamma > 0 \quad (23)$$

质量的参考点设在 $Q = 1$ 。在此处质量项为零，函数便回到经典标度律形式，但联合拟合重新估计各项参数，并不要求数值也回到经典拟合结果。Pythia 没有实测质量，给它取 $Q = 1$ 只是一项参考约定。若固定 Q ，再让参数和数据量同时增大，则有

$$\lim_{N,D \rightarrow \infty} L(N, D, Q) = E + C(1 - Q)^\gamma \geq E \quad (24)$$

只要固定的质量仍低于 1，上式就会保留质量缺口。扩参数、加数据能够压低各自的规模项，却无法在这个加性模型中完全抵消质量不足。该结论来自所选函数的结构，实际使用时仍须限制在有数据支持的范围内。

3. 边际效用与弹性

为刻画各因素微小变化对损失的影响，对广义模型求偏导，并在参考点 (N_0, D_0, Q_0) 处评价：

$$\frac{\partial L}{\partial N} = -\alpha A N^{-\alpha-1}, \quad \frac{\partial L}{\partial D} = -\beta B D^{-\beta-1}, \quad \frac{\partial L}{\partial Q} = -\gamma C(1 - Q)^{\gamma-1} \quad (25)$$

各偏导的单位不同。令参考点的预测损失为 L_0 ，按变量与损失的比例变化定义弹性：

$$\varepsilon_N = \frac{\partial L}{\partial N} \frac{N_0}{L_0}, \quad \varepsilon_D = \frac{\partial L}{\partial D} \frac{D_0}{L_0}, \quad \varepsilon_Q = \frac{\partial L}{\partial Q} \frac{Q_0}{L_0} \quad (26)$$

4. 质量提升与参数扩张的等效条件

我们从同一起点比较两条改善路径：保持 D 与配比不变，分别小幅增加质量或参数；若损失降幅相同，就以所需正向增量之比 R_{NQ} 描述这两种方案：

$$\begin{aligned} \left| \frac{\partial L}{\partial Q} \right| dQ &= \left| \frac{\partial L}{\partial N} \right| dN_{\text{eq}}, \\ R_{NQ} &= \frac{dN_{\text{eq}}}{dQ} = \frac{\gamma C(1 - Q)^{\gamma-1}}{\alpha A N^{-\alpha-1}} = \frac{\gamma C}{\alpha A} (1 - Q)^{\gamma-1} N^{\alpha+1}. \end{aligned} \quad (27)$$

这里比较的是两种改善方案的投入增量。如果沿着同一损失水平移动，则应取 $dN/dQ = -R_{NQ}$ ，含义是质量提高后可减少参数。在 Q 不变时， R_{NQ} 按 $N^{\alpha+1}$ 增长，这是因为大模型再扩容的边际收益较小。上述比较只要求损失效果相等，是否节省算力，还要计算语料处理和训练各自的费用。

对于较大的质量增量 ΔQ ，我们直接计算完整损失差，避免将起点导数用于整个变化区间。记质量改善带来的降幅为 δ_Q ，令参数扩张取得相同降幅，解得

$$\begin{aligned} \delta_Q &= C[(1 - Q)^\gamma - (1 - Q - \Delta Q)^\gamma], \\ \Delta N_{\text{eq}} &= N \left[\left(1 - \frac{\delta_Q N^\alpha}{A} \right)^{-1/\alpha} - 1 \right]. \end{aligned} \quad (28)$$

有限等效解有两个条件。质量增量先要满足 $0 < \Delta Q \leq 1 - Q$ ，保证不越过上界；损失改善还要满足 $\delta_Q < A N^{-\alpha}$ ，因为参数扩张最多只能消除当前的参数项 $A N^{-\alpha}$ 。若两者相等，需要无限参数才能等效；若改善超过这一项，单靠扩容便无解。随着 $\Delta Q \rightarrow 0$ ，完整关系退回 $\Delta N_{\text{eq}} \approx R_{NQ} \Delta Q$ 。即使公式有解，超出拟合规模的数值也仍属外推。

式(28)可从两条改善路径直接得到。质量路径保持参数量为 N ，参数路径保持质量为 Q ，而两者的数据量相同。比较终点损失时，常数项和数据项相消，因此等效条件只剩

$$\begin{aligned} A[N^{-\alpha} - (N + \Delta N_{\text{eq}})^{-\alpha}] &= \delta_Q, \\ \left(1 + \frac{\Delta N_{\text{eq}}}{N}\right)^{-\alpha} &= 1 - \frac{\delta_Q}{AN^{-\alpha}}. \end{aligned} \quad (29)$$

右端表示质量改善量相对于当前参数项的比例扣减。它为正时才能反求有限的正参数增量；越接近零，反求的规模越大。这样，等效关系的可行条件便与参数项本身能够下降的空间对应起来。局部公式和有限公式的差别也在此：局部换算只使用起点导数，有限换算则计入扩容过程中参数边际收益持续降低的影响。两者服务于不同大小的改变量，不能把局部替代率乘以任意质量增量后都视为精确结果。

5. 领域效应的相似性

同一训练领域在不同验证任务上的作用也可能不同。问题一给出了领域 i 、 j 在 13 个任务上的系数向量 $\mathbf{a}_i, \mathbf{a}_j$ 。先减去平均向量，再用余弦相似度比较它们的相对作用：

$$s_{ij} = \frac{\langle \mathbf{a}_i - \bar{\mathbf{a}}, \mathbf{a}_j - \bar{\mathbf{a}} \rangle}{\|\mathbf{a}_i - \bar{\mathbf{a}}\| \|\mathbf{a}_j - \bar{\mathbf{a}}\|} \quad (30)$$

用 17 个领域系数向量的均值 $\bar{\mathbf{a}}$ 作中心后， s_{ij} 接近 1 表示两域对不同任务的相对作用接近，接近 -1 表示方向相反，可能存在任务取舍。但余弦值只保留方向，没有保留幅度，原回归也没有交互项。因此，它能帮助寻找可比较的领域，却不足以证明等量替换无损或混合后有额外收益。

5.2.4 模型求解

辅助分析说明：本问的文段相关辅助参考腾讯 WorkBuddy 接入的 DeepSeek-V4-Flash (2026-07-31 公开测试)，图表展示、程序整理与复现核对使用 OpenAI Codex (GPT-5.6-Luna, 2026-07-09) [14, 15, 16]。正文表达与段落衔接另经 OpenAI Codex 辅助润色。

1. 经典标度律拟合与留出验证

首先用 B1 的 1,176 条记录估计经典模型。图14左侧展示损失与两类规模的关系，右侧比较不同规模模型的残差，拟合得到

$$L(N, D) = 1.6898 + \frac{0.3540}{N^{0.3400}} + \frac{1.2403}{D^{0.2799}} \quad (31)$$

在 Pythia 族内，留出较大模型后预测仍较准确。将最小的 4 个模型用于重估参数，另外 4 个留作预测，检验结果为 $R^2 = 0.9999997$ 、 $\text{MAPE} = 0.005\%$ 。全量拟合的对应结果是 $R^2 = 0.9999998$ 、 $\text{MAPE} = 0.004\%$ ，其 RMSE 为 1.5×10^{-4} 。两种结果接近，说明所考察族内的规模关系较稳定。

这组记录的损失标准差为 0.342，拟合残差标准差仅 1.5×10^{-4} ，二者相差较大。这样的吻合程度只对应当前来源，不能直接推广到其他训练资料。因此，下一步仍以 B4、B5 的外部记录及 B2 半合成轨迹作对照。




图 14 经典标度律拟合

还可从 B3 检查数据量的幂指数。对 8 条插值轨迹分别固定 N ，扣除 $E + AN^{-\alpha}$ 后，将剩余损失 $L - (E + AN^{-\alpha})$ 对 D 作双对数回归。指数落在 $-0.2806 \sim -0.2803$ ，接近模型的 $-\beta = -0.2799$ 。B3 的生成依赖 Pythia 检查点插值，故这项对照只检验同一资料内部的曲线一致性，并未引入独立训练证据。

2. 广义标度律参数估计

再将 Pythia 的规模记录与 B6 质量实验合并，估计表10选出的广义形式。对没有质量实测值的 Pythia 仍按约定取 $Q = 1$ ，各项系数和指数列于表11。

表 11 广义标度律联合拟合的系数与指数

损失组成	系数符号	系数估计	指数符号	指数估计
不可约损失	E	1.6558	—	—
参数规模项	A	0.3808	α	0.3266
训练数据项	B	1.2515	β	0.2767
质量缺口项	C	0.3544	γ	0.9779

注：联合拟合 $R^2 = 0.9896$ ；不可约损失为常数项，不含衰减指数。


表11中的 $\gamma = 0.9779 \approx 1$ ，使质量缺口对应的渐近损失近似线性增加。联合拟合的 RMSE 为 0.036，MAPE 为 0.66%， $R^2 = 0.9896$ 。联合样本加入了质量实验，与经典拟合使用的样本不同，因此两个 R^2 不能直接作差来衡量质量项的收益。

我们不直接比较这两个 R^2 ，因为其分母取决于评价样本相对均值的总平方差。加入 B6 后，损失分布、样本均值和分母均已改变，不能将联合拟合的数值下降归因于质量项。表10在同一联合样本上比较候选形式，才使残差大小具有一致的评价参照；其中再单列 B6，是为了避免仅凭规模记录较多的联合指标判断质量项。

估计结果还与质量参考点有关。对取 $Q = 1$ 的 B1 记录， $C(1 - Q)^\gamma$ 恒为零，因此这部分记录主要约束常数与规模项； C, γ 的质量变化信息来自 B6。联合估计允许规模参数随 B6 的加入一同调整，不能把表11理解为在完全固定的经典模型上单独追加两个质量参数。后续弹性与替代率采用这组联合参数，才与所选损失函数保持一致。

图15说明质量对损失的影响。左图固定 $D = 300\text{B tokens}$ ，用底色和等值线表示不同规模、质量组合的预测损失，空心点为 B6 实验位置；右图以 E 为起点，展示质量不足使损失下限增加多少。

从 $E + C(1 - Q)^\gamma$ 可直接看出损失下限随质量的变化：满分参考 $Q = 1$ 对应 1.656；若只达到 $Q = 0.6$ ，下限为 1.801；降至 $Q = 0.3$ 时，下限为 1.906。



$D=300\text{ B tokens}$ ；空心点：B6 实验位置；底色与等值线：模型预测。

图 15 质量项影响

3. 分层检验与适用范围

为判断拟合参数能够用于哪些配置情景，我们进一步比较不同来源上的预测误差。表12汇总 6 组检验的 MAPE、RMSE 和相关系数，图16展示 $100(\hat{L} - L)/L$ 的分布：负值为低估，正值为高估。为同时看清小误差和大偏差，图中横轴在 $\pm 10\%$ 内采用线性刻度，外侧改用对称对数刻度。

我们联合使用这三类指标，以同时检查变化趋势与数值偏差。相关系数用于查看预测是否跟随样本损失的变化，整体偏高或偏低并不一定明显降低相关；RMSE 保留损失本身的量纲，反映绝对偏差；MAPE 则以各条记录的损失为参照，把误差换成相对比例。相同的绝对误差在低损失记录上对应更大的百分比，因此跨来源比较不能只依赖其中一个指标。图中的带符号相对误差进一步保留了偏差方向，补充了表中取绝对值或平方后无法直接表达的信息。


表12中，B4 的相关为 0.975，B5 为 0.910；相应 MAPE 仍有 8.8% 和 8.0%。由此，我们认为模型保留了部分跨族变化趋势，但其绝对损失预测仍存在迁移偏差。

对于同一半合成设定，B7 的 90 个新增点有 1.6% 的 MAPE，支持质量关系在该设

表 12 按数据性质区分的预测误差与相关性

数据性质	对照样本	记录数	MAPE/%	RMSE	r
真实	B4 跨模型族收敛点	57	8.8	0.293	0.975
	B5 文献标度记录	44	8.0	0.193	0.910
	B7 新增质量实验	90	1.6	0.056	0.991
半合成	B2 Cerebras 轨迹	1,029	33.7	1.245	0.666
	B8 校准段（方向变换）	984	133.4	1.294	0.638
估算	B10 大规模估算损失	128	1.0	0.020	1.000

注：B8 使用 $1 - Q_{\text{score}}$ ；B10 统一取 $Q = 1$ 。B7 属于开发阶段验证，B10 不构成独立实验验证。



相对误差 = $100 \times (\text{预测值} - \text{给定值}) / \text{给定值}$ ；横轴在 $\pm 10\%$ 内线性。
B8 使用 $1 - Q$ ；空心点：中位数；粗线：四分位区间；轮廓：平滑密度。

图 16 分层验证误差

定内作一定扩展。B10 的含义不同：损失本就由估算得到，比较时又统一设为 $Q = 1$ ，所以只检查两种估算是否接近，不检验质量效应，也不属于独立实验验证。

B2 的 MAPE 达到 33.7%；B8 校准段在翻转质量评分后仍有 133.4%，部分损失甚至低于模型渐近下限。可见问题不止是分数方向；损失尺度和数据生成方式不同，也会使这些来源无法直接合并使用。

上述判断还受样本覆盖范围限制。B1 的参数约为 0.07–12B，数据量为 0.134–299.893B tokens；B6 的相应范围为 0.07–11.97B 和 10–600B tokens。对质量效应的判断依赖 B6 的

半合成设定及 B7 新增记录的对照，更大规模的估算资料仅能检查外推关系之间的一致性。

4. 大规模模型的对应与外推范围

B9 提供大模型元数据，B10 提供估算损失，两者先按模型名称和模型族名称配对。B10 的 128 条记录都在 B9 中找到唯一对应，且每对的 N 、 D 相同。B9 共 132 条，剩余 4 条的数据量为 0，又没有 B10 损失，故未进入对照。表13按规模汇总了匹配结果。

表 13 大规模匹配样本的覆盖范围与估算偏差

参数规模区间 N/B	[100, 300)	[300, 1000)	[1000, 10000]
成功匹配记录数	65	43	20
最小数据量 / B tokens	1.3	0.3	0.1
最大数据量 / B tokens	36,000	30,000	36,000
MAPE / %	0.94	1.08	1.12

注：B9 元数据与 B10 损失按名称匹配；统一取 $Q = 1$ ，MAPE 比较本文预测与 B10 估算值。数据量上下限为各组记录的实际极值。

这批记录的规模为 100–10,000B，已经超过主拟合范围。分组误差约 1%，表示本文预测与 B10 估算较接近；但 B10 同样由标度律产生，因此低误差不能代替真实训练检验，更不能说明质量项在这些规模下已经得到验证。

5. 质量投入的局部收益与规模替代

我们选取两个参考配置，比较各项投入小幅变化时的收益。表14同时列出弹性和质量–参数等效增量比，前者比较相同比例变化的影响，后者给出相同损失降幅下的局部换算。

比较两种局部指标时，需要区分质量的相对变化与评分的绝对增量。弹性比较的是 dQ/Q_0 和 dN/N_0 ，而 R_{NQ} 的分母为 dQ ；两者采用的增量口径不同。质量评分又有上界，其相对变化所对应的绝对增量取决于起点评分。因而应用表14时，应先给定起点和改变量，再选择弹性近似或有限等效关系。换到其他 (N, D, Q) 后，表中的数值需要重新评价，不能把某个参考点的换算比例作为固定系数贯穿所有规模。

表 14 两个参考情景下的局部敏感度与等效增量比

	参考情景一	参考情景二
指标	$N_0 = 1, D_0 = 100$	$N_0 = 12, D_0 = 300$
	$Q_0 = 0.6$	$Q_0 = 0.6$
参数量弹性 ε_N	-0.0491	-0.0248
数据量弹性 ε_D	-0.0383	-0.0321
质量弹性 ε_Q	-0.0838	-0.0953
局部等效增量比 R_{NQ}	2.844	76.838

注： N_0 以 B 参数计， D_0 以 B tokens 计；弹性无量纲， R_{NQ} 的单位为 B/单位质量。弹性保留方向，图中展示其绝对值。

在 $(N_0, D_0, Q_0) = (1, 100, 0.6)$ 处，质量弹性绝对值约为参数弹性的 1.7 倍。因此，参数量与质量分别提高同一较小比例时，提高质量对应的损失降幅更大。两个参考点的局部替代率为 2.844 和 76.838 B/单位质量；按一阶近似，0.1 的质量增量分别对应 0.284B、7.684B 参数。这里只比较损失降幅，有限变化仍须用式(28)计算并检查拟合范围，不能据此判断成本。

图17把参考位置的变化展开。前两图分别展示参数、质量的边际导数绝对值，由于单位不同，两图数值不能直接比较。第三图使用无量纲弹性，比较两个参考点上参数量或质量发生相同微小相对变化时的损失响应。




图 17 边际效用与弹性

固定 $D = 300\text{B tokens}$ 后，还可以反求达到目标损失需要的质量，见图18。三个子图各对应一个目标，横轴为参数量，纵轴为质量；实线在主拟合范围内，虚线为外推。

对于 $L = 1.95$ ，图中特别放大了高质量区间，并将参数轴延至 $10^4 B$ 以展示理论边界，这不表示该规模在工程上可行。

我们将边际比较限定在远离质量满分的区间。拟合得到 $\gamma = 0.9779 < 1$ ，使 $|\partial L / \partial Q|$ 在 $Q < 1$ 内逐渐增大，并在 $Q \rightarrow 1^-$ 发散。因此，边际数值只在离端点较远的位置解释，不能直接用满分附近的导数建议实际投入。




图 18 规模与质量替代

6. 领域效应与配比衔接

为观察领域之间的关系，图19左侧按 $d_{ij} = \sqrt{2 - 2s_{ij}}$ 对 17 个训练领域作平均连接聚类；右侧列出相似度最高和最低的各四对领域，用绿色和金色分别表示作用趋同和相反。该图比较的是各域影响验证任务的方式，并不检验混合使用是否产生额外增益。

在图19中，作用接近的例子有百科与网页、医学全文与医学摘要，相似度分别为 0.925、0.903；医学全文与邮件为 -0.967 ，则偏向不同的验证任务。判断领域能否替换时，我们进一步计入系数幅度与任务权重。若从领域 i 转移占比 h 到 j ，保证总量不变且 $0 \leq h \leq p_i$ ，预测加权损失的变化为

$$\Delta \hat{L}_A = h \mathbf{w}^\top (\mathbf{a}_j - \mathbf{a}_i), \quad (32)$$

$\mathbf{w}$ 为验证领域权重。上式为负，表示转移后总体损失下降；为零表示相当；为正则表示变差。相似度接近的两域仍可能有幅度差，方向相反也只说明任务取舍。由于没有建立交互项，不能从这个线性模型再推断额外的混合收益。

使用相同的验证领域和权重，比较问题一推荐配比与参考配比，核岭给出的加权损失差为

$$M = \hat{L}(\mathbf{p}_{\text{rec}}) - \hat{L}(\mathbf{p}_{\text{ref}}) = -0.1730.$$

配比项 M 使用附件 A 的任务和权重计算。把它放入广义标度律，还须假定配比效果可与规模、质量分开，且损失差能够跨来源迁移。前述检验已经显示来源间的偏差，因此 0.1730 是 1M 核岭在训练支持范围内的条件预测差，不是目标规模的实测收益；排序可以迁移也不意味着绝对损失差保持不变。




图 19 领域相似性

在上述分离与迁移条件下，规模、质量和配比的关系可合写为

$$L(N, D, Q, \mathbf{p}) = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^{\gamma} + M(\mathbf{p}),$$

$$M(\mathbf{p}) = \sum_{d \in \mathcal{M}} w_d \left[\hat{L}_d^K(\mathbf{p}) - \hat{L}_d^K(\mathbf{p}_{\text{ref}}) \right]. \quad (33)$$

在参考配比处有 $M(\mathbf{p}_{\text{ref}}) = 0$ 。这里 E 是参考配比下的渐近常数；加入固定配比项后， $N, D \rightarrow \infty$ 且 $Q \rightarrow 1$ 的极限为 $E + M$ ，因此不能再把 E 解释为所有配方共享的绝对下界。配比给定后， M 是一个固定的损失平移量，不改变 N, D, Q 的边际导数，也不改变等损失替代条件；本文的弹性均按参考配比计算。若再使用问题一的质量评分，还需要它与附件 B 的尺度能够衔接，这一点不能单凭加性写法保证。

本问的计算表明，参数规模越大，继续扩容的边际收益越小；质量能够等效替代的参数数量则随起点变化。我们将所选损失函数用于下一问的预算配置。跨族和文献检验仍分别存在 8.8%、8.0% 的 MAPE，故后续使用拟合参数时，也要一并保留质量尺度、数据来源和外推范围的条件。

5.3 问题三：算力约束下的资源配置与结构性转移

5.3.1 问题分析与模型准备

我们在同一训练预算下联合配置参数量、数据量与质量。扩大参数规模会降低参数量损失，同时提高每个 token 的训练费用；改善质量会缩小质量缺口，同时增加整份语

料的处理成本。两项投入都会挤占数据训练预算，因此配置时需要比较直接收益与数据量减少带来的损失。

已有研究给出了固定算力下参数和数据的配置关系 [2]。考虑到题设还包含质量处理与长上下文计算，我们以问题二的损失函数为目标，加入相应费用约束，先求不同预算下的配置，再检验结论对成本形式的依赖。

图20梳理了本问的计算过程。先汇入前两问的质量基线、配比修正与损失参数，再将训练、质量处理和注意力费用写入预算约束。多初值求解后，分别比较三档预算配置、连续预算中的质量投入阶段，以及成本形式和上下文改变时的配置差异。



图 20 问题三资源配置与求解流程

数据与计算口径

本问直接使用问题二估计的损失参数。其中规模项为 $A = 0.3808$ 、 $\alpha = 0.3266$ 、 $B = 1.2515$ 、 $\beta = 0.2767$ ，质量项为 $C_q = 0.3544$ 、 $\gamma = 0.9779$ ，常数项为 $E = 1.6558$ 。质量系数改记 C_q ，以区别预算 C_b 。计算费用时， N 、 D 分别用参数个数与 token 个数；代入损失式时再换成 $n = N/10^9$ 、 $d = D/10^9$ 。下列表格的 B 均表示十亿。

我们在损失拟合与算力核算之间显式换算规模单位。问题二的系数对应以十亿为单位的规模，计算预算时则需恢复绝对数量。因此，成本函数使用绝对数量，求解器以其对数作为决策变量，在计算目标和约束时还原，并按相应单位生成损失预测和结果表。

这样可避免遗漏换算因子或改变拟合系数对应的尺度。后文的一阶条件也先完成系数换算，再对绝对数量求导。

我们先以参考配方确定质量处理的起点。用 A4 的平均配比 $\bar{p}_k$ 加权问题一经 A16 映射的领域评分 Q_k ，得到基线

$$Q_0 = \sum_{k=1}^{17} \bar{p}_k Q_k = 0.5487.$$

该值代表参考配方原有的质量，全量文本均值 0.4912 则留作灵敏度对照。用 Q_A 表示问题一评分、 Q_B 表示附件 B 的质量轴，两者的接口为 $Q_B = h(Q_A)$ 。本问采用恒等映射 $h(q) = q$ ，同时将费用函数定义在该共同数值轴上；这是一项未由配对标定数据识别的衔接假设，并非同向评分天然等价。优化只考虑 $Q_0 \leq Q \leq 1$ ，其中 $Q = 1$ 是模型质量上界，不表示不同来源的满分已获等价验证。

我们以 Q_0 同时作为优化起点和计费参照，只对超过参考质量的部分计算增量费用。领域评分经配比加权后，以单一质量变量进入损失与成本函数。因此，模型给出整体质量与规模的配置关系，尚未细分各领域的清洗、筛选或标注操作；用于语料处理时，仍需将整体目标落实为领域处理方案。配比情景也固定共同基线 Q_0 ，不重新计算 $Q_0(\mathbf{p})$ ，所以这里分别考察损失平移与质量投入，并未求解配方、基线和处理成本同时联动的优化。

为控制情景间的差异，我们先以 $M = 0$ 的参考配比、幂函数型质量成本和 2048 tokens 上下文作基准；之后每次只更换质量成本或上下文。上下文情景依据附件 C7 的架构记录设置：2048、4096、8192、32768、131072 tokens 分别作为给定条件代入预算式，用于比较同一预算在不同上下文要求下的配置。求解器在每个情景内调整参数、数据和质量，不把上下文长度作为自由决策变量。此外，把问题一推荐配比对应的 $M = -0.1730$ 单列为情景，观察预测损失的变化。

5.3.2 模型建立

1. 每个训练 token 的算力代价

基础训练使用 6ND 的成本近似 [2]，质量与注意力费用按照题目第三问及题目附录 B 的成本设定计算。由于三类 $g(Q)$ 在允许范围内均递增，可记质量提升的单位增量费用为 $\Delta g(Q) = g(Q) - g(Q_0) \geq 0$ ，从而将总成本写为

$$C_{\text{tot}} = 6ND + D\Delta g(Q) + \eta NDL_{\text{ctx}} = D \underbrace{[(6 + \eta L_{\text{ctx}})N + \Delta g(Q)]}_{\text{单位 token 的合算力成本}}, \quad \eta = 2 \times 10^{-4}. \quad (34)$$

总费用等于数据量 D 与单位 token 成本的乘积；增加数据时，基础训练、注意力计算和质量处理费用随之按同一数据量计算。质量提升虽然不增加参数，却提高了语料处理单价；达到质量上界后，新加入的数据也仍然需要支付这项费用。

我们保留三项费用共同的数据量因子：基础训练与注意力计算随参数量和数量增加，质量处理按经过处理的 token 数量计费。给定 N, Q 时，增加单位数据的费用不变；

给定 D 时, 质量提升作用于整份语料。由此, 质量费用随处理量累计, 预算消元也同时保留了质量收益与可训练数据量缩减的影响。

表15列出题设的三种质量成本。由于比较的是相对基线的增量 $\Delta g(Q)$, 三种函数在 Q_0 处均不产生额外费用。

表 15 质量处理成本函数 (g 的单位为 FLOPs/token)

成本类型	$g(Q)$	本节用途
幂函数型	$5 \times 10^9 Q^4$	基准配置
指数型	$10^7 e^{6Q}$	成本形式对照
对数渐进型	$2 \times 10^9 \ln(1 + 10Q)$	成本形式对照

2. 预算约束下的配置模型

记 $k = 6 + \eta L_{\text{ctx}}$ 。给定配比和上下文长度后, 以预测验证损失最小为目标, 得到

$$\begin{aligned}
 \min_{N,D,Q} \quad & E + An^{-\alpha} + Bd^{-\beta} + C_q(1 - Q)^\gamma + M, \\
 \text{s.t.} \quad & D[kN + \Delta g(Q)] \leq C_b, \quad Q_0 \leq Q \leq 1, \\
 & 10^5 \leq N \leq 10^{15}, \quad 10^6 \leq D \leq 10^{16}.
 \end{aligned} \tag{35}$$

末尾两项界限用于控制数值搜索范围, 并不表示实际数据供给的上限。每个配比情景中 M 固定, 因而改变配比只会平移预测损失, 不会改变该情景求得的 N, D, Q 。

固定质量且规模界限不活跃时, 增加 N 或 D 都能降低损失, 预算约束因而取等号。将其写为

$$D = \frac{C_b}{kN + \Delta g(Q)} \tag{36}$$

预算式说明, 提高 N 或 Q 后, 能够负担的 D 都会减少。因此, 我们比较一项投入的净收益时, 同时计入其直接降低的损失与数据缩减增加的损失。

我们利用损失关于数据量的单调性判断预算是否用尽。在 N, Q 固定且数据上界未达到时, 增加数据量使 $Bd^{-\beta}$ 下降, 其余损失项不变。如果仍有剩余预算, 就能通过增加数据继续降低目标值。因此, 满足上述条件的解必然位于预算边界上。将数据量消去后, 原来的联合配置转化为在预算边界上比较参数与质量的选择; 这一代数化简用于解释最优条件, 数值程序仍按原三变量约束模型求解。

由式(36)还可分别求得预算固定时的数据变化:

$$\left. \frac{\partial D}{\partial N} \right|_Q = -\frac{kD}{kN + \Delta g(Q)}, \quad \left. \frac{\partial D}{\partial Q} \right|_N = -\frac{Dg'(Q)}{kN + \Delta g(Q)}. \tag{37}$$

两项均为负, 分别对应扩大模型和提高质量带来的数据缩减。质量成本的影响还取决于当前位置的斜率 $g'(Q)$, 因而不能只比较不同成本函数在某一个质量水平上的取值。这也说明, 费用形式相近的情景仍可能产生不同的质量选择。

3. 参数量与数据量的平衡

为统一求导单位, 先令 $\tilde{A} = A(10^9)^\alpha$ 、 $\tilde{B} = B(10^9)^\beta$, 把规模项改写为绝对数量形式。固定 Q 后, 将预算等式(36)代入损失函数, 可得

$$F(N) = \tilde{A}N^{-\alpha} + \tilde{B} \left[\frac{kN + \Delta g(Q)}{C_b} \right]^\beta.$$

此处省略的常数项和质量项在固定质量后不随 N 变化, 不影响导数。参数项的导数为负, 数据项则因预算挤占而产生正导数, 两者相加为

$$F'(N) = -\alpha\tilde{A}N^{-\alpha-1} + \frac{\beta\tilde{B}k}{C_b^\beta} [kN + \Delta g(Q)]^{\beta-1}. \quad (38)$$

令该式为零, 再乘以 $[kN + \Delta g(Q)]/k$, 并用预算等式替换数据项, 即可得到参数与数据损失的平衡关系。对应的平衡式为

$$\alpha\tilde{A}N^{-\alpha} \left(1 + \frac{\tau(Q)}{N} \right) = \beta\tilde{B}D^{-\beta}, \quad \tau(Q) = \frac{\Delta g(Q)}{k}. \quad (39)$$

为解释式(39), 可把 $\tau(Q)$ 看作质量费用折算出的附加参数规模, 它与 N 单位相同。因而, 因子 $1 + \tau/N$ 表示额外质量处理对规模平衡的影响。一旦为质量付费, 原本只在参数与数据之间分配的方案就需要随之调整。

作为对照, 保持基线质量时有 $\tau = 0$, 于是 $\alpha\tilde{A}N^{-\alpha} = \beta\tilde{B}D^{-\beta}$ 。将其与 $kND = C_b$ 联立, 在上下文固定时得到

$$N^* \propto C_b^{\beta/(\alpha+\beta)}, \quad D^* \propto C_b^{\alpha/(\alpha+\beta)}. \quad (40)$$

不额外提高质量时, 数据量随预算增长稍快于参数量: 两者的指数分别约为 0.541、0.459。这只是基线质量下的参照; 开始投入质量后, 应回到包含处理费用的完整模型计算。

基线幂律的比例系数也可由同一组方程求出。将 $D = C_b/(kN)$ 代入平衡条件, 得到

$$\begin{aligned} (N^*)^{\alpha+\beta} &= \frac{\alpha\tilde{A}}{\beta\tilde{B}} \left(\frac{C_b}{k} \right)^\beta, \\ N^* &= \left(\frac{\alpha\tilde{A}}{\beta\tilde{B}} \right)^{1/(\alpha+\beta)} \left(\frac{C_b}{k} \right)^{\beta/(\alpha+\beta)}, \\ D^* &= \left(\frac{\beta\tilde{B}}{\alpha\tilde{A}} \right)^{1/(\alpha+\beta)} \left(\frac{C_b}{k} \right)^{\alpha/(\alpha+\beta)}. \end{aligned} \quad (41)$$

因此, 预算通过幂指数决定规模的增长速度, 系数比值决定具体配置水平。上下文固定时, k 只进入有效预算因子; 质量费用不为零时, 预算中多出无法并入 kN 的处理项, 基线表达式便不再适用于完整配置。因此, 该解析式只适用于没有质量增量费用的参照情形, 用来解释规模权衡; 完整配置仍由含质量费用的预算模型求解。

质量选择也可在同一预算边界上解释。当预算约束活跃、数据量未触及搜索上下界且 $Q_0 < Q < 1$ 时, 固定 N 并对消去数据量后的损失求导, 质量最优的必要条件为

$$\frac{\beta\tilde{B}D^{-\beta}g'(Q)}{kN + \Delta g(Q)} = \gamma C_q(1 - Q)^{\gamma-1}. \quad (42)$$

式中左侧是质量提升挤占数据预算后增加的损失，右侧是质量改善直接减少的损失。我们据此将内部配置解释为两项边际作用相抵的结果。若解位于基线或质量上界，应结合允许的变化方向判断，不能要求上述等式成立。尤其在上界处，质量项的导数性质与内部不同。因此，本问的阶段位置仍依据后文的预算扫描确定，一阶条件用于解释内部配置的局部权衡。

4. 数值求解与阶段识别

我们采用 SciPy 的 SLSQP 实现 [18] 求解式(35)，以 $\ln N$ 、 $\ln D$ 缩小变量尺度差异，并将预算不等式等价写为 $1 - C_{\text{total}}/C_b \geq 0$ ，避免约束绝对量级过大；停止条件取 $\text{ftol}=10^{-14}$ ，单次求解最多迭代 1500 次。三档预算各设 8 组初值，连续预算扫描各设 5 组，从求解成功的结果中选取损失最低的一组，记作 (N^*, D^*, Q^*) 。这样可降低初值和局部解的影响，但不能保证全局最优。另因 $\gamma < 1$ 时 $Q = 1$ 的导数无界，将达到该上界的配置作为边界解处理。将保存的配置重新代入成本函数，三档预算、上下文敏感性与全部 141 个预算扫描点的最大相对预算残差均小于 10^{-12} 。这些数值核验说明记录的配置满足预算约束，但只验证可行性，不构成对全局最优性的证明。

对数变量使参数量与数据量的正值约束自然满足，原有规模上下界相应转换为对数区间。实际初值设置让参数量与数据量沿相反方向变化，同时使质量起点分布在允许区间内部，以比较不同资源组合出发后的求解结果。每次求解都保留总预算不等式和质量边界，而不是先独立确定三项投入后再缩放预算。成功状态用于筛选候选结果，边界配置则保留其实际质量值；未记录成功结果的预算点不参与后续阶段定位。多初值比较用于同一预算下的候选选择，相邻预算点仍分别求解，阶段变化依据有效输出识别。

质量投入的阶段用完成度 $\Theta = (Q^* - Q_0)/(1 - Q_0)$ 表示，质量处理占预算的份额用 $f_Q = D^* \Delta g(Q^*)/C_b$ 表示。完成度为 0 时维持基线，介于 0、1 时正在提升，等于 1 时达到上界。计算在 10^{18} – 10^{25} FLOPs 内设置 141 个对数等距点，相邻预算之比约为 1.122，逐点寻找首次投入与首次饱和的位置。采用无量纲预算约束后，141 个网格点均取得有效配置，阶段分析使用全部输出。

我们同时观察完成度与费用份额，以区分质量提升的进度和资源支出。前者以可提升的质量区间为分母，后者以总预算为分母；质量不变时，规模调整仍可能改变费用份额。因此，质量曲线变平不表示处理费用消失，阶段位置也只能由有效预算网格点定位。

5.3.3 模型求解

辅助分析说明：本问的文段相关辅助参考腾讯 WorkBuddy 接入的 DeepSeek-V4-Flash (2026-07-31 公开测试)，图表展示、程序整理与复现核对使用 OpenAI Codex (GPT-5.6-Luna, 2026-07-09) [14, 15, 16]。正文表达与段落衔接另经 OpenAI Codex 辅助润色。

1. 预算增加后，质量与规模如何分配

比较表16中的三档配置，我们发现各项投入并未按相同比例增长。参数和数据都在增加，但数据更快， D/N 由 30.9 升到 76.1。质量在低预算档停留于基线，中、高预算档则达到上界，不能简单地按固定比例同时扩张三项投入。

表 16 三档预算的基准配置（幂函数型成本， $L_{\text{ctx}} = 2048$ ， $M = 0$ ）

预算 (FLOPs)	N^* (B)	D^* (B tokens)	Q^*	L^*	D^*/N^*	f_Q (%)
10^{19}	0.225	6.9	0.549	3.171	30.9	0.0
10^{22}	6.091	229.4	1.000	2.145	37.7	10.4
10^{24}	44.939	3417.8	1.000	1.897	76.1	1.6

为定位质量投入的阶段变化，我们继续沿用幂函数型成本、 $L_{\text{ctx}} = 2048$ 、 $M = 0$ 作预算扫描。图21左侧为完成度，右侧为三类费用份额，内嵌小图放大了质量提升区间。两条竖线对应首次启动和首次饱和的有效网格点；曲线连接逐点求解得到的记录。




图 21 预算与费用份额

低预算的有效解都保持 $Q^* = Q_0$ 。此时 93.6% 用于基础训练，6.4% 用于注意力计算。虽然提高质量可降低质量项损失，但它会占用原本可用于数据训练的费用；在当前成本设定下，数值比较选择维持基线。

费用份额的变化可进一步从预算等式得到解释。记基础训练和注意力的份额分别为 f_{train} 、 f_{attn} ，预算充分使用时有

$$f_{\text{train}} = \frac{6N^*}{kN^* + \Delta g(Q^*)}, \quad f_{\text{attn}} = \frac{\eta L_{\text{ctx}} N^*}{kN^* + \Delta g(Q^*)}, \quad f_{\text{train}} + f_{\text{attn}} + f_Q = 1. \quad (43)$$

上下文固定时，基础训练与注意力的费用比保持不变。质量投入出现后，这两项在总预算中的份额会共同受到压缩，但彼此的比例仍由上下文决定。因此，图中的三类份额并非能够任意调整的三个独立变量，其变化受到成本结构的约束。

质量投入的两个变化位置可以从扫描点看出。到 1.58×10^{19} FLOPs，首次出现额外质量费用；到 7.08×10^{19} FLOPs，质量达到上界，费用份额也升至峰值 40.7%。在后一

位置之前，最近有效点的质量约为 0.956。结合相邻点，启动区间为 $[1.41, 1.58] \times 10^{19}$ FLOPs，饱和区间为 $[6.31, 7.08] \times 10^{19}$ FLOPs。这些是当前网格的定位范围，精确临界值并未由扫描确定。

达到质量上界后， Q 已不能继续增加，新增预算主要用于扩参数和数据。此时单位质量费用固定为 $\Delta g(1)$ ，预算关系给出

$$f_Q = \frac{\Delta g(1)}{kN^* + \Delta g(1)}.$$

达到上界后，模型越大，质量费用份额越小，至 10^{24} FLOPs 约为 1.6%。这是训练费用增长更快造成的，不能理解为质量处理总支出减少，因为每个新增 token 仍承担同样的处理费用。质量不再增加也来自上界约束，而非边际收益归零；问题二估计的 γ 仍小于 1。

2. 低预算的质量选择取决于成本形式

我们进一步更换质量成本形式，检查上述阶段是否依赖幂函数设定。保持 $L_{\text{ctx}} = 2048$ 、 $M = 0$ ，用表15的三种函数分别求解。图22对照九组结果的质量及费用份额，表17列出对应规模配置。




图 22 成本函数比较

在 10^{19} FLOPs 时，幂函数成本得到的质量是 0.549，指数型为 0.660，对数渐进型直接达到上界。三种预测损失只差约 0.058，质量费用份额却从 0 跨到 31.7%，其中对数渐进型最高。因此，不能只凭损失接近就认为投入方案也相同。

我们从累计费用和增量费用两方面解释情景差异。累计费用决定给定质量水平下还剩多少预算用于训练，成本斜率则进入式(42)中的局部权衡。三种函数的系数和变化形态共同作用，不能仅凭“指数型”或“对数型”的名称判断哪种方案始终更贵。表中结果均在相同预算、上下文和配比下取得，能够用于比较题设成本情景；它们并未提供实际清洗流程的计费测量，也不能据此确定某种具体处理技术更优。

中、高预算档都出现 $Q^* = 1$ ，但这并没有消除成本形式的影响。例如 10^{22} FLOPs 下，三类成本对应的数据量从 229.4B 到 274.1B tokens，相差约 19.5%。所以，低预算基准方案不能直接照搬到其他成本条件；即使质量都达到上界，参数与数据也仍需重新计算。

表 17 三类质量成本下的配置对比 ($L_{\text{ctx}} = 2048$, $M = 0$)

预算 (FLOPs)	成本类型	N^* (B)	D^* (B tokens)	Q^*	L^*	f_Q (%)
10^{19}	指数型	0.266	5.1	0.660	3.163	13.1
	幂函数型	0.225	6.9	0.549	3.171	0.0
	对数渐进型	0.355	3.0	1.000	3.113	31.7
10^{22}	指数型	5.972	237.8	1.000	2.144	9.0
	幂函数型	6.091	229.4	1.000	2.145	10.4
	对数渐进型	5.528	274.1	1.000	2.139	2.9
10^{24}	指数型	44.797	3437.6	1.000	1.897	1.3
	幂函数型	44.939	3417.8	1.000	1.897	1.6
	对数渐进型	44.300	3508.8	1.000	1.897	0.4

3. 长上下文如何改变配置

上下文延长会使式(34)的 k 增大。把注意力费用与基础训练费用相除, 得到 $\lambda = \eta L_{\text{ctx}}/6$, 令这一比值为 1, 可求出两项费用相等的位置:

$$L_{\text{crit}} = \frac{6}{\eta} = 30,000 \text{ tokens.} \quad (44)$$

该长度只表示两项训练费用相等。实际配置还受到质量费用影响, 故进一步固定 10^{22} FLOPs 预算, 比较表18中的五档上下文结果。

表 18 上下文长度敏感性 ($C_b = 10^{22}$ FLOPs, 幂函数型成本, $M = 0$)

L_{ctx} (tokens)	λ	N^* (B)	D^* (B tokens)	Q^*	L^*	注意力份额 (%)
2048	0.068	6.091	229.4	1.000	2.145	5.7
4096	0.137	5.898	223.4	1.000	2.149	10.8
8192	0.273	5.563	212.6	1.000	2.157	19.4
32768	1.092	4.319	170.2	1.000	2.194	48.2
131072	4.369	2.705	109.1	1.000	2.273	77.3

在五档上下文下, 最优质量均为 1, 额外注意力费用主要压缩了规模投入。上下文由 2048 增至 131072 tokens 时, 注意力份额由 5.7% 升至 77.3%, 参数量和数据量分别减

少约 55.6%、52.5%，损失增加约 0.128。32768 tokens 时注意力费用虽已超过基础训练费用，仍只占总预算的 48.2%，因为质量处理也占用预算。

我们将这一损失变化解释为满足更长上下文要求的预算代价。当前损失式中没有单独描述长上下文对任务能力的收益，上下文通过计算费用影响可行的规模与质量配置。因此，表中损失随上下文增长，不能用于评价长文本任务是否值得采用更长上下文。实际应用时，应先根据任务确定上下文要求，再在给定长度下选择配置；不同情景的损失不能直接用于判断任务能力的全面优劣。

图23给出更密集的上下文扫描，仍使用幂函数型成本和 $M = 0$ 。左图固定 10^{22} FLOPs，方形点标明 C7 的五档；右图比较三个较低预算，其中 10^{20} 与 10^{21} FLOPs 的质量曲线重合。竖线表示 L_{crit} 。连续上下文扫描的 40 个点和三档预算下的 42 个质量配置点均求解有效，曲线连接相邻扫描记录。




图 23 上下文敏感性

低预算的质量变化则不同。图23右图中， 10^{19} FLOPs 的质量由 0.549 上升到约 0.671。按题设，质量处理总费用与数据量 D 成正比；上下文延长后，可负担的数据变少，处理整份语料所需的费用也改变了，因此质量与规模之间的取舍随之变化。这一解释依赖当前的数据量成本关系。

4. 配比收益与结果适用范围

领域权重同样影响预训练效率 [19]。在本模型中，它通过固定项 M 体现：在 10^{22} FLOPs 预算下，替换为问题一的推荐配比后， N, D, Q 均不变，而预测损失由 2.1451 降至 1.9721。若保持参考配比，用现有二分计算达到同一损失，约需 1.691×10^{23} FLOPs，约为原预算的 16.9 倍。该倍数由固定损失平移假设得出，表示模型内的等效预算；若该假设幅度仅保留 0%、25%、50%、75%，同一计算给出 1.00、1.81、3.49、7.30 倍。这些保留比例是敏感性情景，没有概率含义；要跨规模使用仍须满足问题二的迁移条件，不能把它当成实际训练加速比。

配比情景与成本情景作用于模型的不同位置。固定的配比修正只改变目标函数的常数项，对参数、数据和质量求导时均消去，因此在同一成本约束下保留原有配置。更换质量成本或上下文则会改变预算边界，即使损失函数的估计系数不变，也需要重新比较

可行配置。据此，我们将推荐配比下“配置不变、损失下降”归因于模型的加性设定；它并不证明真实训练中的配比与规模选择相互独立。

质量未到上界时，新增预算同时影响质量和规模；达到上界后，质量处理继续付费，预算份额随模型扩大而降低。低预算尤其依赖处理成本，上下文则通过训练单价改变可用的数据量。把这些数值用于实际训练，还需核对评分尺度和外推范围，并确认高预算所需语料能否取得。数据受限训练研究已指出，重复使用数据的收益会递减 [20]。本文尚未加入供给与重复训练约束，高预算解因此作为理论情景使用。

各情景共同采用问题二的点估计参数，结果表刻画的是这些参数给定时的配置差异。参数估计误差尚未转换为配置区间，因而表中精确到小数位的规模不应被理解为同等精度的工程需求。本文能够支持的是在既定评分、损失与费用关系下比较投入方向；实际资源安排还需结合可用语料、模型架构及任务要求判断这些条件是否成立。

5.4 问题四：技术演进分析与能力前沿条件预测

5.4.1 能力度量与数据组织

前三问研究训练损失，本问研究模型的实际评测得分。评分方式可能使连续的能力变化呈现为表观突变 [21]，因此不能把分数曲线的形状直接解释为模型机制的变化。我们先检验损失与得分的关系，再将历史增长分解为规模项与非规模项，最后预测未来能力前沿。由于评测体系和样本来源并不完全一致，综合分数与单项任务结果同时保留：前者用于比较整体水平，后者用于寻找具体短板。

图24按数据用途列出四条分析路径。损失与得分的分层回归用于判断变化方向；历史增量分解与未来预测直接使用评测得分，其中规模、年度回归的系数也用于结构情景。子任务结果用于定位能力短板，宏观资料则单独提供资源趋势参照。

辅助分析说明：本问的文段相关辅助参考腾讯 WorkBuddy 接入的 DeepSeek-V4-Flash (2026-07-31 公开测试)，图表展示、程序整理与复现核对使用 OpenAI Codex (GPT-5.6-Luna, 2026-07-09) [14, 15, 16]。正文表达与段落衔接另经 OpenAI Codex 辅助润色。

1. 综合得分、许可筛选与时间变量

综合分数 $\bar{B}$ 定义为 Open LLM Leaderboard v2 六项评测的平均值，满分 100 [22]。六项包括 IFEval、BBH、MATH Lvl 5、GPQA、MUSR 和 MMLU-PRO，分别对应指令遵循、综合推理、数学、研究生级问答、多步推理和专业知识。其中，IFEval 用可验证指令衡量遵循要求的程度 [23]；MMLU-Pro 增加推理要求并扩展选项数量，考察较高难度的知识与推理表现 [24]。本文沿用附件中的评测结果，用平均值追踪整体变化，再用单项得分识别相对薄弱的能力维度。

我们对六项得分赋予相同权重，以形成可比较的综合分数。不过，均值会掩盖能力构成：总分接近的模型可能分别擅长数学和指令遵循。因此，前沿曲线仅描述综合水平，六维分布与子任务统计则用于补充各项能力差异，不改变综合分数的定义。

近期变化采用 C1，长期趋势用 C3 作为补充。时间变量按评测记录的时间字段定义：年度回归取 $t = \text{年份} - 2019$ ，月度前沿用月中点 $t = \text{年份} - 2019 + (\text{月} - 0.5)/12$ ，C3 的年度记录放在年中。这样既能比较规模和年度变化，也不把年度资料误当成精确到月的观测。

C1 的时间字段为 Submission Date，表示记录提交的时间。因此，同一月份的样本是这一时间口径下可观察到的评测记录，不能据此确定各模型完成训练或实际发布的先后。月度聚合有助于减少具体提交日的影响，年度回归则进一步概括较粗的时间差异；两者都沿用原始记录的时间含义。将年份改写为从 2019 年起算，只是改变时间原点，便于与 C3 的历史段连接。




图 24 问题四技术演进与能力前沿分析流程

表19展示了主样本的筛选过程。先去掉关键字段不完整的记录，再按许可白名单保留本文讨论的开放权重模型。白名单包括 apache-2.0、mit、gpl-3.0、cc-by-4.0、mpl-2.0、bsd-3-clause、cc-by-sa-4.0、openrail，以及 llama2、llama3、llama3.1、llama3.2、llama3.3、gemma。其他或未知许可不进入主样本；进入白名单只说明符合本研究的筛选条件，不表示这些许可的具体要求完全相同。

表 19 主样本的形成及模型类型构成

数据层次	记录数	判定依据或构成
C1 原始记录	4,576	六维得分均完整；日期覆盖 2024-06 至 2025-03
完整性筛选后	4,561	日期、参数量和六维得分齐备，排除 15 条记录
许可白名单主样本	2,346	以 Hub License 字段匹配许可集合
预训练类	231	pretrained 与持续预训练模型
对话及微调类	1,497	chat 与领域微调模型
其他类型	618	包含 611 条合并模型记录和 7 条多模态记录

三类模型均保留在主样本中，类型只用于分组比较。为了解预训练与后训练的差别，再分别拟合预训练类、对话及微调类的规模和时间系数。C3 的历史记录按六维得分一致性及参数有效性筛选，没有重复使用 C1 的许可白名单，因而长期样本不是同一批开放权重模型的连续追踪。

我们先检查完整性，使规模、时间和得分逐行对应，再用许可条件限定研究范围。排除不满足条件的记录，并不表示这些模型能力较低。表19所列数量也均以记录为单位，同一模型的多次提交可能形成多条记录，故不能将主样本数量解释为独立训练实验的数量。按类型分组后，比较对象仍是相应记录集合。

2. 从原始评测记录到子任务样本

C8 用来补充综合分数看不到的任务细节。其 1,863 个模型目录共有 1,958 个 JSON 文件，优先读取每个目录的最新文件，失败后再回退，最终 1,860 个目录得到有效结果，3 个没有可用记录。每个任务先检查 `acc_norm` 是否为数值；若无法取用，再依次检查 `acc`、`prompt_level_loose_acc`、`inst_level_loose_acc` 和 `exact_match`，取首个可用值并换算为百分制。名称规范化后，与主样本对应 964 个目录，汇总 BBH 24 项、MATH-Hard 7 项、GPQA 3 项、MUSR 3 项，共 37 项任务，各项有效样本数为 961–964。

文件回退与指标回退处理的是两个层次的问题。前者在文件读取异常，或结果字段缺失、为空、结构不符时，尝试同一目录中的其他文件；后者应对不同任务采用不同指标字段的情况。每个目录保留一份通过结构检查的结果，每个任务按固定优先级取值，而不在多个字段中挑选最高分。文件被接受后，某项任务的指标缺失不会再触发文件回退；该任务值在相应统计中排除，不作为零分加入均值或排序。

C8 保留的是任务原始指标，C1 则对汇总分数作过基准调整，两者不能直接混算。GPQA 的随机基线为 0.25，MMLU-PRO 为 0.10，原始比例 s 分别换成 $(s - 0.25)/0.75$ 、

$(s - 0.10)/0.90$ ；IFEval 还对严格判定下的提示级和指令级结果求平均。因此，C1 用来比较综合能力，C8 用来比较任务内部表现。

两套结果的名称匹配见表20。C1 中同名模型可能有多条记录，配对数因此不等于独立模型数。六项的 Spearman 系数均超过 0.81，多数超过 0.97，说明排序大致相近；BBH、GPQA、MUSR 的平均绝对差却较大，表明任务构成和归一化口径仍会影响绝对分数。

我们按分析目的区分两种匹配集合。表20以完整 C1 记录与 C8 对照，用来检查两个来源在排序和分值上的关系；后续子任务分析则限定在许可筛选后的主样本所对应的目录中。前者按有效记录配对计数，后者按可用目录及任务计数，因此表中的配对数量大于子任务目录数量并不矛盾。名称规范化只是统一匹配键，无法把重复提交自动转化为相互独立的观测。

表 20 C8 原始指标与 C1 汇总得分的记录级相关性及绝对偏差

评测维度	有效配对 记录数	秩相关 ρ	线性相关 r	平均绝对 偏差 / 分
IFEval	1,896	0.987	0.987	2.88
BBH	1,898	0.997	0.998	21.06
MATH Lvl 5	1,897	0.812	0.803	3.47
GPQA	1,894	0.992	0.987	23.38
MUSR	1,894	0.977	0.973	30.73
MMLU-PRO	1,896	0.998	0.998	7.56

5.4.2 损失与评测得分的分层联系

为判断前三问的损失变化能否对应评测能力，我们先在可比数据中检验二者的关系。设验证损失为 L ，采用线性映射估计变化方向及预测误差：

$$\bar{B} = a + bL \quad (45)$$

C6 的高可比层主要由同模型、同验证集的 Pythia 记录构成，可与附件 B 对照；中可比层来自不同模型族和技术报告，验证集并不统一。两层分别采用最小二乘拟合，再把合并结果与 C5 对照，以区分同模型、同验证集记录与跨模型族记录的拟合结果。图25中的散点为 C6 记录，直线为各层拟合结果；两个面板的纵轴范围不同。

我们分层拟合，是因为交叉熵损失依赖验证语料和计算口径，不同来源的相同损失值未必具有相同含义。高可比层减少了部分条件差异，中可比层扩大了模型范围。分别报告斜率和误差后，能够检查扩大范围带来的换算偏差，避免合并拟合掩盖来源差异。各层的样本量、斜率与误差汇总于表21。




图 25 损失与得分映射

表 21 不同可比性样本中损失-得分回归的斜率、相关性与误差

评价量	C6 高可比 $n = 7$	C6 中可比 $n = 68$	C6 合并 $n = 75$	C5 对照 $n = 43$
损失斜率 b	-0.882	-19.185	-20.417	-16.155
Pearson r	-0.397	-0.502	-0.510	-0.502
Spearman ρ	-0.607	-0.509	-0.549	—
决定系数 R^2	0.16	0.25	0.26	—
MAPE / %	5.6	57.3	67.8	—

图25与表21呈现了负相关，但换算精度有限。合并样本有 $R^2 = 0.26$ 、MAPE 67.8%，Pearson $r = -0.510$ 、Spearman $\rho = -0.549$ 。中可比层混用了不同验证集，低分记录还会放大相对误差；高可比层虽仅有 5.6% 的 MAPE，却只有 7 条记录，得分集中于 5.07 ~ 6.06。这一窄范围尚不足以支持高能力模型的损失-得分换算。

相关系数、决定系数与相对误差在这里分别回答不同问题。相关系数用于判断共同变化的方向，决定系数衡量直线对当前得分差异的解释程度，MAPE 则把预测偏差相对于各自得分进行比较。高可比层得分集中，即使预测值靠近样本均值，相对误差也可能较小；这不足以说明斜率在更宽的能力范围内仍然适用。因此，我们结合样本量和得分范围判断表21中的误差，不以较低 MAPE 单独认定映射有效。

基于上述误差，我们仅用该关系判断损失降低与得分提高的共同趋势，不将具体损失降幅换算为能力增量。跨模型的相关也不能证明资源调整具有因果效果。历史增量与未来前沿都直接从 Benchmark 得分计算，以免继续传递换算误差。

5.4.3 规模关系与历史增量分解

1. 控制年份后的规模关联

令 P_{it} 表示模型参数量，单位为十亿参数。对模型记录同时放入规模和时间变量，并以年份固定效应作对照：

$$\text{Score}_{it} = b_0 + b_P \log_{10} P_{it} + b_t t + \varepsilon_{it} \quad \text{或} \quad \text{Score}_{it} = \alpha_t + b_P \log_{10} P_{it} + \varepsilon_{it} \quad (46)$$

在控制年份后， b_P 表示参数扩大十倍对应的得分差；控制规模后， b_t 表示年度标签每增加 1 对应的得分差异， α_t 则吸收某一年度共同存在的差异。它们是条件关联，不能进一步拆成数据工程、网络结构或对齐技术各自带来的因果贡献。

我们对参数量取常用对数，以比较按相同倍数扩大的模型。相同的参数倍数变化在对数轴上对应相同距离，因而规模系数可以用于比较不同起点下的相对扩张。年度项则概括规模相近时不同年份记录之间的差异，其中还可能包含模型类型和收录构成的变化。因此，我们将年度系数解释为不同年份记录的条件差异，不将其视为同一模型延长一年训练的收益。

主样本中，2024 年有 1,588 条记录，2025 年有 758 条，共涉及 2,294 个原始模型名称，没有同名模型跨两个年份出现。因此我们估计的是带年份控制的记录级横截面关系，并非同一模型的纵向变化。只有两个年份时，线性年度变量与年份固定效应本来就会给出相同变化，不能把相同的 R^2 当成独立验证。图26按记录年份分组展示散点，两条直线采用相同的规模系数及各自的年份效应；表22则比较不同模型类型。




图 26 规模与年度效应

全样本的规模和年度系数为 13.842、4.844；预训练类为 6.414、1.552；对话及微调类为 14.853、4.680。这些分组系数表明，解释全样本回归时需要考虑模型类型的构成。由于没有同一模型微调前后的受控对照，不能直接把差异归因于微调效率；线性式在很小参数端还可能给出负分，因此这里只将它作为规模关系的概括和增量核算工具。

表 22 全样本与类型子样本的规模、时间系数

样本与时间设定	n	b_P 分/十倍参数	b_t 分/年度标签	R^2
主样本，年份固定效应	2,346	13.842	—	0.475
主样本，线性年度项	2,346	13.842	4.844	0.475
预训练类，线性年度项	231	6.414	1.552	0.460
对话及微调类，线性年度项	1,497	14.853	4.680	0.484

2. 长周期与近端窗口的贡献核算

我们采用 shift-share 分解核算历史增量，将前沿得分变化拆为规模项与剩余项：

$$\Delta F = \underbrace{b_P \Delta \log_{10} P_{\text{frontier}}}_{\text{规模代理项}} + \underbrace{[\Delta F - b_P \Delta \log_{10} P_{\text{frontier}}]}_{\text{非规模剩余项}} \quad (47)$$

非规模项由总增量减去规模项得到，因此其中既包括技术变化，也可能吸收样本替换、未观测因素和测量差异。分别除以总增量后，得到两部分的占比。

这一分解按得分变化进行核算。先由选定窗口确定前沿的总增量，再把该窗口的参数对数变化代入规模系数，得到规模项；剩余部分归入非规模项，使两部分之和回到同一总增量。分解式本身不增加新的观测，也不单独估计某种技术的效果。因此，我们分别说明各窗口的前沿定义、规模代表值及系数来源，再比较其增量占比。

长期和近期使用的前沿定义不同。C3 取年度累计最高分，并沿用产生该分数的模型参数量；得分并列时保留先达到的前沿记录，同一年并列时先取参数较小者，再按模型名排序。C1 则取每月前 1% 得分均值，并用同一组模型的平均对数参数量，比较首月到峰值月的变化。故两个占比代表不同时间尺度，不能合并成一个平均比例。

年度累计最高分保留截至该年的最好记录，即使后一年新收录模型的得分较低，累计前沿也不会下降。月度前列均值先在当月记录内部选择高分组，后续预测再对各月结果取累计最大值。这种处理使曲线表示已达到的历史位置；其单调性来自定义，不能作为每个模型能力都持续提高的证据。当某月前列组只保留少量记录时，组内均值也仍会受到具体入选记录的影响。

C3 先按 Average 与六维均分的差值检查一致性，差值超过 5 分的 13 条记录予以剔除。其中差异最大的是 GPT-3 175B：Average 为 50.0，六维均分为 7.67，相差约 42.3 分。再排除 7 条非正参数量记录，回归样本为 4,579 条；长期回归的 $b_P = 14.10$ 、 $b_t = 3.30$ 、 $R^2 = 0.42$ 。2019–2025 年的累计前沿从 5.00 达到 52.08，增加 47.08 分。分解后，24.20 分对应规模项，占 51.4%；其余 22.88 分归入非规模项，占 48.6%。2025 年累计最高分仍来自 2024 年的 77.965B 模型，参数量也随该记录保留；不能另取 2025 年最大规模与其配对。由于历史评分来源不完全相同，这些数值仍只是条件核算，不能识别技术进步的因果份额。图27并列展示两个窗口的增量核算。




图 27 规模代理与非规模剩余

近端比较使用评测标准较一致的 C1。2024 年 6—9 月，前列组参数量的几何均值从 70.6B 增加到 78.0B, $\Delta \log_{10} P = 0.043$ ；同一窗口的前沿得分由 37.99 升为 51.00。图27将其增量分成规模项 0.60 分和非规模项 12.41 分，比例分别为 4.6%、95.4%。参数扩张只能解释其中少量变化；其余部分混合了多种因素，既不能归给某一种算法，也不能沿用为全年或未来占比。

5.4.4 前沿曲线与条件预测

1. 饱和曲线及重抽样区间

前沿数据由 C3 的 2019–2023 年年度累计最高分和 C1 月度前 1% 均值的累计最大值连接而成，共 14 个点。每月前列组数量按记录数的 1% 向下取整，但最少保留 1 个。为描述先快后慢的增长，采用 logistic 函数，并把上界限制在 100 以内：

$$F(t) = \frac{K}{1 + e^{-r(t-t_0)}}, \quad K \text{ 为饱和上界, } r \text{ 为增长率, } t_0 \text{ 为拐点} \quad (48)$$

曲线的三个估计参数为 $K = 56.61$ 、 $r = 2.523$ 、 $t_0 = 5.11$ ，对已有前沿的拟合达到 $R^2 = 0.975$ 。采用 bootstrap 重抽样思想 [25]，将残差有放回抽取 600 次，每次重新拟合，以成功拟合所得预测值的第 5 和第 95 百分位为端点，构成条件曲线的中央 90% 重拟合分位范围。该范围未加入未来观测扰动，不能解释为对未来实际得分具有 90% 覆盖率的预测区间，也没有计入评测标准与技术路线改变的影响。

重抽样时，我们固定前沿时间点，有放回地抽取拟合残差并叠加到原曲线上，再重新估计参数和两个未来时点的得分，以考察残差变化如何传递到预测。这里的 600 次是重抽样尝试次数，区间依据其中成功拟合的结果汇总，并非增加了 600 组独立评测数据。

由于时间点和前沿构造规则保持不变，区间也没有检验更换历史样本或前沿定义后的变化。

我们进一步构造放缓情景，假设从预测基点 t_h （2025 年 3 月）起，logistic 动力学中的增长参数由 r 降为 $r/2$ ，饱和上界 K 不变。以连续的有效时间表示该假设：

$$\tau(t) = \min(t, t_h) + \frac{1}{2} \max(t - t_h, 0), \quad F_{\text{slow}}(t) = \frac{K}{1 + e^{-r(\tau(t) - t_0)}}. \quad (49)$$

该曲线在 t_h 处与原曲线相接，之后满足 $dF_{\text{slow}}/dt = (r/2)F_{\text{slow}}(1 - F_{\text{slow}}/K)$ ，仍随时间增长。减半指增长参数，不表示每个未来时点的得分增量都恰好减半。此处将算力放缓的影响表示为条件性增长参数变化，未从附件估计算力增速到该参数的传导关系。

2. 基于规模和年度系数的结构情景

为考察不预设短期饱和的增长路径，我们利用规模和年度系数作结构外推：

$$\hat{F}(t + \Delta) = F(t) + [b_P \Delta \log_{10} P + b_t] \cdot \Delta \quad (50)$$

式中， Δ 为向前预测的年数， $\Delta \log_{10} P$ 为假设的年均参数对数增量。设置三种条件进行比较：基准情景保持规模不变，并假设每个未来整年累加一次年度标签系数 b_t ；放缓情景同样固定规模，但把 b_t 减半；扩容情景则令规模每年增加 0.3 个数量级，同时保留 b_t 。其中放缓幅度是对非规模增长的假设，并不是从算力增速估计出的传导关系。

两个年度组的平均提交时间仅相隔 0.379 年，故 $b_t = 4.844$ 不能直接视为已验证的每年增长速度。改用连续提交时间后，时间系数为 13.803 分/年，这一敏感性对照也不是因果增速。结构外推把标签差异按整年重复，是额外的情景设定；我们保持起点得分和预测时点一致，以比较该设定与规模扩张的作用。每个结果都是给定条件下的点预测，最大值与最小值的跨度只反映情景差异。由于未对这些条件赋予发生概率，该跨度既不是残差重抽样区间，也不覆盖所有可能的未来结果。图28将曲线预测及其重抽样区间与三种结构情景分别展示。

预测以 2025 年 3 月为起点，两个预测时点分别是 2026 年 3 月和 2027 年 3 月。表23列出预测值。logistic 点预测为 56.3、56.6 分，对应条件曲线的 90% 分位范围 [53.62, 64.52]、[53.75, 66.52]；结构情景的点预测范围为 53.42 ~ 59.99 和 55.84 ~ 68.99 分，向外取整后为 53 ~ 60、55 ~ 69 分。后两组范围来自情景点值，不能按区间估计理解。




图 28 前沿条件预测

表 23 以 2025 年 3 月数据为基点的能力前沿条件预测

预测口径	前瞻 12 个月	前瞻 24 个月
	2026-03	2027-03
logistic 点预测	56.33	56.59
bootstrap 第 5 百分位	53.62	53.75
bootstrap 第 95 百分位	64.52	66.52
logistic 增长参数减半	55.62	56.33
结构外推：规模持平	55.84	60.69
结构外推：非规模增速减半	53.42	55.84
结构外推：每年扩容 0.3	59.99	68.99
dex		

两种预测的含义并不相同。图28上图的紫色误差棒表示基准曲线在两个预测时点的90%曲线重拟合分位范围，金色虚线与三角形表示增长参数减半的曲线与点预测，下图展示结构情景的点预测。logistic 曲线在两个预测时点已接近饱和，结构基准则假定年度增量继续存在；将 logistic 增长参数减半后的结果为 55.62、56.33，表示在该情景下仍有增长但速度降低。C1 可比观测窗口约 10 个月，前瞻已是这一长度的 1.2 ~ 2.4 倍，早

期 C3 还存在评分口径差异。因此，高拟合度只说明曲线能描述已有记录，不能代替未来检验，表中数值应和各自情景一起理解。

曲线参数 K 是当前前沿样本和所选函数共同确定的渐近位置，其含义不同于评测量表的满分。观察期末曲线变平，会使近端预测靠近这一位置；结构外推则保留按年累计的增量。两条路径的差异因此主要来自增长形式的设定。我们保留两类预测，用以比较增长形式对结果的影响；二者并不构成相互独立的外部验证。

5.4.5 从综合前沿到具体任务瓶颈

1. 六维能力的分布差异

综合分数只能说明整体位置，不能说明六项能力是否同步。图29中，每一维均有 $n = 2,346$ 条记录；箱体覆盖第 25 至第 75 百分位，箱内线标出中位数，两端须线延伸至最小值和最大值。表24同时列中位数、前列均值和最高分。距满分的差值按 $100 - \text{最优得分}$ 计算，只表示当前评分体系中的剩余空间，不是确定可获得的提升量。




图 29 六维能力分布

IFEval 的中位数为 43.51，最高分则达到 89.98，距满分约 10.0 分。前沿与中间水平仍有距离，不能因少数模型接近满分就判断整体已经饱和。GPQA、MUSR 最高仅 27.74、38.69，中位数更低，是当前较明显的短板。MATH Lvl 5 的中位数为 9.93，最高分为 62.54，也表现出这种分化；单看最高分会高估大多数模型的水平。

我们同时列出中位数、前列均值和最高分，分别描述通常水平、高分组表现和当前观察到的单项上界，以区分少数模型领先与较多模型共同达到较高水平的情况。六个维度分别排序，入选前列的记录并不必然相同，因此不能把六项前列均值拼成一个已经存在的模型得分。

2. 原始子任务中的瓶颈位置

C8 的 37 项子任务进一步把这种差异展开。图30采用各任务的原始指标，每项 $n =$

表 24 六项评测的中位数、前列得分与距满分差值

任务维度	中位数	前 1% 均值	最优得分	距满分差值 / 分
GPQA	5.70	22.80	27.74	72.3
MUSR	9.97	28.06	38.69	61.3
MATH Lvl 5	9.93	58.02	62.54	37.5
BBH	28.52	59.95	65.47	34.5
MMLU-PRO	25.98	55.26	66.80	33.2
IFEval	43.51	84.45	89.98	10.0

961 ~ 964；圆点、短线和菱形分别标出中位数、前 5% 均值和最高分，对应通常水平、前列表现和单项前沿。表25列出距满分差值最大的六项，中文名称与图中保持一致。

表 25 距满分差值最大的六个子任务

所属类别	子任务	n	前 5% 均值	最优得分	距满分 差值 / 分
MATH	中级代数	962	20.11	31.79	68.2
MATH	预备微积分	962	22.89	36.30	63.7
MATH	几何	962	28.72	40.91	59.1
BBH	位置跟踪, 7 个对象	964	32.67	41.20	58.8
BBH	位置跟踪, 5 个对象	964	31.24	41.60	58.4
GPQA	Extended 子集	961	39.74	44.87	55.1

在具体任务层面, MATH-Hard 的中级代数、预备微积分和几何最高分为 31.8 ~ 40.9; BBH 的 5、7 对象位置跟踪约 41 分, GPQA Extended 为 44.9 分。这些最高分仍留有较大余量, 但任务难度和随机基线不同, 不能把原始分数视为完全同尺度的能力值。

类别汇总也反映了前沿与通常水平的距离。MATH 的任务最高分均值为 55.5, 合并全部模型和子任务后的中位数为 3.7; BBH 两项分别为 81.8、48.8。这里平均的是不同任务的最高得分, 它们可能分属不同模型, 不能合成为某个模型的整套能力。

对于任务排序时, 我们同时保留有效样本数与评分方式。各项缺失情况不同, 参与某一任务统计的目录集合可能略有变化; 不同任务的原始得分也有各自的难度背景。表25用于指出当前记录中表现较弱的具体位置, 便于把综合能力的短板落实到任务, 而不据此给出统一的训练收益排序。




图 30 子任务得分

5.4.6 宏观资源证据与预测边界

Epoch AI 数据库 C4 与 C1 的名称规范化后只有 1 条匹配，不能组成逐模型联合样本，因此这里只把 C4 作为宏观资料 [26]。图31上图连接各年 Language 记录的算力中位数和最大值，左下图给出开放权重标记 Yes 的比例，右下图以全量 3,523 条记录为背景展示字段覆盖；浅色部分对应缺失或状态未明确的记录。

2018–2026 年，Language 子集共有 1,783 条记录。对九个年度的最大算力取对数拟合，斜率约为 0.589 个数量级/年，即相邻年度的拟合算力之比约为 3.88。记录整体呈扩张趋势，但并非每年递增，2024 年最大值低于 2023 年。2026 年仅有 40 条 Language 记录，其中 5 条带算力值，该点容易受收录不足影响，不能据此认定趋势反转。

以全部 Language 记录为分母，权重标记 Yes 在 2018 年占 26.7%，2025 年占 59.4%，




图 31 资源趋势与字段覆盖

中间各年有波动。由于分母也含权重状态缺失的记录，这只能反映数据库的收录结构，不能解释为市场份额，也不能据此认定 C1 能代表总体模型。

C4 的 3,523 条记录中，1,390 条含算力值，1,424 条含训练数据量；另有 2,653 条明确记录了权重状态，其中 Yes 为 1,325 条、No 为 1,328 条。训练数据量缺失较多且来源不统一，因此只报告该字段的覆盖情况，不估计其年度增长。C4 可以为宏观资源情景提供参照，但不能确定算力放缓会使非规模进步按何种比例下降。

宏观记录与能力评测在对象范围和字段覆盖上存在差别，因而本问没有把 C4 的年度算力趋势直接代入 C1 的得分回归。年度最大值用于观察数据库中已记录的高算力水平，中位数用于描述当年有算力记录样本的中间位置，两者都依赖收录情况。因此，我们同时报告趋势与字段覆盖，明确各项统计的样本范围，缺失字段不按零投入处理。

综合本问分析，我们观察到损失与得分大体反向变化，并分别核算了长期与近期前沿的增量。在所选规模代理下，长期窗口的规模项与非规模剩余项接近各半；2024 年 6-9 月的短窗口则主要由非规模项构成。未来预测同时保留曲线区间和结构情景，任务层面则提示数学、研究生级问答和多步推理仍是当前评测中的薄弱部分。

六、模型检验与分析

我们从预测误差和条件变化两方面检验模型：前者考察对检验记录的预测，后者考察赋权、成本与预算改变后配置及结论是否保持。

6.1 误差分析

表26汇总各问使用的检验指标。问题一的线性岭与核岭、问题二的经典和广义标度律，以及问题四的损失—得分桥接和记录级规模—年份回归，分别报告 R^2 、RMSE、MAE、MAPE。我们据此同时评价拟合解释度与预测偏差，避免仅凭相关性判断效果。

设同一评价集合中的观测值为 y_i ，预测值为 $\hat{y}_i$ ，记录数为 n ，均值为 $\bar{y}$ 。几类指标分别由残差的平方、绝对值及相对大小构成：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$
$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$
$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|.$$

其中， R^2 需要观测值具有非零变异，MAPE 的逐条计算则要求观测值非零。RMSE 对较大的偏差给予更多权重，MAE 描述平均绝对偏离，两者与被预测量具有相同量纲；MAPE 便于阅读相对误差，但观测值靠近零时，少量记录也可能显著影响其大小。因此，我们结合样本取值范围共同报告这些指标。

我们还区分决定系数与相关系数的用途。 R^2 将残差与观测值围绕均值的变异作比较，要求预测值在实际尺度上接近观测值；Pearson 的 r 则衡量两者共同变化的程度。预测序列整体偏高或偏低时，仍可能保持较高相关。表中的跨尺度相关用于评价趋势，其余结果按各问的评价集合解释，不据同列数值直接排列所有模型的优劣。

表 26 各问拟合、预测误差与预算约束残差汇总

模型（数据集）	R^2 / r 或残差	RMSE / 相对残差	MAE	MAPE(%)
问题一岭回归（训练 1M, $n = 512$ ）	$R^2 = 0.629$	0.551	0.403	8.54
问题一岭回归（检验 1M, $n = 256$ ）	$R^2 = 0.619$	0.523	0.386	8.43
问题一核岭（检验 1M, $n = 256$ ）	$R^2 = 0.9454$	0.2256	0.1344	—
问题一跨尺度 Pearson (60M / 1B)	r : 0.782 / 0.651	—	—	—
问题二经典标度律（B1, $n = 1,176$ ）	$R^2 = 0.9999998$	1.5×10^{-4}	1.05×10^{-4}	0.004
问题二经典标度律留出（4 小模型 → 4 大模型）	$R^2 = 0.9999997$	1.5×10^{-4}	—	0.005

表 26 各问拟合、预测误差与预算约束残差汇总 (续)

模型 (数据集)	R^2 / r 或残差	RMSE / 相对 残差	MAE	MAPE(%)
问题二广义标度律 (B1+B6 联合, $n = 1,536$)	$R^2 = 0.990$	0.036	0.017	0.66
问题二跨族验证 (B4, $n = 57$)	$r = 0.975$	0.293	—	8.83
问题二文献验证 (B5, $n = 44$)	$r = 0.910$	0.193	—	7.99
问题四 Loss—Benchmark 桥接 (C6, $n = 75$)	$R^2 = 0.26$	—	—	67.79
问题四记录级规模—年份 回归 (C1 开源筛选, $n = 2,346$)	$R^2 = 0.475$	—	—	—
问题四记录级规模—年份 回归 (C3 长周期, $n = 4,579$)	$R^2 = 0.424$	—	—	—
问题四前沿 logistic (历史 拟合)	$R^2 = 0.975$	—	—	—
问题三优化约束残差 ($ C_{\text{total}}/C_{\text{budget}} - 1 $)	—	$< 10^{-6}$	—	—

问题一的同尺度预测与训练表现接近。表26中, 13 个验证域的平均训练 R^2 为 0.629, 1M 检验为 0.619, 相差 0.010, MAPE 约 8.5%。这一对照没有显示明显的训练与检验落差, 但不能据此排除线性欠拟合。核岭的同尺度平均域 $R^2 = 0.9454$ 、综合 RMSE 为 0.2256; 相应训练五折误差为 0.2558。跨尺度绝对误差见表7, 较高趋势相关不代表绝对损失准确。

问题二的精度取决于检验来源。对 B1, 经典拟合有 $R^2 \approx 1.000$ 、MAPE 0.004%, 仅用小模型估计后, 对大模型的留出预测仍有 $R^2 = 0.9999997$; 残差标准差 1.5×10^{-4} 相比损失标准差 0.342 很小。这些结果说明对 B1 的贴合程度高, 尚不能说明跨来源同样准确。B4 和 B5 的 MAPE 分别为 8.8%、8.0%, 相关分别为 $r = 0.975$ 、 $r = 0.910$ 。广义模型的 1,536 条联合记录给出 $R^2 = 0.990$ 、MAPE 0.66%; 由于样本组成改变, 不能将其拟合优度与经典模型直接作差来判断泛化收益。

问题四的换算精度主要受样本可比性限制: 中可比层的验证集不同, 高可比层的得分跨度有限, 合并后的 $R^2 = 0.26$ 、MAPE 为 67.8%, 故结果仅作方向解释。问题三检查的是预算可行性; 表中最后一行的数值是成本回代得到的相对预算残差, 虽与 RMSE 同列展示, 不能解释为预测误差。有效解的残差均 $< 10^{-6}$, 符合成本约束。

各问的评价集合不同，也决定了误差数字的使用范围。问题一的检验针对新配方下的领域损失，问题二的对照涉及不同规模、质量和资料来源，问题四的桥接还要跨越损失与能力两种指标。较小误差能够支持相应集合内的描述，却不能自动扩大到其他来源。因此，我们按记录来源及其是否参与估计，限定表26中各项误差的解释范围。

预算约束残差与上述预测误差的含义不同。残差接近零，说明返回的参数数量、数据量和质量在给定成本式下基本用尽预算；它本身不衡量标度律的预测精度，也不说明外部评测得分会提高多少。因此，我们从预算可行性、预测损失和资源份额三个方面评价问题三的配置。

6.2 配方决策与时间外推检验

逐域预测误差与配方选优并非同一指标。我们固定问题一优化时使用的 13 域参考权重，分别对观测损失与预测损失加权，再比较排序及模型选中配方的观测名次。表27中的名次只针对相应检验集合；这些集合不等于有界优化的可行域，不能将名次写成当前线性方案的真实训练排名。

表 27 相同加权目标下的检验配方排序与选优

评价集合	线性岭	核岭	线性选中项	核岭选中项
	Spearman	Spearman	观测名次	观测名次
五折折外 (512 组)	0.3154	0.9567	142/512	2/512
1M 检验 (256 组)	0.4280	0.9628	58/256	1/256
60M 检验 (256 组)	0.4017	0.9572	72/256	4/256
1B 检验 (64 组)	-0.0795	0.6396	64/64	2/64

相同目标的检验支持核岭具有较好的候选排序能力，但不能验证训练范围之外的连续最优配方。对线性对照方案，两模型预测变化分别为 -0.1988 和 $+0.1713$ ；该方案与闭合训练凸包的最小 L_∞ 距离为 0.01003 ，即至少一个领域相差约 1.003 个百分点。正式推荐改由核岭在训练凸包内求解，从而使预测方法、决策目标与支持范围一致；四个初值的目标一致且约束成立，但这仍不是新增训练实验。问题二、三固定配比项采用新方案的核岭预测差，跨来源及跨尺度保留幅度仍需限定为条件假设。

时间预测采用三个截点检验：每次只使用截点及以前的前沿记录拟合，预测其后月份至 2025 年 3 月，并与“保持截点最近累计峰值”的基线比较。表28沿用正式曲线的函数、初值与参数边界；检验对象始终是累计前沿，而非单个新模型的得分。

7 月截点下曲线误差较小，8、9 月截点下持平基线较小，未显示稳定的预测优势。最后一个检验段恰处于平台，持平误差为零不能推广到增长阶段。三个截点拟合的 K 均触及 100 的上界；仅删去正式样本末尾三个平台点， K 又从 56.61 变为 71.40 ，对同一未来两时点的预测由 $56.33/56.59$ 变为 $69.31/71.09$ 。这说明渐近位置对观察窗口敏感，重拟合分位范围不能代替这种结构与窗口不确定性。

表 28 累计前沿的时间留出预测误差（分）

拟合截止月份	后续检验月数	logistic RMSE	持平基线 RMSE
2024 年 7 月	8	6.394	12.446
2024 年 8 月	7	8.269	5.653
2024 年 9 月	6	11.140	0.000

6.3 灵敏度分析

表29比较赋权方式、冲突阈值、岭正则、质量成本、质量基线、上下文长度和预算变化后的结果，同时补充指标方向与跨来源验证的影响。我们通过这些对照识别较稳定的结论，以及依赖特定成本或样本的结论。

表 29 评分规则、成本与预算变化下的结果稳定性

参数/设定变化	输出变化	灵敏度评估
赋权方案：熵权法 → 等权平均 → 首主成分非负载荷加权	域级质量排序一致性 0.643 → 0.679；样本级得分相关 0.875/0.927；得分均值 0.491 → 0.637 → 0.496	中等敏感：整体格局稳定，但领域名次会变化
指标方向：ad_en 按“索引 1= 无广告”（正向）→ 若误判为负向	领域质量排序由「arxiv > stackexchange > c4 > commoncrawl > book > wikipedia > github」变为「c4 > arxiv > commoncrawl > stackexchange > book > wikipedia > github」	高度敏感：方向判定必须用实证证据
冲突阈值 τ ：0.5 → 1.0 → 1.5 → 2.0 → 2.5	冲突率 0.657 → 0.394 → 0.219 → 0.120 → 0.066；与独立基准之比 0.91 → 0.82 → 0.76 → 0.76 → 0.86	结论稳健：所考察阈值下冲突率均低于独立基准
岭正则系数 λ ： $10^{-4} \sim 10^{-1}$	训练 R^2 由 0.6291 降至 0.6238， 检验 R^2 由 0.6187 降至 0.6157	拟合指标变化较小，不能据此认定系数和配置份额稳定
质量成本函数：指数型 → 幂函数型 → 对数渐进型 ($C = 10^{19}$)	$Q^* = 0.660 \rightarrow 0.549 \rightarrow 1.000$ ， L^* 差异 < 0.06；质量份额 13.1% → 0.0% → 31.7%	低预算档较敏感

续下页

表 29 评分规则、成本与预算变化下的结果稳定性 (续)

参数/设定变化	输出变化	灵敏度评估
同上, 考察 $C = 10^{22}$ 、 10^{24}	三种函数下 Q^* 均为 1.000; 在 10^{22} 档, D^* 为 229.4–274.1B tokens, 最大值较最小值高约 19.5%	质量均达到上界, 规模配置仍有差异
质量基线口径: 配比加权 $Q_0 = 0.5487 \rightarrow$ 样本均值 0.4912	三档预算下 Q^* : 0.549/1.000/1.000 $\rightarrow$ 0.507/1.000/1.000, 低预算质量份额由 0 变为 2.63%, N^* 最大变化约 3.24%	规模配置变化较小; 低预算是否启动质量投入依赖基线口径
上下文长度: 2,048 $\rightarrow$ 131,072 tokens (C7 可行取值)	注意力/训练倍数 0.07 $\rightarrow$ 4.37; N^* 由 6.091B 降至 2.705B; 损失上升 6.0%	对配置影响较大; $L_{\text{crit}} = 30,000$ 为两项成本相等的位置
算力预算 C : $10^{19} \rightarrow 10^{24}$ FLOPs	Q^* 由 0.549 升至 1.000; D^*/N^* 由 30.9 升至 76.1; 质量份额 0 $\rightarrow$ 0.407 $\rightarrow$ 0.016	高度敏感, 发生三段式结构性转移
半合成数据验证: B2 / B8	B2 的 MAPE 为 33.7%; B8 校准段翻转质量方向后为 133.4%, 其部分数据损失低于估计的不可约损失下限	跨来源偏差较大, 两者均未参与主拟合

表29显示, 不同设定对结果的影响程度并不相同。

对线性岭进一步比较配置而非只比较 R^2 : 正则系数从 0.001 改为 0.1, 中心化系数矩阵的相对变化为 56.3%, 221 项中有 16 项变号。在相同约束下用线性规划求解, 医学全文占比从 28.43% 变为 11.29%, 百科从 1.63% 变为 18.77%; 把两种配方都代回原模型, 目标仅相差 0.00228。较平坦的目标可以对应差异较大的近优配方, 因此预测指标稳定不等于详细份额稳定。

评分标尺也依赖校准集合。全量记录中 github 占 78.44%, A1 中为 19.52%; 分位截断和熵权均在全量记录上估计, 故扩展集同时影响评分标尺, 不能把 A1 与扩展集的均分接近当作独立标尺验证。对于跨附件接口, 保持 A 侧费用不变, 将 $Q_B = h(Q_A)$ 分别设为 $\sqrt{Q_A}$ 、 Q_A 、 Q_A^2 , 局部质量投入启动条件对应约 2.94×10^{19} 、 1.57×10^{19} 、 1.37×10^{19} FLOPs。这三个值来自基线处的一阶条件, 不是预算网格重新求得的全局临界值; 它们仅说明保持质量顺序和端点仍不足以确定投入门槛。此处改变的是未知的跨附件映射, 若仅更换同一物理模型的坐标, 则损失与费用都应同步变换。

质量项还存在结构敏感性。B6 的 45 个固定 (N, D) 组中, Q 从 0.1 提高到 1 对应的损失下降为 0.1067 $\sim$ 0.6091, 与参数量的 Spearman 相关为 -0.749 ; 当前加性模型对所

有组给出同一下降 0.3197。因此，加性形式是平均近似，尚未刻画质量与规模之间的交互。把 γ 固定为 1，并在相同联合数据、参数边界及 soft-L1 目标下重估其他参数，目标值仅增加 0.0241%；在原首次饱和预算 7.079×10^{19} FLOPs 下，对照配置为 $Q^* = 0.9640$ ，而原模型为 1。原估计 $\gamma = 0.9779 < 1$ 使质量边际收益在 $Q \rightarrow 1$ 时发散；这会影晌端点选择，但不意味着任意预算下端点都是全局最优。正式网格的“首次达到上界”因而依赖质量项的函数形式，不能视为数据直接确定的阈值。

我们按条件作用的位置解释这些差异。调整权重或指标方向，会先改变质量评分；调整质量费用和上下文长度，会改变预算中各项支出的比例；扩大总预算，则是在同一成本形式下改变可配置的资源总量。因而，我们除比较最终损失外，也比较中间变量和配置份额。若两种方案的预测损失接近，但质量份额相差较大，就说明目标值相近并不要求投入方式相同。

阈值、正则参数和预算扫描均由有限取值构成。相邻取值下的结果可用来判断已检验范围内的变化方向，首次发生变化的网格点则给出定位边界的线索。我们保留扫描间距和求解状态，并结合费用关系解释变化。图中连接相邻点仅用于展示趋势，未检验区间不具有与扫描点相同的数值依据。

(1) 较稳定的结果。在所检验阈值内，冲突率始终低于独立参照，比值均 < 0.92 。岭正则变化对拟合精度影响较小；更换质量基线后，规模配置变化较小，但低预算是否启动质量投入随基线口径改变。三类成本在所考察的中高预算档都使质量达到上界，但参数量、数据量的具体组合仍然不同。

(2) 需要区分的边界。 $L_{\text{crit}} = 30,000$ tokens 只表示注意力费用与基础训练费用相等，不代表最优解在此处发生突变； 1.58×10^{19} 、 7.08×10^{19} FLOPs 是预算网格中首次出现质量投入和首次达到上界的有效点，实际边界还受网格间距、求解状态及成本形式影响。

(3) 依赖条件的结果。 $C = 10^{19}$ FLOPs 下更换质量成本时，最优质量覆盖 $0.549 \sim 1.000$ ，说明低预算策略依赖成本设定，应同时比较各情景；损失-得分桥接只有 $R^2 = 0.26$ ，不能精确换算能力分；领域排序也会受指标方向和赋权方式影响。

6.4 各问结果的衔接与使用条件

完成单项检验后，我们进一步核对结果在各问之间的传递。质量基线、配比修正和标度律参数对下一问的作用不同，因此分别检查其影响位置与使用条件，明确现有检验覆盖的范围。

质量基线 Q_0 一方面确定问题三的质量起点，另一方面进入增量费用 $[g(Q) - g(Q_0)]_+$ 。所以，更换基线会同时改变质量可选区间和费用参照，不能仅把结果表中的质量数值平移后仍视为同一方案。前述两种基线的对照已经给出相应配置；我们将各自基线、成本形式及配置共同列为使用条件。问题一中缺少直接领域质量观测的部分，也需要随映射规则一并说明。

配比修正 $M(\mathbf{p})$ 则以损失平移量进入广义模型。配比固定时，它不参与参数量、数据量和质量的求导，但仍影响报告的预测损失水平。因而，讨论规模配置与讨论配方收

益时，需要明确是否沿用同一配比。问题一的有界推荐与问题二的跨来源对照分别提供了配方比较和迁移范围的依据，不能把某一项检验的准确程度视为另一项关系也已得到验证。

标度律参数决定不同投入的边际收益，成本函数决定实现这些投入要支出多少算力。问题二的拟合误差与问题三的成本敏感性分别考察这两侧的关系。现有结果可以说明给定参数和成本下怎样配置，也可以比较已设定成本情景之间的差别；对于参数误差与成本误差同时变化后的影响，本文没有另外给出联合概率区间，因此不把这些情景差别解释成最优配置的置信范围。

能力预测又使用另一组观测。损失-得分桥接展示了两类指标的关联程度，历史前沿和记录级规模—年份回归则直接使用评测记录。问题三中的损失下降据此解释为训练目标的改善，问题四的能力增量保留为相应评测尺度下的结果；两者均应结合各自的样本范围和桥接假设解读。

七、模型的评价

7.1 模型的优点

- **质量评分有明确依据。**表2逐项给出 22 个指标的方向。广告字段通过原文抽查确认“索引 1= 无广告”，负向指标反向处理，长度指标转为靠近中心的得分，列表指标按维度转为标量，单元素列表取原值，多类别字段采用 softmax 期望，qurater 四维分别归一化后等权聚合，19 处缺失填入中位数。抽样与扩展集合在可比较领域的差值约为 0.002，提供了记录集合之间的评分对照；两集合存在重复 ID，不能作为完全独立的验证。

- **指标冲突可以相对比较。**我们从冲突比例和排序一致性两个层面判断分歧，同时报告 21.9% 的冲突率、0.076 的 Kendall 系数和 28.9% 的独立参照，并在 $\tau \in [0.5, 2.5]$ 内检查比值均小于 0.92。据此，我们既识别指标的共同倾向，也保留整体一致程度有限的判断，并结合字段含义解释分歧。

- **质量项便于解释和比较。**加性质量缺口 $C(1 - Q)^\gamma$ 在 $Q = 1$ 时归零，因而与 Chinchilla 形式相接；相比直接写成 $E - CQ^\gamma$ ，高质量端不会因为相减而出现负损失。选择形式时，我们比较四种候选的 R^2 、残差信息评分及范围外表现。B3 的轨迹指数约为 -0.2805 ，与拟合的 -0.2799 接近，只能算内部一致性检查。

- **配置变化可从成本公式解释。**预算模型保留 $C_Q = D[g(Q) - g(Q_0)]_+$ ，质量费用因数据量而变化；注意力费用与基础训练费用的临界长度为 $L_{\text{crit}} = 6/\eta = 30,000$ 。由此可以推导式(39)，并用与参数量同单位的折算量 $\tau(Q)$ 说明质量处理如何改变参数-数据平衡。质量费用采用题设附录 B 的三类函数参数。

- **不同来源的结果分别解释。**我们在问题四中明确许可筛选条件、记录时间含义和模型类型分组；C8 成功解析 1,860 个目录，其中与主样本交集的 964 个目录汇总 37 项任务；C4 只用于宏观资源与字段覆盖。B2、B8 的异常也保留在检验中，例如

B8 有低于不可约损失下限的记录，避免把不同性质的资料当作同一种证据。六维指标另与完整 C1 作名称匹配和记录级秩相关检查，预测时则分别报告重抽样区间与情景范围。

7.2 模型的缺点

- **预测增强仍有适用范围。**核岭使 1M 同尺度平均域 R^2 达到 0.9454，但直接跨尺度的绝对损失失配。线性近似保留系数解释与配方对照，核岭负责训练凸包内推荐；支持范围约束减少外推，却不保证凸包内处处有充分观测，也不能证明数值驻点全局最优。nih_exporter、enron_emails、europarl、philpapers 没有对应的验证损失列，无法直接评价这些领域自身的预测损失，推荐时固定其参考占比；它们对已有 13 个验证任务的作用仍由配比系数表示。混合质量指数与原配比特征严格线性相关，加入后的 R^2 差异来自岭惩罚的改变，无法据此识别质量的独立作用。

- **部分评分方向仍依赖字段含义。**广告、流畅度等方向已经通过原文和领域对照检查，modernbert 的 6 级指标按有序等级处理；qurater 按四个不同维度处理，其同向等权聚合仍是本文假设，尚无独立任务效果校准。熵权还会受分布形态影响，等权后领域排序一致性为 0.643。第 6.3 节的敏感性结果表明，方向判错会改变排名，因此领域名次需要和评分规则一起报告。

- **质量实验的支持范围有限。**质量项主要由 B6/B7 半合成实验支持。B8 方向相反且出现低于损失下限的记录，不能并入主拟合；B2 的 MAPE 为 33.7%，也提醒我们跨来源估计存在较大偏差。B6/B7 的质量取值覆盖 0.1 至 1.0，包含低于基线的记录。问题三将配置限定在 $[Q_0, 1]$ ，是因为该问讨论从既有基线继续提升质量及其增量费用；主动降低质量的配置不在本模型范围内。不同来源质量评分的对应关系仍需额外校准。

- **能力预测受到时间和评分限制。**损失映射的 $R^2 = 0.26$ 、MAPE 为 67.8%，不能把损失改善精确折成能力分。C1 的可比窗口约 10 个月，却要向前预测其 1.2 ~ 2.4 倍；C3 的历史评分又来自不同来源。长期规模占比 51.4% 与 2024 年 6–9 月的 4.6% 只对应各自窗口，不能互相替代。此外，仅两个年份的回归不足以识别具体技术机制，非规模项还混合了样本构成等影响。

八、模型的改进与推广

8.1 模型的改进

结合检验结果，我们认为后续应优先改善跨尺度校准、实际成本估计与数据覆盖。

核岭已改善同尺度配比预测，但跨尺度绝对误差仍然较大。对此，我们建议先补充目标规模的配方实验，在独立留出条件下检验损失偏移和响应幅度是否需要校准，再决定能否将非线性响应用于资源优化。对缺少验证损失的四个领域，可增加文本统计特征

作为代理信息，减少固定参考占比的影响；冲突处理也可以尝试有序 probit 因子模型，以共同潜在质量解释指标分歧并给出可信区间。

质量模型可加入 $C(1 - Q)^{\gamma_1} D^{-\gamma_2}$ 等交互形式，检验质量缺口是否随数据量变化。预算规划还可加入重复训练、稀疏化和量化产生的训练与推理费用，以及分阶段课程学习。鉴于低预算配置对成本形式敏感，我们建议记录实际清洗费用，先拟合经验成本曲线，再与题设三类函数比较。

为检验上述改进，我们建议有针对性地补充数据：收集带质量标注的公开语料，扩大 B6/B7 的质量范围；同时核对发布时间、许可和去重比例等字段能否解释质量标签。C4 与 C1 可先按组织名、参数和时间匹配，经人工核实后再做训练算力与能力的联合分析。若取得 v1、v2 评测的共同校准样本，还可把 2019–2023 年的历史记录换到同一尺度，缓解当前可比窗口只有 10 个月的问题。

8.2 模型的推广

我们将本文方法概括为先估计投入收益、再加入费用约束、最后比较配置的分析过程。推广到其他有限成本场景时，仍需重新核对数据、损失函数与成本关系。

在大模型预训练、微调和蒸馏中，可先拟合损失与投入的关系，再计入费用约束求解配置。式(39)和 $\tau(Q)$ 适合比较语料处理与规模投入，但换到新任务时仍应重新估计参数，不能直接套用本文的算力数值。

语料治理时，22 个指标的方向表和冲突率对照可用于筛选、清洗及配比调整；领域系数相似度 s_{ij} 可以帮助寻找作用方式接近或相反的来源。至于两类语料能否等量替换、混合后是否增加收益，仍需配比实验确认。

资源规划可借鉴长期 shift-share 分解与近期同一评测窗口对照，分别观察扩参数和其他因素对应的增量。这种分解提供的是分析线索，非规模项不能全部当作算法收益。我们据此分别解释较稳定的结果、阶段边界与依赖假设的结果，以限定多来源分析的适用范围。

对于芯片制程、新能源和生物医药等可能逐步饱和的技术指标，也可比较 logistic 曲线与结构情景的预测差异，但前提是先确认该指标具有相应的增长形态。面对半合成或估算资料，本文对评分方向和不可约损失下限的检查，也可帮助判断哪些记录不能直接混合。

参考文献

- [1] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[EB/OL]. (2020-01-23)[2026-09-27].
<https://arxiv.org/abs/2001.08361>.

- [2] HOFFMANN J, BORGEAUD S, MENSCH A, et al. An empirical analysis of compute-optimal large language model training[C]//Advances in Neural Information Processing Systems. Curran Associates, 2022, 35: 30016-30030.
- [3] BESIROGLU T, ERDIL E, BARNETT M, et al. Chinchilla scaling: A replication attempt[EB/OL]. (2024-04-15)[2026-09-27]. <https://arxiv.org/abs/2404.10102>.
- [4] VILLALOBOS P, HO A, SEVILLA J, et al. Position: Will we run out of data? Limits of LLM scaling based on human-generated data[C]//Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024, 235: 49523-49544.
- [5] GUNASEKAR S, ZHANG Y, ANEJA J, et al. Textbooks are all you need[EB/OL]. (2023-06-20)[2026-09-27]. <https://arxiv.org/abs/2306.11644>.
- [6] LI J, FANG A, SMYRNIS G, et al. DataComp-LM: In search of the next generation of training sets for language models[C]//Advances in Neural Information Processing Systems. Curran Associates, 2024, 37: 14200-14282.
- [7] LIU Q, ZHENG X, MUENNIGHOFF N, et al. RegMix: Data mixture as regression for language model pre-training[C/OL]//The Thirteenth International Conference on Learning Representations. 2025[2026-09-27]. <https://openreview.net/forum?id=5BjQ0UXq7i>.
- [8] GAO L, BIDERMAN S, BLACK S, et al. The Pile: An 800GB dataset of diverse text for language modeling[EB/OL]. (2020-12-31)[2026-09-27]. <https://arxiv.org/abs/2101.00027>.
- [9] OPENDATALAB. SlimPajama-Meta-rater[DB/OL]. [2026-09-27]. <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater>.
- [10] SHANNON C E. A mathematical theory of communication[J]. Bell System Technical Journal, 1948, 27(3): 379-423. DOI: 10.1002/j.1538-7305.1948.tb01338.x.
- [11] KENDALL M G, SMITH B B. The problem of m rankings[J]. The Annals of Mathematical Statistics, 1939, 10(3): 275-287. DOI: 10.1214/aoms/1177732186.
- [12] HOERL A E, KENNARD R W. Ridge regression: Biased estimation for nonorthogonal problems[J]. Technometrics, 1970, 12(1): 55-67. DOI: 10.1080/00401706.1970.10488634.
- [13] SCIKIT-LEARN DEVELOPERS. Kernel ridge regression[EB/OL]. [2026-09-27]. https://scikit-learn.org/stable/modules/kernel_ridge.html.

- [14] 腾讯. WorkBuddy: AI 办公工作台 [EB/OL]. [2026-09-27].
<https://cloud.tencent.com/product/workbuddy>.
- [15] DEEPSEEK. DeepSeek-V4-Flash (公开测试) [EB/OL]. (2026-07-31)[2026-09-27].
<https://api-docs.deepseek.com/updates>.
- [16] OPENAI. Codex (模型: GPT-5.6-Luna) [EB/OL]. (2026-07-09)[2026-09-27].
<https://developers.openai.com/api/docs/models/gpt-5.6-luna>.
- [17] BIDERMAN S, SCHOELKOPF H, ANTHONY Q G, et al. Pythia: A suite for analyzing large language models across training and scaling[C]//Proceedings of the 40th International Conference on Machine Learning. PMLR, 2023, 202: 2397-2430.
- [18] SCIPY DEVELOPERS. minimize(method=SLSQP)[EB/OL]. [2026-09-27].
<https://docs.scipy.org/doc/scipy/reference/optimize.minimize-slsqp.html>.
- [19] XIE S M, PHAM H, DONG X, et al. DoReMi: Optimizing data mixtures speeds up language model pretraining[C]//Advances in Neural Information Processing Systems. Curran Associates, 2023, 36: 69798-69818.
- [20] MUENNIGHOFF N, RUSH A, BARAK B, et al. Scaling data-constrained language models[C]//Advances in Neural Information Processing Systems. Curran Associates, 2023, 36: 50358-50376.
- [21] SCHAEFFER R, MIRANDA B, KOYEJO S. Are emergent abilities of large language models a mirage?[C]//Advances in Neural Information Processing Systems. Curran Associates, 2023, 36: 55565-55581.
- [22] HUGGING FACE. Open LLM Leaderboard results[DB/OL]. [2026-09-27]. <https://huggingface.co/datasets/open-llm-leaderboard/results>.
- [23] ZHOU J, LU T, MISHRA S, et al. Instruction-following evaluation for large language models[EB/OL]. (2023-11-14)[2026-09-27].
<https://arxiv.org/abs/2311.07911>.
- [24] WANG Y, MA X, ZHANG G, et al. MMLU-Pro: A more robust and challenging multi-task language understanding benchmark[C]//Advances in Neural Information Processing Systems. Curran Associates, 2024, 37: 95266-95290.
- [25] EFRON B. Bootstrap methods: Another look at the jackknife[J]. The Annals of Statistics, 1979, 7(1): 1-26. DOI: 10.1214/aos/1176344552.

- [26] EPOCH AI. Data on AI models[DB/OL]. [2026-09-27].
<https://epoch.ai/data/ai-models>.
- [27] 中国研究生数学建模竞赛组织委员会, 中国研究生数学建模竞赛专家委员会. “华为杯”第二十三届中国研究生数学建模竞赛人工智能工具及输出使用规定[EB/OL]. (2026-09-16)[2026-09-27].
<https://cpipc.acge.org.cn/sysFile/downFile.do?fileId=4fc024f7a1504abb87fc056440c64a28>.

附录

附录 A：数据利用清单

附录 A 按附件编号说明每份数据在本文中的用途，并把真实记录、半合成实验、插值轨迹和外推估算区分开来。各附件对应的计算环节及直接观测、对照或稳健性检查用途见表30。

表 30 附件数据利用清单

编号	文件名	性质	是否使用	使用方式与可信度说明
A1	slimpajama_quality_signal_sample	真实	使用	对全量 51,230 条计算 22 指标熵权评分、领域 Q 与冲突，并抽查原文
A2	slimpajama_quality_extended/arxiv	真实	使用	以全部 17,523 条计算 arxiv 的领域 Q ，与抽样结果比较
A3	slimpajama_quality_extended/github	真实	使用	以全部 203,752 条计算 github 的领域 Q ，与抽样结果比较
A4	train_mixture_1m	真实	使用	512 组训练配方作为线性岭与核岭输入，用于拟合配比与损失
A5	train_pile_loss_1m	真实	使用	提供回归对应的 13 个验证域损失
A6–A9	test_mixture/loss_1m, 60m	真实	使用	分别检验同尺度和跨尺度的预测，每组 256 条
A10–A11	test_mixture/loss_1B	真实	使用	用 64 组记录检验跨尺度的预测

表 30 附件数据利用清单 (续)

编号	文件名	性质	是否使用	使用方式与可信度说明
A12– A15	est_mixture/loss_10b, 70b	子集/外推	使用	各 63 组用于比较外推尺度因子的稳定性; 属于外推记录, 并非观测
A16	domain_mapping_guide	参考	使用	连接 17 域与质量分类: 6 域按 direct/near_direct 对应, 11 域标为 inferred 并使用全局均值
A17	regmix_domain_summary	真实	未使用	未用于本文分析
A18	regmix_domain_sample	真实	未使用	未用于本文分析
B1	pythia_training_log_existing	真实	使用	1,176 点用于经典拟合和模型留出检验; 这组记录的拟合残差极小
B2	cerebras_training_log	半合成	使用	作模型族外对照, MAPE 为 33.7%; 来源差异较大, 只作定性参考
B3	training_trajectories	插值	使用	检查轨迹内部的 D 指数: -0.2806 至 -0.2803 , 对照拟合值 -0.2799
B4	scaling_baseline	真实	使用	用不同模型族作检验, 相关 $r = 0.975$, MAPE 为 8.8%
B5	published_scaling_data	真实	使用	与文献记录比较, 相关 $r = 0.910$, MAPE 为 8.0%
B6	supplementary_NQ_experiment	半合成	使用	360 点用于估计质量缺口项; 说明半合成条件下的质量效应, 不作为直接实验观测
B7	supplementary_NQ_experiment_expanded	半合成	使用	新增记录用于开发阶段检查, 相关 $r = 0.991$
B8	supplementary_NQ_experiment_large	半合成	部分使用	Q_{score} 与 B6/B7 的方向相反, 且含低于不可约损失下限的记录; 并不入拟合, 用于说明来源间的差异
B9	supplementary_large_models	真实	使用	提供百亿参数以上模型的参数量、数据量和开源可及性资料

表 30 附件数据利用清单（续）

编号	文件名	性质	是否使用	使用方式与可信度说明
B10	supplementary_large_baseline	估算	使用	比较百亿参数以上的损失估算， $r \approx 1.000$ 、MAPE 为 1.0%；该对照不作为直接观测
B11	open_model_family_metadata	真实	未使用	未用于本文分析
B12	pythia_checkpoint_index	真实	未使用	未用于本文分析
C1	leaderboard_cleaned	真实	使用	按六维得分、许可、类型和提交日期整理样本；筛选后的 2,346 条用于记录级规模—年份回归和前沿分析
C2	leaderboard_enhanced	真实	未使用	作为 C1 的增强替代版本，为避免重复计入而不另用
C3	leaderboard_extended_timeseries	混合	使用	核算 2019–2025 年增量；排除 13 条一致性异常记录，长期解释仍保留评分来源差异
C4	epoch_all_ai_models	真实	使用	观察训练算力趋势，年斜率 +0.589 dex；核对数据量与权重字段，Yes 为 1,325、No 为 1,328
C5	loss_benchmark_bridge	混合	使用	作为损失与得分关系的对照， $n = 43$ 、 $r = -0.502$
C6	loss_benchmark_bridge_expanded	混合	使用	用于主要损失–得分拟合， $n = 75$ ；High、Medium 两层按可比程度分别处理
C7	model_architecture_metadata	真实	使用	将 2048、4096、8192、32768、131072 五档上下文用于问题三灵敏度计算
C8	detailed_results/	真实	使用	1,860 个目录取得有效结果，主样本交集的 964 个用于汇总 37 项任务；六维指标另与完整 C1 逐记录校验

表 30 附件数据利用清单（续）

编号	文件名	性质	是否使用	使用方式与可信度说明
C9	data/ (Parquet)	真实	未使用	与 C1 等价，本文不重复计入
C10	pythia_eval_details/	说明	未使用	只有 README 说明，不能作为 C8 的任务记录使用

附录 B：半合成与外推数据的标注

以下资料不全是直接观测，解释相应结果时需分别考虑其生成方式和评分来源。

- **半合成数据**：B2 为 Cerebras 训练日志，B6/B7/B8 为 NQ 质量实验。本文以 B6 估计质量项，以 B7 新增点作开发阶段验证，5.2 节表格标明其半合成性质。检查来源差异后，B2、B8 均不参加主拟合。

- **外推与估算数据**：A12–A15 的 10B/70B 损失由 1M/60M/1B 记录作幂律外推，B10 则为百亿参数以上的损失估算。它们用来比较估算关系的稳定性，不当作真实训练观测。

- **插值数据**：B3 来自 Pythia 检查点之间的插值，只检查轨迹内部幂指数是否一致，不增加独立观测。

- **混合口径数据**：C3 各年的评测标准并不完全相同，异常记录已检查并剔除。C5/C6 的 Loss 来源和验证集也未完全统一，因此按可比程度分层使用。

附录 C：结果文件与核心求解代码

四问的结果分别保存为 CSV，存放在求解/问题一至问题四/结果/ 目录。表31列出主要文件及其作用，表中省略“求解/问题 X/结果/”这一共同前缀，便于阅读。

表 31 主要结果文件说明

文件	说明
质量指标熵权.csv	22 指标的方向判定、语义说明、信息熵与熵权
质量信号缺失审计.csv	逐指标字段级缺失计数（A1–A3 全量）
质量冲突与一致性.csv	抽样集/扩展集/全量的冲突率、独立基准与 Kendall W
冲突样本裁决汇总.csv	按领域、冲突标记和域内中位数判定汇总记录数

表 31 主要结果文件说明（续）

文件	说明
非线性代理对照_汇总.csv、逐域.csv	核岭与线性基线的同尺度、跨尺度误差
非线性代理对照_预测明细.csv	各模型的折外及检验预测，可直接计算图表指标
非线性代理对照_参数搜索.csv、五折.csv、折分配.csv	训练参数选择及折外误差明细
冲突阈值灵敏度.csv	冲突率随阈值 τ 的变化
抽样集与扩展集域级对照.csv	A1 与 A2/A3 的域级质量对照
质量与损失难度一致性.csv	两套质量口径在 6 个映射域上的排序比较
质量项增量检验.csv	冗余质量特征加入后的 R^2 差值
混合系数矩阵.csv、截距.csv	配比—损失岭回归系数与截距
推荐配比调整.csv	有界推荐配比与调整量
问题一_拟合汇总.csv	各损失域的拟合与检验指标
岭正则敏感性.csv	正则系数灵敏度
经典标度律参数.csv	经典标度律参数、拟合与留出验证指标
质量字段方向审计.csv	B6/B7/B8 的组内相关与方向结论
广义标度律形式对比.csv	四种质量项形式的 R^2 与残差信息评分比较
广义标度律分层验证.csv	6 组数据来源的验证结果
弹性与替代关系.csv、质量参数替代关系.csv	弹性与替代率
领域替代互补_top.csv	领域效应的相似性与差异
B3 轨迹验证.csv	轨迹内 D 幂指数验证
三档预算最优配置.csv、成本函数对比.csv	三档预算与三型成本函数的优化结果
结构性转移识别.csv	结构性转移门槛
上下文长度敏感性.csv	C7 五档上下文长度下的最优配置
质量基线灵敏度.csv	质量基线口径灵敏度
配比项算力等价.csv	配比优化的算力等价效果
筛选漏斗.csv	字段完整性与许可筛选过程，以及模型类型构成

表 31 主要结果文件说明 (续)

文件	说明
C8 逐任务解析结果.csv	C8 成功解析目录的任务级原始指标
C8 逐任务聚合.csv、C8 子任务类别 汇总.csv	子任务前沿与剩余空间
C8 与 C1 一致性校验.csv	C8 与 C1 的秩相关校验
Loss_Benchmark 映射.csv	分层桥接拟合结果
规模时间分解.csv、规模时间分解 _ 长周期.csv	规模/非规模贡献分解
C3 口径异常行.csv	C3 自治性审计剔除的记录
前沿预测.csv、前沿预测 _结构外推 情景.csv	能力前沿预测与情景
C4 宏观趋势.csv、C4 宏观摘要.csv	C4 宏观算力与开源权重证据
求解/广义标度律参数.csv、问题一 _ 关键量.json	跨问共享的接口参数

附录 D：人工智能工具及输出使用说明

本论文末尾对人工智能工具的实际使用范围作统一说明。腾讯 WorkBuddy 接入 DeepSeek-V4-Flash (2026-07-31 公开测试) 用于文段相关辅助；OpenAI Codex (GPT-5.6-Luna, 2026-07-09) 用于图表展示、排版检查、程序整理、数据整理和结果复核。工具信息见文献 [14, 15, 16]。正文表达与段落衔接另经 OpenAI Codex 辅助润色。

表32集中列示辅助工作的输入类型、涉及内容与核查方式。各问结果附近的辅助分析说明以及各程序开头的工具注释分别保留，以对应竞赛规定对数据分析和辅助编程的标注要求 [27]。

表 32 人工智能辅助内容与核查方式

辅助环节	输入与涉及内容	核查方式与对应位置
论文表达与排版	已有文段、公式、图表及编译后的 PDF；涉及表述衔接、题注、交叉引用与分页	对照公式、结果表和图示检查含义及单位；各问相应结果附近列出辅助说明
图表展示	附件记录或已保存的计算结果；涉及配色、布局、标记和流程图组织	统计图由附录所列程序读取附件记录或保存结果生成；附录 E 列出图号、输入与生成程序的对应关系
程序整理与结果复核	已有求解程序、绘图程序、运行输出；涉及字段解释、数值检查及复现对应关系	程序开头注明辅助范围；输入、参数及计算过程见附录 E 的完整代码清单与程序依赖表
文献检索与引用整理	论证主题与已有引用；涉及候选文献、来源核对和引用次序	依据出版页面、原文摘要或官方文档核对作者、题名与所支持的论述

辅助生成的图形属于计算结果的展示，不能作为新增实验观测；文献检索得到的条目也不代替原始证据。图表和正文采用的数据范围、计算条件及不确定性均在相应章节说明。

附录 E：运行环境与核心实现

各程序的运行输入、参数和输出关系见附录代码清单及表33；各问程序开头注明辅助工具及使用范围。

程序使用 Python 3，主要依赖 NumPy、pandas、SciPy、scikit-learn、Matplotlib 和 Pillow，数据解压及 JSON 读取调用 Python 标准库。四问共用求解/_common.py，附件根目录由环境变量 MODELING_DATA_DIR 或程序参数指定，也可放在项目祖先目录的 real_attachments 下。压缩 JSONL 文件直接读取，无需修改附件。下面列出四问的完整主程序，涵盖数据读取、模型求解、检验和结果输出；公共模块及正式绘图依赖也在后文完整列出，代码清单直接引用实际源文件。

本次运行环境为 Windows 11、Python 3.14.0，依赖版本为 NumPy 2.5.3、pandas 3.0.6、SciPy 1.18.1、scikit-learn 1.9.1、Matplotlib 3.11.2 和 Pillow 12.3.0。复现时将下列 22 份 Python 代码分别按题注中的相对路径保存为 UTF-8 文件，另保留总体流程图的 TikZ 源码。题目附件保留 A_data_value、B_scaling_laws、C_efficiency_evolution 的目录结构。统计绘图使用宋体（SimSun）和 Times New Roman；第三问另需 Adobe 思源宋体文件 SourceHanSerifCN-Regular.otf，放在 论文/fonts/ 下。该字体可从 Adobe 官方项目 <https://github.com/adobe-fonts/source-han-serif> 获取。字体与依赖版本不同可能改变字形及像素排布，数值核对以计算结果为准。

运行时依次执行问题一、问题二和问题三，问题四读取附件 C、可单独运行。问题一输出质量、配比和关键量，问题二据此估计配比修正及广义标度律参数，问题三读取前两问共享文件。各程序的输入、输出关系见表33。

表 33 问题、程序与数据依赖

问题	核心程序	输入	主要输出
一	求解/问题一/ 问题一.py	附件 A	质量评分、回归系数、推荐配比
二	求解/问题二/ 问题二.py	附件 B、问题一结果	标度律参数、验证指标、配比修正
三	求解/问题三/ 问题三.py	前两问共享结果、附件 C7	三档配置、预算扫描与敏感性
四	求解/问题四/ 问题四.py	附件 C	任务聚合、贡献分解与前沿预测

正式图表与复现顺序

从题目附件首次生成结果时，不需要预先准备结果 CSV。安装上述依赖、保存代码和字体后，在项目根目录依次运行以下命令；其中附件路径替换为实际位置，环境变量设置采用 Windows PowerShell 语法。四问主程序在结果保存后调用对应的正式绘图程序，最后一条命令生成第三、四问的方法流程图。

```
$env:MODELING_DATA_DIR="D:/题目附件"
python 求解/问题一/问题一.py
python 求解/问题二/问题二.py
python 求解/问题三/问题三.py
python 求解/问题四/问题四.py
python 求解/绘制问题三四流程图.py
```

已有结果 CSV 时，只复现图形可在项目根目录运行 `python 求解/复现论文.py --data-dir < 附件根目录 > --mode figures`，该模式不重新拟合。已有完整结果作为比较基准时，使用同一入口的 `--mode verify-models`，它在独立目录依次运行四问，按固定的 84 项预期输出清单，先删除隔离副本中的对应文件，再要求逐项重新生成并比较；包括跨问传递的质量映射、关键量 JSON 和标度律参数。缺失、未生成或数值不一致均报错；没有基准的新输出单列为未比较，不计作核对成功。原结果不被覆盖。数值结果按容差比较；核岭配方绝对容差为 10^{-6} 。训练凸组合不唯一，故另验非负性、权重和、配方重建及约束，多初值记录则验目标、可行性和驻点间隙，不要求非唯一权重与迭代次数逐项相同；第三问使用无量纲预算约束以改善求解稳定性。

补充的决策与时间检验使用 `python 求解/补充检验.py --data-dir < 附件根目录 >`，输出写入独立复现记录目录；其中包括相同加权目标的选优、配方预测分歧、质量结构与收益迁移敏感性、时间留出对照，均不替换四问保存结果。

核岭的独立计算入口为问题一目录中的“非线性代理对照.py”，参数搜索、折分配、预测明细和汇总分别保存。绘图只读取这些输出；核岭支持域推荐程序读取其固定超参数，在训练凸包和既有配比上限内搜索；问题二、三沿用该推荐的核岭损失差，线性系数仅作领域作用解释。总体流程图为原生 TikZ；其余正式图的生成程序见表34，流程图属于方法示意，不代表新增观测数据。

表 34 正式图表与生成程序的对应关系

正文图号	生成程序（Python 路径相对求解目录）	输入或图形内容
图1	论 文/figures/overall-architecture.tex	总体建模流程；原生 TikZ 源码
图2	问题一/重绘图表.py	质量评价、配比预测与核岭支持域推荐流程
图3	问题一/重绘图表.py	全量领域质量评分、抽样与扩展域级对照
图4	问题一/重绘图表.py	冲突指标对与熵权结果
图5	问题一/重绘图表.py	附件 A4 的 512 组训练配方
图6	问题一/重绘图表.py	线性拟合汇总、附件 A4–A11
图7	问题一/重绘图表.py	非线性代理对照逐域表及预测明细
图8	问题一/重绘图表.py	17×13 中心化混合系数矩阵
图9	问题一/重绘图表.py	线性系数、截距及附件 A6–A7
图10	问题一/重绘图表.py	损失代理评分、文本评分与附件 A16 映射
图11	问题一/重绘图表.py	附件 A4–A5、A8–A9、A12–A15
图12	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图13	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图14	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图15	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图16	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图17	问题二/重绘图表.py	问题二保存参数、结果与附件 B

表 34 正式图表与生成程序的对应关系（续）

正文图号	生成程序（Python 路径相对求解目录）	输入或图形内容
图18	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图19	问题二/重绘图表.py	问题二保存参数、结果与附件 B
图20	绘制问题三四流程图.py	对应小问的方法与输入输出关系
图21	问题三/论文绘图.py	问题三保存的预算、成本与上下文扫描 CSV
图22	问题三/论文绘图.py	问题三保存的预算、成本与上下文扫描 CSV
图23	问题三/论文绘图.py	问题三保存的预算、成本与上下文扫描 CSV
图24	绘制问题三四流程图.py	对应小问的方法与输入输出关系
图25	问题四/重绘图表.py	损失-得分映射结果与附件 C6
图26	问题四/重绘图表.py	记录级规模一年份回归结果与附件 C1、C3
图27	问题四/重绘图表.py	近期与长周期贡献分解结果
图28	问题四/重绘图表.py	前沿序列、logistic 参数及两类情景预测
图29	问题四/重绘图表.py	经许可筛选的附件 C1 六维得分
图30	问题四/重绘图表.py	附件 C8 的 37 项子任务聚合结果
图31	问题四/重绘图表.py	附件 C4 宏观趋势与字段覆盖结果

附录 F：问题三图表的计算公式与口径

本附录只补充正文图表的计算口径。正文仍保留问题三的核心模型和必要推导；这里说明图中的曲线、标记和柱高如何由模型输出或结果文件得到。流程图是方法示意，不对应额外的数值公式。

1. 预算与费用份额图 预算扫描在固定上下文长度、配比情景和质量成本形式下，逐个预算点求解正文式(35)，得到 (N^*, D^*, Q^*) 。图中的质量完成度和质量处理份额分别按

$$\Theta = \frac{Q^* - Q_0}{1 - Q_0}, \quad f_Q = \frac{D^* [g(Q^*) - g(Q_0)]}{C_b} \quad (51)$$

计算。基础训练和注意力份额为

$$f_{\text{base}} = \frac{6N^*D^*}{C_b}, \quad f_{\text{attn}} = \frac{\eta N^*D^*L_{\text{ctx}}}{C_b}. \quad (52)$$

三类份额之和在数值误差范围内等于 1。图中每个标记对应“预算扫略.csv”中的一条有效记录；启动点和饱和点是在该离散预算网格上识别的首次正质量投入和首次达到 $Q = 1$ 的记录。

2. 成本形式比较图 成本形式比较图不重新采样解析函数，而是直接读取“成本函数对比.csv”的九组求解记录。每个柱子的质量高度为记录中的 Q^* ，质量投入柱高为 $100f_Q$ ；其中 f_Q 仍按式(51)计算。三种成本函数为正文表15中的 $g(Q)$ ，其差异通过预算约束影响最优配置。

3. 上下文敏感性图 上下文敏感性图固定预算和成本形式，对给定的 L_{ctx} 重新求解配置。注意力与基础训练的成本比为

$$\lambda = \frac{\eta L_{\text{ctx}}}{6}, \quad L_{\text{crit}} = \frac{6}{\eta} = 30,000 \text{ tokens}. \quad (53)$$

左图直接使用“上下文长度连续扫描.csv”中的 L_{ctx} 与 N^* ；右图使用“上下文长度与最优质量.csv”中的 L_{ctx} 与 Q^* 。C7 的五个离散档位来自“上下文长度敏感性.csv”，作为方形标记叠加在左图中。缺失或求解失败的记录不补插值，图中只连接已有有效记录。

上述公式只用于把已保存的求解结果转换为图中坐标或份额，图表不构成新的实验观测；输入文件、生成程序及复现命令见本附录表34和代码清单。

问题一：质量评价、冲突统计与配比建模

```

1 # -*- coding: utf-8 -*-
2 # 本程序及代码的整理与核对使用人工智能工具 Codex 辅助。
3 # 模型：GPT-5.6-Luna；开发机构：OpenAI。
4 # 版本发布日期：2026-07-09（型号发布）。
5 """
6 问题一：数据质量评价、质量冲突消解与领域配比建模
7 数据：附件 A（A1-A3 质量信号；A4-A15 配方/Loss；A16 域映射）
8 方法：1) 22 指标方向统一 + 1%--99% 分位数截断归一化 + 熵权法三
          级综合评分（样本/语料/领域）
9         2) 成对 z 分数差冲突定义 + Kendall 协同系数一致性检验 +
          域内中位数裁决
10        3) 岭正则线性混合回归刻画 17 域配比 -> 13 域损失，并对照
          冗余质量特征的拟合变化
11 输出：图片到 图片/，结果 CSV 到 结果/

```

```

12 """
13 import sys, os, json, lzma, glob
14 sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.
    abspath(__file__))))
15 from _common import *    # noqa: F401,F403
16
17 DATA = data_path
18 RC_FAILS = []
19
20 def save_csv_safe(df, name_cn):
21     """保存 CSV; 若目标被其他进程占用则回退为 *_new.csv, 保证
    流程不中断。"""
22     p = os.path.join(OUT_DIR, name_cn)
23     try:
24         df.to_csv(p, index=False, encoding='utf-8-sig')
25     except PermissionError:
26         alt = os.path.join(OUT_DIR, name_cn.replace('.csv', '_
    _new.csv'))
27         df.to_csv(alt, index=False, encoding='utf-8-sig')
28         RC_FAILS.append((name_cn, os.path.basename(alt)))
29         print('    ! %s 被占用, 已改存为 %s' % (name_cn, os.path
    .basename(alt)))
30
31 # ===== 0. 22 个质量指标的方向定义 =====
32 # positive = 越大越好; negative = 越小越好; target = 越接近稳
    健中心越好
33 QUALITY_COLS = [
34     'fineweb_edu', 'fluency_en', 'modernbert_cleanliness',
35     'modernbert_readability', 'modernbert_reasoning',
36     'modernbert_professionalism', 'dsir_books', 'dsir_wiki', '
    dsir_math',
37     'qurater', 'ad_en', 'rps_doc_word_count', '
    rps_doc_num_sentences',
38     'rps_doc_unigram_entropy', 'rps_doc_frac_unique_words',
39     'rps_doc_frac_no_alph_words', '
    rps_doc_frac_chars_top_2gram',
40     'rps_doc_frac_chars_top_3gram', '
    rps_lines_uppercase_letter_fraction',

```

```

41     'rps_lines_ending_with_terminal_punctution_mark',
42     'rps_lines_numerical_chars_fraction', '
    rps_doc_mean_word_length'
43 ]
44 NEGATIVE_COLS = {
45     'rps_doc_frac_no_alph_words', '
    rps_doc_frac_chars_top_2gram',
46     'rps_doc_frac_chars_top_3gram', '
    rps_lines_uppercase_letter_fraction',
47     'rps_lines_numerical_chars_fraction'
48 }
49 TARGET_COLS = {'rps_doc_word_count', 'rps_doc_num_sentences',
    'rps_doc_mean_word_length'}
50 LIST_COLS = ['fineweb_edu', 'fluency_en', '
    modernbert_cleanliness',
51             'modernbert_readability', 'modernbert_reasoning',
52             'modernbert_professionalism', 'qurater', 'ad_en']
53 DIRECTION_NOTE = {
54     'fineweb_edu': '教育价值（列表型，1 维 logit）',
55     'fluency_en': '英语流畅度（列表型，2 维，取第 2 类概率）',
56     'modernbert_cleanliness': '文本洁净度（列表型，6 级，取归
    一化期望级别）',
57     'modernbert_readability': '可读性（列表型，6 级）',
58     'modernbert_reasoning': '推理性（列表型，6 级）',
59     'modernbert_professionalism': '专业性（列表型，6 级）',
60     'dsir_books': 'DSIR 书籍域重要性权重',
61     'dsir_wiki': 'DSIR 维基域重要性权重',
62     'dsir_math': 'DSIR 数学域重要性权重',
63     'qurater': 'QuRating 四维质量（各维稳健归一化后等权聚合）'
    ,
64     'ad_en': '广告含量（列表型，2 维；第 1 类=“无广告”，正
    向。依据：原文抽查显示第 1 类概率最低的样本均为广告文案）',
65     'rps_doc_word_count': '文档词数（过短/过长均不佳）',
66     'rps_doc_num_sentences': '文档句数（过少/过多均不佳）',
67     'rps_doc_unigram_entropy': '一元词熵（越高越多样）',
68     'rps_doc_frac_unique_words': '唯一词占比（越高越多样）',
69     'rps_doc_frac_no_alph_words': '非字母字符占比（越低越好）'
    ,

```

```

70     'rps_doc_frac_chars_top_2gram': 'Top-2 字符 2-gram 占比
    (重复度, 越低越好) ',
71     'rps_doc_frac_chars_top_3gram': 'Top-2 字符 3-gram 占比
    (重复度, 越低越好) ',
72     'rps_lines_uppercase_letter_fraction': '大写字母行占比 (越
    低越好) ',
73     'rps_lines_ending_with_terminal_punctution_mark': '以终止
    标点结尾的行占比 (越高越好) ',
74     'rps_lines_numerical_chars_fraction': '含数字字符行占比
    (越低越好) ',
75     'rps_doc_mean_word_length': '平均词长 (过短/过长均不佳) ',
76 }
77 CONFLICT_TAU = 1.5      # 成对 z 分数差阈值
78
79 def _softmax_expected(v):
80     """把有序类别 logits 压缩为 [0,1] 上的归一化期望级别。"""
81     a = np.asarray(v, dtype=float).ravel()
82     if len(a) == 0:
83         return np.nan
84     if len(a) == 1:
85         return float(a[0])
86     a = a - np.nanmax(a)
87     p = np.exp(a); p = p / np.nansum(p)
88     return float(p @ np.linspace(0.0, 1.0, len(a)))
89
90 def aggregate_qurater(values):
91     """四维含义依次为写作风格、所需专业知识、事实知识、教育价
    值。
92
93     本文选取四维同向等权；各维缺失以中位数填补，按1%--99%分位
    缩放。
94     聚合后作为22指标之一，仍进入统一的外层方向与分位归一化。
95     """
96     a = np.asarray(values, dtype=float)
97     if a.ndim != 2 or a.shape[1] != 4:
98         raise ValueError('qurater 应为四个维度，而非类别
    logits')
99     a = np.where(np.isfinite(a), a, np.nan)

```

```

100     med = np.nanmedian(a, axis=0)
101     if not np.isfinite(med).all():
102         raise ValueError('qurater 某维无有效记录')
103     a = np.where(np.isnan(a), med, a)
104     lo, hi = np.quantile(a, [.01, .99], axis=0)
105     return np.clip((a-lo)/np.maximum(hi-lo, 1e-12), 0, 1).mean
    (axis=1)
106
107
108 def _scalarize(name, value):
109     if name == 'qurater':
110         return np.nan # 读取全量四维后单独归一化聚合
111     if value is None:
112         return np.nan
113     if isinstance(value, (list, tuple)):
114         return _softmax_expected(value)
115     try:
116         return float(value)
117     except Exception:
118         return np.nan
119
120 def _norm_domain(x):
121     s = str(x).lower().replace('-', '_').replace(' ', '_')
122     aliases = {'common_crawl': 'commoncrawl', 'books': 'book',
123               'wikipedia_en': 'wikipedia'}
124     return aliases.get(s, s)
125
126 def load_quality_records():
127     """流式读取 A1-A3 全量记录，只保留建模字段和 A1 原文摘要。
128     """
129     sample_path = DATA('slimpajama_quality_signal_sample.jsonl
130 ')
131     ext_paths = sorted(glob.glob(os.path.join(DATA_DIR, '
132 A_data_value',
133
134
135 slimpajama_quality_extended', '*.jsonl.xz'))
136     rows, meta, qurater_values = [], [], []
137     miss = {c: 0 for c in QUALITY_COLS}

```

```

132
133     def _is_missing(v):
134         """字段级缺失判定: None、空列表、列表内含 None/NaN、标
135         量为非有限数均计为缺失。"""
136         if v is None:
137             return True
138         if isinstance(v, (list, tuple)):
139             if len(v) == 0:
140                 return True
141             return any((x is None) or (isinstance(x, float)
142 and not np.isfinite(x)) for x in v)
143         try:
144             return not np.isfinite(float(v))
145         except Exception:
146             return True
147
148     def consume(path, source, domain_hint=None):
149         opener = lzma.open if path.endswith('.xz') else open
150         with opener(path, 'rt', encoding='utf-8') as fh:
151             for line in fh:
152                 try:
153                     obj = json.loads(line)
154                     except Exception:
155                         continue
156                     domain = _norm_domain(obj.get('_source_domain'
157 , domain_hint))
158                     for c in QUALITY_COLS:
159                         if _is_missing(obj.get(c)):
160                             miss[c] += 1
161                         rows.append([_scalarize(c, obj.get(c)) for c
162 in QUALITY_COLS])
163                     q = obj.get('qurater')
164                     if q is not None and (not isinstance(q, (list,
165 tuple)) or len(q) != 4):
166                         raise ValueError('qurater 维数错误')
167                     qurater_values.append(q if q is not None else
168 [np.nan]*4)
169
170     excerpt = ''

```

```

164         if source == 'A1':
165             excerpt = ' '.join(str(obj.get('content',
166             '')).split())[:180]
167             meta.append((obj.get('id', ''), domain, source
168             , excerpt))
169
170     consume(sample_path, 'A1')
171     for path in ext_paths:
172         hint = 'arxiv' if os.path.basename(path).lower().
173         startswith('arxiv') else 'github'
174         consume(path, 'A2' if hint == 'arxiv' else 'A3', hint)
175     X = pd.DataFrame(rows, columns=QUALITY_COLS)
176     X['qurater'] = aggregate_qurater(qurater_values)
177     M = pd.DataFrame(meta, columns=['id', 'domain', 'source',
178     'excerpt'])
179     miss_df = pd.DataFrame([{'indicator': k, 'missing_count':
180     v} for k, v in miss.items()])
181     save_csv_safe(miss_df, '质量信号缺失审计.csv')
182     if miss_df.missing_count.sum() > 0:
183         print('\n质量信号缺失审计（合计 %d 个指标取值缺失）： '
184         % int(miss_df.missing_count.sum()))
185         print(miss_df[miss_df.missing_count > 0].to_string(
186         index=False))
187         print('  处理方式：方向统一前按该指标中位数填充（不把
188         缺失当作高质量或低质量）。')
189     return X, M
190
191 def orient_and_normalize(raw):
192     """方向统一 -> 分位数截断的稳健极差归一化（正向缩放、负向
193     取补、长度型转中心接近度）。"""
194     oriented = raw.copy()
195     for c in TARGET_COLS:
196         z = np.loglp(np.clip(raw[c].values, 0, None))
197         med = np.median(z); mad = np.median(np.abs(z - med)) +
198         1e-9
199         oriented[c] = np.exp(-np.abs(z - med) / (2.5 * mad))
200     norm = pd.DataFrame(index=raw.index)
201     for c in QUALITY_COLS:

```

```

192         lo, hi = np.nanquantile(oriented[c], [0.01, 0.99])
193         v = np.clip((oriented[c] - lo) / max(hi - lo, 1e-12),
194 0, 1)
195         norm[c] = 1 - v if c in NEGATIVE_COLS else v
196     return oriented, norm
197
198 def kendall_concordance(values):
199     """对象为行、评价指标为列；平均秩并扣除各列的并列秩修正
200     项。"""
201     values = np.asarray(values, dtype=float)
202     if values.ndim != 2 or not np.isfinite(values).all():
203         raise ValueError('Kendall W 需要有限值二维矩阵')
204     m, n = values.shape
205     if m < 2 or n < 2:
206         raise ValueError('Kendall W 至少需要两个对象和两个评价
207 指标')
208     rank_sum = np.zeros(m)
209     tie_term = 0
210     for column in values.T:
211         rank_sum += stats.rankdata(column, method='average')
212         _, counts = np.unique(column, return_counts=True)
213         # 转成 Python 整数，避免大样本分母乘法发生 int64 溢
214         # 出。
215         tie_term += sum(int(t)**3 - int(t) for t in counts if
216 t > 1)
217     denominator = n**2 * (m**3 - m) - n * tie_term
218     if denominator <= 0:
219         raise ValueError('所有指标均无排序差异，Kendall W 未定
220 义')
221     return float(12 * np.sum((rank_sum - rank_sum.mean())**2)
222 / denominator)
223
224 def quality_evaluation():
225     raw, meta = load_quality_records()
226     raw = raw.replace([np.inf, -np.inf], np.nan)
227     raw = raw.apply(lambda s: s.fillna(s.median()))
228     _, norm = orient_and_normalize(raw)

```

```

223
224 # ---- 熵权法（主方案） ----
225 P = (norm.values + 1e-12) / (norm.values.sum(axis=0,
keepdims=True) + 1e-12)
226 entropy = -(P * np.log(P)).sum(axis=0) / np.log(len(norm))
227 divergence = np.maximum(1 - entropy, 0)
228 w_entropy = divergence / divergence.sum()
229 # ---- 对照方案：等权 / 首主成分非负载荷加权 ----
230 w_equal = np.full(len(QUALITY_COLS), 1.0 / len(
QUALITY_COLS))
231 Z = (norm.values - norm.values.mean(0)) / (norm.values.std
(0) + 1e-12)
232 _, _, vt = np.linalg.svd(Z, full_matrices=False)
233 pc1 = vt[0]
234 if pc1.sum() < 0:
235     pc1 = -pc1
236 w_pca = np.clip(pc1, 0, None); w_pca = w_pca / w_pca.sum()
237
238 # CSV 的历史字段名“PCA第一主成分”表示非负载荷加权，并非
标准主成分得分。
239 names = ['熵权法', '等权平均', 'PCA第一主成分']
240 wdict = dict(zip(names, [w_entropy, w_equal, w_pca]))
241 sc = {k: norm.values @ wdict[k] for k in names}
242 dom_tmp = meta.assign(**sc).groupby('domain')[names].mean
()
243 cmp_df = pd.DataFrame({
244     'scheme': names,
245     'score_mean': [sc[k].mean() for k in names],
246     'score_std': [sc[k].std() for k in names],
247     'corr_with_entropy': [float(np.corrcoef(sc[k], sc['熵
权法'])[0, 1]) for k in names],
248     'domain_spearman_vs_entropy': [1.0,
249         stats.spearmanr(dom_tmp['熵权法'], dom_tmp['等权平
均']).statistic,
250         stats.spearmanr(dom_tmp['熵权法'], dom_tmp['PCA第
一主成分']).statistic]])
251 save_csv_safe(cmp_df, '赋权方案对比.csv')
252

```

```

253     # 仅作判向敏感性对照：将广告方向反转后重新计算熵权，不替换
      主评分。
254     flipped = norm.copy()
255     flipped['ad_en'] = 1 - flipped['ad_en']
256     pf = (flipped.values + 1e-12) / (flipped.values.sum(0,
      keepdims=True) + 1e-12)
257     ef = -(pf * np.log(pf)).sum(0) / np.log(len(flipped))
258     wf = np.maximum(1-ef, 0); wf /= wf.sum()
259     direction_check = meta[['domain']].assign(
260         main_score=sc['熵权法'], reversed_ad_score=flipped.
      values @ wf
261     ).groupby('domain').mean().reset_index()
262     save_csv_safe(direction_check, '广告方向敏感性.csv')
263
264     wdf = pd.DataFrame({'indicator': QUALITY_COLS,
265                         'list_type': [c in LIST_COLS for c in
      QUALITY_COLS],
266                         'direction': ['negative' if c in
      NEGATIVE_COLS else
267                                     ('target' if c in
      TARGET_COLS else 'positive')]
268                                     for c in QUALITY_COLS},
269                         'semantics': [DIRECTION_NOTE[c] for c
      in QUALITY_COLS],
270                         'entropy': entropy, 'weight':
      w_entropy})
271     save_csv_safe(wdf, '质量指标熵权.csv')
272     meta['quality_Q'] = sc['熵权法']
273
274     # ---- 冲突分析：成对 z 分数差 > tau ----
275     def agreement(idx, label):
276         Zs = norm.loc[idx]
277         m, n = Zs.shape                                # m 条文本（对
      象），n=22 指标（评价者）
278         W = kendall_concordance(Zs.values)
279         Am = (Zs.values - Zs.values.mean(axis=0)) / (Zs.values
      .std(axis=0) + 1e-12)
280         iu = np.triu_indices(n, 1)

```

```

281     pairdiff = np.abs(Am[:, iu[0]] - Am[:, iu[1]])
282     rate = float((pairdiff > CONFLICT_TAU).mean())
283     rate_free = float(2 * stats.norm.sf(CONFLICT_TAU / np.
sqrt(2)))
284     chi2 = n * (m - 1) * W
285     pair_rate = pd.Series((pairdiff > CONFLICT_TAU).mean(
axis=0),
286                           index=['%s|%s' % (QUALITY_COLS[i
], QUALITY_COLS[j])
287                               for i, j in zip(*iu)])
288     return {'dataset': label, 'n': m, 'kendall_W': W, '
chi2': chi2,
289            'p_value': stats.chi2.sf(chi2, m - 1),
290            'conflict_rate': rate, 'indep_baseline':
rate_free,
291            'conflict_ratio_vs_indep': rate / rate_free},
pair_rate
292
293     ag, pair_table = [], {}
294     for idx, label in [(meta.index[meta.source == 'A1'], 'A1抽
样集'),
295                       (meta.index[meta.source != 'A1'], 'A2+
A3扩展集'),
296                       (meta.index, '全量')]:
297         a, pf = agreement(idx, label)
298         ag.append(a); pair_table[label] = pf
299         save_csv_safe(pd.DataFrame(ag), '质量冲突与一致性.csv')
300         top_pairs = pair_table['全量'].sort_values(ascending=False
).head(20).rename('conflict_rate')
301         save_csv_safe(top_pairs.reset_index().rename(columns={'
index': 'indicator_pair'}),
302                       '冲突指标对_top20.csv')
303
304     # ---- 冲突阈值灵敏度: tau 变动对冲突率与结论的影响 ----
305     thr_rows = []
306     Zall = (norm.values - norm.values.mean(axis=0)) / (norm.
values.std(axis=0) + 1e-12)
307     iu_all = np.triu_indices(22, 1)

```

```

308     pd_all = np.abs(Zall[:, iu_all[0]] - Zall[:, iu_all[1]])
309     # 样本至少一对指标超过阈值即作标记；冲突率仍指“样本×指标
    对”的比例。
310     # 裁决仅提供域内相对标签，不删样本、不降权，也不改变质量评
    分。
311     flagged = (pd_all > CONFLICT_TAU).any(axis=1)
312     median = meta.groupby('domain')['quality_Q'].transform('
median')
313     decision = np.where(meta.quality_Q > median, '高于域中位数
    ',
314                        np.where(meta.quality_Q < median, '低
    于域中位数', '等于域中位数'))
315     diagnostic = meta[['domain']].assign(conflict_flag=flagged
    , decision=decision)
316     summary = diagnostic.groupby(['domain', 'conflict_flag', '
decision']).size().reset_index(name='n')
317     save_csv_safe(summary, '冲突样本裁决汇总.csv')
318     for tau in [0.5, 1.0, 1.5, 2.0, 2.5]:
319         rc = float((pd_all > tau).mean())
320         r0 = float(2 * stats.norm.sf(tau / np.sqrt(2)))
321         thr_rows.append({'阈值tau': tau, '冲突率': rc, '独立基
    准': r0,
322                        '比值': rc / r0, '结论': '指标正相关
    (冲突率低于独立基准)'
323                        if rc < r0 else '指标间无正相关'})
324     save_csv_safe(pd.DataFrame(thr_rows), '冲突阈值灵敏度.csv'
    )
325
326     # ---- 域级质量：抽样集与扩展集对照 ----
327     domain = meta.groupby(['source', 'domain']).agg(
328         n=('quality_Q', 'size'), quality_mean=('quality_Q', '
mean'),
329         quality_std=('quality_Q', 'std')).reset_index()
330     save_csv_safe(domain, '质量域评分_抽样与扩展.csv')
331     comp = domain.pivot(index='domain', columns='source',
    values='quality_mean')
332     a1 = comp['A1']
333     ext = comp.drop(columns=[c for c in comp.columns if c == '

```

```

A1'])).mean(axis=1)
334     comp_out = pd.DataFrame({'domain': comp.index, 'Q_A1': a1.
values, 'Q_扩展集': ext.values})
335     comp_out['差值_A1减扩展'] = comp_out['Q_A1'] - comp_out['
Q_扩展集']
336     save_csv_safe(comp_out, '抽样集与扩展集域级对照.csv')
337     save_csv_safe(meta[['id', 'domain', 'source', 'quality_Q'
]], '样本级质量评分.csv')
338
339     # ---- 高低分原文抽查（验证评分方向） ----
340     checks = []
341     s1 = meta[meta.source == 'A1']
342     for d, g in s1.groupby('domain'):
343         checks.append(g.nsmallest(2, 'quality_Q').assign(group
='低分'))
344         checks.append(g.nlargest(2, 'quality_Q').assign(group=
'高分'))
345     save_csv_safe(pd.concat(checks)[['domain', 'group', '
quality_Q', 'excerpt']], '原文抽查.csv')
346
347     # ---- A16 跨体系映射 ----
348     pooled = meta.groupby('domain')['quality_Q'].mean().
to_dict()
349     mapping = pd.read_csv(DATA('domain_mapping_guide.csv'))
350     global_q = float(meta.quality_Q.mean())
351     mapping['quality_Q'] = [pooled.get(str(q), global_q) if
str(q) != '(none)' else global_q
352                             for q in mapping['quality_domain'
]]
353     mapping['quality_source'] = np.where(mapping.
quality_domain.eq('(none)'),
354                                         '全局均值推断', 'A1-
A3域映射')
355     save_csv_safe(mapping, '17域质量映射.csv')
356     mapping.to_csv(shared_path('17域质量映射.csv'), index=
False, encoding='utf-8-sig')
357     print('质量全量记录 %s 条; A1=%s, A2+A3=%s' % (f'{len(meta
):,}',

```

```

358         f'{int((meta.source == "A1").sum()):,}', f'{int((
meta.source != "A1").sum()):,}'))
359     print(pd.DataFrame(ag).to_string(index=False))
360     print('\n赋权方案对比: ')
361     print(cmp_df.to_string(index=False))
362     print('\nad_en 熵权 = %.4f (方向敏感性另列对照) '
363           % w_entropy[QUALITY_COLS.index('ad_en')])
364     print('冲突最集中的 5 组指标对: ')
365     print(top_pairs.head(5).to_string())
366     return meta, domain, mapping, norm, w_entropy, pair_table
367
368 # ===== 1. A1-A3 全量质量评价与冲突检验 =====
369 (quality_meta, quality_compare, quality_mapping,
370  quality_norm, quality_weights, quality_pairs) =
371     quality_evaluation()
372 quality_domain = quality_meta.groupby('domain').agg(
373     n=('quality_Q', 'size'), quality_mean=('quality_Q', 'mean'
374     ),
375     quality_std=('quality_Q', 'std')).reset_index().
376     sort_values('quality_mean')
377 save_csv_safe(quality_domain, '质量域评分_全量.csv')
378
379 # ===== 2. 配比与 Loss 数据加载 =====
380 def load_pair(mix_path, loss_path):
381     m = pd.read_csv(mix_path).sort_values('index').reset_index
382     (drop=True)
383     l = pd.read_csv(loss_path).sort_values('index').
384     reset_index(drop=True)
385     mix_cols = [c for c in m.columns if c.startswith('
train_the_pile_')]
386     loss_cols = [c for c in l.columns if 'val_loss' in c]
387     return m[mix_cols].values.astype(float), l[loss_cols].
388     values.astype(float), m['index'].values
389
390 def short(c):
391     return c.replace('train_the_pile_', '').replace('metric/
the_pile_', '').replace('_val_loss', '')

```

```

387 Xtr, Ytr, itr = load_pair(DATA('train_mixture_1m.csv'), DATA('
    train_pile_loss_1m.csv'))
388 Xte1, Yte1, _ = load_pair(DATA('test_mixture_1m.csv'), DATA('
    test_pile_loss_1m.csv'))
389 Xte2, Yte2, _ = load_pair(DATA('test_mixture_60m.csv'), DATA('
    test_pile_loss_60m.csv'))
390 Xte3, Yte3, _ = load_pair(DATA('test_mixture_1B.csv'), DATA('
    test_pile_loss_1B.csv'))
391 Xes10, Yes10, es10_idx = load_pair(DATA('est_mixture_10b.csv')
    , DATA('est_pile_loss_10b.csv'))
392 Xes70, Yes70, es70_idx = load_pair(DATA('est_mixture_70b.csv')
    , DATA('est_pile_loss_70b.csv'))
393
394 tm_df = pd.read_csv(DATA('train_mixture_1m.csv'))
395 MIX_COLS = [c for c in tm_df.columns if c.startswith('
    train_the_pile_')]
396 tl_df = pd.read_csv(DATA('train_pile_loss_1m.csv'))
397 LOSS_COLS = [c for c in tl_df.columns if 'val_loss' in c]
398 DOMAINS = [short(c) for c in MIX_COLS]
399 LOSS_DOMAINS = [short(c) for c in LOSS_COLS]
400 UNMEASURED = ['nih_exporter', 'enron_emails', 'europarl', '
    philpapers'] # 无损失列
401 MEASURED = [d for d in DOMAINS if d not in UNMEASURED]
402
403 # ===== 3. 岭正则线性混合回归 =====
404 def fit_ridge(X, Y, alpha=1e-3):
405     n, K = X.shape
406     Xc = np.hstack([X, np.ones((n, 1))])
407     reg = alpha * np.eye(K + 1); reg[-1, -1] = 0
408     W = np.linalg.solve(Xc.T @ Xc + reg, Xc.T @ Y)
409     return W[:K], W[-1]
410
411 def predict(X, A, b):
412     return X @ A + b
413
414 def r2(y, yhat):
415     ss_res = np.sum((y - yhat) ** 2, axis=0)
416     ss_tot = np.sum((y - y.mean(axis=0)) ** 2, axis=0)

```

```

417         return 1 - ss_res / np.maximum(ss_tot, 1e-12)
418
419 def pearson_col(y, yhat):
420     return np.array([np.corrcoef(y[:, j], yhat[:, j])[0, 1]
421                     for j in range(y.shape[1])])
422
421 A, b = fit_ridge(Xtr, Ytr)
422 r2_tr = r2(Ytr, predict(Xtr, A, b))
423 r2_te1 = r2(Yte1, predict(Xte1, A, b))
424 r_te2 = pearson_col(Yte2, predict(Xte2, A, b))
425 r_te3 = pearson_col(Yte3, predict(Xte3, A, b))
426
427
428 print('\n=== 岭回归训练 R2 (各损失域) ===')
429 for d, v in zip(LOSS_DOMAINS, r2_tr):
430     print(' %-20s %.4f' % (d, v))
431 print('训练平均 R2 = %.4f; 同尺度 1M 检验平均 R2 = %.4f' % (
432     r2_tr.mean(), r2_te1.mean()))
433 print('跨尺度 Pearson: 60M 平均 %.4f, 1B 平均 %.4f' % (r_te2.
434     mean(), r_te3.mean()))
435
433 A_df = pd.DataFrame(A, columns=LOSS_DOMAINS)
434 A_df.insert(0, 'training_domain', DOMAINS)
435 save_csv_safe(A_df, '混合系数矩阵.csv')
436 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
437     intercept': b}), '截距.csv')
438
437
438 lam_rows = []
439 for lam in [1e-4, 1e-3, 1e-2, 1e-1]:
440     A1, b1 = fit_ridge(Xtr, Ytr, lam)
441     lam_rows.append({'lambda': lam, 'train_mean_R2': r2(Ytr,
442         predict(Xtr, A1, b1)).mean(),
443         'test1m_mean_R2': r2(Yte1, predict(Xte1,
444             A1, b1)).mean(),
445         'coef_L2': float(np.linalg.norm(A1))})
446 save_csv_safe(pd.DataFrame(lam_rows), '岭正则敏感性.csv')
447
448
449 # ===== 4. 质量信息引入配比模型的增量检验 =====
450 qmap = quality_mapping.set_index('mixture_domain')['quality_Q'
451     ]

```

```

448 qvec = np.array([qmap.get(d, np.nan) for d in DOMAINS], dtype=
    float)
449 qvec = np.where(np.isnan(qvec), float(quality_meta.quality_Q.
    mean()), qvec)
450 Zq = np.hstack([Xtr, (Xtr @ qvec)[:, None]])
451 Az, bz = fit_ridge(Zq, Ytr, 1e-3)
452 r2_z = r2(Ytr, predict(Zq, Az, bz))
453 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
    train_R2_仅配比': r2_tr,
454                             'train_R2_追加Qbar': r2_z, 'R2增量
    ': r2_z - r2_tr,
455                             'Qbar系数': Az[-1]}), '质量项增量
    检验.csv')
456
457 diff_mean = Ytr.mean(axis=0)
458 quality_proxy = 1 - (diff_mean - diff_mean.min()) / (diff_mean
    .max() - diff_mean.min())
459 q_df = pd.DataFrame({'domain': LOSS_DOMAINS, 'mean_loss(
    difficulty)': diff_mean,
460                      'quality_score_Q(loss代理)':
    quality_proxy}).sort_values(
461     'quality_score_Q(loss代理)', ascending=False)
462 save_csv_safe(q_df, 'Loss代理领域难度.csv')
463 save_csv_safe(q_df, '领域质量评分.csv')
464
465 link = pd.read_csv(DATA('domain_mapping_guide.csv'))
466 link = link[link.mapping_type.isin(['direct', 'near_direct'])
    ].copy()
467 qd_map = quality_domain.set_index('domain').quality_mean
468 qp_map = q_df.set_index('domain')['quality_score_Q(loss代理)']
469 link['Q_A1A3'] = [float(qd_map.get(q, np.nan)) for q in link.
    quality_domain]
470 link['Q_loss代理'] = [float(qp_map.get(m, np.nan)) for m in
    link.mixture_domain]
471 rho_link = float(stats.spearmanr(link.Q_A1A3, link.Q_loss代理)
    .statistic)
472 save_csv_safe(link[['mixture_domain', 'quality_domain', '
    mapping_type', 'Q_A1A3', 'Q_loss代理']],

```

```

473         '质量与损失难度一致性.csv')
474
475 A_cent = A - A.mean(axis=0, keepdims=True)
476 A_cent_df = pd.DataFrame(A_cent, columns=LOSS_DOMAINS)
477 A_cent_df.insert(0, 'training_domain', DOMAINS)
478 save_csv_safe(A_cent_df, '混合系数矩阵_中心化.csv')
479 save_csv_safe(pd.DataFrame({'training_domain': DOMAINS,
480                             'marginal_effect_on_avg_loss':
481                               A_cent.mean(axis=1)}),
482               '训练域边际效应.csv')
483
484 # ===== 5. 外推与跨尺度稳健性 =====
485 tr_lookup = {i: Ytr[j] for j, i in enumerate(itr)}
486 ratio10 = Yes10 / np.array([tr_lookup[i] for i in es10_idx])
487 ratio70 = Yes70 / np.array([tr_lookup[i] for i in es70_idx])
488 print('\n=== 外推尺度因子 (est/train 损失比) ===')
489 print('  10B 均值 %.4f (std %.4f)' % (ratio10.mean(), ratio10.
490                                     std()))
491 print('  70B 均值 %.4f (std %.4f)' % (ratio70.mean(), ratio70.
492                                     std()))
493 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
494                             scale_factor_10B': ratio10.mean(axis=0),
495                             'scale_factor_70B': ratio70.mean(
496                                 axis=0)}), '外推尺度因子.csv')
497 ratio_scale = Yte2 / Yte1
498 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS,
499                             'loss_ratio_60m_vs_1m':
500                               ratio_scale.mean(axis=0),
501                             'loss_ratio_std': ratio_scale.std(
502                                 axis=0)}),
503               '跨尺度损失比_60m_vs_1m.csv')
504
505 # ===== 6. 最优配比 (无约束 + 2.5 倍上界推荐)
506 # =====
507 from scipy.optimize import minimize
508 ref = Xtr.mean(axis=0)
509 w_ref = ref[[DOMAINS.index(d) for d in LOSS_DOMAINS]]
510 w_ref = w_ref / w_ref.sum()

```

```

503 unmeas_sum = ref[[DOMAINS.index(u) for u in UNMEASURED]].sum()
504 meas_idx = [DOMAINS.index(d) for d in MEASURED]
505
506 def build(pm):
507     p = np.zeros(17); p[meas_idx] = pm
508     for u in UNMEASURED:
509         p[DOMAINS.index(u)] = ref[DOMAINS.index(u)]
510     return p / p.sum()
511
512 def obj(pm):
513     return float(w_ref @ predict(build(pm)[None, :], A, b)[0])
514
515 p0m = ref[meas_idx] / ref[meas_idx].sum()
516 cons = {'type': 'eq', 'fun': lambda pm: pm.sum() - (1 -
    unmeas_sum)}
517 res = minimize(obj, p0m, method='SLSQP', bounds=[(0, 1)] * len
    (MEASURED), constraints=cons)
518 p_opt = build(res.x)
519 save_csv_safe(pd.DataFrame({'domain': DOMAINS, '
    reference_mixture': ref,
520                             'optimal_mixture': p_opt}).
    sort_values('optimal_mixture', ascending=False),
521               '最优配比预测.csv')
522 bnds = [(0, 2.5 * ref[i]) for i in meas_idx]
523 res_b = minimize(obj, p0m, method='SLSQP', bounds=bnds,
    constraints=cons)
524 p_b = build(res_b.x)
525 rec_df = pd.DataFrame({'domain': DOMAINS, 'reference_mixture':
    ref, 'recommended_mixture': p_b,
526                        'adjustment': p_b - ref}).sort_values('
    adjustment', ascending=False)
527 save_csv_safe(rec_df, '线性有界配比对照.csv')
528 print('\n线性对照：无约束最优加权平均损失 %.4f；有界方案 %.4f
    ；参考配方 %.4f'
529       % (obj(res.x), obj(res_b.x), float(w_ref @ predict(ref[
    None, :], A, b)[0])))
530 print('线性有界对照配比（调整量最大增/减各 5 域；正式推荐见后
    续核岭输出）：')

```

```

531 print(rec_df.head(5).to_string(index=False))
532 print(rec_df.tail(5).to_string(index=False))
533
534 # 正式图表由文件末尾的独立绘图入口生成。
535
536 # ===== 8. 汇总 =====
537 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
    train_R2': r2_tr, 'test1m_R2': r2_te1,
538                             'test60m_r': r_te2, 'test1B_r':
    r_te3, 'mean_loss': diff_mean,
539                             'quality_Q(loss代理)':
    quality_proxy}), '问题一_拟合汇总.csv')
540
541 conf = pd.read_csv(os.path.join(OUT_DIR, '质量冲突与一致性.csv
    '))
542 meta_out = {
543     'train_mean_R2': float(r2_tr.mean()), 'test1m_mean_R2':
    float(r2_te1.mean()),
544     'test60m_mean_r': float(r_te2.mean()), 'test1B_mean_r':
    float(r_te3.mean()),
545     'n_quality_records': int(len(quality_meta)),
546     'n_A1': int((quality_meta.source == 'A1').sum()),
547     'n_ext': int((quality_meta.source != 'A1').sum()),
548     'Q0_global_mean': float(quality_meta.quality_Q.mean()),
549     'Q0_mix_weighted': float(ref @ qvec),
550     'kendall_W_full': float(conf.loc[conf.dataset.eq('全量'),
    'kendall_W'].iloc[0]),
551     'conflict_rate_full': float(conf.loc[conf.dataset.eq('全量
    '), 'conflict_rate'].iloc[0]),
552     'conflict_indep_baseline': float(conf.loc[conf.dataset.eq(
    '全量'), 'indep_baseline'].iloc[0]),
553     'spearman_quality_vs_lossproxy': float(rho_link),
554     'Qbar_R2_gain_mean': float((r2_z - r2_tr).mean()),
555 }
556 with open(shared_path('问题一_关键量.json'), 'w', encoding='
    utf-8') as fh:
557     json.dump(meta_out, fh, ensure_ascii=False, indent=2)
558

```

```

559 print('\n===== 问题一求解完成 =====')
560 print('训练平均 R2=%.4f; 同尺度检验 R2=%.4f; 跨尺度相关 60M
      =%.4f, 1B=%.4f'
561       % (r2_tr.mean(), r2_te1.mean(), r_te2.mean(), r_te3.mean
          ()))
562 print('追加混合质量指数 Qbar 的平均 R2 增量 = %.5f' % (r2_z -
      r2_tr).mean())
563 print('全局平均质量 = %.4f; 参考配比加权基线 Q0 = %.4f'
564       % (quality_meta.quality_Q.mean(), float(ref @ qvec)))
565 if RC_FAILS:
566     print('注意：以下结果文件因被占用而改存：', RC_FAILS)
567
568 # 模型结果全部保存后生成正文采用的正式图。
569 import subprocess as _subprocess
570 _subprocess.run([sys.executable, os.path.join(BASE_DIR, '非线性
      代理对照.py'), '--data-dir', DATA_DIR], check=True)
571 _subprocess.run([sys.executable, os.path.join(BASE_DIR, '核岭
      支持域推荐.py'), '--data-dir', DATA_DIR], check=True)
572 _subprocess.run([sys.executable, os.path.join(BASE_DIR, '重绘
      图表.py'), '--data-dir', DATA_DIR], check=True)

```

Listing 1: 问题一完整求解程序（求解/问题一/问题一.py）

问题二：广义标度律、验证与边际分析

```

1  # -*- coding: utf-8 -*-
2  # 本程序及代码的整理与核对使用人工智能工具 Codex 辅助。
3  # 模型：GPT-5.6-Luna；开发机构：OpenAI。
4  # 版本发布日期：2026-07-09（型号发布）。
5  """
6  问题二：跨维度数据融合与广义标度律
7  数据：附件 B（B1 主拟合；B2/B3 族外与轨迹验证；B4/B5 跨族与文
      献验证；
8       B6/B7 质量 Q；B8 大规模矩阵（方向异常，仅作可信度边界警
      示）；B9/B10 百亿参数以上外推）
9  模型：经典  $L = E + A N^{-a} + B D^{-b}$ 
10     广义  $L = E + A N^{-a} + B D^{-b} + C (1-Q)^g$ （Q=1 退化为经典
      形式）

```

```

11 输出：图片到 图片/, 结果 CSV 到 结果/, 参数共享至 求解/广义标
    度律参数.csv
12 """
13 import sys, os, glob
14 sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.
    abspath(__file__))))
15 from _common import * # noqa: F401,F403
16 from scipy.optimize import least_squares
17
18 DATA = data_path
19
20 def save_csv_safe(df, name_cn):
21     p = os.path.join(OUT_DIR, name_cn)
22     try:
23         df.to_csv(p, index=False, encoding='utf-8-sig')
24     except PermissionError:
25         alt = p.replace('.csv', '_new.csv')
26         df.to_csv(alt, index=False, encoding='utf-8-sig')
27         print(' ! %s 被占用, 已改存为 %s' % (name_cn, os.path
    .basename(alt)))
28
29 pythia = pd.read_csv(DATA('pythia_training_log_existing.csv'))
30 cerebras = pd.read_csv(DATA('cerebras_training_log.csv'))
31 baseline = pd.read_csv(DATA('scaling_baseline.csv'))
32 published = pd.read_csv(DATA('published_scaling_data.csv'))
33 nq6 = pd.read_csv(DATA('supplementary_NQ_experiment.csv'))
34 nq7 = pd.read_csv(DATA('supplementary_NQ_experiment_expanded.
    csv'))
35 nq8 = pd.read_csv(DATA('supplementary_NQ_experiment_large.csv'
    ))
36 large_models = pd.read_csv(DATA('supplementary_large_models.
    csv'))
37 large_loss = pd.read_csv(DATA('supplementary_large_baseline.
    csv'))
38 traj_files = sorted(glob.glob(os.path.join(DATA_DIR, '
    B_scaling_laws',
39
    '
    training_trajectories', '*.csv'))))

```

```

40
41 N_p = pythia.N_params_B.to_numpy(float)
42 D_p = pythia.D_tokens_B.to_numpy(float)
43 L_p = pythia.val_loss.to_numpy(float)
44
45 # ===== 1. 经典标度律 (B1 主拟合 + 模型留出验证)
    =====
46 def classic(par, N, D):
47     E, A, a, B, b = par
48     return E + A * N ** (-a) + B * D ** (-b)
49
50 r0 = least_squares(lambda p: classic(p, N_p, D_p) - L_p, [1.7,
    .4, .33, 1.2, .28],
51                   bounds=([0, 1e-8, .01, 1e-8, .01], [5, 1e3,
    2, 1e3, 2]),
52                   loss='soft_l1', f_scale=.05, max_nfev
    =40000)
53 E0, A0, a0, B0, b0 = r0.x
54 Lph = classic(r0.x, N_p, D_p)
55 R2_cls = 1 - np.sum((L_p - Lph) ** 2) / np.sum((L_p - L_p.mean
    ()) ** 2)
56 RMSE_cls = float(np.sqrt(np.mean((L_p - Lph) ** 2)))
57
58 Ns = sorted(pythia.N_params_B.unique())
59 tr_m = pythia[pythia.N_params_B.isin(Ns[:4])]
60 te_m = pythia[pythia.N_params_B.isin(Ns[4:])]
61 rh = least_squares(lambda p: classic(p, tr_m.N_params_B.values
    , tr_m.D_tokens_B.values)
62                   - tr_m.val_loss.values, [1.7, .4, .33, 1.2,
    .28],
63                   bounds=([0, 1e-8, .01, 1e-8, .01], [5, 1e3,
    2, 1e3, 2]),
64                   loss='soft_l1', f_scale=.05, max_nfev
    =40000)
65 hp = classic(rh.x, te_m.N_params_B.values, te_m.D_tokens_B.
    values)
66 ym = te_m.val_loss.values
67 hold = {'留出R2': 1 - np.sum((ym - hp) ** 2) / np.sum((ym - ym

```

```

        .mean()) ** 2),
68         '留出RMSE': float(np.sqrt(np.mean((ym - hp) ** 2))),
69         '留出MAPE_%': float(np.mean(np.abs(ym - hp) / ym *
        100))}
70
71 print('=== 1. 经典标度律 (B1 Pythia, n=%d) ===' % len(pythia))
72 print('   E=%.4f A=%.4f alpha=%.4f B=%.4f beta=%.4f' % (E0, A0,
        a0, B0, b0))
73 print('   拟合 R2=%.8f RMSE=%.6f MAPE=%.4f%%' % (
74     R2_cls, RMSE_cls, np.mean(np.abs(L_p - Lph) / L_p) * 100))
75 print('   留出验证 (4 小模型 -> 4 大模型): R2=%.8f RMSE=%.6f
        MAPE=%.4f%%' % (
76     hold['留出R2'], hold['留出RMSE'], hold['留出MAPE_%']))
77 print('   提示: B1 拟合残差标准差仅 %.5f (损失标准差 %.4f), 说
        明该附件近乎无观测噪声, '
78     '其上高 R2 只能确认函数形式自治, 不能替代外部验证。' % (
79     float(np.std(L_p - Lph)), float(np.std(L_p))))
80 save_csv_safe(pd.DataFrame([{'E': E0, 'A': A0, 'alpha': a0, 'B
        ': B0, 'beta': b0,
81                                'R2': R2_cls, 'RMSE': RMSE_cls,
82                                'MAPE_%': float(np.mean(np.abs(
        L_p - Lph) / L_p) * 100),
83                                '残差标准差': float(np.std(L_p -
        Lph))}, **hold])),
84     '经典标度律参数.csv')
85
86 # ===== 2. 质量字段方向审计 =====
87 def group_corr(df, qcol='Q_score'):
88     vals, ng = [], 0
89     for _, g in df.groupby(['N_params_B', 'D_tokens_B']):
90         if g[qcol].nunique() >= 3:
91             vals.append(g[qcol].corr(g.val_loss)); ng += 1
92     return float(np.nanmean(vals)), ng
93
94 audit = []
95 for nm, sub, note in [('B6', nq6, '质量主数据'),
96                        ('B7', nq7, '质量扩展数据 (含 B6 重复
        点) '),

```

```

97         ('B8-calibrated', nq8[nq8.data_type.eq('
calibrated')], '大规模矩阵校准段'),
98         ('B8-extrapolated', nq8[nq8.data_type.eq
('extrapolated')], '大规模矩阵外推段']):
99     r, ng = group_corr(sub)
100     audit.append({'dataset': nm, 'n': len(sub), 'n_groups': ng
, 'within_ND_corr': r,
101                 'conclusion': ('Q 越大损失越低 -> 质量指标
(越高越好) ' if r < -0.5 else
102                               ('Q 越大损失越高 -> 方向与 B6
/B7 相反' if r > 0.5 else
103                               '组内无显著单调关系'))})
104 save_csv_safe(pd.DataFrame(audit), '质量字段方向审计.csv')
105 corr6 = audit[0]['within_ND_corr']; corr7 = audit[1]['
within_ND_corr']
106 corr8 = audit[2]['within_ND_corr']
107 print('\n=== 2. 质量字段方向审计 (控制 N、D 的组内相关) ===')
108 print(pd.DataFrame(audit).to_string(index=False))
109 print(' 结论: B6/B7 的 Q_score 与损失负相关 (r=%.3f / %.3f
) , 是“质量”而非“难度” , '
110       '故取 Q = Q_score (Q=1 最优) , 与问题一“越高越好”口径
一致。' % (corr6, corr7))
111 print('  B8 校准段方向相反 (r=%.3f) : 两套半合成数据口径不一
致, B8 不并入拟合。' % corr8)
112
113 # ===== 3. 广义标度律: 形式比较与参数估计 =====
114 N_all = np.r_[N_p, nq6.N_params_B]
115 D_all = np.r_[D_p, nq6.D_tokens_B]
116 Q_all = np.r_[np.ones(len(pythia)), nq6.Q_score]      # B1 无
质量信息, 取参考水平 Q=1
117 L_all = np.r_[L_p, nq6.val_loss]
118
119 def g_v1(p, N, D, Q):
120     E, A, a, B, b, C, g = p
121     return E + A * N ** (-a) + B * D ** (-b) + C * np.clip(1 -
Q, 0, 1) ** g
122
123 def g_v2(p, N, D, Q):

```

```

124     E, A, a, B, b, g = p
125     return E + A * N ** (-a) + B * (D * np.clip(Q, 1e-6, 1) **
126         g) ** (-b)
127 def g_v4(p, N, D, Q):
128     E, A, a, B, b, C, g = p
129     return E + A * N ** (-a) + B * D ** (-b) + C * np.clip(Q,
130         1e-6, 1) ** (-g)
131 def g_v5(p, N, D, Q):
132     E, A, a, B, b, g1, g2 = p
133     return (E + A * (N * np.clip(Q, 1e-6, 1) ** g1) ** (-a)
134         + B * (D * np.clip(Q, 1e-6, 1) ** g2) ** (-b))
135
136 FORMS = {
137     '加性质量缺口  $C(1-Q)^g$ ': (g_v1, [E0, A0, a0, B0, b0, .35,
138         1.],
139         [0, 1e-8, .01, 1e-8, .01, 1e-8,
140         .05], [5, 1e3, 2, 1e3, 2, 50, 10]),
141     '质量作有效数据乘子': (g_v2, [E0, A0, a0, B0, b0, .5],
142         [0, 1e-8, .01, 1e-8, .01, -10], [5,
143         1e3, 2, 1e3, 2, 30]),
144     '加性质量亏损  $C Q^{-g}$ ': (g_v4, [E0, A0, a0, B0, b0, .2,
145         .5],
146         [0, 1e-8, .01, 1e-8, .01, 1e-8,
147         .05], [5, 1e3, 2, 1e3, 2, 50, 10]),
148     '质量同时乘 N 与 D': (g_v5, [E0, A0, a0, B0, b0, .3, .3],
149         [0, 1e-8, .01, 1e-8, .01, -10, -10],
150         [5, 1e3, 2, 1e3, 2, 30, 30]),
151 }
152 nq7_new = nq7[~nq7.experiment_id.astype(str).isin(set(nq6.
153     experiment_id.astype(str)))]
154 form_rows, fit_store = [], {}
155 for nm, (fn, p0, lo, hi) in FORMS.items():
156     rr = least_squares(lambda p: fn(p, N_all, D_all, Q_all) -
157         L_all, p0,
158         bounds=(lo, hi), loss='soft_l1',
159         f_scale=.05, max_nfev=80000)

```

```

151     hh = fn(rr.x, N_all, D_all, Q_all)
152     R2j = 1 - np.sum((L_all - hh) ** 2) / np.sum((L_all -
L_all.mean()) ** 2)
153     hq = fn(rr.x, nq6.N_params_B.values, nq6.D_tokens_B.values
, nq6.Q_score.values)
154     R2q = 1 - np.sum((nq6.val_loss.values - hq) ** 2) / \
155         np.sum((nq6.val_loss.values - nq6.val_loss.mean()) **
2)
156     h7 = fn(rr.x, nq7_new.N_params_B.values, nq7_new.
D_tokens_B.values, nq7_new.Q_score.values)
157     r7 = float(np.corrcoef(nq7_new.val_loss.values, h7)[0, 1])
158     form_rows.append({'形式': nm, '联合R2': R2j, 'B6拟合R2':
R2q, 'B7新增点r': r7,
159                     '参数个数': len(rr.x),
160                     'AIC': len(N_all) * np.log(np.mean((
L_all - hh) ** 2)) + 2 * len(rr.x)})
161     fit_store[nm] = rr.x
162 sv = pd.DataFrame(form_rows).sort_values('联合R2', ascending=
False)
163 save_csv_safe(sv, '广义标度律形式对比.csv')
164 print('\n=== 3. 广义标度律形式对比 ===')
165 print(sv.to_string(index=False))
166
167 best_name = sv.iloc[0]['形式']
168 fn_best = FORMS[best_name][0]
169 r1x = fit_store[best_name]
170 E, A, alpha, B, beta, Cq, gamma = r1x
171 Lhat = fn_best(r1x, N_all, D_all, Q_all)
172 R2_gen = 1 - np.sum((L_all - Lhat) ** 2) / np.sum((L_all -
L_all.mean()) ** 2)
173 RMSE_gen = float(np.sqrt(np.mean((L_all - Lhat) ** 2)))
174 MAPE_gen = float(np.mean(np.abs(L_all - Lhat) / np.abs(L_all))
* 100)
175 print('\n选定形式: %s' % best_name)
176 print(' E=%.4f A=%.4f alpha=%.4f B=%.4f beta=%.4f C=%.4f
gamma=%.4f R2=%.4f RMSE=%.4f MAPE=%.2f%%'
177       % (E, A, alpha, B, beta, Cq, gamma, R2_gen, RMSE_gen,
MAPE_gen))

```

```

178
179 params = pd.DataFrame({'param': ['E', 'A', 'alpha', 'B', 'beta',
180                                'C', 'gamma'],
181                        'value': [E, A, alpha, B, beta, Cq,
182                                gamma]})
183
184 save_csv_safe(params, '广义标度律参数.csv')
185 params.to_csv(shared_path('广义标度律参数.csv'), index=False,
186               encoding='utf-8-sig')
187
188 # ===== 4. 分层验证 =====
189 def metrics(df, Q=1.0):
190     q = np.full(len(df), Q) if np.isscalar(Q) else np.asarray(
191         Q)
192     ph = fn_best(r1x, df.N_params_B.to_numpy(float), df.
193                 D_tokens_B.to_numpy(float), q)
194     y = df.val_loss.to_numpy(float)
195     return ph, float(np.corrcoef(y, ph)[0, 1]), float(np.sqrt(
196         np.mean((y - ph) ** 2))), \
197         float(np.mean(np.abs(y - ph) / np.maximum(np.abs(y), 1
198             e-9)) * 100)
199
200 nq8c = nq8[nq8.data_type.eq('calibrated')]
201 validation, pred_sets = [], []
202 for name, df, q, kind in [('B2_Cerebras(半合成, 族外)',
203                           cerebras, 1., '半合成'),
204                           ('B4_跨族收敛点(真实)', baseline,
205                            1., '真实'),
206                           ('B5_已发表标度律(真实)', published,
207                            1., '真实'),
208                           ('B7_质量扩展新增点(半合成)',
209                            nq7_new, nq7_new.Q_score, '半合成'),
210                           ('B8_校准段(Q 反向重定向)', nq8c, 1
211                            - nq8c.Q_score, '半合成'),
212                           ('B10_百亿参数以上(估算)',
213                            large_loss, 1., '估算')]:
214     ph, r, rm, mp = metrics(df, q)
215     validation.append({'dataset': name, 'n': len(df), '性质':
216                       kind, 'r': r,

```

```

202         'RMSE': rm, 'MAPE_%': mp})
203     pred_sets.append((name.split('_')[0], df.val_loss.to_numpy
204         (float), ph))
205 val_df = pd.DataFrame(validation)
206 save_csv_safe(val_df, '广义标度律分层验证.csv')
207 print('\n=== 4. 广义标度律分层验证 ===')
208 print(val_df.to_string(index=False))
209
210 save_csv_safe(large_loss.assign(
211     pred=fn_best(r1x, large_loss.N_params_B.values, large_loss
212     .D_tokens_B.values,
213     np.ones(len(large_loss)))), '百亿参数以上外推
214     .csv')
215
216 # ===== 5. 弹性、边际效用与替代关系 =====
217 def marg(p, N, D, Q):
218     E_, A_, a_, B_, b_, C_, g_ = p
219     return (-a_ * A_ * N ** (-a_ - 1), -b_ * B_ * D ** (-b_ -
220     1),
221     -g_ * C_ * np.clip(1 - Q, 1e-9, None) ** (g_ - 1))
222
223 el_rows = []
224 for N_ref, D_ref, Q_ref in [(1., 100., 0.6), (12., 300., 0.6)
225     ]:
226     L_ref = float(fn_best(r1x, N_ref, D_ref, Q_ref))
227     dN, dD, dQ = marg(r1x, N_ref, D_ref, Q_ref)
228     sub = abs(dQ) / abs(dN)
229     el_rows.append({'参考点N(B)': N_ref, 'D(B)': D_ref, 'Q':
230     Q_ref, 'L': L_ref,
231     '弹性e_N': dN * N_ref / L_ref, '弹性e_D':
232     dD * D_ref / L_ref,
233     '弹性e_Q': dQ * Q_ref / L_ref, '替代率dN/
234     dQ(B)': sub,
235     'dQ=0.1等价dN(B)': sub * 0.1})
236 el_df = pd.DataFrame(el_rows)
237 save_csv_safe(el_df, '弹性与替代关系.csv')
238 print('\n=== 5. 弹性与质量—参数替代关系 ===')
239 print(el_df.round(4).to_string(index=False))

```

```

232
233 N_ref, D_ref, Q_ref = 1., 100., 0.6
234 dN, dD, dQ = marg(r1x, N_ref, D_ref, Q_ref)
235 subst = abs(dQ) / abs(dN)
236 save_csv_safe(pd.DataFrame({'质量提升dQ': [.05, .1, .2, .3],
237                               '局部等价参数增量dN(B)': subst *
238                               np.array([.05, .1, .2, .3]),
239                               '等价数据增量dD(B)': abs(dQ) / abs
240                               (dD) * np.array([.05, .1, .2, .3])}),
241                               '质量参数替代关系.csv')
242
243 Qs = np.linspace(0.30, 0.99, 80)
244 subs = np.array([abs(marg(r1x, N_ref, D_ref, q)[2]) / abs(marg
245                               (r1x, N_ref, D_ref, q)[0])
246                               for q in Qs])
247 save_csv_safe(pd.DataFrame({'Q': Qs, 'dN_per_dQ(B)': subs,
248                               'dN_for_dQ_0.1(B)': subs * 0.1}),
249                               '替代率随质量变化.csv')
250 save_csv_safe(pd.DataFrame({'Q': Qs, '不可约损失下限': E + Cq
251                               * (1 - Qs) ** gamma}),
252                               '质量与损失下限.csv')
253
254 # ===== 6. 领域间的替代/互补关系（基于问题一系数向量）
255 # =====
256 p1_dir = os.path.join(SOLVE_DIR, '问题一', '结果')
257 coef = pd.read_csv(os.path.join(p1_dir, '混合系数矩阵.csv')).
258     set_index('training_domain')
259 inter = pd.read_csv(os.path.join(p1_dir, '截距.csv')).
260     set_index('loss_domain').intercept
261 mix = pd.read_csv(DATA('train_mixture_lm.csv'))
262 mix_cols = [c for c in mix if c.startswith('train_the_pile_')]
263 domains = [c.replace('train_the_pile_', '') for c in mix_cols]
264 p_ref = mix[mix_cols].mean().to_numpy(float)
265 loss_domains = list(coef.columns)
266 w_ref = np.array([p_ref[domains.index(d)] for d in
267                     loss_domains]); w_ref /= w_ref.sum()
268
269 def mix_obj(p):

```

```

261     return float(w_ref @ (np.asarray(p) @ coef.loc[domains].
262         to_numpy()
263         + inter.loc[loss_domains].to_numpy()
264     ))
265 mix_cal = pd.read_csv(os.path.join(pl_dir, '核岭推荐_目标对照.
266     csv'))
267 mix_delta_rec = float(mix_cal.loc[mix_cal.mixture.eq('问题一有
268     界推荐'),'M_p'].iloc[0])
269 # 配比修正沿用同一核岭目标，线性系数仅用于下方领域关联解释。
270 save_csv_safe(mix_cal, '配比项校准.csv')
271 Cn = coef.loc[domains].to_numpy()
272 Cc = Cn - Cn.mean(axis=0, keepdims=True)
273 nm_ = np.linalg.norm(Cc, axis=1, keepdims=True)
274 sim = (Cc @ Cc.T) / np.maximum(nm_ @ nm_.T, 1e-12)
275 pd.DataFrame(sim, index=domains, columns=domains).to_csv(
276     os.path.join(OUT_DIR, '领域替代互补矩阵.csv'), encoding='
277     utf-8-sig')
278 tri = np.triu_indices(len(domains), 1)
279 pair_sim = pd.DataFrame({'domain_i': [domains[i] for i in tri
280     [0]],
281     'domain_j': [domains[j] for j in tri
282     [1]],
283     'coefficient_similarity': sim[tri]}).
284     sort_values(
285         'coefficient_similarity', ascending=False)
286 save_csv_safe(pd.concat([pair_sim.head(8).assign(关系='可替代'
287     ),
288     pair_sim.tail(8).assign(关系='互补或
289     冲突')]), '领域替代互补_top.csv')
290 print('\n=== 6. 领域替代与互补（系数向量余弦相似度）===')
291 print('最可替代的 4 组: '); print(pair_sim.head(4).to_string(
292     index=False))
293 print('最互补的 4 组: '); print(pair_sim.tail(4).to_string(
294     index=False))
295 print('推荐配比带来的加权平均损失变化 M(p) = %.4f' %
296     mix_delta_rec)

```

```

286
287 # ===== 7. B3 插值轨迹验证 =====
288 traj_rows = []
289 for f in traj_files:
290     d = pd.read_csv(f)
291     n_par = float(d.N_params_B.iloc[0])
292     base = E0 + A0 * n_par ** (-a0)
293     y = np.clip(d.val_loss.values - base, 1e-9, None)
294     sl = np.polyfit(np.log(d.D_tokens_B.values), np.log(y), 1)
295     traj_rows.append({'file': os.path.basename(f), 'N(B)':
296                     '轨迹内D幂指数': float(sl), '经典beta':
297                     float(-b0)})
298 traj_df = pd.DataFrame(traj_rows)
299 save_csv_safe(traj_df, 'B3轨迹验证.csv')
300 print('\n=== 7. B3 插值轨迹验证 (轨迹内损失对 D 的幂指数 vs 经
301     典 beta) ===')
302 print(traj_df.round(4).to_string(index=False))
303
304 # ===== 8. 汇总 =====
305 save_csv_safe(pd.DataFrame({
306     '指标': ['E', 'A', 'alpha', 'B', 'beta', 'C', 'gamma', '经
307     典R2', '经典残差标准差',
308     '留出R2', '广义R2', '广义RMSE', '广义MAPE%', 'B6
309     方向相关r', 'B7方向相关r', 'B8方向相关r',
310     '参考点弹性e_N', '参考点弹性e_D', '参考点弹性e_Q'
311     , '替代率dN/dQ', '推荐配比M(p)'],
312     '数值': [E, A, alpha, B, beta, Cq, gamma, R2_cls, float(np
313     .std(L_p - Lph)),
314     hold['留出R2'], R2_gen, RMSE_gen, MAPE_gen, corr6
315     , corr7, corr8,
316     el_rows[0]['弹性e_N'], el_rows[0]['弹性e_D'],
317     el_rows[0]['弹性e_Q'],
318     subst, mix_delta_rec])), '问题二_拟合汇总.csv')
319
320 # ===== 9. 绘图 =====
321 from 重绘图表 import render_all

```

```

314 render_all(DATA_DIR)
315
316 print('\n===== 问题二求解完成 =====')
317 print('经典 R2=%.8f, 留出 R2=%.8f; 广义 R2=%.4f; 替代率 dN/dQ
      =%.3f B/单位质量'
318       % (R2_cls, hold['留出R2'], R2_gen, subst))

```

Listing 2: 问题二完整求解程序（求解/问题二/问题二.py）

问题三：预算约束优化与敏感性分析

```

1  # -*- coding: utf-8 -*-
2  # 本程序及代码的整理与核对使用人工智能工具 Codex 辅助。
3  # 模型：GPT-5.6-Luna；开发机构：OpenAI。
4  # 版本发布日期：2026-07-09（型号发布）。
5  """
6  问题三：算力约束下的多维资源联合优化与结构性转移
7  输入：问题二广义标度律参数  $L(N,D,Q)=E+A/N^a+B/D^b+C(1-Q)^g$ ；
8       问题一的质量基线  $Q_0$  与配比修正  $M(p)$ ；附件 C7 的上下文长
       度可行取值。
9  成本（严格按赛题附录 B 与正文公式）：
10       $C_{total} = C_{train} + C_Q + C_{attn}$ 
11       $= 6ND + D * [g(Q) - g(Q_0)]_+ + \eta * N * D * L_{ctx}$ ,  $\eta = 2e-4$ 
12       $g(Q)$  取附录 B 三型（指数型  $1e7 * \exp(6Q)$ 、幂函数型  $5e9 * Q^4$ 、
       对数渐进型  $2e9 * \ln(1+10Q)$ ）
13  临界上下文长度：注意力开销 = 基础训练开销  $\Leftrightarrow \eta * N * D * L = 6 * N * D$ 
        $\Leftrightarrow L_{crit} = 6/\eta = 30000$ 
14  方法：三档预算联合优化（SLSQP，对数参数化）；预算扫略 + 结构性
       转移识别； $L_{ctx}$  敏感性。
15  输出：图片到 图片/，结果 CSV 到 结果/。
16  """
17  import sys, os, json
18  sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.
       abspath(__file__))))
19  from _common import *    # noqa: F401,F403
20  from scipy.optimize import minimize
21

```

```

22 DATA = data_path
23
24 def save_csv_safe(df, name_cn):
25     p = os.path.join(OUT_DIR, name_cn)
26     try:
27         df.to_csv(p, index=False, encoding='utf-8-sig')
28     except PermissionError:
29         alt = p.replace('.csv', '_new.csv')
30         df.to_csv(alt, index=False, encoding='utf-8-sig')
31         print('    ! %s 被占用, 已改存为 %s' % (name_cn, os.path
        .basename(alt)))
32
33 # ===== 0. 读取前两问输出 =====
34 params = pd.read_csv(shared_path('广义标度律参数.csv'),
        index_col='param')['value']
35 E, A, alpha, B, beta, Cq, gamma = (params['E'], params['A'],
        params['alpha'],
36                                     params['B'], params['beta']
        ], params['C'], params['gamma'])
37
38 with open(shared_path('问题一_关键量.json'), encoding='utf-8')
        as fh:
39     k1 = json.load(fh)
40 Q0_sample = float(k1['Q0_global_mean'])
41
42 mix_map = pd.read_csv(shared_path('17域质量映射.csv'))
43 ref_mix = pd.read_csv(data_path('train_mixture_lm.csv'))
44 ref_cols = [c for c in ref_mix if c.startswith('
        train_the_pile_')]
45 ref_p = ref_mix[ref_cols].mean().to_numpy(float)
46 ref_dom = [c.replace('train_the_pile_', '') for c in ref_cols]
47 qmap = mix_map.set_index('mixture_domain')['quality_Q']
48 q_vec = np.array([float(qmap.get(d, Q0_sample)) for d in
        ref_dom])
49 Q0 = float(ref_p @ q_vec)          # 基线质量 = 参考语料配比加权
        平均质量
50 print('=== 0. 质量基线与模型参数 (来自问题一、二) ===')
51 print('    参考语料配比加权基线质量 Q0 = %.4f (全量样本均值 %.4f

```

```

    ) ' % (Q0, Q0_sample))
52 print(' 标度律: E=%.4f A=%.4f alpha=%.4f B=%.4f beta=%.4f C
    =%.4f gamma=%.4f'
53         % (E, A, alpha, B, beta, Cq, gamma))
54
55 def loss(N_abs, D_abs, Q, M_p=0.0):
56     """验证损失: 参数以 B 为单位代入问题二标度律, M_p 为配比项
    修正。"""
57     return (E + A * (N_abs / 1e9) ** (-alpha) + B * (D_abs / 1
    e9) ** (-beta)
58             + Cq * (1 - Q) ** gamma + M_p)
59
60 # ===== 1. 附录 B 的三型质量成本函数 =====
61 GB = {
62     '指数型': dict(gamma=1e7, lam=6.0),
63     '幂函数型': dict(gamma=5e9, lam=4.0),
64     '对数渐进型': dict(gamma=2e9, lam=10.0),
65 }
66 def g_of(Q, form):
67     par = GB[form]
68     if form == '指数型':
69         return par['gamma'] * np.exp(par['lam'] * Q)
70     if form == '幂函数型':
71         return par['gamma'] * Q ** par['lam']
72     return par['gamma'] * np.log(1 + par['lam'] * Q)
73
74 def c_quality(D_abs, Q, form):
75     return D_abs * max(g_of(Q, form) - g_of(Q0, form), 0.0)
76
77 for form in GB:
78     print('  g(%s) 在 Q0=%.3f 处为 %.4e, 在 Q=1 处为 %.4e (单
    位算力/token) '
79           % (form, Q0, g_of(Q0, form), g_of(1.0, form)))
80
81 # ===== 2. 临界上下文长度 =====
82 ETA = 2e-4
83 L_CRIT = 6.0 / ETA
84 arch = pd.read_csv(DATA('model_architecture_metadata.csv'))

```

```

85 L_FEAS = sorted(arch['max_position_embeddings'].dropna().
    unique().astype(int).tolist())
86 print('\n=== 1. 临界上下文长度（解析解） ===')
87 print(' C_attn = eta*N*D*L_ctx, C_train = 6ND -> L_crit = 6/
    eta = %.0f tokens' % L_CRIT)
88 print(' C7 给出的可行上下文长度（max_position_embeddings）： %
    s' % L_FEAS)
89 print(' 可行取值中跨越临界值的一对： 8192（%.2f 倍）与 32768（
    %.2f 倍） '
    % (ETA * 8192 / 6, ETA * 32768 / 6))
90
91
92 # ===== 3. 总成本与单点最优 =====
93 def total_cost(N_abs, D_abs, Q, L_ctx, form):
94     return 6.0 * N_abs * D_abs + c_quality(D_abs, Q, form) +
    ETA * N_abs * D_abs * L_ctx
95
96 def optimize(C_budget, L_ctx=2048, form='幂函数型', M_p=0.0,
    n_starts=8, Qcap=1.0):
97     """SLSQP 对数参数化联合优化 (N, D, Q)。"""
98     def obj(x):
99         return loss(np.exp(x[0]), np.exp(x[1]), x[2], M_p)
100     def con(x):
101         # 无量纲等价约束，避免 1e19--1e24 的量级导致有限差分数
    值失败。
102         return 1.0 - total_cost(np.exp(x[0]), np.exp(x[1]), x
    [2], L_ctx, form) / C_budget
103     best = None
104     for k in range(n_starts):
105         frac = (k + 1) / (n_starts + 1)
106         x0 = [np.log(1e9) + 4 * (frac - .5), np.log(1e11) + 4
    * (.5 - frac),
107             Q0 + (Qcap - Q0) * frac]
108         try:
109             res = minimize(obj, x0, method='SLSQP',
110                 bounds=[(np.log(1e5), np.log(1e15))
    ,
    (np.log(1e6), np.log(1e16))
    , (Q0, Qcap)],

```

```

112         constraints={'type': 'ineq', 'fun':
113             con},
114         options={'maxiter': 1500, 'ftol': 1
115             e-14})
116     except Exception:
117         continue
118     if res.success and (best is None or res.fun < best.fun
119 ):
120         best = res
121     if best is None:
122         raise RuntimeError('优化失败')
123     N_abs, D_abs, Q = np.exp(best.x[0]), np.exp(best.x[1]),
124     best.x[2]
125     c_base = 6.0 * N_abs * D_abs
126     c_qual = c_quality(D_abs, Q, form)
127     c_attn = ETA * N_abs * D_abs * L_ctx
128     return dict(N_B=N_abs / 1e9, D_B=D_abs / 1e9, D_over_N=
129     D_abs / N_abs, Q=Q,
130         L=loss(N_abs, D_abs, Q, M_p), c_base=c_base,
131         c_qual=c_qual,
132         c_attn=c_attn, c_tot=c_base + c_qual + c_attn,
133         f_base=c_base / C_budget, f_qual=c_qual /
134         C_budget,
135         f_attn=c_attn / C_budget, form=form, L_ctx=
136         L_ctx, C=C_budget)
137
138 BUDGETS = [1e19, 1e22, 1e24]
139 print('\n=== 2. 三档预算最优配置（幂函数型质量成本, L_ctx=2048
140     ) ===')
141 rows = []
142 for Cb in BUDGETS:
143     r = optimize(Cb, 2048, '幂函数型')
144     rows.append(r)
145     print('    C=%.0e: N*=%.3fB D*=%.1fB Q*=%.4f L*=%.4f    '
146         '[base %.1f%% qual %.1f%% attn %.1f%%]'
147         % (Cb, r['N_B'], r['D_B'], r['Q'], r['L'],
148             r['f_base'] * 100, r['f_qual'] * 100, r['f_attn']
149             * 100))

```

```

140 save_csv_safe(pd.DataFrame(rows), '三档预算最优配置.csv')
141
142 # ===== 4. 三种质量成本函数对比 =====
143 print('\n=== 3. 质量成本函数对最优解的影响 ===')
144 comp = []
145 for Cb in BUDGETS:
146     for form in GB:
147         r = optimize(Cb, 2048, form)
148         comp.append(r)
149 comp_df = pd.DataFrame(comp)
150 save_csv_safe(comp_df, '成本函数对比.csv')
151 for Cb in BUDGETS:
152     sub = comp_df[comp_df.C.eq(Cb)]
153     print('  C=%.0e' % Cb)
154     for _, r in sub.iterrows():
155         print('      %-6s N*=%.3fB D*=%.1fB Q*=%.4f L*=%.4f 质量
156             投入占比 %.1f%%'
157               % (r['form'], r['N_B'], r['D_B'], r['Q'], r['L'
158                 ], r['f_qual'] * 100))
159
160 # ===== 4b. 质量基线 Q0 口径的灵敏度 =====
161 _Q0_main = Q0
162 Q0 = Q0_sample
163 print('\n=== 3b. 质量基线口径灵敏度 (Q0 由配比加权 %.4f 改为样
164     本均值 %.4f) ==='
165       % (_Q0_main, Q0_sample))
166 q0_rows = []
167 for Cb in BUDGETS:
168     r = optimize(Cb, 2048, '幂函数型')
169     q0_rows.append(r)
170     print('  C=%.0e: N*=%.3fB D*=%.1fB Q*=%.4f L*=%.4f 质量投
171         入占比 %.1f%%'
172         % (Cb, r['N_B'], r['D_B'], r['Q'], r['L'], r['f_qual
173           ' * 100))
174 save_csv_safe(pd.DataFrame(q0_rows), '质量基线灵敏度.csv')
175 Q0 = _Q0_main
176
177 # ===== 5. 领域配比 M(p) 的算力等价效果 =====

```

```

173 mix_cal = pd.read_csv(os.path.join(SOLVE_DIR, '问题二', '结果'
    , '配比项校准.csv'))
174 M_p = float(mix_cal.loc[mix_cal.mixture.eq('问题一有界推荐'),
    'M_p'].iloc[0])
175 print('\n=== 4. 领域配比修正的算力等价效果 (M(p)=%.4f) ===' %
    M_p)
176 r_mix = optimize(1e22, 2048, '幂函数型', M_p=M_p)
177 r_ref = optimize(1e22, 2048, '幂函数型', M_p=0.0)
178 print('    C=1e22: 参考配比 L*=%.4f (N*=%.3fB D*=%.1fB Q*=%.4f)
    ,
179         % (r_ref['L'], r_ref['N_B'], r_ref['D_B'], r_ref['Q']))
180 print('        推荐配比 L*=%.4f (N*=%.3fB D*=%.1fB Q*=%.4f)
    ,
181         % (r_mix['L'], r_mix['N_B'], r_mix['D_B'], r_mix['Q']))
182
183 def budget_for_loss(L_target, L_ctx=2048, form='幂函数型'):
184     lo, hi = 1e17, 1e25
185     for _ in range(60):
186         mid = np.sqrt(lo * hi)
187         try:
188             r = optimize(mid, L_ctx, form, n_starts=3)
189             if r['L'] > L_target:
190                 lo = mid
191             else:
192                 hi = mid
193         except Exception:
194             lo = mid
195     return np.sqrt(lo * hi)
196
197 C_eq = budget_for_loss(r_mix['L'])
198 print('    推荐配比在 C=1e22 时得到的损失 %.4f, 若改用参考配比实
    现同一损失需要'
199     ,
200     % (r_mix['L'], C_eq, C_eq / 1e22))
201 print('    (说明: M(p) 是损失水平上的固定平移, 与算力无关, 故换
    算为算力收益会被'
202     , '损失的算力弹性放大, 此倍数宜作量级参考。) ')

```

```

203 save_csv_safe(pd.DataFrame([{'mixture': '参考配比', 'M_p':
    0.0, **r_ref,
204                               'equivalent_reference_budget':1e22
    , 'budget_multiplier':1.0}],
205                               {'mixture': '问题一有界推荐', 'M_p
    ': M_p, **r_mix,
206                               'equivalent_reference_budget':
    C_eq, 'budget_multiplier':C_eq/1e22}]),
207                               '配比项算力等价.csv')
208
209 # ===== 6. 预算扫略与结构性转移识别 =====
210 print('\n=== 5. 预算扫略与结构性转移 ===')
211 C_sweep = np.logspace(18, 25, 141)
212 sweep = []
213 for Cb in C_sweep:
214     try:
215         sweep.append(optimize(Cb, 2048, '幂函数型', n_starts
    =5))
216     except Exception:
217         sweep.append(dict(N_B=np.nan, D_B=np.nan, Q=np.nan, L=
    np.nan, c_base=np.nan,
218                               c_qual=np.nan, c_attn=np.nan, c_tot=
    np.nan, f_base=np.nan,
219                               f_qual=np.nan, f_attn=np.nan, form='
    幂函数型', L_ctx=2048, C=Cb))
220 sw = pd.DataFrame(sweep)
221 save_csv_safe(sw, '预算扫略.csv')
222
223 Qc = sw['Q'].to_numpy(float)
224 logC = np.log10(C_sweep)
225 ok = np.isfinite(Qc)
226 # 结构性转移的定量定义:
227 # 完成度与费用份额对 log10(C) 的变化率, 用于定位变化最陡的区
    间; 不称为弹性。
228 inQ = (Qc - Q0) / (1 - Q0) # 质量提升完成
    度
229 d_inQ = np.gradient(inQ[ok], logC[ok])
230 fQ = sw['f_qual'].to_numpy(float)

```

```

231 d_fQ = np.gradient(fQ[ok], logC[ok])
232 shift = {'完成度变化率 dTheta/dlog10C 的峰值预算': float(
        C_sweep[ok][np.argmax(d_inQ)]),
233         '质量投入份额变化率 df_Q/dlog10C 的峰值预算': float(
        C_sweep[ok][np.argmax(d_fQ)]),
234         '质量投入份额峰值预算': float(C_sweep[ok][np.argmax(
        fQ[ok]))]),
235         '质量投入份额峰值': float(np.nanmax(fQ[ok]))}
236 shift['质量投入首次正值预算'] = float(sw.loc[sw.Q > Q0 + 1e-7,
        'C'].iloc[0])
237 shift['质量首次达到上界预算'] = float(sw.loc[sw.Q >= 1 - 1e-7,
        'C'].iloc[0])
238 # 以"质量提升完成度"  $\Theta = (Q - Q_0) / (1 - Q_0)$  报告门槛, 避免  $Q_0$  本
        身已高于固定阈值时失去意义
239 for frac in [0.25, 0.5, 0.75, 0.99]:
240     hit = Qc[ok] >= Q0 + frac * (1 - Q0)
241     shift['完成度Theta首次达到%d%%的预算' % int(frac * 100)] =
        (
242         float(C_sweep[ok][np.argmax(hit)]) if hit.any() else
        float('nan'))
243 for k, v in shift.items():
244     print(' %s = %.3e FLOPs' % (k, v))
245
246 # N/D 比随预算的演化 (规模结构)
247 sw['D_over_N'] = sw['D_B'] / sw['N_B']
248 print(' D/N 比: C=1e19 时 %.1f, C=1e22 时 %.1f, C=1e24 时 %.1
        f'
249         % tuple(sw.loc[(sw.C - c).abs().idxmin(), 'D_over_N']
        for c in [1e19, 1e22, 1e24]))
250 save_csv_safe(pd.DataFrame([shift]), '结构性转移识别.csv')
251
252 # ===== 7. 上下文长度敏感性 (C7 可行取值 + 临界值)
        =====
253 print('\n=== 6. 上下文长度敏感性 (C=1e22, 幂函数型) ===')
254 sens = []
255 for L in L_FEAS:
256     r = optimize(1e22, L, '幂函数型')
257     r['attn_over_train'] = ETA * L / 6.0

```

```

258     r['is_above_crit'] = L > L_CRIT
259     sens.append(r)
260     print('    L=%6d (%.2f 倍训练开销) : N*=%.3fB D*=%.1fB Q
*=%.4f L*=%.4f 注意力占比 %.1f%%s'
261           % (L, r['attn_over_train'], r['N_B'], r['D_B'], r['Q
'], r['L'],
262             r['f_attn'] * 100, '    [超临界]' if L > L_CRIT
else ''))
263 sens_df = pd.DataFrame(sens)
264 save_csv_safe(sens_df, '上下文长度敏感性.csv')
265
266 # 连续 L 扫描 (含临界点)
267 L_grid = np.logspace(np.log10(1024), np.log10(200000), 40)
268 cont = []
269 for L in L_grid:
270     try:
271         r = optimize(1e22, float(L), '幂函数型', n_starts=3)
272         r['attn_over_train'] = ETA * L / 6.0
273         cont.append(r)
274     except Exception:
275         pass
276 save_csv_safe(pd.DataFrame(cont), '上下文长度连续扫描.csv')
277
278 # ===== 8. 绘图 =====
279 plt.rcParams['font.size'] = 12
280 C1_, C2_, C3_ = '#3b6ea5', '#e07a3f', '#5aa05a'
281
282 opt_df = pd.DataFrame(rows)
283 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.6))
284 x = np.arange(len(BUDGETS))
285 axes[0].plot(x, opt_df['N_B'], 'o-', lw=2, ms=8, color=C1_,
label='参数量 N* (B)')
286 axes[0].plot(x, opt_df['D_B'], 's--', lw=2, ms=8, color=C2_,
label='数据量 D* (B tokens)')
287 for xi, (nb, db) in enumerate(zip(opt_df['N_B'], opt_df['D_B
'])):
288     axes[0].annotate('%.3g' % nb, (xi, nb), fontsize=8, xytext
=(0, 8),

```

```

289         textcoords='offset points', ha='center',
        color=C1_)
290     axes[0].annotate('%.4g' % db, (xi, db), fontsize=8, xytext
        =(0, -15),
291         textcoords='offset points', ha='center',
        color=C2_)
292 axes[0].set_yscale('log'); axes[0].set_xticks(x)
293 axes[0].set_xticklabels(['1019', '1022', '1024'])
294 axes[0].set_xlabel('算力预算 C (FLOPs)'); axes[0].set_ylabel('
    最优规模 (对数尺度) ')
295 axes[0].set_title('(a) 最优参数量与数据量'); axes[0].legend(
    fontsize=9); despine(axes[0])
296 axes[1].plot(x, opt_df['Q'], 'o-', lw=2, ms=8, color=C3_,
    label='最优质量 Q*')
297 axes[1].axhline(Q0, color='gray', ls=':', lw=1.2, label='基线
    质量 Q0=%.3f' % Q0)
298 for xi, qv in enumerate(opt_df['Q']):
299     axes[1].annotate('%.3f' % qv, (xi, qv), fontsize=9, xytext
        =(0, 8),
300         textcoords='offset points', ha='center',
        color=C3_)
301 axes[1].set_xticks(x); axes[1].set_xticklabels(['1019', '1022'
    , '1024'])
302 axes[1].set_ylim(0, 1.12); axes[1].set_xlabel('算力预算 C (
    FLOPs)')
303 axes[1].set_ylabel('最优质量 Q*'); axes[1].set_title('(b) 最优
    质量随预算的变化')
304 axes[1].legend(fontsize=9); despine(axes[1])
305 fig.tight_layout(); save_fig(fig, '图1_三档预算最优配置')
306
307 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
308 axes[0].plot(C_sweep, Qc, lw=2, color=C3_)
309 axes[0].axhline(Q0, color='gray', ls=':', lw=1.2, label='基线
    质量 Q0=%.3f' % Q0)
310 axes[0].axvline(shift['质量投入份额变化率 df_Q/dlog10C 的峰值
    预算'], color='#d62728', ls='--', lw=1.2,
311     label='投入份额拐点')
312 axes[0].set_xscale('log'); axes[0].set_xlabel('算力预算 C (

```

```

    FLOPs)')
313 axes[0].set_ylabel('最优质量  $Q^*$ '); axes[0].set_ylim(0, 1.05)
314 axes[0].set_title('(a) 最优质量随预算的演化'); axes[0].legend(
    fontsize=8); despine(axes[0])
315 axes[1].plot(C_sweep, sw['f_base'] * 100, lw=2, color=C1_,
    label='基础训练 6ND')
316 axes[1].plot(C_sweep, sw['f_qual'] * 100, lw=2, color=C2_,
    label='质量提升  $D[g(Q)-g(Q_0)]$ ')
317 axes[1].plot(C_sweep, sw['f_attn'] * 100, lw=2, color='#d62728',
    label='长文本注意力')
318 axes[1].set_xscale('log'); axes[1].set_xlabel('算力预算  $C$  (
    FLOPs)')
319 axes[1].set_ylabel('预算份额 (%)'); axes[1].set_title('(b) 预
    算份额的结构性演化')
320 axes[1].legend(fontsize=8); despine(axes[1])
321 fig.tight_layout(); save_fig(fig, '图2_预算份额结构性转移')
322
323 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
324 axes[0].plot([r['attn_over_train'] for r in cont], [r['N_B']
    for r in cont], 'o-', ms=3, color=C1_)
325 axes[0].set_xscale('log'); axes[0].set_yscale('log')
326 axes[0].axvline(1.0, color='#d62728', ls='--', lw=1.2,
327     label='临界  $L^*=%.0f$  (注意力=训练)' % L_CRIT)
328 axes[0].set_xlabel('注意力开销 / 训练开销 =  $\eta L/6$ '); axes[0].
    set_ylabel('N* (B)')
329 axes[0].set_title('(a) 上下文长度对最优规模的影响'); axes[0].
    legend(fontsize=8); despine(axes[0])
330 # 右图: 不同预算档下  $Q^*$  随注意力开销倍数的变化 (低预算档才有内
    点解, 故三档并列)
331 L_small = np.logspace(np.log10(1024), np.log10(150000), 14)
332 _qL_rows = []
333 for Cb, col, lbl in [(1e19, C3_, '1019'), (1e20, C2_, '1020'),
    (1e21, C1_, '1021')]:
334     xs, ys = [], []
335     for L in L_small:
336         try:
337             rr = optimize(Cb, float(L), '幂函数型', n_starts
    =3)

```

```

338         xs.append(ETA * L / 6.0); ys.append(rr['Q'])
339         _qL_rows.append({'C': Cb, 'L_ctx': float(L), '
attn_over_train': ETA * L / 6.0,
340                         'N_B': rr['N_B'], 'D_B': rr['D_B'
], 'Q': rr['Q'], 'L': rr['L']})
341     except Exception:
342         pass
343     axes[1].plot(xs, ys, 'o-', ms=3, color=col, label='预算 %s
FLOPs' % lbl)
344 save_csv_safe(pd.DataFrame(_qL_rows), '上下文长度与最优质量.
csv')
345 axes[1].axvline(1.0, color='#d62728', ls='--', lw=1.2, label='
临界 L*')
346 axes[1].set_xscale('log'); axes[1].set_xlabel('注意力开销 / 训
练开销 =  $\eta L/6$ ')
347 axes[1].set_ylabel('Q*'); axes[1].set_ylim(0, 1.05)
348 axes[1].yaxis.get_major_formatter().set_useOffset(False)
349 axes[1].set_title('(b) 上下文长度对质量投入的影响')
350 axes[1].legend(fontsize=8); despine(axes[1])
351 fig.tight_layout(); save_fig(fig, '图3_上下文长度敏感性')
352
353 fig, ax = plt.subplots(figsize=(7, 5))
354 Q_g = np.linspace(Q0, 1.0, 300)
355 for form, lbl in [('幂函数型', '幂函数型  $5 \times 10^9 Q^4$ '),
356                  ('指数型', '指数型  $10^7 e^{(6Q)}$ '),
357                  ('对数渐进型', '对数渐进型  $2 \times 10^9 \ln(1+10Q)$ ')
]:
358     ax.plot(Q_g, [g_of(q, form) - g_of(Q0, form) for q in Q_g
], lw=2, label=lbl)
359 ax.set_xlabel('数据质量 Q'); ax.set_ylabel('单位 token 质量成
本 g(Q)-g(Q0)')
360 ax.set_title('附录 B 三种质量成本函数 (Q0=%0.3f)' % Q0)
361 ax.legend(fontsize=9); despine(ax); fig.tight_layout();
    save_fig(fig, '图4_质量成本函数对比')
362
363 # ===== 9. 汇总 =====
364 print('\n==== 问题三求解完成 =====')
365 print('    临界上下文长度 L_crit = 6/eta = %.0f tokens; C7 可行

```

```

    取值 %s' % (L_CRIT, L_FEAS))
366 print('  三档预算（幂函数型）： ' +
367       ' ; '.join('C=%0.0e -> N*=%0.3fB D*=%0.1fB Q*=%0.4f L*=%0.4f'
368                  % (r['C'], r['N_B'], r['D_B'], r['Q'], r['L']))
    for r in rows))
369
370 # 以保存的扫描结果生成正文正式图；旧绘图辅助计算不作为最终图版
    本。
371 import subprocess as _subprocess
372 _subprocess.run([sys.executable, os.path.join(BASE_DIR, '论文
    绘图.py')], check=True)

```

Listing 3: 问题三完整求解程序（求解/问题三/问题三.py）

问题四：任务解析、能力分解与前沿预测

```

1  # -*- coding: utf-8 -*-
2  # 本程序及代码的整理与核对使用人工智能工具 Codex 辅助。
3  # 模型：GPT-5.6-Luna；开发机构：OpenAI。
4  # 版本发布日期：2026-07-09（型号发布）。
5  """
6  问题四：技术演进分析与前沿预测
7  数据：C1/C2 排行榜、C3 时序、C4 Epoch 宏观元数据、C5/C6 Loss-
    Benchmark 桥接、C7 架构、C8 逐任务 JSON
8  流程：1) 明确口径：时间轴(提交日期)、开放权重样本口径(许可白名
    单)、模型类型(pretrained/chat)
9          2) C8 逐任务聚合（必做），并与 C1 六维交叉校验
10         3) C6 桥接（按可比性分层）+ C5 对照，建立 Loss ->
    Benchmark 映射
11         4) 面板回归（含年份固定效应）分离规模扩张与非规模技术进
    步贡献
12         5) 情景设定下 logistic 饱和外推 12/24 个月能力前沿 + 残
    差 bootstrap 不确定性
13         6) C4 宏观算力/数据量/开放权重参照，不直接代入能力回归
14  输出：图片到 图片/，结果 CSV 到 结果/
15  """
16 import sys, os, json, glob, re, collections
17 sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.

```

```

    abspath(__file__)))
18 from _common import *    # noqa: F401,F403
19 from scipy.optimize import curve_fit
20
21 DATA = data_path
22 C_DIR = os.path.join(DATA_DIR, 'C_efficiency_evolution')
23
24 def save_csv_safe(df, name_cn):
25     p = os.path.join(OUT_DIR, name_cn)
26     try:
27         df.to_csv(p, index=False, encoding='utf-8-sig')
28     except PermissionError:
29         alt = p.replace('.csv', '_new.csv')
30         df.to_csv(alt, index=False, encoding='utf-8-sig')
31         print('    ! %s 被占用, 已改存为 %s' % (name_cn, os.path
        .basename(alt)))
32
33 TASKS = ['IFEval', 'BBH', 'MATH Lvl 5', 'GPQA', 'MUSR', 'MMLU-
    PRO']
34
35 # ===== 1. C1 排行榜: 口径定义与筛选 =====
36 lb = pd.read_csv(os.path.join(C_DIR, 'leaderboard_cleaned.csv'
    ))
37 lb['P'] = pd.to_numeric(lb['#Params (B)'], errors='coerce')
38 lb['date'] = pd.to_datetime(lb['Submission Date'], errors='
    coerce')
39 lb['Year'] = lb['date'].dt.year
40 lb['avg'] = pd.to_numeric(lb['Average \u2b06\u2013'], errors='
    coerce')
41 for t in TASKS:
42     lb[t] = pd.to_numeric(lb[t], errors='coerce')
43
44 # 字段中的特殊符号使用 Unicode 转义, 保证附录打印后仍能准确复
    制。
45 TYPE_PRE = ['\U0001f7e2 pretrained', '\U0001f7e9 continuously
    pretrained']
46 TYPE_CHAT = ['\U0001f4ac chat models (RLHF, DPO, IFT, ...)',
47     '\U0001f536 fine-tuned on domain-specific

```

```

    datasets']
48 TYPE_EXCL = ['\U0001f91d base merges and moerges', '\U0001f338
    multimodal', '\u2753 other']
49
50 PERMISSIVE = {'apache-2.0', 'mit', 'gpl-3.0', 'cc-by-4.0', '
    mpl-2.0', 'bsd-3-clause',
51               'llama2', 'llama3', 'llama3.1', 'llama3.2', '
    llama3.3', 'gemma',
52               'cc-by-sa-4.0', 'openrail'}
53
54 def license_ok(x):
55     """按本文列明的许可白名单筛选；不将各许可的具体条款视为相
    同。"""
56     return str(x).strip().lower() in PERMISSIVE
57
58 lb['license_ok'] = lb['Hub License'].map(license_ok)
59 lb['type_group'] = np.where(lb['Type'].isin(TYPE_PRE), '
    pretrained',
60                             np.where(lb['Type'].isin(TYPE_CHAT
    ), 'chat/finetuned', '其他'))
61 lb['six_complete'] = lb[TASKS].notna().all(axis=1)
62
63 funnel = [{'层级': 'C1 全量记录', 'n': len(lb)},
64            {'层级': '六维得分完整', 'n': int(lb.six_complete.
    sum())}]
65 core = lb[lb.six_complete & lb.date.notna() & lb.P.notna()]
66 funnel.append({'层级': '时间/参数/六维齐备', 'n': len(core)})
67 core_o = core[core.license_ok]
68 funnel.append({'层级': '许可允许研究复现（开源口径）', 'n':
    len(core_o)})
69 core_pt = core_o[core_o.type_group.eq('pretrained')]
70 core_ch = core_o[core_o.type_group.eq('chat/finetuned')]
71 funnel.append({'层级': ' 其中 pretrained', 'n': len(core_pt)
    })
72 funnel.append({'层级': ' 其中 chat/finetuned', 'n': len(
    core_ch)})
73 save_csv_safe(pd.DataFrame(funnel), '筛选漏斗.csv')
74 print('=== 1. 数据口径与筛选漏斗 ===')
```

```

75 print(pd.DataFrame(funnel).to_string(index=False))
76 print(' 时间轴口径：以 C1 的 Submission Date（提交日期）为基
    准。')
77 print(' 主样本口径：时间、参数量与六维得分完整，且 Hub
    License 在本文白名单中。')
78 print(' 模型类型口径：主样本保留全部类型；pretrained 与 chat/
    finetuned 另作分组分析。')
79 print(' 主样本中的其他类型：base 合并模型 %d 条，多模态 %d
    条。'
80         % (int(core_o['Type'].eq(TYPE_EXCL[0]).sum()),
81            int(core_o['Type'].eq(TYPE_EXCL[1]).sum())))
82 print(' 提交日期范围： %s ~ %s' % (str(lb.date.min())[:10],
    str(lb.date.max())[:10]))
83
84 # ===== 2. C8 逐任务聚合（必用） =====
85 def norm_name(s):
86     return re.sub(r'^[a-z0-9]', '', str(s).lower())
87
88 C8_DIR = os.path.join(C_DIR, 'detailed_results')
89 dirs = sorted(d for d in os.listdir(C8_DIR) if os.path.isdir(
    os.path.join(C8_DIR, d)))
90 METRIC_PREF = ['acc_norm,none', 'acc,none', '
    prompt_level_loose_acc,none',
91                'inst_level_loose_acc,none', 'exact_match,none'
    ]
92 recs, broken = [], 0
93 for d in dirs:
94     fl = sorted(glob.glob(os.path.join(C8_DIR, d, '*.json')))
95     if not fl:
96         continue
97     ok = False
98     for f in reversed(fl):
99         try:
100             o = json.load(open(f, encoding='utf-8'))
101             res = o.get('results')
102             if not isinstance(res, dict) or not res:
103                 continue
104             except Exception:

```

```

105         broken += 1
106         continue
107     rec = {'dir': d, 'json_model_name': o.get('model_name'
108         , ''),
109           'file': os.path.basename(f)}
110     for k, v in res.items():
111         if not isinstance(v, dict):
112             continue
113         for mk in METRIC_PREF:
114             if isinstance(v.get(mk), (int, float)):
115                 rec[k] = float(v[mk]) * 100.0
116                 break
117     recs.append(rec)
118     ok = True
119     break
120 if not ok:
121     broken += 1
122
123 c8 = pd.DataFrame(recs)
124 print('\n=== 2. C8 逐任务聚合（必做） ===')
125 print('  模型目录 %d 个；成功解析 %d 个；跳过损坏/无有效记录 %d 个' % (len(dirs), len(c8), broken))
126 save_csv_safe(c8.fillna(''), 'C8逐任务解析结果.csv')
127
128 C8_MAP = {'IFEval': 'leaderboard_ifeval', 'BBH': '
129     leaderboard_bbh',
130           'MATH Lvl 5': 'leaderboard_math_hard', 'GPQA': '
131     leaderboard_gpqa',
132           'MUSR': 'leaderboard_musr', 'MMLU-PRO': '
133     leaderboard_mmlu_pro'}
134 for t, k in C8_MAP.items():
135     c8[t] = c8[k] if k in c8.columns else np.nan
136 c8['key'] = c8['dir'].map(norm_name)
137
138 lb['key'] = lb['Model'].map(norm_name)
139 core_o = core_o.assign(key=core_o['Model'].map(norm_name))
140 mrg = lb[['key'] + TASKS].merge(c8[['key'] + TASKS], on='key',
141     suffixes=('_C1', '_C8'))

```

```

137 chk_rows = []
138 for t in TASKS:
139     a = pd.to_numeric(mrg[t + '_C1'], errors='coerce')
140     bq = pd.to_numeric(mrg[t + '_C8'], errors='coerce')
141     okm = a.notna() & bq.notna()
142     chk_rows.append({'任务': t, '匹配模型数': int(okm.sum()),
143                     'Pearson_r': float(np.corrcoef(a[okm], bq
144 [okm])[0, 1]) if okm.sum() > 2 else np.nan,
145                     'Spearman_rho': float(stats.spearmanr(a[
146 okm], bq[okm]).statistic)
147                     if okm.sum() > 2 else np.nan,
148                     '平均绝对偏差': float(np.mean(np.abs(a[
149 okm] - bq[okm]))) if okm.sum() else np.nan})
150 chk = pd.DataFrame(chk_rows)
151 save_csv_safe(chk, 'C8与C1一致性校验.csv')
152 print(' C8 与 C1 逐维一致性（规范化模型名匹配，得到 %d 条配对
153 记录）：' % len(mrg))
154 print(chk.to_string(index=False))
155 print(' 口径说明：C8 存的是各任务的原始指标（acc/acc_norm/
156 exact_match），'
157       'C1 存的是官方按随机基线归一化后的六维得分（例如 GPQA=(
158 raw-0.25)/0.75、'
159       'MMLU-PR0=(raw-0.10)/0.90、IFEval=(prompt_strict+
160 inst_strict)/2），'
161       '故两者存在系统性水平差但秩一致性很高。因此：跨模型得分
162 分析用 C1，'
163       '逐任务结构分析在 C8 的原始指标空间内进行。')
164
165 # 逐任务（子任务）聚合：BBH 24 项、MATH 7 项、GPQA 3 项、MUSR
166 3 项
167 SUB_PREFIX = {'BBH子任务': 'leaderboard_bbh_', 'MATH子任务': '
168 leaderboard_math_',
169               'GPQA子集': 'leaderboard_gpqa_', 'MUSR子任务': '
170 leaderboard_musr_' }
171 sub_cols = {}
172 for grp, pre in SUB_PREFIX.items():
173     cols = [c for c in c8.columns if c.startswith(pre) and c.
174 count('_') >= 2]

```

```

163     cols = [c for c in cols if c not in ('leaderboard_bbh', '
164     leaderboard_musr',
165     'leaderboard_gpqa', '
166     leaderboard_math_hard'']]
167     sub_cols[grp] = cols
168     print(' C8 子任务维度数: ' + ', '.join('%s %d 项' % (k, len(v)
169     )) for k, v in sub_cols.items()))
170
171 # 子任务前沿与剩余空间 (限定在开源筛选后的模型集合上)
172 screened_keys = set(core_o['key'])
173 c8s = c8[c8.key.isin(screened_keys)]
174 sub_rows = []
175 for grp, cols in sub_cols.items():
176     for c in cols:
177         s = pd.to_numeric(c8s[c], errors='coerce').dropna()
178         if len(s) < 10:
179             continue
180         sub_rows.append({'类别': grp, '子任务': c.replace('
181         leaderboard_', ''), '样本数': len(s),
182         '最优得分': float(s.max()),
183         '前5%均值': float(s.nlargest(max(1,
184         int(len(s) * 0.05))).mean()),
185         '中位数': float(s.median()),
186         '剩余空间_%': float((100 - s.max()) /
187         100 * 100)})
188 sub_df = pd.DataFrame(sub_rows)
189 save_csv_safe(sub_df, 'C8逐任务聚合.csv')
190 print('\n 子任务层面最弱 6 项 (剩余空间最大): ')
191 print(sub_df.nlargest(6, '剩余空间_%')[['类别', '子任务', '样
192     本数', '最优得分', '前5%均值',
193     '剩余空间_%']]).
194     to_string(index=False))
195
196 CAT_ROWS = []
197 for grp, cols in sub_cols.items():
198     s = pd.to_numeric(c8s[cols].stack(), errors='coerce').
199     dropna()
200     CAT_ROWS.append({'类别': grp, '维度数': len(cols), '平均最

```

```

    优得分': float(
192         np.mean([pd.to_numeric(c8s[c], errors='coerce').max()
    for c in cols])),
193         '整体前5%均值': float(s.quantile(0.95)), '整体中位数':
    float(s.median()))})
194 save_csv_safe(pd.DataFrame(CAT_ROWS), 'C8子任务类别汇总.csv')
195 print('\n 子任务类别汇总: ')
196 print(pd.DataFrame(CAT_ROWS).to_string(index=False))
197
198 # ===== 3. Loss - Benchmark 桥接 (C6 主用, 按可比性分
    层; C5 对照) =====
199 br = pd.read_csv(os.path.join(C_DIR, '
    loss_benchmark_bridge_expanded.csv'))
200 br['cmp'] = np.where(br['Loss_Comparability'].str.startswith('
    High'), '高可比',
201                     '中可比')
202 print('\n=== 3. Loss-Benchmark 桥接 (C6 扩展桥接) ===')
203 bridge_rows, fits = [], {}
204 for lvl in ['高可比', '中可比', '全样本']:
205     d = br if lvl == '全样本' else br[br.cmp.eq(lvl)]
206     sl, ic = np.polyfit(d.Val_Loss, d.LB_Average, 1)
207     pred = ic + sl * d.Val_Loss
208     fits[lvl] = (sl, ic)
209     bridge_rows.append({'可比性': lvl, 'n': len(d),
210                        'Pearson_r': float(np.corrcoef(d.
    Val_Loss, d.LB_Average)[0, 1]),
211                        'Spearman_rho': float(stats.spearmanr(
    d.Val_Loss, d.LB_Average).statistic),
212                        '斜率': float(sl), '截距': float(ic),
213                        'MAPE_%': float(np.mean(np.abs(pred -
    d.LB_Average) / d.LB_Average) * 100),
214                        'R2': float(1 - np.sum((d.LB_Average -
    pred) ** 2)
215                        / np.sum((d.LB_Average - d
    .LB_Average.mean()) ** 2))})
216 bridge_df = pd.DataFrame(bridge_rows)
217 save_csv_safe(bridge_df, 'Loss_Benchmark映射.csv')
218 print(bridge_df.to_string(index=False))

```

```

219 br['pred'] = fits['全样本'][1] + fits['全样本'][0] * br.
    Val_Loss
220 save_csv_safe(br[['Model', 'N_params_B', 'D_tokens_B', '
    Val_Loss', 'LB_Average', 'pred',
221                 'Loss_Comparability']], 'Loss_Benchmark映射
    明细.csv')
222
223 try:
224     b5 = pd.read_csv(os.path.join(C_DIR, '
    loss_benchmark_bridge.csv'))
225     s5, i5 = np.polyfit(b5.Val_Loss, b5.LB_Average, 1)
226     print(' C5 (原始桥接, n=%d) 对照: r=%.3f, 斜率=%.3f'
227           % (len(b5), float(np.corrcoef(b5.Val_Loss, b5.
    LB_Average)[0, 1]), s5))
228 except Exception as e:
229     print(' C5 对照读取失败: ', e)
230 print(' 说明: 全样本 |r|=%.2f (R2=%.2f), 映射误差较大; 高可
    比子集仅 %d 条且落在 '
231       'Pythia 小模型区间, 得分变化幅度极小 (=%.2f-=%.2f), 故桥
    接误差对能力结论的影响'
232       '必须显式讨论。'
233       % (abs(bridge_df.iloc[2]['Pearson_r']), bridge_df.iloc
    [2]['R2'],
234          int(bridge_df.iloc[0]['n']),
235          br[br.cmp.eq('高可比')].LB_Average.min(), br[br.cmp.
    eq('高可比')].LB_Average.max()))
236
237 # ===== 4. 面板回归与贡献分解 (规模扩张 vs 非规模技术进
    步) =====
238 # 思路: 规模系数 bP 在“同一年内的横截面”上识别最稳健 (年份效
    应吸收了当年的技术水平),
239 # 再由 bP 与前沿模型的  $\Delta \log_{10} P$  做 shift-share 分解, 残差
    部分归为非规模技术进步。
240 panel = core_o.copy()
241 lb_o = core_o.copy()
242 panel['logP'] = np.log10(panel.P)
243 panel['t'] = panel.Year - 2019
244 panel = panel[panel.t.between(0, 12)]

```

```

245
246 years = sorted(panel.t.unique())
247 def fit_model(sub, label, fe=True):
248     if fe:
249         Dm = np.column_stack([(sub.t.values == yy).astype(
float) for yy in years])
250         X = np.column_stack([Dm, sub.logP.values])
251     else:
252         X = np.column_stack([np.ones(len(sub)), sub.logP.
values, sub.t.values])
253     b, *_ = np.linalg.lstsq(X, sub.avg.values, rcond=None)
254     pred = X @ b
255     R2 = 1 - np.sum((sub.avg.values - pred) ** 2) / \
256         np.sum((sub.avg.values - sub.avg.values.mean()) ** 2)
257     return (b[-1], b[:-1], R2) if fe else (b[1], b[2], R2)
258
259 bP_fe, alpha_t, R2_fe = fit_model(panel, 'FE', True)
260 bP_ols, bt_ols, R2_ols = fit_model(panel, 'OLS', False)
261 panel['alpha_t'] = panel.t.map(dict(zip(years, alpha_t)))
262 save_csv_safe(pd.DataFrame({'Year': [y + 2019 for y in years],
'年效应alpha_t': alpha_t}),
263               '年份效应.csv')
264 save_csv_safe(panel[['Model', 'P', 'logP', 't', 'avg', '
type_group', 'Year']],
265               '面板回归数据.csv')
266 print('\n=== 4. 规模系数估计 (C1 开源筛选样本, %d 条, %d-%d
年) ==='
267       % (len(panel), int(panel.Year.min()), int(panel.Year.max
()))))
268 print('  年份固定效应模型: bP=%.3f 分/10 倍参数, R2=%.3f' % (
bP_fe, R2_fe))
269 print('  线性时间 OLS 模型: bP=%.3f 分/10 倍参数, bt=%.3f 分/
年, R2=%.3f'
270       % (bP_ols, bt_ols, R2_ols))
271 for tg in ['pretrained', 'chat/finetuned']:
272     sub = panel[panel.type_group.eq(tg)]
273     if len(sub) > 30:
274         bP_t, bt_t, R2_t = fit_model(sub, tg, False)

```

```

275         print(' %s 子样本 (n=%d) : bP=%.3f 分/10 倍参数, bt
           =%.3f 分/年, R2=%.3f'
276               % (tg, len(sub), bP_t, bt_t, R2_t))
277
278 # 口径分层: C3 全期序列 (2019-2025, 跨年标准混合) 用于长周期分
           解;
279 #           C1 开源筛选样本 (2024-2025, 标准一致) 用于近端稳健
           性检验。
280 ts = pd.read_csv(os.path.join(C_DIR, '
           leaderboard_extended_timeseries.csv'))
281 ts['avg'] = pd.to_numeric(ts['Average'], errors='coerce')
282 ts['P'] = pd.to_numeric(ts['Params_B'], errors='coerce')
283 six_ts = ['IFEval', 'BBH', 'MATH_Lvl5', 'GPQA', 'MUSR', '
           MMLU_PRO']
284 for c in six_ts:
285     ts[c] = pd.to_numeric(ts[c], errors='coerce')
286 ts['mean6'] = ts[six_ts].mean(axis=1)
287 ts['gap'] = (ts.avg - ts.mean6).abs()
288 bad = ts[ts.gap > 5]
289 ts_ok = ts[(ts.gap <= 5) & ts.P.notna() & ts.avg.notna() & (ts
           .P > 0)].copy()
290 ts_ok['logP'] = np.log10(ts_ok.P)
291 ts_ok = ts_ok[np.isfinite(ts_ok.logP) & np.isfinite(ts_ok.avg)
           ].copy()
292 ts_ok['t'] = ts_ok.Year - 2019
293 save_csv_safe(bad[['Model', 'Year', 'Average', 'mean6', 'gap'
           ]], 'C3口径异常行.csv')
294 print('\n C3 自洽性审计: |Average - 六维均值| > 5 的记录 %d
           条 (跨口径混入, 已剔除), '
295       '最大差值 %.1f (%s)' % (len(bad), bad.gap.max(),
296                               bad.loc[bad.gap.idxmax(), 'Model
           ']))
297
298 Xl = np.column_stack([np.ones(len(ts_ok)), ts_ok.logP.values,
           ts_ok.t.values])
299 bl, *_ = np.linalg.lstsq(Xl, ts_ok.avg.values, rcond=None)
300 b0_l, bP_l, bt_l = bl
301 pred_l = Xl @ bl

```

```

302 R2_l = 1 - np.sum((ts_ok.avg.values - pred_l) ** 2) / \
303     np.sum((ts_ok.avg.values - ts_ok.avg.values.mean()) ** 2)
304
305 def matched_annual_frontier(records):
306     """累计最高分与其模型规模配对；同分时保留先达到的前沿记
307     录。"""
308     rows=[];incumbent=None
309     for year,group in records.groupby('Year',sort=True):
310         candidate=group.sort_values(['avg','P','Model'],
311         ascending=[False,True,True]).iloc[0]
312         if incumbent is None or candidate.avg>incumbent.avg:
313             incumbent=candidate
314             rows.append(dict(Year=int(year),avg=float(candidate.
315             avg),P=float(incumbent.P),
316             cum_avg=float(incumbent.avg),
317             frontier_model=incumbent.Model,
318             frontier_record_year=int(incumbent.
319             Year)))
320     return pd.DataFrame(rows)
321
322 front_year = matched_annual_frontier(ts_ok)
323 front_year['t'] = front_year.Year - 2019
324 front_year['logP'] = np.log10(front_year.P)
325 save_csv_safe(front_year, '前沿序列.csv')
326
327 f1 = lb_o.groupby('Year').agg(avg=('avg', 'max'), P=('P', 'max
328     ')).reset_index()
329 dF = front_year.cum_avg.iloc[-1] - front_year.cum_avg.iloc[0]
330 dLP = front_year.logP.iloc[-1] - front_year.logP.iloc[0]
331 dec = pd.DataFrame([
332     {'口径': 'C3 长周期（跨年标准混合）', '前沿区间': '%d→%d'
333     % (front_year.Year.iloc[0], front_year.Year.iloc[-1]),
334     '前沿提升分': dF, 'Δlog10P': dLP, 'bP': bP_l, 'bt(分/年)'
335     : bt_l, 'R2': R2_l,
336     '规模贡献分': bP_l * dLP, '非规模贡献分': dF - bP_l * dLP
337     ,
338     '规模占比%': bP_l * dLP / dF * 100, '非规模占比%': (dF -
339     bP_l * dLP) / dF * 100}])

```

```

331 save_csv_safe(dec, '规模时间分解_长周期.csv')
332 print('\n 前沿序列（年度最高分 + 累计最大, %d-%d）： '
333       % (front_year.Year.iloc[0], front_year.Year.iloc[-1]))
334 print(front_year.round(2).to_string(index=False))
335 print(' 贡献分解： ')
336 print(dec.round(2).to_string(index=False))
337 print(' 提示：C3 早期年份为公开报告值（每 1-7 条），跨年评测
      标准不完全一致（C3 标注'
338       '为“混合”口径），故长周期占比视为量级参考；C1 近端口径
      标准一致但窗口仅约 1 年。')
339
340 # ===== 5. 能力前沿的 logistic 外推 =====
341 # 前沿定义：每个时间窗内开源筛选模型平均分的上侧分位（月度取前
      1%，历史年度取最高分）
342 lb_o['ym'] = lb_o.date.dt.to_period('M')
343 mon_top1 = lb_o.groupby('ym').apply(
344     lambda g: g.avg.nlargest(max(1, int(len(g) * 0.01))).mean
      (), include_groups=False)
345 mon_top1 = mon_top1[mon_top1.index >= pd.Period('2024-01')]
346 t_mon = np.array([(pd.Timestamp(str(p)).year - 2019) + (pd.
      Timestamp(str(p)).month - .5) / 12
347                   for p in mon_top1.index])
348
349 # 前沿边界单调不减：历史段取 C3 累计最大，近端取月度前 1% 的累
      计最大
350 hist_rows = front_year[front_year.Year <= 2023]
351 t_h = hist_rows.t.values + .5
352 s_h = np.maximum.accumulate(hist_rows.cum_avg.values)
353 t_front = np.r_[t_h, t_mon]
354 s_front = np.r_[s_h, np.maximum.accumulate(mon_top1.values)]
355 idx = np.argsort(t_front)
356 t_front, s_front = t_front[idx], np.maximum.accumulate(s_front
      [idx])
357
358 # 近端口径（一致窗口）内的前沿分解：从首月到峰值月
359 def month_stats(period):
360     g = lb_o[lb_o.date.dt.to_period('M').eq(period)]
361     g = g.nlargest(max(1, int(len(g) * 0.01)), 'avg')

```

```

362     # 同一组模型的均分与平均对数规模配对；返回几何均值用于原对
    数比公式。
363     return float(g.avg.mean()), float(10**np.log10(g.P).mean()
    )
364
365 p0, pk = mon_top1.index[0], mon_top1.idxmax()
366 F0_, P0_ = month_stats(p0)
367 Fk_, Pk_ = month_stats(pk)
368 dF1 = Fk_ - F0_
369 dLP1 = float(np.log10(Pk_ / P0_))
370 dec1 = pd.DataFrame([
371     '口径': 'C1 近端（一致窗口 %s→%s, 前沿模型 %sB→%sB）'
372     % (str(p0), str(pk), ('%.1f' % P0_), ('%.1f' % Pk_)),
373     '前沿区间': '%s→%s' % (str(p0), str(pk)),
374     '前沿提升分': dF1, 'Δlog10P': dLP1, 'bP': bP_fe, 'bt(分/年
    )': bt_ols, 'R2': R2_fe,
375     '规模贡献分': bP_fe * dLP1, '非规模贡献分': dF1 - bP_fe *
    dLP1,
376     '规模占比%': bP_fe * dLP1 / dF1 * 100 if dF1 != 0 else np.
    nan,
377     '非规模占比%': (dF1 - bP_fe * dLP1) / dF1 * 100 if dF1 !=
    0 else np.nan]])
378 dec_all = pd.concat([dec, dec1], ignore_index=True)
379 save_csv_safe(dec_all, '规模时间分解.csv')
380 print('\n 近端口径（一致窗口）分解：前沿 %s→%s 由 %.2f 升至
    %.2f（+%.2f 分），'
381     '前沿模型规模 %sB→%sB（Δlog10P=%.3f）'
382     % (str(p0), str(pk), F0_, Fk_, dF1, ('%.1f' % P0_), ('
    %.1f' % Pk_), dLP1))
383 print(' -> 规模贡献 %.2f 分，非规模贡献 %.2f 分；该窗口内前沿
    提升基本来自非规模因素。'
384     % (bP_fe * dLP1, dF1 - bP_fe * dLP1))
385
386 def logistic(t, K, r, t0):
387     return K / (1 + np.exp(-r * (t - t0)))
388
389 t_last = float(np.max(t_mon))
390 t_pred = np.array([t_last + 1.0, t_last + 2.0]) # 严格对

```

应未来 12 / 24 个月

```
391 try:
392     popt, _ = curve_fit(logistic, t_front, s_front, p0=[55,
393         .8, 3.5],
394         bounds=([20, .01, 0.5], [100, 5, 8]),
395         maxfev=40000)
396     K_fit, r_fit, t0_fit = popt
397     pred_fit = logistic(t_front, *popt)
398     R2_log = 1 - np.sum((s_front - pred_fit) ** 2) / np.sum((
399         s_front - s_front.mean()) ** 2)
400 except Exception as e:
401     K_fit, r_fit, t0_fit, R2_log = 52., .3, 3., 0.
402     print('logistic 拟合失败: ', e)
403 s_pred = logistic(t_pred, K_fit, r_fit, t0_fit)
404
405 resid = s_front - logistic(t_front, K_fit, r_fit, t0_fit)
406 rng = np.random.default_rng(42)
407 boot = []
408 for _ in range(600):
409     s_b = logistic(t_front, K_fit, r_fit, t0_fit) + rng.choice
410     (resid, size=len(resid), replace=True)
411     try:
412         pb, _ = curve_fit(logistic, t_front, s_b, p0=[K_fit,
413             r_fit, t0_fit], maxfev=40000)
414         boot.append(logistic(t_pred, *pb))
415     except Exception:
416         pass
417 boot = np.array(boot)
418 lo, hi = np.percentile(boot, 5, axis=0), np.percentile(boot,
419     95, axis=0)
420
421 # 条件情景：以 logistic 增长参数减半表征放缓，不估计算力到增长
422 # 率的传导。
423 def logistic_slow(t, K, r, t0, halve_from):
424     """减速前沿用原曲线，减速后增长参数为 r/2，连接点连续。"""
425     t = np.asarray(t, dtype=float)
426     effective_t = np.minimum(t, halve_from) + 0.5 * np.maximum
427     (t - halve_from, 0.0)
```

```

420     return logistic(effective_t, K, r, t0)
421 s_slow = logistic_slow(t_pred, K_fit, r_fit, t0_fit, t_last)
422
423 fut = pd.DataFrame({'t(2019起算年)': t_pred, '对应日历时点':
424                     ['%d-%02d' % (2019 + int(np.floor(tt)),
425                                   int(round((tt % 1) * 12)) + 1)
426                     for tt in t_pred],
427                     'frontier_pred': s_pred,
428                     'CI_low_5%': lo, 'CI_high_95%': hi, '情景_
429     技术增速减半': s_slow})
430 save_csv_safe(fut, '前沿预测.csv')
431
432 # 结构外推:  $F(t+\Delta) = F(t) + [bP \cdot \Delta \log_{10} P + bt] \cdot \Delta$  (把分解式直接
433 # 用作预测方程)
434 F_last = float(np.max(s_front))
435 scen = []
436 for yrs in [1, 2]:
437     for dlogP, bt_use, lbl in [(0.0, bt_ols, '基准 (前沿模型规
438     模持平, 非规模增速不变)'),
439     (0.0, bt_ols / 2, '算力增长放缓
440     (非规模增速减半)'),
441     (0.3, bt_ols, '规模继续扩张 (前
442     沿 +0.3 dex/年)')]:
443         scen.append({'情景': lbl, '前瞻年数': yrs,
444                     '\Delta \log_{10} P 假设': dlogP, 'bt 假设 (分/年)':
445                     bt_use,
446                     '结构外推前沿': F_last + (bP_fe * dlogP +
447                     bt_use) * yrs})
448 scen_df = pd.DataFrame(scen)
449 save_csv_safe(scen_df, '前沿预测_结构外推情景.csv')
450 save_csv_safe(pd.DataFrame([{'K': K_fit, 'r': r_fit, 't0(2019
451     起)': t0_fit, 'R2': R2_log,
452     '数据截止': str(max(lb_o.date))
453     [:10], 'n前沿点': len(t_front),
454     't_last': t_last}]]),
455     'logistic参数.csv')
456 print('\n=== 5. 能力前沿 logistic 外推 ===')
457 print('    F(t)=K/(1+exp(-r(t-t0))): K=%.2f, r=%.3f, t0=%.2f (

```

```

    2019 起算) , R2=%.3f'
448     % (K_fit, r_fit, t0_fit, R2_log))
449 print(fut.round(2).to_string(index=False))
450
451 # ===== 6. C4 宏观证据（算力、数据量、开源权重）
    =====
452 ep = pd.read_csv(os.path.join(C_DIR, 'epoch_all_ai_models.csv'
    ), low_memory=False)
453 ep['compute'] = pd.to_numeric(ep['Training compute (FLOP)'].
    astype(str).str.replace(',', ''),
454                               errors='coerce')
455 ep['dsize'] = pd.to_numeric(ep['Training dataset size (total)'
    ].astype(str).str.replace(',', ''),
456                               errors='coerce')
457 ep['P'] = pd.to_numeric(ep['Parameters'].astype(str).str.
    replace(',', ''), errors='coerce')
458 ep['year'] = pd.to_datetime(ep['Publication date'], errors='
    coerce').dt.year
459 ep['open_w'] = ep['Open model weights?'].astype(str).str.strip
    ().eq('Yes')
460
461 c4 = ep[(ep.Domain.astype(str).str.contains('Language', na=
    False)) &
462         ep.year.between(2018, 2026)].copy()
463 g = c4.groupby('year').agg(n=('Model', 'size'),
464                             n_compute=('compute', 'count'),
465                             前沿算力_max=('compute', 'max'),
466                             前沿算力_中位=('compute', 'median')
467
468                             ,
469                             最大参数量_B=('P', 'max'),
470                             最大数据量_tokens=('dsize', 'max'),
471                             开源权重占比=('open_w', 'mean')).
    reset_index()
472 save_csv_safe(g, 'C4宏观趋势.csv')
473 print('\n=== 6. C4 宏观证据（Epoch AI 全模型元数据, Language
    域）===')
474 print(g.round(3).to_string(index=False))
475 gc = g.dropna(subset=['前沿算力_max'])

```

```

474 gc = gc[gc.前沿算力_max > 0]
475 sl_c, ic_c = np.polyfit(gc.year, np.log10(gc.前沿算力_max), 1)
476 print('  前沿训练算力的年增长率: log10(C) 每年 +%.3f 个数量级
      (即约 %.2f 倍/年) '
      % (sl_c, 10 ** sl_c))
477
478 ov = ep['Open model weights?'].astype(str).str.strip()
479 print('  C4 开源权重字段分布: ' + ';' .join('%s=%d' % (k, v)
      for k, v in ov.value_counts().head(4).items()))
480
481 save_csv_safe(pd.DataFrame([{'log10前沿算力年增速': sl_c, '年
      倍数': 10 ** sl_c,
482                               '开源权重_Yes': int(ov.eq('Yes').
      sum()),
483                               '开源权重_No': int(ov.eq('No').
      sum()),
484                               '有算力记录行数': int(ep.compute.
      notna().sum()),
485                               '有数据量记录行数': int(ep.dsize.
      notna().sum())}]]),
      'C4宏观摘要.csv')
486
487
488 # ===== 7. 六维 Benchmark 前沿与剩余空间 (开源筛选集)
      =====
489 task_rows = []
490 for tk in TASKS:
491     s = lb_o[tk].dropna()
492     task_rows.append({'task': tk, 'n': len(s), 'max': float(s.
      max()),
493                       'top1_mean': float(s.nlargest(max(1, int
      (len(s) * 0.01))).mean()),
494                       'median': float(s.median()),
495                       'headroom_%': float((100 - s.max()))})
496 task_df = pd.DataFrame(task_rows).sort_values('max')
497 save_csv_safe(task_df, '逐任务聚合.csv')
498 print('\n=== 7. 六维 Benchmark 前沿与剩余空间 (开源筛选集, n=%
      d) ===' % len(lb_o))
499 print(task_df.to_string(index=False))
500
501 # 正式图表由文件末尾的独立绘图入口生成。

```

```

502
503 # ===== 9. 汇总 =====
504 d0 = dec.iloc[0]
505 print('\n===== 问题四求解完成 =====')
506 print('  桥接：全样本 r=%.3f；分解（%s）：规模 %.1f%% / 非规模
      %.1f%%； '
507       'OLS 版：规模 %.1f%% / 非规模 %.1f%%'
508       % (bridge_df.iloc[2]['Pearson_r'], d0['前沿区间'], d0['
      规模占比%'], d0['非规模占比%'],
509       dec_all.iloc[1]['规模占比%'], dec_all.iloc[1]['非规模
      占比%']))
510 print('  前沿预测（+12/+24 个月）： %s %.2f（90%%CI %.2f-%.2f
      ）； %s %.2f（90%%CI %.2f-%.2f）； '
511       'logistic 增长参数减半情景 %.2f / %.2f'
512       % (fut['对应日历时点'].iloc[0], fut.frontier_pred.iloc
      [0], fut['CI_low_5%'].iloc[0],
513       fut['CI_high_95%'].iloc[0], fut['对应日历时点'].iloc
      [1], fut.frontier_pred.iloc[1],
514       fut['CI_low_5%'].iloc[1], fut['CI_high_95%'].iloc[1],
515       fut['情景_技术增速减半'].iloc[0], fut['情景_技术增速
      减半'].iloc[1]))
516 print('\n  结构外推情景（基准前沿 F=%.2f）： ' % F_last)
517 print(scen_df.round(2).to_string(index=False))
518 print('  两条路线用于比较预测假设，不构成独立验证。logistic 的
      重抽样区间见上表； '
519       '结构外推给出的是情景点值，其范围不能作为置信区间。')
520
521 # 模型结果全部保存后生成正文采用的正式图。
522 import subprocess as _subprocess
523 _subprocess.run([sys.executable, os.path.join(BASE_DIR, '重绘
      图表.py'), '--data', DATA_DIR], check=True)

```

Listing 4: 问题四完整求解程序（求解/问题四/问题四.py）

公共模块、非线性预测与完整绘图程序

```

1 # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
  构：OpenAI；版本发布日期：2026-07-09。

```

```

2 # 本程序由 OpenAI Codex (GPT-5.6-Luna) 辅助实现, 用于统一执行
   正式绘图与隔离复核。
3 """在仓库根目录执行:
4 python 求解/复现论文.py --data-dir <附件根目录> --mode figures
5 python 求解/复现论文.py --data-dir <附件根目录> --mode verify-
   models
6
7 figures: 读取已存结果、重绘正文全部图。verify-models: 在临时副
   本运行完整四问,
8 按预期清单逐一比较重新生成的 CSV 及跨问 JSON; 不会回写原结果。
9 """
10 from pathlib import Path
11 import argparse
12 import hashlib
13 import json
14 import os
15 import re
16 import shutil
17 import subprocess
18 import sys
19 import tempfile
20 import numpy as np
21 import pandas as pd
22
23 ROOT = Path(__file__).resolve().parents[1]
24
25 # 每问正式数值输出的固定清单; 新增正式输出时须同步登记。
26 EXPECTED_OUTPUTS = {
27     '问题一': [
28         '求解/问题一/结果/线性有界配比对照.csv',
29         '求解/问题一/结果/核岭推荐_训练凸组合.csv',
30         '求解/问题一/结果/核岭推荐_多初值.csv',
31         '求解/问题一/结果/核岭推荐_目标对照.csv',
32         '求解/问题一/结果/17域质量映射.csv',
33         '求解/问题一/结果/Loss代理领域难度.csv',
34         '求解/问题一/结果/冲突指标对_top20.csv',
35         '求解/问题一/结果/冲突样本裁决汇总.csv',
36         '求解/问题一/结果/冲突阈值灵敏度.csv',

```

```

37 '求解/问题一/结果/原文抽查.csv',
38 '求解/问题一/结果/外推尺度因子.csv',
39 '求解/问题一/结果/岭正则敏感性.csv',
40 '求解/问题一/结果/广告方向敏感性.csv',
41 '求解/问题一/结果/截距.csv',
42 '求解/问题一/结果/抽样集与扩展集域级对照.csv',
43 '求解/问题一/结果/推荐配比调整.csv',
44 '求解/问题一/结果/最优配比预测.csv',
45 '求解/问题一/结果/样本级质量评分.csv',
46 '求解/问题一/结果/混合系数矩阵.csv',
47 '求解/问题一/结果/混合系数矩阵_中心化.csv',
48 '求解/问题一/结果/训练域边际效应.csv',
49 '求解/问题一/结果/质量与损失难度一致性.csv',
50 '求解/问题一/结果/质量信号缺失审计.csv',
51 '求解/问题一/结果/质量冲突与一致性.csv',
52 '求解/问题一/结果/质量域评分_全量.csv',
53 '求解/问题一/结果/质量域评分_抽样与扩展.csv',
54 '求解/问题一/结果/质量指标熵权.csv',
55 '求解/问题一/结果/质量项增量检验.csv',
56 '求解/问题一/结果/赋权方案对比.csv',
57 '求解/问题一/结果/跨尺度损失比_60m_vs_1m.csv',
58 '求解/问题一/结果/问题一_拟合汇总.csv',
59 '求解/问题一/结果/非线性代理对照_五折.csv',
60 '求解/问题一/结果/非线性代理对照_参数搜索.csv',
61 '求解/问题一/结果/非线性代理对照_折分配.csv',
62 '求解/问题一/结果/非线性代理对照_汇总.csv',
63 '求解/问题一/结果/非线性代理对照_逐域.csv',
64 '求解/问题一/结果/非线性代理对照_预测明细.csv',
65 '求解/问题一/结果/领域质量评分.csv',
66 '求解/17域质量映射.csv',
67 '求解/问题一_关键量.json',
68 ],
69 '问题二': [
70 '求解/问题二/结果/B3轨迹验证.csv',
71 '求解/问题二/结果/广义标度律分层验证.csv',
72 '求解/问题二/结果/广义标度律参数.csv',
73 '求解/问题二/结果/广义标度律形式对比.csv',
74 '求解/问题二/结果/弹性与替代关系.csv',

```

```

75     '求解/问题二/结果/替代率随质量变化.csv',
76     '求解/问题二/结果/百亿参数以上外推.csv',
77     '求解/问题二/结果/经典标度律参数.csv',
78     '求解/问题二/结果/质量与损失下限.csv',
79     '求解/问题二/结果/质量参数替代关系.csv',
80     '求解/问题二/结果/质量字段方向审计.csv',
81     '求解/问题二/结果/配比项校准.csv',
82     '求解/问题二/结果/问题二_拟合汇总.csv',
83     '求解/问题二/结果/领域替代互补_top.csv',
84     '求解/问题二/结果/领域替代互补矩阵.csv',
85     '求解/广义标度律参数.csv',
86 ],
87 '问题三': [
88     '求解/问题三/结果/三档预算最优配置.csv',
89     '求解/问题三/结果/上下文长度与最优质量.csv',
90     '求解/问题三/结果/上下文长度敏感性.csv',
91     '求解/问题三/结果/上下文长度连续扫描.csv',
92     '求解/问题三/结果/成本函数对比.csv',
93     '求解/问题三/结果/结构性转移识别.csv',
94     '求解/问题三/结果/质量基线灵敏度.csv',
95     '求解/问题三/结果/配比项算力等价.csv',
96     '求解/问题三/结果/预算扫略.csv',
97 ],
98 '问题四': [
99     '求解/问题四/结果/C3口径异常行.csv',
100    '求解/问题四/结果/C4宏观摘要.csv',
101    '求解/问题四/结果/C4宏观趋势.csv',
102    '求解/问题四/结果/C8与C1一致性校验.csv',
103    '求解/问题四/结果/C8子任务类别汇总.csv',
104    '求解/问题四/结果/C8逐任务聚合.csv',
105    '求解/问题四/结果/C8逐任务解析结果.csv',
106    '求解/问题四/结果/logistic参数.csv',
107    '求解/问题四/结果/Loss_Benchmark映射.csv',
108    '求解/问题四/结果/Loss_Benchmark映射明细.csv',
109    '求解/问题四/结果/前沿序列.csv',
110    '求解/问题四/结果/前沿预测.csv',
111    '求解/问题四/结果/前沿预测_结构外推情景.csv',
112    '求解/问题四/结果/年份效应.csv',

```

```

113         '求解/问题四/结果/筛选漏斗.csv',
114         '求解/问题四/结果/规模时间分解.csv',
115         '求解/问题四/结果/规模时间分解_长周期.csv',
116         '求解/问题四/结果/逐任务聚合.csv',
117         '求解/问题四/结果/面板回归数据.csv',
118     ],
119 }
120
121
122 def sha(path):
123     return hashlib.sha256(path.read_bytes()).hexdigest()
124
125
126 def snapshots(root):
127     return {p.relative_to(root).as_posix(): sha(p) for p in (
128         root/'求解').rglob('*')
129         if p.is_file() and p.suffix in ('.csv', '.json')
130         and '图片' not in p.parts
131         and '__pycache__' not in p.parts}
132
133 def run(root, script, args, data):
134     env = dict(os.environ, MODELING_DATA_DIR=str(data),
135               PYTHONIOENCODING='utf-8')
136     print(f'执行: {script}', flush=True)
137     subprocess.run([sys.executable, str(root/script), *map(str,
138         args)], cwd=root, env=env, check=True)
139
140
141 def figure_map(root):
142     # 从真实主入口递归读取；旧拆分稿和注释不参与清单。
143     visited = set(); rows = []
144     def walk(p):
145         p=p.resolve()
146         if p in visited: return
147         visited.add(p)
148         text='\n'.join(re.split(r'(?<!\\\)%',line)[0] for line
149             in p.read_text(encoding='utf-8').splitlines())

```

```

146         for name in re.findall(r'\\(?:input|include)\{([^\}]+\)
147         \}',text):
148             target=root/'论文'/name
149             if not target.suffix: target=target.with_suffix('.
150             tex')
151             if target.exists(): walk(target)
152             for name in re.findall(r'\\includegraphics
153             (?:[^\}]*\\)?\{([^\}]+\)\}',text):
154                 target=(root/'论文'/name).resolve()
155                 if not target.is_file(): raise FileNotFoundError(
156                 target)
157                 rel=target.relative_to(root).as_posix()
158                 if '/问题一/' in rel: source='求解/问题一/重绘图表
159                 .py'
160                 elif '/问题二/' in rel: source='求解/问题二/重绘图
161                 表.py'
162                 elif '/问题三/' in rel: source='求解/问题三/论文绘
163                 图.py'
164                 elif '/问题四/' in rel: source='求解/问题四/重绘图
165                 表.py'
166                 elif 'workflow' in rel: source='求解/绘制问题三四
167                 流程图.py'
168                 else: source='模板静态资源'
169                 rows.append(dict(tex=p.relative_to(root).as_posix
170                 (), figure=rel, source=source, sha256=sha(target)))
171                 walk(root/'论文/论文.tex')
172                 rows.append(dict(tex='论文/2.总体分析.tex',figure='论文/
173                 figures/overall-architecture.tex',
174                 source='原生TikZ, 随论文编译',sha256=sha(
175                 root/'论文/figures/overall-architecture.tex'))))
176             return rows
177
178 def figures(root, data):
179     before=snapshots(root)
180     for script,args in [
181         ('求解/问题一/重绘图表.py',['--data-dir',data]),
182         ('求解/问题二/重绘图表.py',['--data-dir',data]),

```

```

172         ('求解/问题三/论文绘图.py',[]),
173         ('求解/问题四/重绘图表.py',['--data',data]),
174         ('求解/绘制问题三四流程图.py',[]),
175     ]: run(root,Path(script),args,data)
176     if before != snapshots(root): raise RuntimeError('绘图修改
了结果或跨问接口')
177     return figure_map(root)
178
179
180 def compare_csv(a,b,atol=1e-8):
181     x,y=pd.read_csv(a),pd.read_csv(b)
182     if x.shape != y.shape or list(x.columns) != list(y.columns
):
183         return dict(equal=False,reason='shape/columns differ',
saved_shape=list(x.shape),new_shape=list(y.shape))
184     # 数值相同的零份额可能有不同稳定排序；按明确唯一的业务键对
齐。
185     for key in ['index','domain','training_domain','
loss_domain','param']:
186         if key in x and not x[key].duplicated().any() and not
y[key].duplicated().any():
187             x=x.sort_values(key).reset_index(drop=True)
188             y=y.sort_values(key).reset_index(drop=True)
189             break
190     bad=[]
191     for c in x:
192         if pd.api.types.is_numeric_dtype(x[c]) and pd.api.
types.is_numeric_dtype(y[c]):
193             if not np.allclose(x[c],y[c],rtol=1e-6,atol=atol,
equal_nan=True): bad.append(c)
194             elif not x[c].fillna('<NA>').astype(str).equals(y[c].
fillna('<NA>').astype(str)):
195                 bad.append(c)
196     return dict(equal=not bad,columns_differ=bad)
197
198
199 def compare_json(a, b):
200     """递归比较跨问接口，数值容差与 CSV 一致。"""

```

```

201     def equal(x, y):
202         if isinstance(x, dict) and isinstance(y, dict):
203             return x.keys() == y.keys() and all(equal(x[k], y[
204 k]) for k in x)
205         if isinstance(x, list) and isinstance(y, list):
206             return len(x) == len(y) and all(equal(u, v) for u,
207 v in zip(x, y))
208         if type(x) in (int, float) and type(y) in (int, float)
209 :
210             return bool(np.isclose(x, y, rtol=1e-6, atol=1e-8,
211 equal_nan=True))
212         return type(x) is type(y) and x == y
213
214     x = json.loads(a.read_text(encoding='utf-8-sig'))
215     y = json.loads(b.read_text(encoding='utf-8-sig'))
216     return dict(equal=equal(x, y))
217
218 def check_kernel_certificate(root, data):
219     """凸组合表示不唯一：核对其数学含义，不要求权重逐项重现。
220     """
221     folder=root/'求解/问题一/结果'
222     train=pd.read_csv(data/'A_data_value/regmix_tables/
223 train_mixture_lm.csv').set_index('index').sort_index()
224     columns=[c for c in train if c.startswith('train_the_pile_
225 ')]
226     domains=[c.removeprefix('train_the_pile_') for c in
227 columns]
228     raw=train[columns].to_numpy(float);closed=raw/raw.sum(axis
229 =1,keepdims=True)
230     ref=raw.mean(axis=0);ref/=ref.sum()
231     certificate=pd.read_csv(folder/'核岭推荐_训练凸组合.csv').
232 set_index('index')
233     if certificate.index.has_duplicates or set(certificate.
234 index)!=set(train.index):
235         return dict(equal=False,reason='训练凸组合 index 缺失
236 或重复')
237     z=certificate.loc[train.index,'convex_weight'].to_numpy(
238 float)

```

```

226     recipe=pd.read_csv(folder/'推荐配比调整.csv').set_index('
domain').loc[domains]
227     p=recipe.recommended_mixture.to_numpy(float)
228     loss_columns=pd.read_csv(data/'A_data_value/regmix_tables/
train_pile_loss_lm.csv',nrows=0).columns
229     measured=[c.removeprefix('metric/the_pile_').removesuffix(
'_val_loss') for c in loss_columns if c.endswith('_val_loss'
)]
230     fixed=[i for i,d in enumerate(domains) if d not in
measured]
231     residual=max(abs(z.sum()-1),max(0.,-z.min()),float(np.max(
abs(z@closed-p))),
232                 abs(p.sum()-1),float(np.max(abs(p[fixed]-ref[
fixed]))),
233                 float(np.maximum(p-2.5*ref,0).max()),float(np
.max(abs(recipe.reference_mixture-ref))))
234     return dict(equal=bool(np.isfinite(residual) and np.
isfinite(z).all() and np.isfinite(p).all() and residual<1e
-7),
235                 validation='nonnegative convex reconstruction
and recipe constraints',max_residual=float(residual))
236
237
238 def check_kernel_runs(root):
239     folder=root/'求解/问题一/结果'
240     runs=pd.read_csv(folder/'核岭推荐_多初值.csv')
241     target=pd.read_csv(folder/'核岭推荐_目标对照.csv').
set_index('mixture').loc['问题一有界推荐','
predicted_weighted_loss']
242     good=runs[runs.success.eq(True)]
243     ok=(len(runs)==4 and len(good)>0 and np.isfinite(runs.
objective).all()
244         and (runs.constraint_residual<1e-7).all() and (good.
stationarity_gap<1e-6).all()
245         and abs(good.objective.min()-target)<1e-7 and runs.
objective.max()-runs.objective.min()<1e-6)
246     return dict(equal=bool(ok),validation='feasibility,
stationarity and objective agreement',successful_starts=len(

```

```

good))
247
248
249 def compare_output(source, work, rel, data):
250     if rel.name=='核岭推荐_训练凸组合.csv':
251         return check_kernel_certificate(work,data)
252     if rel.name=='核岭推荐_多初值.csv':
253         return check_kernel_runs(work)
254     if rel.name=='推荐配比调整.csv':
255         # 配方为数值驻点；容差与求解停止精度一致，另由凸组合证
书严格检查可行性。
256         return compare_csv(source/rel,work/rel,atol=1e-6)
257     return (compare_csv if rel.suffix=='.csv' else
compare_json)(source/rel,work/rel)
258
259
260 def verify_stage(source, work, name, data, report, runner=run)
:
261     """先删除隔离副本内的预期输出，禁止把旧文件当作新结果。"""
262     required = [Path(p) for p in EXPECTED_OUTPUTS[name]]
263     if not required:
264         raise RuntimeError(f'{name}的预期输出清单为空')
265     for rel in required:
266         if not (source / rel).is_file():
267             raise FileNotFoundError(f'缺少比较基准: {rel}')
268         target = (work / rel).resolve()
269         if not target.is_relative_to(work.resolve()) or source
.resolve() == work.resolve():
270             raise ValueError('输出清理仅允许在隔离副本内进行')
271         target.unlink(missing_ok=True)
272     before = snapshots(work)
273     script = Path('求解') / name / (name + '.py')
274     runner(work, script, [], data)
275     report['commands'].append(str(script))
276     failed = []
277     for rel in required:
278         p = work / rel
279         if not p.is_file():

```

```

280         result = dict(equal=False, status='missing',
reason='未重新生成预期输出')
281     else:
282         try:
283             result = compare_output(source,work,rel,data)
284             result['status'] = 'matched' if result['equal'
] else 'different'
285         except (ValueError, TypeError, OSError, pd.errors.
ParserError) as exc:
286             result = dict(equal=False, status='unreadable'
, reason=str(exc))
287         report['outputs'][rel.as_posix()] = result
288         if not result['equal']:
289             failed.append(rel.as_posix())
290     expected_keys = {p.as_posix() for p in required}
291     # 新出现但没有基准的结果单独列示, 不计入核对成功数量。
292     for rel, value in snapshots(work).items():
293         if rel not in expected_keys and before.get(rel) !=
value:
294             report['uncompared'][rel] = dict(status='
not_compared', stage=name)
295         if failed:
296             raise RuntimeError('预期输出缺失或不一致: ' + ', '.
join(failed))
297
298
299 def main():
300     ap=argparse.ArgumentParser(description=__doc__)
301     ap.add_argument('--data-dir',type=Path,required=True)
302     ap.add_argument('--mode',choices=['figures','verify-models
'],default='figures')
303     ap.add_argument('--report-dir',type=Path,default=R00T/'复
现记录')
304     args=ap.parse_args();data=args.data_dir.resolve()
305     if not (data/'A_data_value').is_dir(): raise
FileNotFoundError(data)
306     args.report_dir.mkdir(parents=True,exist_ok=True)
307     if args.mode=='figures':

```

```

308         rows=figures(ROOT,data)
309         (args.report_dir/'图表来源.json').write_text(json.
dumps(rows,ensure_ascii=False,indent=2),encoding='utf-8')
310         print(f'{len(rows)} 项图形资源已对应到源码; 结果文件未
改动。')
311         return
312     before=snapshots(ROOT)
313     # 隔离目录保留供差异调查; 求解器永远不写原结果。
314     work=Path(tempfile.mkdtemp(prefix='model-check-',dir=args.
report_dir))
315     shutil.copytree(ROOT/'求解',work/'求解',ignore=shutil.
ignore_patterns('__pycache__', '图片', '*.ipynb'))
316     shutil.copytree(ROOT/'论文/fonts',work/'论文/fonts')
317     report=dict(workspace=str(work),outputs={},uncompared={},
commands=[],complete=False)
318     try:
319         for name in ['问题一','问题二','问题三','问题四']:
320             verify_stage(ROOT,work,name,data,report)
321             report['complete']=True
322     finally:
323         report['source_results_unchanged']=(before==snapshots(
ROOT))
324         (args.report_dir/'模型复现比较.json').write_text(json.
dumps(report,ensure_ascii=False,indent=2),encoding='utf-8')
325         count=sum(r['status']=='matched' for r in report['outputs'
].values())
326         if count != sum(map(len, EXPECTED_OUTPUTS.values())) or
not report['complete']:
327             raise RuntimeError('预期输出覆盖不完整')
328         if not report['source_results_unchanged']:
329             raise RuntimeError('原结果发生变化')
330         print(f'已重新生成并核对 {count} 项预期输出; 另有 {len(
report["uncompared"])} 项未比较; 原结果未改动。')
331
332
333 if __name__=='__main__':
334     if hasattr(sys.stdout,'reconfigure'): sys.stdout.
reconfigure(encoding='utf-8')

```

Listing 5: 统一复现入口（求解/复现论文.py）

```

1  # 本补充检验程序使用 OpenAI Codex 辅助编写与核对。
2  # 用途：检验保存结果的决策含义、跨问假设和时间外推；不改写正式
   求解结果。
3  """运行：python 求解/补充检验.py --data-dir <附件根目录>
4  输出写入复现记录/补充检验；核岭超参数沿用保存值，不重新搜索。
5  两组检验依次执行，后一组读取前一组重建的前沿序列。
6  """
7  from pathlib import Path
8  import argparse, hashlib, json
9  import numpy as np
10 import pandas as pd
11 from scipy.linalg import solve
12 from scipy.optimize import linprog, curve_fit, least_squares,
   brentq, minimize_scalar, minimize
13 from scipy.spatial.distance import cdist
14 from scipy.stats import spearmanr
15
16 def check_q1_q4(REPO, DATA, OUT):
17     report = {}
18     def digest(p): return hashlib.sha256(p.read_bytes()).
   hexdigest()
19     before = {str(p): digest(p) for p in (REPO/'求解').rglob('*')
   if p.is_file() and p.suffix in ('.csv', '.json')}
20
21     # Q1: evaluate the exact saved recommendation objective,
   without hyperparameter search.
22     a_dir = DATA/'A_data_value/regmix_tables'
23     mix = pd.read_csv(a_dir/'train_mixture_1m.csv').
   sort_values('index')
24     loss = pd.read_csv(a_dir/'train_pile_loss_1m.csv').
   sort_values('index')
25     assert np.array_equal(mix['index'], loss['index'])
26     mc = [c for c in mix if c.startswith('train_the_pile_')]
27     lc = [c for c in loss if c.endswith('_val_loss')]
28     domains = [c.removeprefix('train_the_pile_') for c in mc]

```

```

29     ld = [c.removeprefix('metric/the_pile_').removesuffix('
_val_loss') for c in lc]
30     xraw = mix[mc].to_numpy(float); x = xraw/xraw.sum(1,
keepdims=True); y = loss[lc].to_numpy(float)
31     rec = pd.read_csv(REP0/'求解/问题一/结果/线性有界配比对照.
csv').set_index('domain').loc[domains]
32     ref = rec.reference_mixture.to_numpy(); proposed = rec.
recommended_mixture.to_numpy()
33     assert np.allclose(ref,xraw.mean(0),atol=1e-14)
34     weights = ref[[domains.index(d) for d in ld]]; weights /=
weights.sum()
35     saved = pd.read_csv(REP0/'求解/问题一/结果/非线性代理对照_
预测明细.csv')
36     ranking = []
37     for (scope,model), rows in saved.groupby(['scope','model'
]):
38         obs = rows.pivot(index='index',columns='loss_domain',
values='observed')[ld]
39         pred = rows.pivot(index='index',columns='loss_domain',
values='predicted')[ld]
40         ov, pv = obs.to_numpy()@weights,pred.to_numpy()
@weights
41         pick = int(np.argmin(pv)); ranks=pd.Series(ov).rank(
method='min').to_numpy()
42         ranking.append(dict(scope=scope,model=model,n=len(ov),
spearman=float(spearmanr(ov,pv).statistic),
43                         selected_index=int(obs.index[pick
]),selected_observed_rank=int(ranks[pick]),
44                         selected_observed=float(ov[pick]),
best_observed=float(ov.min()),
45                         selection_regret=float(ov[pick]-ov
.min()))))
46     pd.DataFrame(ranking).to_csv(OUT/'
ql_same_objective_ranking.csv',index=False,encoding='utf-8-
sig')
47     manifest=json.loads((REP0/'求解/问题一/结果/非线性代理对照
_复现清单.json').read_text('utf-8-sig'))
48     g,l=manifest['selected_gamma'],manifest['selected_lambda']

```

```

49     kernel=lambda u,v:np.exp(-g*cdist(np.sqrt(u),np.sqrt(v), '
sqeuclidean'))
50     k=kernel(x,x);means=k.mean(0);grand=k.mean();kc=k-means[
None,:]-means[:,None]+grand
51     coef=solve(kc+l*np.eye(len(x)),y-y.mean(0),assume_a='pos')
52     def kpredict(v):
53         v=v/v.sum(1,keepdims=True); kv=kernel(v,x)
54         return (kv-kv.mean(1,keepdims=True)-means[None,:]+
grand)@coef+y.mean(0)
55     tm=pd.read_csv(a_dir/'test_mixture_lm.csv').sort_values('
index')
56     check=kpredict(tm[mc].to_numpy(float))
57     saved_k=saved[(saved.scope=='lm')&(saved.model=='sqrt_krr'
)].pivot(index='index',columns='loss_domain',values='
predicted')[ld]
58     assert np.array_equal(tm['index'],saved_k.index)
59     rebuild_error=float(np.max(np.abs(check-saved_k.to_numpy()
)))
60     A=pd.read_csv(REP0/'求解/问题一/结果/混合系数矩阵.csv').
set_index('training_domain').loc[domains,ld].to_numpy()
61     b=pd.read_csv(REP0/'求解/问题一/结果/截距.csv').set_index(
'loss_domain').loc[ld,'intercept'].to_numpy()
62     targets=np.stack([ref,proposed]); linear=(targets@A+b)
@weights; nonlinear=kpredict(targets)@weights
63     # Convex combination feasibility, then nearest Linf
distance as a numerical certificate.
64     hull={}
65     for name,target in [('reference_closed',ref/ref.sum()),('
recommended',proposed)]:
66         eq=np.vstack([x.T,np.ones(len(x))]);rhs=np.r_[target
,1]
67         fit=linprog(np.zeros(len(x)),A_eq=eq,b_eq=rhs,bounds
=(0,None),method='highs')
68         upper=np.vstack([np.column_stack([x.T,-np.ones(len(
domains))]),np.column_stack([-x.T,-np.ones(len(domains))])])
69         dist=linprog(np.r_[np.zeros(len(x)),1.],A_ub=upper,
b_ub=np.r_[target,-target],
70                 A_eq=np.array([np.r_[np.ones(len(x))

```

```

,0.]]),b_eq=[1.],bounds=(0,None),method='highs')
71     hull[name]=dict(feasible=bool(fit.success),status=int(
fit.status),minimum_linf_distance=float(dist.fun))
72     report['q1']=dict(weights=dict(zip(ld,weights)),
same_objective=ranking,krr_rebuild_max_abs_error=
rebuild_error,
73         reference_and_recommended=dict(linear=
linear.tolist(),sqrt_krr=nonlinear.tolist(),
74         linear_change=float(linear[1]-linear[0])
,krr_change=float(nonlinear[1]-nonlinear[0])),hull=hull)
75     # 同一上限与固定未观测领域下，检查正则改变对系数和配方的影
响。
76     measured = [domains.index(d) for d in ld]
77     fixed_idx = [i for i in range(len(domains)) if i not in
measured]
78     def fit_linear(alpha):
79         xc=xraw-xraw.mean(axis=0);yc=y-y.mean(axis=0)
80         co=solve(xc.T@xc+alpha*np.eye(xraw.shape[1]),xc.T@yc,
assume_a='pos')
81         return co,y.mean(axis=0)-xraw.mean(axis=0)@co
82     def recommend(co, intercept):
83         def build(z):
84             v=ref.copy();v[measured]=z
85             return v/v.sum()
86         # 等式约束使配方和为 1，目标为线性；用 LP 避免近乎平坦
目标的提前停止。
87         sol=linprog((co@weights)[measured],A_eq=np.ones((1,len
(measured))),
88             b_eq=[1-ref[fixed_idx].sum()],bounds
=[(0,2.5*ref[i]) for i in measured],method='highs')
89         if not sol.success:raise RuntimeError(sol.message)
90         mixture=build(sol.x)
91         return mixture,float((mixture@co+intercept)@weights)
92     co0,b0=fit_linear(.001);co1,b1=fit_linear(.1)
93     pp0,v0=recommend(co0,b0);pp1,v1=recommend(co1,b1)
94     cc0=co0-co0.mean(axis=0);cc1=co1-co1.mean(axis=0)
95     report['q1']['regularization']=dict(
centered_relative_change=float(np.linalg.norm(cc1-cc0)/np.

```

```

linalg.norm(cc0)),
96     sign_flips=int(np.sum(np.sign(cc1)!=np.sign(cc0))),
domains=domains,
97     mixture_lambda_001=pp0.tolist(),mixture_lambda_01=pp1.
tolist(),
98     objective_lambda_001=v0,objective_lambda_01=v1,
99     both_recipes_under_original_model=[float((v@co0+b0)
@weights) for v in [pp0,pp1]])
100     full=pd.read_csv(REPO/'求解/问题一/结果/质量域评分_全量.
csv')
101     sample=pd.read_csv(REPO/'求解/问题一/结果/质量域评分_抽样
与扩展.csv').query("source == 'A1'")
102     report['q1']['github_shares']=dict(full=float(full.loc[
full.domain.eq('github'),'n'].sum()/full.n.sum()),
103                                     A1=float(sample.loc[
sample.domain.eq('github'),'n'].sum()/sample.n.sum()))
104
105     # Q4: reconstruct filters, time encoding and frontier from
raw tables, no solver imports.
106     cdir=DATA/'C_efficiency_evolution';lb=pd.read_csv(cdir/'
leaderboard_cleaned.csv')
107     lb['P']=pd.to_numeric(lb['#Params (B)'],errors='coerce');
lb['date']=pd.to_datetime(lb['Submission Date'],errors='
coerce')
108     lb['Year']=lb.date.dt.year;lb['avg']=pd.to_numeric(lb['
Average \u2b06\ufe0f'],errors='coerce')
109     tasks=['IFEval','BBH','MATH Lvl 5','GPQA','MUSR','MMLU-PRO
']
110     lb[tasks]=lb[tasks].apply(pd.to_numeric,errors='coerce')
111     licenses={'apache-2.0','mit','gpl-3.0','cc-by-4.0','mpl
-2.0','bsd-3-clause','llama2','llama3','llama3.1','llama3.2'
,'llama3.3','gemma','cc-by-sa-4.0','openrail'}
112     lb=lb[lb[tasks].notna().all(axis=1)&lb.date.notna()&lb.P.
notna()&lb['Hub License'].astype(str).str.strip().str.lower
().isin(licenses)].copy()
113     lb['logP']=np.log10(lb.P);lb['t']=lb.Year-2019;lb=lb[lb.t.
between(0,12)].copy()
114     sample=lb.groupby('Model').Year.nunique();mean_dates=lb.

```

```

groupby('Year').date.mean()
115     def regress(t):
116         X=np.column_stack([np.ones(len(lb)),lb.logP,t]);coef=
np.linalg.lstsq(X,lb.avg,rcond=None)[0]
117         return dict(intercept=float(coef[0]),scale=float(coef
[1]),time=float(coef[2]),r2=float(1-((lb.avg-X@coef)**2).sum
())/((lb.avg-lb.avg.mean())**2).sum()))
118     annual=regress(lb.t);continuous=regress((lb.date-pd.
Timestamp('2019-01-01')).dt.total_seconds()/(365.25*86400))
119     ts=pd.read_csv(cdir/'leaderboard_extended_timeseries.csv')
120     ts['avg']=pd.to_numeric(ts.Average,errors='coerce');ts['P'
]=pd.to_numeric(ts.Params_B,errors='coerce')
121     six=['IFEval','BBH','MATH_Lvl5','GPQA','MUSR','MMLU_PRO'];
ts[six]=ts[six].apply(pd.to_numeric,errors='coerce')
122     ts=ts[((ts.avg-ts[six].mean(axis=1)).abs()<=5)&ts.P.notna
()&ts.avg.notna()&(ts.P>0)].copy()
123     fy=ts.groupby('Year').agg(avg=('avg','max'),P=('P','max'))
.reset_index();fy['cum_avg']=fy.avg.cummax()
124     monthly=lb.groupby(lb.date.dt.to_period('M')).avg.apply(
lambda z:z.nlargest(max(1,int(len(z)*.01))).mean())
125     monthly=monthly[monthly.index>=pd.Period('2024-01')]
126     mt=np.array([(p.year-2019)+(p.month-.5)/12 for p in
monthly.index]);hist=fy[fy.Year<=2023]
127     tf=np.r_[hist.Year.to_numpy()-2019+.5,mt];sf=np.r_[hist.
cum_avg.to_numpy(),np.maximum.accumulate(monthly.to_numpy())
]
128     idx=np.argsort(tf);tf=tf[idx];sf=np.maximum.accumulate(sf[
idx]);future=np.array([mt.max()+1,mt.max()+2])
129     def logistic(t,K,r,t0):return K/(1+np.exp(-r*(np.asarray(t
)-t0)))
130     def lfit(t,s):return curve_fit(logistic,t,s,p0
=[55,.8,3.5],bounds=([20,.01,.5],[100,5,8]),maxfev=40000)[0]
131     full=lfit(tf,sf);short=lfit(tf[:-3],sf[:-3])
132     split=2024-2019+(9-.5)/12;train=tf<=split;test=~train;hold
=lfit(tf[train],sf[train])
133     rmse=lambda a,b:float(np.sqrt(np.mean((a-b)**2)))
134     pd.DataFrame(dict(t=tf,score=sf,held_out=test)).to_csv(OUT
/'q4_reconstructed_frontier.csv',index=False,encoding='utf

```

```

-8-sig')
135     annual_models=[]
136     for year,group in ts.groupby('Year'):
137         peak=group.loc[group.avg.idxmax()];big=group.loc[group
.P.idxmax()]
138         annual_models.append(dict(year=int(year),
score_peak_model=peak.Model,score_peak=float(peak.avg),
score_peak_parameters=float(peak.P),max_size_model=big.Model
,max_size=float(big.P),max_size_model_score=float(big.avg)))
139     report['q4']=dict(records=len(lb),unique_model_names=int(
lb.Model.nunique()),names_across_years=int((sample>1).sum())
,
140         year_mean_dates={str(k):str(v) for k,v in mean_dates.
items()},mean_date_gap_years=float((mean_dates.iloc[-1]-
mean_dates.iloc[0]).total_seconds()/(365.25*86400)),
141         annual_label_regression=annual,
continuous_date_regression=continuous,
annual_frontier_subjects=annual_models,
142         frontier=dict(n=len(tf),historical_n=len(hist),
monthly_n=len(mt),peak_repeated_points=int((sf==sf.max()).
sum()),parameters=full.tolist(),prediction=logistic(future,*
full).tolist(),
143         truncated_last_3_parameters=short.tolist(),
truncated_last_3_prediction=logistic(future,*short).tolist()
,
144         holdout_cutoff='2024-09',holdout_n=int(test.sum()),
holdout_logistic_parameters=hold.tolist(),
145         holdout_logistic_rmse=rmse(logistic(tf[test],*hold),sf
[test]),holdout_persistence_rmse=rmse(np.full(test.sum()),sf[
train][-1]),sf[test]))
146     report['official_results_unchanged']=all(Path(p).exists()
and digest(Path(p))==v for p,v in before.items())
147     assert report['official_results_unchanged']
148     (OUT/'independent_q1_q4_results.json').write_text(json.
dumps(report,ensure_ascii=False,indent=2),encoding='utf-8')
149     return report
150
151

```

```

152 def check_q2_q3(REPO, DATA, OUT):
153     sha=lambda p:hashlib.sha256(p.read_bytes()).hexdigest()
154     before={str(p):sha(p) for p in (REPO/'求解').rglob('*') if
155         p.is_file() and p.suffix in ('.csv','.json')}
156     bdir=DATA/'B_scaling_laws';b1=pd.read_csv(bdir/'
pythia_training_log_existing.csv');b6=pd.read_csv(bdir/'
supplementary_NQ_experiment.csv')
157     p0=pd.read_csv(REPO/'求解/问题二/结果/经典标度律参数.csv')
        .iloc[0][['E','A','alpha','B','beta']].to_numpy(float)
158     p=pd.read_csv(REPO/'求解/广义标度律参数.csv').set_index('
param').loc[['E','A','alpha','B','beta','C','gamma'],'value'
        ].to_numpy(float)
159     classic=lambda p,N,D:p[0]+p[1]*N**(-p[2])+p[3]*D**(-p[4])
        general=lambda p,N,D,Q:classic(p[:5],N,D)+p[5]*np.maximum
        (1-Q,0)**p[6]
160     def metrics(y,yh):
161         e=np.asarray(yh)-np.asarray(y)
162         return dict(n=len(e),R2=float(1-(e*e).sum()/((y-np.
mean(y))**2).sum()),RMSE=float(np.sqrt(np.mean(e*e))),MAE=
float(np.mean(abs(e))),MAPE_percent=float(np.mean(abs(e)/abs
(y))*100))
163     N=np.r_[b1.N_params_B,b6.N_params_B];D=np.r_[b1.D_tokens_B
,b6.D_tokens_B];Q=np.r_[np.ones(len(b1)),b6.Q_score];Y=np.r_
[b1.val_loss,b6.val_loss]
164     errors=dict(classic_B1=metrics(b1.val_loss.to_numpy(),
classic(p0,b1.N_params_B.to_numpy(),b1.D_tokens_B.to_numpy()
)),general_B1_B6=metrics(Y,general(p,N,D,Q)))
165     groups=[]
166     for (n,d),g in b6.groupby(['N_params_B','D_tokens_B']):
167         low=g[np.isclose(g.Q_score,.1)];high=g[np.isclose(g.
Q_score,1)]
168         assert len(low)==len(high)==1
169         groups.append(dict(N=n,D=d,delta=float(low.val_loss.
iloc[0]-high.val_loss.iloc[0])))
170     groups=pd.DataFrame(groups);groups.to_csv(OUT/'
q2_fixed_ND_quality_gain.csv',index=False,encoding='utf-8-
sig')
171     gain=dict(groups=len(groups),min=float(groups.delta.min()))

```

```

,max=float(groups.delta.max()),spearman_with_N=float(
spearmanr(groups.N,groups.delta).statistic),
additive_model_gain=float(p[5]*(.9**p[6]))
172     # Fixed gamma=1 retains identical data, loss, bounds, and
six remaining parameters.
173     fixed=least_squares(lambda v:general(np.r_[v,1.],N,D,Q)-Y,
p[:6],bounds=([0,1e-8,.01,1e-8,.01,1e-8],[5,1e3,2,1e3,2,50])
,loss='soft_l1',f_scale=.05,max_nfev=80000)
174     pg=np.r_[fixed.x,1.]
175     soft=lambda e:float(.05**2*np.sum(np.sqrt(1+(e/.05)**2)-1)
)
176     base_cost=soft(general(p,N,D,Q)-Y);fixed_cost=soft(general
(pg,N,D,Q)-Y)
177     Q0=json.loads((REPO/'求解/问题一_关键量.json').read_text('
utf-8-sig'))['Q0_mix_weighted'];k=6+2e-4*2048
178     def optimum(budget,par):
179         E,A,a,B,b,C,g=par;bc=budget/1e18
180         def atq(q):
181             h=5*(q**4-Q0**4)
182             def deriv(logn):
183                 n=np.exp(logn)
184                 return -a*A*n**(-a-1)+b*B*bc**(-b)*k*(k*n+h)
185             ln=brentq(deriv,np.log(1e-4),np.log(1e6),xtol=1e
-13)
186             n=np.exp(ln);d=bc/(k*n+h)
187             return dict(Q=float(q),N_B=float(n),D_B=float(d),
loss=float(E+A*n**(-a)+B*d**(-b)+C*(1-q)**g))
188             grid=np.linspace(Q0,1,61);vals=[atq(q) for q in grid];
cand=[vals[0],vals[-1]]
189             for i in range(1,len(vals)-1):
190                 if vals[i]['loss']<=vals[i-1]['loss'] and vals[i]['
loss']<=vals[i+1]['loss']:
191                     sol=minimize_scalar(lambda q:atq(q)['loss'],
bounds=(grid[i-1],grid[i+1]),method='bounded',options={'
xatol':1e-13})
192                     cand.append(atq(sol.x))
193             return min(cand,key=lambda x:x['loss'])

```

```

194     sweep=pd.read_csv(REP0/'求解/问题三/结果/预算扫略.csv');
sat=sweep[sweep.Q>=1-1e-8].iloc[0];budget=float(sat.C)
195     base_sat=optimum(budget,p);fixed_sat=optimum(budget,pg)
196     base22=optimum(1e22,p)
197     mix=pd.read_csv(REP0/'求解/问题三/结果/配比项算力等价.csv'
);M=float(mix.loc[mix.mixture=='问题一有界推荐','M_p'].iloc
[0])
198     transfer=[]
199     for fraction in [0,.25,.5,.75,1]:
200         target=base22['loss']+fraction*M
201         root=brentq(lambda logc:optimum(np.exp(logc),p)['loss'
]-target,np.log(1e21),np.log(1e25),xtol=1e-11)
202         transfer.append(dict(retention=fraction,target_loss=
target,equivalent_budget=float(np.exp(root)),multiplier=
float(np.exp(root)/1e22)))
203     # C3 sample count uses the exact documented six-score
consistency filter.
204     ts=pd.read_csv(DATA/'C_efficiency_evolution/
leaderboard_extended_timeseries.csv');cols=['IFEval','BBH','
MATH_Lvl5','GPQA','MUSR','MMLU_PRO']
205     ts['avg']=pd.to_numeric(ts.Average,errors='coerce');ts['P'
]=pd.to_numeric(ts.Params_B,errors='coerce');ts[cols]=ts[
cols].apply(pd.to_numeric,errors='coerce')
206     mask=((ts.avg-ts[cols].mean(axis=1)).abs()<=5)&ts.P.notna
()&ts.avg.notna()&(ts.P>0)
207     c3=ts[mask].copy();X=np.column_stack([np.ones(len(c3)),np.
log10(c3.P),c3.Year-2019]);c=np.linalg.lstsq(X,c3.avg,rcond=
None)[0]
208     c3_summary=dict(raw_n=len(ts),retained_n=len(c3),
excluded_n=int((~mask).sum()),R2=float(1-((c3.avg-X@c)**2).
sum()/((c3.avg-c3.avg.mean())**2).sum()))
209     # Three cutoffs all evaluate their subsequent months
through the same last month.
210     front=pd.read_csv(OUT/'q4_reconstructed_frontier.csv');t=
front.t.to_numpy();s=front.score.to_numpy()
211     logistic=lambda t,K,r,t0:K/(1+np.exp(-r*(np.asarray(t)-t0)
))
212     cuts=[]

```

```

213     for month in [7,8,9]:
214         cutoff=5+(month-.5)/12;tr=t<=cutoff+1e-12;te=~tr
215         theta=curve_fit(logistic,t[tr],s[tr],p0=[55,.8,3.5],
bounds=([20,.01,.5],[100,5,8]),maxfev=40000)[0]
216         pred=logistic(t[te],*theta);baseline=np.full(te.sum(),
s[tr][-1]);rmse=lambda p:float(np.sqrt(np.mean((p-s[te])**2)
))
217         cuts.append(dict(cutoff=f'2024-{month:02}',train_n=int
(tr.sum()),test_n=int(te.sum()),test_end='2025-03',
parameters=theta.tolist(),
218                     logistic_RMSE=rmse(pred),
persistence_RMSE=rmse(baseline),test_time=t[te].tolist(),
test_observed=s[te].tolist(),logistic_prediction=pred.tolist
(),persistence_prediction=baseline.tolist()))
219     result=dict(error_metrics=errors,B6_quality_gain=gain,
gamma_fixed_one=dict(parameters=pg.tolist(),original_cost=
base_cost,fixed_cost=fixed_cost,
220                 cost_increase_percent=(fixed_cost/base_cost-1)*100,
original_first_saturation_budget=budget,original_saved_Q=
float(sat.Q),original_recomputed=base_sat,
fixed_gamma_recomputed=fixed_sat),
221     transfer_sensitivity=transfer,C3=c3_summary,
Q4_time_holdouts=cuts,official_results_unchanged=all(Path(f)
.exists() and sha(Path(f))==v for f,v in before.items()))
222     # 保持 A 侧费用不变，只改变未知的 A -> B 质量映射；不是纯
坐标替换。
223     E,A,a,B,b,C,g=p
224     mapping=[]
225     for power in [.5,1.,2.]:
226         def local_derivative(logbudget):
227             bc=np.exp(logbudget)/1e18
228             n=(a*A/(b*B)*(bc/k)**b)**(1/(a+b));d=bc/(k*n)
229             return b*B*d**(-b)*20*Q0**3/(k*n)-C*g*(1-Q0**power
)**(g-1)*power*Q0**(power-1)
230         boundary=np.exp(brentq(local_derivative,np.log(1e17),
np.log(1e22)))
231         mapping.append(dict(power=power,local_start_budget=
float(boundary)))

```

```

232     result['quality_mapping_local_sensitivity']=mapping
233     assert result['official_results_unchanged']
234     (OUT/'independent_q23_and_timecuts_results.json').
write_text(json.dumps(result,ensure_ascii=False,indent=2),
encoding='utf-8')
235     return result
236
237
238 def main():
239     repo = Path(__file__).resolve().parents[1]
240     ap = argparse.ArgumentParser(description=__doc__)
241     ap.add_argument('--data-dir', type=Path, required=True)
242     ap.add_argument('--out', type=Path, default=repo/'复现记录
/补充检验')
243     args = ap.parse_args()
244     data = args.data_dir.resolve()
245     out = args.out.resolve()
246     if out.is_relative_to(repo/'求解') or out.is_relative_to(
data):
247         raise ValueError('诊断输出目录不得位于正式求解或附件目
录内')
248     out.mkdir(parents=True, exist_ok=True)
249     first = check_q1_q4(repo, data, out)
250     second = check_q2_q3(repo, data, out)
251     print(json.dumps({'output': str(out), '
q1_krr_rebuild_error': first['q1']['
krr_rebuild_max_abs_error'],
252                     'C3_retained_n': second['C3']['retained_n
'], 'official_results_unchanged':
253                     first['official_results_unchanged'] and
second['official_results_unchanged']},
254                     ensure_ascii=False, indent=2))
255
256
257 if __name__ == '__main__':
258     main()

```

Listing 6: 决策、质量结构与时间外推补充检验（求解/补充检验.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  # 公共代码模板：求解/_common.py（系统自动播种，每个任务只写一
    次，不要覆写覆盖函数）
4  import sys, os
5  try:
6      sys.stdout.reconfigure(encoding='utf-8', errors='replace')
7      sys.stderr.reconfigure(encoding='utf-8', errors='replace')
8  except Exception:
9      pass
10 # 问题目录 = 运行脚本所在目录（兼容 cd 求解/问题X 与 求解/ 根
    运行两种方式）
11 _script_dir = os.path.dirname(os.path.abspath(sys.argv[0]))
12 # 在 Jupyter / ipykernel 下 sys.argv[0] 指向内核启动脚本，须改
    用工作目录（notebook 所在目录）
13 if 'ipykernel' in sys.modules or 'ipykernel_launcher' in os.
    path.basename(sys.argv[0]):
14     _script_dir = os.getcwd()
15 if not _script_dir or not os.path.isdir(_script_dir):
16     _script_dir = os.getcwd()
17 BASE_DIR = _script_dir
18
19 import pandas as pd
20 import numpy as np
21 import matplotlib
22 matplotlib.use('Agg')
23 import matplotlib.pyplot as plt
24 import matplotlib.font_manager as _fm
25 import warnings, logging
26 warnings.filterwarnings('ignore')
27 logging.getLogger('matplotlib').setLevel(logging.ERROR) # 抑
    制findfont警告
28 logging.getLogger('matplotlib.font_manager').setLevel(logging.
    ERROR) # 抑制字体管理器警告
29

```

```

30 # ★ 统一绘图类导入中枢：一次性提供常用 matplotlib 类/子模块，
31 # 使脚本只写 `from _common import *` 即可直接用，无需各自重
    复 import（防止遗漏导致 NameError）。
32 import matplotlib.ticker as mticker
33 import scipy.stats as stats
34 from matplotlib.patches import (Rectangle, FancyBboxPatch,
    FancyArrowPatch, FancyArrow,
35                                Circle, RegularPolygon,
    Ellipse, Wedge, Polygon, Arrow, Arc)
36 from matplotlib.collections import PatchCollection,
    LineCollection, PolyCollection
37 from matplotlib.path import Path
38 from matplotlib.spines import Spine
39 try:
40     from matplotlib.projections.polar import PolarAxes
41     from matplotlib.projections import register_projection
42     from mpl_toolkits.axes_grid1.inset_locator import
    inset_axes, mark_inset
43 except Exception:
44     pass
45
46 # 字体：仅首次运行时重建缓存（marker 防止每次都全量扫描字体拖
    慢）
47 def _find_font_dir():
48     starts = [BASE_DIR, os.getcwd()]
49     for start in starts:
50         d = start
51         for _ in range(6):
52             candidate = os.path.join(d, 'fonts')
53             if os.path.isdir(candidate) and os.path.isfile(os.
    path.join(candidate, 'SourceHanSerifCN-Regular.otf')):
54                 return candidate
55             parent = os.path.dirname(d)
56             if parent == d: break
57             d = parent
58     return None
59 _SOLVE_DIR = os.path.dirname(BASE_DIR)
60 # 求解/ 根目录（脚本所在 问题X 的上一级），跨问题共享中间文件

```

统一放这里

```
61 SOLVE_DIR = _SOLVE_DIR
62 _FONT_MARKER = os.path.join(_SOLVE_DIR, '_fonts_ready')
63 if not os.path.exists(_FONT_MARKER):
64     try:
65         import glob as _glb
66         for _fc in _glb.glob(os.path.join(matplotlib.
get_cachedir(), 'font*')):
67             try: os.remove(_fc)
68             except: pass
69         _fm._load_fontmanager(try_read_cache=False)
70         open(_FONT_MARKER, 'w').close()
71     except Exception:
72         pass
73 _FONT_DIR = _find_font_dir()
74 if _FONT_DIR:
75     for _f in ['SourceHanSerifCN-Regular.otf', '
SourceHanSerifCN-Bold.otf']:
76         _p = os.path.join(_FONT_DIR, _f)
77         if os.path.exists(_p): _fm.fontManager.addfont(_p)
78 _SYS_FONT = os.path.join(os.environ.get('WINDIR', 'C:\\Windows
'), 'Fonts')
79 for _f in ['times.ttf', 'timesbd.ttf', 'timesi.ttf', 'simsun.
ttc']:
80     _p = os.path.join(_SYS_FONT, _f)
81     if os.path.exists(_p): _fm.fontManager.addfont(_p)
82 plt.rcParams['font.family'] = ['Times New Roman', 'Source Han
Serif CN', 'SimSun', 'serif']
83 plt.rcParams['font.weight'] = 'normal'
84 plt.rcParams['axes.unicode_minus'] = False
85 plt.rcParams['figure.dpi'] = 150
86 plt.rcParams['savefig.dpi'] = 220
87 plt.rcParams['savefig.bbox'] = 'tight'
88 plt.rcParams['pdf.fonttype'] = 42
89
90 # ★ 兼容层: monkey-patch 旧 API, 防止 agent 用 plt.cm.get_cmap
() 报错
91 if not hasattr(matplotlib.cm, 'get_cmap'):
```

```

92     matplotlib.cm.get_cmap = lambda name, n=None: plt.
        colormaps[name].resampled(n) if n else plt.colormaps[name]
93 try:
94     from mpl_toolkits.mplot3d import Axes3D as _Axes3D
95 except ImportError:
96     pass
97
98 FIG_DIR = os.path.join(BASE_DIR, '图片')
99 OUT_DIR = os.path.join(BASE_DIR, '结果')
100 os.makedirs(FIG_DIR, exist_ok=True)
101 os.makedirs(OUT_DIR, exist_ok=True)
102
103 # ★ 数据目录：兼容工程内“数据/”与赛题目录中的
    real_attachments/。
104 _project_root = os.path.normpath(os.path.join(BASE_DIR, '..',
    '..'))
105 _data_candidates = ([os.environ['MODELING_DATA_DIR']] if os.
    environ.get('MODELING_DATA_DIR') else []) + [
106     os.path.join(_project_root, '数据'),
107     os.path.join(_project_root, 'real_attachments'),
108 ]
109 from pathlib import Path as _Path
110 _data_candidates += [str(p / 'real_attachments') for p in
    _Path(BASE_DIR).parents]
111 DATA_DIR = next((p for p in _data_candidates if os.path.isdir(
    p)), _data_candidates[0])
112 _DATA_INDEX = None
113
114 def data_path(name):
115     """按文件名定位附件；既支持平铺数据目录，也支持 A/B/C 分目
    录。"""
116     direct = os.path.join(DATA_DIR, name)
117     if os.path.exists(direct):
118         return direct
119     global _DATA_INDEX
120     if _DATA_INDEX is None:
121         _DATA_INDEX = {}
122         for root, _, files in os.walk(DATA_DIR):

```

```

123         for fn in files:
124             _DATA_INDEX.setdefault(fn.lower(), os.path.
join(root, fn))
125         key = os.path.basename(name).lower()
126         if key not in _DATA_INDEX and key.endswith('.jsonl') and
key + '.xz' in _DATA_INDEX:
127             key += '.xz'
128         if key not in _DATA_INDEX:
129             raise FileNotFoundError(f'附件中未找到数据文件: {name}
(根目录 {DATA_DIR}) ')
130         return _DATA_INDEX[key]
131
132 def despine(ax):
133     """只保留左侧和底侧边框，移除上侧和右侧"""
134     ax.spines['top'].set_visible(False)
135     ax.spines['right'].set_visible(False)
136
137 def save_fig(fig, name_cn, dpi=300):
138     """保存单张图片，自动加.png后缀（默认 300dpi 高清）"""
139     path = os.path.join(FIG_DIR, name_cn + '.png')
140     fig.savefig(path, dpi=dpi, bbox_inches='tight', facecolor=
'white')
141     plt.close(fig)
142     print(f' 已保存: {name_cn}.png')
143
144 def save_dual(fig, name_cn, dpi=300, bw=False):
145     """保存图片（默认 300dpi 高清）。绘图规则只输出全彩，默认
不再生成黑白版（bw=False，仅保存彩色）。
146     如需临时验证黑白效果可手动传 bw=True，但最终产出图一律不得
黑白。"""
147     from PIL import Image, ImageOps
148     color_path = os.path.join(FIG_DIR, name_cn + '.png')
149     fig.savefig(color_path, dpi=dpi, bbox_inches='tight',
facecolor='white')
150     print(f' 已保存: {name_cn}.png')
151     if bw:
152         bw_path = os.path.join(FIG_DIR, name_cn + '_bw.png')
153         try:

```

```

154         img = Image.open(color_path)
155         img_gray = ImageOps.grayscale(img)
156         img_gray.save(bw_path)
157         img.close()
158     except Exception:
159         fig.savefig(bw_path, dpi=dpi, bbox_inches='tight',
160                     facecolor='white')
161         print(f' 已保存: {name_cn}_bw.png')
162         print(f' ★ 双版本完成: {name_cn}')
163     plt.close(fig)
164
165 def save_csv(df, name_cn):
166     df.to_csv(OUT_DIR + '/' + name_cn, index=False, encoding='
167     utf-8-sig')
168
169 def shared_path(name):
170     """跨问题共享中间文件的统一路径（存到 求解/ 根，供各问题脚
171     本互相读取）。
172     例：问题一存 shared_path('预处理数据.csv')，问题二用 pd.
173     read_csv(shared_path('预处理数据.csv')) 读取。"""
174     return os.path.join(SOLVE_DIR, name)
175
176 def is_ax_empty(ax):
177     """检测坐标轴是否无数据（空图）"""
178     return (len(ax.lines) == 0 and len(ax.collections) == 0
179             and len(ax.patches) == 0 and len(ax.images) == 0)
180
181 def is_flat_line(x, y):
182     """折线是否为直线（完全无变化→不画）：所有y相同或所有x相同
183     """
184     if x is None or y is None or len(x) < 2 or len(y) < 2:
185         return False
186     y_arr = np.asarray(y, dtype=float)
187     x_arr = np.asarray(x, dtype=float)
188     y_flat = np.allclose(y_arr, y_arr[0])
189     x_flat = np.allclose(x_arr, x_arr[0])
190     return y_flat or x_flat

```

```

187 def validate_subplots(nrows, ncols):
188     """
189     子图布局校验，不合法返回错误原因字符串，合法返回None。
190     规则（硬性）：单图1×1；一行多列1×N(N≥2)；两行2×N且N≥4；其
        余禁止。
191     禁止：三行及以上；两行列数≤3；2×2四宫格。
192     """
193     if nrows >= 3:
194         return f"禁止超过两行（{nrows}行），行列最多两行"
195     if nrows == 2 and ncols <= 3:
196         return f"两行列数必须>3（当前{ncols}列），换2×{max(4,
        ncols)}或改单行布局"
197     return None
198
199 def get_colors(cmap_name, n):
200     """安全获取colormap的n个颜色（替代plt.cm.get_cmap，已废弃
        会报错）。"""
201     cmap = plt.colormaps[cmap_name].resampled(n)
202     return [cmap(i) for i in range(n)]
203
204 def safe_cmap(cmap_name):
205     """安全获取colormap对象（不带resampled）。"""
206     return plt.colormaps[cmap_name]
207
208 def safe_boxplot(ax, data, labels, **kwargs):
209     """安全的boxplot（替代ax.boxplot(labels=...），labels参数已
        废弃会报错）。
210     内部强制 patch_artist=True，使 boxes 为 Patch 对象，AI 可
        直接用 bp['boxes'][i].set_facecolor(...) 填色；
211     否则 boxes 是 Line2D，set_facecolor 会抛 AttributeError。
        """
212     kwargs.setdefault('patch_artist', True)
213     bp = ax.boxplot(data, **kwargs)
214     ax.set_xticklabels(labels, fontsize=11)
215     return bp
216
217 def safe_heatmap(ax, data, row_labels=None, col_labels=None,
        cmap='RdBu_r',

```

```

218         linewidth=0.3, edgecolor='black', fontsize
=11, **kwargs):
219     """
220     强制带黑色细边框的热力图（替代裸 imshow/heatmap 的纯色
块）。
221     用 pcolormesh 绘制，每个格子边线统一为黑色细框（edgecolor=
black, linewidth=linewidth），
222     避免"色块连成一片"的观感。NaN 单元格填白色。默认 vmin/vmax
取数据范围。
223     用法：
224         safe_heatmap(ax, corr.values, row_labels=corr.index,
col_labels=corr.columns, cmap='RdBu_r')
225     返回 pcolormesh 的 QuadMesh（可用其 .set_clim 调色标范
围）。
226     """
227     data = np.asarray(data, dtype=float)
228     rows, cols = data.shape
229     cmap_obj = plt.colormaps[cmap]
230     cmap_obj.set_bad(color='#FFFFFF')          # NaN 为白，避
免黑洞
231     mesh = ax.pcolormesh(np.ma.masked_invalid(data), cmap=
cmap_obj,
232                           edgecolors=edgecolor, linewidth=
linewidth, **kwargs)
233     if row_labels is not None:
234         ax.set_yticks(np.arange(rows) + 0.5)
235         ax.set_yticklabels(list(row_labels), fontsize=fontsize
)
236     if col_labels is not None:
237         ax.set_xticks(np.arange(cols) + 0.5)
238         ax.set_xticklabels(list(col_labels), rotation=45, ha='
right',
239                           rotation_mode='anchor', fontsize=
fontsize)
240     ax.set_xlim(0, cols)
241     ax.set_ylim(0, rows)
242     ax.set_aspect('auto')
243     return mesh

```

```

244
245 def png_wh(png_path):
246     """读取PNG实际宽高（字节，读16-24字节IHDR）"""
247     import struct
248     with open(png_path, 'rb') as f:
249         f.read(16)
250         w, h = struct.unpack('>II', f.read(8))
251     return w, h
252
253 def latex_includegraphics(png_path, caption, label, pair=False
, float_pos='ht'):
254     r"""
255     按高宽比生成匹配档位的 \includegraphics LaTeX 片段（直接粘
论文）。
256     pair=True: 同一张figure里两张并排minipage，给半宽。
float_pos默认'ht'，禁止'H'锁死。
257     """
258     if float_pos.upper() == 'H':
259         raise ValueError("float_pos禁止'H'强制定位，默认用'ht'
允许浮动")
260     w, h = png_wh(png_path)
261     aspect = h / w
262     if pair:
263         width = '0.48\\textwidth'
264     elif aspect >= 0.9:
265         width = '0.60\\textwidth'
266     elif aspect >= 0.6:
267         width = '0.65\\textwidth'
268     else:
269         width = '0.70\\textwidth'
270     rel = png_path.replace('\\', '/')
271     return (
272         f"\\begin{{figure}}[{{float_pos}}]\n"
273         f"    \\centering\n"
274         f"    \\includegraphics[width={{width}}]{{{rel}}}\n"
275         f"    \\caption{{{caption}}}\n"
276         f"    \\label{{fig:{{label}}}}\n"
277         f"\\end{{figure}}")

```

```

278     )
279
280 # ★ 数据清洗辅助（避免 "--" 等非数值导致 min/max/idxmax 报错）
281 def numeric_clean(s, default=None):
282     """将列安全转为数值：非数值元素→NaN；default 不为 None 时
    用 default 填充NaN。
283     用法：df['评分'] = numeric_clean(df['评分'])    # 先转数值
    (NaN保留)
284     df['评分'] = numeric_clean(df['评分'], default=0.0)
    # 转数值并填0"""
285     s = pd.to_numeric(s, errors='coerce')
286     if default is not None:
287         s = s.fillna(default)
288     return s
289
290 def safe_idxmax(s, default_idx=None):
291     """安全的 idxmax：空序列/全NA 返回 default_idx，否则返回最
    大值索引。"""
292     s = pd.to_numeric(s, errors='coerce')
293     s = s.dropna()
294     if s.empty:
295         return default_idx
296     return s.idxmax()
297
298 def safe_idxmin(s, default_idx=None):
299     """安全的 idxmin：空序列/全NA 返回 default_idx，否则返回最
    小值索引。"""
300     s = pd.to_numeric(s, errors='coerce')
301     s = s.dropna()
302     if s.empty:
303         return default_idx
304     return s.idxmin()
305
306 def has_na(df):
307     """检测DataFrame是否含NaN/空值（用于空值防线）。"""
308     return bool(df.isna().any().any())

```

Listing 7: 公共数据与绘图模块（求解/_common.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
   # 构：OpenAI；版本发布日期：2026-07-09。
2  # -*- coding: utf-8 -*-
3  # 本程序的实现、验证与说明由 OpenAI Codex (GPT-5.6-Luna) 辅助
   # 完成。
4  """同尺度配比预测：既有线性岭基线与平方根嵌入核岭。
5
6  python 求解/问题一/非线性代理对照.py --data-dir <附件根目录>
7  只写“非线性代理对照_*”结果，不写任何跨问接口。绘图另由重绘图
   # 表.py执行。
8  核岭采用闭合配方、训练核中心化、未惩罚截距；全部超参数只用训练
   # 五折选择。
9  CV最小值是调参得分，不是嵌套CV泛化估计；既有检验集不是新的盲测
   # 集。
10 """
11 from pathlib import Path
12 import argparse
13 import hashlib
14 import json
15 import platform
16 import sys
17 import time
18 import importlib.metadata
19
20 import numpy as np
21 import pandas as pd
22 from scipy.linalg import eigh, solve
23 from scipy.spatial.distance import cdist
24 from scipy.stats import spearmanr
25 from sklearn.model_selection import KFold
26
27 HERE = Path(__file__).resolve().parent
28 SEED = 20260926
29 LAMBDA_S = 10.0 ** np.arange(-6, 3)
30 GAMMA_S = 2.0 ** np.arange(-6, 3)
31
32

```

```

33 def find_data(path=None):
34     candidates = [Path(path)] if path else [p / '
real_attachments' for p in HERE.parents]
35     for p in candidates:
36         if (p / 'A_data_value/regmix_tables').is_dir():
37             return p.resolve()
38     raise FileNotFoundError('请用 --data-dir 指定包含
A_data_value 的附件根目录')
39
40
41 def load_pair(root, split, scale):
42     folder = root / 'A_data_value/regmix_tables'
43     paths = [folder / f'{split}_mixture_{scale}.csv',
44             folder / f'{split}_pile_loss_{scale}.csv']
45     mix, loss = [pd.read_csv(p).sort_values('index').
reset_index(drop=True) for p in paths]
46     if mix['index'].duplicated().any() or loss['index'].
duplicated().any():
47         raise ValueError('配方或损失存在重复 index')
48     if not np.array_equal(mix['index'].values, loss['index'].
values):
49         raise ValueError('配方与损失 index 不匹配')
50     mc = [c for c in mix if c.startswith('train_the_pile_')]
51     lc = [c for c in loss if c.endswith('_val_loss')]
52     x, y = mix[mc].to_numpy(float), loss[lc].to_numpy(float)
53     if not (np.isfinite(x).all() and np.isfinite(y).all() and
(x >= 0).all()
54             and (x.sum(1) > 0).all()):
55         raise ValueError('非有限值、负配比或零行和')
56     domains = [c.replace('metric/the_pile_', '').replace('
_val_loss', '') for c in lc]
57     return x, y, mix['index'].values, mc, domains, paths
58
59
60 def closed(x):
61     return x / x.sum(axis=1, keepdims=True)
62
63

```

```

64 def ridge_predict(x, y, v, alpha=1e-3):
65     # 与问题一.py完全相同: 17个原始份额, 截距不受惩罚。
66     a = np.column_stack([x, np.ones(len(x))])
67     penalty = alpha * np.eye(a.shape[1])
68     penalty[-1, -1] = 0
69     w = np.linalg.solve(a.T @ a + penalty, a.T @ y)
70     return np.column_stack([v, np.ones(len(v))]) @ w
71
72
73 def kernel(x, v, gamma):
74     return np.exp(-gamma * cdist(np.sqrt(x), np.sqrt(v), '
sqeuclidean'))
75
76
77 def centered_kernel(k):
78     means, grand = k.mean(axis=0), float(k.mean())
79     return k - means[None, :] - means[:, None] + grand, means,
grand
80
81
82 def cross_center(k, means, grand):
83     return k - k.mean(axis=1, keepdims=True) - means[None, :]
+ grand
84
85
86 def krr_predict(x, y, v, gamma, lam):
87     kc, means, grand = centered_kernel(kernel(x, x, gamma))
88     ym = y.mean(0)
89     coef = solve(kc + lam * np.eye(len(x)), y - ym, assume_a='
pos')
90     return cross_center(kernel(v, x, gamma), means, grand) @
coef + ym
91
92
93 def metrics(y, pred):
94     err = y - pred
95     r2 = 1 - (err**2).sum(0) / np.maximum(((y - y.mean(0))**2)
.sum(0), 1e-12)

```

```

96     rho = np.array([spearmanr(y[:, j], pred[:, j]).statistic
for j in range(y.shape[1])])
97     rmse = np.sqrt((err**2).mean(0))
98     mae = np.abs(err).mean(0)
99     overall = dict(R2_mean=float(r2.mean()),
Spearman_domain_mean=float(rho.mean()),
100                    RMSE_pooled=float(np.sqrt((err**2).mean()))
,
101                    RMSE_domain_mean=float(rmse.mean()), MAE=
float(mae.mean()),
102                    RMSE_recipe_mean=float(np.sqrt(((y.mean(1)
- pred.mean(1))**2).mean()))),
103                    Spearman_recipe_mean=float(spearmanr(y.mean
(1), pred.mean(1)).statistic))
104     return overall, dict(R2=r2, Spearman=rho, RMSE=rmse, MAE=
mae)
105
106
107 def cv_search(xraw, y, folds, gammas=GAMMAS, lambdas=LAMBDA):
108     x = closed(xraw)
109     oof_ridge = np.empty_like(y)
110     squared = np.zeros((len(gammas), len(lambdas)))
111     fold_rows = []
112     for fold, (tr, va) in enumerate(folds, 1):
113         oof_ridge[va] = ridge_predict(xraw[tr], y[tr], xraw[va
])
114         for g, gamma in enumerate(gammas):
115             kc, means, grand = centered_kernel(kernel(x[tr], x
[tr], gamma))
116             eig, vectors = eigh(kc)
117             if eig.min() < -1e-9:
118                 raise ValueError('中心化核出现显著负特征值')
119             eig = np.maximum(eig, 0)
120             ym = y[tr].mean(0)
121             rotated = vectors.T @ (y[tr] - ym)
122             projection = cross_center(kernel(x[va], x[tr],
gamma), means, grand) @ vectors
123             for a, lam in enumerate(lambdas):

```

```

124         pred = projection @ (rotated / (eig[:, None] +
125         lam)) + ym
126         sse = float(((y[va] - pred)**2).sum())
127         squared[g, a] += sse
128         fold_rows.append(dict(fold=fold, n_valid=len(
129         va), gamma=gamma, lambda_=lam,
130         SSE=sse, RMSE=np.sqrt(
131         sse / y[va].size)))
132         print(f'五折选择: {fold}/{len(folds)}', flush=True)
133         scores = np.sqrt(squared / y.size)
134         g, a = np.unravel_index(scores.argmin(), scores.shape)
135         gamma, lam = float(gammas[g]), float(lambdas[a])
136         oof_krr = np.empty_like(y)
137         for tr, va in folds:
138             oof_krr[va] = krr_predict(x[tr], y[tr], x[va], gamma,
139             lam)
140         grid = [dict(gamma=float(gammas[g]), lambda_=float(lambdas
141         [a]), CV_RMSE=float(scores[g, a]))
142             for g in range(len(gammas)) for a in range(len(
143             lambdas))]
144         return gamma, lam, oof_ridge, oof_krr, pd.DataFrame(grid),
145         pd.DataFrame(fold_rows)
146
147 def self_check(data_root):
148     # 与增广核方程独立比较, 检验训练/预测中心化及不惩罚截距。
149     raw, y, _, _, _ = load_pair(data_root, 'train', 'lm')
150     x = closed(raw[:32]); v = closed(raw[32:40]); y = y[:32]
151     gamma, lam = .125, .01
152     k = kernel(x, x, gamma)
153     augmented = np.block([[k + lam*np.eye(len(x)), np.ones((
154     len(x), 1))],
155         [np.ones((1, len(x))), np.zeros((1,
156         1))]])
157     rhs = np.vstack([y, np.zeros((1, y.shape[1]))])
158     solution = np.linalg.solve(augmented, rhs)
159     reference = kernel(v, x, gamma) @ solution[:-1] + solution
160     [-1]

```

```

152     actual = krr_predict(x, y, v, gamma, lam)
153     np.testing.assert_allclose(actual, reference, atol=1e-9,
154                                rtol=1e-9)
154     np.testing.assert_allclose(krr_predict(x, y+7, v, gamma,
155                                lam), actual+7, atol=1e-9)
155     folds = list(KFold(2, shuffle=True, random_state=SEED).
156                  split(raw[:40]))
156     cv_search(raw[:40], load_pair(data_root, 'train', 'lm')
157              [1][:40], folds,
158              gammas=np.array([.125]), lambdas=np.array([.01])
159              )
158     print(f'最小核验通过; 增广方程最大偏差 {abs(actual-
159            reference).max():.3g}')
160
161 def main():
162     ap = argparse.ArgumentParser(description=__doc__)
163     ap.add_argument('--data-dir', type=Path)
164     ap.add_argument('--output-dir', type=Path, default=HERE/'
165            结果')
166     ap.add_argument('--self-check', action='store_true')
167     args = ap.parse_args(); root = find_data(args.data_dir)
168     if args.self_check:
169         self_check(root); return
170     start = time.monotonic()
171     raw, y, indices, columns, domains, inputs = load_pair(root
172            , 'train', 'lm')
173     x = closed(raw)
174     if len(np.unique(x, axis=0)) != len(x):
175         raise ValueError('重复配方需采用分组交叉验证')
176     folds = list(KFold(5, shuffle=True, random_state=SEED).
177                  split(x))
178     gamma, lam, cv_r, cv_k, grid, foldscores = cv_search(raw,
179            y, folds)
180     fold_ids = np.empty(len(y), int)
181     for fold, (_, va) in enumerate(folds, 1): fold_ids[va] =
182            fold
183     summary, detail, predictions = [], [], []

```

```

179
180     def record(scope, idx, obs, preds):
181         for model, pred in preds.items():
182             overall, per_domain = metrics(obs, pred)
183             summary.append(dict(scope=scope, model=model, n=
184 len(obs), **overall))
185             for j, domain in enumerate(domains):
186                 detail.append(dict(scope=scope, model=model,
187 loss_domain=domain,
188                                     **{key: float(val[j]) for
189 key, val in per_domain.items()}))
190                 predictions.append(pd.DataFrame(dict(scope=
191 scope, model=model, index=idx,
192 loss_domain=domain, observed=obs[:, j],
193 predicted=pred[:, j])))
194     record('train_oof', indices, y, dict(ridge=cv_r, sqrt_krr=
195 cv_k))
196     profiles = [dict(scope='train', n=len(raw), min_share=
197 float(raw.min()),
198                 max_row_sum_error=float(abs(raw.sum(1)-1)
199 .max()))]
200     for scale in ['1m', '60m', '1B']:
201         test, obs, idx, mc, ds, paths = load_pair(root, 'test'
, scale)
202         if mc != columns or ds != domains: raise ValueError('
203 跨文件字段顺序不一致')
204         inputs += paths
205         record(scale, idx, obs, dict(ridge=ridge_predict(raw,
206 y, test),
207                                     sqrt_krr=krr_predict(x, y,
208 closed(test), gamma, lam)))
209         profiles.append(dict(scope=scale, n=len(test),
210 min_share=float(test.min()),
211                 max_row_sum_error=float(abs(test.
212 sum(1)-1).max()))))
213     out = args.output_dir; out.mkdir(parents=True, exist_ok=
214 True)
215     tables = dict(汇总=pd.DataFrame(summary), 逐域=pd.

```

```

DataFrame(detail),
202         预测明细=pd.concat(predictions, ignore_index
= True), 参数搜索=grid,
203         五折=foldscores, 折分配=pd.DataFrame(dict(
index=indices, fold=fold_ids)))
204     for name, table in tables.items():
205         table.to_csv(out/f'非线性代理对照_{name}.csv', index=
False, encoding='utf-8-sig')
206     manifest = dict(seed=SEED, n_train=len(y), n_domains=len(
domains), selected_gamma=gamma,
207         selected_lambda=lam, baseline_lambda=.001,
profiles=profiles,
208         lambda_grid=LAMBDA_S.tolist(), gamma_grid=
GAMMA_S.tolist(),
209         selection='minimum pooled out-of-fold RMSE
; not nested CV',
210         preprocessing='KRR: row closure, sqrt,
fold-local kernel/output centering; ridge: original shares',
211         test_status='previously inspected existing
test sets; not a fresh blind holdout',
212         python=platform.python_version(),
213         packages={p: importlib.metadata.version(p)
for p in ['numpy', 'pandas', 'scipy', 'scikit-learn']},
214         inputs={str(p.relative_to(root)): hashlib.
sha256(p.read_bytes()).hexdigest() for p in inputs},
215         script_sha256=hashlib.sha256(Path(__file__
).read_bytes()).hexdigest(),
216         command='python 求解/问题一/非线性代理对照
.py --data-dir <附件根目录>',
217         elapsed_seconds=time.monotonic()-start,
shared_outputs_modified=False)
219     (out/'非线性代理对照_复现清单.json').write_text(json.dumps
(manifest, ensure_ascii=False, indent=2), encoding='utf-8')
220     print(f'选择 gamma={gamma}, lambda={lam}')
221     print(tables['汇总'].to_string(index=False))
222
223
224 if __name__ == '__main__':

```

```

225     if hasattr(sys.stdout, 'reconfigure'): sys.stdout.
reconfigure(encoding='utf-8')
226     main()

```

Listing 8: 问题一核岭预测与交叉验证（求解/问题一/非线性代理对照.py）

```

1  # 本程序使用 OpenAI Codex 辅助实现与数值核对。
2  # 用途：沿用已选核岭，以训练配方凸组合限制推荐范围；不重新搜索
   超参数。
3  """python 求解/问题一/核岭支持域推荐.py --data-dir <附件根目录
   >
4  推荐写入原结果目录；--output-dir 可用于隔离核验。
5  """
6  from pathlib import Path
7  import argparse
8  import json
9  import numpy as np
10 import pandas as pd
11 from scipy.linalg import solve
12 from scipy.optimize import linprog, minimize
13 from 非线性代理对照 import find_data, load_pair, closed,
   kernel, krr_predict
14
15 HERE=Path(__file__).resolve().parent
16
17
18 def recommend(data, result_dir, output_dir):
19     raw,y,indices,columns,loss_domains,_=load_pair(data,'train
   ','1m')
20     domains=[s.removeprefix('train_the_pile_') for s in
   columns]
21     x=closed(raw);ref=raw.mean(axis=0);ref=ref/ref.sum()
22     measured=[domains.index(d) for d in loss_domains]
23     fixed=[i for i in range(len(domains)) if i not in measured
   ]
24     weights=ref[measured];weights=weights/weights.sum()
25     config=json.loads((result_dir/'非线性代理对照_复现清单.
   json').read_text('utf-8-sig'))
26     gamma,lam=config['selected_gamma'],config['selected_lambda

```

```

']
27     k=kernel(x,x,gamma);means=k.mean(axis=0);grand=k.mean()
28     kc=k-means[None,:]-means[:,None]+grand
29     beta=solve(kc+lam*np.eye(len(x)),y-y.mean(axis=0),assume_a
='pos')@weights
30     offset=float(y.mean(axis=0)@weights-means@beta+grand*beta.
sum())
31     beta=beta-beta.mean()
32     sx=np.sqrt(x)
33     def value_gradient(z):
34         p=z@x;sp=np.sqrt(np.maximum(p,1e-30))
35         kval=np.exp(-gamma*np.sum((sx-sp)**2,axis=1))
36         v=kval*beta
37         gp=-gamma*(v.sum()-(v@sx)/sp)
38         return float(v.sum()+offset),x@gp
39     # 全部约束在凸组合权重上为线性；四个无验证域固定闭合参考占比。
40     eq=np.vstack([np.ones(len(x)),x[:,fixed].T]);rhs=np.r_[1.,
ref[fixed]]
41     cap=2.5*ref[measured];upper=x[:,measured].T
42     init=linprog(np.zeros(len(x)),A_eq=eq,b_eq=rhs,A_ub=upper,
b_ub=cap,bounds=(0,None),method='highs')
43     if not init.success:raise RuntimeError('训练支持域与配比约
束无共同可行点')
44     starts=[init.x]
45     rng=np.random.default_rng(20260927)
46     for _ in range(3):
47         vertex=linprog(rng.normal(size=len(x)),A_eq=eq,b_eq=
rhs,A_ub=upper,b_ub=cap,
48                         bounds=(0,None),method='highs')
49         if vertex.success:starts.append(vertex.x)
50     fits=[]
51     for j,start in enumerate(starts):
52         z=start.copy();vertices=[z.copy()];combination=np.ones
(1)
53     # 全校正条件梯度：在少量可行顶点的凸组合上求解，约束始终可行。
54     for iteration in range(150):

```

```

55         value,gradient=value_gradient(z)
56         vertex=linprog(gradient,A_eq=eq,b_eq=rhs,A_ub=
upper,b_ub=cap,
57                         bounds=(0,None),method='highs')
58         if not vertex.success:raise RuntimeError(vertex.
message)
59         direction=vertex.x-z;gap=float(-gradient@direction
)
60         if gap<1e-6:break
61         vertices.append(vertex.x);basis=np.stack(vertices)
62         def reduced(c):
63             val,grad=value_gradient(c@basis)
64             return val,basis@grad
65         fit=minimize(reduced,np.r_[combination,0.],jac=
True,method='SLSQP',
66                     bounds=[(0,1)]*len(vertices),
constraints={'type':'eq','fun':lambda c:c.sum()-1.,'jac':
lambda c:np.ones_like(c)},
67             options={'maxiter':1000,'ftol':1e
-13})
68         combination=np.maximum(fit.x,0.);combination/=
combination.sum()
69         keep=combination>1e-10;combination=combination[
keep];combination/=combination.sum()
70         vertices=[v for v,yes in zip(vertices,keep) if yes
];z=combination@np.stack(vertices)
71         residual=max(float(np.max(abs(eq@z-rhs))),float(np.
maximum(upper@z-cap,0).max()),float(max(0,-z.min())))
72         fits.append(dict(start=j,success=bool(gap<1e-6),
objective=value_gradient(z)[0],
73                         constraint_residual=residual,
iterations=iteration+1,stationarity_gap=gap,weights=z))
74         print({k:v for k,v in fits[-1].items() if k!='weights'
},flush=True)
75         valid=[f for f in fits if f['success'] and f['
constraint_residual']<1e-7]
76         if not valid:raise RuntimeError('多初值推荐求解未通过可行
性检查')

```

```

77     best=min(valid,key=lambda f:f['objective']);z=best['
weights'];p=z@x
78     # 与正式核岭预测函数交叉核验目标值，并保存训练凸组合证书。
79     scores=krr_predict(x,y,np.stack([ref/ref.sum(),p]),gamma,
lam)@weights
80     assert abs(scores[1]-best['objective'])<1e-7
81     output_dir.mkdir(parents=True,exist_ok=True)
82     pd.DataFrame(dict(domain=domains,reference_mixture=ref,
recommended_mixture=p,adjustment=p-ref)).sort_values('
adjustment',ascending=False).to_csv(output_dir/'推荐配比调整
.csv',index=False,encoding='utf-8-sig')
83     pd.DataFrame(dict(index=indices,convex_weight=z)).to_csv(
output_dir/'核岭推荐_训练凸组合.csv',index=False,encoding='
utf-8-sig')
84     pd.DataFrame([{k:v for k,v in f.items() if k!='weights'}
for f in fits]).to_csv(output_dir/'核岭推荐_多初值.csv',
index=False,encoding='utf-8-sig')
85     pd.DataFrame([dict(mixture=name,predicted_weighted_loss=
float(score),M_p=float(score-scores[0])) for name,score in
zip(['参考配比','问题一有界推荐'],scores)]).to_csv(
output_dir/'核岭推荐_目标对照.csv',index=False,encoding='utf
-8-sig')
86     print(json.dumps(dict(reference=float(scores[0]),
recommended=float(scores[1]),change=float(scores[1]-scores
[0]),active_training_rows=int(np.sum(z>1e-8)),runs=[{k:v for
k,v in f.items() if k!='weights'} for f in fits]),
ensure_ascii=False,indent=2))
87     return p,scores
88
89
90 def main():
91     ap=argparse.ArgumentParser(description=__doc__)
92     ap.add_argument('--data-dir',type=Path)
93     ap.add_argument('--output-dir',type=Path,default=HERE/'结
果')
94     args=ap.parse_args()
95     recommend(find_data(args.data_dir),HERE/'结果',args.
output_dir)

```

```

96
97
98 if __name__ == '__main__': main()

```

Listing 9: 核岭训练支持范围内的配比推荐（求解/问题一/核岭支持域推荐.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
   构：OpenAI；版本发布日期：2026-07-09。
2  """问题一十幅图的展示版入口：只读既有结果，不执行求解程序。
3
4  运行：python 重绘图表.py --data-dir <附件根目录>
5  输出：同名400 dpi PNG、矢量SVG、数据及画布边界核验记录。
6  开发辅助工具：OpenAI Codex；采用 academic-research-suite 图形
   工作流。
7  """
8  from pathlib import Path
9  import argparse
10 import hashlib
11 import json
12 import sys
13 from 展示风格公共 import configure
14 from 绘图数据 import HERE, DOMAIN_NAMES, load_plot_data,
   verify_inputs_unchanged
15 from 展示风格概览 import plot_quality, plot_mixture, plot_fit
16 from 展示风格诊断 import plot_prediction, plot_coefficients,
   plot_quality_comparison, plot_extrapolation
17 from 展示风格冲突 import plot_conflicts
18 from 展示风格流程 import plot_workflow
19 from 展示风格非线性 import plot_nonlinear
20
21 NAMES = ['图0_A1-A3全量质量评分', '图1_训练配比结构', '图2_线
   性模型R2',
22         '图3_预测vs实测', '图4_混合系数热力图', '图5_领域质量
   评分',
23         '图6_冲突与赋权诊断', '图7_外推与跨尺度', '图8_问题一
   求解流程', '图9_非线性代理对照']
24
25
26 def main():

```

```

27     if hasattr(sys.stdout, 'reconfigure'):
28         sys.stdout.reconfigure(encoding='utf-8')
29     parser = argparse.ArgumentParser(description=__doc__)
30     parser.add_argument('--data-dir', type=Path)
31     parser.add_argument('--output-dir', type=Path, default=
HERE/' 图片')
32     parser.add_argument('--only', type=int, nargs='+', choices
=range(10), help='只重绘指定图文件编号')
33     args = parser.parse_args()
34     configure()
35     data = load_plot_data(args.data_dir)
36     args.output_dir.mkdir(parents=True, exist_ok=True)
37     functions = [plot_quality, plot_mixture, plot_fit,
plot_prediction, plot_coefficients,
38                 plot_quality_comparison, plot_conflicts,
plot_extrapolation, plot_workflow, plot_nonlinear]
39     selected = args.only if args.only is not None else list(
range(10))
40     for i in selected:
41         functions[i](data, args.output_dir)
42         print(f'已绘制 {NAMES[i]}', flush=True)
43     verify_inputs_unchanged(data)
44     manifest = {'style': '建模展示风',
45                'skill': 'academic-research-suite 3.22.0 /
visualization_agent',
46                'scripts_sha256': {p.name: hashlib.sha256(p.
read_bytes()).hexdigest() for p in
47                [Path(__file__), HERE/'绘图数据.py', HERE/'
出版导出.py', *sorted(HERE.glob('展示风格*.py'))]}, '
input_checks': data.checks,
48                'inputs': {k: {field: value for field, value in v.
items() if field != '_path'} for k, v in data.inputs.items()},
49                'output_figures': [NAMES[i] for i in selected],
50                'indicator_key': data.weights[['code', '
indicator', 'display_name']].to_dict(orient='records'),
51                'domain_key': DOMAIN_NAMES, 'prediction_points':
int(data.observed.size),
52                'coefficient_entries': int(data.centered.size),

```

```

'whole_paper_compiled':False}
53 (args.output_dir/'绘图数据核验.json').write_text(json.
dumps(manifest,ensure_ascii=False,indent=2),encoding='utf-8'
)
54 provenance = {
55     'scope': '本次生成的图形、实际读取输入和绘图程序；不替
代模型假设与论文分页审查。',
56     'scripts_sha256': manifest['scripts_sha256'], 'inputs'
: manifest['inputs'],
57     'figures': [{ 'file': NAMES[i]+ext,
58                   'sha256': hashlib.sha256((args.output_dir
/(NAMES[i]+ext)).read_bytes()).hexdigest()}
59               for i in selected for ext in ('.png','.svg
' )],
60     }
61 (args.output_dir/'图形溯源.json').write_text(json.dumps(
provenance,ensure_ascii=False,indent=2),encoding='utf-8')
62 print(f'{len(data.checks)} 项数值核对通过; {len(data.
inputs)} 个输入文件哈希未变。',flush=True)
63
64
65 if __name__ == '__main__':
66     main()

```

Listing 10: 问题一正式绘图入口（求解/问题一/重绘图表.py）

```

1 # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
   构：OpenAI；版本发布日期：2026-07-09。
2 # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
   Luna）辅助。
3 """读取问题一既有结果并核对绘图数值；不拟合、不优化、不写结果
   表。"""
4 from pathlib import Path
5 from types import SimpleNamespace
6 import hashlib
7 import json
8
9 import numpy as np
10 import pandas as pd

```

```

11
12 HERE = Path(__file__).resolve().parent
13 ROOT = HERE.parents[1]
14
15 DOMAIN_NAMES = {
16     'arxiv': '学术预印本', 'freelaw': '法律判例', '
17     nih_exporter': '科研项目',
18     'pubmed_central': '医学全文', 'wikipedia_en': '百科', '
19     dm_mathematics': '数学',
20     'github': '代码', 'philpapers': '哲学论文', 'stackexchange
21     ': '专业问答',
22     'enron_emails': '邮件', 'gutenberg_pg_19': '图书', '
23     pile_cc': '网页',
24     'ubuntu_irc': '技术聊天', 'europarl': '议会记录', '
25     hackernews': '科技社区',
26     'pubmed_abstracts': '医学摘要', 'uspto_backgrounds': '专利
27     背景',
28     'wikipedia': '百科', 'book': '图书', 'commoncrawl': '
29     Common Crawl', 'c4': 'C4',
30 }
31
32 INDICATOR_NAMES = {
33     'fineweb_edu': '教育价值', 'fluency_en': '英语流畅度',
34     'modernbert_cleanliness': '文本洁净度', '
35     modernbert_readability': '可读性',
36     'modernbert_reasoning': '推理性', '
37     modernbert_professionalism': '专业性',
38     'dsir_books': '书籍域权重', 'dsir_wiki': '维基域权重', '
39     dsir_math': '数学域权重',
40     'qurater': '四维质量聚合', 'ad_en': '广告信号', '
41     rps_doc_word_count': '文档词数',
42     'rps_doc_num_sentences': '文档句数', '
43     rps_doc_unigram_entropy': '一元词熵',
44     'rps_doc_frac_unique_words': '不同词占比', '
45     rps_doc_frac_no_alph_words': '非字母信号',
46     'rps_doc_frac_chars_top_2gram': '2-gram 重复度',
47     'rps_doc_frac_chars_top_3gram': '3-gram 重复度',
48     'rps_lines_uppercase_letter_fraction': '大写字母行占比',

```

```

36     'rps_lines_ending_with_terminal_punctution_mark': '终止标
点行占比',
37     'rps_lines_numerical_chars_fraction': '含数字行占比',
38     'rps_doc_mean_word_length': '平均词长',
39 }
40
41
42 def sha256(path):
43     return hashlib.sha256(Path(path).read_bytes()).hexdigest()
44
45
46 def short_name(name):
47     return name.replace('train_the_pile_', '').replace('metric
/the_pile_', '').replace('_val_loss', '')
48
49
50 def load_plot_data(data_dir=None):
51     candidates = [Path(data_dir)] if data_dir else [ROOT/'
real_attachments', ROOT.parent/'real_attachments']
52     data_root = next((p for p in candidates if p.is_dir()),
None)
53     if data_root is None:
54         raise FileNotFoundError('请用 --data-dir 指定
real_attachments 根目录。')
55     regmix = data_root/'A_data_value/regmix_tables'
56     if not regmix.is_dir():
57         raise FileNotFoundError(f'缺少配比附件目录: {regmix}')
58     inputs, checks = {}, {}
59
60     def read(path):
61         path = path.resolve()
62         df = pd.read_csv(path)
63         try:
64             label = path.relative_to(ROOT).as_posix()
65         except ValueError:
66             label = '附件/' + path.relative_to(data_root).
as_posix()
67         inputs[label] = {'sha256': sha256(path), 'rows': len(

```

```

df), 'columns': len(df.columns),
68         '_path': path}
69     return df
70
71     def result(name, index=None):
72         frame = read(HERE/'结果'/name)
73         return frame.set_index(index, verify_integrity=True)
if index else frame
74
75     def attachment(name, prefix):
76         frame = read(regmix/name).set_index('index',
verify_integrity=True).sort_index()
77         columns = [c for c in frame.columns if c.startswith(
prefix)]
78         frame = frame.loc[:, columns].rename(columns=
short_name)
79         if frame.empty or not np.isfinite(frame.to_numpy()).
all():
80             raise ValueError(f'附件 {name} 无有效数值或含缺
失。')
81         return frame
82
83     def same(name, actual, expected, tol=1e-10):
84         actual, expected = np.asarray(actual, dtype=float), np
.asarray(expected, dtype=float)
85         if actual.shape != expected.shape or not np.allclose(
actual, expected, atol=tol, rtol=tol):
86             raise ValueError(f'绘图数值与保存结果不一致: {name
}')
87         checks[name] = {'passed': True, 'max_abs_diff': float(
np.max(np.abs(actual-expected)))}
88
89     coef = result('混合系数矩阵.csv', 'training_domain')
90     centered = result('混合系数矩阵_中心化.csv', '
training_domain').loc[coef.index, coef.columns]
91     intercept = result('截距.csv', 'loss_domain').loc[coef.
columns, 'intercept']
92     metrics = result('问题一_拟合汇总.csv', 'loss_domain').loc

```

```

[coef.columns]
93     recommended = result('推荐配比调整.csv', 'domain').loc[
coef.index]
94     scale = result('外推尺度因子.csv', 'loss_domain').loc[coef
.columns]
95     cross = result('跨尺度损失比_60m_vs_1m.csv', 'loss_domain'
).loc[coef.columns]
96     quality = result('质量域评分_全量.csv').sort_values('
quality_mean', ascending=False).reset_index(drop=True)
97     weights = result('质量指标熵权.csv')
98     conflicts = result('冲突指标对_top20.csv').sort_values('
conflict_rate', ascending=False)
99     proxy = result('Loss代理领域难度.csv').sort_values('
quality_score_Q(loss代理)', ascending=False)
100     link = result('质量与损失难度一致性.csv')
101     nonlinear_domains = result('非线性代理对照_逐域.csv')
102     nonlinear_predictions = result('非线性代理对照_预测明细.
.csv')
103
104     same('中心化系数', coef.to_numpy()-coef.to_numpy().mean(
axis=0), centered)
105     same('熵权之和', weights.weight.sum(), 1.)
106     assert len(weights) == 22 and len(quality) == 7 and coef.
shape == (17, 13)
107     assert quality.n.sum() == 272505
108     assert set(weights.indicator) == set(INDICATOR_NAMES)
109     weights['code'] = [f'M{i:02d}' for i in range(1, 23)]
110     weights['display_name'] = weights.indicator.map(
INDICATOR_NAMES)
111
112     train_x = attachment('train_mixture_lm.csv', '
train_the_pile_').loc[:, coef.index]
113     train_y = attachment('train_pile_loss_lm.csv', 'metric/
the_pile_').loc[:, coef.columns]
114     if not train_x.index.equals(train_y.index):
115         raise ValueError('训练配方与损失的 index 不一致。')
116     mean_mixture=train_x.mean(axis=0)
117     same('闭合参考配比', mean_mixture/mean_mixture.sum(),

```

```

recommended.reference_mixture)
118     same('训练领域平均损失', train_y.mean(axis=0), metrics.
mean_loss)
119
120     def r_squared(y, pred):
121         return 1-((y-pred)**2).sum(axis=0)/((y-y.mean(axis=0))
**2).sum(axis=0)
122
123     pred_train = train_x.to_numpy() @ coef.to_numpy() +
intercept.to_numpy()
124     same('训练 R2', r_squared(train_y.to_numpy(), pred_train),
metrics.train_R2)
125     test_x = attachment('test_mixture_lm.csv', '
train_the_pile_').loc[:, coef.index]
126     test_y = attachment('test_pile_loss_lm.csv', 'metric/
the_pile_').loc[:, coef.columns]
127     if not test_x.index.equals(test_y.index):
128         raise ValueError('1M 检验配方与损失的 index 不一致。')
129     prediction = test_x.to_numpy() @ coef.to_numpy() +
intercept.to_numpy()
130     same('1M 检验 R2', r_squared(test_y.to_numpy(), prediction
), metrics.test1m_R2)
131
132     ratios = {}
133     for size, column in [('10b', 'scale_factor_10B'), ('70b', '
scale_factor_70B')]:
134         est_y = attachment(f'est_pile_loss_{size}.csv', '
metric/the_pile_').loc[:, coef.columns]
135         if not est_y.index.isin(train_y.index).all():
136             raise ValueError(f'{size} 外推损失无法按 index 对
应训练记录。')
137         values = est_y.to_numpy()/train_y.loc[est_y.index].
to_numpy()
138         same(f'{size} 外推均值', values.mean(axis=0), scale[
column])
139         ratios[size] = values
140
141     test60 = attachment('test_pile_loss_60m.csv', 'metric/

```

```

the_pile_').loc[:, coef.columns]
142     if set(test60.index) != set(test_y.index):
143         raise ValueError('60M、1M 检验记录的 index 集合不同。 '
)
144     cross_values = test60.loc[test_y.index].to_numpy()/test_y.
to_numpy()
145     same('60M/1M 均值', cross_values.mean(axis=0), cross.
loss_ratio_60m_vs_1m)
146     same('60M/1M 标准差', cross_values.std(axis=0), cross.
loss_ratio_std)
147     rho = float(link.Q_A1A3.corr(link['Q_loss代理'], method='
spearman'))
148     shared_path = HERE.parent/'问题一_关键量.json'
149     shared = json.loads(shared_path.read_text(encoding='utf-8'
))
150     inputs[shared_path.relative_to(ROOT).as_posix()] = {'
sha256': sha256(shared_path), '_path': shared_path}
151     same('质量口径 Spearman', rho, shared['
spearman_quality_vs_lossproxy'])
152     return SimpleNamespace(quality=quality, weights=weights,
conflicts=conflicts, metrics=metrics,
153                             coef=coef, centered=centered,
train_x=train_x, reference=train_x.mean(),
154                             observed=test_y.to_numpy(),
prediction=prediction, proxy=proxy, link=link,
155                             rho=rho, ratios=ratios, scale=scale
, cross=cross, inputs=inputs, checks=checks,
156                             nonlinear_domains=nonlinear_domains
, nonlinear_predictions=nonlinear_predictions)
157
158
159 def verify_inputs_unchanged(data):
160     for label, info in data.inputs.items():
161         if sha256(info['_path']) != info['sha256']:
162             raise RuntimeError(f'绘图期间输入文件发生变化: {
label}')

```

Listing 11: 问题一绘图数据读取（求解/问题一/绘图数据.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  """Q1 展示版的字体、分组标题和导出约定。"""
4  from pathlib import Path
5  import json
6  import os
7
8  # Keep matplotlib's cache in a writable, task-local directory.
9  os.environ.setdefault('MPLCONFIGDIR', str(Path(__file__).
    resolve().parent/'__pycache__/' 'matplotlib'))
10 import matplotlib
11 matplotlib.use('Agg')
12 import matplotlib.pyplot as plt
13 from matplotlib import font_manager as fm
14 from matplotlib.patches import Rectangle
15 from matplotlib.text import Text
16
17 PURPLE, TEAL, GOLD, BLUE = '#665080', '#287C78', '#BC8030', '
    #365E8D'
18 INK, GRAY, GRID = '#243348', '#637186', '#E6EBF1'
19
20
21 def configure():
22     for name in ['simsun.ttc', 'times.ttf', 'timesi.ttf', '
        timesbd.ttf']:
23         path=Path('C:/Windows/Fonts')/name
24         if path.exists():
25             fm.fontManager.addfont(str(path))
26     for family in ['SimSun', 'Times New Roman']:
27         fm.findfont(family, fallback_to_default=False)
28     plt.rcParams.update({
29         'font.family':['Times New Roman', 'SimSun'], 'font.size
        ':10,
30         'axes.labelsize':10, 'axes.titlesize':11, 'xtick.
        labelsize':9,

```

```

31         'ytick.labelsize':9, 'legend.fontsize':9, 'mathtext.
fontset':'stix',
32         'axes.unicode_minus':False, 'axes.spines.top':False, '
axes.spines.right':False,
33         'axes.edgecolor':'#9AA7B7','axes.linewidth':.6,
34         'text.color':INK,'axes.labelcolor':INK,'xtick.color':
GRAY,'ytick.color':INK,
35         'grid.color':GRID,'grid.linewidth':.55,'legend.frameon
':False,
36         'axes.axisbelow':True, 'figure.facecolor':'white', '
axes.facecolor':'white',
37         'savefig.facecolor':'white','savefig.dpi':400,'svg.
fonttype':'path',
38         'svg.hashsalt':'Q1-ARS-display-v2',
39     })
40
41
42 def panel(ax, letter, title, color=BLUE):
43     """A compact group header; keep enough top margin for its
44     11 pt title."""
45     ax.add_patch(Rectangle((0,1.035),1,.095,transform=ax.
transAxes,
46                             facecolor=color,alpha=.075,
edgecolor='none',clip_on=False))
47     ax.text(.015,1.082,letter,transform=ax.transAxes,va='
center',ha='left',
48             fontsize=11,fontweight='bold',color=color)
49     ax.text(.105,1.082,title,transform=ax.transAxes,va='center
',ha='left',
50             fontsize=10.5,color=INK)
51
52 def clean(ax, axis='x', bands=False, n=None):
53     ax.grid(axis=axis)
54     ax.tick_params(length=0,pad=5)
55     if bands:
56         for y in range(0,n,2):
57             ax.axhspan(y-.5,y+.5,color='#F4F6FA',zorder=-2)

```

```

58
59
60 def save(fig, stem, out):
61     """Export fixed-size, 400 dpi PNG/SVG and a canvas-
62     boundary audit."""
63     out=Path(out)
64     out.mkdir(parents=True,exist_ok=True)
65     fig.canvas.draw()
66     renderer=fig.canvas.get_renderer()
67     canvas=fig.bbox
68     issues=[]
69     # Tick labels outside the current axis interval may be
70     invisible after clipping.
71     for text in fig.findobj(Text):
72         if not text.get_visible() or not text.get_text().strip
73         ():
74             continue
75         if text.axes is not None and text.get_clip_on():
76             continue
77         b=text.get_window_extent(renderer)
78         if b.width and b.height and (b.x0<canvas.x0-1 or b.x1>
79         canvas.x1+1 or
80         b.y0<canvas.y0-1 or b.y1>
81         canvas.y1+1):
82             issues.append({'text':text.get_text(),'bbox':[
83             round(v,2) for v in b.bounds]})
84         fig.savefig(out/f'{stem}.png',dpi=400)
85         svg=out/f'{stem}.svg'
86         fig.savefig(svg,metadata={'Date':None,'Creator':'Q1 ARS
87         visualization workflow'})
88         svg.write_text('\n'.join(x.rstrip() for x in svg.read_text
89         (encoding='utf-8').splitlines()))+'\n',encoding='utf-8')
90         # This only checks canvas bounds, not semantic correctness
91         or internal overlaps.
92         (out/f'{stem}_布局核验.json').write_text(json.dumps({
93         'canvas_inches':list(fig.get_size_inches()),'dpi':400,
94         'boundary_issues':issues,'scope':'canvas text bounds
95         only; visual review still required'

```

```

86     },ensure_ascii=False,indent=2),encoding='utf-8')
87     plt.close(fig)
88     if issues:
89         print(f'{stem}: {len(issues)} canvas-boundary item(s)
            need review',flush=True)

```

Listing 12: 问题一图形样式与导出（求解/问题一/展示风格公共.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  """问题一质量、配方结构与拟合概览的展示图。
4
5  仅读取绘图数据模块提供的既有结果；图中均值、标准差、配方占比及
6  拟合统计均按原值展示。学术图表规范来源与项目字体约定同公共模
    块。
7  """
8  from pathlib import Path
9
10 import numpy as np
11 import matplotlib.pyplot as plt
12 from matplotlib.colors import LinearSegmentedColormap
13 from matplotlib.ticker import PercentFormatter
14
15 from 绘图数据 import DOMAIN_NAMES
16 from 展示风格公共 import (
17     PURPLE, TEAL, GOLD, BLUE, INK, GRAY, GRID, configure,
18     panel, clean, save,
19 )
20
21 STEMS = ['图0_A1-A3全量质量评分', '图1_训练配比结构', '图2_线
    性模型R2']
22
23
24 def _names(domains):
25     return [DOMAIN_NAMES[name] for name in domains]
26

```

```

27
28 def plot_quality(data, out):
29     q = data.quality.sort_values('quality_mean', ascending=
30     False).reset_index(drop=True)
31     short_labels = {
32         'arxiv': '学术\n预印本', 'stackexchange': '专业\n问答'
33     },
34     'commoncrawl': 'Common\nCrawl', 'github': '代码',
35     'wikipedia': '百科', 'book': '图书', 'c4': 'C4',
36     }
37     x = np.arange(len(q))
38     fig, ax = plt.subplots(figsize=(6.5, 3.6))
39     colors = [PURPLE] + [TEAL] * (len(q) - 1)
40     ax.bar(x, q.quality_mean, width=.66, color=colors,
41     edgecolor='white',
42     linewidth=.6, zorder=3)
43     ax.errorbar(x, q.quality_mean, yerr=q.quality_std, fmt='
44     none',
45     ecolor=INK, elinewidth=.9, capsize=3, capthick
46     =.9, zorder=4)
47     for pos, row in q.iterrows():
48         ax.text(pos, row.quality_mean + row.quality_std +
49         .025,
50         f'{row.quality_mean:.3f}', fontsize=9.5,
51         ha='center', va='bottom', color=colors[pos])
52         ax.text(pos, .055, f'n =\n{int(row.n):,}', fontsize=9,
53         ha='center', va='bottom', linespacing=1.2,
54         color='white', zorder=5)
55     ax.set(xticks=x, xticklabels=[short_labels[name] for name
56     in q.domain],
57     ylabel='质量评分 Q', ylim=(0, .87), yticks=[0, .2,
58     .4, .6, .8],
59     xlim=(-.65, len(q)-.35))
60     ax.text(.99, .985, '误差线: 标准差', transform=ax.
61     transAxes,
62     fontsize=9, color=GRAY, ha='right', va='top')
63     ax.spines['bottom'].set_color(GRID)
64     clean(ax, axis='y')

```

```

55     panel(ax, 'A', '语料领域的质量评分', PURPLE)
56     fig.subplots_adjust(left=.11, right=.975, bottom=.18, top
57     =.82)
58     save(fig, STEMS[0], out)
59
60 def plot_mixture(data, out):
61     order = data.reference.sort_values(ascending=False).index
62     assert len(order) == 17
63     matrix = data.train_x.loc[:, order].iloc[:8].to_numpy().T
64     assert matrix.shape == (17, 8)
65     values = data.reference.loc[order].to_numpy()
66     fig = plt.figure(figsize=(5.0, 3.65))
67     grid = fig.add_gridspec(1, 2, width_ratios=[1.30, 1],
68     left=.20, right=.98, bottom=.21,
69     top=.86, wspace=.18)
70     ax = fig.add_subplot(grid[0])
71     right = fig.add_subplot(grid[1], sharey=ax)
72     cmap = LinearSegmentedColormap.from_list(
73     'q1_mixture_share', ['#F4F7FA', '#D4E8E6', '#68A5A0',
74     TEAL, PURPLE])
75     image = ax.imshow(matrix, vmin=0, vmax=1, cmap=cmap,
76     interpolation='nearest', aspect='auto')
77     ax.set(xticks=np.arange(8),
78     xticklabels=[str(i) for i in data.train_x.index
79     [:8]],
80     yticks=np.arange(17), yticklabels=_names(order),
81     xlabel='配方编号',
82     ylim=(16.5, -.5))
83     ax.set_xticks(np.arange(-.5, 8, 1), minor=True)
84     ax.set_yticks(np.arange(-.5, 17, 1), minor=True)
85     ax.grid(which='minor', color='white', linewidth=.65)
86     ax.tick_params(which='both', length=0, pad=5)
87     for row, col in zip(*np.where(matrix >= .10)):
88         value = matrix[row, col]
89         ax.text(col, row, f'{value:.0%}', ha='center', va='
center', fontsize=9,
90         color='white' if value >= .45 else INK)

```

```

87     for spine in ax.spines.values():
88         spine.set_visible(False)
89     panel(ax, 'A', '前 8 组训练配方', PURPLE)
90
91     y = np.arange(17)
92     right.barh(y, values, color=TEAL, height=.62, edgecolor='
white', linewidth=.5,
93               zorder=3)
94     for pos, value in enumerate(values):
95         right.text(value + .005, pos, f'{value:.1%}',
96                   ha='left', va='center', fontsize=9, color=
TEAL)
97     right.set(xlim=(0, .17), xticks=[0, .05, .10, .15],
98             xlabel='平均训练占比')
99     right.tick_params(axis='y', labelleft=False)
100    right.xaxis.set_major_formatter(PercentFormatter(1,
decimals=0))
101    right.spines['left'].set_visible(False)
102    clean(right, bands=True, n=17)
103    right.tick_params(axis='y', which='both', length=0)
104    panel(right, 'B', '平均领域占比', TEAL)
105    cax = fig.add_axes([.205, .055, .38, .020])
106    bar = fig.colorbar(image, cax=cax, orientation='horizontal
',
107                      ticks=[0, .25, .5, .75, 1], format=
PercentFormatter(1, decimals=0))
108    bar.ax.tick_params(length=2, labelsize=9, pad=2)
109    bar.outline.set_linewidth(.4)
110    fig.text(.64, .065, '配方实际占比', ha='left', va='center'
, fontsize=9, color=GRAY)
111    save(fig, STEMS[1], out)
112
113
114 def plot_fit(data, out):
115     m = data.metrics.sort_values('test1m_R2', ascending=False)
116     fig, axes = plt.subplots(1, 2, figsize=(5.0, 3.45), sharey
=True)
117     y = np.arange(len(m))

```

```

118     specs = [
119         (axes[0], 'train_R2', 'test1m_R2', '训练 1M', '检验 1M',
120          PURPLE, TEAL, 'o', 'o', '决定系数  $R^2$ '),
121         (axes[1], 'test60m_r', 'test1B_r', '检验 60M', '检验 1B',
122          BLUE, GOLD, '^', 's', 'Pearson 相关系数  $r$ '),
123     ]
124     for ax, col1, col2, lab1, lab2, color1, color2, marker1,
125     marker2, xlabel in specs:
126         ax.hlines(y, np.minimum(m[col1], m[col2]), np.maximum(
127             m[col1], m[col2]),
128             color='#B9C5D3', linewidth=1.35, zorder=2)
129         ax.scatter(m[col1], y, s=29, marker=marker1,
130             color=color1, edgecolor='white', linewidth
131             =.45, label=lab1, zorder=4)
132         ax.scatter(m[col2], y, s=33, marker=marker2,
133             facecolor='none', edgecolor=color2,
134             linewidth=1.05, label=lab2, zorder=5)
135         ax.set(xlim=(0, 1), xticks=[0, .25, .5, .75, 1],
136             ylim=(len(m)-.6, -.6), xlabel=xlabel)
137         ax.legend(loc='upper center', bbox_to_anchor=(.5,
138             -.27), ncol=2,
139             fontsize=9, handletextpad=.28, columnspacing
140             =.8, borderaxespad=0)
141         clean(ax, bands=True, n=len(m))
142         axes[0].set(yticks=y, yticklabels=_names(m.index))
143         axes[1].tick_params(axis='y', labelleft=False)
144         axes[1].spines['left'].set_visible(False)
145         panel(axes[0], 'A', '同尺度拟合与检验', PURPLE)
146         panel(axes[1], 'B', '跨尺度相关性', BLUE)
147     fig.subplots_adjust(left=.20, right=.96, bottom=.25, top
148         =.85, wspace=.18)
149     save(fig, STEMS[2], out)
150
151 if __name__ == '__main__':
152     import argparse

```

```

147     import sys
148     from 绘图数据 import load_plot_data,
verify_inputs_unchanged
149     if hasattr(sys.stdout, 'reconfigure'):
150         sys.stdout.reconfigure(encoding='utf-8')
151     parser = argparse.ArgumentParser(description=__doc__)
152     parser.add_argument('--data-dir', type=Path, required=True
)
153     parser.add_argument('--output-dir', type=Path, required=
True)
154     args = parser.parse_args()
155     configure()
156     data = load_plot_data(args.data_dir)
157     for draw in [plot_quality, plot_mixture, plot_fit]:
158         draw(data, args.output_dir)
159     verify_inputs_unchanged(data)
160     print(f'{len(data.checks)} 项数据核对通过; 已绘制 3 张概览
图。')

```

Listing 13: 问题一概览图（求解/问题一/展示风格概览.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  """问题一预测、系数、质量口径及尺度诊断的展示图；不重新求解。
    """
4  from 展示风格公共 import panel, clean, save, PURPLE, TEAL,
    GOLD, BLUE, INK, GRAY
5  import numpy as np
6  import matplotlib.pyplot as plt
7  from matplotlib.colors import LinearSegmentedColormap,
    SymLogNorm, to_rgb
8  from matplotlib.patches import Patch
9  from matplotlib.ticker import MaxNLocator
10 from 绘图数据 import DOMAIN_NAMES
11
12 SEQ = LinearSegmentedColormap.from_list('q1_density', ['#
    EE4F5', '#8DC1BE', TEAL, '#24426C'])

```

```

13 DIVERGING = LinearSegmentedColormap.from_list('q1_signed', [
    TEAL, '#ACD2CD', '#F9FAFC', '#C2B5D1', PURPLE])
14
15
16 def labels(domains):
17     return [DOMAIN_NAMES[d] for d in domains]
18
19
20 def annotation_color(background):
21     """Select the higher-contrast text colour for the actual
    rendered cell."""
22     def luminance(rgb):
23         c=np.array(rgb[:3])
24         linear=np.where(c<=.04045,c/12.92,((c+.055)/1.055)
    **2.4)
25         return float(linear @ np.array([.2126,.7152,.0722]))
26     bg=luminance(background)
27     dark=luminance(to_rgb(INK))
28     white_contrast=1.05/(bg+.05)
29     dark_contrast=(max(bg,dark)+.05)/(min(bg,dark)+.05)
30     return 'white' if white_contrast>dark_contrast else INK
31
32
33 def plot_prediction(data, out):
34     x, y = data.observed.ravel(), data.prediction.ravel()
35     lo, hi = min(x.min(),y.min()), max(x.max(),y.max())
36     lo, hi = np.floor(lo*2)/2-.1, np.ceil(hi*2)/2+.1
37     fig = plt.figure(figsize=(4.3,3.7))
38     # Equal axis lengths and identical numerical ranges
    preserve the 45-degree reference.
39     square_height = .57 * 4.3 / 3.7
40     ax = fig.add_axes([.15,.17,.57,square_height])
41     top = fig.add_axes([.15,.855,.57,.085], sharex=ax)
42     right = fig.add_axes([.735,.17,.075,square_height], sharey
    =ax)
43     cax = fig.add_axes([.865,.29,.025,.39])
44     h = ax.hexbin(x,y,gridsize=43,mincnt=1,cmap=SEQ,linewidths
    =0,

```

```

45         extent=(lo,hi,lo,hi),rasterized=False)
46     ax.plot([lo,hi],[lo,hi],color=GOLD,lw=1.15,ls=(0,(4,3)),
label='预测值 = 实测值')
47     ax.set(xlim=(lo,hi),ylim=(lo,hi),xlabel='实测验证损失',
ylabel='模型预测损失',aspect='equal')
48     ax.legend(loc='lower right',fontsize=8)
49     ax.text(.035,.963,f'N = {len(x):,}',transform=ax.transAxes
,ha='left',va='top',
50             fontsize=10,color=BLUE,bbox={'facecolor':'white','
edgecolor':'none','alpha':.9,'pad':3})
51     bins=np.linspace(lo,hi,37)
52     top.hist(x,bins=bins,color=TEAL,alpha=.65,edgecolor='white
',linewidth=.2)
53     right.hist(y,bins=bins,orientation='horizontal',color=
PURPLE,alpha=.65,edgecolor='white',linewidth=.2)
54     top.axis('off');right.axis('off')
55     cb=fig.colorbar(h,cax=cax)
56     cb.ax.set_title('记录数',fontsize=9,pad=8)
57     cb.locator=MaxNLocator(5,integer=True);cb.update_ticks()
58     cb.outline.set_visible(False)
59     save(fig,'图3_预测vs实测',out)
60
61
62 def plot_coefficients(data,out):
63     matrix=data.centered.to_numpy()
64     vmax=float(np.abs(matrix).max())
65     fig=plt.figure(figsize=(5.3,4.3))
66     ax=fig.add_axes([.18,.29,.79,.57])
67     # Only colour mapping changes: all 221 original
coefficients are retained.
68     norm=SymLogNorm(linthresh=1,linscale=.5,vmin=-vmax,vmax=
vmax,base=10)
69     mesh=ax.imshow(matrix,aspect='auto',interpolation='nearest
',cmap=DIVERGING,norm=norm)
70     wrapped={'学术预印本':'学术\n预印本','法律判例':'法律\n判
例','医学全文':'医学\n全文',
71             '专业问答':'专业\n问答','技术聊天':'技术\n聊天','
科技社区':'科技\n社区',

```

```

72         '医学摘要': '医学\n摘要', '专利背景': '专利\n背景'}
73     ax.set(yticks=np.arange(17), yticklabels=labels(data.
centered.index),
74           xticks=np.arange(13), xticklabels=[wrapped.get(t, t)
for t in labels(data.centered.columns)])
75     ax.tick_params(length=0, pad=5)
76     ax.set_xticks(np.arange(-.5, 13, 1), minor=True)
77     ax.set_yticks(np.arange(-.5, 17, 1), minor=True)
78     ax.grid(which='minor', color='white', linewidth=.5)
79     ax.tick_params(which='minor', length=0)
80     for j in range(13):
81         i=int(np.argmax(np.abs(matrix[:,j])))
82         v=matrix[i,j]
83         ax.text(j,i,f'{v:+.1f}', ha='center', va='center',
fontsize=9,
84               color=annotation_color(DIVERGING(norm(v))))
85     panel(ax, 'A', '17 个训练域 × 13 个验证域', PURPLE)
86     ax.set_xlabel('验证领域', labelpad=9)
87     cax=fig.add_axes([.29,.12,.60,.025])
88     cb=fig.colorbar(mesh,cax=cax,orientation='horizontal',
ticks=[-15,-5,-1,0,1,5,15])
89     cb.ax.set_xticklabels(['-15','-5','-1','0','1','5','15'])
90     cb.set_label('中心化系数（对称对数色标）', labelpad=4)
91     cb.outline.set_visible(False)
92     save(fig, '图4_混合系数热力图', out)
93
94
95 def plot_quality_comparison(data, out):
96     p=data.proxy
97     fig=plt.figure(figsize=(5.3,3.65))
98     ax=fig.add_axes([.16,.17,.315,.66])
99     ar=fig.add_axes([.56,.17,.40,.66])
100    y=np.arange(len(p))
101    vals=p['quality_score_0(loss代理)'].to_numpy()
102    ax.barh(y,vals,height=.57,color=BLUE,alpha=.85)
103    for i,v in enumerate(vals):
104        ax.text(v+.025,i,f'{v:.2f}',ha='left',va='center',
fontsize=9,color=BLUE)

```

```

105     ax.set(yticks=y,yticklabels=labels(p.domain),ylim
=(12.6,-.6),xlim=(0,1.2),
106         xticks=[0,.5,1],xlabel='损失代理评分')
107     clean(ax,bands=True,n=13)
108     panel(ax,'A','13 域代理评分',BLUE)
109     link=data.link.set_index('mixture_domain')
110     rank_a=link.Q_A1A3.rank(ascending=False).astype(int)
111     rank_b=link['Q_loss代理'].rank(ascending=False).astype(int
)
112     # Lines encode identity across two methods, not a time
trend or score change.
113     colors=[BLUE,TEAL,GOLD,PURPLE,'#708398','#9D7465']
114     for color,d in zip(colors,rank_a.sort_values().index):
115         a,b=rank_a[d],rank_b[d]
116         ar.plot([0,1],[a,b],color=color,lw=1.8,alpha=.85,
zorder=2)
117         ar.scatter([0,1],[a,b],s=110,c=color,edgecolors='white
',linewidth=1,zorder=3)
118         for xpos,r in [(0,a),(1,b)]:
119             ar.text(xpos,r,str(r),color='white',fontsize=9,ha=
'center',va='center',zorder=4)
120             ar.text(-.11,a,DOMAIN_NAMES[d],ha='right',va='center',
fontsize=9,color=color)
121             ar.text(1.11,b,DOMAIN_NAMES[d],ha='left',va='center',
fontsize=9,color=color)
122     ar.set(xlim=(-.82,1.82),ylim=(6.65,.2))
123     for xpos,name in [(0,'指标质量'),(1,'损失代理')]:
124         ar.text(xpos,.48,name,ha='center',va='center',fontsize
=9,color=INK)
125     ar.text(.5,6.5,rf'Spearman $\rho$={data.rho:.2f}$',ha='
center',va='center',fontsize=10,color=GRAY)
126     ar.axis('off')
127     panel(ar,'B','6 个公共领域的排名',TEAL)
128     save(fig,'图5_领域质量评分',out)
129
130
131 def plot_extrapolation(data,out):
132     domains=list(data.coef.columns)

```

```

133     order=np.argsort(data.ratios['10b'].mean(axis=0))
134     names=[domains[i] for i in order]
135     cross=data.cross.loc[names]
136     fig=plt.figure(figsize=(6.5,4.8))
137     ax=fig.add_axes([.15,.15,.40,.64])
138     ar=fig.add_axes([.64,.15,.325,.64],sharey=ax)
139     y=np.arange(13)
140     for size,offset,color in [('10b',-.17,TEAL),('70b',.17,
PURPLE)]:
141         samples=[data.ratios[size][:,i] for i in order]
142         ax.boxplot(samples,positions=y+offset,vert=False,
widths=.24,patch_artist=True,
143                     whis=(0,100),showfliers=False,manage_ticks
=False,
144                     boxprops={'facecolor':color,'edgecolor':
color,'alpha':.42,'linewidth':.7},
145                     medianprops={'color':color,'linewidth'
:1.3},
146                     whiskerprops={'color':color,'linewidth'
:.75},
147                     capprops={'color':color,'linewidth':.75})
148     ax.set(yticks=y,yticklabels=labels(names),ylim=(12.6,-.6),
xlabel='外推损失 / 1M 训练损失')
149     ax.xaxis.set_major_locator(MaxNLocator(4))
150     ar.errorbar(cross.loss_ratio_60m_vs_1m,y,xerr=cross.
loss_ratio_std,fmt='o',
151                color=GOLD,ecolor=GOLD,ms=4,capsize=2.5,
elinewidth=1.1)
152     ar.axvline(1,color=GRAY,lw=.8,ls=(0,(3,3)))
153     ar.tick_params(labelleft=False)
154     ar.set(xlim=(.42,1.035),xticks=[.5,.7,.9,1],xlabel='60M /
1M 检验损失')
155     for a in [ax,ar]:
156         clean(a,bands=True,n=13)
157     panel(ax,'A','10B / 70B 外推分布',TEAL)
158     panel(ar,'B','同配方跨尺度比值',GOLD)
159     fig.legend(handles=[Patch(facecolor=TEAL,alpha=.55,label='
10B')],

```

```

160         Patch(facecolor=PURPLE,alpha=.55,label
    = '70B')],
161         loc='upper left',bbox_to_anchor=(.15,.962),
    ncol=2,handlelength=1.3,columnspacing=1.8)
162     save(fig,'图7_外推与跨尺度',out)

```

Listing 14: 问题一诊断图（求解/问题一/展示风格诊断.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  """用原有前 12 对冲突关系和 22 项熵权绘制网络与权重面板。"""
4  from pathlib import Path
5
6  import numpy as np
7  import matplotlib.pyplot as plt
8  from matplotlib.lines import Line2D
9  from matplotlib.ticker import PercentFormatter
10
11 from 展示风格公共 import configure, save, panel, PURPLE, TEAL,
    GOLD, BLUE, INK, GRAY, GRID
12
13
14 def plot_conflicts(data, out):
15     """节点等大、连线宽度从零按冲突率线性编码，不推断其他连
    接。"""
16     weights = data.weights.sort_values('weight', ascending=
    False)
17     key = data.weights.set_index('indicator')
18     pairs = data.conflicts.sort_values('conflict_rate',
    ascending=False).head(12)
19     edges = [(key.loc[a, 'code'], key.loc[b, 'code'], float(
    row.conflict_rate))
20              for row in pairs.itertuples()]
21     for a, b in [row.indicator_pair.split('|')]:
22         nodes = {node for edge in edges for node in edge[:2]}
23     # A fixed tree layout keeps every observed edge visible
    and avoids crossings.

```

```

24     positions = {
25         'M15': (.39, .64), 'M14': (.05, .92), 'M06': (.54,
.92),
26         'M02': (.93, .69), 'M04': (.04, .63),
27         'M05': (.05, .38), 'M19': (.37, .30), 'M01': (.62,
.40),
28         'M22': (.95, .38), 'M16': (.74, .14), 'M03': (1.04,
.13),
29         'M12': (.38, .08), 'M18': (.06, .08),
30     }
31     if nodes != set(positions):
32         raise ValueError('冲突指标集合改变，需要重新检查固定网
络布局。')
33     kind = data.weights.set_index('code').list_type.to_dict()
34
35     fig = plt.figure(figsize=(6.5, 5.8))
36     network = fig.add_axes([.035, .14, .415, .71])
37     bars = fig.add_axes([.73, .14, .245, .71])
38     # A separate header spans both the bar labels and plotting
area.
39     header = fig.add_axes([.48, .14, .495, .71], frameon=False
)
40     header.set_axis_off()
41     panel(network, 'A', '高冲突指标网络', color=GOLD)
42     panel(header, 'B', '22 项质量指标的熵权', color=PURPLE)
43     network.set(xlim=(-.055, 1.135), ylim=(-.015, 1.06))
44     network.set_axis_off()
45
46     for a, b, value in edges:
47         x1, y1 = positions[a]
48         x2, y2 = positions[b]
49         network.plot([x1, x2], [y1, y2], color=GOLD, alpha
=.65,
50                     linewidth=6 * value, zorder=1,
solid_capstyle='round')
51         # Offset perpendicular to each edge by a small screen-
space distance.
52         dx = (x2-x1) * .415 * 6.5

```

```

53     dy = (y2-y1) * .71 * 5.8
54     length = np.hypot(dx, dy)
55     offset = (-dy/length*5.8, dx/length*5.8)
56     network.annotate(f'{{value:.1%}}', ((x1+x2)/2, (y1+y2)
/2),
57                     xytext=offset, textcoords='offset
points',
58                     ha='center', va='center', fontsize=9,
color=GRAY,
59                     bbox={'facecolor':'white', 'edgecolor
': 'none', 'pad':.35}, zorder=3)
60     for node in sorted(nodes):
61         color = PURPLE if kind[node] else TEAL
62         network.scatter(*positions[node], s=475, color=color,
edgecolor='white',
63                         linewidth=1.2, zorder=4)
64         network.text(*positions[node], node, color='white',
fontsize=9,
65                     ha='center', va='center', zorder=5)
66
67     y = np.arange(len(weights))
68     colors = [PURPLE if is_list else TEAL for is_list in
weights.list_type]
69     for i in range(0, len(weights), 2):
70         bars.axhspan(i-.5, i+.5, color='#F4F6FA', zorder=0)
71         bars.barh(y, weights.weight, color=colors, height=.58,
edgecolor='none', zorder=2)
72         for i, value in enumerate(weights.weight):
73             bars.text(value+.006, i, f'{{value:.1%}}', color=INK,
fontsize=9,
74                     ha='left', va='center')
75     bars.set(yticks=y,
76             yticklabels=[f'{{row.code}}  {{row.display_name}}'
for row in weights.itertuples()],
77             ylim=(21.7, -.7), xlim=(0, .19), xticks
=[0, .05, .10, .15],
78             xlabel='熵权占比')
79     bars.tick_params(axis='y', length=0, pad=5, labelsize=9)

```

```

80     bars.tick_params(axis='x', length=0, labelsiz=9)
81     bars.spines['left'].set_visible(False)
82     bars.spines['bottom'].set_visible(False)
83     bars.xaxis.set_major_formatter(PercentFormatter(1,
decimals=0))
84     bars.grid(axis='x', color=GRID, linewidth=.55)
85
86     handles = [Line2D([], [], marker='o', color='none',
markerfacecolor=color,
87                 markeredgecolor='none', markersize=6,
label=label)]
88     for color, label in [(PURPLE, '列表型指标'), (
TEAL, '标量型指标')]
89     fig.legend(handles=handles, loc='lower center',
bbox_to_anchor=(.50, .025),
90                ncol=2, columnspacing=2.5, handletextpad=.5,
fontsize=9)
91     network.text(.5, -.065, '前 12 对冲突关系；线宽正比于冲突
率',
92                 transform=network.transAxes, ha='center', va=
'top', fontsize=9, color=GRAY)
93     save(fig, '图6_冲突与赋权诊断', Path(out))
94
95
96 if __name__ == '__main__':
97     import argparse
98     from 绘图数据 import load_plot_data,
verify_inputs_unchanged
99     parser = argparse.ArgumentParser(description=__doc__)
100     parser.add_argument('--data-dir', type=Path, required=True
)
101     parser.add_argument('--output-dir', type=Path, required=
True)
102     args = parser.parse_args()
103     configure()
104     source = load_plot_data(args.data_dir)
105     plot_conflicts(source, args.output_dir)
106     verify_inputs_unchanged(source)

```

Listing 15: 问题一冲突图（求解/问题一/展示风格冲突.py）

```
1 # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
   # 构：OpenAI；版本发布日期：2026-07-09。
2 # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
   # Luna）辅助。
3 """问题一双泳道流程图；仅调整展示，不运行模型或读取原始附件。
4
5 使用 academic-research-suite 的 visualization_agent 绘图检查规
   范；
6 中文宋体、英文 Times New Roman 与竞赛图注格式遵循本项目要求。
7 """
8 from pathlib import Path
9
10 import matplotlib.pyplot as plt
11 from matplotlib.patches import FancyArrowPatch, FancyBboxPatch
   , Rectangle
12 from matplotlib.colors import to_rgb
13
14 from 展示风格公共 import PURPLE, TEAL, GOLD, BLUE, INK, GRAY,
   GRID, save
15
16
17 def _tint(color, strength=.075):
18     """Blend a group color into the white paper background."""
19     return tuple(1 - strength * (1 - value) for value in
   to_rgb(color))
20
21
22 def plot_workflow(data, out):
23     """Render the existing Q1 procedure as two clearly
   connected swimlanes.
24
25     ``data`` is accepted for compatibility with the numeric
   figure generators.
26     There are no computed quantities in this conceptual figure
   .
```

```

27     """
28     out = Path(out)
29     out.mkdir(parents=True, exist_ok=True)
30     fig = plt.figure(figsize=(6.5, 4.5))
31     ax = fig.add_axes([0, 0, 1, 1])
32     ax.set(xlim=(0, 6.5), ylim=(0, 4.5))
33     ax.axis('off')
34
35     def lane(y, h, label, color):
36         ax.add_patch(FancyBboxPatch(
37             (.08, y), 6.34, h,
38             boxstyle='round,pad=0,rounding_size=.06',
39             facecolor=_tint(color, .045), edgecolor=_tint(
color, .22),
40             linewidth=.7, zorder=0))
41         ax.add_patch(Rectangle((.08, y + h - .33), .045, .22,
42                               facecolor=color, edgecolor='
none', zorder=1))
43         ax.text(.23, y + h - .22, label, fontsize=10.5, color=
color,
44                ha='left', va='center')
45
46     def node(x, y, w, h, heading, body, color, body_size=9.2):
47         ax.add_patch(FancyBboxPatch(
48             (x, y), w, h, boxstyle='round,pad=0,rounding_size
=.035',
49             facecolor='white', edgecolor=_tint(color, .55),
50             linewidth=.85, zorder=3))
51         ax.add_patch(Rectangle((x + .012, y + h - .27), w -
.024, .258,
52                               facecolor=_tint(color, .105),
edgecolor='none',
53                               zorder=4))
54         ax.text(x + w/2, y + h - .139, heading, fontsize=9.4,
55                color=color, ha='center', va='center', zorder
=5)
56         ax.text(x + w/2, y + (h - .27)/2 - .006, body,
fontsize=body_size,

```

```

57         color=INK, ha='center', va='center',
linespacing=1.33, zorder=5)
58
59     def arrow(points, color=GRAY, dashed=False):
60         linestyle = (0, (3.2, 2.1)) if dashed else '-'
61         if len(points) > 2:
62             xx, yy = zip(*points[:-1])
63             ax.plot(xx, yy, color=color, linewidth=.95,
64                     linestyle=linestyle, solid_capstyle='round
', zorder=2)
65             ax.add_patch(FancyArrowPatch(
66                 points[-2], points[-1], arrowstyle='->',
mutation_scale=8,
67                 linewidth=.95, color=color, linestyle=linestyle,
68                 shrinkA=0, shrinkB=0, zorder=2))
69
70     lane(2.14, 2.21, '质量评价', PURPLE)
71     lane(.44, 1.57, '配比回归', TEAL)
72
73     # Upper lane: normalized quality signals drive both
scoring and diagnostics.
74     node(.20, 2.95, 1.88, 1.01, 'A1—A3 质量信号',
75         '22 项指标的缺失处理\n列表标量化、方向统一\n归一化并
保留领域标签', PURPLE)
76     node(2.55, 3.06, 1.50, .90, '熵权综合评价',
77         '样本与语料评分\n领域质量评分', PURPLE)
78     node(4.54, 3.06, 1.72, .90, 'A16 领域映射',
79         '构造配比加权\n质量指数', PURPLE)
80     node(.20, 2.18, 1.88, .64, '指标冲突诊断',
81         '成对标准化差异\nKendall 并列秩校正', GOLD, body_size
=9)
82
83     arrow([(2.11, 3.50), (2.50, 3.50)], PURPLE)
84     arrow([(4.08, 3.50), (4.49, 3.50)], PURPLE)
85     arrow([(1.14, 2.92), (1.14, 2.85)], GOLD)
86
87     # Lower lane: exactly the same four stages as the existing
manuscript.

```

```

88     y, w, h = .59, 1.40, 1.04
89     node(.18, y, w, h, 'A4—A5 配方与损失',
90         '按 index 对齐\n17 域训练配比\n13 域验证损失', TEAL,
body_size=9)
91     node(1.76, y, w, h, '岭回归与核岭',
92         '线性系数解释\n核岭同尺度预测', TEAL)
93     node(3.34, y, w, h, '检验与跨尺度',
94         '1M / 60M / 1B 检验\n10B / 70B 外推表', BLUE,
body_size=9)
95     node(4.92, y, w, h, '核岭支持域推荐',
96         '训练配方凸组合\n固定未测量域\n保留配比上限', GOLD,
body_size=9)
97     for right, left in [(1.58, 1.76), (3.16, 3.34), (4.74,
4.92)]:
98         arrow([(right + .025, 1.105), (left - .025, 1.105)],
TEAL)
99
100     # The quality term is an incremental diagnostic, not the
sole regression input.
101     arrow([(5.40, 3.02), (5.40, 2.20), (2.46, 2.20), (2.46,
1.66)]),
102         color=PURPLE, dashed=True)
103     ax.text(3.88, 2.31, '追加质量项的冗余特征对照', fontsize
=9,
104         color=PURPLE, ha='center', va='center',
105         bbox={'boxstyle': 'square,pad=.15',
106             'facecolor': _tint(PURPLE, .045), 'edgecolor
': 'none'}, zorder=5)
107
108     # Compact line-style key; figure number and caption remain
in the LaTeX file.
109     arrow([(0.22, .21), (.62, .21)], GRAY)
110     ax.text(.72, .21, '主要处理流程', fontsize=9, va='center',
color=GRAY)
111     arrow([(3.08, .21), (3.48, .21)], PURPLE, dashed=True)
112     ax.text(3.58, .21, '冗余质量特征对照', fontsize=9, va='
center', color=GRAY)
113

```

```

114     save(fig, '图8_问题一求解流程', out)
115
116
117 if __name__ == '__main__':
118     import argparse
119     from 展示风格公共 import configure
120     parser = argparse.ArgumentParser(description=__doc__)
121     parser.add_argument('--output-dir', type=Path, required=
True)
122     args = parser.parse_args()
123     configure()
124     plot_workflow(None, args.output_dir)

```

Listing 16: 问题一流程图（求解/问题一/展示风格流程.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
   构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序由 OpenAI Codex（GPT-5.6-Luna）辅助实现；仅从保存的验
   证结果绘图。
3  """核岭增强的证据图：逐域精度及逐配方平均损失；不重新拟合。"""
4  from pathlib import Path
5  import numpy as np
6  import pandas as pd
7  import matplotlib.pyplot as plt
8  from 展示风格公共 import PURPLE, TEAL, configure
9  from 绘图数据 import DOMAIN_NAMES
10 from 出版导出 import export_figure
11
12
13 def plot_nonlinear(data, out):
14     table = data.nonlinear_domains
15     table = table[table.scope.eq('1m')]
16     a = table[table.model.eq('ridge')].set_index('loss_domain'
   )
17     b = table[table.model.eq('sqrt_krr')].set_index('
   loss_domain').loc[a.index]
18     pred = data.nonlinear_predictions
19     pred = pred[pred.scope.eq('1m') & pred.model.eq('sqrt_krr'
   )]

```

```

20     p = pred.groupby('index')[['observed','predicted']].mean()
21     assert len(p) == 256 and len(a) == 13 and len(pred) ==
3328
22     configure()
23     fig, axes = plt.subplots(1, 2, figsize=(5.92, 3.65),
gridspec_kw={'width_ratios':[1.1,1]})
24     ax = axes[0]; y = np.arange(len(a))
25     for i in y:
26         ax.plot([a.R2.iloc[i], b.R2.iloc[i]], [i,i], color='#
CAD1D9', lw=1.4)
27     ax.scatter(a.R2,y,s=24,marker='o',color=PURPLE,label='线性
岭')
28     ax.scatter(b.R2,y,s=29,marker='D',color=TEAL,label='平方根
核岭')
29     ax.set(yticks=y, yticklabels=[DOMAIN_NAMES[d] for d in a.
index], xlim=(0,1.025),
30             xlabel='逐域  $R^2$ ', title='(a) 同尺度预测精度')
31     ax.invert_yaxis(); ax.grid(axis='x'); ax.tick_params(
labels=8)
32     ax.legend(loc='lower left', bbox_to_anchor=(-.04,-.34),
ncol=2, fontsize=8,
33             handletextpad=.3, columnspacing=.9)
34     ax=axes[1]
35     ax.scatter(p.observed,p.predicted,s=9,alpha=.6,color=TEAL,
edgecolors='none')
36     lim=[min(p.min())-.08,max(p.max())+.08]
37     ax.plot(lim,lim,color='#79818C',ls='--',lw=.9)
38     ax.set(xlim=lim,ylim=lim,xlabel='观测平均损失',ylabel='预
测平均损失',
39           title='(b) 256 组检验配方')
40     ax.set_aspect('equal', adjustable='box');ax.grid()
41     rmse=np.sqrt(np.mean((p.observed-p.predicted)**2))
42     ax.text(.04,.95,f'配方均值 RMSE = {rmse:.4f}',transform=ax
.transAxes,va='top',fontsize=8)
43     for ax in axes:
44         ax.title.set_fontsize(9); ax.xaxis.label.set_fontsize
(9);ax.yaxis.label.set_fontsize(9)
45     fig.subplots_adjust(left=.14,right=.99,bottom=.22,top=.91,

```

```

wspace=.42)
46     export_figure(fig, str(Path(out) / '图9_非线性代理对照'),
    formats=['png', 'svg'],
47         dpi=400, size_inches=(5.92, 3.65), tight=False)
48     # 统一矢量文本行尾并去除导出时钟，保持版本对照稳定。
49     svg = Path(out) / '图9_非线性代理对照.svg'
50     svg.write_text('\n'.join(line.rstrip() for line in svg.
    read_text(encoding='utf-8').splitlines()
51         if '<dc:date>' not in line) + '\n',
    encoding='utf-8')
52     plt.close(fig)

```

Listing 17: 问题一核岭验证图（求解/问题一/展示风格非线性.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  """
4  scipilot-figure-skill :: export_figure.py
5  =====
6  Unified figure export to multiple formats at exact final size.
7
8  - Vector preferred: PDF / SVG / EPS for line/bar/scatter (
    lossless, journal-friendly).
9  - Raster for photos / micrographs: PNG / TIFF at >= 300 DPI;
    never JPEG for data figures.
10 - Embeds TrueType fonts (fonttype 42) so journals don't reject
    Type-3 PDFs.
11 - Optional grayscale preview to sanity-check colorblind safety
    .
12
13 Usage
14 -----
15     from export_figure import export_figure
16     import matplotlib.pyplot as plt
17
18     fig, ax = plt.subplots()
19     ax.plot([0,1,2],[3,1,4])

```

```

20
21     paths = export_figure(
22         fig,
23         basename="figs/fig1_main",
24         formats=["pdf", "svg", "png"],
25         size_inches=(3.5, 2.625),    # 强制成 Nature 单栏尺寸
26         dpi=600,
27         grayscale_preview=True,
28     )
29     # -> ['figs/fig1_main.pdf', 'figs/fig1_main.svg',
30     #     'figs/fig1_main.png', 'figs/fig1_main_grayscale.png']
31
32 CLI: ``python export_figure.py demo`` 生成一张演示图并多格式导
    出。
33 """
34 from __future__ import annotations
35
36 import argparse
37 import os
38 import sys
39 from typing import Iterable
40
41 import matplotlib.pyplot as plt
42
43
44 VECTOR_FORMATS = {"pdf", "svg", "eps"}
45 RASTER_FORMATS = {"png", "tiff", "tif", "jpg", "jpeg"}
46 SUPPORTED_FORMATS = VECTOR_FORMATS | RASTER_FORMATS
47
48
49 def _ensure_parent(path: str) -> None:
50     parent = os.path.dirname(os.path.abspath(path))
51     if parent and not os.path.exists(parent):
52         os.makedirs(parent, exist_ok=True)
53
54
55 def export_figure(

```

```

56     fig,
57     basename: str,
58     formats: Iterable[str] | None = None,
59     dpi: int = 300,
60     size_inches: tuple[float, float] | None = None,
61     grayscale_preview: bool = False,
62     tight: bool = True,
63     pad_inches: float = 0.05,
64     transparent: bool = False,
65 ) -> list[str]:
66     """
67     Export a matplotlib Figure to one or more formats at exact
68     final size.
69
70     Args:
71         fig: matplotlib Figure object.
72         basename: 输出路径前缀（不含扩展名）；可包含子目录，自
73             动创建。
74         formats: list/tuple of extensions, e.g. ['pdf', 'svg',
75             'png'].
76             Default: ['pdf', 'svg', 'png'].
77         dpi: raster 格式分辨率；建议 300（普通）/ 600（IEEE
78             等）。
79         size_inches: (width, height) 英寸；指定后会 fig.
80             set_size_inches() 强制
81             最终尺寸。强烈建议传入——保证导出后不必在 Word/
82             LaTeX 里二次缩放。
83         grayscale_preview: 额外生成一张 _grayscale.png 供色盲
84             安全检查。
85         tight: 是否走 bbox_inches='tight'（裁掉留白）。
86         pad_inches: tight 模式下保留的边距（英寸）。
87         transparent: 透明背景（PPT/海报可能需要）。
88
89     Returns:
90         实际写出的文件路径列表。
91     """
92     if formats is None:
93         formats = ("pdf", "svg", "png")

```

```

87     formats = [f.lower().lstrip(".") for f in formats]
88     unknown = [f for f in formats if f not in
SUPPORTED_FORMATS]
89     if unknown:
90         raise ValueError(f"Unsupported formats: {unknown}. "
91                           f"Supported: {sorted(
SUPPORTED_FORMATS)}")
92
93     if size_inches is not None:
94         if len(size_inches) != 2:
95             raise ValueError("size_inches must be (width,
height)")
96         fig.set_size_inches(*size_inches)
97
98     # 强制嵌入 TrueType 字体 (fonttype 42) ; 多家期刊明确拒绝
Type-3 PDF。
99     plt.rcParams["pdf.fonttype"] = 42
100    plt.rcParams["ps.fonttype"] = 42
101    plt.rcParams["svg.fonttype"] = "none" # 文本仍可编辑, 期
刊通常更欢迎
102
103    saved: list[str] = []
104    for fmt in formats:
105        if fmt in {"jpg", "jpeg"}:
106            print(f"[scipilot-figure-skill] WARNING: skipping
{fmt} — "
107                  "JPEG is lossy and unsuitable for line/text
figures.",
108                  file=sys.stderr)
109            continue
110        path = f"{basename}.{fmt}"
111        _ensure_parent(path)
112        kwargs: dict = {
113            "bbox_inches": "tight" if tight else None,
114            "pad_inches": pad_inches,
115            "transparent": transparent,
116        }
117        if fmt in RASTER_FORMATS:

```

```

118         kwargs["dpi"] = dpi
119         fig.savefig(path, **kwargs)
120         saved.append(path)
121         print(f"[scipilot-figure-skill] wrote {path}")
122
123     if grayscale_preview:
124         gray_path = _grayscale_from(fig, basename, dpi=dpi)
125         if gray_path:
126             saved.append(gray_path)
127     return saved
128
129
130 def _grayscale_from(fig, basename: str, dpi: int) -> str |
None:
131     """
132     导出灰度预览版用于色盲安全检查。
133     优先用 PIL 转灰度；找不到 PIL 时退化为重新画图（关闭颜
134     色）。
135     """
136     try:
137         from PIL import Image
138     except ImportError:
139         print("[scipilot-figure-skill] Pillow not available; "
140             "grayscale preview skipped.", file=sys.stderr)
141         return None
142
143     png_path = f"{basename}.png"
144     _ensure_parent(png_path)
145     fig.savefig(png_path, dpi=dpi, bbox_inches="tight")
146
147     gray_path = f"{basename}_grayscale.png"
148     Image.open(png_path).convert("L").save(gray_path)
149     print(f"[scipilot-figure-skill] wrote {gray_path} (
150     grayscale preview)")
151     return gray_path
152
153 def _demo(out_basename: str) -> None:

```

```

153     """Generate a small demo figure for quick smoke testing.
154     """
155     import numpy as np
156     rng = np.random.default_rng(7)
157     x = np.linspace(0, 10, 50)
158     y1 = np.sin(x) + rng.normal(0, 0.1, x.size)
159     y2 = np.cos(x) + rng.normal(0, 0.1, x.size)
160
161     fig, ax = plt.subplots(figsize=(3.5, 2.625))
162     ax.plot(x, y1, label="sin", marker="o", markersize=3)
163     ax.plot(x, y2, label="cos", marker="s", markersize=3,
164             linestyle="--")
165     ax.set_xlabel("x")
166     ax.set_ylabel("y")
167     ax.legend(frameon=False)
168
169     paths = export_figure(
170         fig, out_basename,
171         formats=["pdf", "svg", "png"],
172         size_inches=(3.5, 2.625),
173         dpi=300,
174         grayscale_preview=True,
175     )
176     print("\nDemo done. Files:")
177     for p in paths:
178         print(f"  {p}")
179
180 def _cli() -> int:
181     p = argparse.ArgumentParser(description="scipilot-figure-
182     skill figure exporter")
183     p.add_argument("cmd", choices=["demo"], help="`demo`: 跑一
184     张演示图导出 4 种格式")
185     p.add_argument("--out", default="./scipilot_demo",
186                     help="输出 basename (默认 ./scipilot_demo)"
187     )
188     args = p.parse_args()
189     if args.cmd == "demo":

```

```

186         _demo(args.out)
187     return 0
188
189
190 if __name__ == "__main__":
191     sys.exit(_cli())

```

Listing 18: 出版图形导出（求解/问题一/出版导出.py）

```

1  # 本绘图程序及代码在人工智能工具 Codex 辅助下完成。
2  # 开发机构：OpenAI；模型：GPT-5.6-Luna（2026-07-09）。
3  # 仅读取既有附件、参数和结果绘图，不重新拟合或修改结果数据。
4  """问题二图表：读取既有参数及附件，不重新拟合或覆盖跨问共享结果。
5
6  运行：python 重绘图表.py
7  依赖：numpy pandas scipy matplotlib；字体：Windows 宋体、Times
      New Roman。
8  输出：原图片目录中的同名 PNG；不写入任何结果或参数文件。
9  """
10 from pathlib import Path
11 import argparse
12 import json
13 import numpy as np
14 import pandas as pd
15 import matplotlib
16 matplotlib.use('Agg')
17 import matplotlib.pyplot as plt
18 from matplotlib import font_manager as fm
19 from matplotlib.colors import LinearSegmentedColormap,
      Normalize
20 from matplotlib.patches import FancyBboxPatch, FancyArrowPatch
21 from matplotlib.ticker import ScalarFormatter, NullLocator,
      NullFormatter
22 from scipy.cluster.hierarchy import linkage, leaves_list
23 from scipy.spatial.distance import squareform
24
25 HERE = Path(__file__).resolve().parent
26 ROOT = HERE.parents[1]

```

```

27 BLUE, TEAL, RED, GRAY = '#665080', '#367E73', '#CB8B38', '
    #45414C'
28 PALE, INK = '#FAF8F4', '#302F3D'
29 CMAP = LinearSegmentedColormap.from_list('effect', ['#FAF3D8',
    '#D8B979', '#AD8792', '#6D527D', '#382F58'])
30
31
32 def render_all(data_root=None):
33     data_root = Path(data_root) if data_root else ROOT.parent
    / 'real_attachments'
34     if not data_root.is_dir():
35         data_root = ROOT / 'real_attachments'
36     if not data_root.is_dir():
37         raise FileNotFoundError('未找到 real_attachments, 请使
    用 --data-dir 指定附件根目录。')
38     figdir = HERE / '图片'
39     figdir.mkdir(exist_ok=True)
40     fontdir = Path('C:/Windows/Fonts')
41     for name in ['simsun.ttc', 'times.ttf', 'timesi.ttf', '
    timesbd.ttf']:
42         if (fontdir / name).exists():
43             fm.fontManager.addfont(str(fontdir / name))
44     for family in ['SimSun', 'Times New Roman']:
45         fm.findfont(family, fallback_to_default=False)
46     plt.rcParams.update({
47         'font.family': ['Times New Roman', 'SimSun'], 'font.
    size': 11,
48         'axes.titlesize': 11.5, 'axes.labelsize': 11, 'xtick.
    labelsize': 10,
49         'ytick.labelsize': 10, 'legend.fontsize': 9.5,
50         'mathtext.fontset': 'stix', 'axes.unicode_minus':
    False,
51         'axes.edgecolor': '#9AA8B3', 'axes.linewidth': .7,
52         'axes.labelcolor': INK, 'text.color': INK,
53         'xtick.color': INK, 'ytick.color': INK,
54         'axes.spines.top': False, 'axes.spines.right': False,
55         'grid.color': '#E0E7ED', 'grid.linewidth': .6,
56         'legend.frameon': False, 'pdf.fonttype': 42,

```

```

57         'savefig.dpi': 400, 'figure.facecolor': 'white', 'axes
    .facecolor': 'white',
58     })
59     bdir = data_root / 'B_scaling_laws'
60     read = lambda f: pd.read_csv(bdir / f)
61     py = read('pythia_training_log_existing.csv')
62     b6 = read('supplementary_NQ_experiment.csv')
63     b7 = read('supplementary_NQ_experiment_expanded.csv')
64     b7n = b7[~b7.experiment_id.isin(b6.experiment_id)]
65     b8 = read('supplementary_NQ_experiment_large.csv')
66     b8c = b8[b8.data_type.eq('calibrated')]
67     par = pd.read_csv(HERE/'结果/广义标度律参数.csv').
    set_index('param').value
68     E,A,a,B,b,C,g = [float(par[k]) for k in ['E','A','alpha','
    B','beta','C','gamma']]
69     cl = pd.read_csv(HERE/'结果/经典标度律参数.csv').iloc[0]
70     def classic(N,D): return cl.E+cl.A*np.asarray(N)**(-cl.
    alpha)+cl.B*np.asarray(D)**(-cl.beta)
71     def model(N,D,Q): return E+A*np.asarray(N)**(-a)+B*np.
    asarray(D)**(-b)+C*(1-np.asarray(Q))*g
72     def save(fig, name):
73         from matplotlib.text import Text
74         # Dense automatic log minor ticks form a serrated edge
    at manuscript scale.
75         # Retain the scale, limits, major ticks and all
    plotted values.
76         for ax in fig.axes:
77             for axis, scale in [(ax.xaxis, ax.get_xscale()), (
    ax.yaxis, ax.get_yscale())]:
78                 if scale in ('log', 'symlog'):
79                     axis.set_minor_locator(NullLocator())
80                     axis.set_minor_formatter(NullFormatter())
81             for text in fig.findobj(Text):
82                 if text.get_text().strip() and text.get_fontsize()
    < 11:
83                     text.set_fontsize(11)
84             fig.savefig(figdir/f'{name}.png', bbox_inches='tight',
    pad_inches=.08)

```

```

85         plt.close(fig)
86     def axes_style(ax, axis='both'):
87         ax.set_axisbelow(True); ax.grid(True, axis=axis)
88     def note(ax, text, xy=(.04,.95)):
89         ax.text(*xy, text, transform=ax.transAxes, ha='left',
90 va='top', fontsize=9.5,
91             bbox=dict(facecolor='white',edgecolor='none',
92 alpha=.88,pad=2.5))
93
94     redesign(py,b6,b7,b7n,b8,b8c,read,model,classic,E,A,a,B,b,
95 C,g,save)
96     summarize_large_baseline(read, model)
97     print('已更新原图片目录中的八张 PNG; 模型参数未更改。')
98
99 def summarize_large_baseline(read, model):
100     """只读复现正文 B9/B10 对照表, 不改变模型或已有结果文件。
101     """
102     metadata = read('supplementary_large_models.csv')
103     losses = read('supplementary_large_baseline.csv')
104     matched = losses.merge(metadata, left_on='family',
105 right_on='model_name',
106                             how='left', validate='one_to_one',
107                             suffixes=('', '_meta'), indicator=
108 True)
109     assert matched['_merge'].eq('both').all()
110     for field in ['N_params_B', 'D_tokens_B']:
111         assert np.allclose(matched[field], matched[field + '_meta'])
112     excluded = metadata[~metadata.model_name.isin(losses.family)]
113     assert len(metadata) == 132 and len(matched) == 128
114     assert len(excluded) == 4 and excluded.D_tokens_B.eq(0).all()
115     prediction = model(matched.N_params_B, matched.D_tokens_B, 1.)
116     matched['absolute_relative_error'] = 100 * abs(prediction - matched.val_loss) / matched.val_loss

```

```

112     rows = []
113     for low, high, label in [(100, 300, '[100,300)'), (300,
114     1000, '[300,1000)'),
115     (1000, np.inf, '[1000,10000]')]:
116         group = matched[matched.N_params_B.ge(low) & matched.
117         N_params_B.lt(high)]
118         rows.append({'N / B': label, '记录数': len(group),
119         'D最小值': group.D_tokens_B.min(), 'D最大
120         值': group.D_tokens_B.max(),
121         'MAPE_%': group.absolute_relative_error.
122         mean()})
123     assert sum(row['记录数'] for row in rows) == len(matched)
124     assert matched.N_params_B.max() == 10000
125     print('B9/B10 一对一匹配; MAPE 对照 B10 估算值, 统一 Q=1:
126     ')
127     print(pd.DataFrame(rows).round(2).to_string(index=False))
128     return rows
129
130 def redesign(py,b6,b7,b7n,b8,b8c,read,model,classic,E,A,a,B,b,
131 C,g,save):
132     """改变视觉编码方式, 以附件记录和只读模型输出生成八张图。
133     """
134     from scipy.cluster.hierarchy import dendrogram
135     from matplotlib.lines import Line2D
136     def title(ax,s): ax.set_title(s,loc='left',pad=12,fontsize
137     =12)
138     def style(ax): ax.set_axisbelow(True);ax.grid(axis='x',
139     color='#E5E1E8');ax.tick_params(length=3)
140     def foot(fig,s): fig.text(.02,.012,s,fontsize=11,color=INK
141     ,ha='left')
142
143     # 0. Evidence lanes keep the conditional p transfer
144     outside the fitted N/D/Q equation.
145     fig,ax=plt.subplots(figsize=(7.8,3.5));ax.axis('off');ax.
146     set(xlim=(0,10),ylim=(0,4.1))
147     for x,num,label,col in [(.1,'01','数据依据',BLUE),(3.55,'
148     02','关系识别',TEAL),(7,'03','结果解释',RED)]:

```

```

137         ax.text(x,3.82,num,color=col,fontsize=23,va='center');
ax.text(x+.65,3.82,label,fontsize=13,va='center',color=col)
138     def box(x,y,w,h,head,body,col):
139         ax.add_patch(FancyBboxPatch((x,y),w,h,boxstyle='round,
pad=.025,rounding_size=.06',fc=PALE,ec='#E5E1E8',lw=.8))
140         ax.plot([x+.12,x+.12],[y+.15,y+h-.15],color=col,lw=3,
solid_capstyle='round')
141         ax.text(x+.27,y+h-.23,head,fontsize=11.5,color=col,va=
'center')
142         ax.text(x+.27,y+.22,body,fontsize=10,va='center')
143     def arrow(x,y,u,v,dash=False):
144         ax.add_patch(FancyArrowPatch((x,y),(u,v),arrowstyle='
-|>',mutation_scale=11,color=GRAY,lw=1.1,linestyle='--' if
dash else '-'))
145     for y,h,t,col in [(2.4,'B1 · 规模轨迹','1,176 个检查点',
BLUE),(1.25,'B6 · 质量实验','360 条半合成记录',TEAL),(.1,'问
题一 · 配比输出','线性系数 / 核岭损失差',RED)]:box(.1,y
,2.8,.86,h,t,col)
146     box(3.55,1.85,2.9,1.4,'规模—质量标度律',r'$E+AN^{\alpha}$'+BD^{\beta}$'+'\n'+r'$+\ C(1-Q)^{\gamma}$',BLUE)
147     box(3.55,.1,2.9,1.05,'配比影响分析','领域相似性 / 收益校准',RED)
148     box(7,2.4,2.85,.86,'跨来源检验','真实 / 半合成 / 估算',BLUE)
149     box(7,1.25,2.85,.86,'规模与质量取舍','弹性 / 等损失条件',TEAL)
150     box(7,.1,2.85,.86,'配比情景修正','在损失尺度可迁移时',RED)
151     arrow(2.95,2.8,3.5,2.8);arrow(2.95,1.68,3.5,2.05);arrow
(2.95,.53,3.5,.53)
152     arrow(6.5,2.8,6.95,2.8);arrow(6.5,2.1,6.95,1.68);arrow
(6.5,.53,6.95,.53,True)
153     fig.subplots_adjust(left=.01,right=.99,bottom=.01,top=.99)
;save(fig,'图0_问题二分析框架')
154
155     # 1. All B1 losses in a scale map, alongside per-model
residual distributions.
156     ns=np.sort(py.N_params_B.unique());ds=np.sort(py.
D_tokens_B.unique())

```

```

157     z=py.pivot(index='N_params_B',columns='D_tokens_B',values=
'val_loss').loc[ns,ds].to_numpy()
158     fig=plt.figure(figsize=(7.8,3.7));gs=fig.add_gridspec(1,2,
width_ratios=[1.15,1],wspace=.3)
159     ax=fig.add_subplot(gs[0]);ar=fig.add_subplot(gs[1])
160     edges=np.r_[ds[0]/np.sqrt(ds[1]/ds[0]),np.sqrt(ds[:-1]*ds
[1:]),ds[-1]*np.sqrt(ds[-1]/ds[-2])]
161     im=ax.pcolormesh(edges,np.arange(9)-.5,z,cmap=CMAP,shading
='flat')
162     ax.set(xscale='log',yticks=np.arange(8),yticklabels=[f'{n
:.2f}' for n in ns],xlabel='训练数据量 D / B tokens',ylabel=
'参数量 N / B',ylim=(-.5,7.5))
163     ax.set_xticks([.2,1,10,100]);ax.set_xticklabels(['0.2','1'
,'10','100']);title(ax,'(a) 附件记录的损失地图')
164     cb=fig.colorbar(im,cax=ax.inset_axes([0,1.16,1,.045]),
orientation='horizontal');cb.ax.tick_params(labelsize=11,
length=2)
165     ax.set_title('(a) 附件记录的损失地图',loc='left',pad=52,
fontsize=12)
166     residuals=[]
167     for n in ns:
168         sub=py[py.N_params_B.eq(n)];residuals.append((classic(
n,sub.D_tokens_B)-sub.val_loss).to_numpy()*1e4)
169     v=ar.violinplot(residuals,positions=np.arange(8),vert=
False,widths=.8,showextrema=False)
170     for body in v['bodies']:body.set(facecolor=BLUE,edgecolor=
BLUE,alpha=.24,linewidth=.7)
171     for j,err in enumerate(residuals):
172         ar.scatter(err,np.full(len(err),j),s=3,color=BLUE,
alpha=.2,edgecolors='none')
173         q25,med,q75=np.quantile(err,[.25,.5,.75]);ar.plot([q25
,q75],[j,j],color=BLUE,lw=3);ar.scatter(med,j,s=18,color=RED
,zorder=4)
174     ar.axvline(0,color=GRAY,ls='--',lw=.8);ar.set(yticks=np.
arange(8),yticklabels=[f'{n:.2f}' for n in ns],ylim
=(-.5,7.5),xlabel='预测残差 / 10-4')
175     ar.set_title('(b) 各参数规模的拟合残差',loc='left',pad=52,
fontsize=12);style(ar)

```

```

176     fig.subplots_adjust(left=.09,right=.985,bottom=.23,top
177     =.75)
177     foot(fig,'B1: 8 个模型 × 147 个检查点; 左图颜色表示验证损
        失。\\n右图: 记录点、四分位区间及金色中位点; 轮廓表示平滑密
        度。')
178     save(fig,'图1_经典标度律拟合')
179
180     # 2. Signed error distributions complement the summary-
        metric table.
181     sets=[('B4 跨族收敛点','真实',read('scaling_baseline.csv'
        ),1.,BLUE),('B5 文献标度数据','真实',read('
        published_scaling_data.csv'),1.,BLUE),
182         ('B7 新增质量点','半合成',b7n,b7n.Q_score,TEAL),('B2
        Cerebras','半合成',read('cerebras_training_log.csv'),1.,
        TEAL),
183         ('B8 校准段','半合成',b8c,1-b8c.Q_score,TEAL),('B10
        大规模损失','估算',read('supplementary_large_baseline.csv')
        ,1.,RED)]
184     fig,ax=plt.subplots(figsize=(6.2,3.8));rng=np.random.
        default_rng(20260925)
185     saved=pd.read_csv(HERE/'结果/广义标度律分层验证.csv');
        labels=[]
186     for j,(name,kind,df,q,col) in enumerate(sets):
187         y=df.val_loss.to_numpy();pred=model(df.N_params_B,df.
        D_tokens_B,q);err=100*(pred-y)/y;mape=np.mean(abs(err));r=np
        .corrcoef(y,pred)[0,1]
188         old=saved[saved.dataset.str.startswith(name.split()
        [0])].iloc[0]
189         assert np.isclose(mape,old['MAPE_%'],atol=1e-10) and
        np.isclose(r,old.r,atol=1e-10)
190         labels.append(f'{name}\\n{kind} · n={len(df):,}');ax.
        axhspan(j-.45,j+.45,color=PALE,zorder=0)
191         v=ax.violinplot([err],positions=[j],vert=False,widths
        =.62,showextrema=False);v['bodies'][0].set(facecolor=col,
        edgecolor=col,alpha=.2)
192         ax.scatter(err,j+rng.uniform(-.1,.1,len(err)),s=5,
        alpha=.26,color=col,lw=0)
193         q25,med,q75=np.quantile(err,[.25,.5,.75]);ax.plot([q25

```

```

, q75], [j, j], lw=3, color=col); ax.scatter(med, j, s=20, fc='white'
, ec=col, zorder=4)
194 ax.axvline(0, color=INK, lw=.8, ls='--'); ax.set(yticks=np.
arange(6), yticklabels=labels, ylim=(5.6, -.65), xlabel='有符号
相对误差 / %'); style(ax)
195 ax.set_xscale('symlog', linthresh=10); ax.set_xticks
([-50, -10, 0, 10, 100, 500]); ax.set_xticklabels(['-50', '-10', '0'
, '10', '100', '500'], fontsize=11)
196 fig.subplots_adjust(left=.26, right=.98, bottom=.25, top=.96)
197 foot(fig, '相对误差 =  $100 \times (\text{预测值} - \text{给定值}) / \text{给定值}$ ; 横
轴在  $\pm 10\%$  内线性。 \nB8 使用 1-Q; 空心点: 中位数; 粗线: 四分
位区间; 轮廓: 平滑密度。')
198 save(fig, '图2_广义标度律验证')
199
200 # 3. N-Q contour map and asymptotic loss increments; raw
design sites are explicit.
201 fig=plt.figure(figsize=(7.8, 3.7)); gs=fig.add_gridspec(1, 2,
width_ratios=[1.25, 1], wspace=.42)
202 ax=fig.add_subplot(gs[0]); ar=fig.add_subplot(gs[1]); q=np.
linspace(.1, 1, 240); n=np.geomspace(.07, 12, 240); Q, N=np.
meshgrid(q, n); Z=model(N, 300, Q)
203 cs=ax.contourf(Q, N, Z, levels=np.linspace(2.08, 3.15, 20), cmap
=CMAP, extend='both')
204 cont=ax.contour(Q, N, Z, levels=[2.2, 2.4, 2.6, 2.8, 3.0], colors=
'white', linewidths=.8); ax.clabel(cont, fmt='%.1f', fontsize=9,
inline_spacing=5, manual=[(.7, 6), (.55, 1.6), (.45, .45), (.3, .14)
, (.3, .075)])
205 design=b6[b6.D_tokens_B.eq(300)]; ax.scatter(design.Q_score
, design.N_params_B, s=9, facecolors='none', edgecolors=INK,
linewidths=.35, alpha=.5)
206 ax.set(yscale='log', xlabel='数据质量 Q', ylabel='参数量 N /
B', xlim=(.1, 1), ylim=(.07, 12)); title(ax, '(a) 规模—质量响应
面')
207 cb=fig.colorbar(cs, ax=ax, pad=.03, fraction=.06, ticks
=[2.2, 2.6, 3.0]); cb.set_label('预测损失', fontsize=10)
208 for j, (q0, col) in enumerate(zip([1., .6, .3], [TEAL, RED, BLUE
])):
209     floor=E+C*(1-q0)**g; ar.barh(j, floor-E, left=E, height

```

```

=.4,color=col,alpha=.85);ar.scatter(floor,j,s=50,color=col,
zorder=3);ar.text(floor+.012,j,f'{floor:.3f}',va='center',
color=col,fontsize=12)
210     ar.axvline(E,color=GRAY,ls='--',lw=1);ar.set(yticks
=[0,1,2],yticklabels=['Q = 1.0','Q = 0.6','Q = 0.3'],ylim
=(2.7,-.7),xlim=(1.62,2.015),xlabel='模型渐近损失')
211     ar.text(E,2.57,f'E = {E:.3f}',ha='center',fontsize=10,
color=GRAY);title(ar,'(b) 质量缺口对下限的抬升');style(ar)
212     fig.subplots_adjust(left=.085,right=.98,bottom=.23,top
=.85);foot(fig,'D=300 B tokens; 空心点: B6 实验位置; 底色与
等值线: 模型预测。');save(fig,'图3_质量边际影响')
213
214     # 4. Marginal response locations and a dumbbell comparison
of saved elasticities.
215     fig,axs=plt.subplots(1,3,figsize=(7.8,3.5),gridspec_kw={'
width_ratios':[1,1,1.35]})
216     nvals=np.array([.07,.3,1,3,12]);qvals=np.array
([.1,.3,.6,.9,.99])
217     for ax,effect,col,labels,xlabel,heading in [
218         (axs[0],a*A*nvals**(-a-1),BLUE,[f'{n:g}' for n in
nvals],r'$|\partial L/\partial N|_{\text{B}}^{-1}$','(a) 参数边际
效应'),
219         (axs[1],C*g*(1-qvals)**(g-1),RED,[f'{q:g}' for q in
qvals],r'$|\partial L/\partial Q|_{\text{B}}$', '(b) 质量边际效应')]:
220         ypos=np.arange(5)
221         ax.scatter(effect,ypos,color=col,s=42,zorder=3)
222         ax.set(yticks=ypos,yticklabels=labels,ylim=(4.5,-.6),
xlabel=xlabel);title(ax,heading);style(ax)
223         axs[0].set_xscale('log');axs[0].set_ylabel('参考参数量 N /
B')
224         axs[1].set(xlim=(.34,.391),ylabel='参考质量 Q',xticks
=[.35,.37,.39])
225         el=pd.read_csv(HERE/'结果/弹性与替代关系.csv');v=-el[['弹
性e_N','弹性e_D','弹性e_Q']].to_numpy();ar=axs[2]
226         for j in range(3):
227             ar.plot(v[:,j],[j,j],color='#E5E1E8',lw=5,zorder=1)
228             for i,col in enumerate([BLUE,TEAL]):
229                 ar.scatter(v[i,j],j,s=48,color=col,zorder=3,marker

```

```

=[ 'o', 'D' ][i], label=[ 'N=1, D=100', 'N=12, D=300' ][i] if j==0
else None)
230         ar.annotate(f'{v[i,j]:.3f}', (v[i,j], j), xytext
=(0, 10 if i==0 else -16), textcoords='offset points', ha='
center', fontsize=9, color=col)
231     ar.set(yticks=[0, 1, 2], yticklabels=['参数 N', '数据 D', '质量
Q'], ylim=(2.55, -.75), xlim=(.01, .112), xlabel='弹性绝对值')
232     title(ar, '(c) 两个参考点的敏感度'); style(ar); ar.legend(loc
='upper center', bbox_to_anchor=(.5, -.2), ncol=1, fontsize=9)
233     fig.subplots_adjust(left=.075, right=.98, bottom=.34, top
=.87, wspace=.62)
234     foot(fig, '左、中图：边际导数，各用自身量纲；右图：无量纲弹
性。\\n仅右图两个参考点均取 Q=0.6；N、D 以 B 为单位。'); save(
fig, '图4_边际效用对比')

235
236     # 5. Three original loss targets, separate panels,
explicit scale extrapolation.
237     fig, axs = plt.subplots(1, 3, figsize=(7.8, 3.25), sharex=True);
ng = np.geomspace(.07, 1e4, 1200); base = E + B * 300 ** (-b)
238     for ax, target, col in zip(axs, [2.30, 2.10, 1.95], [BLUE, TEAL,
RED]):
239         remaining = target - base - A * ng ** (-a); qreq = np.full_like(ng,
np.nan); valid = remaining >= 0
240         qreq[valid] = 1 - (remaining[valid] / C) ** (1 / g); qreq[(qreq
< .1) | (qreq > 1)] = np.nan
241         ax.axvspan(.07, 12, color=TEAL, alpha=.065); ax.axvspan
(12, 1e4, color=RED, alpha=.075); ax.axvline(12, color=GRAY, ls=':
', lw=1)
242         ax.plot(ng, np.where(ng <= 12, qreq, np.nan), color=col, lw
=2.5); ax.plot(ng, np.where(ng > 12, qreq, np.nan), color=col, lw=2,
ls='--')
243         ax.set(xscale='log', xlim=(.07, 1e4), ylim=(.08, 1.035),
xlabel='参数量 N / B', xticks=[.1, 10, 1e3], ylabel='所需质量 Q'
); title(ax, f'目标损失 L = {target:.2f}'); ax.grid(axis='y')
244         min_n = (A / (target - base)) ** (1 / a)
245         if .07 < min_n < 1e4:
246             ax.scatter(min_n, 1, s=32, color=col, zorder=3)
247             pos = (.74, .83) if target == 2.30 else ((.27, .48) if

```

```

target==2.10 else (.43,.73))
248         ax.annotate(f'Q=1\nN={min_n:.2f} B' if min_n<10
else f'Q=1\nN={min_n:.1f} B',(min_n,1),xytext=pos,textcoords
='axes fraction',fontsize=11,color=col,ha='center',va='top',
bbox=dict(facecolor=PALE,edgecolor='none',pad=1.5),
arrowprops=dict(arrowstyle='-',lw=.7,color=col))
249         if target==1.95:
250             ax.set_ylim(.95,1.008);ax.set_yticks([.96,.98,1]);
ax.text(.06,.1,'高质量区间放大',transform=ax.transAxes,
fontsize=10,color=col)
251     fig.subplots_adjust(left=.08,right=.985,bottom=.28,top
=.84,wspace=.42)
252     foot(fig,'D=300 B tokens; 实线:  $N \leq 12$  B; 虚线: 规模外推.\n
右图纵轴单独放大; 阴影区分拟合规模与外推规模。');save(fig,'
图5_质量参数替代')
253
254     # 6. All 17 domains via A-derived question-one
coefficients, not raw A refitting.
255     names={'arxiv':'学术预印本','freelaw':'法律判例','
nih_exporter':'科研项目','pubmed_central':'医学全文',
256             'wikipedia_en':'百科','dm_mathematics':'数学','github'
:'代码','philpapers':'哲学论文','stackexchange':'专业问答',
257             'enron_emails':'邮件','gutenberg_pg_19':'图书','
pile_cc':'网页','ubuntu_irc':'技术聊天','europarl':'议会记录
',
258             'hackernews':'科技社区','pubmed_abstracts':'医学摘要',
'uspto_backgrounds':'专利背景'}
259     coef=pd.read_csv(ROOT/'求解/问题一/结果/混合系数矩阵.csv')
.set_index('training_domain')
260     saved_sim=pd.read_csv(HERE/'结果/领域替代互补矩阵.csv',
index_col=0);coef=coef.loc[saved_sim.index]
261     center=coef.to_numpy()-coef.to_numpy().mean(axis=0);unit=
center/np.linalg.norm(center,axis=1,keepdims=True);sim=
unit@unit.T
262     assert np.allclose(sim,saved_sim.to_numpy(),atol=1e-12)
263     dist=np.sqrt(np.maximum(0,2*(1-sim)));np.fill_diagonal(
dist,0);tree=linkage(squareform(dist,checks=False),method='
average',optimal_ordering=True)

```

```

264     pairs=sorted([(sim[i,j],i,j) for i in range(17) for j in
range(i)],key=lambda t:t[0]);selected=list(reversed(pairs
[-4:]))+pairs[:4]
265     fig=plt.figure(figsize=(7.8,5.15));gs=fig.add_gridspec
(1,2,width_ratios=[1,1.48],wspace=.88)
266     ax=fig.add_subplot(gs[0]);ar=fig.add_subplot(gs[1])
267     dendrogram(tree,orientation='left',labels=[names[x] for x
in coef.index],ax=ax,color_threshold=0,above_threshold_color
=BLUE,leaf_font_size=10)
268     ax.set_xlabel('平均连接距离');title(ax,'(a) 17 域效应模式
聚类');ax.grid(axis='x');ax.spines[['top','right','left']].
set_visible(False)
269     labels=[]
270     for j,(value,i,k) in enumerate(selected):
271         col=TEAL if value>=0 else RED;labels.append(names[coef
.index[i]]+' / '+names[coef.index[k]])
272         ar.barh(j,value,height=.55,color=col,alpha=.85);ar.
text(value*.5,j,f'{value:+.3f}',ha='center',va='center',
fontsize=10,color='white')
273     ar.axvline(0,color=GRAY,lw=.8);ar.axhline(3.5,color='#
E5E1E8',lw=1.5)
274     ar.set(yticks=np.arange(8),yticklabels=labels,ylim
=(7.7,-.8),xlim=(-1.05,1.05),xlabel='中心化系数的余弦相似度'
);title(ar,'(b) 最相似与最相反的区域对');style(ar)
275     fig.subplots_adjust(left=.04,right=.98,top=.87,bottom=.17)
276     foot(fig,'聚类距离  $\sqrt{2-2s}$ ; 绿色: 效应趋同; 金色: 效应相
反。\\n右图列示 s 最大与最小的各 4 对; 相似性不代表互补增益。
');save(fig,'图6_领域替代互补')
277
278     # 7. Group correlation distributions rather than point
clouds mixing all groups.
279     fig,ax=plt.subplots(figsize=(7.8,3.1));rng=np.random.
default_rng(19)
280     datasets=[('B6',b6,BLUE),('B7',b7,TEAL),('B8 校准段',b8c,
RED),('B8 外推段',b8[b8.data_type.eq('extrapolated')],RED)];
labels=[]
281     for j,(name,df,col) in enumerate(datasets):
282         cors=np.array([group.Q_score.corr(group.val_loss) for

```

```

_,group in df.groupby(['N_params_B','D_tokens_B']) if group.
Q_score.nunique()>=3]);assert len(cors)>0
283     labels.append(f'{name}\n{len(df):,} 条记录 / {len(cors
)} 组');ax.axhspan(j-.44,j+.44,color=PALE)
284     ax.scatter(cors,j+rng.uniform(-.19,.19,len(cors)),s
=22,color=col,alpha=.43,lw=0);ax.scatter(cors.mean(),j,s=75,
marker='D',color=col,ec='white',lw=.9,zorder=4)
285     ax.text(1.13,j,f'{cors.mean():+.3f}',va='center',ha='
left',color=col,fontsize=12)
286     ax.axvline(0,color=GRAY,ls='--',lw=.9);ax.set(xlim
=(-1.08,1.42),ylim=(3.6,-.65),yticks=np.arange(4),
yticklabels=labels,xticks=[-1,-.5,0,.5,1],xlabel='固定 (N,D)
组内的 Pearson 相关系数')
287     ax.text(1.13,-.6,'组间均值',fontsize=10,ha='left');title(
ax,'质量字段与损失：组内方向及组间差异');style(ax)
288     fig.subplots_adjust(left=.21,right=.98,top=.84,bottom=.32)
289     foot(fig,'圆点：一个 (N,D) 组；菱形：组间均值。\\n均为半合
成数据；B7 含 B6，不构成独立证据。');save(fig,'图7_质量方向
对照')
290
291 if __name__=='__main__':
292     parser=argparse.ArgumentParser();parser.add_argument('--
data-dir');args=parser.parse_args()
293     render_all(args.data_dir)

```

Listing 19: 问题二正式绘图（求解/问题二/重绘图表.py）

```

1 # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
   构：OpenAI；版本发布日期：2026-07-09。
2 # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
   Luna）辅助。
3 """从已保存的 CSV 重绘论文图；不运行优化器，也不修改原始结果。
4
5 用法：python 求解/问题三/论文绘图.py
6 依赖：numpy、pandas、matplotlib。输出同名 PNG（300 dpi）和矢量
   PDF。
7 圆点对应 CSV 有效记录；缺失区间用虚线连接两端，仅引导视线，不
   补算或插值。
8 """

```

```

9  from pathlib import Path
10 import hashlib
11 import json
12 import numpy as np
13 import pandas as pd
14 import matplotlib
15 matplotlib.use("Agg")
16 import matplotlib.pyplot as plt
17 from matplotlib import font_manager as fm, ticker
18
19 ROOT = Path(__file__).resolve().parent
20 DATA, OUT = ROOT / "结果", ROOT / "图片"
21 FONT = ROOT.parents[1] / "论文" / "fonts" / "SourceHanSerifCN-
    Regular.otf"
22 fm.fontManager.addfont(str(FONT))
23 plt.rcParams.update({
24     "font.family": [fm.FontProperties(fname=str(FONT)).
        get_name(), "DejaVu Sans"],
25     "font.size": 10, "axes.labelsize": 10, "legend.fontsize":
        8.5,
26     "xtick.labelsize": 9, "ytick.labelsize": 9, "axes.
        unicode_minus": False,
27     "pdf.fonttype": 42, "savefig.dpi": 300, "axes.linewidth":
        .7,
28 })
29 BLUE, ORANGE, CYAN, PURPLE = "#356B9A", "#C87530", "#238A8D",
    "#8064A2"
30
31
32 AUDIT = {}
33
34 def read(name):
35     path = DATA / (name + ".csv")
36     df = pd.read_csv(path)
37     AUDIT[name] = {"sha256": hashlib.sha256(path.read_bytes())
        .hexdigest(), "rows": len(df)}
38     return df
39

```

```

40
41 def finish(fig, name):
42     for ax in fig.axes:
43         ax.spines[["top", "right"]].set_visible(False)
44         ax.grid(axis="y", color="#E4E7EA", lw=.55)
45         ax.set_axisbelow(True)
46         ax.tick_params(which="both", direction="out", length
=3)
47     for ext in ("png", "pdf"):
48         fig.savefig(OUT / (name + "." + ext), bbox_inches="
tight", pad_inches=.07)
49     plt.close(fig)
50
51
52 def panel(ax, text):
53     ax.text(0, 1.045, text, transform=ax.transAxes, va="bottom
", fontsize=10)
54
55
56 def recover_grid(df, grid, key):
57     """将已输出的有效点放回原脚本定义的网格，显式暴露被跳过的
失败点。"""
58     output = pd.DataFrame({key: grid})
59     df = df.select_dtypes(include="number")
60     for col in df.columns:
61         if col != key:
62             output[col] = np.nan
63     for _, row in df.iterrows():
64         index = np.argmin(abs(np.log(grid / row[key])))
65         if not np.isclose(grid[index], row[key], rtol=1e-9):
66             raise ValueError(f"{key}={row[key]} 不属于原始扫描
网格")
67     for col in df.columns:
68         if col != key:
69             output.loc[index, col] = row[col]
70     return output
71
72

```

```

73 def measured_line(ax, x, y, *, color, lw=1.3, ls="--", label=
    None, marker="o", ms=2.5):
74     """实心标记只画有效记录；跨缺测的连接单独用点线，不生成任
        何中间数据。"""
75     x, y = np.asarray(x, float), np.asarray(y, float)
76     good = np.isfinite(x) & np.isfinite(y)
77     ax.plot(x, y, color=color, lw=lw, ls=ls, label=label)
78     ax.plot(x[good], y[good], ls="none", marker=marker, ms=ms,
        color=color)
79     ids = np.flatnonzero(good)
80     for left, right in zip(ids[:-1], ids[1:]):
81         if right-left > 1:
82             ax.plot(x[[left,right]], y[[left,right]], color=
                color, lw=lw, ls=":")
83
84
85 opt = read("三档预算最优配置").sort_values("C")
86 q0 = float(opt.iloc[0].Q)
87 fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.65), layout="
    constrained")
88 for col, color, marker, label in [("N_B", BLUE, "o", "参数量 (
    B) "),
89                                   ("D_B", CYAN, "s", "数据量
        (B tokens) ")]:
90     ax[0].plot(opt.C, opt[col], marker=marker, ls="--", color=
        color, lw=1.4,
91                ms=5, label=label)
92     for x, y in zip(opt.C, opt[col]):
93         label_value = f"{y:.1f}" if col == "D_B" else f"{y:.3f
        }"
94         ax[0].annotate(label_value, (x, y), xytext=(0, 8 if
        col == "D_B" else -13),
95                        textcoords="offset points", ha="center"
        , fontsize=8, color=color)
96 ax[0].set_yscale("log")
97 ax[0].set_ylim(.045, 10000)
98 ax[0].set_ylabel("规模 (对数刻度) ")
99 ax[0].legend(loc="upper left")

```

```

100 panel(ax[0], "(a) 参数量与数据量")
101 ax[1].plot(opt.C, opt.Q, "o--", color=ORANGE, lw=1.4, ms=5)
102 ax[1].axhline(q0, color="#777777", ls=":", lw=1)
103 for x, y in zip(opt.C, opt.Q):
104     ax[1].annotate(f"{y:.3f}", (x, y), xytext=(0, 8),
105                   textcoords="offset points",
106                   ha="center", fontsize=8)
107 ax[1].text(1.4e20, q0-.065, rf"基线 $Q_0={q0:.3f}$", fontsize
108           =9, color="#666666")
109 ax[1].set_ylim(.45, 1.12)
110 ax[1].set_ylabel(r"最优质量 $Q^*$")
111 panel(ax[1], "(b) 质量水平")
112 for a in ax:
113     a.set_xscale("log")
114     a.set_xlim(3.5e18, 3e24)
115     a.set_xticks(opt.C)
116     a.xaxis.set_minor_locator(ticker.NullLocator())
117     a.set_xlabel(r"算力预算 $C_{\mathrm{b}}$ (FLOPs) ")
118 finish(fig, "图1_三档预算最优配置")
119
120 sw = read("预算扫略").sort_values("C")
121 theta = (sw.Q-q0)/(1-q0)
122 valid = sw.Q.notna()
123 start = float(sw.loc[valid & (sw.Q > q0+1e-7), "C"].iloc[0])
124 sat = float(sw.loc[valid & (sw.Q >= 1-1e-7), "C"].iloc[0])
125 peak = sw.loc[sw.f_qual.idxmax()]
126 fig, axs = plt.subplots(1, 2, figsize=(7.2, 3.35), layout="
127 constrained")
128 a, b = axs
129 measured_line(a, sw.C, theta*100, color=ORANGE)
130 for col, color, ls, label in [("f_base", BLUE, "-", "基础训练"
131                               ),
132                               ("f_qual", ORANGE, "--", "质量提
133                               升"),
134                               ("f_attn", PURPLE, "-.", "注意力
135                               计算")]:
136     measured_line(b, sw.C, sw[col]*100, color=color, ls=ls,
137                   label=label, ms=2)

```

```

131 for aa in axs:
132     aa.set_xscale("log")
133     aa.set_xlim(1e18, 1e25)
134     aa.set_ylim(-3, 108)
135     aa.set_xticks([1e18, 1e20, 1e22, 1e24])
136     aa.xaxis.set_minor_locator(ticker.NullLocator())
137     aa.axvline(start, color="#777777", lw=.8, ls="--")
138     aa.axvline(sat, color="#777777", lw=.8, ls=":")
139     aa.axvspan(start, sat, color=ORANGE, alpha=.07)
140     aa.set_xlabel(r"算力预算  $C_{\mathrm{b}}$  (FLOPs) ")
141 a.set_ylabel(r"质量完成度  $\Theta$  (%) ")
142 b.set_ylabel("预算份额 (%) ")
143 panel(a, "(a) 质量由基线升至上界")
144 panel(b, "(b) 质量份额先升后降")
145 b.legend(loc="upper right", bbox_to_anchor=(1,.78), fontsize
        =8, framealpha=.95)
146 b.annotate(f"峰值 {peak.f_qual*100:.1f}%", (peak.C, peak.
        f_qual*100), xytext=(2e21, 42),
147         fontsize=8, arrowprops={"arrowstyle": "-", "color":
        ORANGE, "lw":.8})
148 zoom = a.inset_axes([.40, .14, .57, .50])
149 measured_line(zoom, sw.C, theta*100, color=ORANGE, ms=3)
150 zoom.set_xscale("log")
151 zoom.set_xlim(1e19, 1e20)
152 zoom.set_ylim(-4,104)
153 zoom.set_xticks([1e19,1e20])
154 zoom.set_xticklabels([r"$10^{19}$",r"$10^{20}$"],fontsize=8)
155 zoom.xaxis.set_minor_locator(ticker.NullLocator())
156 zoom.set_yticks([0,50,100])
157 zoom.tick_params(labelsize=8)
158 zoom.axvline(start,color="#777777",ls="--",lw=.8)
159 zoom.axvline(sat,color="#777777",ls=":",lw=.8)
160 zoom.text(.04,.9,"转移区间放大",transform=zoom.transAxes,
        fontsize=8)
161 zoom.grid(axis="y",color="#e4e7ea",lw=.5)
162 finish(fig, "图2_预算份额结构性转移")
163
164 ctx = read("上下文长度敏感性")

```

```

165 cont = recover_grid(read("上下文长度连续扫描"), np.geomspace
    (1024, 200000, 40), "L_ctx")
166 ql = read("上下文长度与最优质量")
167 fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.85), layout="
    constrained")
168 measured_line(ax[0], cont.L_ctx, cont.N_B, color=BLUE, label="
    扫描有效记录")
169 ax[0].plot(ctx.L_ctx, ctx.N_B, "s", color=BLUE, ms=4, label="
    C7 五档配置")
170 ax[0].set_ylabel(r"最优参数量  $N \times (B)$  ")
171 ax[0].set_ylim(2, 6.6)
172 ax[0].legend(loc="lower left", fontsize=8)
173 panel(ax[0], r"(a) 规模配置:  $10^{22}$  FLOPs")
174 for budget, color, ls, marker, label in [(1e19, ORANGE, "-", "
    o", r" $10^{19}$  FLOPs"),
175                                           (1e20, BLUE, "-", "s",
    r" $10^{20}$  FLOPs"),
176                                           (1e21, CYAN, "--", "^",
    r" $10^{21}$  FLOPs")]:
177     d = recover_grid(ql.loc[ql.C.eq(budget)], np.geomspace
    (1024, 150000, 14), "L_ctx")
178     measured_line(ax[1], d.L_ctx, d.Q, color=color, ls=ls,
    marker=marker, ms=3, label=label)
179 ax[1].set_ylim(.49, 1.085)
180 ax[1].set_ylabel(r"最优质量  $Q \times$  ")
181 ax[1].text(1600, .925, r" $10^{20}$  与  $10^{21}$  曲线重合",
    fontsize=8)
182 ax[1].legend(loc="center left", fontsize=8)
183 panel(ax[1], "(b) 不同预算下的质量响应")
184 for a in ax:
185     a.set_xscale("log")
186     a.set_xlim(850, 220000)
187     a.axvline(30000, color=PURPLE, ls=":", lw=1.1)
188     a.set_xticks([1e3, 1e4, 3e4, 1e5])
189     a.set_xticklabels([r" $10^3$ ", r" $10^4$ ", r" $3 \times 10^4$ ", r" $10^5$ 
    "])
190     a.xaxis.set_minor_locator(ticker.NullLocator())
191     a.set_xlabel(r"上下文长度  $L_{\mathrm{ctx}}$  (tokens) ")

```

```

192 finish(fig, "图3_上下文长度敏感性")
193
194 # 图4只使用成本函数对比.csv的九组求解记录, 不再绘制解析函数采
    样线。
195 comp = read("成本函数对比")
196 fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.85), layout="
    constrained")
197 budgets = sorted(comp.C.unique())
198 x = np.arange(len(budgets))
199 for i, (form, color) in enumerate([("幂函数型", BLUE), ("指数
    型", ORANGE), ("对数渐进型", CYAN)]):
200     d = comp.loc[comp.form.eq(form)].sort_values("C")
201     assert d.C.tolist() == budgets and len(d) == 3
202     for a, column, factor in [(ax[0], "Q", 1), (ax[1], "f_qual
    ", 100)]:
203         bars = a.bar(x+(i-1)*.24, d[column]*factor, width=.22,
            color=color, label=form)
204         a.bar_label(bars, labels=[f"{v:.3f}" if column == "Q"
            else f"{v:.1f}" for v in d[column]*factor], fontsize=8,
            padding=3, rotation=90)
205 for a in ax:
206     a.set_xticks(x, [rf"$10^{{{int(np.log10(c))}}}$" for c in
        budgets])
207     a.set_xlabel(r"算力预算  $\$C_{\mathrm{b}}$  (FLOPs) ")
208 ax[0].set_ylim(0, 1.3)
209 ax[1].set_ylim(0, 40)
210 ax[0].set_ylabel(r"最优质量  $\$Q^*\$")
211 ax[1].set_ylabel("质量投入份额 (%) ")
212 panel(ax[0], "(a) 质量水平")
213 panel(ax[1], "(b) 质量投入份额")
214 fig.legend(*ax[0].get_legend_handles_labels(), loc="outside
    lower center", ncol=3, frameon=False)
215 finish(fig, "图4_质量成本函数对比")
216
217 AUDIT["预算扫略"]["valid_Q"] = int(valid.sum())
218 AUDIT["预算扫略"]["missing_C"] = sw.loc[~valid, "C"].tolist()
219 AUDIT["上下文长度连续扫描"]["expected_grid_rows"] = 40
220 AUDIT["上下文长度连续扫描"]["missing_L_ctx"] = cont.loc[cont.$ 
```

```

    N_B.isna(), "L_ctx"].tolist()
221 AUDIT["上下文长度与最优质量"]["valid_rows_by_budget"] = {str(c
    ): len(d) for c,d in ql.groupby("C")}
222 (OUT / "论文绘图数据核验.json").write_text(json.dumps(AUDIT,
    ensure_ascii=False, indent=2), encoding="utf-8")
223
224 print(f"已生成四组 PNG/PDF; 扫描点 {len(sw)}, 有效点 {valid.
    sum()}。")
225 print(f"首次正投入 {start:.6g}; 首次饱和 {sat:.6g}; 份额峰值 {
    peak.f_qual:.6f}。")

```

Listing 20: 问题三正式绘图（求解/问题三/论文绘图.py）

```

1  # 本绘图程序在人工智能工具 Codex 辅助下完成。
2  # 开发机构：OpenAI；模型：GPT-5.6-Luna（2026-07-09）。
3  # 仅读取附件和已有计算结果，不拟合模型，不写入结果目录。
4  """重绘问题四的七幅图。运行时以 --data 指定 real_attachments
    目录。
5
6  例：python 重绘图表.py --data ../../../../real_attachments
7  可选 --audit 指定内部审查目录，输出可编辑 SVG、数据摘要和布局
    检查。
8  """
9  from pathlib import Path
10 import argparse
11 import hashlib
12 import json
13 import sys
14 import numpy as np
15 import pandas as pd
16 import matplotlib
17 matplotlib.use('Agg')
18 import matplotlib.pyplot as plt
19 from matplotlib import font_manager
20 from matplotlib.lines import Line2D
21
22 HERE = Path(__file__).resolve().parent
23 RESULT = HERE / '结果'
24 PURPLE, TEAL, GOLD, INK = '#665080', '#367E73', '#CB8B38', '

```

```

#302F3D'
25 TASKS = ['IFEval', 'BBH', 'MATH Lvl 5', 'GPQA', 'MUSR', 'MMLU-
    PRO']
26 LICENSES = {'apache-2.0', 'mit', 'gpl-3.0', 'cc-by-4.0', 'mpl
    -2.0',
27             'bsd-3-clause', 'llama2', 'llama3', 'llama3.1', '
    llama3.2',
28             'llama3.3', 'gemma', 'cc-by-sa-4.0', 'openrail'}
29 NAMES = {
30     'bbh_boolean_expressions': '布尔表达式', '
    bbh_causal_judgement': '因果判断',
31     'bbh_date_understanding': '日期理解', '
    bbh_disambiguation_qa': '歧义消解',
32     'bbh_formal_fallacies': '形式谬误', 'bbh_geometric_shapes':
    '几何形状',
33     'bbh_hyperbaton': '形容词排序', '
    bbh_logical_deduction_five_objects': '逻辑推断·5对象',
34     'bbh_logical_deduction_seven_objects': '逻辑推断·7对象',
35     'bbh_logical_deduction_three_objects': '逻辑推断·3对象',
36     'bbh_movie_recommendation': '电影推荐', 'bbh_navigate': '路
    径导航',
37     'bbh_object_counting': '对象计数', 'bbh_penguins_in_a_table
    ': '表格中的企鹅',
38     'bbh_reasoning_about_colored_objects': '彩色对象推理', '
    bbh_ruin_names': '名称变换',
39     'bbh_salient_translation_error_detection': '翻译错误识别',
    'bbh_snarks': '讽刺识别',
40     'bbh_sports_understanding': '体育知识理解', '
    bbh_temporal_sequences': '时间序列推理',
41     'bbh_tracking_shuffled_objects_five_objects': '位置跟踪·5对
    象',
42     'bbh_tracking_shuffled_objects_seven_objects': '位置跟踪·7
    对象',
43     'bbh_tracking_shuffled_objects_three_objects': '位置跟踪·3
    对象',
44     'bbh_web_of_lies': '真假陈述推理',
45     'math_algebra_hard': '代数', 'math_counting_and_prob_hard':
    '计数与概率',

```

```

46     'math_geometry_hard': '几何', '
math_intermediate_algebra_hard': '中级代数',
47     'math_num_theory_hard': '数论', 'math_prealgebra_hard': '初
等代数',
48     'math_precalculus_hard': '预备微积分',
49     'gpqa_diamond': 'Diamond', 'gpqa_extended': 'Extended', '
gpqa_main': 'Main',
50     'musr_murder_mysteries': '谋杀谜题', '
musr_object_placements': '物体摆放',
51     'musr_team_allocation': '团队分配',
52 }
53
54 def read(name):
55     return pd.read_csv(RESULT / (name + '.csv'))
56
57 def hashes():
58     return {str(p.relative_to(RESULT)): hashlib.sha256(p.
read_bytes()).hexdigest()
59             for p in RESULT.rglob('*') if p.is_file()}
60
61 def style():
62     # 固定原导出样式，避免依赖绘图者个人目录中的可选技能包。
63     plt.rcParams.update({'figure.dpi': 150, 'figure.figsize'
: [5, 3.5],
64                          'font.sans-serif': ['Arial', 'Helvetica', 'DejaVu Sans'],
65                          'font.serif': ['Noto Serif SC', 'Times New Roman', 'Times
', 'DejaVu Serif'],
66                          'lines.linewidth': 1.2, 'lines.markersize': 5, 'pdf.
fonttype': 42,
67                          'ps.fonttype': 42, 'savefig.dpi': 300})
68     for name in ['simSun.ttc', 'times.ttf']:
69         p = Path('C:/Windows/Fonts') / name
70         if p.exists():
71             font_manager.fontManager.addfont(str(p))
72     plt.rcParams.update({'font.family': ['Times New Roman', '
SimSun'], 'font.size': 10,
73                          'axes.labelsize': 10, 'axes.titlesize': 11, 'xtick.
labelsize': 9, 'ytick.labelsize': 9,

```

```

74         'text.color':INK, 'axes.labelcolor':INK, 'axes.
edgecolor':'#88838D',
75         'axes.spines.top':False, 'axes.spines.right':False, '
axes.unicode_minus':False,
76         'axes.linewidth':.6, 'legend.fontsize':9, 'legend.
frameon':False,
77         'svg.fonttype':'none', 'savefig.facecolor':'white',
78         'figure.constrained_layout.use':False, 'figure.
autolayout':False})
79
80 def grid(ax, axis='y'):
81     ax.grid(axis=axis, color='#E8E4E9', lw=.6)
82     ax.set_axisbelow(True)
83
84 def title(ax, label):
85     ax.set_title(label, loc='left', pad=9)
86
87 def save(fig, name, audit):
88     fig.canvas.draw()
89     issues = []
90     try:
91         from visual_qa import audit_layout
92         issues = audit_layout(fig)
93     except ImportError:
94         pass
95     if any(level == 'FAIL' for level, _ in issues):
96         raise RuntimeError(issues)
97     out = HERE / '图片' / (name + '.png')
98     fig.savefig(out, dpi=400)
99     if audit:
100         fig.savefig(audit / (name + '.svg'))
101         (audit / (name + '_layout.json')).write_text(json.
dumps(issues, ensure_ascii=False, indent=2), encoding='utf-8
')
102     plt.close(fig)
103     print(name, issues)
104
105 def bridge(audit):

```

```

106     df, fits = read('Loss_Benchmark映射明细'), read('
Loss_Benchmark映射').set_index('可比性')
107     fig, axes = plt.subplots(1, 2, figsize=(6.2, 3.05))
108     for ax, level, prefix, color, marker in zip(axes, ['高可比
', '中可比'], ['High', 'Medium'], [TEAL, PURPLE], ['D', 'o']):
109         d = df[df.Loss_Comparability.str.startswith(prefix)]
110         f = fits.loc[level]
111         assert len(d) == f['n']
112         ax.scatter(d.Val_Loss, d.LB_Average, s=25, color=color
, marker=marker, alpha=.75, edgecolors='white', linewidths
=.4)
113         x = np.linspace(d.Val_Loss.min(), d.Val_Loss.max(),
80)
114         ax.plot(x, f['截距'] + f['斜率']*x, color=color, lw
=1.7)
115         title(ax, f'{"(a)" if level == "高可比" else "(b)"} {
level} · n={len(d)}')
116         ax.set_xlabel('验证交叉熵损失')
117         grid(ax)
118         ax.text(.97, .93, f'$R^2$ = {f.R2:.2f}\nMAPE = {f["
MAPE_%"]:.1f}%', ha='right', va='top', transform=ax.
transAxes, fontsize=9)
119     axes[0].set(ylabel='Leaderboard 均分', ylim=(4.7, 6.6))
120     axes[1].set(ylim=(0, 65))
121     fig.subplots_adjust(left=.09, right=.98, bottom=.20, top
=.85, wspace=.30)
122     save(fig, '图1_Loss_Benchmark映射', audit)
123
124 def decomposition(audit):
125     df = read('规模时间分解')
126     fig, axes = plt.subplots(1, 2, figsize=(6.2, 3.45), sharey=
True)
127     for ax, (_, r), label in zip(axes, df.iterrows(), ['(a) C3
· 2019—2025', '(b) C1 · 2024年6—9月']):
128         v = [r['规模贡献分'], r['非规模贡献分'], r['前沿提升分
']]
129         ax.bar([0, 1, 2], v, bottom=[0, v[0], 0], color=[TEAL, GOLD
, PURPLE], width=.62)

```

```

130         ax.plot([.31,.69],[v[0],v[0]],lw=.7,color=INK)
131         ax.plot([1.31,1.69],[v[2],v[2]],lw=.7,color=INK)
132         for i, (value, y) in enumerate(zip(v,[v[0],v[2],v[2]]
):
133             ax.text(i, y+1.2, f'{value:.2f}',ha='center',
fontsize=10)
134         ax.set(xticks=[0,1,2],xticklabels=['规模代理项','非规
模剩余','总增量'],ylim=(0,67))
135         title(ax,label)
136         grid(ax)
137         ax.text(.03,.93,f'规模代理项 {r["规模占比%"]:.1f}%\n非
规模剩余 {r["非规模占比%"]:.1f}%', transform=ax.transAxes,va
='top',fontsize=9)
138         axes[0].set_ylabel('前沿提升 / 分')
139         fig.subplots_adjust(left=.10,right=.98,bottom=.17,top=.85,
wspace=.20)
140         save(fig,'图2_规模时间分解',audit)
141
142 def forecast(lb, audit):
143     par=read('logistic参数').iloc[0]
144     pred=read('前沿预测')
145     hist=read('前沿序列').query('Year <= 2023')
146     mon=lb.groupby(lb.date.dt.to_period('M'))['avg'].apply(
lambda s:s.nlargest(max(1,int(len(s)*.01))).mean())
147     times=np.array([p.year+(p.month-.5)/12 for p in mon.index
])
148     x=np.r_[hist.Year.to_numpy()+.5,times]
149     y=np.maximum.accumulate(np.r_[hist.cum_avg.to_numpy(),mon.
cummax().to_numpy()])
150     assert len(x)==par['n前沿点']
151     log=lambda xx:par.K/(1+np.exp(-par.r*(np.asarray(xx)-2019-
par['t0(2019起)'])))
152     assert np.allclose(log(pred.iloc[:,0]+2019),pred.
frontier_pred)
153     fig=plt.figure(figsize=(6.2,4.65))
154     gs=fig.add_gridspec(2,1,height_ratios=[1.35,1],hspace=.54)
155     ax=fig.add_subplot(gs[0]); last=2019+par.t_last
156     xx=np.linspace(x.min(),2027.3,250)

```

```

157     ax.axvspan(last,2027.4,color='#F3EFF6',zorder=0)
158     ax.plot(xx,log(xx),color=PURPLE,lw=1.6,label='logistic 曲线')
159     slow_x=np.linspace(last,2027.3,100)
160     slow_y=log(last+0.5*(slow_x-last))
161     assert np.allclose(log(last+0.5*(pred.iloc[:,0]+2019-last)),pred['情景_技术增速减半'])
162     ax.plot(slow_x,slow_y,color=GOLD,lw=1.4,ls='--',label='logistic 增长参数减半')
163     ax.plot(x,y,ls=':',lw=.8,color='#8E8994')
164     ax.scatter(x[:len(hist)],y[:len(hist)],color=GOLD,marker='s',s=25,label='C3 年度锚点',zorder=3)
165     ax.scatter(x[len(hist):],y[len(hist):],color=TEAL,marker='o',s=20,label='C1 月度前沿',zorder=3)
166     xp=pred.iloc[:,0].to_numpy()+2019
167     ax.scatter(xp,pred['情景_技术增速减半'],marker='v',s=23,color=GOLD,zorder=4)
168     ax.errorbar(xp,pred.frontier_pred,yerr=[pred.frontier_pred-pred['CI_low_5%'],pred['CI_high_95%]-pred.frontier_pred],
169               fmt='D',color=PURPLE,capsize=4,ms=4,label='曲线重拟合 5%—95%')
169     ax.set(xlim=(2019,2027.5),ylim=(0,75),xticks=[2019,2021,2023,2025,2027],ylabel='前沿得分 / 分')
170     ax.axvline(last,color='#ACA5B2',ls='--',lw=.8)
171     ax.text(last+.15,7,'预测期',fontsize=9,color=PURPLE)
172     title(ax,'(a) 历史前沿与曲线外推')
173     ax.legend(loc='upper left',ncol=2,fontsize=8,handlelength=1.4,columnspacing=.8)
174     grid(ax)
175     ax=fig.add_subplot(gs[1]); scen=read('前沿预测_结构外推情景')
176     styles=[('放缓',1,GOLD,'v'),('基准',0,TEAL,'o'),('扩容',2,PURPLE,'s')]
177     for name,i,color,mark in styles:
178         vals=[scen[scen['前瞻年数'].eq(yr)].iloc[i]['结构外推前沿'] for yr in [1,2]]
179         yy=np.array([1,0])+{'放缓':-.19,'基准':0,'扩容':.19}[name]

```

```

180         ax.scatter(vals,yy,color=color,marker=mark,s=32,label=
name)
181         for v,z in zip(vals,yy):
182             ax.text(v+.4,z,f'{v:.2f}',va='center',fontsize=9)
183         ax.set(yticks=[1,0],yticklabels=['2026-03','2027-03'],ylim
=(-.5,1.5),xlim=(50,73),xlabel='结构外推得分 / 分')
184         title(ax,'(b) 三种结构情景的分歧')
185         ax.legend(loc='upper right',ncol=3,fontsize=8,
handletextpad=.3,columnspacing=.8)
186         grid(ax,'x')
187         fig.subplots_adjust(left=.13,right=.98,bottom=.12,top=.92)
188         save(fig,'图3_能力前沿预测',audit)
189
190 def subtasks(audit):
191     df=read('C8逐任务聚合')
192     assert len(df)==37 and set(df['子任务'])==set(NAMES)
193     fig=plt.figure(figsize=(6.2,6.45))
194     gs=fig.add_gridspec(3,2,width_ratios=[1.12,1],
height_ratios=[7,3,3],wspace=.85,hspace=.76)
195     blocks=[(fig.add_subplot(gs[:,0]),'BBH子任务',PURPLE,'(a)
BBH · 24项'),
196             (fig.add_subplot(gs[0,1]),'MATH子任务',GOLD,'(b)
MATH · 7项'),
197             (fig.add_subplot(gs[1,1]),'GPQA子集',TEAL,'(c)
GPQA · 3项'),
198             (fig.add_subplot(gs[2,1]),'MUSR子任务','#38678E','
(d) MUSR · 3项')]
199     for ax,cat,color,label in blocks:
200         d=df[df['类别'].eq(cat)].sort_values('最优得分')
201         yy=np.arange(len(d))
202         assert (d['中位数']<=d['前5%均值']).all() and (d['前5%
均值']<=d['最优得分']).all()
203         ax.hlines(yy,d['中位数'],d['最优得分'],color=color,
alpha=.40,lw=2.5)
204         for col,mark,fill in [('中位数','o','white'),('前5%均
值','|',color),('最优得分','D',color)]:
205             if mark == '|':
206                 ax.scatter(d[col],yy,s=55,marker=mark,color=

```

```

color,linewidths=.9,zorder=3)
207         else:
208             ax.scatter(d[col],yy,s=20,marker=mark,
facecolors=fill,edgecolors=color,linewidths=.9,zorder=3)
209             ax.set(yticks=yy,yticklabels=[NAMES[k] for k in d['子
任务']],xlim=(-2,103),xticks=[0,50,100],ylim=(-.65,len(d)
-.35))
210             ax.invert_yaxis(); ax.tick_params(axis='y',length=0,
labelsize=8.5)
211             title(ax,label); grid(ax,'x')
212             ax.set_xlabel('原始指标 / 分',fontsize=9)
213             handles=[Line2D([],[],marker='o',mfc='white',mec=INK,ls='',
label='中位数'),Line2D([],[],marker='|',color=INK,ls='',
label='前5%均值'),Line2D([],[],marker='D',color=INK,ls='',
label='最优得分')]
214             fig.legend(handles=handles,loc='lower center',
bbox_to_anchor=(.52,.008),ncol=3,fontsize=9)
215             fig.subplots_adjust(left=.205,right=.98,bottom=.115,top
=.93)
216             save(fig,'图4_逐任务聚合',audit)
217
218 def macro(audit):
219     d=read('C4宏观趋势'); summary=read('C4宏观摘要').iloc[0]
220     fig=plt.figure(figsize=(6.2,4.75))
221     gs=fig.add_gridspec(2,2,height_ratios=[1.15,1],hspace=.72,
wspace=.32)
222     ax=fig.add_subplot(gs[0,:])
223     ax.vlines(d.year,d['前沿算力_中位'],d['前沿算力_max'],
color=TEAL,alpha=.5,lw=3)
224     ax.scatter(d.year,d['前沿算力_中位'],s=26,facecolors='
white',edgecolors=TEAL,label='年度中位数',zorder=3)
225     ax.scatter(d.year,d['前沿算力_max'],marker='D',s=25,color=
PURPLE,label='年度最大值',zorder=3)
226     ax.axvspan(2025.6,2026.4,color='#F5F0E6')
227     ax.text(2026,2e18,'5条算力记录',ha='center',fontsize=8,
rotation=90)
228     ax.set(yscale='log',ylim=(1e16,5e27),xlim=(2017.6,2026.4),
xticks=d.year, ylabel='训练算力 / FLOP')

```

```

229     ax.set_yticks([1e17,1e20,1e23,1e26]);title(ax,'(a)
Language 领域的算力跨度');grid(ax)
230     ax.legend(loc='upper left',ncol=2,fontsize=9)
231     ax=fig.add_subplot(gs[1,0])
232     ax.plot(d.year,d['开源权重占比']*100,color=TEAL,marker='o'
,ms=4,lw=1.2)
233     ax.axvspan(2025.6,2026.4,color='#F5F0E6')
234     ax.set(ylim=(0,100),yticks=[0,25,50,75,100],xticks
=[2018,2020,2022,2024,2026],xlabel='年份',ylabel='Yes 标记比
例 / %')
235     title(ax,'(b) 开放权重的收录比例');grid(ax)
236     ax=fig.add_subplot(gs[1,1])
237     counts=[int(summary['有算力记录行数']),int(summary['有数据
量记录行数']),int(summary['开源权重_Yes']+summary['开源权重
_No'])]
238     ax.barh([2,1,0],[3523]*3,color='#EFCF1',height=.5)
239     ax.barh([2,1,0],counts,color=[PURPLE,GOLD,TEAL],height=.5)
240     for yy,nn in zip([2,1,0],counts):ax.text(nn+65,yy,f'{nn:,'
,va='center',fontsize=9)
241     ax.set(yticks=[2,1,0],yticklabels=['算力','数据量','权重状
态'],xlim=(0,3800),xticks=[0,1500,3000],xlabel='有效记录数 /
条',ylim=(-.6,2.6))
242     title(ax,'(c) C4 全量字段覆盖')
243     fig.subplots_adjust(left=.105,right=.98,bottom=.12,top
=.92)
244     save(fig,'图5_C4宏观趋势',audit)
245
246 def distributions(lb,audit):
247     fig,ax=plt.subplots(figsize=(6.2,3.15))
248     order=['GPQA','MUSR','MATH Lvl 5','BBH','MMLU-PRO','IFEval
']
249     vals=[lb[t].to_numpy() for t in order]
250     # Full range is explicit; no data points are suppressed as
outliers.
251     bp=ax.boxplot(vals,orientation='horizontal',tick_labels=
order,whis=(0,100),showfliers=False,patch_artist=True,widths
=.52,
252                     medianprops={'color':INK,'lw':1.4},boxprops

```

```

    ={'edgecolor':PURPLE},whiskerprops={'color':PURPLE},capprops
    ={'color':PURPLE})
253     for patch in bp['boxes']:patch.set_facecolor('#E5DEED')
254     ax.invert_yaxis();ax.set(xlim=(0,100),xticks=np.arange
    (0,101,20),xlabel='C1 基准得分 / 分')
255     grid(ax,'x');ax.tick_params(axis='y',length=0)
256     fig.subplots_adjust(left=.16,right=.98,bottom=.20,top=.94)
257     save(fig,'图6_六维能力分布',audit)
258
259 def scale(audit):
260     d=read('面板回归数据');alpha=read('年份效应').set_index('
    Year')['年效应alpha_t'];bp=read('规模时间分解').iloc[1]['bP'
    ]
261     fig,axes=plt.subplots(1,2,figsize=(6.2,3.15),sharex=True,
    sharey=True)
262     for ax,year,color,mark in zip(axes,[2024,2025],[TEAL,
    PURPLE],['o','^']):
263         sub=d[d.Year.eq(year)]
264         ax.scatter(sub.P,sub.avg,c=color,s=6,alpha=.25,marker=
    mark,edgecolors='none')
265         xx=np.geomspace(sub.P.min(),sub.P.max(),150)
266         ax.plot(xx,alpha[year]+bp*np.log10(xx),color=INK,lw
    =1.4)
267         ax.set(xscale='log',xlim=(.001,220),ylim=(-35,60),
    xticks=[.001,.01,.1,1,10,100],xticklabels=['0.001','0.01','
    0.1','1','10','100'],xlabel='参数量 / B (对数轴)')
268         assert sub.P.between(.001,220).all() and sub.avg.
    between(-35,60).all()
269         ax.axhline(0,color='#B6AFBA',lw=.6,ls=':')
270         title(ax,f'{"(a)" if year==2024 else "(b)"} {year}年 ·
    n={len(sub):,}')
271         grid(ax)
272         axes[0].set_ylabel('Leaderboard 均分')
273         fig.subplots_adjust(left=.10,right=.98,bottom=.22,top=.85,
    wspace=.12)
274         save(fig,'图7_年度规模效应',audit)
275
276 def main():

```

```

277 ap=argparse.ArgumentParser(description=__doc__)
278 ap.add_argument('--data',type=Path,required=True)
279 ap.add_argument('--audit',type=Path)
280 args=ap.parse_args(); before=hashes();style()
281 if args.audit:args.audit.mkdir(parents=True,exist_ok=True)
282 src=args.data/'C_efficiency_evolution'
283 lb=pd.read_csv(src/'leaderboard_cleaned.csv')
284 lb['P']=pd.to_numeric(lb['#Params (B)'],errors='coerce')
285 lb['date']=pd.to_datetime(lb['Submission Date'],errors='
coerce')
286 lb['avg']=pd.to_numeric(lb['Average \u2b06\u2013'],errors=
'coerce')
287 lb[TASKS]=lb[TASKS].apply(pd.to_numeric,errors='coerce')
288 lb=lb[lb[TASKS].notna().all(axis=1)&lb.date.notna()&lb.P.
notna()&lb['Hub License'].astype(str).str.strip().str.lower
().isin(LICENSES)].copy()
289 assert len(lb)==2346
290 td=read('逐任务聚合').set_index('task')
291 for task in TASKS:
292     s=lb[task]
293     assert np.allclose([s.max(),s.nlargest(max(1,int(len(s)
)*.01)).mean(),s.median()],td.loc[task,['max','top1_mean','
median']]).astype(float))
294 actual=pd.read_csv(src/'loss_benchmark_bridge_expanded.csv
')
295 saved=read('Loss_Benchmark映射明细')
296 assert actual.Model.tolist()==saved.Model.tolist()
297 assert np.allclose(actual[['Val_Loss','LB_Average']],saved
[['Val_Loss','LB_Average']])
298 bridge(args.audit);decomposition(args.audit);forecast(lb,
args.audit);subtasks(args.audit)
299 macro(args.audit);distributions(lb,args.audit);scale(args.
audit)
300 assert before==hashes(),'绘图期间结果文件发生改变'
301 if args.audit:
302     report={'records':len(lb),'years':lb.date.dt.year.
value_counts().to_dict(),
303             'task_summary':lb[TASKS].describe().to_dict(),

```

```

    'result_files_unchanged':True,
304         'chart_contracts':{
305             '图1': '分层散点与已存拟合；仅组内损失范
            围；两面板纵轴不同。',
306             '图2': '两个窗口的代理核算；同一纵轴；非规
            模项为算术剩余，不识别因果贡献。',
307             '图3': '历史记录、模型曲线、仅两时点的曲线
            重拟合分位范围；结构情景独立面板。',
308             '图4': '37子任务中位数/前5%均值/最大值；原
            始指标；按类别分面。',
309             '图5': '年度算力跨度、Yes记录比例、全量字段
            覆盖；2026覆盖不完整。',
310             '图6': '2346条实际附件记录的四分位区间与完
            整极差；展示总体分布。',
311             '图7': '年度分面规模散点及既有固定效应直
            线；未重拟合。'}}
312     (args.audit/'plot_checks.json').write_text(json.dumps(
            report,ensure_ascii=False,indent=2),encoding='utf-8')
313
314 if __name__=='__main__':main()

```

Listing 21: 问题四正式绘图（求解/问题四/重绘图表.py）

```

1  # 本程序的整理与核对使用 Codex 辅助；模型：GPT-5.6-Luna；机
    构：OpenAI；版本发布日期：2026-07-09。
2  # 本程序的整理、复现核对或绘图实现使用 OpenAI Codex（GPT-5.6-
    Luna）辅助。
3  """按论文已有分析绘制问题三、四流程图，不读取数据、不运行求解
    模型。
4
5  运行：python 求解/绘制问题三四流程图.py
6  输出：论文/figures 下的 PDF、SVG、400 dpi PNG 及文字边界核验记
    录。
7  """
8  from pathlib import Path
9  import argparse
10 import json
11 import os
12 import tempfile

```

```

13
14 os.environ.setdefault('MPLCONFIGDIR', str(Path(tempfile.
    gettempdir()) / 'huawei-expand-mpl'))
15 import matplotlib
16 matplotlib.use('Agg')
17 import matplotlib.pyplot as plt
18 from matplotlib import font_manager
19 from matplotlib.colors import to_rgb
20 from matplotlib.patches import FancyArrowPatch, FancyBboxPatch
    , Rectangle
21
22 PURPLE, TEAL, GOLD, BLUE = '#665080', '#287C78', '#BC8030', '
    #365E8D'
23 INK, GRAY = '#243348', '#637186'
24
25
26 def configure():
27     for name in ('simsum.ttc', 'times.ttf', 'timesi.ttf', '
    timesbd.ttf'):
28         path = Path('C:/Windows/Fonts') / name
29         if path.exists():
30             font_manager.fontManager.addfont(str(path))
31     for family in ('SimSun', 'Times New Roman'):
32         font_manager.findfont(family, fallback_to_default=
    False)
33     plt.rcParams.update({
34         'font.family': ['Times New Roman', 'SimSun'], 'font.
    size': 10,
35         'mathtext.fontset': 'stix', 'axes.unicode_minus':
    False,
36         'text.color': INK, 'figure.facecolor': 'white',
37         'savefig.facecolor': 'white', 'pdf.fonttype': 42,
38         'svg.fonttype': 'path', 'svg.hashsalt': 'huawei-expand
    -workflows',
39     })
40
41
42 def tint(color, strength):

```

```

43     return tuple(1 - strength * (1 - value) for value in
to_rgb(color))
44
45
46 class Workflow:
47     def __init__(self, height):
48         self.fig = plt.figure(figsize=(6.5, height))
49         self.ax = self.fig.add_axes([0, 0, 1, 1])
50         self.ax.set(xlim=(0, 6.5), ylim=(0, height))
51         self.ax.axis('off')
52         self.labels = []
53
54     def text(self, x, y, text, size=10, color=INK, bounds=None
, **kwargs):
55         if '$' in text:
56             # Mathtext needs a Chinese-capable default font
for its non-math runs.
57             kwargs['fontfamily'] = 'SimSun'
58             artist = self.ax.text(x, y, text, fontsize=size, color
=color,
59                                 ha='center', va='center',
linespacing=1.4,
60                                 zorder=5, **kwargs)
61             self.labels.append((artist, bounds))
62
63     def box(self, x, y, w, h, title, content, color, size=10):
64         self.ax.add_patch(FancyBboxPatch(
65             (x, y), w, h, boxstyle='round,pad=0,rounding_size
=.045',
66             facecolor='white', edgecolor=tint(color, .55),
linewidth=.85,
67             zorder=3))
68         self.ax.add_patch(Rectangle(
69             (x+.012, y+h-.29), w-.024, .278, facecolor=tint(
color, .11),
70             edgecolor='none', zorder=4))
71         self.text(x+w/2, y+h-.145, title, 10.4, color,
72                 bounds=(x+.03, y+h-.28, w-.06, .26))

```

```

73         self.text(x+w/2, y+(h-.29)/2, content, size,
74                   bounds=(x+.04, y+.025, w-.08, h-.33))
75
76     def arrow(self, points, color=GRAY, dashed=False):
77         style = (0, (3, 2)) if dashed else '-'
78         if len(points) > 2:
79             xx, yy = zip(*points[:-1])
80             self.ax.plot(xx, yy, color=color, lw=.95,
81                           linestyle=style, zorder=2)
82             self.ax.add_patch(FancyArrowPatch(
83                 points[-2], points[-1], arrowstyle='->',
84                 mutation_scale=8,
85                 color=color, lw=.95, linestyle=style, shrinkA=0,
86                 shrinkB=0,
87                 zorder=2))
88
89     def lane(self, y, title, color):
90         self.ax.add_patch(FancyBboxPatch(
91             (.07, y), 6.36, 1.19,
92             boxstyle='round,pad=0,rounding_size=.055',
93             facecolor=tint(color, .04), edgecolor=tint(color,
94                 .19),
95             linewidth=.65, zorder=0))
96         self.ax.add_patch(Rectangle((.17, y+.97), .04, .14,
97                                     facecolor=color, edgecolor=
98                 'none'))
99         self.text(.29, y+1.04, title, 10.1, color)
100        self.labels[-1][0].set_ha('left')
101
102    def save(self, out, stem):
103        out.mkdir(parents=True, exist_ok=True)
104        self.fig.canvas.draw()
105        renderer = self.fig.canvas.get_renderer()
106        errors = []
107        for artist, bounds in self.labels:
108            box = artist.get_window_extent(renderer)
109            if bounds is None:
110                outer = self.fig.bbox

```

```

106         else:
107             x, y, w, h = bounds
108             from matplotlib.transforms import Bbox
109             outer = Bbox.from_bounds(x, y, w, h).
transformed(self.ax.transData)
110             if (box.x0 < outer.x0-1 or box.x1 > outer.x1+1 or
111                 box.y0 < outer.y0-1 or box.y1 > outer.y1
+1):
112                 errors.append(artist.get_text())
113             if errors:
114                 raise ValueError(f'{stem}: text exceeds bounds: {
errors}')
115             self.fig.savefig(out / f'{stem}.pdf', metadata={
116                 'Title': stem, 'CreationDate': None, 'ModDate':
None})
117             svg = out / f'{stem}.svg'
118             self.fig.savefig(svg, metadata={'Date': None})
119             svg.write_text('\n'.join(line.rstrip() for line in
120                                     svg.read_text(encoding='utf-8
').splitlines()))+'\n',
121                             encoding='utf-8')
122             self.fig.savefig(out / f'{stem}.png', dpi=400)
123             (out / f'{stem}-layout.json').write_text(json.dumps({
124                 'canvas_inches': list(self.fig.get_size_inches()),
125                 'text_count': len(self.labels), '
text_bounds_issues': errors,
126                 'scope': 'Text within nodes and canvas; visual
review also required.',
127                 }, ensure_ascii=False, indent=2)+'\n', encoding='utf-8
')
128             plt.close(self.fig)
129             print(f'{stem}: exported PDF/SVG/PNG, text bounds
passed')
130
131
132 def q3(out):
133     f = Workflow(5.18)
134     f.box(.15, 4.02, 1.96, 1.00, '问题一：质量与配比',

```

```

135         '配比加权质量  $Q_0$ \n配比修正  $M$ ', PURPLE)
136     f.box(2.27, 4.02, 1.96, 1.00, '问题二：损失关系',
137         '广义标度律参数\n构建  $L(N,D,Q)$ ', TEAL)
138     f.box(4.39, 4.02, 1.96, 1.00, '题设：预算与费用',
139         '训练、质量、注意力\n预算与上下文条件', BLUE)
140     for x in (1.13, 3.25, 5.37):
141         f.arrow([(x, 3.995), (x, 3.79), (3.25, 3.79), (3.25,
142 3.72)]))
143     f.box(.15, 2.77, 6.2, .91, '构建预算约束下的资源配置模型',
144         '以预测验证损失最小为目标，合计三类算力费用\n'
145         r' $C_{\mathrm{tot}} \leq C_{\mathrm{b}}, \quad Q_0 \leq Q \leq 1$ '
146         '; 固定配比与上下文，统一规模计量口径', PURPLE)
147     f.arrow([(3.25, 2.74), (3.25, 2.55)], PURPLE)
148     f.box(.15, 1.60, 6.2, .91, '多初值 SLSQP 求解',
149         r'采用  $\ln N, \ln D$  与  $Q$ ; 三档预算设 8 组初值，
150 预算扫描设 5 组'
151         '\n比较求解成功的结果，取其中损失最低者，并处理质量
152 上界', TEAL)
153     for x in (1.13, 3.25, 5.37):
154         f.arrow([(3.25, 1.57), (3.25, 1.44), (x, 1.44), (x,
155 1.36)]), TEAL)
156     f.box(.15, .23, 1.96, 1.09, '三档预算配置',
157         '参数、数据与质量\n预测损失与费用份额\n比较投入结构',
158         PURPLE, 9.7)
159     f.box(2.27, .23, 1.96, 1.09, '连续预算扫描',
160         '141 个对数网格点\n质量完成度与费用份额\n定位启动、
161 饱和区间', TEAL, 9.7)
162     f.box(4.39, .23, 1.96, 1.09, '情景与敏感性分析',
163         '三种质量成本\n五档上下文与配比情景\n比较配置与损失
164 变化', GOLD, 9.7)
165     f.text(3.25, .09, '扫描中的失败点不补算；阶段边界按有效预
166 算网格报告。', 9, GRAY)
167     f.save(out, 'q3-workflow')
168
169 def q4(out):
170     f = Workflow(5.45)

```

```

164     rows = [
165         (4.14, '损失与得分的联系', PURPLE,
166         'C6 分层、C5 对照', '区分记录可比程度\n分别整理损失与
得分',
167         '分层最小二乘回归', '拟合损失—得分关系\n检查相关性与
换算误差',
168         '方向判断', '说明变化方向\n保留换算误差边界'),
169         (2.81, '历史增量的来源', TEAL,
170         'C1 与 C3 分别整理', 'C1 字段与许可筛选\nC3 得分一致
性检查',
171         '规模、年份回归与分解', '估计规模和年度系数\n按长、短
窗口作 shift-share 分解',
172         '历史贡献核算', '规模项与非规模项\n分别报告两类窗口')
,
173         (1.48, '未来前沿的条件预测', BLUE,
174         '前沿序列与回归系数', 'C3 年度、C1 月度前沿\n沿用规模
和年度系数',
175         '两条预测路径', 'logistic 拟合与 bootstrap 区间\n规
模、非规模增长的结构情景',
176         '前瞻 12 / 24 个月', '曲线预测与区间\n结构情景点值'),
177         (.15, '任务瓶颈与宏观参照', GOLD,
178         'C1 / C8 与 C4', '六维得分与原始子任务\n宏观资源和字
段覆盖',
179         '任务比较与资源趋势', 'C1—C8 名称匹配与口径核对\nC4
单独统计算力与开放权重',
180         '适用范围说明', '识别评测薄弱项\n说明宏观证据边界'),
181     ]
182     for y, label, color, t1, b1, t2, b2, t3, b3 in rows:
183         f.lane(y, label, color)
184         f.box(.17, y+.09, 1.70, .80, t1, b1, color, 9.25)
185         f.box(2.09, y+.09, 2.39, .80, t2, b2, color, 9.25)
186         f.box(4.71, y+.09, 1.60, .80, t3, b3, color, 9.25)
187         f.arrow([(1.90, y+.46), (2.06, y+.46)], color)
188         f.arrow([(4.51, y+.46), (4.68, y+.46)], color)
189     f.save(out, 'q4-workflow')
190
191
192 if __name__ == '__main__':

```

```

193     parser = argparse.ArgumentParser(description=__doc__)
194     parser.add_argument('--output-dir', type=Path,
195                          default=Path(__file__).resolve().
parents[1] / '论文' / 'figures')
196     args = parser.parse_args()
197     configure()
198     q3(args.output_dir)
199     q4(args.output_dir)

```

Listing 22: 问题三四流程图（求解/绘制问题三四流程图.py）

```

1  % 总体架构：横向箭头对应每问的数据、方法和产出。
2  % 不在此图中表达尚未核实的跨问数值校准关系。
3  \begin{group
4  \definecolor{archblue}{HTML}{315A79}
5  \definecolor{archlight}{HTML}{EDF3F7}
6  \definecolor{archgray}{HTML}{536572}
7  \begin{tikzpicture}[
8      font=\song\fontsize{10}{13}\selectfont,
9      archbox/.style={draw=archblue!55, line width=0.55pt, rounded
        corners=2pt,
10         fill=archlight, align=center, inner sep=7pt, minimum
        height=1.55cm},
11     archdata/.style={archbox, text width=2.55cm},
12     archmodel/.style={archbox, text width=5.1cm},
13     archoutput/.style={archbox, text width=3.3cm, fill=white},
14     archlink/.style={-{Stealth[length=2mm]}}, draw=archblue, line
        width=0.7pt},
15     archhead/.style={text=archblue, font=\song\bfseries\fontsize
        {11}{14}\selectfont}
16 ]
17 \node[archhead] at (-5.8,0.65) {数据与条件};
18 \node[archhead] at (-0.8,0.65) {建模任务与方法};
19 \node[archhead] at (4.8,0.65) {主要产出};
20
21 \node[archdata] (a) at (-5.8,-0.75) {附件 A\质量信号\配方与
        验证损失};
22 \node[archmodel, fill=archblue, text=white] (q1) at
        (-0.8,-0.75)

```

```

23 {问题一：数据质量与领域配比\\熵权评价、冲突分析、岭与核岭};
24 \node[archoutput] (o1) at (4.8,-0.75)
25 {综合质量评分\\配比与损失关系\\推荐配比};
26
27 \node[archdata] (b) at (-5.8,-3.0) {附件 B\\规模、训练量\\与质
    量信息};
28 \node[archmodel] (q2) at (-0.8,-3.0)
29 {问题二：损失与资源的关系\\广义标度律、边际效用与弹性};
30 \node[archoutput] (o2) at (4.8,-3.0)
31 {损失函数与参数\\资源之间的替代关系};
32
33 \node[archdata] (c) at (-5.8,-5.25)
34 {算力预算\\题给成本设定\\C7 上下文信息};
35 \node[archmodel] (q3) at (-0.8,-5.25)
36 {问题三：算力约束下的配置\\成本建模与约束优化};
37 \node[archoutput] (o3) at (4.8,-5.25)
38 {最优配置  $(N,D,Q)$ \\预算变化下的\\配置特征};
39
40 \node[archdata] (d) at (-5.8,-7.5)
41 {附件 C\\历史模型\\与评测信息};
42 \node[archmodel] (q4) at (-0.8,-7.5)
43 {问题四：能力演进与前沿预测\\损失与评测桥接、回归与外推};
44 \node[archoutput] (o4) at (4.8,-7.5)
45 {规模项与非规模剩余项\\能力前沿条件外推};
46
47 \foreach \archsrc/\archmid/\archdst in {a/q1/o1,b/q2/o2,c/q3/o
    3,d/q4/o4} {
48 \draw[archlink] (\archsrc.east) -- (\archmid.west);
49 \draw[archlink] (\archmid.east) -- (\archdst.west);
50 }
51 \end{tikzpicture}
52 \endgroup

```

Listing 23: 总体流程图原生源码 (论文/figures/overall-architecture.tex)