



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 东南大学

参赛队号

队员姓名	1. 周泽华
	2. 单文杰
	3. 苏永强

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘要

本文针对算力约束下提升大语言模型能力的资源配置建模问题，结合综合评价、标度律建模、约束优化与技术演进预测等方法，提出了从“数据质量与配比刻画”到“算力最优配置”再到“能力前沿预测”的系统解决方案。

针对问题一：本问是综合评价与回归建模问题，需对 22 个质量指标预处理并建立综合评价模型、定义并消解质量冲突、建立 17 域配比与交叉熵损失的定量关系。首先，逐指标判定方向并统一为“越高越好”（其中广告字段经原文抽查确认为“第 1 类 = 无广告”的正向指标），对 8 个多维列表型指标用 softmax 期望压缩为标量，再作极差归一化、用熵权法客观赋权得到样本级、语料级与领域级质量评分；其次，以成对标准化得分差定义冲突、以 Kendall 协同系数检验一致性，并给出“多数指标方向裁决”的消解规则；再次，用岭正则线性混合回归刻画 17 域配比到 13 域损失的线性关系，并检验追加质量项的增量解释力；最后在 1M、60M、1B 三套检验集上验证并做跨尺度外推。结果表明，全量 272,505 条质量记录（另审计出 19 处字段缺失并按中位数填充）的 Kendall 协同系数为 0.069、冲突率 22.3%（低于独立基准 28.9%），说明指标间为正但不强的一致关系；抽样集 A1 与扩展集 A2/A3 的域级质量高度吻合（arxiv 0.703 对 0.701，github 0.455 对 0.455），领域质量排序为 $\text{arxiv} > \text{stackexchange} > \text{c4} > \text{commoncrawl} > \text{book} \approx \text{wikipedia} > \text{github}$ ；配比—损失模型训练平均 $R^2 = 0.629$ 、同尺度检验 0.619，60M 与 1B 跨尺度 Pearson 相关达 0.782 与 0.651；追加混合质量指数后平均 R^2 仅提升 9.9×10^{-5} ，说明配比本身已编码质量信息，故将质量作为独立资源交由后续问题处理。

针对问题二：本问是标度律建模问题，需拟合经典标度律、将数据质量纳入得到广义标度律、分析边际效用与弹性并推导质量与参数规模的替代条件。首先，用稳健非线性最小二乘在 Pythia 主拟合数据上拟合经典形式并做模型留出验证；其次，在控制 N 、 D 的组内条件下审计质量字段方向；再次，比较四类含质量项的广义标度律形式，以拟合优度与内插/外推表现择优；最后计算弹性、等损失曲线与替代率。结果表明，经典标度律为 $L = 1.6898 + 0.3540N^{-0.3400} + 1.2403D^{-0.2799}$ ， $R^2 = 0.9999998$ ；方向审计的组内相关为 -0.925 ，确认 Q_{score} 是质量指标（ $Q = 1$ 最优）；最优形式为加性质量缺口 $L = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^\gamma$ ，联合拟合 $R^2 = 0.9896$ ，参数 $E = 1.6558$ 、 $A = 0.3808$ 、 $\alpha = 0.3266$ 、 $B = 1.2515$ 、 $\beta = 0.2767$ 、 $C = 0.3544$ 、 $\gamma = 0.9779$ ；B3 插值轨迹的 D 幂指数为 -0.2805 ，与拟合值 -0.2799 高度一致；参考点 $N = 1\text{B}$ 、 $D = 100\text{B}$ 、

$Q = 0.6$ 处质量弹性为 -0.084 ，强于规模弹性 -0.049 ，质量提升 0.1 等价于参数量增加约 0.28B（在 $N = 12\text{B}$ 处等价于约 7.68B），验证了“以质量换规模”的可行性。

针对问题三：建立包含基础训练、质量处理与注意力开销的预算约束模型，在给定配比情景下采用 SLSQP 求解参数量、数据量与质量水平。以幂函数型质量成本、参考配比和 2048 tokens 上下文为基准，三档预算 10^{19} 、 10^{22} 、 10^{24} FLOPs 下的配置分别为 (0.225B, 6.9B, 0.551)、(6.089B, 229.5B, 1.000)、(44.937B, 3418.0B, 1.000)，对应参数量、训练 token 数与质量评分。预算扫描显示基线质量、质量提升与质量饱和三个阶段：首次观察到正质量投入和饱和配置的网格预算分别为 1.78×10^{19} 与 7.08×10^{19} FLOPs，后者对应质量份额峰值 40.7%；这些预算数值是识别值而非精确临界点。解析得到注意力与基础训练成本相等的上下文长度 30,000 tokens。在 10^{22} FLOPs 下，上下文由 2048 增至 131072 tokens 时，参数量由 6.089B 降至 2.705B，预测损失上升约 6.0%。三类质量成本均在所考察中高预算档给出质量饱和配置，但低预算质量决策明显依赖成本形式；定量结果受评分尺度衔接和标度律外推假设约束。

针对问题四：本问是技术演进建模与前沿预测问题，需结合历史评测数据分离规模扩张与非规模技术进步的贡献并预测未来 12 至 24 个月能力前沿。首先明确时间轴（提交日期）、开源口径（开源权重且许可允许研究复现）与模型类型口径（pretrained 与 chat/finetuned 分组），得到 2,346 条开源筛选样本；其次完成附件 C8 的逐任务聚合（1,860 个模型目录、37 个子任务维度）并与 C1 交叉校验；再次按可比性分层建立 Loss—Benchmark 桥接，并用面板回归分离规模效应与年份效应；最后用 logistic 饱和模型与结构外推两条路线给出预测区间，并引用附件 C4 的算力与开源权重证据设定情景。结果表明，桥接全样本 $r = -0.510$ ($R^2 = 0.26$)，映射误差须显式讨论；规模系数为 13.84 分/10 倍参数、非规模进步 4.84 分/年；长周期（2019—2025）前沿提升中规模扩张贡献 50.5%、非规模技术进步 49.5%，而在评测标准一致的近端窗口内前沿提升的 95.4% 来自非规模因素；未来 12/24 个月开源模型能力前沿预测为 56.3（90% 置信区间 [53.6, 64.5]）与 56.6（[53.8, 66.5]），算力增长放缓情景下为 53.3 与 55.8；逐任务上指令遵循已近饱和（剩余空间 10.0%），而研究生级问答与多轮对话仍有 72.3% 与 61.3% 的剩余空间。

综上，本文完成了数据质量评价、广义标度律建模、算力约束最优配置与能力前沿预测的全链条研究，各问结论均给出可复现的数值证据与不确定性刻画，可为算力受限条件下大模型训练的资源分配、数据治理与技术路线选择提供理论依据和决策参考。

关键词：大语言模型；标度律；数据质量；资源配置优化；算力约束；能力前沿预测

目录

一、引言	5
1.1 问题背景	5
1.2 问题重述	5
二、总体分析	5
三、模型假设	6
四、符号说明	7
五、模型的建立与求解	8
5.1 问题一的模型的建立和求解	8
5.1.1 具体分析	8
5.1.2 模型准备	8
5.1.3 模型建立	11
5.1.4 模型求解	13
5.2 问题二：跨维度数据融合与广义标度律	18
5.2.1 具体分析	18
5.2.2 模型准备	18
5.2.3 模型建立	19
5.2.4 模型求解	21
5.3 问题三：算力约束下的资源配置与结构性转移	25
5.3.1 具体分析	25
5.3.2 模型准备	26
5.3.3 模型建立	26
5.3.4 模型求解	28
5.4 问题四的模型的建立和求解	32
5.4.1 具体分析	32
5.4.2 模型准备	33
5.4.3 模型建立	35
5.4.4 模型求解	36
六、模型检验与分析	41
6.1 误差分析	41
6.2 灵敏度分析	42
七、模型的评价	44
7.1 模型的优点	44
7.2 模型的缺点	45

八、模型的改进与推广	45
8.1 模型的改进	45
8.2 模型的推广	46
参考文献	47

一、引言

1.1 问题背景

以大语言模型（Large Language Models, LLMs）为代表的人工智能技术在近年来取得飞速发展，其能力的跃升高度依赖于模型规模、训练数据规模、数据质量与领域配比等多维资源的协同配置。为直观理解这一过程，可将大模型训练类比为培养一名高质量学生：参数量 N 相当于脑容量，训练数据量 D 相当于阅读量，计算量 C 相当于教育经费，数据质量 Q 相当于教材质量，领域配比 p 相当于各科课时分配。标度律（Scaling Laws）刻画了模型损失随规模变化的经验关系，是理解大模型能力形成的核心工具 [1, 2]。

然而，随着人工智能对高质量语料的需求持续增长，干净数据日益稀缺、数据污染问题日趋严重，数据墙（Data Wall）问题日益突出 [5]。2026 年《Nature》发表的研究表明，一个仅有 80 亿参数的小规模模型 OpenScholar-8B 在引文准确率、降低幻觉等任务上的表现优于 GPT-4o [6, 11]，充分说明数据质量与领域比对模型能力具有不可忽视的作用。扩大模型规模、提升数据质量与延长上下文长度均需付出算力代价，而算力始终有限，四者之间存在复杂的取舍关系。

因此，如何利用真实公开数据建立数学模型，刻画参数规模、数据规模、数据质量、领域配比与交叉熵损失之间的定量关系，并在算力约束下求解最优资源配置，成为亟待解决的关键科学问题。本赛题要求参赛队伍在无须底层系统开发与大规模训练经验的前提下，完成这一建模任务，为算力受限条件下的大模型能力提升提供理论依据与决策参考。

1.2 问题重述

问题 1：对 22 个质量指标统一方向并建立综合评价模型，给出样本级、语料级与领域级质量评分 Q ，定义并消解质量指标间的冲突，并建立 17 域配比与交叉熵损失之间的定量关系。

问题 2：将数据质量 Q 与领域配比 p 纳入经典标度律，建立同时包含 N 、 D 、 Q 、 p 的广义标度律，分析各因素边际效用与弹性，推导质量与参数规模可相互替代的条件。

问题 3：在算力预算约束下，联合优化参数量 N 、数据量 D 、领域配比 p 与数据质量 Q ，并分析预算跨越不同量级时资源配置是否发生结构性转移。

问题 4：结合历史评测数据建立技术演进模型，分离并量化规模扩张与非规模技术进步的贡献占比，预测未来 12 至 24 个月开源大语言模型能力的前沿边界。

二、总体分析

本赛题围绕“算力约束下提升大语言模型能力”这一核心目标，要求利用真实公开数据刻画参数规模、数据规模、数据质量与领域配比同交叉熵损失之间的定量关系，并在算力约束下求解最优资源配置，四道小题层层递进、前后衔接。

针对问题一，本问建立了基于熵权法的质量综合评价模型、基于成对标准化得分差与 Kendall 协同系数的冲突消解模型、以及基于岭正则的领域配比线性混合回归模型，来解决“如何量化数据质量与配比、并建立配比—损失定量关系”的问题，其输出的质量评分 Q 、质量基线 Q_0 与配比—损失系数矩阵为后续问题提供质量与配比输入。针对问题二，本问建立了含质量缺口的广义标度律 $L(N, D, Q) = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^\gamma$ ，在经典 Chinchilla 标度律基础上引入质量维并保证 $Q = 1$ 时精确退化，解决“质量与规模、数据如何共同决定损失、能否相互替代”的问题，其输出的标度律参数直接供问题三的优化目标使用。针对问题三，本问建立了严格按赛题公式分解的“基础训练 $6ND$ + 质量提升 $D[g(Q) - g(Q_0)]_+$ + 长文本注意力 ηNDL_{ctx} ”成本模型与预算约束下的 SLSQP 联合优化模型，解析给出临界上下文长度 $L_{\text{crit}} = 6/\eta$ ，并给出结构性转移的可操作数学定义，解决“算力有限时如何在 N 、 D 、 Q 之间最优配置并识别制度切换”的问题。针对问题四，本问建立了分层 Loss—Benchmark 桥接模型、含年份固定效应的面板回归分解模型、logistic 饱和外推与结构外推双路线预测模型，并完成附件 C8 的逐任务聚合与附件 C4 的宏观证据检验，解决“如何分离规模扩张与非规模技术进步的贡献并预测能力边界”的问题，将前三问以损失为目标的结论桥接为以评测得分为度量的能力演进。

由此可见，四个问题构成一条完整的建模链条：问题一提供质量与配比这一“数据侧”输入，问题二将其纳入标度律得到统一损失函数，问题三在此损失函数与成本模型上完成算力约束下的最优配置，问题四则将损失层面的结论映射到真实评测能力并外推前沿。四问共享同一套“损失最小化”的优化主线，差异在于资源的维度与约束逐步扩充；同时四问之间以显式接口相互耦合——问题一输出的质量基线 Q_0 与配比修正 $M(\mathbf{p})$ 被问题三直接引用，问题二输出的标度律参数被问题三作为目标函数读取，问题四则用 Loss—Benchmark 桥接把前三问的损失结论折算为能力得分，形成“数据 → 损失 → 算力 → 能力”的闭环。

三、模型假设

为简化问题，本文做出以下假设：

- **假设 1：**附件 A 各训练配方的 17 个领域配比与各验证域交叉熵损失之间存在线性混合关系，且该关系在不同参数规模间可由同一组系数近似刻画（配比—损失线性外推假设）；该假设的依据是 1M 训练集平均 $R^2 = 0.629$ 且 60M/1B 检验集 Pearson 相关达 0.782/0.651。

- **假设 2：**附件 B 的 Q_{score} 字段即为数据质量（越大越好， $Q = 1$ 为最优），且验证损失随参数量、数据量与质量的变化可用形如 $L = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^\gamma$ 的广义标度律描述（质量缺口可加假设）；该方向由控制 N, D 后 B6/B7 的组内相关 $-0.925/-0.918$ 一致确认，该形式在四类候选中拟合优度与信息准则最优。

- **假设 3：**训练总成本严格按赛题公式分解为基础训练 $6ND$ 、质量提升 $D[g(Q) - g(Q_0)]_+$ 与长文本注意力 ηNDL_{ctx} 三部分之和，其中 $g(Q)$ 取附录 B 规定的三型之一、 $\eta = 2 \times 10^{-4}$ 、 L_{ctx} 由附件 C7 外生给定（成本可加分解假设）；该假设不做额外

简化, C_Q 与训练 token 数成正比。

• **假设 4:** 开源大语言模型能力前沿随时间先加速上升后趋于饱和, 可用 logistic 饱和函数刻画; 同时规模扩张与非规模技术进步对能力得分的贡献可由面板回归线性分离 (技术演进可分解假设); 该假设的先验依据是六维得分存在上界 100, 且年份与参数量在控制年份效应后仍可分别识别。

四、符号说明

本文使用的主要符号及其含义如表1所示。

表 1 符号说明

符号	说明
N	模型参数量 (问题二以 B 为单位; 问题三成本计算使用参数个数)
D	训练数据规模 (问题二以 B tokens 为单位; 问题三成本计算使用 token 数)
L	验证交叉熵损失 (越低越好)
Q	数据质量评分 ($Q \in [0, 1]$, 越高越好)
Q_0	基线数据质量 (参考语料配比加权平均, $Q_0 = 0.5510$)
$\mathbf{p}$	17 个训练领域的配比向量 (分量非负且和为 1)
E	不可约损失 ($N, D \rightarrow \infty$ 且 $Q = 1$ 时的极限损失)
A, B	标度律中规模项与数据项的系数
α, β	标度律中规模项与数据项的指数
C, γ	广义标度律中质量缺口项的系数与指数 (问题三将系数记为 C_q)
$\varepsilon_N, \varepsilon_D, \varepsilon_Q$	损失对参数量、数据量、质量的弹性
$M(\mathbf{p})$	配比项对损失的平移修正 (相对参考配比)
$C_{\text{train}}, C_Q, C_{\text{attn}}$	基础训练、质量提升、长文本注意力三类算力开销
C_{budget}, C_b	算力预算 (单位: FLOPs; 问题三简记为 C_b)
$g(Q)$	数据质量成本函数 (指数型/幂函数型/对数渐进型)
η	长文本注意力的算力系数 ($\eta = 2 \times 10^{-4}$)
$\lambda(L_{\text{ctx}})$	注意力开销相对训练开销的倍数 $\eta L_{\text{ctx}}/6$
L_{crit}	注意力开销等于训练开销的临界上下文长度 ($L_{\text{crit}} = 6/\eta = 30,000$)
$\tau(Q)$	质量处理成本折算的等效附加参数规模, 与问题三的 N 同口径
$\Theta(C_b)$	质量提升完成度; 问题三以其对 $\log_{10} C_b$ 的变化率描述提升速度
$F(t)$	时刻 t 的模型能力前沿 (Leaderboard 六维均分)
K, r, t_0	logistic 饱和外推的饱和上界、增长率与拐点
b_P, b_t	面板回归中的规模系数 (分/10 倍参数) 与时间系数 (分/年)
α_t	面板回归的年份固定效应 (非规模技术进步)

表 1 符号说明 (续)

符号	说明
$\bar{B}$	Leaderboard 六维平均得分
w_j, e_j	第 j 个质量指标的熵权与信息熵
W	Kendall 协同系数 (指标一致性度量)
ρ_c, ρ_0	冲突率与指标独立时的冲突基准
R^2	决定系数
RMSE / MAE / MAPE	均方根误差 / 平均绝对误差 / 平均绝对百分比误差

五、模型的建立与求解

5.1 问题一的模型的建立和求解

5.1.1 具体分析

针对问题一，本问属于**综合评价与回归建模**类问题，需要完成三项递进任务：一是对 22 个质量指标进行预处理并建立综合评价模型，给出样本级、语料级与领域级质量评分 Q ；二是定义并消解不同质量指标之间的冲突；三是建立 17 域配比 p 与交叉熵损失之间的定量关系并验证。本问综合采用指标方向统一、极差归一化与熵权法进行质量评价，采用成对标准化得分差与 Kendall 协同系数进行冲突检验与消解，采用岭正则线性混合回归 (Ridge Mixture Regression) 刻画配比—损失关系 [8]。

首先对质量信号数据进行清洗，将 22 个质量指标 (含 8 个多维列表型指标) 统一为“越高越好”的方向并压缩为标量，建立综合评价模型得到质量评分 Q ；接着定义“冲突”为两指标标准化得分之差超过阈值的情形，用 Kendall 协同系数检验指标一致性并给出消解规则；然后利用训练配方表与损失表建立配比 p_k 到各域损失 L_d 的线性混合回归模型，并以岭正则处理成分数据的闭合效应与未测量域；最后在 1M、60M、1B 三套检验集上验证，并利用 10B、70B 外推表讨论跨尺度外推的稳健性。

5.1.2 模型准备

1. 数据预处理

附件 A 的配方表 (A4) 以 17 个 The Pile 子领域的训练配比 p_k (分量非负且和为 1) 为特征 [10]，损失表 (A5) 以 13 个验证域的交叉熵损失为响应，二者通过 index 列一一对应。17 个训练域中 nih_exporter、enron_emails、europarl、philpapers 仅有配比列而无对应损失列，本文保留其配比分量但在系数解释时标注为“间接影响域”。质量信号数据 (A1–A3) 含 22 个质量指标，其方向并不统一，须先逐指标统一为“越高越好”。设第 j 个指标的原始取值为 x_j ，对正向指标直接做极差归一化，对负向指标先取补再归一

化，对“长度型”指标（过长过短均不佳）转为中心接近度：

$$x'_j = \begin{cases} \frac{x_j - \min x_j}{\max x_j - \min x_j}, & \text{正向指标} \\ \frac{\max x_j - x_j}{\max x_j - \min x_j}, & \text{负向指标} \\ \exp\left(-\frac{|\ln(1 + x_j) - m_j|}{2.5 \text{MAD}_j}\right), & \text{长度型指标} \end{cases} \quad (1)$$

其中 m_j 与 MAD_j 为对数尺度的中位数与中位绝对偏差； $x'_j \in [0, 1]$ 且统一为“越高越好”。22 个指标的方向判定与语义说明见表2，其中 8 个多维列表型指标（原始为有序类别 logits）先按 softmax 概率取归一化期望级别压缩为标量，再参与归一化。

表 2 22 个质量指标的方向判定与熵权

指标	类型	语义（方向依据）	方向	熵权 w_j
fineweb_edu	列表 (1)	教育价值	正向	0.0437
fluency_en	列表 (2)	英语流畅度（第 1 类 = 流畅，已核验）	正向	0.0682
modernbert_cleanliness	列表 (6)	文本洁净度	正向	0.1434
modernbert_readability	列表 (6)	可读性	正向	0.0567
modernbert_reasoning	列表 (6)	推理性	正向	0.1517
modernbert_professionalism	列表 (6)	专业性	正向	0.0396
dsir_books	标量	书籍域重要性权重	正向	0.0081
dsir_wiki	标量	维基域重要性权重	正向	0.0081
dsir_math	标量	数学域重要性权重	正向	0.0086
qurater	列表 (4)	教育质量评级（4 项取均值）	正向	0.0492
ad_en	列表 (2)	广告含量（第 1 类 = “无广告”，正向；依据：原文抽查）	正向	0.0072
rps_doc_word_count	标量	文档词数	长度型	0.0516
rps_doc_num_sentences	标量	文档句数	长度型	0.0523
rps_doc_unigram_entropy	标量	一元词熵（多样性）	正向	0.0347
rps_doc_frac_unique_words	标量	唯一词占比	正向	0.0538

表 2 22 个质量指标的方向判定与熵权 (续)

指标	类型	语义 (方向依据)	方向	熵权 w_j
rps_doc_frac_no_alph_words	标量	非字母字符占比	负向	0.0287
rps_doc_frac_chars_top_2gram	标量	字符 2-gram 重复度	负向	0.0130
rps_doc_frac_chars_top_3gram	标量	字符 3-gram 重复度	负向	0.0119
rps_lines_uppercase_letter_fraction	标量	大写字母行占比	负向	0.0316
rps_lines_ending_with_terminal_punctuation_mark	标量	标点结尾行占比	正向	0.0880
rps_lines_numerical_chars_fraction	标量	含数字行占比	负向	0.0125
rps_doc_mean_word_length	标量	平均词长	长度型	0.0373

样本级质量评分由各指标加权求和得到, 领域级质量 Q_d 为该领域内样本评分的均值:

$$Q_i = \sum_{j=1}^{22} w_j x'_{ij}, \quad Q_d = \frac{1}{n_d} \sum_{i \in \mathcal{D}_d} Q_i, \quad \sum_j w_j = 1 \quad (2)$$

其中权重 w_j 由熵权法确定。由表2可见, 权重最大的两项是 modernbert_reasoning (0.152) 与 modernbert_cleanliness (0.143), 即“推理性”与“洁净度”两个信号提供的信息量最多; 需要说明的是, 熵权法对取值分布的形态较敏感 (极端左偏的指标会获得更大权重), 因此本文在误差分析中对赋权方案作了敏感性检验 (见第6.1节)。

质量信号存在少量字段级缺失, 本文流式读取时逐字段审计, 结果见表3, 并按该指标中位数填充, 不把缺失当作高质量或低质量。

表 3 质量信号的字段级缺失审计 (A1–A3 全量 272,505 条)

指标	缺失记录数	形态
modernbert_reasoning	13	整行 6 维取值均为 NaN
modernbert_professionalism	6	整行 6 维取值均为 NaN
其余 20 个指标	0	无缺失

2. 算法选择

本问涉及质量评价 (指标聚合)、冲突分析 (一致性检验) 与配比建模 (回归) 三类任务, 需在候选算法中择优。质量聚合比较熵权法、主成分分析 (PCA) 第一主成分与等权平均; 冲突分析以成对标准化得分差为主、Kendall 协同系数为辅; 配比建模比较普通最小二乘、岭回归与随机森林。质量聚合的三种方案对比如表4所示。

表 4 问题一赋权方案对比（样本级相关性与域级排序一致性）

方案	得分均值	与熵权法相关性	域级 Spearman 排序一致性（对熵权法）
熵权法	0.495	1.000	1.000
等权平均	0.639	0.854	0.679
PCA 第一主成分	0.520	0.881	0.679

如表4所示，熵权法能依据指标自身信息量客观赋权、避免主观打分；与等权方案相比，样本级得分相关系数为 0.854、域级排序一致性为 0.679，说明主体格局稳定但并非完全一致——改用等权后领域排序会发生变化，故本文在误差分析中把赋权方案列入灵敏度检验。PCA 方案虽降维去相关，但主成分含义难以解释，受篇幅限制不作备选。配比建模中 17 域配比满足单纯形约束（和为 1）而天然存在共线性，岭回归通过 L_2 正则化能稳定估计且外推可解释，故采用岭正则线性混合回归。冲突分析方面，Kendall 协同系数刻画的是“指标作为评价者”的整体一致性，而问题要求的是“对同一文本给出显著不一致评价”的样本级冲突，二者互补，故同时报告。

5.1.3 模型建立

步骤 1：质量评价模型

设 m 条质量信号样本、22 个指标经方向统一与归一化后构成矩阵 $\mathbf{X} = (x'_{ij})$ 。第 j 个指标的信息熵与熵权为：

$$e_j = -\frac{1}{\ln m} \sum_{i=1}^m f_{ij} \ln f_{ij}, \quad f_{ij} = \frac{x'_{ij} + \varepsilon}{\sum_i (x'_{ij} + \varepsilon)}, \quad w_j = \frac{1 - e_j}{\sum_{j=1}^{22} (1 - e_j)} \quad (3)$$

为与附件 B 的损失数据耦合，本问同时给出“结果导向”的领域质量代理指标：以各验证域在平均配方下的观测损失表征领域内在难度并映射为质量：

$$Q_d^{(\text{loss})} = 1 - \frac{\bar{L}_d - \min_d \bar{L}_d}{\max_d \bar{L}_d - \min_d \bar{L}_d} \quad (4)$$

其中 $\bar{L}_d$ 为领域 d 的平均交叉熵损失。该代理指标仅在 13 个可测损失域上有定义，与 A1–A3 的 7 个质量域并非同一分类体系，二者的关联由 A16 映射表建立、并在模型求解中作一致性检验。

步骤 2：质量冲突消解模型

当两个质量指标对同一文本给出显著不一致的评价时即产生冲突。以方向统一后的标准化得分为基础，定义第 i 样本在指标 j 与 k 上的冲突指示：

$$\delta_i(j, k) = |z_{ij} - z_{ik}|, \quad z_{ij} = \frac{x'_{ij} - \mu_j}{\sigma_j}, \quad \mathbf{1}\{\delta_i(j, k) > \tau\} \quad (5)$$

取阈值 $\tau = 1.5$ ；全样本冲突率为

$$\rho_c = \frac{1}{m \binom{22}{2}} \sum_{i=1}^m \sum_{j < k} \mathbf{1}\{\delta_i(j, k) > \tau\} \quad (6)$$

为给出参照系，本文同时计算“指标独立”基准 $\rho_0 = 2\Phi(-\tau/\sqrt{2})$ ：若 $\rho_c/\rho_0 < 1$ ，说明指标间存在正相关、并非互相矛盾。指标间整体一致性用 Kendall 协同系数检验（22 个指标为评价者、 m 条文本为评价对象）：

$$W = \frac{12 \sum_i (R_i - \bar{R})^2}{22^2 (m^3 - m)}, \quad R_i = \sum_{j=1}^{22} r_{ij}, \quad \chi^2 = 22(m-1)W \quad (7)$$

其中 r_{ij} 为第 i 样本在第 j 指标上的秩。消解规则为：若某样本被判为冲突，则以其上“多数指标”的方向（即加权得分 Q_i 相对该样本所在域中位数的偏离方向）作为该样本的最终质量裁决，并在报告中保留冲突标记以供下游剔除或降权。

步骤 3：领域配比建模（线性混合回归）

设训练配方矩阵 $\mathbf{P} \in [0, 1]^{n \times 17}$ （行和为 1），损失矩阵 $\mathbf{L} \in \mathbb{R}^{n \times 13}$ 。建立各验证域损失对配比的线性混合模型：

$$L_d(\mathbf{p}) = \sum_{k=1}^{17} a_{dk} p_k + b_d, \quad d = 1, \dots, 13 \quad \Longleftrightarrow \quad \hat{\mathbf{L}} = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top \quad (8)$$

由于 $\mathbf{P}$ 各行和为 1，回归存在闭合不可辨识性，采用岭正则估计系数矩阵 $\mathbf{A} \in \mathbb{R}^{17 \times 13}$ 与截距 $\mathbf{b}$ ：

$$\min_{\mathbf{A}, \mathbf{b}} \|\mathbf{L} - \mathbf{P}\mathbf{A} - \mathbf{1}\mathbf{b}^\top\|_F^2 + \lambda \|\mathbf{A}\|_F^2, \quad \begin{bmatrix} \mathbf{A} \\ \mathbf{b}^\top \end{bmatrix} = \left(\tilde{\mathbf{P}}^\top \tilde{\mathbf{P}} + \lambda \mathbf{D} \right)^{-1} \tilde{\mathbf{P}}^\top \mathbf{L} \quad (9)$$

其中 $\tilde{\mathbf{P}} = [\mathbf{P}, \mathbf{1}]$ ， $\mathbf{D} = \text{diag}(1, \dots, 1, 0)$ （不惩罚截距）， $\lambda = 10^{-3}$ 。

步骤 4：质量信息的引入方式与检验

问题一要求论证“是否以及如何引入质量评分 Q ”。本文构造混合质量指数 $\bar{Q}(\mathbf{p}) = \sum_k p_k Q_k$ （ Q_k 由 A16 映射得到：direct/near_direct 域直接取用 A1–A3 域级质量，inferred 域取全局均值），并做增量回归检验：

$$\hat{\mathbf{L}} = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top + \mathbf{1}c^\top \bar{Q}(\mathbf{p}) \quad (10)$$

若质量项带来的 R^2 增量可忽略，则说明线性配比已吸收质量信息，此时不宜重复引入以免共线；质量评分转而作为独立资源交由问题二、三使用。

步骤 5：最优配比与稳健推荐

在系数矩阵 $\mathbf{A}$ 基础上，固定未测量域配比于参考值，优化 13 个可测域的配比使加权平均损失最小：

$$\min_{\mathbf{p} \in \Delta_{17}} \sum_{d \in \mathcal{M}} w_d \left(\sum_k a_{dk} p_k + b_d \right), \quad \Delta_{17} = \{\mathbf{p} : p_k \geq 0, \sum_k p_k = 1\} \quad (11)$$

为给出可落地的稳健方案，进一步限制各域配比不超过参考配比的 2.5 倍，得到有界推荐配比。

5.1.4 模型求解

基于上述模型，利用附件 A 的质量信号（A1–A3）与配方/损失数据（A4–A15）进行求解，共处理全量质量记录 272,505 条（A1 抽样集 51,230 条、A2+A3 扩展集 221,275 条）。

1. 质量评分与冲突分析

质量域的领域级评分如图1所示，A1 抽样集与扩展集的对照结果如表5所示。




图 1 A1–A3 全量质量信号的领域级评分（均值 ± 标准差）

表 5 抽样集 A1 与扩展集 A2/A3 的域级质量对照

质量域	Q（A1）	Q（扩展集）	差值	对应配方域
arxiv	0.7031	0.7011	+0.0021	arxiv
stackexchange	0.6549	—	—	stackexchange
c4	0.6368	—	—	（配方侧无同名列）
commoncrawl	0.6153	—	—	pile_cc
book	0.5524	—	—	gutenberg_pg_19
wikipedia	0.5509	—	—	wikipedia_en
github	0.4553	0.4547	+0.0006	github

由表5可知，在同时具有抽样与扩展质量信号的两个域上（arxiv、github），两种口径的域级质量差异不超过 0.002（arxiv +0.0021、github +0.0006），说明抽样集对扩展集具有代表性、评分口径可跨集合迁移。全体记录的领域质量排序为 arxiv（0.703）> stackexchange（0.655）> c4（0.637）> commoncrawl（0.615）> book（0.552）≈ wikipedia（0.551）> github（0.455）。需要指出，该排序是 22 个分类器信号的合成结果，其中若干信号（如 rps_doc_frac_unique_words、rps_doc_unigram_entropy）与文档长度相关，因此“c4/commoncrawl 高于 book/wikipedia”反映的是信号体系的口径，而非对语料价值的终极判断——这一点在使用该评分时须注意。

冲突与一致性检验结果如表6所示，冲突最集中的指标对与熵权分布见图2。

表 6 质量冲突与一致性检验结果

数据集	样本数	Kendall W	冲突率 ρ_c	独立基准 ρ_0	ρ_c/ρ_0
A1 抽样集	51,230	0.0783	0.2252	0.2888	0.780
A2+A3 扩展集	221,275	0.0628	0.2208	0.2888	0.764
全量	272,505	0.0687	0.2235	0.2888	0.774




图 2 冲突最集中的指标对（左）与熵权分布（右）

由表6可知：(1) 三套数据的冲突率几乎一致（0.221 ~ 0.225），说明冲突结构在抽样集与扩展集上同样成立，A2/A3 的结论可外推至 A1 所代表的总体；(2) Kendall 协同系数为 0.069 (χ^2 检验 $p < 0.001$ ，样本量极大故显著性很高)，属于“正相关但一致性较弱”的水平，与冲突率 22.3% 一致，说明“各质量指标完全一致、不存在冲突”的判断并不成立；(3) 但冲突率低于指标完全独立时的基准 28.9%（比值 0.774），说明指标间确为正相关，冲突主要发生在语义上本就不同的指标之间。冲突成因可归纳为三类：一是度量对象不同（如 rps_doc_unigram_entropy 与 rps_doc_frac_unique_words 同测“多样性”但量纲不同），二是内容类型差异（如 modernbert_professionalism 对学术文本与论坛文本的评价尺度不同），三是分布形态差异（如 ad_en 为二分类概率、在长文档上两极化）。据此本文按“多数指标方向裁决 + 冲突标记保留”的规则消解：冲突样本仍参与领域均值，但以 Q_i 相对域中位数的偏离方向标注其可信度，并在问题二、三中不单独使用冲突样本。

2. 配比—损失建模与验证

配方结构与拟合、泛化表现分别如图3与图4所示，预测—实测对比如图6所示，系数热力图如图5所示。

由图4可知，训练集上 13 个损失域的 R^2 位于 0.42 ~ 0.77 之间、平均 0.629；同尺度 1M 检验集平均 $R^2 = 0.619$ ，与训练接近，说明模型未明显过拟合。由于不同参数规模下损失水平本身不同（60M 与 1M 的损失比约 0.68），跨尺度直接比较 R^2 无意义，故改




图3 训练配方结构（左：前 8 组配方堆叠；右：全部配方平均配比）




图4 线性混合回归的拟合与泛化表现

用尺度无关的 Pearson 相关：60M 与 1B 检验集上的平均相关分别为 0.782 与 0.651，表明同一套配比—损失系数可在不同参数规模间复用。由图5可知，各训练域对验证损失的相对影响差异明显，dm_mathematics、arxiv 等域降低损失，而 pile_cc、ubuntu_irc 等域抬高损失，印证了领域配比是影响模型性能的关键变量。

为验证质量信息的引入方式，本文比较了“仅配比”与“配比 + 混合质量指数 $\bar{Q}$ ”两种设定：追加质量项后 13 个损失域的平均 R^2 增量仅为 9.9×10^{-5} ，说明线性配比系数已经吸收了质量信息。因此本文不把质量评分再次作为配比模型的解释变量，而是将其作为独立资源交由问题二、三使用。

两套质量口径（A1–A3 的熵权质量 Q 与损失难度代理 $Q^{(\text{loss})}$ ）在 6 个可映射域上的排序一致性如图7所示。

由图7(a)可知，13 个损失域的内在难度差异显著，dm_mathematics 最易（代理质量 1.000）、ubuntu_irc 最难（代理质量 0.000）；图7(b)显示，A16 的 direct/near_direct 映射中两套口径的 Spearman 排序相关为 0.60：arxiv、stackexchange、github 三个域在两种口径下同向（文本质量高、损失也相对低），但 wikipedia、book、pile_cc 存在明显分歧——文本质量较高而该域损失并不低（学术与百科长文属“高质量但难拟合”）。因此质量评分必须按用途区分：面向数据治理使用 A1–A3 的文本质量，面向性能预测使用损失难




图 5 领域配比对交叉熵损失的相对影响热力图




图 6 同尺度检验集 (1M) 预测损失与实测损失对比

度代理。

3. 最优配比与跨尺度稳健性

无约束优化倾向于把配比集中于单一低损失域 (预测加权平均损失 4.177), 不具备可落地性; 故采用 2.5 倍上限的有界推荐作为最终方案, 推荐配比与参考配比的对比见表7, 该方案使预测加权平均损失由 5.336 降至 5.136 (下降 0.199)。





图 7 左：13 个验证域的损失难度代理；右：A1-A3 质量与损失难度代理的排序一致性

表 7 有界推荐配比调整

领域	参考配比	推荐配比	调整量
pubmed_central	0.1137	0.2843	+0.1706
stackexchange	0.0994	0.2486	+0.1491
pubmed_abstracts	0.0662	0.1654	+0.0993
gutenberg_pg_19	0.0469	0.1173	+0.0704
dm_mathematics	0.0255	0.0637	+0.0382
uspto_backgrounds	0.0755	0.0000	-0.0755
freelaw	0.0968	0.0000	-0.0968
github	0.1107	0.0000	-0.1107
arxiv	0.1130	0.0000	-0.1130
pile_cc	0.1195	0.0000	-0.1195

由表7可知，推荐方案应显著增加 pubmed_central、stackexchange、pubmed_abstracts 等学术领域的配比，同时压缩 pile_cc、arxiv、github、freelaw 等领域的占比。需要说明的是，这一结论是针对“13 个验证域加权平均损失”这一目标的优化结果，与“提升单个域自身表现”并不等价（例如 arxiv 的配比下降并不意味着 arxiv 质量低，而是因为其对加权平均损失的边际贡献为负）。外推稳健性方面，10B 与 70B 外推表的损失尺度因子（est/train）在各损失域上高度一致（10B 均值 0.338、标准差 0.038；70B 均值 0.266、标准差 0.036），且同配方下 60M 与 1M 的跨尺度损失比稳定（均值 0.51 ~ 0.82），说明同一套配比—损失系数可在不同参数规模间复用、具备跨尺度外推能力，如图8所示。



5.2 问题二：跨维度数据融合与广义标度律

5.2.1 具体分析

问题二需要回答：在参数规模与训练数据量之外，数据质量和领域配比如何影响验证损失，以及质量提升能够在何种条件下替代规模扩张。难点在于附件 A 与 B 并非同一组联合实验，质量评分与配比效应不能未经校准便直接叠加。本文以经典标度律描述规模效应，在附件 B 内比较质量项的候选形式，再利用问题一输出讨论领域效应及其迁移条件。

具体而言，先在 Pythia 训练轨迹上拟合经典关系，并以较小模型拟合、较大模型留出的方式检验族内迁移表现；随后核对半合成质量字段的方向，比较四类广义模型；最后在既定模型下计算局部弹性与质量-参数等效关系，结合多源检验界定结论的适用范围。领域分析利用问题一的配比系数，考察各训练域在不同验证任务上的效应差异。

5.2.2 模型准备

1. 数据组织与变量口径

经典标度律以 B1 为主拟合数据。该表包含 8 个 Pythia 模型的训练轨迹，每个模型具有 147 个检查点，共 1,176 条记录 [4]。质量项由 B6 半合成实验提供信息，B7 中去除与 B6 重复的记录后用于扩展检验。其余数据按用途分层：B2、B3 检查轨迹一致性，B4、B5 评价跨族及文献数据上的适用性，B8 用于口径诊断，B10 用于大规模估算对照。

记参数量为 N ，训练数据量为 D ，验证集交叉熵损失为 L 。本节计算中， N 以十亿个参数为单位， D 以十亿 tokens 为单位，质量变量记为 Q 。问题三的算力计算采用参数个数与 token 数，二者分别为本节 N 、 D 数值的 10^9 倍。拟合直接针对原函数进行，以保留不可约损失项 E ；因此，参数估计不依赖忽略常数项的双对数线性化。

2. 质量字段方向检验

附件 B 以 Q_{score} 表示质量，不同补充数据集的方向一致性通过组内相关检验考察。本文在固定 (N, D) 的各组内计算质量字段与损失的 Pearson 相关系数，再取组间算术平均，以检查方向一致性。负相关对应质量提高时损失下降，正相关则表明数据与这一方向约定不一致。组间平均相关系数仅描述方向，不代表统计显著性。检验结果如表8所示。

表 8 质量字段 Q_{score} 的方向检验（控制 N 、 D 的组内相关）

数据集	样本数	分组数	组内相关 r	结论
B6	360	45	-0.925	Q 越大损失越低：质量指标（ $Q = 1$ 为最优）
B7	450	45	-0.918	含 B6 的全部记录，仅新增点用于检验
B8（校准段）	984	90	+0.995	方向与 B6/B7 相反：口径不一致
B8（外推段）	720	60	+0.968	同上

由表8可知, B6 与 B7 的平均组内相关分别为 -0.925 和 -0.918 , 支持在这两套数据中沿用 $Q = Q_{\text{score}}$ 。经逐行核对, B7 包含 B6 的全部 360 条记录, 故其全量统计不能视为独立证据; 后续仅以 90 个新增点进行扩展检验。B8 两个子集的相关方向均与 B6/B7 相反, 且其部分损失低于本文估计的基线下限, 表明当前模型与该数据不能直接兼容。本文不将 B8 纳入主拟合, 仅尝试 $1 - Q_{\text{score}}$ 的方向变换进行诊断; 变换后的预测误差用于衡量单纯方向调整的解释能力。

问题一的综合评分与附件 B 的 Q_{score} 均采用“越高越好”的方向, 但来源和构造方式不同。本节质量效应的参数估计以附件 B 的评分尺度为依据, 数值解释限于该尺度; 评分方向一致不意味着跨来源分数等值。

3. 参数估计方法与候选模型比较

模型参数采用带界约束的非线性最小二乘估计, 并使用 $\text{soft-}L_1$ 损失减弱大残差对拟合的影响。该方法能够直接保留常数项与幂函数结构, 同时限制参数取值范围。对四类质量项, 使用相同的联合样本比较拟合优度, 并结合 B6 内部误差、B7 新增点预测相关和残差信息评分评价其表现。比较结果见表9。

表9 广义标度律候选形式的比较

质量项形式	联合 R^2	B6 拟合 R^2	B7 新增点 r	参数数	I_{RSS}
加性质量缺口 $C(1 - Q)^\gamma$	0.9896	0.9556	0.991	7	-10236
质量同时乘 N 与 D	0.9882	0.9495	0.991	7	-10042
加性质量亏损 $CQ^{-\gamma}$	0.9848	0.9349	0.991	7	-9660
质量作有效数据乘子	0.9745	0.8905	0.983	6	-8866

表9中, 四类形式在 B7 新增点上的预测相关均不低于 0.983。加性质量缺口形式具有最高的联合拟合与 B6 内部拟合 R^2 , 因此本文采用该形式。预测偏差进一步由 RMSE 与 MAPE 衡量。表中 $I_{\text{RSS}} = n \ln(\text{RSS}/n) + 2k$ 由拟合残差计算, 其中 n 为样本数、 k 为模型参数数。参数采用 $\text{soft-}L_1$ 稳健估计, 因此该评分仅用于同一样本下的辅助比较, 并非严格的高斯极大似然 AIC。B7 新增点用于模型比较与扩展检验, 两者共享样本, 结果按开发阶段的验证性能解释。

5.2.3 模型建立

1. 经典标度律

以 Chinchilla 标度律为基础 [2], 验证损失 L 满足:

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} \quad (12)$$

其中, E 表示 $N, D \rightarrow \infty$ 时模型给出的损失极限; A, B 为尺度系数, α, β 为衰减指数, 分别共同决定参数规模与数据规模的收益变化。该模型将数据质量固定在参考水平。

2. 质量缺口修正

将质量项以“质量缺口”形式引入，得到广义标度律：

$$L(N, D, Q) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} + C(1 - Q)^\gamma, \quad C > 0, \gamma > 0 \quad (13)$$

本文将 $Q = 1$ 设为参考质量，此时质量缺口项为零，广义模型退化为经典标度律的函数形式。Pythia 样本的 $Q = 1$ 是归一化设定，不是对其语料质量的实测结论；联合估计允许各参数相对于经典拟合重新调整。在此模型假设下，固定质量对应的渐近损失为：

$$\lim_{N, D \rightarrow \infty} L(N, D, Q) = E + C(1 - Q)^\gamma \geq E \quad (14)$$

在这一加性结构下，质量缺口决定渐近损失相对于 E 的增量。固定 $Q < 1$ 时，增加 N 、 D 可以减小规模项，但质量项保持不变。该渐近关系是模型的理论性质，其适用范围受拟合数据限制。

3. 边际效用与弹性

在参考点 (N_0, D_0, Q_0) 处，各因素的边际效用为：

$$\frac{\partial L}{\partial N} = -\alpha A N^{-\alpha-1}, \quad \frac{\partial L}{\partial D} = -\beta B D^{-\beta-1}, \quad \frac{\partial L}{\partial Q} = -\gamma C(1 - Q)^{\gamma-1} \quad (15)$$

对应弹性为：

$$\varepsilon_N = \frac{\partial L}{\partial N} \frac{N_0}{L_0}, \quad \varepsilon_D = \frac{\partial L}{\partial D} \frac{D_0}{L_0}, \quad \varepsilon_Q = \frac{\partial L}{\partial Q} \frac{Q_0}{L_0} \quad (16)$$

4. 质量提升与参数扩张的局部等效关系

在固定 D 和配比的条件下，分别考察从同一参考点出发的微小质量提升与参数扩张。定义 R_{NQ} 为两种方案产生同一阶损失降幅时的正向等效增量比：

$$\begin{aligned} \left| \frac{\partial L}{\partial Q} \right| dQ &= \left| \frac{\partial L}{\partial N} \right| dN_{\text{eq}}, \\ R_{NQ} &= \frac{dN_{\text{eq}}}{dQ} = \frac{\gamma C(1 - Q)^{\gamma-1}}{\alpha A N^{-\alpha-1}} = \frac{\gamma C}{\alpha A} (1 - Q)^{\gamma-1} N^{\alpha+1}. \end{aligned} \quad (17)$$

沿等损失曲线有 $dN/dQ = -R_{NQ}$ ，即提高质量允许减少参数。固定 Q 时， R_{NQ} 随 $N^{\alpha+1}$ 增长，反映参数扩张的边际收益递减。该指标度量损失效果的等价关系，算力效率则同时取决于参数训练与质量处理的成本。

5. 领域效应的相似性

线性混合模型下，两个训练域 i, j 对 13 个验证域损失的效应向量分别为 $\mathbf{a}_i, \mathbf{a}_j$ 。采用中心化后的余弦相似度描述两域的相对效应模式：

$$s_{ij} = \frac{\langle \mathbf{a}_i - \bar{\mathbf{a}}, \mathbf{a}_j - \bar{\mathbf{a}} \rangle}{\|\mathbf{a}_i - \bar{\mathbf{a}}\| \|\mathbf{a}_j - \bar{\mathbf{a}}\|} \quad (18)$$

其中 $\bar{\mathbf{a}}$ 为 17 个域的平均效应向量。 $s_{ij} \rightarrow 1$ 表示两域在验证任务上的相对效应模式趋同； $s_{ij} \rightarrow -1$ 表示效应模式相反，反映任务间的收益权衡。余弦相似度不包含效应幅值，且线性配比模型不含交互项，因而这一指标描述的是效应结构，不识别等量替代关系或联合使用带来的额外增益。

5.2.4 模型求解

1. 经典标度律拟合与留出验证

经典标度律在 B1 全量 1,176 点上的拟合结果如图9所示，参数估计如下：

$$L(N, D) = 1.6898 + \frac{0.3540}{N^{0.3400}} + \frac{1.2403}{D^{0.2799}} \quad (19)$$

拟合 $R^2 = 0.9999998$ 、 $\text{RMSE} = 1.5 \times 10^{-4}$ 、 $\text{MAPE} = 0.004\%$ 。以 4 个最小模型训练、预测其余 4 个更大模型，留出 R^2 仍为 0.9999997、 $\text{MAPE} = 0.005\%$ ，说明标度律参数在模型族内部可迁移。




图 9 经典标度律对 Pythia 训练轨迹的拟合（左：随参数规模；右：随数据规模）

B1 拟合残差的标准差为 1.5×10^{-4} ，远小于损失本身的标准差 0.342。这一结果表明附件中的规模关系与所选函数高度吻合，但不能由此推断跨数据来源的泛化能力。下文使用 B4、B5 评估外部适用性，并将 B2 的半合成轨迹结果单独讨论。

2. 广义标度律参数估计

将 Pythia（无质量信息，取参考质量 $Q = 1$ ）与 B6 质量实验联合拟合，采用表9选定的加性质量缺口形式，参数估计如表10所示。

表 10 广义标度律参数估计

参数	估计值	参数	估计值
不可约损失 E	1.6558	数据规模指数 β	0.2767
规模系数 A	0.3808	质量缺口系数 C	0.3544
规模指数 α	0.3266	质量指数 γ	0.9779
数据系数 B	1.2515	联合拟合 R^2	0.9896

由表10可知，质量指数 $\gamma = 0.9779 \approx 1$ ，说明质量缺口近似线性地抬高模型的渐近损失下限；联合拟合 $R^2 = 0.9896$ 、 $\text{RMSE} = 0.036$ 、 $\text{MAPE} = 0.66\%$ 。由于联合数据与经典拟合数据不同，两者的 R^2 不能直接用于判断引入质量项是否提高精度。图10展示固

定规模下的预测质量效应。由模型的渐近表达式 $E + C(1 - Q)^\gamma$ 可得：当 $Q = 1$ 时下限为 1.656， $Q = 0.6$ 时为 1.801， $Q = 0.3$ 时为 1.906。




图 10 固定 N 、 D 时模型预测的质量效应 ($Q = 1$ 退化为经典标度律)

3. 分层检验与适用范围

广义标度律在 6 组不同来源与性质的数据上的分层检验结果如表11所示，预测值与各来源给定值的对比如图11所示。

表 11 广义标度律的分层验证

验证来源	样本数	性质	r	RMSE	MAPE(%)
B4 跨族收敛点	57	真实	0.975	0.293	8.8
B5 已发表标度律	44	真实	0.910	0.193	8.0
B7 质量扩展新增点	90	半合成	0.991	0.056	1.6
B10 百亿参数以上	128	估算	1.000	0.020	1.0
B2 Cerebras 族外	1,029	半合成	0.666	1.245	33.7
B8 大规模矩阵（方向重定向）	984	半合成	0.638	1.294	133.4

由表11可知，模型在 B4 与 B5 上的相关系数分别为 0.975 和 0.910，MAPE 分别为 8.8% 和 8.0%，表明其能够描述部分跨族规模趋势，但仍存在来源差异与绝对误差。B7 的 90 个新增点给出 1.6% 的 MAPE，支持同一半合成框架内的扩展一致性；B10 属于估算数据，且检验中统一设定 $Q = 1$ ，因而其低误差既不是独立实验验证，也不能用于验证质量项。

B2 的 MAPE 为 33.7%，B8 校准段在尝试反向变换后仍达 133.4%。较大的误差表明，该模型不能统一解释所有补充数据的损失水平。B8 的部分损失低于本文估计的渐近下限，方向变换也未消除偏差，反映出不同来源之间的损失尺度或生成机制差异。




图 11 广义标度律预测值与给定损失的多源对比（含真实、半合成与估算数据）

主拟合中，B1 的参数范围约为 0.07–12B、数据范围为 0.134–299.893B tokens；B6 的参数范围约为 0.07–11.97B、数据范围为 10–600B tokens。质量效应的定量证据主要来自 B6/B7 半合成数据；大规模估算点用于考察外推一致性，其证据等级低于直接实验观测。

此外，用 B3 的 8 条插值轨迹检验数据规模指数：在每条轨迹内（ N 固定）以 $L - (E + AN^{-\alpha})$ 对 D 做双对数回归，得到的幂指数为 $-0.2806 \sim -0.2803$ ，与经典拟合的 $-\beta = -0.2799$ 高度一致，说明插值轨迹与经典拟合基本自洽；由于 B3 来源于 Pythia 检查点插值，该结果不是独立观测验证。

4. 弹性结果与领域效应

规模与质量的边际效用对比如图12所示，等损失曲线如图13所示，弹性与替代率计算结果如表12所示。

表 12 弹性与质量—参数替代关系

$N_0(B)$	$D_0(B)$	Q_0	ε_N	ε_D	ε_Q	R_{NQ} (B/单位质量)
1	100	0.6	-0.0491	-0.0383	-0.0838	2.844
12	300	0.6	-0.0248	-0.0321	-0.0953	76.838

在 $(N_0, D_0, Q_0) = (1, 100, 0.6)$ 处，质量弹性的绝对值约为参数弹性的 1.7 倍，即在相同比例的微小变量变化下，质量改善产生更大的损失降幅。两个参考点的局部替代率分别为 2.844 与 76.838 B/单位质量。以质量提升 0.1 作一阶估计，对应的等效参数增量




图 12 规模与质量的边际效应（左：随 N 衰减；右：在 $Q < 1$ 内随 Q 缓慢增加）




图 13 等损失曲线：达到同一损失所需参数量随质量的演化 ($D = 300B$)

分别为 0.284B 与 7.684B；这些数值为局部线性近似，其误差随变化幅度增加而扩大，不表示等成本投入。

估计值 $\gamma = 0.9779 < 1$ 使 $|\partial L/\partial Q|$ 在 $Q < 1$ 内单调增加，并在 $Q \rightarrow 1^-$ 时发散。因此，质量边际效应的定量解释限于远离端点的区域， $Q = 1$ 附近的导数不具有可靠的资源配置含义。图13中的等损失曲线描述固定数据量下的参数需求；超出主拟合规模的部分属于理论外推。

领域效应的相似与相反模式如图14所示。

图14中，wikipedia_en 与 pile_cc、pubmed_central 与 pubmed_abstracts 的相似度分别为 0.925 和 0.903，表明它们在 13 个验证域上的相对效应模式接近。pubmed_central 与 enron_emails 的相似度为 -0.967 ，表示两者的效应方向存在明显差异。这些差异反映了配比调整对不同验证任务的影响并不一致，单一领域的收益需要结合整体任务权重评价。

利用问题一的线性配比模型,推荐配比相对于参考配比的加权损失差为 $M = \hat{L}(\mathbf{p}_{\text{rec}}) - \hat{L}(\mathbf{p}_{\text{ref}}) = -0.1988$ 。该结果对应附件 A 的验证域及权重口径。在配比效应与规模、质量




图 14 训练领域效应的余弦相似度（暖色为正、冷色为负；不直接表示互补增益）

项可分离且损失增量尺度可迁移的假设下， $M(\mathbf{p})$ 可作为广义标度律的加性情景修正。跨来源检验显示损失水平存在差异，因此这一修正的跨规模解释依赖上述假设，0.1988 不代表所有规模下均可实现的损失降幅。

模型结果表明，参数扩张的边际收益随规模增大而递减，质量改善与参数扩张之间存在参考点相关的局部等效关系。跨族与文献数据上的 MAPE 分别为 8.8% 和 8.0%，而半合成数据的检验误差存在明显差异。由此，资源配置分析以所估标度关系为基础，同时受质量评分尺度、数据来源和外推范围的约束。

5.3 问题三：算力约束下的资源配置与结构性转移

5.3.1 具体分析

问题三关注有限算力如何在模型参数、训练数据与质量提升之间分配，以及最优配置如何随预算和上下文长度变化。算力最优训练研究表明，参数规模与训练数据量需要协同配置，单独扩大模型并不必然获得最优性能 [2]。本文承接问题二的广义标度律，将基础训练、质量处理与注意力计算纳入统一预算约束，在给定领域配比的情景下求解参数量、数据量与质量水平。

具体而言，先统一前两问输出与算力公式的变量口径，建立三类成本函数下的约束优化模型；随后求解三档预算的资源配置，并通过连续预算网格识别质量投入的启动、提升与饱和阶段；最后分析上下文长度的影响，比较不同质量成本和领域配比下的结果。这里的配置变化均指既定标度律与成本假设下的数值预测。

5.3.2 模型准备

1. 输入数据与变量口径

问题二输出的广义标度律参数为

$$(E, A, \alpha, B, \beta, C_q, \gamma) = (1.6558, 0.3808, 0.3266, 1.2515, 0.2767, 0.3544, 0.9779). \quad (20)$$

本节以 C_q 表示质量缺口系数，以 C_b 表示算力预算，避免与成本函数混淆。算力计算中的 N 、 D 分别表示参数个数与训练 token 数；代入问题二标度律时，使用 $n = N/10^9$ 、 $d = D/10^9$ 。结果表中的 B 表示十亿，数据量列的单位为十亿 tokens。

基线质量采用参考配比加权的领域评分：

$$Q_0 = \sum_{k=1}^{17} \bar{p}_k Q_k = 0.5510, \quad (21)$$

其中 $\bar{p}_k$ 为 A4 训练配方的平均配比， Q_k 为经 A16 映射得到的领域质量评分。该口径反映参考配方，而非 A1–A3 抽样样本的领域构成；未加权样本均值 0.4952 用作基线灵敏度对照。按照问题二对质量尺度的讨论，附件 A 的综合评分与附件 B 的 Q_{score} 并非经验证的等值量。本节沿用其数值可衔接的情景设定，因此最优质量和预算门槛的定量解释依赖这一假设。

上下文长度 L_{ctx} 由架构与任务需求外生给定，不作为优化变量。根据附件 C7 的 `max_position_embeddings` 字段，考察 2048、4096、8192、32768、131072 tokens 五个档位。质量可行域取 $Q \in [Q_0, 1]$ ，其中 $Q = 1$ 表示模型设定的参考质量上界，不意味着现实语料达到绝对完美质量。

2. 求解方法

采用序列二次规划法 (SLSQP) 求解约束优化问题，以 $x = \ln N$ 、 $y = \ln D$ 表示规模变量，缓解变量数量级差异。三档预算计算使用 8 组初值，预算扫描使用 5 组初值，并在求解器报告成功的结果中选取损失最小者。多初值有助于降低初值依赖，但不构成全局最优性证明；下文的“最优配置”均指现有数值求解得到的最优候选解。由于 $\gamma < 1$ 时质量项在 $Q = 1$ 处的导数不有界，饱和解按边界配置解释，不使用该端点的导数判断资源收益。

5.3.3 模型建立

1. 目标函数与预算约束

在给定配比 $\mathbf{p}$ 与上下文长度下，最小化预测验证损失：

$$\begin{aligned} \min_{N, D, Q} \quad & L = E + \frac{A}{n^\alpha} + \frac{B}{d^\beta} + C_q(1 - Q)^\gamma + M(\mathbf{p}), \\ \text{s.t.} \quad & C_{\text{tot}} = 6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C_b, \\ & Q_0 \leq Q \leq 1, \quad n = N/10^9, \quad d = D/10^9, \end{aligned} \quad (22)$$

其中 $\eta = 2 \times 10^{-4}$, $[z]_+ = \max(z, 0)$ 。基础训练项采用 $6ND$ 近似 [2]; 质量处理与注意力开销沿用赛题给定形式 [14]。计算中另设宽范围数值边界 $10^5 \leq N \leq 10^{15}$ 、 $10^6 \leq D \leq 10^{16}$, 以限定搜索域, 而非表示可用语料的实际供给上限。

基准结果采用参考配比 $M = 0$ 。推荐配比取问题一的有界方案, 对应 $M = -0.1988$, 作为独立情景对照。由于本模型中的 M 是与 N, D, Q 无关的常数, 其作用是平移预测损失, 不改变资源配置的最优点。因此, 本节并未重新联合优化配比; 这一处理也依赖问题二所述配比效应可分离、损失增量尺度可迁移的假设。

三类质量成本函数为

$$\begin{aligned} g_{\text{exp}}(Q) &= 10^7 e^{6Q}, \\ g_{\text{pow}}(Q) &= 5 \times 10^9 Q^4, \\ g_{\text{log}}(Q) &= 2 \times 10^9 \ln(1 + 10Q). \end{aligned} \quad (23)$$

$g(Q) - g(Q_0)$ 表示单位 token 的增量质量处理成本, 单位为 FLOPs/token。总质量成本还需乘以数据量 D , 故即使 Q 保持不变, 扩大语料规模也会增加质量处理开销。本文以幂函数型为基准, 并比较另两种函数下的配置差异。

2. 注意力与基础训练的成本分界

令注意力成本等于基础训练成本, 可得

$$\eta N D L_{\text{ctx}} = 6ND \implies L_{\text{crit}} = \frac{6}{\eta} = 30,000 \text{ tokens}. \quad (24)$$

定义成本比 $\lambda = \eta L_{\text{ctx}}/6$, 则

$$C_{\text{tot}} = 6(1 + \lambda)ND + D[g(Q) - g(Q_0)]_+. \quad (25)$$

因此, 长上下文使训练与注意力合计的单位 ND 成本增加为原基础训练成本的 $1 + \lambda$ 倍。 L_{crit} 仅表示两项成本相等的分界, 不等于最优配置必然发生突变的临界点; 注意力成本超过基础训练成本, 也不自动意味着其超过总预算的一半, 因为预算还包含质量成本。

3. 规模配置的平衡关系

固定质量 Q , 记 $K_1 = 6(1 + \lambda)$ 、 $K_2 = g(Q) - g(Q_0)$ 。由于预测损失随 N, D 增大而降低, 在规模边界不活跃时, 最优配置使用全部预算, 即 $D(K_1 N + K_2) = C_b$ 。将损失的规模项写成 $\tilde{A}N^{-\alpha} + \tilde{B}D^{-\beta}$, 其中 $\tilde{A} = A(10^9)^\alpha$ 、 $\tilde{B} = B(10^9)^\beta$, 由拉格朗日一阶条件得到

$$\alpha \tilde{A} N^{-\alpha-1} [N + \tau(Q)] = \beta \tilde{B} D^{-\beta}, \quad \tau(Q) = \frac{K_2}{K_1}. \quad (26)$$

$\tau(Q)$ 与 N 具有相同的计量口径, 可解释为质量处理成本折算的等效附加参数规模。它不是额外的训练 token 数, 也不表示实际增加了模型参数。

当 $Q = Q_0$ 时, $K_2 = 0$, 式(26)退化为经典平衡关系; 在固定上下文长度下有

$$N^* \propto C_b^{\beta/(\alpha+\beta)}, \quad D^* \propto C_b^{\alpha/(\alpha+\beta)}. \quad (27)$$

此时 $\beta/(\alpha + \beta) \approx 0.459$ 、 $\alpha/(\alpha + \beta) \approx 0.541$, 即数据量随预算增长略快于参数量。投入质量后, 需使用含 $\tau(Q)$ 的平衡式; 跨越不同质量阶段的结果不能直接用于验证式(27)的严格比例关系。

4. 配置阶段与识别口径

以质量提升完成度和质量预算份额描述配置变化：

$$\Theta(C_b) = \frac{Q^*(C_b) - Q_0}{1 - Q_0}, \quad f_Q(C_b) = \frac{D^*[g(Q^*) - g(Q_0)]}{C_b}. \quad (28)$$

$\Theta = 0$ 对应基线质量， $0 < \Theta < 1$ 对应质量提升， $\Theta = 1$ 对应质量达到上界。以首次观察到正质量投入和首次观察到饱和配置的网格点识别阶段边界，同时报告完成度阈值和份额峰值，描述阶段内部变化。

现有扫描在 $[10^{18}, 10^{25}]$ FLOPs 上设置 141 个对数等距预算点，相邻预算比为 $10^{0.05} \approx 1.122$ ；其中 1.41×10^{19} FLOPs 处未取得成功解，其余 140 点用于分析，图中保留该缺口。变化率 $d\Theta/d\log_{10} C_b$ 由有效网格点的数值差分计算，它不同于对数弹性 $d\ln \Theta/d\ln C_b$ ，且在 $\Theta = 0$ 时后者不定义。以下门槛均为网格识别值，不作为精确临界预算。

5.3.4 模型求解

1. 三档预算的基准配置

在幂函数型质量成本、 $L_{\text{ctx}} = 2048$ tokens 和参考配比下，三档预算的数值结果见表13，规模与质量的变化见图15。

表 13 三档预算的基准配置（幂函数型成本， $L_{\text{ctx}} = 2048$ ， $M = 0$ ）

预算 (FLOPs)	N^* (B)	D^* (B tokens)	Q^*	L^*	D^*/N^*	f_Q (%)
10^{19}	0.225	6.9	0.551	3.170	30.9	0.0
10^{22}	6.089	229.5	1.000	2.145	37.7	10.4
10^{24}	44.937	3418.0	1.000	1.897	76.1	1.6




图 15 三档预算下的规模与质量配置。横轴按真实预算的对数间距排列；各点表示独立情景，虚线仅辅助比较。

预算由 10^{19} 增至 10^{24} FLOPs 时, 参数量由 0.225B 增至 44.937B, 训练数据量由 6.9B 增至 3418.0B tokens, 预测损失由 3.170 降至 1.897。数据量与参数量之比由 30.9 升至 76.1, 表明预算扩张伴随配置结构变化。低预算下质量保持在基线水平, 预算分别用于基础训练 (93.6%) 与注意力计算 (6.4%); 中、高预算下质量均达到上界。

高预算时质量份额降至 1.6%, 并不意味着不再支付质量成本。此时单位 token 的质量成本固定, 而基础训练成本还随参数量增长, 故质量开销在总预算中的相对份额下降。另需注意, 高预算配置超过问题二主拟合数据的规模范围, 属于模型外推; 数据受限训练研究也表明, 重复 token 的收益不能始终视为新增独立数据的收益 [7]。本节未引入语料供给和重复训练约束, 因而这些配置是既定成本条件下的理论情景。

2. 预算扫描与配置阶段

图16展示质量完成度与预算份额的联合变化, 并放大主要转移区间。表14列出有效扫描点上的关键识别量。




图 16 预算变化下的配置阶段 (幂函数型成本, $L_{\text{ctx}} = 2048$, $M = 0$)。上排为完整预算范围, 下排放大转移区间; 虚线表示首次观察到质量投入和饱和配置的网格预算, 曲线缺口对应求解失败点。

在有效扫描点上, 质量配置表现为三个阶段。预算不超过 1.58×10^{19} FLOPs 时, 已取得的解均保持 $Q^* = Q_0$; 至 1.78×10^{19} FLOPs, 首次观察到正质量投入, 表明启动边界位于这两个相邻有效预算之间。此后质量完成度与质量份额同步上升, 在 6.31×10^{19} FLOPs 时 $Q^* \approx 0.955$; 至下一网格点 7.08×10^{19} FLOPs, 质量达到上界, 质量份额为

表 14 配置阶段的网格识别结果

识别量	预算 (FLOPs)
首次观察到正质量投入	1.78×10^{19}
完成度 Θ 首次达到 25%	2.82×10^{19}
完成度 Θ 首次达到 50%	3.98×10^{19}
完成度 Θ 首次达到 75%	5.62×10^{19}
完成度变化率 $d\Theta/d\log_{10} C_b$ 最大	6.31×10^{19}
首次观察到 $Q^* = 1$ (亦首次超过 $\Theta = 99\%$)	7.08×10^{19}
质量预算份额最大 (40.7%)	7.08×10^{19}

40.7%。因此，现有扫描将饱和边界定位在 $[6.31, 7.08] \times 10^{19}$ FLOPs 范围内。上述区间描述数值扫描中的阶段切换，不排除网格之间存在更细的变化。

进入饱和阶段后，质量水平保持为 1，质量预算份额逐步下降，新增算力主要支持参数和数据规模扩张。其原因是质量已触及可行上界，而非质量边际收益趋于零：由问题二的参数 $\gamma = 0.9779 < 1$ 可知， $|\partial L/\partial Q| = C_q \gamma (1 - Q)^{\gamma-1}$ 在 $Q < 1$ 内缓慢增加，接近端点时不有界。因此，本节用边界约束解释饱和配置，并将三阶段结论限定于当前成本函数、基线质量与上下文设定。

3. 上下文长度的影响

固定预算 $C_b = 10^{22}$ FLOPs，五档上下文的配置见表15。图17同时展示参数规模的连续变化，以及较低预算下的质量响应。

表 15 上下文长度敏感性 ($C_b = 10^{22}$ FLOPs，幂函数型成本， $M = 0$)

L_{ctx} (tokens)	λ	N^* (B)	D^* (B tokens)	Q^*	L^*	注意力份额 (%)
2048	0.068	6.089	229.5	1.000	2.145	5.7
4096	0.137	5.897	223.5	1.000	2.149	10.8
8192	0.273	5.562	212.7	1.000	2.157	19.4
32768	1.092	4.318	170.2	1.000	2.194	48.2
131072	4.369	2.705	109.1	1.000	2.273	77.3

当上下文由 2048 增至 131072 tokens 时，注意力份额从 5.7% 升至 77.3%，最优参数量和数据量分别下降约 55.6% 和 52.5%，预测损失上升约 0.128。五档配置的质量均为 1，说明该预算下长上下文的额外开销主要挤压参数与数据规模。32768 tokens 虽已超过成本分界，但注意力份额仍为 48.2%，进一步说明“两类成本相等”与“注意力占总预算过半”不是同一条件。

低预算情景具有不同响应。在 10^{19} FLOPs 下，上下文从 1024 增至 150000 tokens 时，已有计算点的最优质量从基线 0.551 升至约 0.670。这一现象与质量成本的结构有关：注




图 17 上下文长度对资源配置的影响（幂函数型成本， $M = 0$ ）。左： 10^{22} FLOPs 下的参数规模，方形点为 C7 五档配置；右： 10^{19} 、 10^{20} 、 10^{21} FLOPs 下的质量水平，后两条曲线重合。竖线表示注意力与基础训练成本相等的位置。

注意力开销增长使可负担的数据量下降，而较小的 D 又降低整份语料提升质量的总成本，从而改变规模与质量的相对投入收益。这是当前成本模型中的耦合效应，不应直接解释为所有长上下文训练都更适合提高数据质量。连续扫描中未成功求解的位置在图中保留为缺口。

4. 质量成本函数与配比情景

图18比较三类单位 token 增量质量成本，表16给出相同预算与上下文下的配置。




图 18 三类单位 token 增量质量成本 $g(Q) - g(Q_0)$ （基线 $Q_0 = 0.5510$ ）。各曲线均从零增量成本出发，函数形式与系数见式(23)。

成本函数对低预算下的质量决策影响明显： 10^{19} FLOPs 时，幂函数型保持基线质量，指数型选择 $Q^* = 0.660$ ，对数渐进型则达到质量上界；三种配置的预测损失差异约为 0.057。因此，“低预算不投入质量”仅适用于基准成本情景。中、高两档预算下，三类成本均给出 $Q^* = 1$ ，但资源规模并非完全一致：在 10^{22} FLOPs 下，数据量为 229.5–274.2B

表 16 三类质量成本下的配置对比 ($L_{\text{ctx}} = 2048$, $M = 0$)

预算 (FLOPs)	成本类型	N^* (B)	D^* (B tokens)	Q^*	L^*	f_Q (%)
10^{19}	指数型	0.265	5.1	0.660	3.163	12.9
	幂函数型	0.225	6.9	0.551	3.170	0.0
	对数渐进型	0.354	3.0	1.000	3.113	31.6
10^{22}	指数型	5.972	237.9	1.000	2.144	8.9
	幂函数型	6.089	229.5	1.000	2.145	10.4
	对数渐进型	5.527	274.2	1.000	2.138	2.9
10^{24}	指数型	44.796	3437.7	1.000	1.897	1.3
	幂函数型	44.937	3418.0	1.000	1.897	1.6
	对数渐进型	44.298	3509.0	1.000	1.897	0.4

tokens，最大值较最小值高约 19.5%。现有结果支持所考察中高预算情景下的质量饱和判断，不支持配置对成本形式完全不敏感。

领域配比优化研究表明，训练域权重可以影响预训练效率 [8]。在本节的加性修正情景中，将 $M = 0$ 改为 $M = -0.1988$ 后， 10^{22} FLOPs 下的最优 (N^*, D^*, Q^*) 不变，预测损失由 2.1450 降至 1.9462。现有二分求解给出的参考配比等损失预算约为 3.05×10^{23} FLOPs，即约为原预算的 30 倍。该倍数是固定损失平移假设下的模型内算力等价估计，既非实际训练加速比，也不由上述配比文献直接验证；其数值对平移项的跨规模适用性及损失曲线形状敏感。

综上，在参考配比、幂函数型质量成本和固定上下文的基准情景下，预算扩张依次对应基线质量、质量提升和质量饱和三个配置阶段。长上下文增加注意力成本，并通过数据规模与质量处理成本的耦合影响配置；成本函数则显著影响低预算质量决策。上述结果提供了给定模型中的资源配置依据，其定量适用性仍受质量评分衔接、可用数据供给及标度律外推范围约束。

5.4 问题四的模型的建立和求解

5.4.1 具体分析

针对问题四，本问属于**技术演进建模与前沿预测**类问题，需要结合历史评测数据建立技术演进模型，分离并量化规模扩张与非规模技术进步的贡献占比，并预测未来 12 至 24 个月开源大语言模型能力的前沿边界 [12]。本问综合采用“口径界定 → Loss—Benchmark 桥接 → 面板回归分解 → 前沿预测 → 宏观证据校验”五步框架：首先明确综合能力的度量方式、开源筛选口径、模型类型口径与时间轴口径；再按可比性分层建立交叉熵损失与 Leaderboard 得分的映射，把前三问以损失为目标的结论桥接到以评测得分为度量的能力；然后以参数规模与年份为解释变量做面板回归（含年份固定效应），

把能力提升分解为“规模扩张”与“非规模技术进步”两部分；接着用 logistic 饱和模型与结构外推两条路线给出未来 12/24 个月的前沿预测与不确定性区间；最后用附件 C4 的算力、数据量与开源权重证据检验“算力增长放缓”情景的合理性。

本问严格完成题设的必用要求：对 C8 的逐任务评测 JSON 做逐任务聚合分析（不依赖汇总表），对 C4 的算力、数据量与开源权重字段作宏观证据检验，桥接数据按可比性等级（C6 的 High/Medium，并以 C5 对照）分层使用。

5.4.2 模型准备

1. 口径界定

(1) **综合能力度量**。采用 Open LLM Leaderboard v2 的六维平均分 $\bar{B}$ ：IFEval（指令遵循）、BBH（多跳推理）、MATH Lvl 5（数学）、GPQA（研究生级问答）、MUSR（多轮推理）、MMLU-PRO（专业知识）。六维等权平均，取值 0 ~ 100。

(2) **时间轴口径**。统一以 C1 的 Submission Date（提交日期）为基准，并按“年 + 月”折算为连续时间变量 $t = \text{年份} - 2019 + (\text{月} - 0.5)/12$ 。之所以不采用发布日期或版本日期，是因为 Leaderboard 上的评测结果均在提交时冻结、且提交日期字段完整无缺失；C3 的 Year 字段仅用于 2019–2023 的历史锚点对照。

(3) **开源筛选口径**。同时要求两个条件：(a) 模型权重可获取（Type 属 pretrained、持续预训练、chat、域内微调四类）；(b) Hub License 允许研究与复现，即采用 apache-2.0、mit、gpl-3.0、cc-by-4.0、mpl-2.0、bsd-3-clause、llama2/3/3.1/3.2/3.3、gemma、cc-by-sa-4.0、openrail 等许可，排除 cc-by-nc 系列（非商用）、creativeml-openrail、bigscience-bloom-rail 等受限许可以及未知许可。筛选漏斗见表17。

(4) **模型类型口径**。明确区分 pretrained（含持续预训练，共 231 条）与 chat/finetuned（经对话指令或监督微调，共 1,497 条）两类，分组统计规模效应与时间效应；base 合并模型（1,724 条，非独立训练过程）与多模态模型（9 条，任务构成不同）不并入主分析。

表 17 数据筛选漏斗（C1 排行榜）

筛选层级	记录数	说明
C1 全量记录	4,576	提交日期 2024-06-08 ~ 2025-03-13
六维得分完整	4,576	无缺失
时间/参数/六维齐备	4,561	剔除 15 条参数或 日期缺失
许可允许研究复现（开源口径）	2,346	符合上述许可白名单
其中 pretrained	231	类型为 pretrained / 持续预训练

表 17 数据筛选漏斗（续）

筛选层级	记录数	说明
其中 chat/finetuned	1,497	类型为 chat / 域内 微调

2. 附件 C8 的逐任务聚合

附件 C8 含 1,863 个模型子目录、1,958 个评测 JSON。本文按目录取最新可解析记录，提取每个模型在各任务上的原始指标（按 acc_norm、acc、prompt_level_loose_acc、inst_level_loose_acc、exact_match 的优先级选取），共成功解析 1,860 个模型，跳过 7 个损坏或无有效记录的目录。解析后可用的子任务维度共 37 项：BBH 子任务 24 项、MATH-Hard 子任务 7 项、GPQA 子集 3 项、MUSR 子任务 3 项。

由于 C8 保存的是原始指标、而 C1 保存的是官方按随机基线归一化后的六维得分（例如 $GPQA = (raw - 0.25) / 0.75$ 、 $MMLU-PRO = (raw - 0.10) / 0.90$ 、 $IFEval = (prompt_strict + inst_strict) / 2$ ），两者存在系统性水平差。因此本文的处理是：跨模型得分分析使用 C1，逐任务结构分析在 C8 的原始指标空间内进行，并以秩相关作为两者的衔接验证，结果见表 18。

表 18 C8 解析结果与 C1 的一致性校验

任务	匹配模型数	Pearson r	Spearman ρ	平均绝对偏差
IFEval	1,896	0.987	0.987	2.88
BBH	1,898	0.998	0.997	21.06
MATH Lvl 5	1,897	0.803	0.812	3.47
GPQA	1,894	0.987	0.992	23.38
MUSR	1,894	0.973	0.977	30.73
MMLU-PRO	1,896	0.998	0.998	7.56

由表 18 可知，两套数据的秩一致性均在 0.81 以上（多数在 0.97 以上），说明 C8 的逐任务解析结果与官方汇总得分反映同一批评测；平均绝对偏差较大的维度（GPQA 23.4、MUSR 30.7、BBH 21.1）正是“原始分”与“基线归一化分”差异最大的维度，与前述口径说明完全对应。这一校验保证了后续逐任务结论的可靠性。

3. 算法选择

Loss—Benchmark 映射采用按可比性分层的线性最小二乘（并在全样本上给出整体拟合），分层可避免“同模型同验证集”与“跨族近似验证集”样本混用造成的偏置；规模/时间分解同时采用线性时间 OLS 与年份固定效应两种设定，后者把非规模技术进步完全交由年效应吸收，可显著缓解规模与年份的共线性；前沿外推同时采用 logistic 饱和模型（有界、符合满分 100 的物理约束）与结构外推（把分解方程直接用作预测方程），

两条路线互为校验；不确定性由残差 bootstrap（600 次重抽样）与情景分析共同给出。

5.4.3 模型建立

步骤 1：Loss—Benchmark 映射模型

设验证损失 L 与 Leaderboard 均分 $\bar{B}$ 之间存在近似线性关系：

$$\bar{B} = a + bL \quad (29)$$

系数 a 、 b 由最小二乘估计，并按 C6 的 Loss_Comparability 字段分为“高可比”（同模型同验证集，主要来自 Pythia，可与附件 B 对照）与“中可比”（Loss 来自不同技术报告或论文）两层分别估计。映射误差对结论的影响通过分层的 R^2 、MAPE 与相关系数共同刻画。

步骤 2：规模扩张与技术进步分解模型

以参数量对数与时间为解释变量建立面板回归：

$$\text{Score}_{it} = b_0 + b_P \log_{10} P_{it} + b_t t + \varepsilon_{it} \quad \text{或} \quad \text{Score}_{it} = \alpha_t + b_P \log_{10} P_{it} + \varepsilon_{it} \quad (30)$$

其中 b_P 为规模系数（参数量每增大 10 倍带来的得分提升）， b_t 为时间系数（每年非规模技术进步带来的得分提升）， α_t 为年份固定效应。前沿提升的 shift-share 分解为

$$\Delta F = \underbrace{b_P \Delta \log_{10} P_{\text{frontier}}}_{\text{规模扩张贡献}} + \underbrace{[\Delta F - b_P \Delta \log_{10} P_{\text{frontier}}]}_{\text{非规模技术进步贡献}} \quad (31)$$

两者占比即为所求贡献份额。 $\Delta \log_{10} P_{\text{frontier}}$ 取各年“参数量最大的开放权重模型”的对数差， ΔF 取累计前沿（按定义单调不减）之差。

步骤 3：能力前沿预测模型（两条路线）

路线一（曲线外推）：能力前沿随时间的演化以 logistic 饱和函数刻画，并用残差 bootstrap 给出区间：

$$F(t) = \frac{K}{1 + e^{-r(t-t_0)}}, \quad K \text{ 为饱和上界, } r \text{ 为增长率, } t_0 \text{ 为拐点} \quad (32)$$

前沿序列取“年度累计最大”与“月度前 1% 均值累计最大”拼接而成的单调不减序列。算力增长放缓情景以“增速减半”实现：

$$F_{\text{slow}}(t) = K \left[1 + e^{-r(\min(t, t_h) - t_0)} \right]^{-1}, \quad t_h \text{ 为增速减半时刻} \quad (33)$$

路线二（结构外推）：直接把分解方程用作预测方程，

$$\hat{F}(t + \Delta) = F(t) + [b_P \Delta \log_{10} P + b_t] \cdot \Delta \quad (34)$$

并按“前沿模型规模持平（ $\Delta \log_{10} P = 0$ ）”“算力增长放缓（ b_t 减半）”“规模继续扩张（ $\Delta \log_{10} P = +0.3/\text{年}$ ）”三种情景给出区间。




图 19 验证损失与 Leaderboard 均分的映射关系（按可比性分层）

5.4.4 模型求解

1. Loss—Benchmark 桥接结果

映射结果如图19所示，分层拟合结果如表19所示。

表 19 Loss—Benchmark 映射的分层拟合结果（C6， $n = 75$ ）

可比性	n	Pearson r	Spearman ρ	斜率 b	R^2	MAPE(%)
高可比	7	-0.397	-0.607	-0.882	0.16	5.6
中可比	68	-0.502	-0.509	-19.185	0.25	57.3
全样本	75	-0.510	-0.549	-20.417	0.26	67.8
C5 对照（全样本）	43	-0.502	—	-16.155	—	—

由表19可知：（1）损失与能力得分确实负相关（全样本 $r = -0.510$ ，Spearman $\rho = -0.549$ ， $p < 10^{-6}$ ），验证了“以损失为目标的资源配置可转化为能力收益”的桥接逻辑；（2）但映射的 R^2 仅 0.26、MAPE 高达 67.8%，说明桥接关系是弱关系，其原因是中可比样本的 Loss 来自不同论文的不同验证集、量纲不完全统一；（3）高可比子集（Pythia 同模型同验证集）的斜率最缓（-0.882）、MAPE 最低（5.6%），但其得分变化幅度极小（5.07 ~ 6.06），因为这些小规模基础模型在六维基准上都接近随机水平，损失的大幅下降并未转化为得分提升。因此本文的桥接结论仅用于方向性判定与量级估计，不用于把损失数值精确换算为得分。

2. 规模扩张与非规模技术进步的贡献分解

面板回归结果见表20，贡献分解如图20所示。

表 20 规模系数估计 (C1 开源筛选样本, 2,346 条, 2024–2025 年)

子样本	n	b_P (分/10 倍参数)	b_t (分/年)	R^2	说明
全样本 (年份固定效应)	2,346	13.842	—	0.475	年效应吸收非 规模进步
全样本 (线性时间 OLS)	2,346	13.842	4.844	0.475	两设定结果一 致
pretrained	231	6.414	1.552	0.460	基础模型
chat/finetuned	1,497	14.853	4.680	0.484	指令/微调模型




图 20 规模效应与前沿提升来源分解 (左: 同一年内的规模效应; 右: 长周期贡献分解)

由表20可知: (1) 规模系数 $b_P = 13.84$, 即参数数量每增大 10 倍, 六维平均分提升约 13.8 分; 非规模技术进步速率 $b_t = 4.84$ 分/年。(2) 模型类型差异显著: pretrained 子样本的规模系数仅 6.41、时间系数 1.55, 而 chat/finetuned 子样本达 14.85 与 4.68, 说明经指令微调对齐后的模型对参数规模的利用效率更高, 基础模型在同一评测上的得分提升要慢得多。这提示在讨论“规模扩张 vs 技术进步”时必须区分模型类型, 否则会因样本构成变化而混淆两者。

在长周期口径 (C3, 2019–2025) 上, 以 $b_P = 14.10$ 、 $b_t = 3.30$ ($R^2 = 0.42$) 做 shift-share 分解: 前沿由 5.00 升至 52.08 (提升 47.08 分), 其中 $b_P \Delta \log_{10} P = 23.77$ 分、残差部分 23.31 分, 即**规模扩张贡献 50.5%、非规模技术进步贡献 49.5%**, 二者几乎平分秋色。

但需指出长周期锚点存在口径风险。本文对 C3 做了自洽性审计: 比较每行 Average 与其六维均值, 发现 13 条记录的差值超过 5 (最大差值 42.3, 为 GPT-3 (175B) 的 Average = 50.0 而六维均值仅 7.67), 说明这些历史条目混入了不同评测标准, 已予以剔除。剔除后, 在评测标准完全一致的近端窗口 (2024-06 至 2024-09, 前沿由 37.99 升至 51.00) 内分解得: 前沿模型参数量仅由 70.6B 增至 78.0B ($\Delta \log_{10} P = 0.043$), 规模贡献 0.60

分、非规模贡献 12.41 分，即**该窗口内前沿提升的 95.4% 来自非规模因素**。这与长周期口径的 50.5% 形成互补：长期看规模与技术进步各贡献约一半，但在最近一年、模型规模趋于稳定的条件下，能力提升主要由数据工程、对齐方法等非规模因素驱动。

3. 能力前沿预测

前沿序列与 logistic 拟合如图21所示，预测结果与不确定性见表21。




图 21 开源大语言模型能力前沿预测（未来 12/24 个月）

表 21 能力前沿预测及不确定性（满分 100）

前瞻期	logistic 预测	下界 (5%)	上界 (95%)	增速减半	结构外推 (基准/放缓/扩容)
+12 个月 (2026-03)	56.33	53.62	64.52	53.27	55.84 / 53.42 / 59.99
+24 个月 (2027-03)	56.59	53.75	66.52	53.27	60.69 / 55.84 / 68.99

logistic 拟合参数为 $K = 56.61$ 、 $r = 2.523$ 、 $t_0 = 5.11$ （自 2019 年起算），拟合 $R^2 = 0.975$ 。由表21可知：（1）曲线外推给出未来 12/24 个月前沿约 56.3 与 56.6，90% 置信区间分别为 [53.6, 64.5] 与 [53.8, 66.5]；（2）若算力增长放缓、非规模技术增速减半，前沿将降至 53.3 附近并在两年内基本停滞；（3）结构外推在三种情景下给出 53.4 ~ 69.0 的区间。两条路线的差异来自“当前前沿是否已接近饱和”这一判断，因此本文以**区间**而非点值作为结论：未来 12 个月开源模型六维平均分前沿预计达 53 ~ 60，24 个月达 54 ~ 69；若算力增长显著放缓，前沿增速将接近停滞（约 53 ~ 56）。

需强调该预测的局限：本文可用的评测标准一致的窗口仅约 10 个月（2024-06 至 2025-03，Leaderboard v2 已停更），2019–2023 的锚点口径不完全一致（已剔除异常条目），故外推期约为一致窗口的 1.2 ~ 2.4 倍，结论应理解为情景化区间而非精确点预测。

4. 逐任务聚合分析

六维前沿与剩余空间如表22与图22所示，C8 子任务层面的结果见表23。




图 22 （左）六维 Benchmark 前沿与饱和程度；（右）C8 子任务剩余空间最大的 10 项

表 22 六维 Benchmark 逐任务聚合结果（开源筛选集， $n = 2,346$ ）

任务	最优得分	前 1% 均值	中位数	剩余空间
IFEval	89.98	84.45	43.51	10.0%
MMLU-PRO	66.80	55.26	25.98	33.2%
BBH	65.47	59.95	28.52	34.5%
MATH Lvl 5	62.54	58.02	9.93	37.5%
MUSR	38.69	28.06	9.97	61.3%
GPQA	27.74	22.80	5.70	72.3%

表 23 C8 子任务层面剩余空间最大的 6 项（原始指标口径）

子任务	样本数	最优得分	前 5% 均值	剩余空间
math_intermediate_algebra_hard (MATH)	962	31.79	20.11	68.2%
math_precalculus_hard (MATH)	962	36.30	22.89	63.7%
math_geometry_hard (MATH)	962	40.91	28.72	59.1%
bbh_tracking_shuffled_objects_seven (BBH)	964	41.20	32.67	58.8%
bbh_tracking_shuffled_objects_five (BBH)	964	41.60	31.24	58.4%

表 23 C8 子任务剩余空间最大的 6 项（续）

子任务	样本数	最优得分	前 5% 均值	剩余空间
gpqa_extended (GPQA)	961	44.87	39.74	55.1%

由表22与表23可知：（1）六维能力发展极不均衡，指令遵循（IFEval, 89.98）已接近满分、剩余空间仅 10.0%，而研究生级问答（GPQA, 27.74）与多轮推理（MUSR, 38.69）远未饱和，剩余空间分别达 72.3% 与 61.3%。（2）C8 子任务层面进一步定位了瓶颈：MATH-Hard 中的中级代数、预备微积分、几何三个子任务最优得分仅 31.8 ~ 40.9（该类别 7 个子任务的平均最优得分为 55.5，而整体中位数低至 3.7），BBH 中“跟踪被洗牌对象”类多步状态推理子任务最优得分约 41，GPQA 的 extended 子集为 44.9，这些是未来能力增量的主要方向。（3）C8 各类别的中位数普遍远低于最优值（BBH 中位数 48.8 对最优 81.8；MATH 中位数 3.7 对最优 55.5），说明开源社区的能力分布高度长尾，前列模型与总体水平差距巨大。

5. 附件 C4 的宏观证据与“算力增长放缓”情景校验

C4 的宏观趋势如图23所示。




图 23 C4 宏观证据（左：训练算力的年度演化；右：开源权重模型占比）

由图23可知：（1）C4 中 Language 域模型的前沿训练算力持续增长，对数尺度上的年增速约 +0.589 个数量级（约 3.88 倍/年），表明近年算力投入仍在快速扩张；但年际波动明显（2024 年前沿算力低于 2023 年，2025 年再创新高），说明算力增速并非单调外推、存在阶段性放缓的可能，这也正是本文把“算力增长放缓”作为 ** 情景 **（非规模增速减半）而非基准假设、并同时给出基准情景的原因。（2）开源权重模型的占比由 2018 年的 26.7% 持续上升至 2025 年的 59.4%，说明本文以开源筛选样本刻画“能力前沿”具有良好的代表性与可持续性。（3）C4 中共有 1,390 条记录含训练算力、1,424 条含训练数据量、2,653 条标注开源权重（Yes 1,325、No 1,328）。需要说明的是，C4 的模型命名体系与 C1 不通用（规范化名称匹配仅命中 1 条），故 C4 仅作宏观尺度证据，不

与 C1 逐行合并。

综合以上结果，本节完成了问题四的求解：明确并执行了时间轴、开源筛选与模型类型三类口径；完成了 C8 的逐任务聚合（1,860 个模型、37 个子任务维度）并与 C1 交叉校验；建立了分层 Loss—Benchmark 桥接并量化了映射误差；用面板回归分离出规模扩张与非规模技术进步的贡献（长周期各约 50%，近端一致窗口内非规模因素占 95.4%）；给出了未来 12/24 个月能力前沿的情景化预测区间与逐任务瓶颈定位。

六、模型检验与分析

为验证本文构建的模型的有效性和稳健性，从误差分析与灵敏度分析两个维度进行检验：误差分析考察各模型在训练集与检验集上的拟合精度与泛化能力，灵敏度分析考察模型输出对关键输入与参数扰动的稳定程度。

6.1 误差分析

对问题一的岭正则线性混合回归、问题二的经典/广义标度律、问题四的 Loss—Benchmark 桥接与面板回归，分别计算决定系数 R^2 、均方根误差 RMSE、平均绝对误差 MAE 与平均绝对百分比误差 MAPE，结果如表24所示。

表 24 模型误差分析结果

模型（数据集）	R^2 / r	RMSE	MAE	MAPE(%)
问题一岭回归（训练 1M, $n = 512$ ）	0.629	0.551	0.403	8.54
问题一岭回归（检验 1M, $n = 256$ ）	0.619	0.523	0.386	8.43
问题一跨尺度 Pearson（60M / 1B）	0.782 / 0.651	—	—	—
问题二经典标度律（B1, $n = 1,176$ ）	0.9999998	1.5×10^{-4}	1.2×10^{-4}	0.004
问题二经典标度律留出（4 小模型 →4 大模型）	0.9999997	1.5×10^{-4}	—	0.005
问题二广义标度律（B1+B6 联合, $n = 1,536$ ）	0.990	0.036	0.024	0.66
问题二跨族验证（B4, $n = 57$ ）	0.975	0.293	—	8.83
问题二文献验证（B5, $n = 44$ ）	0.910	0.193	—	7.99
问题四 Loss—Benchmark 桥接（C6, $n = 75$ ）	0.26	—	—	67.79
问题四面板回归（C1 开源筛选, $n = 2,346$ ）	0.475	—	—	—

表 24 模型误差分析结果（续）

模型（数据集）	R^2 / r	RMSE	MAE	MAPE(%)
问题四面板回归（C3 长周期， $n = 4,586$ ）	0.424	—	—	—
问题四前沿 logistic 外推	0.975	—	—	—
问题三优化约束残差 ($ C_{\text{total}}/C_{\text{budget}} - 1 $)	—	$< 10^{-6}$	—	—

由表24可知：（1）问题一的岭回归在 13 个损失域上的平均训练 $R^2 = 0.629$ 、同尺度检验 $R^2 = 0.619$ ，训练与检验精度基本一致（差距 0.010），未出现明显过拟合；MAPE 约 8.5%，相对误差可控。（2）问题二的经典标度律在 B1 上 $R^2 \approx 1.000$ 、MAPE 0.004%，且以小模型训练、大模型留出的验证结果几乎不变（ $R^2 = 0.9999997$ ）——但如 5.2 节所述，B1 的拟合残差标准差仅 1.5×10^{-4} 而损失标准差为 0.342，说明该附件近乎无噪声，此处的极高精度只能证明函数形式自治，真正的泛化证据来自 B4（跨族真实数据， $r = 0.975$ 、MAPE 8.8%）与 B5（文献数据， $r = 0.910$ 、MAPE 8.0%）。（3）引入质量项后的广义标度律在 1,536 个联合样本上 $R^2 = 0.990$ 、MAPE 0.66%，说明加入质量维未牺牲拟合精度。（4）问题四的 Loss—Benchmark 桥接 R^2 仅 0.26、MAPE 达 67.8%，这是本文误差最大的环节，其成因已在 5.4 节说明（中可比样本的验证集不统一、高可比样本的得分变化幅度过小），因此桥接结果仅用于方向性判定。（5）问题三的优化模型在所有求解点上均满足预算约束（相对残差 $< 10^{-6}$ ），无约束违反。

6.2 灵敏度分析

为考察模型结论对关键输入与假设的稳健性，分别对赋权方案、冲突阈值、正则系数、质量成本函数形式、质量基线口径、上下文长度与算力预算进行扰动分析，结果如表25所示。

表 25 灵敏度分析结果

参数/设定变化	输出变化	灵敏度评估
赋权方案：熵权法 → 等权平均 → PCA	域级质量排序一致性 0.679 → 0.679；样本级得分相关 0.854/0.881；得分均值 0.495 → 0.639 → 0.520	中等敏感：整体格局稳定，但领域名次会变化

表 25 灵敏度分析结果 (续)

参数/设定变化	输出变化	灵敏度评估
指标方向: ad_en 按“第 1 类 = 无广告”(正向) → 若误判为负向	领域质量排序由「arxiv > stackexchange > c4 > commoncrawl > book ≈ wikipedia > github」变为「c4 > commoncrawl > arxiv > stackexchange > book > wikipedia > github」	高度敏感: 方向判定必须用实证证据
冲突阈值 τ : 0.5 → 1.0 → 1.5 → 2.0 → 2.5	冲突率 0.670 → 0.402 → 0.223 → 0.121 → 0.067; 与独立基准之比 0.93 → 0.84 → 0.77 → 0.77 → 0.86	结论稳健: 任一阈值下冲突率均显著低于独立基准
岭正则系数 λ : $10^{-4} \sim 10^{-1}$	训练 R^2 由 0.6291 降至 0.6238, 检验 R^2 由 0.6187 降至 0.6157	不敏感, 估计稳定
质量成本函数: 指数型 → 幂函数型 → 对数渐进型 ($C = 10^{19}$)	$Q^* = 0.660 \rightarrow 0.551 \rightarrow 1.000$, L^* 差异 < 0.06; 质量份额 12.9% → 0.0% → 31.6%	低预算档较敏感
同上, 但 $C \geq 10^{22}$	三种函数下 Q^* 均为 1.000, N^* 、 D^* 差异 < 10%	不敏感, 结论稳健
质量基线口径: 配比加权 $Q_0 = 0.5510 \rightarrow$ 样本均值 0.4952	三档预算下 Q^* : 0.551/1.000/1.000 → 0.504/1.000/1.000, N^* 变化 < 2%	不敏感
上下文长度: 2,048 → 131,072 tokens (C7 可行取值)	注意力/训练倍数 0.07 → 4.37; N^* 由 6.089B 降至 2.705B; 损失上升 6.0%	高度敏感, 存在临界点 $L_{\text{crit}} = 30,000$
算力预算 C : $10^{19} \rightarrow 10^{24}$ FLOPs	Q^* 由 0.551 升至 1.000; D^*/N^* 由 30.9 升至 76.1; 质量份额 0 → 0.407 → 0.016	高度敏感, 发生三段式结构性转移
半合成数据口径: 并入 B2 / B8	B2 使 MAPE 升至 33.7%; B8 使 MAPE 升至 133.4% 且预测低于不可约损失下限	不可并入; 已划出可信度边界

由表25可知, 本文结论可按稳健程度分为三类:

(1) 高度稳健的结论: 冲突率显著低于独立基准 (任一阈值下比值均 < 0.93); 岭正则系数不影响配比系数与拟合精度; 质量基线口径不影响最优配置; 中高预算下“质

量拉满”的结论不依赖质量成本函数的具体形式。这些结论可直接用于后续决策。

(2) 成本分界与配置阶段： $L_{\text{crit}} = 30,000$ tokens 表示注意力与基础训练成本相等，并不意味着最优规模在该点突变。在问题三的基准情景中，首次观察到正质量投入与质量饱和的网格预算分别为 1.78×10^{19} 和 7.08×10^{19} FLOPs。上述数值受扫描分辨率、求解状态及质量成本设定影响，宜作为配置阶段的数值识别结果，而非普遍成立的精确门槛。

(3) 需要谨慎表述的结论： 低预算档 ($C = 10^{19}$ FLOPs) 的最优质量对质量成本函数形式高度敏感 ($0.551 \sim 1.000$ ，即从“完全不投资质量”到“质量拉满”)，因此该档的具体数值应作为区间而非点值使用；Loss—Benchmark 桥接的 R^2 仅 0.26，其换算出的“损失改善等价于多少能力分”只具方向意义；领域质量排序对指标方向判定与赋权方案均为中等以上敏感，引用该排序时须同时引述其口径。

综上，除已明确标注的低预算档与桥接环节外，本文模型的资源配置与演进结论对参数扰动均保持稳定，具备可靠性与可解释性。

七、模型的评价

7.1 模型的优点

- **优点 1：** 质量评价体系完整且可核验——逐指标给出 22 个质量指标的方向判定与语义依据 (表2)，其中争议最大的广告字段通过原文抽查确认为“第 1 类 = 无广告”的正向指标；对负向指标作补转换、对长度型指标转为中心接近度、对 8 个多维列表型指标用 softmax 期望压缩，逐字段审计出 19 处缺失并按中位数填充，并用抽样集与扩展集的域级质量对照 (差值不超过 0.002) 证明评分口径可跨集合迁移，从而避免了“方向未统一”这一常见错误。

- **优点 2：** 冲突分析给出了可比较的参照系——不仅报告冲突率 (22.3%) 与 Kendall 协同系数 (0.069)，还计算了“指标独立”基准 (28.9%) 并做阈值灵敏度检验 ($\tau \in [0.5, 2.5]$ 下比值恒 < 0.92)，从而客观得出“指标正相关但一致性不强”的结论，并归纳出三类冲突成因与消解规则，未回避数据中的不一致性。

- **优点 3：** 广义标度律的形式设计兼顾物理合理性与兼容性——采用质量缺口项 $C(1 - Q)^\gamma$ ，在 $Q = 1$ 时精确退化为经典 Chinchilla 形式，且不会在高质量端产生负损失 (避免了 $E - CQ^\gamma$ 形式的非物理缺陷)；同时通过四种形式的同口径比较 (R^2 、AIC、内插与外推) 择优，并用 B3 的独立插值轨迹验证数据项指数 (-0.2805 vs -0.2799)。

- **优点 4：** 算力成本模型严格遵循赛题公式、不做简化——完整保留质量成本与训练 token 数成正比的结构 ($C_Q = D[g(Q) - g(Q_0)]_+$) 与附录 B 规定的三型函数参数，并解析给出临界上下文长度 $L_{\text{crit}} = 6/\eta = 30,000$ 与最优性条件式(26)，用“等效附加数据量 $\tau(Q)$ ”把质量投入折算为 token 成本，使结构性转移具有清晰的解析解释。

- **优点 5：** 口径界定与证据分层规范——问题四明确给出时间轴、开源许可白名单

与模型类型三套口径及筛选漏斗，完成附件 C8 的逐任务聚合（1,860 个模型、37 个子任务维度）并与 C1 做秩相关校验，用附件 C4 的算力增速与开源占比支撑情景假设；对 B2/B8 等口径异常的半合成数据主动作自治性审计并划出可信度边界（B8 最小损失低于模型不可约损失下限）。

7.2 模型的缺点

- **缺点 1：** 配比—损失模型假设线性关系且未含领域交互项，13 个可测域的平均 R^2 仅 0.629，说明仍有约 37% 的损失变异未被配比解释（可能来自随机种子、数据顺序等未观测因素）；nih_exporter、enron_emails、europarl、philpapers 四个无损失列的域只能固定于参考配比处理，其影响难以识别；追加混合质量指数后 R^2 增量仅 5×10^{-5} ，虽有明确结论（质量信息已被配比吸收），但也意味着本文无法在线性框架内把 17 域质量评分进一步用于配比优化。

- **缺点 2：** 质量评价的指标方向仍部分依赖语义先验。广告、流畅度两个二分类字段已用原文与域对比完成实证核验，但 modernbert 系列的 6 级列表型指标、qurater 的 4 级评级等，“级别越高越好”仍来自字段语义而非独立验证；此外熵权法对分布形态敏感（左偏指标获更大权重），灵敏度检验显示改用等权平均后域级排序一致性为 0.679，方向判定若出错更会使排序发生实质变化（见第 6.1 节），说明域级质量排名的部分细节对赋权与方向设定敏感，引用时须同时给出其口径。

- **缺点 3：** 广义标度律的质量项依赖半合成数据标定（B6/B7），B8 因方向相反且损失低于不可约损失下限而不能使用，B2（Cerebras）的 MAPE 达 33.7%，说明跨数据源的质量效应标定仍不充分；质量可行域受数据支持范围限制在 $[Q_0, 1]$ ，向更低质量的外推缺乏数据支撑。

- **缺点 4：** 问题四的 Loss—Benchmark 桥接 R^2 仅 0.26、MAPE 达 67.8%，且 C1 中评测标准一致的窗口仅约 10 个月（2024-06 至 2025-03），2019–2023 的历史锚点口径不完全一致（已剔除 13 条异常条目），因此前沿预测的外推期约为一致窗口的 1.2 ~ 2.4 倍，预测结果只能作为情景化区间；面板回归中规模与年份仍存在一定共线性，贡献占比对数据口径较敏感（长周期口径 50.5% vs 近端口径规模占比可正可负）。

八、模型的改进与推广

8.1 模型的改进

本文模型可在方法、参数与数据三个层面进一步改进。

方法层面，可将配比—损失的线性混合回归替换为 Dirichlet 回归，或引入领域间交互项与稀疏先验（如 Group Lasso），以捕捉非线性效应并把 13 个域平均 $R^2 = 0.629$ 中未被解释的约 37% 变异进一步压缩；对未测量域（nih_exporter 等四个域）可尝试用域文本统计特征构造代理变量，替代当前“固定于参考配比”的处理；冲突消解可由当前

的“多数指标方向裁决”升级为基于潜变量模型（如有序 probit 因子模型）的一致性度量，从而给出冲突样本的质量可信度区间而非二值标记。

参数层面，广义标度律的质量缺口项可放宽为更灵活的形式（如 $C(1 - Q)^{\gamma_1} D^{-\gamma_2}$ 或质量与数据量的交互项），以检验“质量缺口是否与数据规模耦合”；算力优化模型可进一步纳入数据重复轮次（epoch）、稀疏化/量化带来的推理与训练成本差异、以及分阶段课程学习等新决策变量；质量成本函数可在附录 B 三型之外引入由真实清洗流水线标定的经验成本曲线，以缓解低预算档对成本函数形式较敏感的问题。

数据层面，可用更多具备质量标注的公开语料扩充 B6/B7 的质量区间（当前外推下限受数据支持范围限制），并尝试从语料元数据（发布时间、来源许可、去重比例）反推质量标签；对附件 C4 可通过组织名、参数量与发布时间做模糊匹配，与 C1 建立更细粒度的行级连接，从而用真实训练算力直接约束前沿预测；对问题四，若能获得跨评测标准（v1 与 v2）的校准样本，则可把 2019–2023 的历史锚点统一到同一标尺，显著缓解当前“一致窗口仅 10 个月”的外推局限。

8.2 模型的推广

本文提出的“损失函数—成本约束—资源配置”建模框架具有广泛的推广价值。

在工程领域，该框架可直接迁移至算力受限场景下的大模型预训练、微调与蒸馏资源配置决策：式(26)给出的最优性条件与“等效附加数据量 $\tau(Q)$ ”这一折算量，使得数据治理投入与算力扩张投入可以直接放在同一成本口径下比较，帮助企业以最小算力达到目标能力。

在数据治理领域，本文的质量综合评价与冲突消解模型（含 22 指标的显式方向表与“冲突率—独立基准”对比框架）可用于通用语料清洗、数据筛选与领域配比的动态调整；本文提出的可替代度指标 s_{ij} （式中的系数向量余弦相似度）可用于识别哪些领域可以合并、哪些领域必须搭配使用，为配比策略提供结构化依据。

在行业与政策层面，本文“长周期 shift-share 分解 + 近端一致窗口分解”的双重口径方法，可为科研机构评估“堆参数”与“改进算法”两条路线的投入产出、制定算力与数据资源的宏观配置政策提供定量依据；同时本文在方法上刻意区分“可直接使用的稳健结论”“存在临界点的结论”与“需谨慎表述的结论”，这一证据分级范式对涉及多源异构数据的政策评估同样适用。

更进一步，能力前沿的饱和外推方法（logistic 曲线外推与结构外推双路线互为校验）可推广至芯片制程、新能源技术、生物医药研发等具有渐进饱和特征的技术演进预测场景；而本文对半合成数据所做的“方向审计 + 不可约损失下限检验”自洽性筛查流程，可作为使用半合成/估算数据开展定量建模时的通用质量把关步骤。

参考文献

- [1] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[J]. arXiv preprint arXiv:2001.08361, 2020.
- [2] HOFFMANN J, BORGEAUD S, MENSCH A, et al. Training compute-optimal large language models[C]. Advances in Neural Information Processing Systems, 2022, 35: 30016-30030.
- [3] BAHRI Y, DYER E, KAPLAN J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27): e2311878121. DOI: 10.1073/pnas.2311878121.
- [4] BIDERMAN S, SCHOELKOPF H, ANTHONY Q, et al. Pythia: A suite for analyzing large language models across training and scaling[C]. International Conference on Machine Learning, 2023: 2397-2430.
- [5] VILLALOBOS P, HO A, SEVILLA J, et al. Will we run out of data? Limits of LLM scaling based on human-generated data[J]. arXiv preprint arXiv:2211.04325, 2022.
- [6] ASAI A, HE J, SHAO R, et al. Synthesizing scientific literature with retrieval-augmented language models[J]. Nature, 2026, 650: 857-863. DOI: 10.1038/s41586-025-10072-4.
- [7] MUENNIGHOFF N, RUSH A, BARAK B, et al. Scaling data-constrained language models[C]. Advances in Neural Information Processing Systems, 2023, 36: 50358-50376.
- [8] XIE S M, PHAM H, ERMON S, et al. DoReMi: Optimizing data mixtures speeds up language model pretraining[C]. Advances in Neural Information Processing Systems, 2023, 36: 69798-69818.
- [9] LIU Q, ZHENG X, MUENNIGHOFF N, et al. RegMix: Data mixture as regression for language model pre-training[C]. International Conference on Machine Learning, 2024: 32213-32236.
- [10] GAO L, BIDERMAN S, BLACK S, et al. The Pile: An 800GB dataset of diverse text for language modeling[J]. arXiv preprint arXiv:2101.00027, 2020.
- [11] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[C]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.
- [12] WEI J, TAY Y, BOMMASANI R, et al. Emergent abilities of large language models[J]. Transactions on Machine Learning Research, 2022.

- [13] SCHAEFFER R, MIRANDA B, KOYEJO S. Are emergent abilities of large language models a mirage?[C]. Advances in Neural Information Processing Systems, 2023, 36: 55551-55563.
- [14] 第二十三届中国研究生数学建模竞赛 F 题数据说明: 算力约束下提升大语言模型能力的资源配置建模 [R]. 2026.
- [15] EPOCH AI. Data on machine learning models[DB/OL]. https://epoch.ai/data/all_ai_models.csv, 2025.
- [16] HUGGING FACE. Open LLM Leaderboard v2 results and evaluation details[DB/OL]. <https://huggingface.co/datasets/open-llm-leaderboard/results>, 2025.
- [17] OPENDATALAB. SlimPajama-Meta-rater: quality signals for SlimPajama[R/OL]. <https://huggingface.co/datasets/pendatalab/SlimPajama-Meta-rater>, 2025.
- [18] OpenAI, GPT-5 (Codex CLI), OpenAI, 2026-01.

附录

附录 A：数据利用清单

按数据说明的要求，列出本文对各附件的实际使用情况，并标注半合成/外推数据的可信度边界，如表26所示。

表 26 附件数据利用清单

编号	文件名	性质	是否使用	使用方式与可信度说明
A1	slimpajama_quality_signal_sample	真实	使用	22 指标熵权评分、冲突分析、域级 Q 、原文抽查 (51,230 条全量)
A2	slimpajama_quality_extended_arxiv	真实	使用	扩展集域级 Q 与抽样集对照 (17,523 条全量)
A3	slimpajama_quality_extended_arxiv	真实	使用	扩展集域级 Q 与抽样集对照 (203,752 条全量)
A4	train_mixture_1m	真实	使用	配比—损失岭回归训练集 (512 组)
A5	train_pile_loss_1m	真实	使用	13 域损失标签
A6–A9	test_mixture/loss_1m, 60m	真实	使用	同尺度与跨尺度检验 (各 256 组)
A10–A11	test_mixture/loss_1B	真实	使用	跨尺度检验 (64 组)
A12–A15	est_mixture/loss_10b, 70b	子集/外推	使用	外推尺度因子稳健性 (各 63 组，均标注为外推非观测)
A16	domain_mapping_guide	参考	使用	17 域到质量域跨体系映射 (6 域 direct/near_direct, 11 域 inferred 用全局均值并标明)
A17	regmix_domain_summary	真实	未使用	版内未接入，供扩展分析
A18	regmix_domain_sample	真实	未使用	可选辅助，未接入
B1	pythia_training_log_existing	真实	使用	经典标度律主拟合与模型留出验证 (1,176 点)；已说明该附件近乎无观测噪声
B2	cerebras_training_log	半合成	使用	族外验证；结果 MAPE 33.7%，判为口径差异、仅作定性参考

表 26 附件数据利用清单（续）

编号	文件名	性质	是否使用	使用方式与可信度说明
B3	training_trajectories	插值	使用	轨迹内 D 幂指数验证 (-0.2806 至 -0.2803 , 拟合值 -0.2799)
B4	scaling_baseline	真实	使用	跨族验证 ($r = 0.975$ 、MAPE 8.8%)
B5	published_scaling_data	真实	使用	文献验证 ($r = 0.910$ 、MAPE 8.0%)
B6	supplementary_NQ_experiment	混合	使用	质量缺口项拟合主数据 (360 点); 仅用于标定质量效应, 不作直接实验观测
B7	supplementary_NQ_experiment_expanded	混合	使用	新增点独立验证 ($r = 0.991$)
B8	supplementary_NQ_experiment_large	混合	部分使用	方向审计发现其 Q_{score} 与 B6/B7 反号, 且最小损失低于不可约损失下限, 故不并入拟合, 仅作可信度边界警示
B9	supplementary_large_model	真实	使用	百亿参数以上模型元数据 (参数量、数据量、开源可及性)
B10	supplementary_large_baseline	估算	使用	百亿参数以上外推检验 ($r \approx 1.000$ 、MAPE 1.0%); 标注为估算值
B11	open_model_family_metadata	真实	未使用	辅助文件, 版内未接入
B12	pythia_checkpoint_index	真实	未使用	辅助文件, 版内未接入
C1	leaderboard_cleaned	真实	使用	六维得分、许可、类型、提交日期; 开源筛选后 2,346 条用于面板回归与前沿
C2	leaderboard_enhanced	真实	未使用	C1 的增强替代版, 为避免重复计算未使用
C3	leaderboard_extended_time_series	混合	使用	2019–2025 长周期分解; 已剔除 13 条自治性异常行, 口径混合性在正文标注
C4	epoch_all_ai_models	真实	使用	训练算力年增速 ($+0.589$ dex/年)、训练数据量、开源权重字段 (Yes 1,325 / No 1,328)
C5	loss_benchmark_bridge	混合	使用	桥接对照 ($n = 43$, $r = -0.502$)

表 26 附件数据利用清单（续）

编号	文件名	性质	是否使用	使用方式与可信度说明
C6	loss_benchmark_bridge_expanded	混合	使用	桥接主用 ($n = 75$), 按 High/Medium 可比性分层使用
C7	model_architecture_metadata	真实	使用	上下文长度可行取值 (2048、4096、8192、32768、131072) 用于问题三敏感性分析
C8	detailed_results/	真实	使用	逐任务聚合 (1,860 个模型成功解析、37 个子任务维度), 并与 C1 做秩相关校验
C9	data/ (Parquet)	真实	未使用	与 C1 等价, 任选其一
C10	pythia_eval_details/	说明	未使用	仅含 README, 不可替代 C8

附录 B：半合成与外推数据的标注

按数据说明要求，以下数据为非直接观测，正文中的相关结论均已限定适用范围：

- **半合成数据**：B2 (Cerebras 训练日志)、B6/B7/B8 (NQ 质量实验)。本文在标度律拟合中仅使用 B6 (主) 与 B7 (验证)，并在 5.2 节以表格明确其“半合成”性质；B2、B8 经自洽性审计后不并入拟合。
- **外推与估算数据**：A12–A15 (10B/70B 损失外推，源自 1M/60M/1B 幂律外推)、B10 (百亿参数以上损失估算)。相关结论仅用于稳健性检验，未作为观测证据。
- **插值数据**：B3 (Pythia 插值轨迹)，仅用于轨迹内幕指数的交叉验证。
- **混合口径数据**：C3 (跨年评测标准不完全一致)、C5/C6 (Loss 来源与验证集不完全统一)。前者的异常行已被审计剔除，后者已按可比性等级分层使用。

附录 C：结果文件与核心求解代码

本文的求解结果以 CSV 形式保存在求解/问题一至问题四/结果/ 目录下，主要结果文件如表27所示（表中文件名省略“求解/问题 X/结果/”前缀）。

表 27 主要结果文件说明

文件	说明
质量指标熵权.csv	22 指标的方向判定、语义说明、信息熵与熵权

表 27 主要结果文件说明（续）

文件	说明
质量信号缺失审计.csv	逐指标字段级缺失计数（A1–A3 全量）
质量冲突与一致性.csv	抽样集/扩展集/全量的冲突率、独立基准与 Kendall W
冲突阈值灵敏度.csv	冲突率随阈值 τ 的变化
抽样集与扩展集域级对照.csv	A1 与 A2/A3 的域级质量对照
质量与损失难度一致性.csv	两套质量口径在 6 个映射域上的排序比较
质量项增量检验.csv	追加混合质量指数后的 R^2 增量
混合系数矩阵.csv、截距.csv	配比—损失岭回归系数与截距
推荐配比调整.csv	有界推荐配比与调整量
问题一_拟合汇总.csv	各损失域的拟合与检验指标
岭正则敏感性.csv	正则系数灵敏度
经典标度律参数.csv	经典标度律参数、拟合与留出验证指标
质量字段方向审计.csv	B6/B7/B8 的组内相关与方向结论
广义标度律形式对比.csv	四种质量项形式的 R^2 /AIC 比较
广义标度律分层验证.csv	6 个独立来源的验证结果
弹性与替代关系.csv、质量参数替代关系.csv	弹性与替代率
领域替代互补_top.csv	领域间替代/互补结构
B3 轨迹验证.csv	轨迹内 D 幂指数验证
三档预算最优配置.csv、成本函数对比.csv	三档预算与三型成本函数的优化结果
结构性转移识别.csv	结构性转移门槛
上下文长度敏感性.csv	C7 五档上下文长度下的最优配置
质量基线灵敏度.csv	质量基线口径灵敏度
配比项算力等价.csv	配比优化的算力等价效果
筛选漏斗.csv	时间轴/开源/模型类型三套口径的筛选漏斗
C8 逐任务解析结果.csv	C8 全部模型的任务级原始指标
C8 逐任务聚合.csv、C8 子任务类别汇总.csv	子任务前沿与剩余空间

表 27 主要结果文件说明（续）

文件	说明
C8 与 C1 一致性校验.csv	C8 与 C1 的秩相关校验
Loss_Benchmark 映射.csv	分层桥接拟合结果
规模时间分解.csv、规模时间分解 _ 长周期.csv	规模/非规模贡献分解
C3 口径异常行.csv	C3 自治性审计剔除的记录
前沿预测.csv、前沿预测 _ 结构外推 情景.csv	能力前沿预测与情景
C4 宏观趋势.csv、C4 宏观摘要.csv	C4 宏观算力与开源权重证据
求解/广义标度律参数.csv、问题一 _ 关键量.json	跨问共享的接口参数

核心求解代码

本附录列出四个问题的核心求解代码，代码文件位于求解目录下对应的问题一至问题四子目录中，共享工具函数位于求解/_common.py。

问题一：质量评价、冲突消解与配比建模（问题一.py）

```
1  # -*- coding: utf-8 -*-
2  """
3  问题一：数据质量评价、质量冲突消解与领域配比建模
4  数据：附件 A（A1-A3 质量信号；A4-A15 配方/Loss；A16 域映射）
5  方法：1) 22 指标方向统一 + 极差归一化 + 熵权法三级综合评分（样
        本/语料/领域）
6         2) 成对 z 分数差冲突定义 + Kendall 协同系数一致性检验 +
        多数方向裁决
7         3) 岭正则线性混合回归刻画 17 域配比 -> 13 域损失，并检验
        追加质量项的增量解释力
8  输出：图片到 图片/，结果 CSV 到 结果/
9  """
10 import sys, os, json, lzma, glob
11 sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.
    abspath(__file__))))
12 from _common import *    # noqa: F401,F403
13
14 DATA = data_path
15 RC_FAILS = []
16
17 def save_csv_safe(df, name_cn):
18     """保存 CSV；若目标被其他进程占用则回退为 *_new.csv，保证
        流程不中断。"""
19     p = os.path.join(OUT_DIR, name_cn)
20     try:
21         df.to_csv(p, index=False, encoding='utf-8-sig')
22     except PermissionError:
23         alt = os.path.join(OUT_DIR, name_cn.replace('.csv', '
        _new.csv'))
24         df.to_csv(alt, index=False, encoding='utf-8-sig')
25         RC_FAILS.append((name_cn, os.path.basename(alt)))
26         print('    ! %s 被占用，已改存为 %s' % (name_cn, os.path
```

```

        .basename(alt)))
27
28 # ===== 0. 22 个质量指标的方向定义 =====
29 # positive = 越大越好; negative = 越小越好; target = 越接近稳
    健中心越好
30 QUALITY_COLS = [
31     'fineweb_edu', 'fluency_en', 'modernbert_cleanliness',
32     'modernbert_readability', 'modernbert_reasoning',
33     'modernbert_professionalism', 'dsir_books', 'dsir_wiki', '
    dsir_math',
34     'qurater', 'ad_en', 'rps_doc_word_count', '
    rps_doc_num_sentences',
35     'rps_doc_unigram_entropy', 'rps_doc_frac_unique_words',
36     'rps_doc_frac_no_alph_words', '
    rps_doc_frac_chars_top_2gram',
37     'rps_doc_frac_chars_top_3gram', '
    rps_lines_uppercase_letter_fraction',
38     'rps_lines_ending_with_terminal_punctution_mark',
39     'rps_lines_numerical_chars_fraction', '
    rps_doc_mean_word_length'
40 ]
41 NEGATIVE_COLS = {
42     'rps_doc_frac_no_alph_words', '
    rps_doc_frac_chars_top_2gram',
43     'rps_doc_frac_chars_top_3gram', '
    rps_lines_uppercase_letter_fraction',
44     'rps_lines_numerical_chars_fraction'
45 }
46 TARGET_COLS = {'rps_doc_word_count', 'rps_doc_num_sentences',
    'rps_doc_mean_word_length'}
47 LIST_COLS = ['fineweb_edu', 'fluency_en', '
    modernbert_cleanliness',
48             'modernbert_readability', 'modernbert_reasoning',
49             'modernbert_professionalism', 'qurater', 'ad_en']
50 DIRECTION_NOTE = {
51     'fineweb_edu': '教育价值（列表型，1 维 logit）',
52     'fluency_en': '英语流畅度（列表型，2 维，取第 2 类概率）',
53     'modernbert_cleanliness': '文本洁净度（列表型，6 级，取归

```

```

一化期望级别) ',
54     'modernbert_readability': '可读性 (列表型, 6 级) ',
55     'modernbert_reasoning': '推理性 (列表型, 6 级) ',
56     'modernbert_professionalism': '专业性 (列表型, 6 级) ',
57     'dsir_books': 'DSIR 书籍域重要性权重',
58     'dsir_wiki': 'DSIR 维基域重要性权重',
59     'dsir_math': 'DSIR 数学域重要性权重',
60     'qurater': '教育质量评级 (列表型, 4 级) ',
61     'ad_en': '广告含量 (列表型, 2 维; 第 1 类=“无广告”, 正
        向。依据: 原文抽查显示第 1 类概率最低的样本均为广告文案) ',
62     'rps_doc_word_count': '文档词数 (过短/过长均不佳) ',
63     'rps_doc_num_sentences': '文档句数 (过少/过多均不佳) ',
64     'rps_doc_unigram_entropy': '一元词熵 (越高越多样) ',
65     'rps_doc_frac_unique_words': '唯一词占比 (越高越多样) ',
66     'rps_doc_frac_no_alph_words': '非字母字符占比 (越低越好) '
    ,
67     'rps_doc_frac_chars_top_2gram': 'Top-2 字符 2-gram 占比
        (重复度, 越低越好) ',
68     'rps_doc_frac_chars_top_3gram': 'Top-2 字符 3-gram 占比
        (重复度, 越低越好) ',
69     'rps_lines_uppercase_letter_fraction': '大写字母行占比 (越
        低越好) ',
70     'rps_lines_ending_with_terminal_punctution_mark': '以终止
        标点结尾的行占比 (越高越好) ',
71     'rps_lines_numerical_chars_fraction': '含数字字符行占比
        (越低越好) ',
72     'rps_doc_mean_word_length': '平均词长 (过短/过长均不佳) ',
73 }
74 CONFLICT_TAU = 1.5      # 成对 z 分数差阈值
75
76 def _softmax_expected(v):
77     """把有序类别 logits 压缩为 [0,1] 上的归一化期望级别。"""
78     a = np.asarray(v, dtype=float).ravel()
79     if len(a) == 0:
80         return np.nan
81     if len(a) == 1:
82         return float(a[0])
83     a = a - np.nanmax(a)

```

```

84     p = np.exp(a); p = p / np.nansum(p)
85     return float(p @ np.linspace(0.0, 1.0, len(a)))
86
87 def _scalarize(name, value):
88     if value is None:
89         return np.nan
90     if isinstance(value, (list, tuple)):
91         return _softmax_expected(value)
92     try:
93         return float(value)
94     except Exception:
95         return np.nan
96
97 def _norm_domain(x):
98     s = str(x).lower().replace('-', '_').replace(' ', '_')
99     aliases = {'common_crawl': 'commoncrawl', 'books': 'book',
100               'wikipedia_en': 'wikipedia'}
101     return aliases.get(s, s)
102
103 def load_quality_records():
104     """流式读取 A1-A3 全量记录，只保留建模字段和 A1 原文摘要。"""
105     sample_path = DATA('slimpajama_quality_signal_sample.jsonl')
106     ext_paths = sorted(glob.glob(os.path.join(DATA_DIR, 'A_data_value',
107                                               'slimpajama_quality_extended', '*.jsonl.xz')))
108     rows, meta = [], []
109     miss = {c: 0 for c in QUALITY_COLS}
110
111     def _is_missing(v):
112         """字段级缺失判定：None、空列表、列表内含 None/NaN、标
113         量为非有限数均计为缺失。"""
114         if v is None:
115             return True
116         if isinstance(v, (list, tuple)):
117             if len(v) == 0:

```

```

116         return True
117         return any((x is None) or (isinstance(x, float)
and not np.isfinite(x)) for x in v)
118     try:
119         return not np.isfinite(float(v))
120     except Exception:
121         return True
122
123 def consume(path, source, domain_hint=None):
124     opener = lzma.open if path.endswith('.xz') else open
125     with opener(path, 'rt', encoding='utf-8') as fh:
126         for line in fh:
127             try:
128                 obj = json.loads(line)
129             except Exception:
130                 continue
131             domain = _norm_domain(obj.get('_source_domain'
, domain_hint))
132             for c in QUALITY_COLS:
133                 if _is_missing(obj.get(c)):
134                     miss[c] += 1
135             rows.append([_scalarize(c, obj.get(c)) for c
in QUALITY_COLS])
136             excerpt = ''
137             if source == 'A1':
138                 excerpt = ' '.join(str(obj.get('content',
'')).split())[:180]
139             meta.append((obj.get('id', ''), domain, source
, excerpt))
140
141     consume(sample_path, 'A1')
142     for path in ext_paths:
143         hint = 'arxiv' if os.path.basename(path).lower().
startswith('arxiv') else 'github'
144         consume(path, 'A2' if hint == 'arxiv' else 'A3', hint)
145     X = pd.DataFrame(rows, columns=QUALITY_COLS)
146     M = pd.DataFrame(meta, columns=['id', 'domain', 'source',
'excerpt'])

```

```

147     miss_df = pd.DataFrame([{'indicator': k, 'missing_count':
148 v} for k, v in miss.items()])
149     save_csv_safe(miss_df, '质量信号缺失审计.csv')
149     if miss_df.missing_count.sum() > 0:
150         print('\n质量信号缺失审计（合计 %d 个指标取值缺失）： '
151 % int(miss_df.missing_count.sum()))
151         print(miss_df[miss_df.missing_count > 0].to_string(
152 index=False))
152         print('    处理方式：方向统一后按该指标中位数填充（不把
153 缺失当作高质量或低质量）。')
153         return X, M
154
155 def orient_and_normalize(raw):
156     """方向统一 -> 极差归一化（正向缩放、负向取补、长度型转中
157 心接近度）。"""
157     oriented = raw.copy()
158     for c in TARGET_COLS:
159         z = np.loglp(np.clip(raw[c].values, 0, None))
160         med = np.median(z); mad = np.median(np.abs(z - med)) +
161 1e-9
161         oriented[c] = np.exp(-np.abs(z - med) / (2.5 * mad))
162     norm = pd.DataFrame(index=raw.index)
163     for c in QUALITY_COLS:
164         lo, hi = np.nanquantile(oriented[c], [0.01, 0.99])
165         v = np.clip((oriented[c] - lo) / max(hi - lo, 1e-12),
166 0, 1)
166         norm[c] = 1 - v if c in NEGATIVE_COLS else v
167     return oriented, norm
168
169 def quality_evaluation():
170     raw, meta = load_quality_records()
171     raw = raw.replace([np.inf, -np.inf], np.nan)
172     raw = raw.apply(lambda s: s.fillna(s.median()))
173     _, norm = orient_and_normalize(raw)
174
175     # ---- 熵权法（主方案） ----
176     P = (norm.values + 1e-12) / (norm.values.sum(axis=0,
177 keepdims=True) + 1e-12)

```

```

177     entropy = -(P * np.log(P)).sum(axis=0) / np.log(len(norm))
178     divergence = np.maximum(1 - entropy, 0)
179     w_entropy = divergence / divergence.sum()
180     # ---- 对照方案: 等权 / 第一主成分 ----
181     w_equal = np.full(len(QUALITY_COLS), 1.0 / len(
QUALITY_COLS))
182     Z = (norm.values - norm.values.mean(0)) / (norm.values.std
(0) + 1e-12)
183     _, _, vt = np.linalg.svd(Z, full_matrices=False)
184     pc1 = vt[0]
185     if pc1.sum() < 0:
186         pc1 = -pc1
187     w_pca = np.clip(pc1, 0, None); w_pca = w_pca / w_pca.sum()
188
189     names = ['熵权法', '等权平均', 'PCA第一主成分']
190     wdict = dict(zip(names, [w_entropy, w_equal, w_pca]))
191     sc = {k: norm.values @ wdict[k] for k in names}
192     dom_tmp = meta.assign(**sc).groupby('domain')[names].mean
()
193     cmp_df = pd.DataFrame({
194         'scheme': names,
195         'score_mean': [sc[k].mean() for k in names],
196         'score_std': [sc[k].std() for k in names],
197         'corr_with_entropy': [float(np.corrcoef(sc[k], sc['熵
权法'])[0, 1]) for k in names],
198         'domain_spearman_vs_entropy': [1.0,
199             stats.spearmanr(dom_tmp['熵权法'], dom_tmp['等权平
均']).statistic,
200             stats.spearmanr(dom_tmp['熵权法'], dom_tmp['PCA第
一主成分']).statistic]})
201     save_csv_safe(cmp_df, '赋权方案对比.csv')
202
203     wdf = pd.DataFrame({'indicator': QUALITY_COLS,
204         'list_type': [c in LIST_COLS for c in
QUALITY_COLS],
205         'direction': ['negative' if c in
NEGATIVE_COLS else
206             ('target' if c in

```

```

TARGET_COLS else 'positive')
207                                     for c in QUALITY_COLS],
208                                     'semantics': [DIRECTION_NOTE[c] for c
in QUALITY_COLS],
209                                     'entropy': entropy, 'weight':
w_entropy})
210     save_csv_safe(wdf, '质量指标熵权.csv')
211     meta['quality_Q'] = sc['熵权法']
212
213     # ---- 冲突分析：成对 z 分数差 > tau ----
214     def agreement(idx, label):
215         Zs = norm.loc[idx]
216         m, n = Zs.shape                                # m 条文本（对
象），n=22 指标（评价者）
217         rank_sum = np.zeros(m)
218         for c in Zs.columns:
219             rank_sum += stats.rankdata(Zs[c].values, method='
average')
220         S = np.sum((rank_sum - rank_sum.mean()) ** 2)
221         W = 12 * S / max(n ** 2 * (m ** 3 - m), 1)
222         Am = (Zs.values - Zs.values.mean(axis=0)) / (Zs.values
.std(axis=0) + 1e-12)
223         iu = np.triu_indices(n, 1)
224         pairdiff = np.abs(Am[:, iu[0]] - Am[:, iu[1]])
225         rate = float((pairdiff > CONFLICT_TAU).mean())
226         rate_free = float(2 * stats.norm.sf(CONFLICT_TAU / np.
sqrt(2)))
227         chi2 = n * (m - 1) * W
228         pair_rate = pd.Series((pairdiff > CONFLICT_TAU).mean(
axis=0),
229                               index=['%s|%s' % (QUALITY_COLS[i
], QUALITY_COLS[j])
230                                     for i, j in zip(*iu)])
231         return {'dataset': label, 'n': m, 'kendall_W': W, '
chi2': chi2,
232                'p_value': stats.chi2.sf(chi2, m - 1),
233                'conflict_rate': rate, 'indep_baseline':
rate_free,

```

```

234         'conflict_ratio_vs_indep': rate / rate_free},
pair_rate
235
236     ag, pair_table = [], {}
237     for idx, label in [(meta.index[meta.source == 'A1'], 'A1抽
样集'),
238                        (meta.index[meta.source != 'A1'], 'A2+
A3扩展集'),
239                        (meta.index, '全量')]:
240         a, pf = agreement(idx, label)
241         ag.append(a); pair_table[label] = pf
242         save_csv_safe(pd.DataFrame(ag), '质量冲突与一致性.csv')
243         top_pairs = pair_table['全量'].sort_values(ascending=False
).head(20).rename('conflict_rate')
244         save_csv_safe(top_pairs.reset_index().rename(columns={'
index': 'indicator_pair'}),
245                        '冲突指标对_top20.csv')
246
247     # ---- 冲突阈值灵敏度: tau 变动对冲突率与结论的影响 ----
248     thr_rows = []
249     Zall = (norm.values - norm.values.mean(axis=0)) / (norm.
values.std(axis=0) + 1e-12)
250     iu_all = np.triu_indices(22, 1)
251     pd_all = np.abs(Zall[:, iu_all[0]] - Zall[:, iu_all[1]])
252     for tau in [0.5, 1.0, 1.5, 2.0, 2.5]:
253         rc = float((pd_all > tau).mean())
254         r0 = float(2 * stats.norm.sf(tau / np.sqrt(2)))
255         thr_rows.append({'阈值tau': tau, '冲突率': rc, '独立基
准': r0,
256                        '比值': rc / r0, '结论': '指标正相关
(冲突率低于独立基准)'
257                        if rc < r0 else '指标间无正相关'})
258     save_csv_safe(pd.DataFrame(thr_rows), '冲突阈值灵敏度.csv'
)
259
260     # ---- 域级质量: 抽样集与扩展集对照 ----
261     domain = meta.groupby(['source', 'domain']).agg(
262         n=('quality_Q', 'size'), quality_mean=('quality_Q', '

```

```

mean'),
263     quality_std=('quality_Q', 'std')).reset_index()
264     save_csv_safe(domain, '质量域评分_抽样与扩展.csv')
265     comp = domain.pivot(index='domain', columns='source',
values='quality_mean')
266     a1 = comp['A1']
267     ext = comp.drop(columns=[c for c in comp.columns if c == '
A1']).mean(axis=1)
268     comp_out = pd.DataFrame({'domain': comp.index, 'Q_A1': a1.
values, 'Q_扩展集': ext.values})
269     comp_out['差值_A1减扩展'] = comp_out['Q_A1'] - comp_out['
Q_扩展集']
270     save_csv_safe(comp_out, '抽样集与扩展集域级对照.csv')
271     save_csv_safe(meta[['id', 'domain', 'source', 'quality_Q'
]], '样本级质量评分.csv')
272
273     # ---- 高低分原文抽查（验证评分方向） ----
274     checks = []
275     s1 = meta[meta.source == 'A1']
276     for d, g in s1.groupby('domain'):
277         checks.append(g.nsmallest(2, 'quality_Q').assign(group
='低分'))
278         checks.append(g.nlargest(2, 'quality_Q').assign(group=
'高分'))
279     save_csv_safe(pd.concat(checks)[['domain', 'group', '
quality_Q', 'excerpt']], '原文抽查.csv')
280
281     # ---- A16 跨体系映射 ----
282     pooled = meta.groupby('domain')['quality_Q'].mean().
to_dict()
283     mapping = pd.read_csv(DATA('domain_mapping_guide.csv'))
284     global_q = float(meta.quality_Q.mean())
285     mapping['quality_Q'] = [pooled.get(str(q), global_q) if
str(q) != '(none)' else global_q
286         for q in mapping['quality_domain'
]]
287     mapping['quality_source'] = np.where(mapping.
quality_domain.eq('(none)'),

```

```

288                                     '全局均值推断', 'A1-
A3域映射')
289     save_csv_safe(mapping, '17域质量映射.csv')
290     mapping.to_csv(shared_path('17域质量映射.csv'), index=
False, encoding='utf-8-sig')
291     print('质量全量记录 %s 条; A1=%s, A2+A3=%s' % (f'{len(meta
):,}',
292             f'{int((meta.source == "A1").sum()):,}', f'{int((
meta.source != "A1").sum()):,}'))
293     print(pd.DataFrame(ag).to_string(index=False))
294     print('\n赋权方案对比: ')
295     print(cmp_df.to_string(index=False))
296     print('\nad_en 熵权 = %.4f (单指标权重最大项, 须在敏感性分
析中讨论) '
297             % w_entropy[QUALITY_COLS.index('ad_en')])
298     print('冲突最集中的 5 组指标对: ')
299     print(top_pairs.head(5).to_string())
300     return meta, domain, mapping, norm, w_entropy, pair_table
301
302 # ===== 1. A1-A3 全量质量评价与冲突检验 =====
303 (quality_meta, quality_compare, quality_mapping,
304  quality_norm, quality_weights, quality_pairs) =
    quality_evaluation()
305 quality_domain = quality_meta.groupby('domain').agg(
306     n=('quality_Q', 'size'), quality_mean=('quality_Q', 'mean'
),
307     quality_std=('quality_Q', 'std')).reset_index().
    sort_values('quality_mean')
308 save_csv_safe(quality_domain, '质量域评分_全量.csv')
309
310 # ===== 2. 配比与 Loss 数据加载 =====
311 def load_pair(mix_path, loss_path):
312     m = pd.read_csv(mix_path).sort_values('index').reset_index
(drop=True)
313     l = pd.read_csv(loss_path).sort_values('index').
    reset_index(drop=True)
314     mix_cols = [c for c in m.columns if c.startswith('
train_the_pile_')]

```

```

315     loss_cols = [c for c in l.columns if 'val_loss' in c]
316     return m[mix_cols].values.astype(float), l[loss_cols].
        values.astype(float), m['index'].values
317
318 def short(c):
319     return c.replace('train_the_pile_', '').replace('metric/
        the_pile_', '').replace('_val_loss', '')
320
321 Xtr, Ytr, itr = load_pair(DATA('train_mixture_1m.csv'), DATA('
        train_pile_loss_1m.csv'))
322 Xte1, Yte1, _ = load_pair(DATA('test_mixture_1m.csv'), DATA('
        test_pile_loss_1m.csv'))
323 Xte2, Yte2, _ = load_pair(DATA('test_mixture_60m.csv'), DATA('
        test_pile_loss_60m.csv'))
324 Xte3, Yte3, _ = load_pair(DATA('test_mixture_1B.csv'), DATA('
        test_pile_loss_1B.csv'))
325 Xes10, Yes10, es10_idx = load_pair(DATA('est_mixture_10b.csv')
        , DATA('est_pile_loss_10b.csv'))
326 Xes70, Yes70, es70_idx = load_pair(DATA('est_mixture_70b.csv')
        , DATA('est_pile_loss_70b.csv'))
327
328 tm_df = pd.read_csv(DATA('train_mixture_1m.csv'))
329 MIX_COLS = [c for c in tm_df.columns if c.startswith('
        train_the_pile_')]
330 tl_df = pd.read_csv(DATA('train_pile_loss_1m.csv'))
331 LOSS_COLS = [c for c in tl_df.columns if 'val_loss' in c]
332 DOMAINS = [short(c) for c in MIX_COLS]
333 LOSS_DOMAINS = [short(c) for c in LOSS_COLS]
334 UNMEASURED = ['nih_exporter', 'enron_emails', 'europarl', '
        philpapers'] # 无损失列
335 MEASURED = [d for d in DOMAINS if d not in UNMEASURED]
336
337 # ===== 3. 岭正则线性混合回归 =====
338 def fit_ridge(X, Y, alpha=1e-3):
339     n, K = X.shape
340     Xc = np.hstack([X, np.ones((n, 1))])
341     reg = alpha * np.eye(K + 1); reg[-1, -1] = 0
342     W = np.linalg.solve(Xc.T @ Xc + reg, Xc.T @ Y)

```

```

343     return W[:K], W[-1]
344
345 def predict(X, A, b):
346     return X @ A + b
347
348 def r2(y, yhat):
349     ss_res = np.sum((y - yhat) ** 2, axis=0)
350     ss_tot = np.sum((y - y.mean(axis=0)) ** 2, axis=0)
351     return 1 - ss_res / np.maximum(ss_tot, 1e-12)
352
353 def pearson_col(y, yhat):
354     return np.array([np.corrcoef(y[:, j], yhat[:, j])[0, 1]
355                      for j in range(y.shape[1])])
356
357 A, b = fit_ridge(Xtr, Ytr)
358 r2_tr = r2(Ytr, predict(Xtr, A, b))
359 r2_tel = r2(Ytel, predict(Xtel, A, b))
360 r_te2 = pearson_col(Yte2, predict(Xte2, A, b))
361 r_te3 = pearson_col(Yte3, predict(Xte3, A, b))
362
363 print('\n=== 岭回归训练 R2 (各损失域) ===')
364 for d, v in zip(LOSS_DOMAINS, r2_tr):
365     print(' %-20s %.4f' % (d, v))
366 print('训练平均 R2 = %.4f; 同尺度 1M 检验平均 R2 = %.4f' % (
367     r2_tr.mean(), r2_tel.mean()))
368 print('跨尺度 Pearson: 60M 平均 %.4f, 1B 平均 %.4f' % (r_te2.
369     mean(), r_te3.mean()))
370
371 A_df = pd.DataFrame(A, columns=LOSS_DOMAINS)
372 A_df.insert(0, 'training_domain', DOMAINS)
373 save_csv_safe(A_df, '混合系数矩阵.csv')
374 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
375     intercept': b}), '截距.csv')
376
377 lam_rows = []
378 for lam in [1e-4, 1e-3, 1e-2, 1e-1]:
379     A_l, b_l = fit_ridge(Xtr, Ytr, lam)
380     lam_rows.append({'lambda': lam, 'train_mean_R2': r2(Ytr,
381         predict(Xtr, A_l, b_l)).mean(),

```

```

376         'testlm_mean_R2': r2(Ytel, predict(Xtel,
    Al, bl)).mean(),
377         'coef_L2': float(np.linalg.norm(A1)))
378 save_csv_safe(pd.DataFrame(lam_rows), '岭正则敏感性.csv')
379
380 # ===== 4. 质量信息引入配比模型的增量检验 =====
381 qmap = quality_mapping.set_index('mixture_domain')['quality_Q'
    ]
382 qvec = np.array([qmap.get(d, np.nan) for d in DOMAINS], dtype=
    float)
383 qvec = np.where(np.isnan(qvec), float(quality_meta.quality_Q.
    mean()), qvec)
384 Zq = np.hstack([Xtr, (Xtr @ qvec)[:, None]])
385 Az, bz = fit_ridge(Zq, Ytr, 1e-3)
386 r2_z = r2(Ytr, predict(Zq, Az, bz))
387 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
    train_R2_仅配比': r2_tr,
388                             'train_R2_追加Qbar': r2_z, 'R2增量
    ': r2_z - r2_tr,
389                             'Qbar系数': Az[-1]}), '质量项增量
    检验.csv')
390
391 diff_mean = Ytr.mean(axis=0)
392 quality_proxy = 1 - (diff_mean - diff_mean.min()) / (diff_mean
    .max() - diff_mean.min())
393 q_df = pd.DataFrame({'domain': LOSS_DOMAINS, 'mean_loss(
    difficulty)': diff_mean,
394                     'quality_score_Q(loss代理)':
    quality_proxy}).sort_values(
395     'quality_score_Q(loss代理)', ascending=False)
396 save_csv_safe(q_df, 'Loss代理领域难度.csv')
397 save_csv_safe(q_df, '领域质量评分.csv')
398
399 link = pd.read_csv(DATA('domain_mapping_guide.csv'))
400 link = link[link.mapping_type.isin(['direct', 'near_direct'])
    ].copy()
401 qd_map = quality_domain.set_index('domain').quality_mean
402 qp_map = q_df.set_index('domain')['quality_score_Q(loss代理)']

```

```

403 link['Q_A1A3'] = [float(qd_map.get(q, np.nan)) for q in link.
    quality_domain]
404 link['Q_loss代理'] = [float(qp_map.get(m, np.nan)) for m in
    link.mixture_domain]
405 rho_link = float(stats.spearmanr(link.Q_A1A3, link.Q_loss代理)
    .statistic)
406 save_csv_safe(link[['mixture_domain', 'quality_domain', '
    mapping_type', 'Q_A1A3', 'Q_loss代理']],
407     '质量与损失难度一致性.csv')
408
409 A_cent = A - A.mean(axis=0, keepdims=True)
410 A_cent_df = pd.DataFrame(A_cent, columns=LOSS_DOMAINS)
411 A_cent_df.insert(0, 'training_domain', DOMAINS)
412 save_csv_safe(A_cent_df, '混合系数矩阵_中心化.csv')
413 save_csv_safe(pd.DataFrame({'training_domain': DOMAINS,
414     'marginal_effect_on_avg_loss':
    A_cent.mean(axis=1)}),
415     '训练域边际效应.csv')
416
417 # ===== 5. 外推与跨尺度稳健性 =====
418 tr_lookup = {i: Ytr[j] for j, i in enumerate(itr)}
419 ratio10 = Yes10 / np.array([tr_lookup[i] for i in es10_idx])
420 ratio70 = Yes70 / np.array([tr_lookup[i] for i in es70_idx])
421 print('\n=== 外推尺度因子 (est/train 损失比) ===')
422 print(' 10B 均值 %.4f (std %.4f)' % (ratio10.mean(), ratio10.
    std()))
423 print(' 70B 均值 %.4f (std %.4f)' % (ratio70.mean(), ratio70.
    std()))
424 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
    scale_factor_10B': ratio10.mean(axis=0),
425     'scale_factor_70B': ratio70.mean(
    axis=0)}), '外推尺度因子.csv')
426 ratio_scale = Yte2 / Yte1
427 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS,
428     'loss_ratio_60m_vs_1m':
    ratio_scale.mean(axis=0),
429     'loss_ratio_std': ratio_scale.std(
    axis=0)}),

```

```

430         '跨尺度损失比_60m_vs_1m.csv')
431
432 # ===== 6. 最优配比（无约束 + 2.5 倍上界推荐）
433     =====
434 from scipy.optimize import minimize
435 ref = Xtr.mean(axis=0)
436 w_ref = ref[[DOMAINS.index(d) for d in LOSS_DOMAINS]]
437 w_ref = w_ref / w_ref.sum()
438 unmeas_sum = ref[[DOMAINS.index(u) for u in UNMEASURED]].sum()
439 meas_idx = [DOMAINS.index(d) for d in MEASURED]
440
441 def build(pm):
442     p = np.zeros(17); p[meas_idx] = pm
443     for u in UNMEASURED:
444         p[DOMAINS.index(u)] = ref[DOMAINS.index(u)]
445     return p / p.sum()
446
447 def obj(pm):
448     return float(w_ref @ predict(build(pm)[None, :], A, b)[0])
449
450 p0m = ref[meas_idx] / ref[meas_idx].sum()
451 cons = {'type': 'eq', 'fun': lambda pm: pm.sum() - (1 -
452         unmeas_sum)}
453 res = minimize(obj, p0m, method='SLSQP', bounds=[(0, 1)] * len
454         (MEASURED), constraints=cons)
455 p_opt = build(res.x)
456 save_csv_safe(pd.DataFrame({'domain': DOMAINS, '
457         reference_mixture': ref,
458         'optimal_mixture': p_opt}).
459         sort_values('optimal_mixture', ascending=False),
460         '最优配比预测.csv')
461
462 bnds = [(0, 2.5 * ref[i]) for i in meas_idx]
463 res_b = minimize(obj, p0m, method='SLSQP', bounds=bnds,
464         constraints=cons)
465 p_b = build(res_b.x)
466 rec_df = pd.DataFrame({'domain': DOMAINS, 'reference_mixture':
467         ref, 'recommended_mixture': p_b,
468         'adjustment': p_b - ref}).sort_values('

```

```

    adjustment', ascending=False)
461 save_csv_safe(rec_df, '推荐配比调整.csv')
462 print('\n无约束最优加权平均损失 %.4f; 有界推荐 %.4f; 参考配方
    %.4f'
463         % (obj(res.x), obj(res_b.x), obj(p0m)))
464 print('有界推荐配比（调整量最大增/减各 5 域）：')
465 print(rec_df.head(5).to_string(index=False))
466 print(rec_df.tail(5).to_string(index=False))
467
468 # ===== 7. 绘图 =====
469 plt.rcParams['font.size'] = 12
470 cmap = safe_cmap('tab20')
471 colors = [cmap(i % 20) for i in range(17)]
472
473 fig, ax = plt.subplots(figsize=(8.5, 4.8))
474 ax.barh(quality_domain['domain'], quality_domain['quality_mean
    '],
475         xerr=quality_domain['quality_std'], color='#3b6ea5',
        alpha=0.85)
476 ax.set_xlabel('全量质量评分 Q（均值±标准差）')
477 ax.set_title('A1 - A3 全量质量信号的域级评分')
478 despine(ax); fig.tight_layout(); save_fig(fig, '图0_A1-A3全量
    质量评分')
479
480 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
481 ax = axes[0]
482 for r in range(8):
483     bottom = 0
484     for k in range(17):
485         ax.bar(r, Xtr[r, k], bottom=bottom, color=colors[k],
            width=0.7)
486         bottom += Xtr[r, k]
487 ax.set_xticks(range(8)); ax.set_xticklabels(['#%d' % (r + 1)
    for r in range(8)])
488 ax.set_ylabel('领域配比 p_k'); ax.set_title('(a) 训练配方示例
    （前 8 组）'); ax.set_ylim(0, 1.05)
489 ax = axes[1]
490 order = np.argsort(-ref)

```

```

491 ax.bar(range(17), ref[order], color=[colors[k] for k in order
    ])
492 ax.set_xticks(range(17)); ax.set_xticklabels([DOMAINS[k] for k
    in order],
493
    rotation=60, ha='
    right', fontsize=8)
494 ax.set_ylabel('平均配比'); ax.set_title('(b) 全部训练配方平均
    配比 (参考配方)')
495 fig.tight_layout(); save_fig(fig, '图1_训练配比结构')
496
497 fig, ax = plt.subplots(figsize=(10, 4.8))
498 x = np.arange(13); w = 0.22
499 ax.bar(x - w, r2_tr, w, label='训练集(1M)', color='#3b6ea5')
500 ax.bar(x, r2_tel, w, label='检验(1M, 同尺度)', color='#e07a3f'
    )
501 ax.bar(x + w, r_te2, w, label='检验(60M, 跨尺度 r)', color='#5
    aa05a')
502 ax.axhline(0, color='k', lw=0.8)
503 ax.set_xticks(x); ax.set_xticklabels(LOSS_DOMAINS, rotation
    =45, ha='right', fontsize=9)
504 ax.set_ylabel('R2 / Pearson r'); ax.set_title('线性混合回归的
    拟合与泛化表现')
505 ax.legend(); despine(ax); fig.tight_layout(); save_fig(fig, '
    图2_线性模型R2')
506
507 fig, ax = plt.subplots(figsize=(6, 6))
508 Yh = predict(Xtel, A, b)
509 all_y, all_h = Ytel.ravel(), Yh.ravel()
510 lo, hi = min(all_y.min(), all_h.min()), max(all_y.max(), all_h
    .max())
511 ax.scatter(all_y, all_h, s=6, alpha=0.35, color='#3b6ea5')
512 ax.plot([lo, hi], [lo, hi], 'r--', lw=1.2, label='$y=\hat{y}$'
    )
513 ax.set_xlabel('实测交叉熵损失'); ax.set_ylabel('模型预测损失')
514 ax.set_title('同尺度检验集(1M): 预测 vs 实测')
515 ax.legend(); despine(ax); fig.tight_layout(); save_fig(fig, '
    图3_预测vs实测')
516

```

```

517 fig, ax = plt.subplots(figsize=(11, 6.5))
518 mesh = safe_heatmap(ax, A_cent.T, row_labels=LOSS_DOMAINS,
    col_labels=DOMAINS,
519                      cmap='RdBu_r', fontsize=9)
520 vmax = np.abs(A_cent).max()
521 mesh.set_clim(-vmax, vmax)
522 cb = fig.colorbar(mesh, ax=ax, shrink=0.85)
523 cb.set_label('中心化混合系数（相对效应）')
524 ax.set_xlabel('训练领域 k（17 域）'); ax.set_ylabel('验证损失
    领域 d（13 域）')
525 ax.set_title('领域配比对交叉熵损失的相对影响（暖=更难，冷=更
    易）')
526 fig.tight_layout(); save_fig(fig, '图4_混合系数热力图')
527
528 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.6))
529 ax = axes[0]
530 qs = q_df.sort_values('quality_score_Q(loss代理)')
531 ax.barh(qs['domain'], qs['quality_score_Q(loss代理)'],
532         color=plt.colormaps['RdYlGn'](qs['quality_score_Q(loss
    代理)'].values))
533 ax.set_xlabel('Loss 反向映射代理（越高表示越易）')
534 ax.set_title('(a) 13 个验证域的 Loss 难度代理')
535 despine(ax)
536 ax = axes[1]
537 ax.scatter(link.Q_A1A3, link.Q_loss代理, s=45, color='#3b6ea5'
    )
538 for _, r in link.iterrows():
539     ax.annotate(r.mixture_domain, (r.Q_A1A3, r.Q_loss代理),
    fontsize=7,
540                xytext=(3, 3), textcoords='offset points')
541 ax.set_xlabel('A1 - A3 域级质量 Q'); ax.set_ylabel('Loss 难度代
    理质量')
542 ax.set_title('(b) 两套口径排序一致性 Spearman  $\rho$ =%.2f' %
    rho_link)
543 despine(ax); fig.tight_layout(); save_fig(fig, '图5_领域质量评
    分')
544
545 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.6))

```

```

546 ax = axes[0]
547 tp = quality_pairs['全量'].sort_values(ascending=False).head
    (12)[::-1]
548 ax.barh(range(len(tp)), tp.values, color='#c44e52')
549 ax.set_yticks(range(len(tp))); ax.set_yticklabels(tp.index,
    fontsize=7)
550 ax.set_xlabel('该指标对的冲突样本占比')
551 ax.set_title('(a) 冲突最集中的指标对 ( $|z_j - z_k| > .1f$ ) ' %
    CONFLICT_TAU)
552 despine(ax)
553 ax = axes[1]
554 wi = np.argsort(quality_weights)[::-1]
555 ax.bar(range(22), quality_weights[wi], color='#4c72b0')
556 ax.set_xticks(range(22)); ax.set_xticklabels([QUALITY_COLS[k]
    for k in wi],
557                                             rotation=75, ha='
        right', fontsize=7)
558 ax.set_ylabel('熵权  $w_j$ '); ax.set_title('(b) 熵权分布 (客观赋
    权诊断)')
559 despine(ax); fig.tight_layout(); save_fig(fig, '图6_冲突与赋权
    诊断')
560
561 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
562 ax = axes[0]
563 bp = safe_boxplot(ax, [ratio10[:, j] for j in range(13)],
    LOSS_DOMAINS)
564 for box in bp['boxes']:
565     box.set_facecolor('#aec7e8')
566 ax.set_xticklabels(LOSS_DOMAINS, rotation=45, ha='right',
    fontsize=8)
567 ax.axhline(ratio10.mean(), color='r', ls='--', lw=1, label='均
    值  $.3f$ ' % ratio10.mean())
568 ax.set_ylabel('损失比  $est/train$ '); ax.set_title('(a) 10B 外推
    尺度因子'); ax.legend()
569 ax = axes[1]
570 x = np.arange(13)
571 ax.bar(x, ratio_scale.mean(axis=0), 0.5, yerr=ratio_scale.std(
    axis=0),

```

```

572         color='#ff9f68', capsize=2, label='60M vs 1M')
573 ax.axhline(1, color='k', ls='--', lw=0.8)
574 ax.set_xticks(x); ax.set_xticklabels(LOSS_DOMAINS, rotation
    =45, ha='right', fontsize=8)
575 ax.set_ylabel('损失比 60M/1M'); ax.set_title('(b) 跨尺度损失比
    (同配方) '); ax.legend()
576 fig.tight_layout(); save_fig(fig, '图7_外推与跨尺度')
577
578 # ===== 8. 汇总 =====
579 save_csv_safe(pd.DataFrame({'loss_domain': LOSS_DOMAINS, '
    train_R2': r2_tr, 'test1m_R2': r2_te1,
580                             'test60m_r': r_te2, 'test1B_r':
    r_te3, 'mean_loss': diff_mean,
581                             'quality_Q(loss代理)':
    quality_proxy}), '问题一_拟合汇总.csv')
582
583 conf = pd.read_csv(os.path.join(OUT_DIR, '质量冲突与一致性.csv
    '))
584 meta_out = {
585     'train_mean_R2': float(r2_tr.mean()), 'test1m_mean_R2':
    float(r2_te1.mean()),
586     'test60m_mean_r': float(r_te2.mean()), 'test1B_mean_r':
    float(r_te3.mean()),
587     'n_quality_records': int(len(quality_meta)),
588     'n_A1': int((quality_meta.source == 'A1').sum()),
589     'n_ext': int((quality_meta.source != 'A1').sum()),
590     'Q0_global_mean': float(quality_meta.quality_Q.mean()),
591     'Q0_mix_weighted': float(ref @ qvec),
592     'kendall_W_full': float(conf.loc[conf.dataset.eq('全量'),
    'kendall_W'].iloc[0]),
593     'conflict_rate_full': float(conf.loc[conf.dataset.eq('全量
    '), 'conflict_rate'].iloc[0]),
594     'conflict_indep_baseline': float(conf.loc[conf.dataset.eq(
    '全量'), 'indep_baseline'].iloc[0]),
595     'spearman_quality_vs_lossproxy': float(rho_link),
596     'Qbar_R2_gain_mean': float((r2_z - r2_tr).mean()),
597 }
598 with open(shared_path('问题一_关键量.json'), 'w', encoding='

```

```

    utf-8') as fh:
599     json.dump(meta_out, fh, ensure_ascii=False, indent=2)
600
601 print('\n===== 问题一求解完成 =====')
602 print('训练平均 R2=%.4f; 同尺度检验 R2=%.4f; 跨尺度相关 60M
    =%.4f, 1B=%.4f'
603         % (r2_tr.mean(), r2_te1.mean(), r_te2.mean(), r_te3.mean
            ()))
604 print('追加混合质量指数 Qbar 的平均 R2 增量 = %.5f' % (r2_z -
    r2_tr).mean())
605 print('全局平均质量 Q0 = %.4f (供问题三基线使用) ' %
    quality_meta.quality_Q.mean())
606 if RC_FAILS:
607     print('注意： 以下结果文件因被占用而改存： ', RC_FAILS)

```

Listing 1: 问题一求解代码（质量综合评价、冲突消解与岭正则配比建模）

问题二：广义标度律（问题二.py）

```

1  # -*- coding: utf-8 -*-
2  """
3  问题二：跨维度数据融合与广义标度律
4  数据：附件 B（B1 主拟合；B2/B3 族外与轨迹验证；B4/B5 跨族与文
    献验证；
5      B6/B7 质量 Q；B8 大规模矩阵（方向异常，仅作可信度边界警
        示）；B9/B10 百亿参数以上外推）
6  模型：经典  $L = E + A N^{-a} + B D^{-b}$ 
7      广义  $L = E + A N^{-a} + B D^{-b} + C (1-Q)^g$  (Q=1 退化为经典
        形式)
8  输出：图片到 图片/, 结果 CSV 到 结果/, 参数共享至 求解/广义标
        度律参数.csv
9  """
10 import sys, os, glob
11 sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.
    abspath(__file__))))
12 from _common import * # noqa: F401,F403
13 from scipy.optimize import least_squares
14

```

```

15 DATA = data_path
16
17 def save_csv_safe(df, name_cn):
18     p = os.path.join(OUT_DIR, name_cn)
19     try:
20         df.to_csv(p, index=False, encoding='utf-8-sig')
21     except PermissionError:
22         alt = p.replace('.csv', '_new.csv')
23         df.to_csv(alt, index=False, encoding='utf-8-sig')
24         print('    ! %s 被占用, 已改存为 %s' % (name_cn, os.path
        .basename(alt)))
25
26 pythia = pd.read_csv(DATA('pythia_training_log_existing.csv'))
27 cerebras = pd.read_csv(DATA('cerebras_training_log.csv'))
28 baseline = pd.read_csv(DATA('scaling_baseline.csv'))
29 published = pd.read_csv(DATA('published_scaling_data.csv'))
30 nq6 = pd.read_csv(DATA('supplementary_NQ_experiment.csv'))
31 nq7 = pd.read_csv(DATA('supplementary_NQ_experiment_expanded.
    csv'))
32 nq8 = pd.read_csv(DATA('supplementary_NQ_experiment_large.csv'
    ))
33 large_models = pd.read_csv(DATA('supplementary_large_models.
    csv'))
34 large_loss = pd.read_csv(DATA('supplementary_large_baseline.
    csv'))
35 traj_files = sorted(glob.glob(os.path.join(DATA_DIR, '
    B_scaling_laws',
36
        '
        training_trajectories', '*.csv'))))
37
38 N_p = pythia.N_params_B.to_numpy(float)
39 D_p = pythia.D_tokens_B.to_numpy(float)
40 L_p = pythia.val_loss.to_numpy(float)
41
42 # ===== 1. 经典标度律 (B1 主拟合 + 模型留出验证)
    =====
43 def classic(par, N, D):
44     E, A, a, B, b = par

```

```

45     return E + A * N ** (-a) + B * D ** (-b)
46
47 r0 = least_squares(lambda p: classic(p, N_p, D_p) - L_p, [1.7,
48     .4, .33, 1.2, .28],
49     bounds=([0, 1e-8, .01, 1e-8, .01], [5, 1e3,
50     2, 1e3, 2]),
51     loss='soft_l1', f_scale=.05, max_nfev
52     =40000)
53 E0, A0, a0, B0, b0 = r0.x
54 Lph = classic(r0.x, N_p, D_p)
55 R2_cls = 1 - np.sum((L_p - Lph) ** 2) / np.sum((L_p - L_p.mean
56     ()) ** 2)
57 RMSE_cls = float(np.sqrt(np.mean((L_p - Lph) ** 2)))
58
59 Ns = sorted(pythia.N_params_B.unique())
60 tr_m = pythia[pythia.N_params_B.isin(Ns[:4])]
61 te_m = pythia[pythia.N_params_B.isin(Ns[4:])]
62 rh = least_squares(lambda p: classic(p, tr_m.N_params_B.values
63     , tr_m.D_tokens_B.values)
64     - tr_m.val_loss.values, [1.7, .4, .33, 1.2,
65     .28],
66     bounds=([0, 1e-8, .01, 1e-8, .01], [5, 1e3,
67     2, 1e3, 2]),
68     loss='soft_l1', f_scale=.05, max_nfev
69     =40000)
70 hp = classic(rh.x, te_m.N_params_B.values, te_m.D_tokens_B.
71     values)
72 ym = te_m.val_loss.values
73 hold = {'留出R2': 1 - np.sum((ym - hp) ** 2) / np.sum((ym - ym
74     .mean()) ** 2),
75     '留出RMSE': float(np.sqrt(np.mean((ym - hp) ** 2))),
76     '留出MAPE_%': float(np.mean(np.abs(ym - hp) / ym) *
77     100)}
78
79 print('=== 1. 经典标度律 (B1 Pythia, n=%d) ===' % len(pythia))
80 print('    E=%.4f A=%.4f alpha=%.4f B=%.4f beta=%.4f' % (E0, A0,
81     a0, B0, b0))
82 print('    拟合 R2=%.8f  RMSE=%.6f  MAPE=%.4f%%' % (

```

```

71     R2_cls, RMSE_cls, np.mean(np.abs(L_p - Lph) / L_p) * 100))
72 print('  留出验证 (4 小模型 -> 4 大模型) : R2=%.8f RMSE=%.6f
      MAPE=%.4f%%' % (
73     hold['留出R2'], hold['留出RMSE'], hold['留出MAPE_%']))
74 print('  提示: B1 拟合残差标准差仅 %.5f (损失标准差 %.4f), 说
      明该附件近乎无观测噪声, '
75     '其上高 R2 只能确认函数形式自洽, 不能替代外部验证。' % (
76         float(np.std(L_p - Lph)), float(np.std(L_p))))
77 save_csv_safe(pd.DataFrame([{'E': E0, 'A': A0, 'alpha': a0, 'B
      ': B0, 'beta': b0,
78                               'R2': R2_cls, 'RMSE': RMSE_cls,
79                               'MAPE_%': float(np.mean(np.abs(
      L_p - Lph) / L_p) * 100),
80                               '残差标准差': float(np.std(L_p -
      Lph))}, **hold])),
81     '经典标度律参数.csv')
82
83 # ===== 2. 质量字段方向审计 =====
84 def group_corr(df, qcol='Q_score'):
85     vals, ng = [], 0
86     for _, g in df.groupby(['N_params_B', 'D_tokens_B']):
87         if g[qcol].nunique() >= 3:
88             vals.append(g[qcol].corr(g.val_loss)); ng += 1
89     return float(np.nanmean(vals)), ng
90
91 audit = []
92 for nm, sub, note in [('B6', nq6, '质量主数据'),
93                       ('B7', nq7, '质量扩展数据 (含 B6 重复
      点)'),
94                       ('B8-calibrated', nq8[nq8.data_type.eq('
      calibrated')], '大规模矩阵校准段'),
95                       ('B8-extrapolated', nq8[nq8.data_type.eq
      ('extrapolated')], '大规模矩阵外推段')]:
96     r, ng = group_corr(sub)
97     audit.append({'dataset': nm, 'n': len(sub), 'n_groups': ng
      , 'within_ND_corr': r,
98                   'conclusion': ('Q 越大损失越低 -> 质量指标
      (越高越好) ' if r < -0.5 else

```

```

99         ('Q 越大损失越高 -> 方向与 B6
    /B7 相反' if r > 0.5 else
100         '组内无显著单调关系'))))
101 save_csv_safe(pd.DataFrame(audit), '质量字段方向审计.csv')
102 corr6 = audit[0]['within_ND_corr']; corr7 = audit[1]['
    within_ND_corr']
103 corr8 = audit[2]['within_ND_corr']
104 print('\n=== 2. 质量字段方向审计（控制 N、D 的组内相关）===')
105 print(pd.DataFrame(audit).to_string(index=False))
106 print(' 结论：B6/B7 的 Q_score 与损失负相关 (r=%.3f / %.3f
    ), 是“质量”而非“难度”，'
107       '故取 Q = Q_score (Q=1 最优)，与问题一“越高越好”口径
    一致。' % (corr6, corr7))
108 print('  B8 校准段方向相反 (r=%.3f)：两套半合成数据口径不一
    致，B8 不并入拟合。' % corr8)
109
110 # ===== 3. 广义标度律：形式比较与参数估计 =====
111 N_all = np.r_[N_p, nq6.N_params_B]
112 D_all = np.r_[D_p, nq6.D_tokens_B]
113 Q_all = np.r_[np.ones(len(pythia)), nq6.Q_score]      # B1 无
    质量信息，取参考水平 Q=1
114 L_all = np.r_[L_p, nq6.val_loss]
115
116 def g_v1(p, N, D, Q):
117     E, A, a, B, b, C, g = p
118     return E + A * N ** (-a) + B * D ** (-b) + C * np.clip(1 -
    Q, 0, 1) ** g
119
120 def g_v2(p, N, D, Q):
121     E, A, a, B, b, g = p
122     return E + A * N ** (-a) + B * (D * np.clip(Q, 1e-6, 1) **
    g) ** (-b)
123
124 def g_v4(p, N, D, Q):
125     E, A, a, B, b, C, g = p
126     return E + A * N ** (-a) + B * D ** (-b) + C * np.clip(Q,
    1e-6, 1) ** (-g)
127

```

```

128 def g_v5(p, N, D, Q):
129     E, A, a, B, b, g1, g2 = p
130     return (E + A * (N * np.clip(Q, 1e-6, 1) ** g1) ** (-a)
131             + B * (D * np.clip(Q, 1e-6, 1) ** g2) ** (-b))
132
133 FORMS = {
134     '加性质量缺口  $C(1-Q)^g$ ': (g_v1, [E0, A0, a0, B0, b0, .35,
135     1.],
136                                     [0, 1e-8, .01, 1e-8, .01, 1e-8,
137     .05], [5, 1e3, 2, 1e3, 2, 50, 10]),
138     '质量作有效数据乘子': (g_v2, [E0, A0, a0, B0, b0, .5],
139     [0, 1e-8, .01, 1e-8, .01, -10], [5,
140     1e3, 2, 1e3, 2, 30]),
141     '加性质量亏损  $C Q^{-g}$ ': (g_v4, [E0, A0, a0, B0, b0, .2,
142     .5],
143                                     [0, 1e-8, .01, 1e-8, .01, 1e-8,
144     .05], [5, 1e3, 2, 1e3, 2, 50, 10]),
145     '质量同时乘 N 与 D': (g_v5, [E0, A0, a0, B0, b0, .3, .3],
146     [0, 1e-8, .01, 1e-8, .01, -10, -10],
147     [5, 1e3, 2, 1e3, 2, 30, 30]),
148 }
149 nq7_new = nq7[~nq7.experiment_id.astype(str).isin(set(nq6.
150     experiment_id.astype(str)))]
151 form_rows, fit_store = [], {}
152 for nm, (fn, p0, lo, hi) in FORMS.items():
153     rr = least_squares(lambda p: fn(p, N_all, D_all, Q_all) -
154     L_all, p0,
155                         bounds=(lo, hi), loss='soft_l1',
156     f_scale=.05, max_nfev=80000)
157     hh = fn(rr.x, N_all, D_all, Q_all)
158     R2j = 1 - np.sum((L_all - hh) ** 2) / np.sum((L_all -
159     L_all.mean()) ** 2)
160     hq = fn(rr.x, nq6.N_params_B.values, nq6.D_tokens_B.values
161     , nq6.Q_score.values)
162     R2q = 1 - np.sum((nq6.val_loss.values - hq) ** 2) / \
163     np.sum((nq6.val_loss.values - nq6.val_loss.mean()) **
164     2)
165     h7 = fn(rr.x, nq7_new.N_params_B.values, nq7_new.

```

```

D_tokens_B.values, nq7_new.Q_score.values)
154     r7 = float(np.corrcoef(nq7_new.val_loss.values, h7)[0, 1])
155     form_rows.append({'形式': nm, '联合R2': R2j, 'B6拟合R2':
R2q, 'B7新增点r': r7,
156                     '参数个数': len(rr.x),
157                     'AIC': len(N_all) * np.log(np.mean((
L_all - hh) ** 2)) + 2 * len(rr.x)})
158     fit_store[nm] = rr.x
159 sv = pd.DataFrame(form_rows).sort_values('联合R2', ascending=
False)
160 save_csv_safe(sv, '广义标度律形式对比.csv')
161 print('\n=== 3. 广义标度律形式对比 ===')
162 print(sv.to_string(index=False))
163
164 best_name = sv.iloc[0]['形式']
165 fn_best = FORMS[best_name][0]
166 r1x = fit_store[best_name]
167 E, A, alpha, B, beta, Cq, gamma = r1x
168 Lhat = fn_best(r1x, N_all, D_all, Q_all)
169 R2_gen = 1 - np.sum((L_all - Lhat) ** 2) / np.sum((L_all -
L_all.mean()) ** 2)
170 RMSE_gen = float(np.sqrt(np.mean((L_all - Lhat) ** 2)))
171 MAPE_gen = float(np.mean(np.abs(L_all - Lhat) / np.abs(L_all))
* 100)
172 print('\n选定形式: %s' % best_name)
173 print('    E=%.4f A=%.4f alpha=%.4f B=%.4f beta=%.4f C=%.4f
gamma=%.4f R2=%.4f RMSE=%.4f MAPE=%.2f%%'
174       % (E, A, alpha, B, beta, Cq, gamma, R2_gen, RMSE_gen,
MAPE_gen))
175
176 params = pd.DataFrame({'param': ['E', 'A', 'alpha', 'B', 'beta
', 'C', 'gamma'],
177                        'value': [E, A, alpha, B, beta, Cq,
gamma]})
178 save_csv_safe(params, '广义标度律参数.csv')
179 params.to_csv(shared_path('广义标度律参数.csv'), index=False,
encoding='utf-8-sig')
180

```

```

181 # ===== 4. 分层验证 =====
182 def metrics(df, Q=1.0):
183     q = np.full(len(df), Q) if np.isscalar(Q) else np.asarray(
184         Q)
185     ph = fn_best(r1x, df.N_params_B.to_numpy(float), df.
186         D_tokens_B.to_numpy(float), q)
187     y = df.val_loss.to_numpy(float)
188     return ph, float(np.corrcoef(y, ph)[0, 1]), float(np.sqrt(
189         np.mean((y - ph) ** 2))), \
190         float(np.mean(np.abs(y - ph) / np.maximum(np.abs(y), 1
191             e-9)) * 100)
192
193 nq8c = nq8[nq8.data_type.eq('calibrated')]
194 validation, pred_sets = [], []
195 for name, df, q, kind in [('B2_Cerebras(半合成,族外)',
196     cerebras, 1., '半合成'),
197     ('B4_跨族收敛点(真实)', baseline,
198     1., '真实'),
199     ('B5_已发表标度律(真实)', published,
200     1., '真实'),
201     ('B7_质量扩展新增点(半合成)',
202     nq7_new, nq7_new.Q_score, '半合成'),
203     ('B8_校准段(Q 反向重定向)', nq8c, 1
204     - nq8c.Q_score, '半合成'),
205     ('B10_百亿参数以上(估算)',
206     large_loss, 1., '估算')]:
207     ph, r, rm, mp = metrics(df, q)
208     validation.append({'dataset': name, 'n': len(df), '性质':
209         kind, 'r': r,
210         'RMSE': rm, 'MAPE_%': mp})
211     pred_sets.append((name.split('_')[0], df.val_loss.to_numpy(
212         float), ph))
213 val_df = pd.DataFrame(validation)
214 save_csv_safe(val_df, '广义标度律分层验证.csv')
215 print('\n=== 4. 广义标度律分层验证 ===')
216 print(val_df.to_string(index=False))
217
218 save_csv_safe(large_loss.assign(

```

```

207     pred=fn_best(r1x, large_loss.N_params_B.values, large_loss
.D_tokens_B.values,
208                 np.ones(len(large_loss))), '百亿参数以上外推
.csv')
209
210 # ===== 5. 弹性、边际效用与替代关系 =====
211 def marg(p, N, D, Q):
212     E_, A_, a_, B_, b_, C_, g_ = p
213     return (-a_ * A_ * N ** (-a_ - 1), -b_ * B_ * D ** (-b_ -
1),
214            -g_ * C_ * np.clip(1 - Q, 1e-9, None) ** (g_ - 1))
215
216 el_rows = []
217 for N_ref, D_ref, Q_ref in [(1., 100., 0.6), (12., 300., 0.6)
]:
218     L_ref = float(fn_best(r1x, N_ref, D_ref, Q_ref))
219     dN, dD, dQ = marg(r1x, N_ref, D_ref, Q_ref)
220     sub = abs(dQ) / abs(dN)
221     el_rows.append({'参考点N(B)': N_ref, 'D(B)': D_ref, 'Q':
Q_ref, 'L': L_ref,
222                   '弹性e_N': dN * N_ref / L_ref, '弹性e_D':
dD * D_ref / L_ref,
223                   '弹性e_Q': dQ * Q_ref / L_ref, '替代率dN/
dQ(B)': sub,
224                   'dQ=0.1等价dN(B)': sub * 0.1})
225 el_df = pd.DataFrame(el_rows)
226 save_csv_safe(el_df, '弹性与替代关系.csv')
227 print('\n=== 5. 弹性与质量—参数替代关系 ===')
228 print(el_df.round(4).to_string(index=False))
229
230 N_ref, D_ref, Q_ref = 1., 100., 0.6
231 dN, dD, dQ = marg(r1x, N_ref, D_ref, Q_ref)
232 subst = abs(dQ) / abs(dN)
233 save_csv_safe(pd.DataFrame({'质量提升dQ': [.05, .1, .2, .3],
234                             '局部等价参数增量dN(B)': subst *
np.array([.05, .1, .2, .3]),
235                             '等价数据增量dD(B)': abs(dQ) / abs
(dD) * np.array([.05, .1, .2, .3])})),

```

```

236         '质量参数替代关系.csv')
237
238 Qs = np.linspace(0.30, 0.99, 80)
239 subs = np.array([abs(marg(r1x, N_ref, D_ref, q)[2]) / abs(marg
240         (r1x, N_ref, D_ref, q)[0])
241         for q in Qs])
242 save_csv_safe(pd.DataFrame({'Q': Qs, 'dN_per_dQ(B)': subs,
243         'dN_for_dQ_0.1(B)': subs * 0.1}),
244         '替代率随质量变化.csv')
245
246 save_csv_safe(pd.DataFrame({'Q': Qs, '不可约损失下限': E + Cq
247         * (1 - Qs) ** gamma}),
248         '质量与损失下限.csv')
249
250 # ===== 6. 领域间的替代/互补关系（基于问题一系数向量）
251 # =====
252 p1_dir = os.path.join(SOLVE_DIR, '问题一', '结果')
253 coef = pd.read_csv(os.path.join(p1_dir, '混合系数矩阵.csv')).
254     set_index('training_domain')
255 inter = pd.read_csv(os.path.join(p1_dir, '截距.csv')).
256     set_index('loss_domain').intercept
257 mix = pd.read_csv(DATA('train_mixture_lm.csv'))
258 mix_cols = [c for c in mix if c.startswith('train_the_pile_')]
259 domains = [c.replace('train_the_pile_', '') for c in mix_cols]
260 p_ref = mix[mix_cols].mean().to_numpy(float)
261 loss_domains = list(coef.columns)
262 w_ref = np.array([p_ref[domains.index(d)] for d in
263     loss_domains]); w_ref /= w_ref.sum()
264
265 def mix_obj(p):
266     return float(w_ref @ (np.asarray(p) @ coef.loc[domains].
267         to_numpy()
268         + inter.loc[loss_domains].to_numpy()
269     ))
270
271 ref_obj = mix_obj(p_ref)
272 rec = pd.read_csv(os.path.join(p1_dir, '推荐配比调整.csv')).
273     set_index('domain').loc[domains]
274 p_rec = rec.recommended_mixture.to_numpy(float)

```

```

264 mix_delta_rec = mix_obj(p_rec) - ref_obj
265 save_csv_safe(pd.DataFrame([{'mixture': '参考配比', '
    predicted_weighted_loss': ref_obj, 'M_p': 0.},
266                               {'mixture': '问题一有界推荐', '
    predicted_weighted_loss': mix_obj(p_rec),
267                               'M_p': mix_delta_rec}]), '配比项
    校准.csv')
268
269 Cn = coef.loc[domains].to_numpy()
270 Cc = Cn - Cn.mean(axis=0, keepdims=True)
271 nm_ = np.linalg.norm(Cc, axis=1, keepdims=True)
272 sim = (Cc @ Cc.T) / np.maximum(nm_ @ nm_.T, 1e-12)
273 pd.DataFrame(sim, index=domains, columns=domains).to_csv(
274     os.path.join(OUT_DIR, '领域替代互补矩阵.csv'), encoding='
    utf-8-sig')
275 tri = np.triu_indices(len(domains), 1)
276 pair_sim = pd.DataFrame({'domain_i': [domains[i] for i in tri
    [0]],
277                          'domain_j': [domains[j] for j in tri
    [1]],
278                          'coefficient_similarity': sim[tri]}).
    sort_values(
279     'coefficient_similarity', ascending=False)
280 save_csv_safe(pd.concat([pair_sim.head(8).assign(关系='可替代'
    ),
281                          pair_sim.tail(8).assign(关系='互补或
    冲突')]), '领域替代互补_top.csv')
282 print('\n=== 6. 领域替代与互补（系数向量余弦相似度）===')
283 print('最可替代的 4 组: '); print(pair_sim.head(4).to_string(
    index=False))
284 print('最互补的 4 组: '); print(pair_sim.tail(4).to_string(
    index=False))
285 print('推荐配比带来的加权平均损失变化  $M(p) = %.4f$  %
    mix_delta_rec)
286
287 # ===== 7. B3 插值轨迹验证 =====
288 traj_rows = []
289 for f in traj_files:

```

```

290     d = pd.read_csv(f)
291     n_par = float(d.N_params_B.iloc[0])
292     base = E0 + A0 * n_par ** (-a0)
293     y = np.clip(d.val_loss.values - base, 1e-9, None)
294     sl = np.polyfit(np.log(d.D_tokens_B.values), np.log(y), 1)
295     traj_rows.append({'file': os.path.basename(f), 'N(B)':
296                     '轨迹内D幂指数': float(sl), '经典beta':
297                     float(-b0)})
298     traj_df = pd.DataFrame(traj_rows)
299     save_csv_safe(traj_df, 'B3轨迹验证.csv')
300     print('\n=== 7. B3 插值轨迹验证 (轨迹内损失对 D 的幂指数 vs 经
301           典 beta) ===')
302     print(traj_df.round(4).to_string(index=False))
303     # ===== 8. 汇总 =====
304     save_csv_safe(pd.DataFrame({
305         '指标': ['E', 'A', 'alpha', 'B', 'beta', 'C', 'gamma', '经
306               典R2', '经典残差标准差',
307               '留出R2', '广义R2', '广义RMSE', '广义MAPE%', 'B6
308               方向相关r', 'B7方向相关r', 'B8方向相关r',
309               '参考点弹性e_N', '参考点弹性e_D', '参考点弹性e_Q'
310               , '替代率dN/dQ', '推荐配比M(p)'],
311         '数值': [E, A, alpha, B, beta, Cq, gamma, R2_cls, float(np
312               .std(L_p - Lph)),
313               hold['留出R2'], R2_gen, RMSE_gen, MAPE_gen, corr6
314               , corr7, corr8,
315               el_rows[0]['弹性e_N'], el_rows[0]['弹性e_D'],
316               el_rows[0]['弹性e_Q'],
317               subst, mix_delta_rec])), '问题二_拟合汇总.csv')
318     # ===== 9. 绘图 =====
319     plt.rcParams['font.size'] = 12
320     fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
321     axes[0].scatter(N_p, L_p, s=5, alpha=.2)
322     ns = np.logspace(-1.2, 1.3, 100)
323     axes[0].plot(ns, classic(r0.x, ns, np.full_like(ns, 300)),

```

```

    color='#d62728')
318 axes[0].set_xscale('log'); axes[0].set_xlabel('N (B)'); axes
    [0].set_ylabel('Loss')
319 axes[0].set_title('(a) 参数标度')
320 for n in [.07, 1., 6.9]:
321     ds = np.logspace(-1, 2.6, 100)
322     axes[1].plot(ds, classic(r0.x, np.full_like(ds, n), ds),
        label='N=%sB' % n)
323 axes[1].scatter(D_p, L_p, s=4, alpha=.1)
324 axes[1].set_xscale('log'); axes[1].set_xlabel('D (B tokens)');
    axes[1].set_ylabel('Loss')
325 axes[1].set_title('(b) 数据标度'); axes[1].legend()
326 fig.tight_layout(); save_fig(fig, '图1_经典标度律拟合')
327
328 fig, ax = plt.subplots(figsize=(6, 6))
329 for name, y, ph in [('B1+B6 联合拟合', L_all, Lhat)] +
    pred_sets:
330     ax.scatter(y, ph, s=9, alpha=.45, label=name)
331 lo = min(np.min(x[1]) for x in [('', L_all, Lhat)] + pred_sets
    )
332 hi = max(np.max(x[1]) for x in [('', L_all, Lhat)] + pred_sets
    )
333 ax.plot([lo, hi], [lo, hi], 'k--')
334 ax.set_xlabel('观测/给定 Loss'); ax.set_ylabel('预测 Loss')
335 ax.set_title('广义标度律分层验证'); ax.legend(fontsize=7)
336 fig.tight_layout(); save_fig(fig, '图2_广义标度律验证')
337
338 Qg = np.linspace(.05, 1, 120)
339 fig, ax = plt.subplots(figsize=(7, 4.8))
340 for n in [.41, 2.8, 12]:
341     ax.plot(Qg, fn_best(r1x, n, 300, Qg), label='N=%sB' % n)
342 ax.set_xlabel('数据质量 Q'); ax.set_ylabel('Loss')
343 ax.set_title('质量缺口惩罚随 Q 消失 (Q=1 退化为经典标度律)')
344 ax.legend(); despine(ax); fig.tight_layout(); save_fig(fig, '
    图3_质量边际影响')
345
346 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
347 Ng = np.logspace(-1.2, 2.5, 100)

```

```

348 axes[0].plot(Ng, alpha * A * Ng ** (-alpha - 1))
349 axes[0].set_xscale('log'); axes[0].set_yscale('log')
350 axes[0].set_title('(a) 参数边际效用  $|\partial L / \partial N|$ '); axes[0].
    set_xlabel('N (B)')
351 axes[1].plot(Qg, Cq * gamma * (1 - Qg + 1e-9) ** (gamma - 1))
352 axes[1].set_title('(b) 质量边际效用  $|\partial L / \partial Q|$ '); axes[1].
    set_xlabel('Q')
353 fig.tight_layout(); save_fig(fig, '图4_边际效用对比')
354
355 fig, ax = plt.subplots(figsize=(7, 5.2))
356 for target in [2.30, 2.10, 1.95]:
357     rhs = target - E - B * 300.0 ** (-beta) - Cq * (1 - Qg) **
        gamma
358     Ns2 = np.where(rhs > 0, (A / np.maximum(rhs, 1e-12)) ** (1
        / alpha), np.nan)
359     ax.plot(Qg, Ns2, label='L=%.2f' % target)
360 ax.set_yscale('log'); ax.set_xlabel('数据质量 Q'); ax.
    set_ylabel('所需 N (B)')
361 ax.set_title('质量—参数等损失曲线 (D=300B) '); ax.legend()
362 despine(ax); fig.tight_layout(); save_fig(fig, '图5_质量参数替
    代')
363
364 fig, ax = plt.subplots(figsize=(7.5, 6))
365 mesh = safe_heatmap(ax, sim, row_labels=domains, col_labels=
    domains, cmap='RdBu_r', fontsize=7)
366 mesh.set_clim(-1, 1)
367 cb = fig.colorbar(mesh, ax=ax, shrink=0.8); cb.set_label('系数
    向量余弦相似度')
368 ax.set_title('训练领域的替代/互补结构 (暖=互补, 冷=可替代) ')
369 fig.tight_layout(); save_fig(fig, '图6_领域替代互补')
370
371 print('\n===== 问题二求解完成 =====')
372 print('经典 R2=%.8f, 留出 R2=%.8f; 广义 R2=%.4f; 替代率 dN/dQ
    =%.3f B/单位质量')
373 % (R2_cls, hold['留出R2'], R2_gen, subst))

```

Listing 2: 问题二求解代码（经典与广义标度律拟合、方向审计、弹性与质量—参数替代分析）

问题三：算力约束联合优化（问题三.py）

```
1 # -*- coding: utf-8 -*-
2 """
3 问题三：算力约束下的多维资源联合优化与结构性转移
4 输入：问题二广义标度律参数  $L(N,D,Q)=E+A/N^a+B/D^b+C(1-Q)^g$ ；
5 问题一的质量基线  $Q0$  与配比修正  $M(p)$ ；附件 C7 的上下文长
   度可行取值。
6 成本（严格按赛题附录 B 与正文公式）：
7      $C_{total} = C_{train} + C_Q + C_{attn}$ 
8      $= 6ND + D * [g(Q) - g(Q0)]_+ + eta * N * D * L_{ctx}$ ,  $eta = 2e-4$ 
9      $g(Q)$  取附录 B 三型（指数型  $1e7 * \exp(6Q)$ 、幂函数型  $5e9 * Q^4$ 、
   对数渐进型  $2e9 * \ln(1+10Q)$ ）
10 临界上下文长度：注意力开销 = 基础训练开销  $\Leftrightarrow eta * N * D * L = 6 * N * D$ 
    $\Leftrightarrow L_{crit} = 6/eta = 30000$ 
11 方法：三档预算联合优化（SLSQP，对数参数化）；预算扫略 + 结构性
   转移识别； $L_{ctx}$  敏感性。
12 输出：图片到 图片/，结果 CSV 到 结果/。
13 """
14 import sys, os, json
15 sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.abspath(__file__))))
16 from _common import * # noqa: F401,F403
17 from scipy.optimize import minimize
18
19 DATA = data_path
20
21 def save_csv_safe(df, name_cn):
22     p = os.path.join(OUT_DIR, name_cn)
23     try:
24         df.to_csv(p, index=False, encoding='utf-8-sig')
25     except PermissionError:
26         alt = p.replace('.csv', '_new.csv')
27         df.to_csv(alt, index=False, encoding='utf-8-sig')
28         print('! %s 被占用，已改存为 %s' % (name_cn, os.path.basename(alt)))
29
```

```

30 # ===== 0. 读取前两问输出 =====
31 params = pd.read_csv(shared_path('广义标度律参数.csv'),
    index_col='param')['value']
32 E, A, alpha, B, beta, Cq, gamma = (params['E'], params['A'],
    params['alpha'],
33                                     params['B'], params['beta']
    ], params['C'], params['gamma'])
34
35 with open(shared_path('问题一_关键量.json'), encoding='utf-8')
    as fh:
36     k1 = json.load(fh)
37 Q0_sample = float(k1['Q0_global_mean'])
38
39 mix_map = pd.read_csv(shared_path('17域质量映射.csv'))
40 ref_mix = pd.read_csv(data_path('train_mixture_lm.csv'))
41 ref_cols = [c for c in ref_mix if c.startswith('
    train_the_pile_')]
42 ref_p = ref_mix[ref_cols].mean().to_numpy(float)
43 ref_dom = [c.replace('train_the_pile_', '') for c in ref_cols]
44 qmap = mix_map.set_index('mixture_domain')['quality_Q']
45 q_vec = np.array([float(qmap.get(d, Q0_sample)) for d in
    ref_dom])
46 Q0 = float(ref_p @ q_vec)          # 基线质量 = 参考语料配比加权
    平均质量
47 print('=== 0. 质量基线与模型参数（来自问题一、二）===')
48 print(' 参考语料配比加权基线质量 Q0 = %.4f（全量样本均值 %.4f
    ）' % (Q0, Q0_sample))
49 print(' 标度律: E=%.4f A=%.4f alpha=%.4f B=%.4f beta=%.4f C
    =%.4f gamma=%.4f'
50         % (E, A, alpha, B, beta, Cq, gamma))
51
52 def loss(N_abs, D_abs, Q, M_p=0.0):
53     """验证损失：参数以 B 为单位代入问题二标度律，M_p 为配比项
    修正。"""
54     return (E + A * (N_abs / 1e9) ** (-alpha) + B * (D_abs / 1
    e9) ** (-beta)
55             + Cq * (1 - Q) ** gamma + M_p)
56

```

```

57 # ===== 1. 附录 B 的三型质量成本函数 =====
58 GB = {
59     '指数型': dict(gamma=1e7, lam=6.0),
60     '幂函数型': dict(gamma=5e9, lam=4.0),
61     '对数渐进型': dict(gamma=2e9, lam=10.0),
62 }
63 def g_of(Q, form):
64     par = GB[form]
65     if form == '指数型':
66         return par['gamma'] * np.exp(par['lam'] * Q)
67     if form == '幂函数型':
68         return par['gamma'] * Q ** par['lam']
69     return par['gamma'] * np.log(1 + par['lam'] * Q)
70
71 def c_quality(D_abs, Q, form):
72     return D_abs * max(g_of(Q, form) - g_of(Q0, form), 0.0)
73
74 for form in GB:
75     print(' g(%s) 在 Q0=%.3f 处为 %.4e, 在 Q=1 处为 %.4e (单
76         位算力/token) '
77         % (form, Q0, g_of(Q0, form), g_of(1.0, form)))
78 # ===== 2. 临界上下文长度 =====
79 ETA = 2e-4
80 L_CRIT = 6.0 / ETA
81 arch = pd.read_csv(DATA('model_architecture_metadata.csv'))
82 L_FEAS = sorted(arch['max_position_embeddings'].dropna().
83     unique().astype(int).tolist())
84 print('\n=== 1. 临界上下文长度 (解析解) ===')
85 print(' C_attn = eta*N*D*L_ctx, C_train = 6ND -> L_crit = 6/
86     eta = %.0f tokens' % L_CRIT)
87 print(' C7 给出的可行上下文长度 (max_position_embeddings) : %
88     s' % L_FEAS)
89 print(' 可行取值中跨越临界值的一对: 8192 (0.2f 倍) 与 32768 (
90     0.2f 倍) '
91     % (ETA * 8192 / 6, ETA * 32768 / 6))
92
93 # ===== 3. 总成本与单点最优 =====

```

```

90 def total_cost(N_abs, D_abs, Q, L_ctx, form):
91     return 6.0 * N_abs * D_abs + c_quality(D_abs, Q, form) +
        ETA * N_abs * D_abs * L_ctx
92
93 def optimize(C_budget, L_ctx=2048, form='幂函数型', M_p=0.0,
        n_starts=8, Qcap=1.0):
94     """SLSQP 对数参数化联合优化 (N, D, Q)。"""
95     def obj(x):
96         return loss(np.exp(x[0]), np.exp(x[1]), x[2], M_p)
97     def con(x):
98         return C_budget - total_cost(np.exp(x[0]), np.exp(x
100 [1]), x[2], L_ctx, form)
101     best = None
102     for k in range(n_starts):
103         frac = (k + 1) / (n_starts + 1)
104         x0 = [np.log(1e9) + 4 * (frac - .5), np.log(1e11) + 4
105 * (.5 - frac),
106             Q0 + (Qcap - Q0) * frac]
107         try:
108             res = minimize(obj, x0, method='SLSQP',
109                             bounds=[(np.log(1e5), np.log(1e15))
110 ,
111                                     (np.log(1e6), np.log(1e16))
112 , (Q0, Qcap)],
113                             constraints={'type': 'ineq', 'fun':
114 con},
115                             options={'maxiter': 1500, 'ftol': 1
116 e-14})
117         except Exception:
118             continue
119         if res.success and (best is None or res.fun < best.fun
120 ):
121             best = res
122     if best is None:
123         raise RuntimeError('优化失败')
124     N_abs, D_abs, Q = np.exp(best.x[0]), np.exp(best.x[1]),
125 best.x[2]
126     c_base = 6.0 * N_abs * D_abs

```

```

118     c_qual = c_quality(D_abs, Q, form)
119     c_attn = ETA * N_abs * D_abs * L_ctx
120     return dict(N_B=N_abs / 1e9, D_B=D_abs / 1e9, D_over_N=
D_abs / N_abs, Q=Q,
121                 L=loss(N_abs, D_abs, Q, M_p), c_base=c_base,
c_qual=c_qual,
122                 c_attn=c_attn, c_tot=c_base + c_qual + c_attn,
123                 f_base=c_base / C_budget, f_qual=c_qual /
C_budget,
124                 f_attn=c_attn / C_budget, form=form, L_ctx=
L_ctx, C=C_budget)
125
126 BUDGETS = [1e19, 1e22, 1e24]
127 print('\n=== 2. 三档预算最优配置（幂函数型质量成本, L_ctx=2048
) ===')
128 rows = []
129 for Cb in BUDGETS:
130     r = optimize(Cb, 2048, '幂函数型')
131     rows.append(r)
132     print('    C=%.0e: N*=%.3fB D*=%.1fB Q*=%.4f L*=%.4f    '
133           '[base %.1f%% qual %.1f%% attn %.1f%%]'
134           % (Cb, r['N_B'], r['D_B'], r['Q'], r['L'],
135              r['f_base'] * 100, r['f_qual'] * 100, r['f_attn']
* 100))
136 save_csv_safe(pd.DataFrame(rows), '三档预算最优配置.csv')
137
138 # ===== 4. 三种质量成本函数对比 =====
139 print('\n=== 3. 质量成本函数对最优解的影响 ===')
140 comp = []
141 for Cb in BUDGETS:
142     for form in GB:
143         r = optimize(Cb, 2048, form)
144         comp.append(r)
145 comp_df = pd.DataFrame(comp)
146 save_csv_safe(comp_df, '成本函数对比.csv')
147 for Cb in BUDGETS:
148     sub = comp_df[comp_df.C.eq(Cb)]
149     print('    C=%.0e' % Cb)

```

```

150     for _, r in sub.iterrows():
151         print('      %-6s N*=% .3fB D*=% .1fB Q*=% .4f L*=% .4f 质量
投入占比 % .1f%%'
              % (r['form'], r['N_B'], r['D_B'], r['Q'], r['L'
], r['f_qual'] * 100))
153
154 # ===== 4b. 质量基线 Q0 口径的灵敏度 =====
155 _Q0_main = Q0
156 Q0 = Q0_sample
157 print('\n=== 3b. 质量基线口径灵敏度 (Q0 由配比加权 % .4f 改为样
本均值 % .4f) ==='
      % (_Q0_main, Q0_sample))
159 q0_rows = []
160 for Cb in BUDGETS:
161     r = optimize(Cb, 2048, '幂函数型')
162     q0_rows.append(r)
163     print('    C=% .0e: N*=% .3fB D*=% .1fB Q*=% .4f L*=% .4f 质量投
入占比 % .1f%%'
          % (Cb, r['N_B'], r['D_B'], r['Q'], r['L'], r['f_qual
'] * 100))
165 save_csv_safe(pd.DataFrame(q0_rows), '质量基线灵敏度.csv')
166 Q0 = _Q0_main
167
168 # ===== 5. 领域配比 M(p) 的算力等价效果 =====
169 mix_cal = pd.read_csv(os.path.join(SOLVE_DIR, '问题二', '结果'
, '配比项校准.csv'))
170 M_p = float(mix_cal.loc[mix_cal.mixture.eq('问题一有界推荐'),
'M_p'].iloc[0])
171 print('\n=== 4. 领域配比修正的算力等价效果 (M(p)=% .4f) ===' %
M_p)
172 r_mix = optimize(1e22, 2048, '幂函数型', M_p=M_p)
173 r_ref = optimize(1e22, 2048, '幂函数型', M_p=0.0)
174 print('    C=1e22: 参考配比 L*=% .4f (N*=% .3fB D*=% .1fB Q*=% .4f)
,
175         % (r_ref['L'], r_ref['N_B'], r_ref['D_B'], r_ref['Q']))
176 print('        推荐配比 L*=% .4f (N*=% .3fB D*=% .1fB Q*=% .4f)
,
177         % (r_mix['L'], r_mix['N_B'], r_mix['D_B'], r_mix['Q']))

```

```

178
179 def budget_for_loss(L_target, L_ctx=2048, form='幂函数型'):
180     lo, hi = 1e17, 1e25
181     for _ in range(60):
182         mid = np.sqrt(lo * hi)
183         try:
184             r = optimize(mid, L_ctx, form, n_starts=3)
185             if r['L'] > L_target:
186                 lo = mid
187             else:
188                 hi = mid
189         except Exception:
190             lo = mid
191     return np.sqrt(lo * hi)
192
193 C_eq = budget_for_loss(r_mix['L'])
194 print('  推荐配比在 C=1e22 时得到的损失 %.4f, 若改用参考配比实
195     ' C≈%.3e FLOPs, 即配比优化的效果等价于约 %.1f 倍算力扩张
196     ,
197     % (r_mix['L'], C_eq, C_eq / 1e22))
198 print('  (说明: M(p) 是损失水平上的固定平移, 与算力无关, 故换
199     ' 损失的算力弹性放大, 此倍数宜作量级参考。) ')
200 save_csv_safe(pd.DataFrame([{'mixture': '参考配比', 'M_p':
201     0.0, **r_ref},
202     {'mixture': '问题一有界推荐', 'M_p':
203     M_p, **r_mix}]),
204     '配比项算力等价.csv')
205
206 # ===== 6. 预算扫略与结构性转移识别 =====
207 print('\n=== 5. 预算扫略与结构性转移 ===')
208 C_sweep = np.logspace(18, 25, 141)
209 sweep = []
210 for Cb in C_sweep:
211     try:
212         sweep.append(optimize(Cb, 2048, '幂函数型', n_starts
213     =5))

```

```

210     except Exception:
211         sweep.append(dict(N_B=np.nan, D_B=np.nan, Q=np.nan, L=
np.nan, c_base=np.nan,
212                             c_qual=np.nan, c_attn=np.nan, c_tot=
np.nan, f_base=np.nan,
213                             f_qual=np.nan, f_attn=np.nan, form='
幂函数型', L_ctx=2048, C=Cb))
214 sw = pd.DataFrame(sweep)
215 save_csv_safe(sw, '预算扫略.csv')
216
217 Qc = sw['Q'].to_numpy(float)
218 logC = np.log10(C_sweep)
219 ok = np.isfinite(Qc)
220 # 结构性转移的定量定义:
221 # 以“质量投入份额 f_qual 的相对变化方向反转 + 最优质量对预
算的弹性改变符号/量级”为标志。
222 inQ = (Qc - Q0) / (1 - Q0) # 质量提升完成
度
223 d_inQ = np.gradient(inQ[ok], logC[ok])
224 fQ = sw['f_qual'].to_numpy(float)
225 d_fQ = np.gradient(fQ[ok], logC[ok])
226 shift = {'质量提升完成度弹性 dln(Theta)/dlnC 的最大值点预算':
float(C_sweep[ok][np.argmax(d_inQ)]),
227         '质量投入启动边界（份额由零转正的拐点预算）': float(
C_sweep[ok][np.argmax(d_fQ)]),
228         '质量投入份额峰值预算': float(C_sweep[ok][np.argmax(
fQ[ok]))],
229         '质量投入份额峰值': float(np.nanmax(fQ[ok]))}
230 # 以“质量提升完成度”  $\Theta = (Q^* - Q_0) / (1 - Q_0)$  报告门槛，避免 Q0 本
身已高于固定阈值时失去意义
231 for frac in [0.25, 0.5, 0.75, 0.99]:
232     hit = Qc[ok] >= Q0 + frac * (1 - Q0)
233     shift['完成度Theta首次达到%d%%的预算' % int(frac * 100)] =
(
234         float(C_sweep[ok][np.argmax(hit)]) if hit.any() else
float('nan'))
235 for k, v in shift.items():
236     print(' %s = %.3e FLOPs' % (k, v))

```

```

237
238 # N/D 比随预算的演化（规模结构）
239 sw['D_over_N'] = sw['D_B'] / sw['N_B']
240 print(' D/N 比: C=1e19 时 %.1f, C=1e22 时 %.1f, C=1e24 时 %.1
    f'
241     % tuple(sw.loc[(sw.C - c).abs().idxmin(), 'D_over_N']
    for c in [1e19, 1e22, 1e24]))
242 save_csv_safe(pd.DataFrame([shift]), '结构性转移识别.csv')
243
244 # ===== 7. 上下文长度敏感性（C7 可行取值 + 临界值）
    =====
245 print('\n=== 6. 上下文长度敏感性（C=1e22, 幂函数型） ===')
246 sens = []
247 for L in L_FEAS:
248     r = optimize(1e22, L, '幂函数型')
249     r['attn_over_train'] = ETA * L / 6.0
250     r['is_above_crit'] = L > L_CRIT
251     sens.append(r)
252     print(' L=%6d (%.2f 倍训练开销) : N*=%.3fB D*=%.1fB Q
    *=%.4f L*=%.4f 注意力占比 %.1f%%s'
253           % (L, r['attn_over_train'], r['N_B'], r['D_B'], r['Q
    '], r['L'],
254             r['f_attn'] * 100, ' [超临界]' if L > L_CRIT
    else ''))
255 sens_df = pd.DataFrame(sens)
256 save_csv_safe(sens_df, '上下文长度敏感性.csv')
257
258 # 连续 L 扫描（含临界点）
259 L_grid = np.logspace(np.log10(1024), np.log10(200000), 40)
260 cont = []
261 for L in L_grid:
262     try:
263         r = optimize(1e22, float(L), '幂函数型', n_starts=3)
264         r['attn_over_train'] = ETA * L / 6.0
265         cont.append(r)
266     except Exception:
267         pass
268 save_csv_safe(pd.DataFrame(cont), '上下文长度连续扫描.csv')

```

```

269
270 # ===== 8. 绘图 =====
271 plt.rcParams['font.size'] = 12
272 C1_, C2_, C3_ = '#3b6ea5', '#e07a3f', '#5aa05a'
273
274 opt_df = pd.DataFrame(rows)
275 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.6))
276 x = np.arange(len(BUDGETS))
277 axes[0].plot(x, opt_df['N_B'], 'o-', lw=2, ms=8, color=C1_,
278             label='参数量 N* (B)')
279 axes[0].plot(x, opt_df['D_B'], 's--', lw=2, ms=8, color=C2_,
280             label='数据量 D* (B tokens)')
281 for xi, (nb, db) in enumerate(zip(opt_df['N_B'], opt_df['D_B']
282                                 ])):
283     axes[0].annotate('%.3g' % nb, (xi, nb), fontsize=8, xytext
284                     =(0, 8),
285                     textcoords='offset points', ha='center',
286                     color=C1_)
287     axes[0].annotate('%.4g' % db, (xi, db), fontsize=8, xytext
288                     =(0, -15),
289                     textcoords='offset points', ha='center',
290                     color=C2_)
291 axes[0].set_yscale('log'); axes[0].set_xticks(x)
292 axes[0].set_xticklabels(['1019', '1022', '1024'])
293 axes[0].set_xlabel('算力预算 C (FLOPs)'); axes[0].set_ylabel('
    最优规模（对数尺度）')
294 axes[0].set_title('(a) 最优参数量与数据量'); axes[0].legend(
295     fontsize=9); despine(axes[0])
296 axes[1].plot(x, opt_df['Q'], 'o-', lw=2, ms=8, color=C3_,
297             label='最优质量 Q*')
298 axes[1].axhline(Q0, color='gray', ls=':', lw=1.2, label='基线
299             质量 Q0=%.3f' % Q0)
300 for xi, qv in enumerate(opt_df['Q']):
301     axes[1].annotate('%.3f' % qv, (xi, qv), fontsize=9, xytext
302                     =(0, 8),
303                     textcoords='offset points', ha='center',
304                     color=C3_)
305 axes[1].set_xticks(x); axes[1].set_xticklabels(['1019', '1022'

```

```

    , '1024'])
294 axes[1].set_ylim(0, 1.12); axes[1].set_xlabel('算力预算 C (
    FLOPs)')
295 axes[1].set_ylabel('最优质量 Q*'); axes[1].set_title('(b) 最优
    质量随预算的变化')
296 axes[1].legend(fontsize=9); despine(axes[1])
297 fig.tight_layout(); save_fig(fig, '图1_三档预算最优配置')
298
299 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
300 axes[0].plot(C_sweep, Qc, lw=2, color=C3_)
301 axes[0].axhline(Q0, color='gray', ls=':', lw=1.2, label='基线
    质量 Q0=%.3f' % Q0)
302 axes[0].axvline(shift['质量投入启动边界（份额由零转正的拐点预
    算）'], color='#d62728', ls='--', lw=1.2,
303                 label='投入份额拐点')
304 axes[0].set_xscale('log'); axes[0].set_xlabel('算力预算 C (
    FLOPs)')
305 axes[0].set_ylabel('最优质量 Q*'); axes[0].set_ylim(0, 1.05)
306 axes[0].set_title('(a) 最优质量随预算的演化'); axes[0].legend(
    fontsize=8); despine(axes[0])
307 axes[1].plot(C_sweep, sw['f_base'] * 100, lw=2, color=C1_,
    label='基础训练 6ND')
308 axes[1].plot(C_sweep, sw['f_qual'] * 100, lw=2, color=C2_,
    label='质量提升 D[g(Q)-g(Q0)]')
309 axes[1].plot(C_sweep, sw['f_attn'] * 100, lw=2, color='#d62728
    ', label='长文本注意力')
310 axes[1].set_xscale('log'); axes[1].set_xlabel('算力预算 C (
    FLOPs)')
311 axes[1].set_ylabel('预算份额 (%)'); axes[1].set_title('(b) 预
    算份额的结构性演化')
312 axes[1].legend(fontsize=8); despine(axes[1])
313 fig.tight_layout(); save_fig(fig, '图2_预算份额结构性转移')
314
315 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
316 axes[0].plot([r['attn_over_train'] for r in cont], [r['N_B']
    for r in cont], 'o-', ms=3, color=C1_)
317 axes[0].set_xscale('log'); axes[0].set_yscale('log')
318 axes[0].axvline(1.0, color='#d62728', ls='--', lw=1.2,

```

```

319         label='临界  $L^* = \%.0f$  (注意力=训练)' % L_CRIT)
320 axes[0].set_xlabel('注意力开销 / 训练开销 =  $\eta L/6$ '); axes[0].
    set_ylabel('N* (B)')
321 axes[0].set_title('(a) 上下文长度对最优规模的影响'); axes[0].
    legend(fontsize=8); despine(axes[0])
322 # 右图: 不同预算档下  $Q^*$  随注意力开销倍数的变化 (低预算档才有内
    点解, 故三档并列)
323 L_small = np.logspace(np.log10(1024), np.log10(150000), 14)
324 _qL_rows = []
325 for Cb, col, lbl in [(1e19, C3_, '1019'), (1e20, C2_, '1020'),
    (1e21, C1_, '1021')]:
326     xs, ys = [], []
327     for L in L_small:
328         try:
329             rr = optimize(Cb, float(L), '幂函数型', n_starts
    =3)
330             xs.append(ETA * L / 6.0); ys.append(rr['Q'])
331             _qL_rows.append({'C': Cb, 'L_ctx': float(L), '
    attn_over_train': ETA * L / 6.0,
332                             'N_B': rr['N_B'], 'D_B': rr['D_B']
    ], 'Q': rr['Q'], 'L': rr['L']})
333         except Exception:
334             pass
335     axes[1].plot(xs, ys, 'o-', ms=3, color=col, label='预算 %s
    FLOPs' % lbl)
336 save_csv_safe(pd.DataFrame(_qL_rows), '上下文长度与最优质量.
    csv')
337 axes[1].axvline(1.0, color='#d62728', ls='--', lw=1.2, label='
    临界  $L^*$ ')
338 axes[1].set_xscale('log'); axes[1].set_xlabel('注意力开销 / 训
    练开销 =  $\eta L/6$ ')
339 axes[1].set_ylabel('Q*'); axes[1].set_ylim(0, 1.05)
340 axes[1].yaxis.get_major_formatter().set_useOffset(False)
341 axes[1].set_title('(b) 上下文长度对质量投入的影响')
342 axes[1].legend(fontsize=8); despine(axes[1])
343 fig.tight_layout(); save_fig(fig, '图3_上下文长度敏感性')
344
345 fig, ax = plt.subplots(figsize=(7, 5))

```

```

346 Q_g = np.linspace(Q0, 1.0, 300)
347 for form, lbl in [('幂函数型', '幂函数型 5×109Q4'),
348                  ('指数型', '指数型 107e(6Q)'),
349                  ('对数渐进型', '对数渐进型 2×109ln(1+10Q)')
350                  ]:
351     ax.plot(Q_g, [g_of(q, form) - g_of(Q0, form) for q in Q_g], lw=2, label=lbl)
352 ax.set_xlabel('数据质量 Q'); ax.set_ylabel('单位 token 质量成本 g(Q)-g(Q0)')
353 ax.set_title('附录 B 三种质量成本函数 (Q0=%.3f)' % Q0)
354 ax.legend(fontsize=9); despine(ax); fig.tight_layout();
355 save_fig(fig, '图4_质量成本函数对比')
356
357 # ===== 9. 汇总 =====
358 print('\n===== 问题三求解完成 =====')
359 print('  临界上下文长度 L_crit = 6/eta = %.0f tokens; C7 可行取值 %s' % (L_CRIT, L_FEAS))
360 print('  三档预算（幂函数型）： ' +
361       '; '.join('C=%.0e -> N*=%.3fB D*=%.1fB Q*=%.4f L*=%.4f' % (r['C'], r['N_B'], r['D_B'], r['Q'], r['L'])
362               for r in rows))

```

Listing 3: 问题三求解代码（赛题成本模型、临界上下文长度、预算约束联合优化与结构性转移识别）

问题四：技术演进与前沿预测（问题四.py）

```

1  # -*- coding: utf-8 -*-
2  """
3  问题四：技术演进分析与前沿预测
4  数据：C1/C2 排行榜、C3 时序、C4 Epoch 宏观元数据、C5/C6 Loss-
5  Benchmark 桥接、C7 架构、C8 逐任务 JSON
6  流程：1) 明确口径：时间轴(提交日期)、开源口径(开源权重+许可允许研究复现)、模型类型(pretrained/chat)
7         2) C8 逐任务聚合（必做），并与 C1 六维交叉校验
8         3) C6 桥接（按可比性分层）+ C5 对照，建立 Loss -> Benchmark 映射
9         4) 面板回归（含年份固定效应）分离规模扩张与非规模技术进

```

步贡献

5) 情景设定下 logistic 饱和外推 12/24 个月能力前沿 + 残差 bootstrap 不确定性

6) C4 宏观算力/数据量/开源权重证据, 支撑"算力增长放缓"情景

输出: 图片到 图片/, 结果 CSV 到 结果/

"""

```
import sys, os, json, glob, re, collections
```

```
sys.path.insert(0, os.path.dirname(os.path.dirname(os.path.abspath(__file__))))
```

```
from _common import * # noqa: F401,F403
```

```
from scipy.optimize import curve_fit
```

```
DATA = data_path
```

```
C_DIR = os.path.join(DATA_DIR, 'C_efficiency_evolution')
```

```
def save_csv_safe(df, name_cn):
```

```
    p = os.path.join(OUT_DIR, name_cn)
```

```
    try:
```

```
        df.to_csv(p, index=False, encoding='utf-8-sig')
```

```
    except PermissionError:
```

```
        alt = p.replace('.csv', '_new.csv')
```

```
        df.to_csv(alt, index=False, encoding='utf-8-sig')
```

```
        print(' ! %s 被占用, 已改存为 %s' % (name_cn, os.path.basename(alt)))
```

```
TASKS = ['IFEval', 'BBH', 'MATH Lvl 5', 'GPQA', 'MUSR', 'MMLU-PRO']
```

```
# ===== 1. C1 排行榜: 口径定义与筛选 =====
```

```
lb = pd.read_csv(os.path.join(C_DIR, 'leaderboard_cleaned.csv'))
```

```
lb['P'] = pd.to_numeric(lb['#Params (B)'], errors='coerce')
```

```
lb['date'] = pd.to_datetime(lb['Submission Date'], errors='coerce')
```

```
lb['Year'] = lb['date'].dt.year
```

```
lb['avg'] = pd.to_numeric(lb['Average ↑'], errors='coerce')
```

```
for t in TASKS:
```

```

39     lb[t] = pd.to_numeric(lb[t], errors='coerce')
40
41 TYPE_PRE = ['▯ pretrained', '▯ continuously pretrained']
42 TYPE_CHAT = ['▯ chat models (RLHF, DPO, IFT, ...)',
43             '▯ fine-tuned on domain-specific datasets']
44 TYPE_EXCL = ['▯ base merges and moerges', '▯ multimodal', '▯
    other']
45
46 PERMISSIVE = {'apache-2.0', 'mit', 'gpl-3.0', 'cc-by-4.0', '
    mpl-2.0', 'bsd-3-clause',
47             'llama2', 'llama3', 'llama3.1', 'llama3.2', '
    llama3.3', 'gemma',
48             'cc-by-sa-4.0', 'openrail'}
49
50 def license_ok(x):
51     """许可是否允许研究与复现（非商用/受限/未知一律排除）。"""
52     return str(x).strip().lower() in PERMISSIVE
53
54 lb['license_ok'] = lb['Hub License'].map(license_ok)
55 lb['type_group'] = np.where(lb['Type'].isin(TYPE_PRE), '
    pretrained',
56                             np.where(lb['Type'].isin(TYPE_CHAT
    ), 'chat/finetuned', '其他'))
57 lb['six_complete'] = lb[TASKS].notna().all(axis=1)
58
59 funnel = [{'层级': 'C1 全量记录', 'n': len(lb)},
60           {'层级': '六维得分完整', 'n': int(lb.six_complete.
    sum())}]
61 core = lb[lb.six_complete & lb.date.notna() & lb.P.notna()]
62 funnel.append({'层级': '时间/参数/六维齐备', 'n': len(core)})
63 core_o = core[core.license_ok]
64 funnel.append({'层级': '许可允许研究复现（开源口径）', 'n':
    len(core_o)})
65 core_pt = core_o[core_o.type_group.eq('pretrained')]
66 core_ch = core_o[core_o.type_group.eq('chat/finetuned')]
67 funnel.append({'层级': ' 其中 pretrained', 'n': len(core_pt)
    })
68 funnel.append({'层级': ' 其中 chat/finetuned', 'n': len(

```

```

        core_ch}))
69 save_csv_safe(pd.DataFrame(funnel), '筛选漏斗.csv')
70 print('=== 1. 数据口径与筛选漏斗 ===')
71 print(pd.DataFrame(funnel).to_string(index=False))
72 print('  时间轴口径: 以 C1 的 Submission Date (提交日期) 为基
    准。')
73 print('  开源口径: 权重可获取 (pretrained/持续预训练/chat/微
    调) 且 Hub License 允许研究复现。')
74 print('  模型类型口径: pretrained 与 chat/finetuned 分组统计;
    base 合并模型 (%d 条)、'
75         '多模态 (%d 条) 不并入主分析。'
76         % (int(lb['Type'].eq(TYPE_EXCL[0]).sum()), int(lb['Type'
    ].eq(TYPE_EXCL[1]).sum())))
77 print('  提交日期范围: %s ~ %s' % (str(lb.date.min())[:10],
    str(lb.date.max())[:10]))
78
79 # ===== 2. C8 逐任务聚合 (必用) =====
80 def norm_name(s):
81     return re.sub(r'^[a-z0-9]', '', str(s).lower())
82
83 C8_DIR = os.path.join(C_DIR, 'detailed_results')
84 dirs = sorted(d for d in os.listdir(C8_DIR) if os.path.isdir(
    os.path.join(C8_DIR, d)))
85 METRIC_PREF = ['acc_norm,none', 'acc,none', '
    prompt_level_loose_acc,none',
86                 'inst_level_loose_acc,none', 'exact_match,none'
    ]
87 recs, broken = [], 0
88 for d in dirs:
89     fl = sorted(glob.glob(os.path.join(C8_DIR, d, '*.json')))
90     if not fl:
91         continue
92     ok = False
93     for f in reversed(fl):
94         try:
95             o = json.load(open(f, encoding='utf-8'))
96             res = o.get('results')
97             if not isinstance(res, dict) or not res:

```

```

98         continue
99     except Exception:
100         broken += 1
101         continue
102     rec = {'dir': d, 'json_model_name': o.get('model_name'
103         , ''),
104           'file': os.path.basename(f)}
105     for k, v in res.items():
106         if not isinstance(v, dict):
107             continue
108         for mk in METRIC_PREF:
109             if isinstance(v.get(mk), (int, float)):
110                 rec[k] = float(v[mk]) * 100.0
111                 break
112     recs.append(rec)
113     ok = True
114     break
115 if not ok:
116     broken += 1
117
118 c8 = pd.DataFrame(recs)
119 print('\n=== 2. C8 逐任务聚合（必做） ===')
120 print('  模型目录 %d 个; 成功解析 %d 个; 跳过损坏/无有效记录 %d 个' % (len(dirs), len(c8), broken))
121 save_csv_safe(c8.fillna(''), 'C8逐任务解析结果.csv')
122
123 C8_MAP = {'IFEval': 'leaderboard_ifeval', 'BBH': '
124     leaderboard_bbh',
125           'MATH Lvl 5': 'leaderboard_math_hard', 'GPQA': '
126     leaderboard_gpqa',
127           'MUSR': 'leaderboard_musr', 'MMLU-PRO': '
128     leaderboard_mmlu_pro'}
129 for t, k in C8_MAP.items():
130     c8[t] = c8[k] if k in c8.columns else np.nan
131 c8['key'] = c8['dir'].map(norm_name)
132
133 lb['key'] = lb['Model'].map(norm_name)
134 core_o = core_o.assign(key=core_o['Model'].map(norm_name))

```

```

131 mrg = lb[['key'] + TASKS].merge(c8[['key'] + TASKS], on='key',
    suffixes=('_C1', '_C8'))
132 chk_rows = []
133 for t in TASKS:
134     a = pd.to_numeric(mrg[t + '_C1'], errors='coerce')
135     bq = pd.to_numeric(mrg[t + '_C8'], errors='coerce')
136     okm = a.notna() & bq.notna()
137     chk_rows.append({'任务': t, '匹配模型数': int(okm.sum()),
138                     'Pearson_r': float(np.corrcoef(a[okm], bq
139 [okm])[0, 1]) if okm.sum() > 2 else np.nan,
140                     'Spearman_rho': float(stats.spearmanr(a[
141 okm], bq[okm]).statistic)
142                     if okm.sum() > 2 else np.nan,
143                     '平均绝对偏差': float(np.mean(np.abs(a[
144 okm] - bq[okm]))) if okm.sum() else np.nan})
145 chk = pd.DataFrame(chk_rows)
146 save_csv_safe(chk, 'C8与C1一致性校验.csv')
147 print(' C8 与 C1 逐维一致性（规范化模型名匹配，命中 %d 个模
    型）：' % len(mrg))
148 print(chk.to_string(index=False))
149 print(' 口径说明：C8 存的是各任务的原始指标（acc/acc_norm/
    exact_match），'
150       'C1 存的是官方按随机基线归一化后的六维得分（例如 GPQA=(
    raw-0.25)/0.75、'
151       'MMLU-PR0=(raw-0.10)/0.90、IFEval=(prompt_strict+
    inst_strict)/2），'
152       '故两者存在系统性水平差但秩一致性很高。因此：跨模型得分
    分析用 C1，'
153       '逐任务结构分析在 C8 的原始指标空间内进行。')
154 # 逐任务（子任务）聚合：BBH 24 项、MATH 7 项、GPQA 3 项、MUSR
    3 项
155 SUB_PREFIX = {'BBH子任务': 'leaderboard_bbh_', 'MATH子任务': '
    leaderboard_math_',
156               'GPQA子集': 'leaderboard_gpqa_', 'MUSR子任务': '
    leaderboard_musr_'}
157 sub_cols = {}
158 for grp, pre in SUB_PREFIX.items():

```

```

157     cols = [c for c in c8.columns if c.startswith(pre) and c.
count('_') >= 2]
158     cols = [c for c in cols if c not in ('leaderboard_bbh', '
leaderboard_musr',
159                                         'leaderboard_gpqa', '
leaderboard_math_hard'']]
160     sub_cols[grp] = cols
161 print(' C8 子任务维度数: ' + ', '.join('%s %d 项' % (k, len(v
)) for k, v in sub_cols.items()))
162
163 # 子任务前沿与剩余空间（限定在开源筛选后的模型集合上）
164 screened_keys = set(core_o['key'])
165 c8s = c8[c8.key.isin(screened_keys)]
166 sub_rows = []
167 for grp, cols in sub_cols.items():
168     for c in cols:
169         s = pd.to_numeric(c8s[c], errors='coerce').dropna()
170         if len(s) < 10:
171             continue
172         sub_rows.append({'类别': grp, '子任务': c.replace('
leaderboard_', ''), '样本数': len(s),
173                         '最优得分': float(s.max()),
174                         '前5%均值': float(s.nlargest(max(1,
int(len(s) * 0.05))).mean()),
175                         '中位数': float(s.median()),
176                         '剩余空间_%': float((100 - s.max()) /
100 * 100)})
177 sub_df = pd.DataFrame(sub_rows)
178 save_csv_safe(sub_df, 'C8逐任务聚合.csv')
179 print('\n 子任务层面最弱 6 项（剩余空间最大）: ')
180 print(sub_df.nlargest(6, '剩余空间_%')[['类别', '子任务', '样
本数', '最优得分', '前5%均值',
181                                         '剩余空间_%']].
to_string(index=False))
182
183 CAT_ROWS = []
184 for grp, cols in sub_cols.items():
185     s = pd.to_numeric(c8s[cols].stack(), errors='coerce').

```

```

dropna()
186     CAT_ROWS.append({'类别': grp, '维度数': len(cols), '平均最
        优得分': float(
187         np.mean([pd.to_numeric(c8s[c], errors='coerce').max()
        for c in cols])),
188         '整体前5%均值': float(s.quantile(0.95)), '整体中位数':
        float(s.median()))})
189 save_csv_safe(pd.DataFrame(CAT_ROWS), 'C8子任务类别汇总.csv')
190 print('\n 子任务类别汇总: ')
191 print(pd.DataFrame(CAT_ROWS).to_string(index=False))
192
193 # ===== 3. Loss – Benchmark 桥接 (C6 主用, 按可比性分
        层; C5 对照) =====
194 br = pd.read_csv(os.path.join(C_DIR, '
        loss_benchmark_bridge_expanded.csv'))
195 br['cmp'] = np.where(br['Loss_Comparability'].str.startswith('
        High'), '高可比',
196                     '中可比')
197 print('\n=== 3. Loss-Benchmark 桥接 (C6 扩展桥接) ===')
198 bridge_rows, fits = [], {}
199 for lvl in ['高可比', '中可比', '全样本']:
200     d = br if lvl == '全样本' else br[br.cmp.eq(lvl)]
201     sl, ic = np.polyfit(d.Val_Loss, d.LB_Average, 1)
202     pred = ic + sl * d.Val_Loss
203     fits[lvl] = (sl, ic)
204     bridge_rows.append({'可比性': lvl, 'n': len(d),
205                        'Pearson_r': float(np.corrcoef(d.
206 Val_Loss, d.LB_Average)[0, 1]),
207                        'Spearman_rho': float(stats.spearmanr(
208 d.Val_Loss, d.LB_Average).statistic),
209                        '斜率': float(sl), '截距': float(ic),
210                        'MAPE_%': float(np.mean(np.abs(pred -
211 d.LB_Average) / d.LB_Average) * 100),
212                        'R2': float(1 - np.sum((d.LB_Average -
213 pred) ** 2)
214 / np.sum((d.LB_Average - d
215 .LB_Average.mean()) ** 2))})
216 bridge_df = pd.DataFrame(bridge_rows)

```

```

212 save_csv_safe(bridge_df, 'Loss_Benchmark映射.csv')
213 print(bridge_df.to_string(index=False))
214 br['pred'] = fits['全样本'][1] + fits['全样本'][0] * br.
    Val_Loss
215 save_csv_safe(br[['Model', 'N_params_B', 'D_tokens_B', '
    Val_Loss', 'LB_Average', 'pred',
216                 'Loss_Comparability']], 'Loss_Benchmark映射
    明细.csv')
217
218 try:
219     b5 = pd.read_csv(os.path.join(C_DIR, '
    loss_benchmark_bridge.csv'))
220     s5, i5 = np.polyfit(b5.Val_Loss, b5.LB_Average, 1)
221     print(' C5 (原始桥接, n=%d) 对照: r=%.3f, 斜率=%.3f'
222           % (len(b5), float(np.corrcoef(b5.Val_Loss, b5.
    LB_Average)[0, 1]), s5))
223 except Exception as e:
224     print(' C5 对照读取失败: ', e)
225 print(' 说明: 全样本 |r|=%.2f (R2=%.2f), 映射误差较大; 高可
    比子集仅 %d 条且落在 '
226       'Pythia 小模型区间, 得分变化幅度极小 (%.2f-%.2f), 故桥
    接误差对能力结论的影响'
227       '必须显式讨论。'
228       % (abs(bridge_df.iloc[2]['Pearson_r']), bridge_df.iloc
    [2]['R2'],
229          int(bridge_df.iloc[0]['n']),
230          br[br.cmp.eq('高可比')].LB_Average.min(), br[br.cmp.
    eq('高可比')].LB_Average.max()))
231
232 # ===== 4. 面板回归与贡献分解 (规模扩张 vs 非规模技术进
    步) =====
233 # 思路: 规模系数 bP 在“同一年内的横截面”上识别最稳健 (年份效
    应吸收了当年的技术水平),
234 # 再由 bP 与前沿模型的  $\Delta \log_{10} P$  做 shift-share 分解, 残差
    部分归为非规模技术进步。
235 panel = core_o.copy()
236 lb_o = core_o.copy()
237 panel['logP'] = np.log10(panel.P)

```

```

238 panel['t'] = panel.Year - 2019
239 panel = panel[panel.t.between(0, 12)]
240
241 years = sorted(panel.t.unique())
242 def fit_model(sub, label, fe=True):
243     if fe:
244         Dm = np.column_stack([(sub.t.values == yy).astype(
245             float) for yy in years])
246         X = np.column_stack([Dm, sub.logP.values])
247     else:
248         X = np.column_stack([np.ones(len(sub)), sub.logP.
249             values, sub.t.values])
250     b, *_ = np.linalg.lstsq(X, sub.avg.values, rcond=None)
251     pred = X @ b
252     R2 = 1 - np.sum((sub.avg.values - pred) ** 2) / \
253         np.sum((sub.avg.values - sub.avg.values.mean()) ** 2)
254     return (b[-1], b[:-1], R2) if fe else (b[1], b[2], R2)
255
256 bP_fe, alpha_t, R2_fe = fit_model(panel, 'FE', True)
257 bP_ols, bt_ols, R2_ols = fit_model(panel, 'OLS', False)
258 panel['alpha_t'] = panel.t.map(dict(zip(years, alpha_t)))
259 save_csv_safe(pd.DataFrame({'Year': [y + 2019 for y in years],
260     '年效应alpha_t': alpha_t}),
261     '年份效应.csv')
262 save_csv_safe(panel[['Model', 'P', 'logP', 't', 'avg', '
263     type_group', 'Year']],
264     '面板回归数据.csv')
265
266 print('\n=== 4. 规模系数估计 (C1 开源筛选样本, %d 条, %d-%d
267     年) ==='
268     % (len(panel), int(panel.Year.min()), int(panel.Year.max()
269     )))
270 print('  年份固定效应模型: bP=%.3f 分/10 倍参数, R2=%.3f' % (
271     bP_fe, R2_fe))
272 print('  线性时间 OLS 模型: bP=%.3f 分/10 倍参数, bt=%.3f 分/
273     年, R2=%.3f'
274     % (bP_ols, bt_ols, R2_ols))
275 for tg in ['pretrained', 'chat/finetuned']:
276     sub = panel[panel.type_group.eq(tg)]

```

```

268     if len(sub) > 30:
269         bP_t, bt_t, R2_t = fit_model(sub, tg, False)
270         print('    %s 子样本 (n=%d) : bP=%.3f 分/10 倍参数, bt
271             =%.3f 分/年, R2=%.3f'
272                 % (tg, len(sub), bP_t, bt_t, R2_t))
273 # 口径分层: C3 全期序列 (2019-2025, 跨年标准混合) 用于长周期分
274 # 解;
275 # C1 开源筛选样本 (2024-2025, 标准一致) 用于近端稳健
276 # 性检验。
277 ts = pd.read_csv(os.path.join(C_DIR, '
278     leaderboard_extended_timeseries.csv'))
279 ts['avg'] = pd.to_numeric(ts['Average'], errors='coerce')
280 ts['P'] = pd.to_numeric(ts['Params_B'], errors='coerce')
281 six_ts = ['IFEval', 'BBH', 'MATH_Lvl5', 'GPQA', 'MUSR', '
282     MMLU_PRO']
283 for c in six_ts:
284     ts[c] = pd.to_numeric(ts[c], errors='coerce')
285 ts['mean6'] = ts[six_ts].mean(axis=1)
286 ts['gap'] = (ts.avg - ts.mean6).abs()
287 bad = ts[ts.gap > 5]
288 ts_ok = ts[(ts.gap <= 5) & ts.P.notna() & ts.avg.notna() & (ts
289     .P > 0)].copy()
290 ts_ok['logP'] = np.log10(ts_ok.P)
291 ts_ok = ts_ok[np.isfinite(ts_ok.logP) & np.isfinite(ts_ok.avg)
292     ].copy()
293 ts_ok['t'] = ts_ok.Year - 2019
294 save_csv_safe(bad[['Model', 'Year', 'Average', 'mean6', 'gap'
295     ]], 'C3口径异常行.csv')
296 print('\n C3 自洽性审计: |Average - 六维均值| > 5 的记录 %d
297     条 (跨口径混入, 已剔除), '
298     '最大差值 %.1f (%s)' % (len(bad), bad.gap.max(),
299     bad.loc[bad.gap.idxmax(), 'Model
300     ']))
301
302 Xl = np.column_stack([np.ones(len(ts_ok)), ts_ok.logP.values,
303     ts_ok.t.values])
304 bl, *_ = np.linalg.lstsq(Xl, ts_ok.avg.values, rcond=None)

```

```

295 b0_l, bP_l, bt_l = bl
296 pred_l = Xl @ bl
297 R2_l = 1 - np.sum((ts_ok.avg.values - pred_l) ** 2) / \
298     np.sum((ts_ok.avg.values - ts_ok.avg.values.mean()) ** 2)
299
300 front_year = ts_ok.groupby('Year').agg(avg=('avg', 'max'), P=(
    'P', 'max')).reset_index()
301 front_year['cum_avg'] = front_year.avg.cummax()          # 前沿边
    界按定义单调不减
302 front_year['t'] = front_year.Year - 2019
303 front_year['logP'] = np.log10(front_year.P)
304 save_csv_safe(front_year, '前沿序列.csv')
305
306 f1 = lb_o.groupby('Year').agg(avg=('avg', 'max'), P=('P', 'max
    ')).reset_index()
307 dF = front_year.cum_avg.iloc[-1] - front_year.cum_avg.iloc[0]
308 dLP = front_year.logP.iloc[-1] - front_year.logP.iloc[0]
309 dec = pd.DataFrame([
310     {'口径': 'C3 长周期（跨年标准混合）', '前沿区间': '%d→%d'
311     % (front_year.Year.iloc[0], front_year.Year.iloc[-1]),
312     '前沿提升分': dF, 'Δlog10P': dLP, 'bP': bP_l, 'bt(分/年)'
    : bt_l, 'R2': R2_l,
313     '规模贡献分': bP_l * dLP, '非规模贡献分': dF - bP_l * dLP
    ,
314     '规模占比%': bP_l * dLP / dF * 100, '非规模占比%': (dF -
    bP_l * dLP) / dF * 100}])
315 save_csv_safe(dec, '规模时间分解_长周期.csv')
316 print('\n 前沿序列（年度最高分 + 累计最大, %d-%d）: '
317     % (front_year.Year.iloc[0], front_year.Year.iloc[-1]))
318 print(front_year.round(2).to_string(index=False))
319 print(' 贡献分解: ')
320 print(dec.round(2).to_string(index=False))
321 print(' 提示: C3 早期年份为公开报告值（每 1-7 条），跨年评测
    标准不完全一致（C3 标注'
322     '为“混合”口径），故长周期占比视为量级参考；C1 近端口径
    标准一致但窗口仅约 1 年。')
323
324 # ===== 5. 能力前沿的 logistic 外推 =====

```

```

325 # 前沿定义：每个时间窗内开源筛选模型平均分的上侧分位（月度取前
    1%，历史年度取最高分）
326 lb_o['ym'] = lb_o.date.dt.to_period('M')
327 mon_top1 = lb_o.groupby('ym').apply(
328     lambda g: g.avg.nlargest(max(1, int(len(g) * 0.01))).mean
    (), include_groups=False)
329 mon_top1 = mon_top1[mon_top1.index >= pd.Period('2024-01')]
330 t_mon = np.array([(pd.Timestamp(str(p)).year - 2019) + (pd.
    Timestamp(str(p)).month - .5) / 12
331                     for p in mon_top1.index])
332
333 # 前沿边界单调不减：历史段取 C3 累计最大，近端取月度前 1% 的累
    计最大
334 hist_rows = front_year[front_year.Year <= 2023]
335 t_h = hist_rows.t.values + .5
336 s_h = np.maximum.accumulate(hist_rows.cum_avg.values)
337 t_front = np.r_[t_h, t_mon]
338 s_front = np.r_[s_h, np.maximum.accumulate(mon_top1.values)]
339 idx = np.argsort(t_front)
340 t_front, s_front = t_front[idx], np.maximum.accumulate(s_front
    [idx])
341
342 # 近端口径（一致窗口）内的前沿分解：从首月到峰值月
343 def month_stats(period):
344     g = lb_o[lb_o.date.dt.to_period('M').eq(period)]
345     g = g.nlargest(max(1, int(len(g) * 0.01)), 'avg')
346     return float(g.avg.mean()), float(g.P.max())
347
348 p0, pk = mon_top1.index[0], mon_top1.idxmax()
349 F0_, P0_ = month_stats(p0)
350 Fk_, Pk_ = month_stats(pk)
351 dF1 = Fk_ - F0_
352 dLP1 = float(np.log10(Pk_ / P0_))
353 dec1 = pd.DataFrame([
354     '口径': 'C1 近端（一致窗口 %s→%s，前沿模型 %sB→%sB) '
355     % (str(p0), str(pk), ('%.1f' % P0_), ('%.1f' % Pk_)),
356     '前沿区间': '%s→%s' % (str(p0), str(pk)),
357     '前沿提升分': dF1, 'Δlog10P': dLP1, 'bP': bP_fe, 'bt(分/年

```

```

    ): bt_ols, 'R2': R2_fe,
358     '规模贡献分': bP_fe * dLP1, '非规模贡献分': dF1 - bP_fe *
        dLP1,
359     '规模占比%': bP_fe * dLP1 / dF1 * 100 if dF1 != 0 else np.
        nan,
360     '非规模占比%': (dF1 - bP_fe * dLP1) / dF1 * 100 if dF1 !=
        0 else np.nan}}))
361 dec_all = pd.concat([dec, dec1], ignore_index=True)
362 save_csv_safe(dec_all, '规模时间分解.csv')
363 print('\n 近端口径（一致窗口）分解：前沿 %s->%s 由 %.2f 升至
        %.2f (+%.2f 分), '
364         '前沿模型规模 %sB->%sB ( $\Delta\log_{10}P=$ %.3f) '
365         % (str(p0), str(pk), F0_, Fk_, dF1, ('%.1f' % P0_), ('
        %.1f' % Pk_), dLP1))
366 print(' -> 规模贡献 %.2f 分, 非规模贡献 %.2f 分; 该窗口内前沿
        提升基本来自非规模因素。 '
367         % (bP_fe * dLP1, dF1 - bP_fe * dLP1))
368
369 def logistic(t, K, r, t0):
370     return K / (1 + np.exp(-r * (t - t0)))
371
372 t_last = float(np.max(t_mon))
373 t_pred = np.array([t_last + 1.0, t_last + 2.0]) # 严格对
        应未来 12 / 24 个月
374 try:
375     popt, _ = curve_fit(logistic, t_front, s_front, p0=[55,
        .8, 3.5],
376                         bounds=([20, .01, 0.5], [100, 5, 8]),
        maxfev=40000)
377     K_fit, r_fit, t0_fit = popt
378     pred_fit = logistic(t_front, *popt)
379     R2_log = 1 - np.sum((s_front - pred_fit) ** 2) / np.sum((
        s_front - s_front.mean()) ** 2)
380 except Exception as e:
381     K_fit, r_fit, t0_fit, R2_log = 52., .3, 3., 0.
382     print('logistic 拟合失败: ', e)
383 s_pred = logistic(t_pred, K_fit, r_fit, t0_fit)
384

```

```

385 resid = s_front - logistic(t_front, K_fit, r_fit, t0_fit)
386 rng = np.random.default_rng(42)
387 boot = []
388 for _ in range(600):
389     s_b = logistic(t_front, K_fit, r_fit, t0_fit) + rng.choice
        (resid, size=len(resid), replace=True)
390     try:
391         pb, _ = curve_fit(logistic, t_front, s_b, p0=[K_fit,
            r_fit, t0_fit], maxfev=40000)
392         boot.append(logistic(t_pred, *pb))
393     except Exception:
394         pass
395 boot = np.array(boot)
396 lo, hi = np.percentile(boot, 5, axis=0), np.percentile(boot,
    95, axis=0)
397
398 # 情景分析：算力增长放缓 -> 技术增速减半
399 def logistic_slow(t, K, r, t0, halve_from):
400     te = np.minimum(t, halve_from)
401     return K / (1 + np.exp(-r * (te - t0)))
402 s_slow = logistic_slow(t_pred, K_fit, r_fit, t0_fit, t_pred[0]
    - 1)
403
404 fut = pd.DataFrame({'t(2019起算年)': t_pred, '对应日历时点':
405     ['%d-%02d' % (2019 + int(np.floor(tt)),
        int(round((tt % 1) * 12)) + 1)
406         for tt in t_pred],
407     'frontier_pred': s_pred,
408     'CI_low_5%': lo, 'CI_high_95%': hi, '情景_
    技术增速减半': s_slow})
409 save_csv_safe(fut, '前沿预测.csv')
410
411 # 结构外推： $F(t+\Delta) = F(t) + [bP \cdot \Delta \log_{10} P + bt] \cdot \Delta$ （把分解式直接
    用作预测方程）
412 F_last = float(np.max(s_front))
413 scen = []
414 for yrs in [1, 2]:
415     for dlogP, bt_use, lbl in [(0.0, bt_ols, '基准（前沿模型规

```

```

    模持平，非规模增速不变) '),
416         (0.0, bt_ols / 2, '算力增长放缓
    (非规模增速减半) '),
417         (0.3, bt_ols, '规模继续扩张 (前
    沿 +0.3 dex/年) ')]):
418     scen.append({'情景': lbl, '前瞻年数': yrs,
419                 'Δlog10P假设': dlogP, 'bt假设(分/年)':
    bt_use,
420                 '结构外推前沿': F_last + (bP_fe * dlogP +
    bt_use) * yrs})
421 scen_df = pd.DataFrame(scen)
422 save_csv_safe(scen_df, '前沿预测_结构外推情景.csv')
423 save_csv_safe(pd.DataFrame([{'K': K_fit, 'r': r_fit, 't0(2019
    起)': t0_fit, 'R2': R2_log,
424                             '数据截止': str(max(lb_o.date))
    [:10], 'n前沿点': len(t_front),
425                             't_last': t_last}])),
426                 'logistic参数.csv')
427 print('\n=== 5. 能力前沿 logistic 外推 ===')
428 print('    F(t)=K/(1+exp(-r(t-t0))): K=%.2f, r=%.3f, t0=%.2f (
    2019 起算) , R2=%.3f'
429         % (K_fit, r_fit, t0_fit, R2_log))
430 print(fut.round(2).to_string(index=False))
431
432 # ===== 6. C4 宏观证据 (算力、数据量、开源权重)
    =====
433 ep = pd.read_csv(os.path.join(C_DIR, 'epoch_all_ai_models.csv'
    ), low_memory=False)
434 ep['compute'] = pd.to_numeric(ep['Training compute (FLOP)'].
    astype(str).str.replace(',', ''),
435                             errors='coerce')
436 ep['dsize'] = pd.to_numeric(ep['Training dataset size (total)'
    ].astype(str).str.replace(',', ''),
437                             errors='coerce')
438 ep['P'] = pd.to_numeric(ep['Parameters'].astype(str).str.
    replace(',', ''), errors='coerce')
439 ep['year'] = pd.to_datetime(ep['Publication date'], errors='
    coerce').dt.year

```

```

440 ep['open_w'] = ep['Open model weights?'].astype(str).str.strip
    ().eq('Yes')
441
442 c4 = ep[(ep.Domain.astype(str).str.contains('Language', na=
    False)) &
443         ep.year.between(2018, 2026)].copy()
444 g = c4.groupby('year').agg(n=('Model', 'size'),
445                             n_compute=('compute', 'count'),
446                             前沿算力_max=('compute', 'max'),
447                             前沿算力_中位=('compute', 'median')
448
449                             ,
450                             最大参数量_B=('P', 'max'),
451                             最大数据量_tokens=('dsize', 'max'),
452                             开源权重占比=('open_w', 'mean')).
    reset_index()
451 save_csv_safe(g, 'C4宏观趋势.csv')
452 print('\n=== 6. C4 宏观证据 (Epoch AI 全模型元数据, Language
    域) ===')
453 print(g.round(3).to_string(index=False))
454 gc = g.dropna(subset=['前沿算力_max'])
455 gc = gc[gc.前沿算力_max > 0]
456 sl_c, ic_c = np.polyfit(gc.year, np.log10(gc.前沿算力_max), 1)
457 print('  前沿训练算力的年增长率: log10(C) 每年 +%.3f 个数量级
    (即约 %.2f 倍/年) '
458       % (sl_c, 10 ** sl_c))
459 ov = ep['Open model weights?'].astype(str).str.strip()
460 print('  C4 开源权重字段分布: ' + ';' .join('%s=%d' % (k, v)
461       for k, v in ov.value_counts().head(4).items()))
462 save_csv_safe(pd.DataFrame([{'log10前沿算力年增速': sl_c, '年
    倍数': 10 ** sl_c,
463                             '开源权重_Yes': int(ov.eq('Yes').
    sum()),
464                             '开源权重_No': int(ov.eq('No').
    sum()),
465                             '有算力记录行数': int(ep.compute.
    notna().sum()),
466                             '有数据量记录行数': int(ep.dsize.
    notna().sum())}]]),

```

```

467         'C4宏观摘要.csv')
468
469 # ===== 7. 六维 Benchmark 前沿与剩余空间（开源筛选集）
470     =====
471 task_rows = []
472 for tk in TASKS:
473     s = lb_o[tk].dropna()
474     task_rows.append({'task': tk, 'n': len(s), 'max': float(s.
475         max()),
476         'top1_mean': float(s.nlargest(max(1, int
477             (len(s) * 0.01))).mean()),
478         'median': float(s.median()),
479         'headroom_%': float((100 - s.max()))})
480 task_df = pd.DataFrame(task_rows).sort_values('max')
481 save_csv_safe(task_df, '逐任务聚合.csv')
482 print('\n=== 7. 六维 Benchmark 前沿与剩余空间（开源筛选集, n=%
483     d) ===' % len(lb_o))
484 print(task_df.to_string(index=False))
485
486 # ===== 8. 绘图 =====
487 plt.rcParams['font.size'] = 12
488 C1_, C2_, C3_ = '#3b6ea5', '#e07a3f', '#5aa05a'
489
490 fig, ax = plt.subplots(figsize=(6.8, 5))
491 hi_pt = br[br.cmp.eq('高可比')]; me_pt = br[br.cmp.eq('中可比'
492     )]
493 ax.scatter(hi_pt.Val_Loss, hi_pt.LB_Average, s=30, color=C1_,
494     label='高可比 (n=%d)' % len(hi_pt))
495 ax.scatter(me_pt.Val_Loss, me_pt.LB_Average, s=20, color='#
496     aec7e8',
497     label='中可比 (n=%d)' % len(me_pt))
498 Ls = np.linspace(br.Val_Loss.min(), br.Val_Loss.max(), 50)
499 ax.plot(Ls, fits['全样本'][1] + fits['全样本'][0] * Ls, '--',
500     color='#d62728', lw=1.6,
501     label='全样本 r=%.2f' % bridge_df.iloc[2]['Pearson_r'
502     ])
503 ax.set_xlabel('验证交叉熵损失 L'); ax.set_ylabel('Leaderboard
504     均分 B')

```

```

496 ax.set_title('Loss 与 Benchmark 得分的桥接（按可比性分层）')
497 ax.legend(fontsize=9); despine(ax); fig.tight_layout();
    save_fig(fig, '图1_Loss_Benchmark映射')
498
499 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
500 ax = axes[0]
501 sc = ax.scatter(panel.logP, panel.avg, s=8, c=panel.Year, cmap
    ='viridis', alpha=.5)
502 cb = fig.colorbar(sc, ax=ax, shrink=.85); cb.set_label('提交年
    份')
503 Pg = np.linspace(panel.logP.min(), panel.logP.max(), 50)
504 for yy in [2023, 2024, 2025]:
505     k = yy - 2019
506     if k in list(years):
507         off = float(panel.loc[panel.t.eq(k), 'alpha_t'].iloc
    [0])
508         ax.plot(Pg, off + bP_fe * Pg, lw=1.6, label='%d 年拟合
    (含年效应) ' % yy)
509 ax.set_xlabel('log10 参数量 (B)'); ax.set_ylabel('Leaderboard
    均分')
510 ax.set_title('(a) 同一年内的规模效应'); ax.legend(fontsize=8);
    despine(ax)
511 ax = axes[1]
512 d0 = dec.iloc[0]
513 ax.bar(['规模扩张', '非规模技术进步'], [d0['规模贡献分'], d0['
    非规模贡献分']],
514         color=[C1_, C2_], width=.5)
515 for i, v in enumerate([d0['规模贡献分'], d0['非规模贡献分']]):
516     ax.text(i, v + .3, '%.1f%%' % ([d0['规模占比%'], d0['非规
    模占比%']][i]), ha='center')
517 ax.set_ylabel('对前沿提升的贡献（分）')
518 ax.set_title('(b) %s 前沿提升来源分解' % d0['前沿区间']);
    despine(ax)
519 fig.tight_layout(); save_fig(fig, '图2_规模时间分解')
520
521 fig, ax = plt.subplots(figsize=(8, 5))
522 ax.plot(t_front, s_front, 'o', color=C1_, ms=4, label='历史前
    沿（年度锚点+月频前1%）')

```

```

523 tt = np.linspace(0, t_pred[-1] + 1, 300)
524 ax.plot(tt, logistic(tt, K_fit, r_fit, t0_fit), '-', color='#
    d62728', lw=2, label='logistic 饱和外推')
525 ax.plot(t_pred, s_pred, 's', color=C2_, ms=8, label='预测前沿'
    )
526 ax.fill_between(t_pred, lo, hi, color=C2_, alpha=.2, label='
    90% 置信区间 (残差 bootstrap)')
527 ax.plot(t_pred, s_slow, 'v--', color='gray', ms=7, label='情
    景：技术增速减半')
528 ax.set_xlabel('年份 (2019 起算)'); ax.set_ylabel('能力前沿 (
    Leaderboard 均分)')
529 ax.set_ylim(0, 100); ax.legend(fontsize=8); despine(ax)
530 ax.set_title('开源大语言模型能力前沿预测 (未来 12/24 个月)')
531 fig.tight_layout(); save_fig(fig, '图3_能力前沿预测')
532
533 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.6))
534 ax = axes[0]
535 td = task_df.sort_values('max')
536 ax.barh(td['task'], td['max'], color=C1_, label='任务最优得分'
    )
537 ax.barh(td['task'], td['top1_mean'], color='#aec7e8', label='
    前 1% 均值')
538 ax.axvline(100, color='gray', ls=':', lw=1)
539 ax.set_xlabel('Benchmark 得分 (满分 100)'); ax.set_title('(a)
    六维前沿与饱和程度')
540 ax.legend(fontsize=9); despine(ax)
541 ax = axes[1]
542 top = sub_df.nlargest(10, '剩余空间_%').sort_values('剩余空间_
    %')
543 ax.barh(top['子任务'], top['剩余空间_%'], color=C2_)
544 ax.set_xlabel('相对满分的剩余空间 (%)'); ax.set_title('(b) C8
    子任务剩余空间最大 10 项')
545 despine(ax); fig.tight_layout(); save_fig(fig, '图4_逐任务聚合
    ')
546
547 fig, axes = plt.subplots(1, 2, figsize=(11.5, 4.5))
548 ax = axes[0]
549 gg = g.dropna(subset=['前沿算力_max'])

```

```

550 ax.plot(gg.year, gg.前沿算力_max, 'o-', color=C1_, label='年度
    前沿训练算力')
551 ax.plot(gg.year, gg.前沿算力_中位, 's--', color=C2_, label='年
    度中位训练算力')
552 ax.set_yscale('log'); ax.set_xlabel('发布年份'); ax.set_ylabel
    ('训练算力 (FLOP)')
553 ax.set_title('(a) C4: 训练算力的年度演化'); ax.legend(fontsize
    =8); despine(ax)
554 ax = axes[1]
555 ax.bar(g.year, g.开源权重占比 * 100, color=C3_)
556 ax.set_xlabel('发布年份'); ax.set_ylabel('开源权重模型占比 (%)
    ')
557 ax.set_title('(b) C4: 开源权重比例'); despine(ax)
558 fig.tight_layout(); save_fig(fig, '图5_C4宏观趋势')
559
560 # ===== 9. 汇总 =====
561 print('\n===== 问题四求解完成 =====')
562 print('  桥接: 全样本 r=%.3f; 分解 (%s): 规模 %.1f%% / 非规模
    %.1f%%; '
563       '0LS 版: 规模 %.1f%% / 非规模 %.1f%%'
564       % (bridge_df.iloc[2]['Pearson_r'], d0['前沿区间'], d0['
    规模占比%'], d0['非规模占比%'],
565       dec_all.iloc[1]['规模占比%'], dec_all.iloc[1]['非规模
    占比%']))
566 print('  前沿预测 (+12/+24 个月): %s %.2f (90%%CI %.2f-%.2f
    ); %s %.2f (90%%CI %.2f-%.2f); '
567       '技术增速减半情景 %.2f / %.2f'
568       % (fut['对应日历时点'].iloc[0], fut.frontier_pred.iloc
    [0], fut['CI_low_5%'].iloc[0],
569       fut['CI_high_95%'].iloc[0], fut['对应日历时点'].iloc
    [1], fut.frontier_pred.iloc[1],
570       fut['CI_low_5%'].iloc[1], fut['CI_high_95%'].iloc[1],
571       fut['情景_技术增速减半'].iloc[0], fut['情景_技术增速
    减半'].iloc[1]))
572 print('\n  结构外推情景 (基准前沿 F=%.2f): ' % F_last)
573 print(scen_df.round(2).to_string(index=False))
574 print('  两条路线互为校验: 曲线外推 (logistic) 给出约 %.0f-%.0
    f, 结构外推给出约 '

```

```

575         '%.0f-%.0f; 差异来自“前沿是否已饱和”的判断，故以区间而
          非点值作为结论。'
576         % (min(fut.frontier_pred.min(), fut['CI_low_5%'].min()),
          fut['CI_high_95%'].max(),
577         scen_df['结构外推前沿'].min(), scen_df['结构外推前沿'
          ].max()))

```

Listing 4: 问题四求解代码（口径筛选、C8 逐任务聚合、Loss 桥接、规模/时间分解与能力前沿外推）