



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 东南大学

参赛队号

1. 周泽华
队员姓名 2. 单文杰
3. 苏永强

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目：算力约束下提升大语言模型能力的资源配置建模

摘要

本文针对算力约束下提升大语言模型能力的资源配置建模问题，结合综合评价、标度律建模、约束优化与技术演进预测等方法，提出了从“数据质量与配比刻画”到“算力最优配置”再到“能力前沿预测”的系统解决方案。

针对问题一：围绕数据质量评价、指标冲突处理和领域配比建模，先将 22 个质量指标统一为“越高越好”的方向。其中，广告字段经原文抽查确认为“第 1 类 = 无广告”的正向指标；8 个列表型指标经 softmax 期望压缩和极差归一化后，与其余指标共同参与熵权评分，得到样本级、语料级与领域级质量。以成对标准化得分差定义冲突，用 Kendall 协同系数考察整体一致性，并给出“多数指标方向裁决”的消解规则。随后通过岭正则线性混合回归建立 17 域配比与 13 域损失的关系，检验追加质量项的增量解释力，并利用 1M、60M、1B 检验集开展验证与跨尺度外推分析。结果表明，全量 272,505 条质量记录（另审计出 19 处字段缺失并按中位数填充）的 Kendall 协同系数为 0.069、冲突率 22.3%（低于独立基准 28.9%），说明指标间为正但不强的一致关系；抽样集 A1 与扩展集 A2/A3 的域级质量高度吻合（arxiv 0.703 对 0.701，github 0.455 对 0.455），领域质量由高到低依次为 arxiv、stackexchange、c4、commoncrawl、book、wikipedia、github，其中 book 与 wikipedia 接近；配比—损失模型训练平均决定系数为 0.629、同尺度检验 0.619，60M 与 1B 跨尺度 Pearson 相关达 0.782 与 0.651；追加混合质量指数后平均决定系数仅提升 0.000099，说明配比本身已编码质量信息，故将质量作为独立资源交由后续问题处理。

针对问题二：基于 Pythia 训练轨迹，采用稳健非线性最小二乘估计经典标度律，并通过模型规模留出检验族内迁移表现；结合半合成质量实验，比较四类质量项后采用加性质量缺口模型，将参数规模、数据规模与质量不足造成的损失分开刻画。经典拟合决定系数为 0.9999998，广义模型联合拟合决定系数为 0.9896；跨族与文献数据上的 MAPE 分别为 8.8% 与 8.0%。由模型导数得到，在质量评分同为 0.6 时，参数数量为 1B、数据量为 100B tokens，以及参数数量为 12B、数据量为 300B tokens 的两个参考点的局部质量—参数替代率分别为 2.844、76.838 B/单位质量，并推导有限质量增量的等效条件，区分局部近似与规模外推。领域效应以中心化余弦相似度描述，并在损失尺度可迁移的假设下引入配比情景修正。B9 与 B10 匹配的 128 条大规模记录用于估算一致性对照，相关结论受半合成质量证据与跨来源尺度衔接假设限制。

针对问题三：建立包含基础训练、质量处理与注意力开销的预算约束模型，在给定配比情景下采用 SLSQP 求解参数量、数据量与质量水平。以幂函数型质量成本、参考配比和 2048 tokens 上下文为基准，三档预算 10 的 19 次方、10 的 22 次方、10 的 24 次方 FLOPs 下的配置依次为：参数量 0.225B、数据量 6.9B tokens、质量评分 0.551；参数量 6.089B、数据量 229.5B tokens、质量评分 1.000；参数量 44.937B、数据量 3418.0B tokens、质量评分 1.000。预算扫描显示基线质量、质量提升与质量饱和三个阶段：首次观察到正质量投入和饱和配置的网格预算分别为 1.78×10 的 19 次方与 7.08×10 的 19 次方 FLOPs，后者对应质量份额峰值 40.7%；这些预算数值是数值识别值而非精确临界点。解

析得到注意力与基础训练成本相等的上下文长度 **30,000 tokens**。在 **10** 的 **22** 次方 **FLOPs** 下，上下文由 **2048** 增至 **131072 tokens** 时，参数量由 **6.089B** 降至 **2.705B**，预测损失上升约 **6.0%**。三类质量成本均在所考察中高预算档给出质量饱和配置，但低预算质量决策明显依赖成本形式；定量结果受评分尺度衔接和标度律外推假设约束。

针对问题四：本问是技术演进建模与前沿预测问题，需结合历史评测数据分离规模扩张与非规模技术进步的贡献并预测未来 **12** 至 **24** 个月能力前沿。首先明确时间轴（提交日期）、开源口径（开源权重且许可允许研究复现）与模型类型口径（**pretrained** 与 **chat/finetuned** 分组），得到 **2,346** 条开源筛选样本；其次完成附件 **C8** 的逐任务聚合（**1,860** 个模型目录、**37** 个子任务维度）并与 **C1** 交叉校验；再次按可比性分层建立 **Loss—Benchmark** 桥接，并用面板回归分离规模效应与年份效应；最后用 **logistic** 饱和模型与结构外推两条路线给出预测区间，并引用附件 **C4** 的算力与开源权重证据设定情景。结果表明，桥接全样本 **Pearson** 相关系数为 **-0.510**（决定系数为 **0.26**），映射误差须显式讨论；规模系数为 **13.84** 分/10 倍参数、非规模进步 **4.84** 分/年；长周期（**2019—2025**）前沿提升中规模扩张贡献 **50.5%**、非规模技术进步 **49.5%**，而在评测标准一致的近端窗口内前沿提升的 **95.4%** 来自非规模因素；未来 **12/24** 个月开源模型能力前沿预测为 **56.3**（**90%** 置信区间 **53.6** 至 **64.5**）与 **56.6**（**53.8** 至 **66.5**），算力增长放缓情景下为 **53.3** 与 **55.8**；逐任务上指令遵循已近饱和（剩余空间 **10.0%**），而研究生级问答与多轮对话仍有 **72.3%** 与 **61.3%** 的剩余空间。

综上，本文完成了数据质量评价、广义标度律建模、算力约束最优配置与能力前沿预测的全链条研究，对主要结论给出数值证据，并说明数据口径与外推的不确定性，可为算力受限条件下大模型训练的资源分配、数据治理与技术路线选择提供理论依据和决策参考。

关键词：大语言模型；标度律；数据质量；资源配置优化；能力前沿预测

一、引言

1.1 问题背景

大语言模型的训练需要共同配置参数规模 N 、训练数据量 D 、数据质量 Q 与领域配比 p 。这些资源的调整受到计算预算 C 的约束：增加模型参数或训练数据会改变计算需求，选择数据质量和领域构成也会影响模型的学习表现。标度律描述模型损失随规模变化的经验关系，为分析资源投入与模型能力之间的联系提供了基础 [1, 2]。

然而，随着人工智能对高质量语料的需求持续增长，干净数据日益稀缺、数据污染问题日趋严重，数据墙（Data Wall）问题日益突出 [3]。2026 年《Nature》发表的研究表明，一个仅有 80 亿参数的小规模模型 OpenScholar-8B 在引文准确率、降低幻觉等任务上的表现优于 GPT-4o[4]，充分说明数据质量与领域比对模型能力具有不可忽视的作用。扩大模型规模、提升数据质量与延长上下文长度均需付出算力代价，而算力始终有限，四者之间存在复杂的取舍关系。

本赛题要求利用公开数据，建立参数规模、数据量、质量和领域配比与交叉熵损失之间的定量关系，并在算力约束下寻求资源配置方案。研究重点是通过数学建模比较不同资源的作用与取舍，为算力有限时的训练决策提供依据。

1.2 问题重述

问题 1：对 22 个质量指标统一方向并建立综合评价模型，给出样本级、语料级与领域级质量评分 Q ，定义并消解质量指标间的冲突，并建立 17 域配比与交叉熵损失之间的定量关系。

问题 2：将数据质量 Q 与领域配比 p 纳入经典标度律，建立同时包含 N 、 D 、 Q 、 p 的广义标度律，分析各因素边际效用与弹性，推导质量与参数规模可相互替代的条件。

问题 3：在算力预算约束下，联合优化参数数量 N 、数据量 D 、领域配比 p 与数据质量 Q ，并分析预算跨越不同量级时资源配置是否发生结构性转移。

问题 4：结合历史评测数据建立技术演进模型，分离并量化规模扩张与非规模技术进步的贡献占比，预测未来 12 至 24 个月开源大语言模型能力的前沿边界。

二、总体分析

本文围绕算力预算下的资源配置展开分析，考察参数规模、数据规模、质量及领域配比与交叉熵损失的关系。总体研究内容如图 1 所示。

问题一从数据侧开展建模：利用熵权法计算综合质量评分，结合成对标准化得分差与 Kendall 协同系数分析指标冲突，再以岭回归建立领域配比与验证损失的关系。其输出包括质量评分 Q 、质量基线 Q_0 与配比回归系数矩阵。针对问题二，本问建立了含质量缺口的广义标度律 $L(N, D, Q) = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^\gamma$ ，在经典 Chinchilla 标度律基础上引入质量维并保证 $Q = 1$ 时精确退化，解决“质量与规模、数据如何共同决定损失、能否相互替代”的问题，其输出的标度律参数直接供问题三的优化目标使用。针对问题三，本问建立了严格按赛题公式分解的“基础训练 $6ND$ + 质量提升 $D[g(Q) - g(Q_0)]_+$ + 长文本注意力 ηNDL_{ctx} ”成本模型与预算约束下的 SLSQP 联合优化模型，解析给出临界上下文长度 $L_{\text{crit}} = 6/\eta$ ，并给出结构性转移的可操作数学定义，解决“算力有限时如何在 N 、 D 、 Q 之间最优配置并识别制度切换”的问题。针对问题四，本问建立了分层 Loss-Benchmark 桥接模型、含年份固定效应的面板回归分解模型、logistic 饱和外推与结构外推双路线预测模型，并完成附件 C8 的逐任务聚合与附件 C4 的宏观证据检验，解决“如何分离规模扩张与非规模技术进步的贡献并预测能力边界”的问题，将前三问以损失为目标的结论桥接为以评测得分为度量的能力演进。




图 1 算力约束下资源配置建模的总体架构

由此可见，四个问题构成一条完整的建模链条：问题一提供质量与配比这一“数据侧”输入，问题二将其纳入标度律得到统一损失函数，问题三在此损失函数与成本模型上完成算力约束下的最优配置，问题四则将损失层面的结论映射到真实评测能力并外推前沿。四问共享同一套“损失最小化”的优化主线，差异在于资源的维度与约束逐步扩充；同时四问之间以显式接口相互耦合——问题一输出的质量基线 Q_0 与配比修正 $M(\mathbf{p})$ 被问题三直接引用，问题二输出的标度律参数被问题三作为目标函数读取，问题四则用 **Loss—Benchmark** 桥接把前三问的损失结论折算为能力得分，形成“数据 → 损失 → 算力 → 能力”的闭环。

三、模型假设

为简化问题，本文做出以下假设：

- **假设 1：**在附件 A 覆盖的配方范围内，17 个领域配比与验证域交叉熵损失可用线性混合关系近似描述；跨参数规模使用该关系时，允许整体损失尺度发生变化。
- **假设 2：**将附件 B6、B7 的质量评分视为数值越大质量越好，并假设质量不足带来的损失可作为独立的加性项纳入经典标度律；其他来源的质量字段须先核对方向和口径。
- **假设 3：**按赛题成本公式，将总开销分为基础训练、质量提升与长文本注意力三部分，质量成本采用赛题附录 B 给定的函数，上下文长度由附件 C7 外生给定。
- **假设 4：**在所考察的时间窗口内，以 **logistic** 函数近似描述能力前沿的饱和趋势，并以面板回归近似分离参数规模与非规模技术进步对得分的贡献。

四、符号说明

主要符号列于表 1。表中“1”表示无量纲，B 表示十亿。问题二拟合时以十亿参数和十亿 **tokens** 计量规模，问题三计算成本时转换为参数个数和 **token** 数。

表 1 主要符号、含义与单位

符号	含义	单位
N	模型包含的参数数量	B 或参数个数
D	用于模型训练的数据总量	B tokens 或 tokens
L, E	分别表示验证交叉熵损失与不可约损失	1
Q	数据质量评分, 分值越高则质量越好	1
Q_0	质量基线; 问题二说明来源间的参考水平, 问题三采用参考配比加权质量	1
$\mathbf{p}$	各领域训练占比构成的向量, 各项非负且总和为 1	1
A, B	参数规模项、数据规模项的标度系数	随规模计量单位确定
α, β	参数规模项、数据规模项的幂指数	1
C, C_q	质量缺口系数, 问题三记为 C_q	1
γ	质量缺口的幂指数	1
$\varepsilon_N, \varepsilon_D, \varepsilon_Q$	损失对参数量、数据量和质量的弹性	1
$M(\mathbf{p})$	相对参考配比的损失平移修正	1
$C_{\text{train}}, C_Q, C_{\text{attn}}$	基础训练、质量提升和注意力开销	FLOPs
$C_{\text{budget}}, C_{\mathbf{b}}$	总算力预算, 问题三简记为 $C_{\mathbf{b}}$	FLOPs
$g(Q)$	单个 token 的质量处理成本	FLOPs/token
η	注意力开销系数; 参数个数作为计数代入成本公式	FLOPs/token ²
$L_{\text{ctx}}, L_{\text{crit}}$	上下文长度、注意力与训练开销相等时的长度	tokens
$\lambda(L_{\text{ctx}})$	注意力开销与基础训练开销的比值	1
$\tau(Q)$	质量处理成本折算的等效附加参数规模	参数个数
$\Theta(C_{\mathbf{b}})$	质量提升完成度	1
$F(t), K$	能力前沿及 logistic 饱和上界	分
t, t_0	以 2019 年为原点的时间、 logistic 拐点时间	年
r	logistic 增长率	年 ⁻¹
b_P	参数量每扩大十倍对应的回归得分变化	分
b_t	面板回归的年度得分变化系数	分/年
α_t	面板回归的年份固定效应	分
$\bar{B}$	Leaderboard 六维平均得分	分
$Q_i, Q_d, \bar{Q}(\mathbf{p})$	依次表示样本评分、领域平均评分和按训练配比加权的质量指数	1
$\mathbf{P}, \mathbf{L}$	分别由各组训练配比及其对应的验证损失构成的矩阵	1
$\mathbf{A}, \mathbf{b}$	配比回归中的系数矩阵和截距向量	1
λ	配比回归的岭惩罚系数, 设为 10^{-3}	1

表 1 主要符号、含义与单位 (续)

符号	含义	单位
τ	判断两个指标的标准化得分是否冲突的阈值, 设为 1.5	1
w_j, e_j	指标 j 对应的熵权系数与信息熵值	1
W	Kendall 协同系数, 用于衡量指标排序的一致程度	1
ρ_c, ρ_0	指标评价的冲突比例及指标独立条件下的参考冲突比例	1
R^2	决定系数	1
RMSE、MAE	均方根误差、平均绝对误差	与响应变量一致
MAPE	平均绝对百分比误差	%

五、模型的建立与求解

本节的数据整理、图表绘制与数值核对使用 **Codex** 辅助, 所用模型为 **OpenAI** 的 **GPT-5.4 (2026-03-05)** 及 **GPT-6** 系列 (2026-09-03 首发) [5, 6]。文段整理与图表辅助制作使用腾讯 **WorkBuddy** 接入的 **DeepSeek-V4-Flash** (深度求索, 2026-04-24 首次公开发布), 格式排版使用 **GLM-5.1** (智谱, 2026-04-07) 辅助检查 [7, 8]。参赛队对模型选取、假设设定及结果解释负责。

5.1 问题一：数据质量评价与领域配比建模

5.1.1 具体分析

问题一需要回答三个相互关联的问题：如何将 22 个质量指标合成为可比较的评分, 如何识别并处理指标评价之间的冲突, 以及训练领域配比如何影响验证损失。本文据此建立质量综合评价、冲突分析和配比回归三个模块, 分别采用熵权法、成对标准化得分差与 **Kendall** 协同系数、岭正则线性混合回归。质量评价给出样本、语料和领域三个层次的评分, 配比回归则描述 17 个训练领域配比与 13 个验证领域交叉熵损失之间的关系 [9]。

具体求解分为两条流程。质量评价流程从 **A1-A3** 的质量信号出发, 经过缺失处理、指标标量化、方向统一和归一化, 计算综合评分并分析指标冲突。配比建模流程将训练配方与验证损失按索引匹配, 用岭回归估计配比与损失的关系, 再利用 **1M**、**60M**、**1B** 检验集及 **10B**、**70B** 外推表考察模型表现, 求得有界推荐配比。两条流程通过领域映射表关联, 整体步骤见图 2。

5.1.2 模型准备

1. 数据来源与预处理

问题一使用两类数据。配方表 **A4** 包含 17 个 **The Pile** 子领域的训练配比, 各分量非负且总和为 1[10]; 损失表 **A5** 包含 13 个验证领域的交叉熵损失, 两表通过 **index** 列对应。**nih_exporter**、**enron_emails**、**europarl** 和 **philpapers** 四个训练领域没有对应的验证损失列, 因此保留其配比分量, 并在系数解释中将其标为“间接影响域”。




图 2 问题一的质量评价与领域配比建模流程

A1-A3 提供 22 个质量指标。为使各指标能够共同参与评分，需要统一其方向。设第 j 个指标的原始值为 x_j ，正向指标作极差归一化，负向指标反向缩放；对于过长或过短均不合适的长度型指标，使用其与稳健中心的接近程度表示质量：

$$x'_j = \begin{cases} \frac{x_j - \min x_j}{\max x_j - \min x_j}, & \text{正向指标} \\ \frac{\max x_j - x_j}{\max x_j - \min x_j}, & \text{负向指标} \\ \exp\left(-\frac{|\ln(1 + x_j) - m_j|}{2.5 \text{MAD}_j}\right), & \text{长度型指标} \end{cases} \quad (1)$$

其中， m_j 和 MAD_j 分别为对数尺度上的中位数和中位绝对偏差。处理后的 x'_j 位于 $[0, 1]$ ，数值越大表示质量越高。表 2 列出了各指标的类型、方向依据及熵权。8 个列表型指标按有序类别 **logits** 处理，先由 **softmax** 概率计算归一化期望级别，将其压缩为标量，再参与归一化。

表 2 质量指标的含义、评价方向及熵权

指标字段	类型	指标含义与判向依据	方向	熵权 w_j
fineweb_edu	列表 (1)	文本用于教育的价值	正向	0.0437
fluency_en	列表 (2)	英语流畅度（第 1 类 = 流畅，已核验）	正向	0.0682
modernbert_cleanliness	列表 (6)	文本内容的洁净程度	正向	0.1434
modernbert_readability	列表 (6)	文本的易读程度	正向	0.0567

表 2 质量指标的含义、评价方向及熵权（续）

指标字段	类型	指标含义与判向依据	方向	熵权 w_j
modernbert_reasoning	列表 (6)	内容体现的推理程度	正向	0.1517
modernbert_professionalism	列表 (6)	内容的专业程度	正向	0.0396
dsir_books	标量	相对于书籍领域的重要性权重	正向	0.0081
dsir_wiki	标量	相对于维基领域的重要性权重	正向	0.0081
dsir_math	标量	相对于数学领域的重要性权重	正向	0.0086
qurater	列表 (4)	教育质量评级（4 项取均值）	正向	0.0492
ad_en	列表 (2)	广告含量（第 1 类 = “无广告”，正向；依据：原文抽查）	正向	0.0072
rps_doc_word_count	标量	文档包含的词总数	长度型	0.0516
rps_doc_num_sentences	标量	文档包含的句子总数	长度型	0.0523
rps_doc_unigram_entropy	标量	用一元词熵衡量词汇多样性	正向	0.0347
rps_doc_frac_unique_words	标量	不同词项所占比例	正向	0.0538
rps_doc_frac_no_alph_words	标量	非字母字符所占比例	负向	0.0287
rps_doc_frac_chars_top_2gram	标量	字符 2-gram 的重复程度	负向	0.0130
rps_doc_frac_chars_top_3gram	标量	字符 3-gram 的重复程度	负向	0.0119
rps_lines_uppercase_letter_fraction	标量	大写字母行所占比例	负向	0.0316
rps_lines_ending_with_terminal_punctuation_mark	标量	以终止标点结束的行所占比例	正向	0.0880
rps_lines_numerical_chars_fraction	标量	含有数字的行所占比例	负向	0.0125
rps_doc_mean_word_length	标量	词项长度的平均值	长度型	0.0373

在统一指标方向后，以加权和计算样本质量 Q_i ，再对同一领域内的样本取均值，得到领域质量 Q_d ：

$$Q_i = \sum_{j=1}^{22} w_j x'_{ij}, \quad Q_d = \frac{1}{n_d} \sum_{i \in \mathcal{D}_d} Q_i, \quad \sum_j w_j = 1 \quad (2)$$

权重 w_j 由熵权法确定。表 2 中，**modernbert_reasoning** 和 **modernbert_cleanliness** 的权重分别为 0.152 和 0.143，在本指标体系中提供的信息量最多。熵权对指标分布形态较敏感，极端左偏的指标可能获得较大权重，因此还需考察赋权方案变化对结果的影响，相关检验见第 6.1 节。

读取质量信号时逐字段检查缺失情况，结果见表 3。缺失值按对应指标的中位数填充，以避免将缺失直接解释为高质量或低质量。

表 3 A1-A3 中 272,505 条记录的质量字段缺失统计

缺失字段	涉及记录数	缺失情况
modernbert_reasoning	13	该记录中此字段的 6 个分量均为 NaN
modernbert_professionalism	6	该记录中此字段的 6 个分量均为 NaN
其余 20 个指标	0	未发现缺失值

2. 方法选择及其依据

质量聚合比较熵权法、等权平均和 PCA 第一主成分三种方案，结果见表 4。冲突分析采用成对标准化得分差与 Kendall 协同系数，分别考察单个样本的评价分歧和整体排序的一致程度。配比建模则比较普通最小二乘、岭回归与随机森林。

表 4 不同赋权方式下的样本得分及领域排序比较

赋权方法	样本平均得分	与熵权得分的相关系数	领域排序相关性 Spearman 系数，参照熵权法
熵权法	0.495	1.000	1.000
等权平均	0.639	0.854	0.679
PCA 第一主成分	0.520	0.881	0.679

表 4 显示，等权方案与熵权方案的样本级得分相关系数为 0.854，领域排序的 Spearman 相关系数为 0.679。两种方案的主体格局相近，但部分领域名次会随赋权方式改变，因此将赋权方案纳入灵敏度分析。本文采用熵权法，利用指标自身的信息量确定权重；PCA 虽可降维并减少相关性，但主成分含义较难解释，受篇幅限制不作备选。

17 个领域配比之和为 1，配比变量之间存在闭约束。岭回归通过 L_2 正则化稳定系数估计，兼顾模型解释与外推分析，因此用于配比建模。冲突分析同时报告样本级分歧与 Kendall 协同系数：前者对应同一文本受到不同评价的情形，后者描述各指标对样本排序的整体一致性。

5.1.3 模型建立

1. 综合质量评分

将 m 条质量样本的 22 个指标统一方向并归一化，记所得矩阵为 $\mathbf{X} = (x'_{ij})$ 。由各指标在样本间的分布计算信息熵 e_j ，再确定熵权 w_j ：

$$e_j = -\frac{1}{\ln m} \sum_{i=1}^m f_{ij} \ln f_{ij}, \quad f_{ij} = \frac{x'_{ij} + \varepsilon}{\sum_i (x'_{ij} + \varepsilon)}, \quad w_j = \frac{1 - e_j}{\sum_{j=1}^{22} (1 - e_j)} \quad (3)$$

为与附件 B 的损失数据耦合，本问同时给出“结果导向”的领域质量代理指标：以各验证域在平均配方下的观测损失表征领域内在难度并映射为质量：

$$Q_d^{(\text{loss})} = 1 - \frac{\bar{L}_d - \min_d \bar{L}_d}{\max_d \bar{L}_d - \min_d \bar{L}_d} \quad (4)$$

其中 $\bar{L}_d$ 为领域 d 的平均交叉熵损失。该代理指标仅在 **13** 个可测损失域上有定义，与 **A1-A3** 的 **7** 个质量域并非同一分类体系，二者的关联由 **A16** 映射表建立、并在模型求解中作一致性检验。

2. 质量冲突的定义与处理

当两个质量指标对同一文本给出显著不一致的评价时即产生冲突。以方向统一后的标准化得分为基础，定义第 i 样本在指标 j 与 k 上的冲突指示：

$$\delta_i(j, k) = |z_{ij} - z_{ik}|, \quad z_{ij} = \frac{x'_{ij} - \mu_j}{\sigma_j}, \quad \mathbf{1}\{\delta_i(j, k) > \tau\} \quad (5)$$

取阈值 $\tau = 1.5$ ；全样本冲突率为

$$\rho_c = \frac{1}{m \binom{22}{2}} \sum_{i=1}^m \sum_{j < k} \mathbf{1}\{\delta_i(j, k) > \tau\} \quad (6)$$

为给出参照系，本文同时计算“指标独立”基准 $\rho_0 = 2\Phi(-\tau/\sqrt{2})$ ：若 $\rho_c/\rho_0 < 1$ ，说明指标间存在正相关、并非互相矛盾。指标间整体一致性用 **Kendall** 协同系数检验（**22** 个指标为评价者、 m 条文本为评价对象）：

$$W = \frac{12 \sum_i (R_i - \bar{R})^2}{22^2 (m^3 - m)}, \quad R_i = \sum_{j=1}^{22} r_{ij}, \quad \chi^2 = 22(m-1)W \quad (7)$$

其中 r_{ij} 为第 i 样本在第 j 指标上的秩。消解规则为：若某样本被判为冲突，则以其上“多数指标”的方向（即加权得分 Q_i 相对该样本所在域中位数的偏离方向）作为该样本的最终质量裁决，并在报告中保留冲突标记以供下游剔除或降权。

3. 领域配比的线性混合回归

记训练配方矩阵为 $\mathbf{P} \in [0, 1]^{n \times 17}$ ，每行对应一组配方且分量之和为 **1**；损失矩阵为 $\mathbf{L} \in \mathbb{R}^{n \times 13}$ 。对每个验证领域建立线性混合模型：

$$L_d(\mathbf{p}) = \sum_{k=1}^{17} a_{dk} p_k + b_d, \quad d = 1, \dots, 13 \quad (8)$$

其矩阵形式为

$$\hat{\mathbf{L}} = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top \quad (9)$$

由于 $\mathbf{P}$ 各行和为 **1**，回归存在闭合不可辨识性，采用岭正则估计系数矩阵 $\mathbf{A} \in \mathbb{R}^{17 \times 13}$ 与截距 $\mathbf{b}$ ：

$$\min_{\mathbf{A}, \mathbf{b}} \|\mathbf{L} - \mathbf{P}\mathbf{A} - \mathbf{1}\mathbf{b}^\top\|_F^2 + \lambda \|\mathbf{A}\|_F^2 \quad (10)$$

相应的系数估计为

$$\begin{bmatrix} \mathbf{A} \\ \mathbf{b}^\top \end{bmatrix} = \left(\tilde{\mathbf{P}}^\top \tilde{\mathbf{P}} + \lambda \mathbf{D} \right)^{-1} \tilde{\mathbf{P}}^\top \mathbf{L} \quad (11)$$

其中 $\tilde{\mathbf{P}} = [\mathbf{P}, \mathbf{1}]$ ， $\mathbf{D} = \text{diag}(1, \dots, 1, 0)$ （不惩罚截距）， $\lambda = 10^{-3}$ 。

4. 混合质量指数及其增量检验

为考察质量评分的引入方式，构造混合质量指数 $\bar{Q}(\mathbf{p}) = \sum_k p_k Q_k$ 。其中， Q_k 依据 **A16** 建立映射：**direct** 和 **near_direct** 领域取 **A1-A3** 的相应领域质量，**inferred** 领域取全局均值。将该指数加入配比回归，进行增量检验：

$$\hat{\mathbf{L}} = \mathbf{P}\mathbf{A} + \mathbf{1}\mathbf{b}^\top + \mathbf{1}c^\top \bar{Q}(\mathbf{p}) \quad (12)$$

若质量项带来的 R^2 增量可忽略，则说明线性配比已吸收质量信息，此时不宜重复引入以免共线；质量评分转而作为独立资源交由问题二、三使用。

5. 配比优化与有界推荐

以系数矩阵 $\mathbf{A}$ 为基础，将缺少对应验证损失的四个领域固定在参考配比，优化其余 13 个领域，使验证损失的加权均值最小：

$$\min_{\mathbf{p} \in \Delta_{17}} \sum_{d \in \mathcal{M}} w_d \left(\sum_k a_{dk} p_k + b_d \right), \quad \Delta_{17} = \{\mathbf{p} : p_k \geq 0, \sum_k p_k = 1\} \quad (13)$$

进一步将各领域配比限制在参考值的 2.5 倍以内，得到有界推荐方案。

5.1.4 模型求解

模型求解使用 **A1–A3** 的质量信号及 **A4–A15** 的配方与损失数据。质量记录共 272,505 条，其中 **A1** 抽样集包含 51,230 条，**A2** 与 **A3** 扩展集合计 221,275 条。

1. 质量评分与冲突分析

质量域的领域级评分如图 3 所示，**A1** 抽样集与扩展集的对照结果如表 5 所示。




图 3 A1–A3 全量质量信号的领域级评分 (均值 ± 标准差)

表 5 各领域在 A1 抽样集与 A2/A3 扩展集中的质量评分

质量信号领域	A1 评分 Q	扩展集评分 Q	评分差值	训练配方对应领域
arxiv	0.7031	0.7011	+0.0021	arxiv
stackexchange	0.6549	—	—	stackexchange
c4	0.6368	—	—	(配方侧无同名列)
commoncrawl	0.6153	—	—	pile_cc
book	0.5524	—	—	gutenberg_pg_19
wikipedia	0.5509	—	—	wikipedia_en
github	0.4553	0.4547	+0.0006	github

由表 5 可知，在同时具有抽样与扩展质量信号的两个域上 (**arxiv**、**github**)，两种口径的域级质量差异不超过 0.002 (**arxiv** +0.0021、**github** +0.0006)，说明抽样集对扩展集具有代表性、评分口径可跨集合迁移。

全体记录的领域质量排序为 **arxiv** (0.703) > **stackexchange** (0.655) > **c4** (0.637) > **commoncrawl** (0.615) > **book** (0.552) ≈ **wikipedia** (0.551) > **github** (0.455)。需要指出，该排序是 22 个分类器信号的合成结果，其中若干信号（如 **rps_doc_frac_unique_words**、**rps_**

doc_unigram_entropy) 与文档长度相关, 因此 “c4/commoncrawl 高于 book/wikipedia” 反映的是信号体系的口径, 而非对语料价值的终极判断——这一点在使用该评分时须注意。

冲突与一致性检验结果如表 6 所示, 冲突最集中的指标对与熵权分布见图 4。

表 6 各数据集的指标冲突比例与排序一致性

统计范围	记录数	Kendall W	冲突比例 ρ_c	独立基准 ρ_0	ρ_c/ρ_0
A1抽样集	51,230	0.0783	0.2252	0.2888	0.780
A2+A3 扩展集	221,275	0.0628	0.2208	0.2888	0.764
全量	272,505	0.0687	0.2235	0.2888	0.774




图 4 冲突最集中的指标对（左）与熵权分布（右）

由表 6 可知：(1) 三套数据的冲突率几乎一致 (0.221 ~ 0.225)，说明冲突结构在抽样集与扩展集上同样成立，A2/A3 的结论可外推至 A1 所代表的总体；

(2) Kendall 协同系数为 0.069 (χ^2 检验 $p < 0.001$, 样本量极大故显著性很高)，属于“正相关但一致性较弱”的水平，与冲突率 22.3% 一致，说明“各质量指标完全一致、不存在冲突”的判断并不成立；(3) 但冲突率低于指标完全独立时的基准 28.9% (比值 0.774)，说明指标间确为正相关，冲突主要发生在语义上本就不同的指标之间。

冲突成因可归纳为三类：一是度量对象不同 (如 **rps_doc_unigram_entropy** 与 **rps_doc_frac_unique_words** 同测“多样性”但量纲不同)，二是内容类型差异 (如 **modernbert_professionalism** 对学术文本与论坛文本的评价尺度不同)，三是分布形态差异 (如 **ad_en** 为二分类概率、在长文档上两极化)。

据此本文按“多数指标方向裁决 + 冲突标记保留”的规则消解：冲突样本仍参与领域均值，但以 Q_i 相对域中位数的偏离方向标注其可信度，并在问题二、三中不单独使用冲突样本。

2. 领域配比与损失的拟合及验证

图 5 展示训练配方的构成。模型的拟合与检验表现见图 6，同尺度预测值与观测值的比较见图 8，不同训练领域的回归系数见图 7。

由图 6 可知，训练集上 13 个损失域的 R^2 位于 0.42 ~ 0.77 之间、平均 0.629；同尺度 1M 检验集平均 $R^2 = 0.619$ ，与训练接近，说明模型未明显过拟合。




图 5 训练配方结构（左：前 8 组配方堆叠；右：全部配方平均配比）




图 6 线性混合回归的拟合与泛化表现

由于不同参数规模下损失水平本身不同（60M 与 1M 的损失比约 0.68），跨尺度直接比较 R^2 无意义，故改用尺度无关的 Pearson 相关：60M 与 1B 检验集上的平均相关分别为 0.782 与 0.651，表明同一套配比—损失系数可在不同参数规模间复用。

由图 7 可知，各训练域对验证损失的相对影响差异明显，dm_mathematics、arxiv 等域降低损失，而 pile_cc、ubuntu_irc 等域抬高损失，印证了领域配比是影响模型性能的关键变量。

为验证质量信息的引入方式，本文比较了“仅配比”与“配比 + 混合质量指数 $\bar{Q}$ ”两种设定：追加质量项后 13 个损失域的平均 R^2 增量仅为 9.9×10^{-5} ，说明线性配比系数已经吸收了质量信息。因此本文不把质量评分再次作为配比模型的解释变量，而是将其作为独立资源交由问题二、三使用。

两套质量口径（A1-A3 的熵权质量 Q 与损失难度代理 $Q^{(\text{loss})}$ ）在 6 个可映射域上的排序一致性如图 9 所示。

由图 9(a) 可知，13 个损失域的内在难度差异显著，dm_mathematics 最易（代理质量 1.000）、ubuntu_irc 最难（代理质量 0.000）；图 9(b) 显示，A16 的 direct/near_direct 映射中两套口径的 Spearman 排序相关为 0.60：arxiv、stackexchange、github 三个域在两种口径下同向（文本质量高、损失也相对低），但 wikipedia、book、pile_cc 存在明显分歧——文本质量较高而该域损失并不低（学术与百科长文属“高质量但难拟合”）。因此质量评分必须按用途区分：面向数据治理使用 A1-A3 的文本质量，面向性能预测使用损失难度代理。




图 7 领域配比对交叉熵损失的相对影响热力图




图 8 同尺度检验集（1M）预测损失与实测损失对比

3. 配比推荐与跨尺度分析

无约束优化倾向于把配比集中于单一低损失域（预测加权平均损失 4.177），不具备可落地性；故采用 **2.5** 倍上限的有界推荐作为最终方案，推荐配比与参考配比的对比见表 7，该方案使预测加权平均损失由 5.336 降至 5.136（下降 0.199）。




图 9 左：13 个验证域的损失难度代理；右：A1-A3 质量与损失难度代理的排序一致性

表 7 配比上限约束下的推荐方案与参考方案

训练领域	参考占比	推荐占比	占比变化量
pubmed_central	0.1137	0.2843	+0.1706
stackexchange	0.0994	0.2486	+0.1491
pubmed_abstracts	0.0662	0.1654	+0.0993
gutenberg_pg_19	0.0469	0.1173	+0.0704
dm_mathematics	0.0255	0.0637	+0.0382
uspto_backgrounds	0.0755	0.0000	-0.0755
freelaw	0.0968	0.0000	-0.0968
github	0.1107	0.0000	-0.1107
arxiv	0.1130	0.0000	-0.1130
pile_cc	0.1195	0.0000	-0.1195

由表 7 可知,推荐方案应显著增加 **pubmed_central**、**stackexchange**、**pubmed_abstracts** 等学术领域的配比,同时压缩 **pile_cc**、**arxiv**、**github**、**freelaw** 等领域的占比。需要说明的是,这一结论是针对“13 个验证域加权平均损失”这一目标的优化结果,与“提升单个域自身表现”并不等价(例如 **arxiv** 的配比下降并不意味着 **arxiv** 质量低,而是因为其对加权平均损失的边际贡献为负)。

外推稳健性方面, **10B** 与 **70B** 外推表的损失尺度因子 (**est/train**) 在各损失域上高度一致 (**10B** 均值 0.338、标准差 0.038; **70B** 均值 0.266、标准差 0.036), 且同配方下 **60M** 与 **1M** 的跨尺度损失比稳定 (均值 0.51 ~ 0.82), 说明同一套配比—损失系数可在不同参数规模间复用、具备跨尺度外推能力, 如图 10 所示。




图 10 外推稳健性验证 (左: 10B 外推尺度因子; 右: 同配方 60M/1M 跨尺度损失比)

本节得到领域质量评分、配比与损失的定量关系及有界推荐配比，并通过质量口径对照、同尺度检验和跨尺度分析考察结果，为后续资源配置研究提供数据侧输入。

5.2 问题二：跨维度数据融合与广义标度律

5.2.1 具体分析

相同的参数规模与训练数据量未必对应相同的验证损失，语料质量和领域构成也是解释差异的关键。问题二据此考察两个层面：质量与配比怎样进入损失模型，以及改善数据能在多大程度上替代参数扩张。附件 **A** 提供领域配比信息，附件 **B** 提供规模与质量实验；两者并非联合观测，因而跨来源衔接需要明确评分尺度和效应迁移条件。

本文先区分各数据集承担的估计与检验任务，并核对质量字段的方向。在此基础上，以 **Pythia** 训练轨迹确定规模关系，通过小模型拟合与大模型留出检验族内迁移，再比较四种质量项构造广义标度律。局部弹性和等损失关系用于解释质量投入，问题一的配比系数用于分析领域效应；各项结论的适用范围由多来源检验限定。图 11 给出了这些环节之间的联系。




图 11 规模、质量与领域效应的分析框架

5.2.2 模型准备

1. 数据组织与变量口径

数据按其能够支持的结论分别使用。**B1** 记录了 8 个 **Pythia** 模型各 147 个训练检查点，共 1,176 条记录，是规模项的主要估计依据 [11]；**B6** 的半合成实验用于估计质量项，**B7** 只保留未在 **B6** 出现的记录作扩展检验。轨迹关系由 **B2**、**B3** 检查，跨族与文献数据上的表现由 **B4**、**B5** 评价。**B8** 用于诊断质量口径，**B9** 的模型元数据与 **B10** 的估算损失则共同用于大规模情景对照。

本节以参数量 N 、训练数据量 D 和质量 Q 解释验证集交叉熵损失 L 。计算时， N 的单位为十亿个参数， D 的单位为十亿 **tokens**。问题三使用参数个数和 **token** 数计算算力，因此需要将本节的 N 、 D 数值分别乘以 10^9 。不可约损失 E 作为常数项参与原函数拟合，避免在双对数线性化中将其忽略。

2. 质量字段方向检验

使用质量字段之前，先检查其变化是否与损失变化方向一致。对附件 **B** 中每个固定 (N, D) 的实验组，计算 Q_{score} 与损失的 **Pearson** 相关系数，再对各组取算术平均。若平均方向为负，则与质量越高、损失越低的约定相符；正向关系则提示口径差异。表 8 汇总了检验结果，这里的平均相关只用于描述方向，不作为显著性判据。


表 8 质量评分方向与样本使用方式

数据分组	平均组内 相关系数	记录数 / 实验组数	评分解释与使用方式
B6	-0.925	360 / 45	沿用原评分； $Q = 1$ 为最优参考
B7	-0.918	450 / 45	与 B6 同向，仅新增记录用于检验
B8 校准段	+0.995	984 / 90	方向相反，翻转评分后作诊断
B8 外推段	+0.968	720 / 60	方向相反，不纳入主拟合

注：实验组固定 N, D 。**B7** 包含 **B6** 的全部 360 条记录，新增 90 条；均值只描述方向，不表示显著性。

B6、**B7** 的平均组内相关分别为 -0.925、-0.918，因此在这两套数据中采用 $Q = Q_{\text{score}}$ 。但两者不能当作相互独立的证据：逐行匹配显示，**B7** 已包含 **B6** 的全部 360 条记录，后续检验仅使用其余 90 个新增点。**B8** 两个子集均呈相反方向，且部分损失低于本文估计的基线下限。基于这一差异，主拟合不使用 **B8**，仅以 $1 - Q_{\text{score}}$ 作诊断性变换，考察翻转方向后还剩多少预测偏差。

图 12 进一步保留了各实验组的信息：圆点表示固定 (N, D) 下的组内相关，菱形表示组间平均。**B6**/**B7** 与 **B8** 的点群分居零点两侧，说明方向差异广泛存在于各组中。**B6** 与 **B7** 的点群接近还受到样本重叠的影响，不能据此增加独立验证的证据量。



圆点：一个 (N, D) 组；菱形：组间均值。
均为半合成数据；B7 含 B6，不构成独立证据。

图 12 质量字段与损失的组内相关分布

质量方向确定后，还需区分评分尺度。问题一综合评分和附件 B 的 Q_{score} 虽然都随质量提高而增大，但构造方法与数据来源不同，相同分值并不必然代表相同质量。本节质量参数的估计及数值解释均以附件 B 的尺度为准。

5.2.3 模型建立

1. 经典标度律

先将质量固定在参考水平，采用 **Chinchilla** 标度律 [2] 描述参数与数据规模共同决定的验证损失 L ：

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} \quad (14)$$

该式将损失分成一个极限项和两个随规模衰减的项。 E 对应 $N, D \rightarrow \infty$ 时的损失极限；参数规模项由系数 A 与指数 α 决定，数据规模项由 B 与 β 决定。由此可在同一参考质量下分别考察两类规模扩张的收益。

2. 质量项的选择与损失修正

质量可以通过改变有效规模或增加损失项进入模型。为比较这些表达，四类候选形式采用同一组联合样本，并以 **B6** 拟合表现、**B7** 新增点的预测相关及残差信息评分辅助判断，结果列于表 9。经典模型与各候选模型均使用带界约束的非线性最小二乘法，保留常数项和幂函数结构；估计时采用 **soft- L_1** 损失，以减弱大残差的影响。

表 9 不同质量作用形式的拟合与扩展检验指标

比较指标	加性质量缺口 $C(1 - Q)^\gamma$	质量同时乘 N 与 D	加性质量亏损 $CQ^{-\gamma}$	质量作为 有效数据乘子
联合样本 R^2	0.9896	0.9882	0.9848	0.9745
B6 样本 R^2	0.9556	0.9495	0.9349	0.8905
B7 新增点 r	0.991	0.991	0.991	0.983
待估参数个数	7	7	7	6
残差信息评分 I_{RSS}	-10236	-10042	-9660	-8866

注：相关系数保留三位小数；加粗的最优指标按未舍入值确定。 I_{RSS} 越小越优，仅用于同样本比较。

四类形式在 **B7** 新增点上的相关系数均达到 0.983 以上，仅凭相关性难以充分区分。表 9 显示，加性质量缺口形式同时取得最高的联合拟合与 **B6** 拟合 R^2 ，据此选定该形式，并在后续检验中用 **RMSE**、**MAPE** 评价绝对偏差与相对偏差。

残差信息评分按 $I_{\text{RSS}} = n \ln(\text{RSS}/n) + 2k$ 计算， n 、 k 分别为样本数和参数数。由于参数来自 **soft- L_1** 稳健估计，该评分只承担同一样本下的辅助比较作用，不解释为严格的高斯极大似然 **AIC**。**B7** 新增点同时参与形式比较和扩展检验，故相应表现属于开发阶段验证，不能再视为完全独立的模型评价。

将选定的质量缺口项加入规模基线后，损失关系写为：

$$L(N, D, Q) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta} + C(1 - Q)^\gamma, \quad C > 0, \gamma > 0 \quad (15)$$

为使质量项具有统一参照，规定 $Q = 1$ 时其值为零。此时广义模型具有经典标度律的函数形式，但联合估计不要求参数等于经典拟合值。**Pythia** 缺少质量测量，因此其 $Q = 1$ 仅是归一化设定。固定质量并令两类规模趋于无穷，有

$$\lim_{N, D \rightarrow \infty} L(N, D, Q) = E + C(1 - Q)^\gamma \geq E \quad (16)$$

这一极限揭示了加性模型中的质量作用：当 $Q < 1$ 保持不变时，增加 N 、 D 只能削减规模项，无法消除相对于 E 的质量缺口。上述结论来自模型结构，向实际训练情景推广仍受拟合数据范围约束。

3. 边际效用与弹性

为刻画各因素微小变化对损失的影响，对广义模型求偏导，并在参考点 (N_0, D_0, Q_0) 处评价：

$$\frac{\partial L}{\partial N} = -\alpha A N^{-\alpha-1}, \quad \frac{\partial L}{\partial D} = -\beta B D^{-\beta-1}, \quad \frac{\partial L}{\partial Q} = -\gamma C(1 - Q)^{\gamma-1} \quad (17)$$

各偏导的单位不同。令参考点的预测损失为 L_0 ，按变量与损失的比例变化定义弹性：

$$\varepsilon_N = \frac{\partial L}{\partial N} \frac{N_0}{L_0}, \quad \varepsilon_D = \frac{\partial L}{\partial D} \frac{D_0}{L_0}, \quad \varepsilon_Q = \frac{\partial L}{\partial Q} \frac{Q_0}{L_0} \quad (18)$$

4. 质量提升与参数扩张的等效条件

比较质量投入与参数投入时，固定 D 和领域配比，让两种方案从同一参考点出发。若微小质量提升与参数扩张带来相同的一阶损失降幅，则二者的正向等效增量比 R_{NQ} 满足

$$\left| \frac{\partial L}{\partial Q} \right| dQ = \left| \frac{\partial L}{\partial N} \right| dN_{eq}, \quad (19)$$

$$R_{NQ} = \frac{dN_{eq}}{dQ} = \frac{\gamma C (1-Q)^{\gamma-1}}{\alpha A N^{-\alpha-1}} = \frac{\gamma C}{\alpha A} (1-Q)^{\gamma-1} N^{\alpha+1}.$$

这里比较的是两项改善方案的等效增量。若沿一条等损失曲线移动，则有 $dN/dQ = -R_{NQ}$ ，质量提高对应所需参数减少。固定 Q 后， R_{NQ} 按 $N^{\alpha+1}$ 增长，原因在于参数扩张的边际收益不断减弱。损失效果相等并不意味着算力成本相等，后者还取决于质量处理与参数训练的成本。

对于有限的质量增量 ΔQ ，一阶近似未必足够。先记质量改善产生的损失降幅为 δ_Q ，再令参数扩张产生同样的降幅，可直接解得

$$\delta_Q = C[(1-Q)^\gamma - (1-Q-\Delta Q)^\gamma],$$

$$\Delta N_{eq} = N \left[\left(1 - \frac{\delta_Q N^\alpha}{A} \right)^{-1/\alpha} - 1 \right]. \quad (20)$$

质量增量须满足 $0 < \Delta Q \leq 1-Q$ 。当 $\delta_Q < AN^{-\alpha}$ 时，等效参数增量存在有限解；达到等号时需要无穷大的参数量，超过该阈值则无法仅靠扩大参数获得同等降幅。这是因为当前参数项 $AN^{-\alpha}$ 给出了参数扩张能够消除的全部损失。随着 $\Delta Q \rightarrow 0$ ，有限增量关系趋于 $\Delta N_{eq} \approx R_{NQ} \Delta Q$ 。若求得的规模超出拟合区间，应按模型外推解释。

5. 领域效应的相似性

领域之间的差异由其对各验证任务的作用描述。问题一线性混合模型给出训练域 i, j 在 13 个验证域上的效应向量 $\mathbf{a}_i, \mathbf{a}_j$ 。将它们中心化后，采用余弦相似度衡量相对效应模式：

$$s_{ij} = \frac{\langle \mathbf{a}_i - \bar{\mathbf{a}}, \mathbf{a}_j - \bar{\mathbf{a}} \rangle}{\|\mathbf{a}_i - \bar{\mathbf{a}}\| \|\mathbf{a}_j - \bar{\mathbf{a}}\|} \quad (21)$$

中心向量 $\bar{\mathbf{a}}$ 为 17 个训练域效应向量的平均值。 $s_{ij} \rightarrow 1$ 表示两域在验证任务上的相对作用趋同， $s_{ij} \rightarrow -1$ 则表示作用模式相反，提示任务收益之间的权衡。该度量不保留效应幅值；同时，线性配比模型未包含领域交互项。因此，相似度本身不能确定等量替代是否有效，也不能证明联合使用具有额外收益。

5.2.4 模型求解

1. 经典标度律拟合与留出验证

以 B1 的全部 1,176 条记录估计规模关系。图 13 将损失随参数量和数据量的变化置于左侧，右侧按模型规模汇总残差。相应拟合函数为

$$L(N, D) = 1.6898 + \frac{0.3540}{N^{0.3400}} + \frac{1.2403}{D^{0.2799}} \quad (22)$$

全量拟合得到 $R^2 = 0.9999998$ 、 $\mathbf{RMSE} = 1.5 \times 10^{-4}$ 、 $\mathbf{MAPE} = 0.004\%$ 。为检查族内迁移，再仅用最小的 4 个模型估计参数，将其余 4 个较大模型留出；预测 R^2 为 0.9999997， $\mathbf{MAPE}$ 为 0.005%。这一结果支持在该模型族内沿用所估规模关系。




图 13 Pythia 规模-损失地图与分模型残差分布

拟合残差标准差为 1.5×10^{-4} ，损失标准差则为 0.342，两者相差较大，说明所选函数能够高度贴合附件 B1 的规模关系。这样的族内表现尚不足以说明跨来源泛化，仍需分别考察 B4、B5 的外部数据和 B2 的半合成轨迹。

B3 提供了另一项族内检查。对 8 条插值轨迹分别固定 N ，以扣除极限项和参数项后的 $L - (E + AN^{-\alpha})$ 对 D 作双对数回归，幂指数落在 $-0.2806 \sim -0.2803$ ，接近经典拟合的 $-\beta = -0.2799$ 。这表明插值轨迹与经典规模关系基本自治；由于轨迹来自 Pythia 检查点插值，这项检查不增加独立观测证据。

2. 广义标度律参数估计

接着合并 Pythia 规模记录与 B6 质量实验，估计表 9 所选形式的参数。Pythia 无实测质量信息，按前述约定取参考质量 $Q = 1$ ；估计结果见表 10。

表 10 广义模型各损失项的参数配置


损失组成	系数符号	系数估计	指数符号	指数估计
不可约损失	E	1.6558	—	—
参数规模项	A	0.3808	α	0.3266
训练数据项	B	1.2515	β	0.2767
质量缺口项	C	0.3544	γ	0.9779

注：联合拟合 $R^2 = 0.9896$ ；不可约损失为常数项，不含衰减指数。

联合拟合的 $R^2 = 0.9896$ 、**RMSE** = 0.036、**MAPE** = 0.66%。表 10 中 $\gamma = 0.9779 \approx 1$ ，意味着渐近损失随质量缺口近似线性上升。这里的联合样本与经典拟合不同，因此不能将两个 R^2 的大小直接解释为质量项带来的精度变化。

图 14 从两个角度呈现质量效应。左侧固定 $D = 300B$ tokens，以底色和等值线绘制模型的规模-质量响应面，空心点标记 B6 半合成实验位置；右侧从基线 E 出发，分解不同质量缺口引起的渐近损失增量。

代入渐近关系 $E + C(1 - Q)^\gamma$ ，参考质量 $Q = 1$ 对应下限 1.656；质量降至 $Q = 0.6$ 和 $Q = 0.3$ 时，下限分别升至 1.801 和 1.906。



D=300 B tokens; 空心点: B6 实验位置; 底色与等值线: 模型预测。

图 14 规模-质量响应面与渐近损失分解

3. 分层检验与适用范围

模型能否用于配置分析，需要结合数据来源判断。表 11 列出 6 组数据的检验指标，图 15 补充误差分布。图中采用有符号相对误差 $100(\hat{L} - L)/L$ ，负值表示低估、正值表示高估；为同时呈现较小与较大的偏差，横轴在 $\pm 10\%$ 内保持线性，外侧使用对称对数刻度。**MAPE**、**RMSE** 与相关系数由表中给出。

表 11 按数据性质区分的预测误差与相关性


数据性质	对照样本	记录数	MAPE/%	RMSE	r
真实	B4 跨模型族收敛点	57	8.8	0.293	0.975
	B5 文献标度记录	44	8.0	0.193	0.910
	B7 新增质量实验	90	1.6	0.056	0.991
半合成	B2 Cerebras 轨迹	1,029	33.7	1.245	0.666
	B8 校准段（方向变换）	984	133.4	1.294	0.638
估算	B10 大规模估算损失	128	1.0	0.020	1.000

注: **B8** 使用 $1 - Q_{\text{score}}$; **B10** 统一取 $Q = 1$ 。 **B7** 属于开发阶段验证, **B10** 不构成独立实验验证。

在跨族数据 **B4** 和文献数据 **B5** 上，相关系数分别为 0.975、0.910，**MAPE** 分别为 8.8%、8.0%，见表 11。模型能够反映部分跨族规模趋势，但预测损失仍受来源差异影响，不能仅凭较高相关忽略绝对偏差。

B7 的 90 个新增点得到 1.6% 的 **MAPE**，支持质量关系在同一半合成框架内的扩展一致性。**B10** 则提供估算损失，检验统一取 $Q = 1$ ；它只能用于比较估算关系，既不构成独立实验验证，也不提供质量项的验证证据。

偏差较大的数据揭示了模型边界。**B2** 的 **MAPE** 为 33.7%，**B8** 校准段即使翻转质量方向，**MAPE** 仍为 133.4%。此外，**B8** 部分损失已经低于本文估计的渐近下限。方向调整无法消除这些差异，说明不同来源的损失尺度或生成机制不能由当前模型统一解释。



相对误差 = $100 \times (\text{预测值} - \text{给定值}) / \text{给定值}$ ；横轴在 $\pm 10\%$ 内线性。
B8 使用 1-Q；空心点：中位数；粗线：四分位区间；轮廓：平滑密度。

图 15 不同数据源的有符号相对误差分布

定量解释还须对照实际估计区间：**B1** 的 N 、 D 分别约为 $0.07\text{--}12\text{B}$ 、 $0.134\text{--}299.893\text{B tokens}$ ，**B6** 对应区间约为 $0.07\text{--}11.97\text{B}$ 、 $10\text{--}600\text{B tokens}$ 。质量效应的数值依据主要是 **B6/B7** 半合成实验；超出这一背景的大规模估算记录，只承担外推一致性对照的作用。

4. 大规模模型的对应与外推范围

进一步核对大规模记录的对应关系。按 **B9** 模型名称与 **B10** 模型族名称匹配后，**B10** 的 128 条记录全部获得一对一对应，参数量 N 与数据量 D 也逐条相同。**B9** 共 132 条，其中未匹配的 4 条将训练数据量记为 0，且缺少 **B10** 损失，因此予以排除。表 12 按参数规模汇总匹配样本。

表 12 大规模匹配样本的覆盖范围与估算偏差

参数规模区间 N/B	[100, 300)	[300, 1000)	[1000, 10000]
成功匹配记录数	65	43	20
最小数据量 / B tokens	1.3	0.3	0.1
最大数据量 / B tokens	36,000	30,000	36,000
MAPE / %	0.94	1.08	1.12

注：**B9** 元数据与 **B10** 损失按名称匹配；统一取 $Q = 1$ ，MAPE 比较本文预测与 **B10** 估算值。数据量上下限为各组记录的实际极值。

这些记录的参数规模为 $100\text{--}10,000\text{B}$ ，已全部越过主拟合上限。各组相对误差均约为 1%，反映出本文模型与 **B10** 所用估算关系接近。由于 **B10** 本身由标度律估算生成，低误差不能替代真实大模型实验，也不能据此将质量效应直接推广到该规模区间。

5. 质量投入的局部收益与规模替代

在给出应用范围后，选取两个参考点考察投入方向。表 13 列出局部弹性与质量-参数等效增量比，用于比较比例变化的影响及其随参考位置的差异。


表 13 两个参考情景下的局部敏感度与等效增量比

指标	参考情景一	参考情景二
	$N_0 = 1, D_0 = 100$ $Q_0 = 0.6$	$N_0 = 12, D_0 = 300$ $Q_0 = 0.6$
参数量弹性 ε_N	-0.0491	-0.0248
数据量弹性 ε_D	-0.0383	-0.0321
质量弹性 ε_Q	-0.0838	-0.0953
局部等效增量比 R_{NQ}	2.844	76.838

注： N_0 以 **B** 参数计， D_0 以 **B tokens** 计；弹性无量纲， R_{NQ} 的单位为 **B/单位质量**。弹性保留方向，图中展示其绝对值。

在参考点 $(N_0, D_0, Q_0) = (1, 100, 0.6)$ ，质量弹性绝对值约为参数弹性的 1.7 倍，意味着相同比例的微小质量改善带来更大的损失降幅。两个参考点的局部替代率分别为 2.844 和 76.838 **B/单位质量**。若以 0.1 的质量增量作一阶估计，得到的等效参数增量为 0.284**B**、7.684**B**。它们只表示局部损失效果，不表示等成本投入；有限幅度配置须使用式(20)，并核对解所在的规模是否超出拟合范围。

图 16 进一步展示边际收益怎样随参考位置变化：前两幅点图分别给出参数和质量量的边际导数绝对值，第三幅用成对标记比较两个参考点的弹性绝对值。前两幅导数各有量纲，不宜直接按数值大小比较，第三幅弹性绝对值则可用于比较相同比例变化的影响幅度。



左、中图：边际导数，各用自身量纲；右图：无量纲弹性。
仅右图两个参考点均取 $Q=0.6$ ； N 、 D 以 **B** 为单位。

图 16 参考位置的边际效应与弹性对比

图 17 把局部比较扩展为固定 $D = 300\text{B tokens}$ 下的等损失配置。三个子图各给定一个目标损失，横轴为参数量，纵轴为所需质量；实线对应主拟合规模范围，虚线对应外推。 $L = 1.95$ 的子图放大高质量区间，横轴延伸至 10^4B 仅为显示理论关系，不代表工程可行。

还需注意， $\gamma = 0.9779 < 1$ 使 $|dL/dQ|$ 在 $Q < 1$ 区间内递增，并在 $Q \rightarrow 1^-$ 时发散。因此，接近 $Q = 1$ 时不宜依据导数给出资源配置判断，质量边际效应的定量解释应避免这一端点。





图 17 三个目标损失下的规模-质量配置边界

6. 领域效应与配比衔接

规模与质量的分析之外，领域配比还会改变各验证任务的损失。图 18 左侧以 $d_{ij} = \sqrt{2 - 2s_{ij}}$ 为距离，通过平均连接法聚类 17 个训练域；右侧选取相似度最高和最低的各四对领域，绿色、金色分别标记相对效应趋同与相反。聚类展示的是效应结构，不代表领域联合使用存在额外收益。



聚类距离 $\sqrt{2-2s}$; 绿色: 效应趋同; 金色: 效应相反。
右图列示 s 最大与最小的各 4 对; 相似性不代表互补增益。

图 18 训练领域效应聚类与典型领域对比较

从图 18 可见，百科与网页、医学全文与医学摘要的相似度为 0.925、0.903，其在 13 个验证域上的相对效应较接近；医学全文与邮件的相似度为 -0.967，则体现出明显的任务收益差异。判断能否替换某一领域，还必须结合效应幅值与验证任务权重。具体地，

在单纯形内将比例 h 从领域 i 转移至 j , 并满足 $0 \leq h \leq p_i$, 线性模型给出的加权损失变化为

$$\Delta \hat{L}_A = h \mathbf{w}^T (\mathbf{a}_j - \mathbf{a}_i), \quad (23)$$

其中 $\mathbf{w}$ 为验证域权重。损失变化小于零、等于零或大于零, 分别表示这次替换改善、保持或降低加权表现。因而, 效应方向相似不等于等量替换无损, 效应相反也只提示任务间权衡; 在没有领域交互项的线性模型中, 无法进一步识别联合使用的互补增益。

对问题一推荐配比与参考配比作同口径比较, 线性模型给出的加权损失差为

$$M = \hat{L}(\mathbf{p}_{\text{rec}}) - \hat{L}(\mathbf{p}_{\text{ref}}) = -0.1988.$$

这一差值基于附件 A 的验证域及权重。若配比效应可与规模、质量效应分离, 且损失增量能够跨来源迁移, 就可将 $M(\mathbf{p})$ 写成广义标度律的加性修正。多来源检验已显示损失水平存在差别, 因此 0.1988 只描述上述口径下的结果, 不能理解为各规模均可获得的固定降幅。

在上述分离与迁移条件下, 规模、质量和配比的关系可合写为

$$L(N, D, Q, \mathbf{p}) = E + AN^{-\alpha} + BD^{-\beta} + C(1 - Q)^{\gamma} + M(\mathbf{p}),$$

$$M(\mathbf{p}) = \sum_{i=1}^{17} (p_i - p_{\text{ref},i}) \mathbf{w}^T \mathbf{a}_i. \quad (24)$$

以参考配比为零点, 有 $M(\mathbf{p}_{\text{ref}}) = 0$ 。配比固定时, M 改变损失水平, 但不改变 N, D, Q 的边际导数和等损失替代条件; 本节报告的弹性使用参考配比。质量参数仍定义在附件 B 的评分尺度上, 若将问题一评分直接用于后续配置, 则需额外接受尺度衔接假设, 这一点不能由加性表达式本身验证。

上述结果为资源配置提供了带适用条件的损失关系: 参数扩张的边际收益随规模增大而降低, 质量改善的等效参数增量则随参考点变化。跨族和文献数据的 MAPE 为 8.8%、8.0%, 提示后续配置应同时考虑预测偏差。质量尺度、数据来源与外推范围共同限定了这些结论的解释边界。

5.3 问题三: 算力约束下的资源配置与结构性转移

5.3.1 问题分析与模型准备

在总算力固定时, 扩大模型、增加训练数据和提高数据质量会争夺同一笔预算。更大的模型能够降低参数规模项, 却提高了每个 **token** 的训练成本; 更高的质量能够减小质量缺口, 却需要处理整份训练语料。因而, 问题三的关键是比较这些投入带来的损失改善与算力代价, 而非分别寻找三个变量的最大值。

问题二已经给出参数量、数据量和质量与损失之间的关系。本节据此加入成本约束, 考察预算增加后最优配置的变化。算力最优训练研究中的参数-数据协同配置为这一分析提供了基础 [2]; 本题进一步计入质量处理和长上下文开销, 并比较不同成本设定下的选择。

数据与计算口径

本节直接使用问题二估计的标度律参数, 取 $E = 1.6558$ 、 $A = 0.3808$ 、 $\alpha = 0.3266$ 、 $B = 1.2515$ 、 $\beta = 0.2767$ 、 $C_q = 0.3544$ 、 $\gamma = 0.9779$ 。其中质量项系数记为 C_q , 与算力预算 C_b 区分。计算成本时, N 和 D 分别使用参数个数与 **token** 数; 代入标度律时换算为 $n = N/10^9$ 、 $d = D/10^9$, 结果表中的 **B** 均表示十亿。

质量提升从参考语料出发。设 $\bar{p}_k$ 为 **A4** 配方的平均领域占比， Q_k 为问题一经 **A16** 映射得到的领域评分，则基线取为

$$Q_0 = \sum_{k=1}^{17} \bar{p}_k Q_k = 0.5510.$$

这一加权方式与参考配方保持一致，未加权样本均值 0.4952 则用于基线灵敏度对照。沿用前两问的衔接设定，将该评分代入质量标度律，并限定 $Q_0 \leq Q \leq 1$ ；评分的跨来源数值可比性仍属于模型假设， $Q = 1$ 表示设定的参考质量上界。

基准情景采用参考配比 $M = 0$ 、幂函数型质量成本及 2048 **tokens** 上下文。对照分析分别更换质量成本函数和上下文长度，其余条件保持一致。上下文长度由任务与架构外生给定，取附件 **C7** 的五个档位：**2048**、**4096**、**8192**、**32768** 和 **131072 tokens**。问题一的推荐配比以 $M = -0.1988$ 作补充情景，讨论其对损失水平的影响。

5.3.2 模型建立

1. 每个训练 token 的算力代价

基础训练成本采用 $6ND$ 近似 [2]，质量处理和注意力成本采用赛题给定形式 [12]。在允许的质量范围内，三类 $g(Q)$ 均单调增加，故记 $\Delta g(Q) = g(Q) - g(Q_0) \geq 0$ ，总成本可整理为

$$C_{\text{tot}} = 6ND + D\Delta g(Q) + \eta NDL_{\text{ctx}} = D \underbrace{[(6 + \eta L_{\text{ctx}})N + \Delta g(Q)]}_{\text{单位 token 的合计算力成本}}, \quad \eta = 2 \times 10^{-4}. \quad (25)$$

这一写法说明，增加数据量会同时增加训练、注意力与质量处理开销；提高质量虽然不改变模型参数量，却增加每个 **token** 的处理成本。即使质量已经达到上界，新增数据仍需支付这笔费用。

题设的三类质量成本列于表 14。比较时使用增量 $\Delta g(Q)$ ，各函数在 Q_0 处的增量成本均为零。

表 14 质量处理成本函数 (g 的单位为 FLOPs/token)

成本类型	$g(Q)$	本节用途
幂函数型	$5 \times 10^9 Q^4$	基准配置
指数型	$10^7 e^{6Q}$	成本形式对照
对数渐进型	$2 \times 10^9 \ln(1 + 10Q)$	成本形式对照

2. 预算约束下的配置模型

记 $k = 6 + \eta L_{\text{ctx}}$ 。给定配比和上下文长度后，以预测验证损失最小为目标，得到

$$\begin{aligned} \min_{N,D,Q} \quad & E + An^{-\alpha} + Bd^{-\beta} + C_q(1 - Q)^\gamma + M, \\ \text{s.t.} \quad & D[kN + \Delta g(Q)] \leq C_{\text{b}}, \quad Q_0 \leq Q \leq 1, \\ & 10^5 \leq N \leq 10^{15}, \quad 10^6 \leq D \leq 10^{16}. \end{aligned} \quad (26)$$

后两项规模界限用于限定数值搜索域，并非实际语料供给上限。 M 为固定的配比修正项，因此改变 M 只平移目标函数，不改变本模型的最优配置。

固定质量且规模界限不活跃时，增加 N 或 D 都能降低损失，预算约束因而取等号。将其写为

$$D = \frac{C_{\text{b}}}{kN + \Delta g(Q)} \quad (27)$$

即可看出两类竞争：提高 N 会压缩可负担的数据量，提高 Q 也会通过处理成本减少 D 。最优配置需要在直接收益与这部分间接损失之间取得平衡。

3. 参数量与数据量的平衡

为在绝对数量口径下求导，令 $\tilde{A} = A(10^9)^\alpha$ 、 $\tilde{B} = B(10^9)^\beta$ 。将式(27)代入规模损失项，固定 Q 后得到

$$F(N) = \tilde{A}N^{-\alpha} + \tilde{B} \left[\frac{kN + \Delta g(Q)}{C_b} \right]^\beta.$$

令 $F'(N) = 0$ ，整理可得

$$\alpha \tilde{A} N^{-\alpha} \left(1 + \frac{\tau(Q)}{N} \right) = \beta \tilde{B} D^{-\beta}, \quad \tau(Q) = \frac{\Delta g(Q)}{k}. \quad (28)$$

$\tau(Q)$ 是把质量处理费用按单位参数训练成本折算的附加规模，与 N 同口径。式(28)把质量投入对参数-数据平衡的影响集中在 $1 + \tau/N$ 中；因此，付费提升质量后，原有的两类规模项平衡也会改变。

若质量保持在基线， $\tau = 0$ ，则有 $\alpha \tilde{A} N^{-\alpha} = \beta \tilde{B} D^{-\beta}$ 。再结合 $kND = C_b$ ，在固定上下文条件下得到

$$N^* \propto C_b^{\beta/(\alpha+\beta)}, \quad D^* \propto C_b^{\alpha/(\alpha+\beta)}. \quad (29)$$

两个指数分别约为 0.459 和 0.541，数据量随预算增长略快于参数量。这一关系作为无额外质量投入时的基准；跨越质量提升阶段时，配置应由完整模型确定。

4. 数值求解与阶段识别

采用 **SLSQP** 求解式(26)，以 $\ln N$ 、 $\ln D$ 为规模变量，减小数量级差异。三档预算分别使用 8 组初值，预算扫描使用 5 组初值，在求解成功的结果中取损失最低者。下文将这一数值候选解记为 (N^*, D^*, Q^*) ；多初值不能保证全局最优，且 $\gamma < 1$ 时端点 $Q = 1$ 的导数不有界，故饱和配置按边界解处理。

为比较不同预算下的质量投入，定义完成度 $\Theta = (Q^* - Q_0)/(1 - Q_0)$ 与质量份额 $f_Q = D^* \Delta g(Q^*)/C_b$ 。质量处于基线、内部或上界，分别对应 $\Theta = 0$ 、 $0 < \Theta < 1$ 和 $\Theta = 1$ 。在 10^{18} – 10^{25} **FLOPs** 范围设置 141 个对数等距预算点，相邻预算比约为 1.122，以有效解中首次出现正质量投入和达到上界的位置识别阶段变化。扫描中 1.41×10^{19} **FLOPs** 处求解失败，分析使用其余 140 点。图中标记对应有效记录，跨缺测点的点线仅连接两端，不代表补算结果。

5.3.3 模型求解

1. 预算增加后，质量与规模如何分配

表 15 给出基准情景的三档配置。预算增加时，参数量和数量均上升，但二者并非按固定比例扩张： D/N 从 30.9 增至 76.1，高预算配置使用了相对更多的训练数据。质量则从基线水平升至上界，中、高两档的质量水平相同。

三档结果尚不能说明质量在何时提升。图 19 沿用幂函数型成本、 $L_{\text{ctx}} = 2048$ 和 $M = 0$ 的基准情景，左图展示质量完成度，右图展示三类成本份额。内嵌图放大质量提升区间，两条竖线分别标出扫描识别的启动与饱和位置。图中标记为已有的有效求解记录，跨缺测位置的点线仅连接两端，不代表补算结果。

在预算较低的有效扫描点上， $Q^* = Q_0$ ，基础训练和注意力计算分别占预算的 93.6% 和 6.4%。增加质量虽可降低质量缺口项，但处理成本会减少可用于训练的数据量；这一阶段的数值解选择保持基线质量。

预算增至 1.78×10^{19} **FLOPs** 时，首次出现额外质量投入。此后质量完成度与质量份额同步上升，至 7.08×10^{19} **FLOPs**，质量达到上界，质量份额也达到扫描峰值 40.7%。前一有效点的质量约为 0.955，因此扫描将饱和和边界定位在 $[6.31, 7.08] \times 10^{19}$ **FLOPs** 之

表 15 三档预算的基准配置（幂函数型成本， $L_{\text{ctx}} = 2048$ ， $M = 0$ ）

预算 (FLOPs)	N^* (B)	D^* (B tokens)	Q^*	L^*	D^*/N^*	f_Q (%)
10^{19}	0.225	6.9	0.551	3.170	30.9	0.0
10^{22}	6.089	229.5	1.000	2.145	37.7	10.4
10^{24}	44.937	3418.0	1.000	1.897	76.1	1.6




图 19 预算变化下的质量与成本份额

间；相应的启动边界位于 $[1.58, 1.78] \times 10^{19}$ FLOPs 之间。这些区间反映当前网格分辨率，不能解释为精确的临界预算。

质量达到上界后，进一步投入无法继续提高 Q ，预算扩张转而支持参数量和数据量增长。此时 $\Delta g(1)$ 固定，由预算等式可得

$$f_Q = \frac{\Delta g(1)}{kN^* + \Delta g(1)}.$$

随着参数量上升，质量份额自然下降，至 10^{24} FLOPs 时约为 1.6%。这并不要求质量处理的总费用下降：新增 token 仍支付相同处理单价，只是模型训练费用增长得更快。质量饱和的原因是可行上界，而非边际质量收益趋零；后者与问题二估计的 $\gamma < 1$ 不符。

2. 低预算的质量选择取决于成本形式

上述阶段变化是在幂函数型成本下得到的。若质量处理方式改变，相同预算是否仍应保持基线质量？保持 $L_{\text{ctx}} = 2048$ 、 $M = 0$ ，分别采用表 14 中的三类成本函数求解。图 20 以九组求解结果比较质量水平和投入份额，具体配置见表 16。

在 10^{19} FLOPs 下，三类成本给出了不同选择：幂函数型保持 $Q^* = 0.551$ ，指数型将质量提高至 **0.660**，对数渐进型则达到上界。对数渐进型在这一预算下的质量投入份额也最高，为 31.6%。三种配置的预测损失相差约 **0.057**，但质量份额从 0 到 31.6% 不等，说明相近损失可以对应明显不同的投入结构。

当预算达到所考察的中、高两档时，三类成本均给出 $Q^* = 1$ ，质量是否饱和的判断一致。规模配置仍有差别： 10^{22} FLOPs 下的数据量为 **229.5–274.2B tokens**，最大值较最




图 20 不同成本下的质量投入

表 16 三类质量成本下的配置对比 ($L_{\text{ctx}} = 2048$, $M = 0$)

预算 (FLOPs)	成本类型	N^* (B)	D^* (B tokens)	Q^*	L^*	f_Q (%)
10^{19}	指数型	0.265	5.1	0.660	3.163	12.9
	幂函数型	0.225	6.9	0.551	3.170	0.0
	对数渐进型	0.354	3.0	1.000	3.113	31.6
10^{22}	指数型	5.972	237.9	1.000	2.144	8.9
	幂函数型	6.089	229.5	1.000	2.145	10.4
	对数渐进型	5.527	274.2	1.000	2.138	2.9
10^{24}	指数型	44.796	3437.7	1.000	1.897	1.3
	幂函数型	44.937	3418.0	1.000	1.897	1.6
	对数渐进型	44.298	3509.0	1.000	1.897	0.4

小值高约 19.5%。因此，基准情景的低预算策略不宜推广到所有成本形式；即使质量水平相同，模型规模和数据量仍需按具体处理成本配置。

3. 长上下文如何改变配置

延长上下文会提高式(25)中的 k 。注意力与基础训练的成本比为 $\lambda = \eta L_{\text{ctx}}/6$ ，两者相等时

$$L_{\text{crit}} = \frac{6}{\eta} = 30,000 \text{ tokens.} \quad (30)$$

该值是两项成本的分界；配置如何变化，还需连同质量处理成本一起考察。固定预算为 10^{22} FLOPs，五档结果列于表 17。

表 17 上下文长度敏感性 ($C_b = 10^{22}$ FLOPs，幂函数型成本， $M = 0$)

L_{ctx} (tokens)	λ	N^* (B)	D^* (B tokens)	Q^*	L^*	注意力份额 (%)
2048	0.068	6.089	229.5	1.000	2.145	5.7
4096	0.137	5.897	223.5	1.000	2.149	10.8
8192	0.273	5.562	212.7	1.000	2.157	19.4
32768	1.092	4.318	170.2	1.000	2.194	48.2
131072	4.369	2.705	109.1	1.000	2.273	77.3

上下文由 2048 增至 131072 tokens 时，注意力份额从 5.7% 升至 77.3%，参数量和数量分别减少约 55.6% 和 52.5%，预测损失增加约 0.128。五档质量均保持为 1，额外注意力开销主要压缩了规模投入。值得区分的是，32768 tokens 已使注意力成本超过基础训练，但其总预算份额仍为 48.2%，因为质量处理也占用预算。

为观察五档之间的变化，图 21 进一步给出上下文扫描结果，仍采用幂函数型成本与参考配比 $M = 0$ 。左图预算为 10^{22} FLOPs，方形点对应 C7 的五档配置；右图比较三档较低预算的质量响应，其中 10^{20} 与 10^{21} FLOPs 下的曲线重合。竖线标出 L_{crit} ，各标记对应有效求解记录，跨缺测位置的点线仅用于连接已有记录。




图 21 上下文长度对资源配置的影响

图 21 右侧显示，低预算下的响应有所不同： 10^{19} FLOPs 时，已有计算点的质量由 0.551 升至约 0.670。较长上下文压缩了可负担的数据量，而质量处理费用正比于 D ；处理更少的数据使提高整份语料质量的代价降低，从而改变了质量与规模的取舍。这一解释来自题设成本中的数据量因子，适用于当前模型中的联动关系。

4. 配比收益与结果适用范围

数据配比研究表明，领域权重可以影响预训练效率 [13]。本模型以常数项 M 表示这一影响：在 10^{22} FLOPs 下，采用问题一推荐配比后，配置不变，预测损失从 **2.1450** 降至 **1.9462**。现有二分计算给出的参考配比等损失预算约为 3.05×10^{23} FLOPs，即约 **30** 倍原预算。这是固定损失平移假设下的算力等价估计，其跨规模含义依赖第二题讨论的迁移条件，不能作为实际训练加速比。

本节得到的主要区别在于：质量水平达到上界以前，增加预算会改变质量与规模的投入组合；达到上界以后，质量处理继续发生，但其预算份额随参数规模增长而下降。低预算选择对质量成本较敏感，长上下文则通过训练单价与可负担数据量共同影响配置。定量使用这些结果还需考虑评分尺度衔接及外推范围，特别是高预算方案所需的数据量。数据受限训练研究指出，重复数据的收益会随重复次数增加而衰减 [14]；本文尚未加入语料供给与重复训练约束，高预算配置因而应视为理论情景。

5.4 问题四的模型的建立和求解

5.4.1 具体分析

针对问题四，本问属于**技术演进建模与前沿预测**类问题，需要结合历史评测数据建立技术演进模型，分离并量化规模扩张与非规模技术进步的贡献占比，并预测未来 **12** 至 **24** 个月开源大语言模型能力的前沿边界。本问综合采用“口径界定 → **Loss—Benchmark** 桥接 → 面板回归分解 → 前沿预测 → 宏观证据校验”五步框架：首先明确综合能力的度量方式、开源筛选口径、模型类型口径与时间轴口径；再按可比性分层建立交叉熵损失与 **Leaderboard** 得分的映射，把前三问以损失为目标的结论桥接到以评测得分为度量的能力；然后以参数规模与年份为解释变量做面板回归（含年份固定效应），把能力提升分解为“规模扩张”与“非规模技术进步”两部分；接着用 **logistic** 饱和模型与结构外推两条路线给出未来 **12/24** 个月的前沿预测与不确定性区间；最后用附件 **C4** 的算力、数据量与开源权重证据检验“算力增长放缓”情景的合理性。

本问严格完成题设的必用要求：对 **C8** 的逐任务评测 **JSON** 做逐任务聚合分析（不依赖汇总表），对 **C4** 的算力、数据量与开源权重字段作宏观证据检验，桥接数据按可比性等级（**C6** 的 **High/Medium**，并以 **C5** 对照）分层使用。

5.4.2 模型准备

1. 口径界定

(1) **综合能力度量**。采用 **Open LLM Leaderboard v2** 的六维平均分 $\bar{B}$ ：**IFEval**（指令遵循）、**BBH**（多跳推理）、**MATH Lvl 5**（数学）、**GPQA**（研究生级问答）、**MUSR**（多轮推理）、**MMLU-PRO**（专业知识）。六维等权平均，取值 $0 \sim 100$ 。

(2) **时间轴口径**。统一以 **C1** 的 **Submission Date**（提交日期）为基准，并按“年 + 月”折算为连续时间变量 $t = \text{年份} - 2019 + (\text{月} - 0.5)/12$ 。之所以不采用发布日期或版本日期，是因为 **Leaderboard** 上的评测结果均在提交时冻结、且提交日期字段完整无缺失；**C3** 的 **Year** 字段仅用于 **2019–2023** 的历史锚点对照。

(3) **开源筛选口径**。同时要求两个条件：(a) 模型权重可获取（**Type** 属 **pretrained**、持续预训练、**chat**、域内微调四类）；(b) **Hub License** 允许研究与复现，即采用 **apache-2.0**、**mit**、**gpl-3.0**、**cc-by-4.0**、**mpl-2.0**、**bsd-3-clause**、**llama2/3/3.1/3.2/3.3**、**gemma**、**cc-by-sa-4.0**、**openrail** 等许可，排除 **cc-by-nc** 系列（非商用）、**creativeml-openrail**、**bigscience-bloom-rail** 等受限许可以及未知许可。筛选漏斗见表 18。

(4) **模型类型口径**。明确区分 **pretrained**（含持续预训练，共 **231** 条）与 **chat/finetuned**（经对话指令或监督微调，共 **1,497** 条）两类，分组统计规模效应与时间效应；**base** 合并模型（**1,724** 条，非独立训练过程）与多模态模型（**9** 条，任务构成不同）不并入主分析。

表 18 数据筛选漏斗（C1 排行榜）

筛选层级	记录数	说明
C1 全量记录	4,576	提交日期 2024-06-08 ~ 2025-03-13
六维得分完整	4,576	无缺失
时间/参数/六维齐备	4,561	剔除 15 条参数或 日期缺失
许可允许研究复现（开源口径）	2,346	符合上述许可白名 单
其中 pretrained	231	类型为 pretrained / 持续预训练
其中 chat/finetuned	1,497	类型为 chat / 域内 微调

2. 附件 C8 的逐任务聚合

附件 C8 含 1,863 个模型子目录、1,958 个评测 JSON。本文按目录取最新可解析记录，提取每个模型在各任务上的原始指标（按 `acc_norm`、`acc`、`prompt_level_loose_acc`、`inst_level_loose_acc`、`exact_match` 的优先级选取），共成功解析 1,860 个模型，跳过 7 个损坏或无有效记录的目录。解析后可用的子任务维度共 37 项：BBH 子任务 24 项、MATH-Hard 子任务 7 项、GPQA 子集 3 项、MUSR 子任务 3 项。

由于 C8 保存的是原始指标、而 C1 保存的是官方按随机基线归一化后的六维得分（例如 $GPQA = (\text{raw} - 0.25)/0.75$ 、 $MMLU-PRO = (\text{raw} - 0.10)/0.90$ 、 $IFEval = (\text{prompt_strict} + \text{inst_strict})/2$ ），两者存在系统性水平差。因此本文的处理是：跨模型得分分析使用 C1，逐任务结构分析在 C8 的原始指标空间内进行，并以秩相关作为两者的衔接验证，结果见表 19。

表 19 C8 解析结果与 C1 的一致性校验

任务	匹配模型数	Pearson r	Spearman ρ	平均绝对偏差
IFEval	1,896	0.987	0.987	2.88
BBH	1,898	0.998	0.997	21.06
MATH Lvl 5	1,897	0.803	0.812	3.47
GPQA	1,894	0.987	0.992	23.38
MUSR	1,894	0.973	0.977	30.73
MMLU-PRO	1,896	0.998	0.998	7.56

由表 19 可知，两套数据的秩一致性均在 0.81 以上（多数在 0.97 以上），说明 C8 的逐任务解析结果与官方汇总得分反映同一批评测；平均绝对偏差较大的维度（GPQA 23.4、MUSR 30.7、BBH 21.1）正是“原始分”与“基线归一化分”差异最大的维度，与前述口径说明完全对应。这一校验保证了后续逐任务结论的可靠性。

3. 算法选择

Loss—Benchmark 映射采用按可比性分层的线性最小二乘（并在全样本上给出整体拟合），分层可避免“同模型同验证集”与“跨族近似验证集”样本混用造成的偏置；规

模/时间分解同时采用线性时间 **OLS** 与年份固定效应两种设定，后者把非规模技术进步完全交由年效应吸收，可显著缓解规模与年份的共线性；前沿外推同时采用 **logistic** 饱和模型（有界、符合满分 **100** 的物理约束）与结构外推（把分解方程直接用作预测方程），两条路线互为校验；不确定性由残差 **bootstrap**（**600** 次重抽样）与情景分析共同给出。

5.4.3 模型建立

步骤 1：Loss—Benchmark 映射模型

设验证损失 L 与 **Leaderboard** 均分 $\bar{B}$ 之间存在近似线性关系：

$$\bar{B} = a + bL \quad (31)$$

系数 a 、 b 由最小二乘估计，并按 **C6** 的 **Loss_Comparability** 字段分为“高可比”（同模型同验证集，主要来自 **Pythia**，可与附件 **B** 对照）与“中可比”（**Loss** 来自不同技术报告或论文）两层分别估计。映射误差对结论的影响通过分层的 R^2 、**MAPE** 与相关系数共同刻画。

步骤 2：规模扩张与技术进步分解模型

以参数量对数与时间为解释变量建立面板回归：

$$\text{Score}_{it} = b_0 + b_P \log_{10} P_{it} + b_t t + \varepsilon_{it} \quad \text{或} \quad \text{Score}_{it} = \alpha_t + b_P \log_{10} P_{it} + \varepsilon_{it} \quad (32)$$

其中 b_P 为规模系数（参数量每增大 **10** 倍带来的得分提升）， b_t 为时间系数（每年非规模技术进步带来的得分提升）， α_t 为年份固定效应。前沿提升的 **shift-share** 分解为

$$\Delta F = \underbrace{b_P \Delta \log_{10} P_{\text{frontier}}}_{\text{规模扩张贡献}} + \underbrace{[\Delta F - b_P \Delta \log_{10} P_{\text{frontier}}]}_{\text{非规模技术进步贡献}} \quad (33)$$

两者占比即为所求贡献份额。 $\Delta \log_{10} P_{\text{frontier}}$ 取各年“参数量最大的开放权重模型”的对数差， ΔF 取累计前沿（按定义单调不减）之差。

步骤 3：能力前沿预测模型（两条路线）

路线一（曲线外推）：能力前沿随时间的演化以 **logistic** 饱和函数刻画，并用残差 **bootstrap** 给出区间：

$$F(t) = \frac{K}{1 + e^{-r(t-t_0)}}, \quad K \text{ 为饱和上界, } r \text{ 为增长率, } t_0 \text{ 为拐点} \quad (34)$$

前沿序列取“年度累计最大”与“月度前 1% 均值累计最大”拼接而成的单调不减序列。算力增长放缓情景以“增速减半”实现：

$$F_{\text{slow}}(t) = K [1 + e^{-r(\min(t, t_h) - t_0)}]^{-1}, \quad t_h \text{ 为增速减半时刻} \quad (35)$$

路线二（结构外推）：直接把分解方程用作预测方程，

$$\hat{F}(t + \Delta) = F(t) + [b_P \Delta \log_{10} P + b_t] \cdot \Delta \quad (36)$$

并按“前沿模型规模持平（ $\Delta \log_{10} P = 0$ ）”“算力增长放缓（ b_t 减半）”“规模继续扩张（ $\Delta \log_{10} P = +0.3/\text{年}$ ）”三种情景给出区间。

5.4.4 模型求解

1. Loss—Benchmark 桥接结果

映射结果如图 **22** 所示，分层拟合结果如表 **20** 所示。




图 22 验证损失与 Leaderboard 均分的映射关系（按可比性分层）

表 20 Loss—Benchmark 映射的分层拟合结果（C6, $n = 75$ ）

可比性	n	Pearson r	Spearman ρ	斜率 b	R^2	MAPE(%)
高可比	7	-0.397	-0.607	-0.882	0.16	5.6
中可比	68	-0.502	-0.509	-19.185	0.25	57.3
全样本	75	-0.510	-0.549	-20.417	0.26	67.8
C5 对照（全样本）	43	-0.502	—	-16.155	—	—

由表 20 可知：（1）损失与能力得分确实负相关（全样本 $r = -0.510$ ，Spearman $\rho = -0.549$ ， $p < 10^{-6}$ ），验证了“以损失为目标的资源配置可转化为能力收益”的桥接逻辑；（2）但映射的 R^2 仅 0.26、MAPE 高达 67.8%，说明桥接关系是弱关系，其原因是中可比样本的 Loss 来自不同论文的不同验证集、量纲不完全统一；（3）高可比子集（Pythia 同模型同验证集）的斜率最缓（-0.882）、MAPE 最低（5.6%），但其得分变化幅度极小（5.07 ~ 6.06），因为这些小规模基础模型在六维基准上都接近随机水平，损失的大幅下降并未转化为得分提升。因此本文的桥接结论仅用于方向性判定与量级估计，不用于把损失数值精确换算为得分。

2. 规模扩张与非规模技术进步的贡献分解

面板回归结果见表 21，贡献分解如图 23 所示。

由表 21 可知：（1）规模系数 $b_P = 13.84$ ，即参数量每增大 10 倍，六维平均分提升约 13.8 分；非规模技术进步速率 $b_t = 4.84$ 分/年。（2）模型类型差异显著：pretrained 子样本的规模系数仅 6.41、时间系数 1.55，而 chat/finetuned 子样本达 14.85 与 4.68，说明经指令微调对齐后的模型对参数规模的利用效率更高，基础模型在同一评测上的得分提升要慢得多。这提示在讨论“规模扩张 vs 技术进步”时必须区分模型类型，否则会因样本构成变化而混淆两者。

表 21 规模系数估计 (C1 开源筛选样本, 2,346 条, 2024–2025 年)

子样本	n	b_P (分/10 倍参数)	b_t (分/年)	R^2	说明
全样本 (年份固定效应)	2,346	13.842	—	0.475	年效应吸收非规模进步
全样本 (线性时间 OLS)	2,346	13.842	4.844	0.475	两设定结果一致
pretrained	231	6.414	1.552	0.460	基础模型
chat/finetuned	1,497	14.853	4.680	0.484	指令/微调模型




图 23 规模效应与前沿提升来源分解 (左: 同一年内的规模效应; 右: 长周期贡献分解)

在长周期口径 (C3, 2019–2025) 上, 以 $b_P = 14.10$ 、 $b_t = 3.30$ ($R^2 = 0.42$) 做 **shift-share** 分解: 前沿由 5.00 升至 52.08 (提升 47.08 分), 其中 $b_P \Delta \log_{10} P = 23.77$ 分、残差部分 23.31 分, 即**规模扩张贡献 50.5%、非规模技术进步贡献 49.5%**, 二者几乎平分秋色。

但需指出长周期锚点存在口径风险。本文对 C3 做了自洽性审计: 比较每行 **Average** 与其六维均值, 发现 13 条记录的差值超过 5 (最大差值 42.3, 为 **GPT-3 (175B)** 的 **Average** = 50.0 而六维均值仅 7.67), 说明这些历史条目混入了不同评测标准, 已予以剔除。剔除后, 在评测标准完全一致的近端窗口 (**2024-06 至 2024-09**, 前沿由 37.99 升至 51.00) 内分解得: 前沿模型参数量仅由 70.6B 增至 78.0B ($\Delta \log_{10} P = 0.043$), 规模贡献 0.60 分、非规模贡献 12.41 分, 即**该窗口内前沿提升的 95.4% 来自非规模因素**。这与长周期口径的 50.5% 形成互补: 长期看规模与技术进步各贡献约一半, 但在最近一年、模型规模趋于稳定的条件下, 能力提升主要由数据工程、对齐方法等非规模因素驱动。

3. 能力前沿预测

前沿序列与 **logistic** 拟合如图 24 所示, 预测结果与不确定性见表 22。

logistic 拟合参数为 $K = 56.61$ 、 $r = 2.523$ 、 $t_0 = 5.11$ (自 2019 年起算), 拟合 $R^2 = 0.975$ 。由表 22 可知: (1) 曲线外推给出未来 12/24 个月前沿约 56.3 与 56.6, 90% 置信区间分别为 [53.6, 64.5] 与 [53.8, 66.5]; (2) 若算力增长放缓、非规模技术增速减半, 前沿将降至 53.3 附近并在两年内基本停滞; (3) 结构外推在三种情景下给出 53.4 ~ 69.0 的区间。两条路线的差异来自“当前前沿是否已接近饱和”这一判断, 因此本文以**区间**而非点值作为结论: 未来 12 个月开源模型六维平均分前沿预计达 53 ~ 60, 24 个月达 54 ~ 69; 若算力增长显著放缓, 前沿增速将接近停滞 (约 53 ~ 56)。




图 24 开源大语言模型能力前沿预测（未来 12/24 个月）

表 22 能力前沿预测及不确定性（满分 100）

前瞻期	logistic 预测	下界 (5%)	上界 (95%)	增速减半	结构外推（基准/放缓/扩容）
+12 个月 (2026-03)	56.33	53.62	64.52	53.27	55.84 / 53.42 / 59.99
+24 个月 (2027-03)	56.59	53.75	66.52	53.27	60.69 / 55.84 / 68.99

需强调该预测的局限：本文可用的评测标准一致的窗口仅约 10 个月（2024-06 至 2025-03，Leaderboard v2 已停更），2019–2023 的锚点口径不完全一致（已剔除异常条目），故外推期约为一致窗口的 1.2 ~ 2.4 倍，结论应理解为情景化区间而非精确点预测。

4. 逐任务聚合分析

六维前沿与剩余空间见表 23，C8 子任务中的瓶颈见表 24。图 25 进一步比较全部 37 个子任务的中位数与最优得分，展示各任务中总体水平与前列模型之间的差距。

表 23 六维 Benchmark 逐任务聚合结果（开源筛选集， $n = 2,346$ ）

任务	最优得分	前 1% 均值	中位数	剩余空间
IFEval	89.98	84.45	43.51	10.0%
MMLU-PRO	66.80	55.26	25.98	33.2%
BBH	65.47	59.95	28.52	34.5%
MATH Lvl 5	62.54	58.02	9.93	37.5%
MUSR	38.69	28.06	9.97	61.3%
GPQA	27.74	22.80	5.70	72.3%




图 25 C8 全部子任务的中位数与最优得分对照

表 24 C8 子任务层面剩余空间最大的 6 项（原始指标口径）

子任务	样本数	最优得分	前 5% 均值	剩余空间
math_intermediate_algebra_hard (MATH)	962	31.79	20.11	68.2%
math_precalculus_hard (MATH)	962	36.30	22.89	63.7%
math_geometry_hard (MATH)	962	40.91	28.72	59.1%
bbh_tracking_shuffled_objects_seven (BBH)	964	41.20	32.67	58.8%
bbh_tracking_shuffled_objects_five (BBH)	964	41.60	31.24	58.4%
gpqa_extended (GPQA)	961	44.87	39.74	55.1%

由表 23 与表 24 可知：（1）六维能力发展极不均衡，指令遵循（IFEval, 89.98）已接近满分、剩余空间仅 10.0%，而研究生级问答（GPQA, 27.74）与多轮推理（MUSR, 38.69）远未饱和，剩余空间分别达 72.3% 与 61.3%。（2）C8 子任务层面进一步定位了瓶颈：MATH-Hard 中的中级代数、预备微积分、几何三个子任务最优得分仅 31.8 ~ 40.9（该类别 7 个子任务的平均最优得分为 55.5，而整体中位数低至 3.7），BBH 中“跟踪被洗牌对象”类多步状态推理子任务最优得分约 41，GPQA 的 extended 子集为 44.9，这些是未来能力增量的主要方向。（3）C8 各类别的中位数普遍远低于最优值（BBH 中位数 48.8 对最优 81.8；MATH 中位数 3.7 对最优 55.5），说明开源社区的能力分布高度长尾，前列模型与总体水平差距巨大。

5. 附件 C4 的宏观证据与“算力增长放缓”情景校验

C4 的宏观趋势如图 26 所示。




图 26 C4 宏观证据（左：训练算力的年度演化；右：开源权重模型占比）

由图 26 可知：（1）C4 中 Language 域模型的前沿训练算力持续增长，对数尺度上的年增速约 +0.589 个数量级（约 3.88 倍/年），表明近年算力投入仍在快速扩张；但年际波动明显（2024 年前沿算力低于 2023 年，2025 年再创新高），说明算力增速并非单调外推、存在阶段性放缓的可能，这也正是本文把“算力增长放缓”作为情景（非规模增速减半）而非基准假设、并同时给出基准情景的原因。（2）开源权重模型的占比由 2018 年的 26.7% 持续上升至 2025 年的 59.4%，说明本文以开源筛选样本刻画“能力前沿”具有良好的代表性与可持续性。（3）C4 中共有 1,390 条记录含训练算力、1,424 条含训练数据量、2,653 条标注开源权重（Yes 1,325、No 1,328）。需要说明的是，C4 的模型命名体系与 C1 不通用（规范化名称匹配仅命中 1 条），故 C4 仅作宏观尺度证据，不与 C1 逐行合并。

综合以上结果，本节完成了问题四的求解：明确并执行了时间轴、开源筛选与模型类型三类口径；完成了 C8 的逐任务聚合（1,860 个模型、37 个子任务维度）并与 C1 交叉校验；建立了分层 Loss—Benchmark 桥接并量化了映射误差；用面板回归分离出规模扩张与非规模技术进步的贡献（长周期各约 50%，近端一致窗口内非规模因素占 95.4%）；给出了未来 12/24 个月能力前沿的情景化预测区间与逐任务瓶颈定位。

六、模型检验与分析

为验证本文构建的模型的有效性和稳健性，从误差分析与灵敏度分析两个维度进行检验：误差分析考察各模型在训练集与检验集上的拟合精度与泛化能力，灵敏度分析考察模型输出对关键输入与参数扰动的稳定程度。

6.1 误差分析

对问题一的岭正则线性混合回归、问题二的经典/广义标度律、问题四的 Loss—Benchmark 桥接与面板回归，分别计算决定系数 R^2 、均方根误差 RMSE、平均绝对误差 MAE 与平均绝对百分比误差 MAPE，结果如表 25 所示。

表 25 模型误差分析结果

模型（数据集）	R^2 / r	RMSE	MAE	MAPE(%)
问题一岭回归（训练 1M, $n = 512$ ）	0.629	0.551	0.403	8.54
问题一岭回归（检验 1M, $n = 256$ ）	0.619	0.523	0.386	8.43
问题一跨尺度 Pearson (60M / 1B)	0.782 / 0.651	—	—	—
问题二经典标度律 (B1, $n = 1,176$)	0.9999998	1.5×10^{-4}	1.2×10^{-4}	0.004
问题二经典标度律留出 (4 小模型 $\rightarrow$ 4 大模型)	0.9999997	1.5×10^{-4}	—	0.005
问题二广义标度律 (B1+B6 联合, $n = 1,536$)	0.990	0.036	0.024	0.66
问题二跨族验证 (B4, $n = 57$)	0.975	0.293	—	8.83
问题二文献验证 (B5, $n = 44$)	0.910	0.193	—	7.99
问题四 Loss—Benchmark 桥接 (C6, $n = 75$)	0.26	—	—	67.79
问题四面板回归 (C1 开源筛选, $n = 2,346$)	0.475	—	—	—
问题四面板回归 (C3 长周期, $n = 4,586$)	0.424	—	—	—
问题四前沿 logistic 外推	0.975	—	—	—
问题三优化约束残差 ($ C_{\text{total}}/C_{\text{budget}} - 1 $)	—	$< 10^{-6}$	—	—

由表 25 可知：(1) 问题一的岭回归在 13 个损失域上的平均训练 $R^2 = 0.629$ 、同尺度检验 $R^2 = 0.619$ ，训练与检验精度基本一致（差距 0.010），未出现明显过拟合；MAPE 约 8.5%，相对误差可控。(2) 问题二的经典标度律在 B1 上 $R^2 \approx 1.000$ 、MAPE 0.004%，且以小模型训练、大模型留出的验证结果几乎不变（ $R^2 = 0.9999997$ ）——但如 5.2 节所述，B1 的拟合残差标准差仅 1.5×10^{-4} 而损失标准差为 0.342，说明该附件近乎无噪声，此处的极高精度只能证明函数形式自洽，真正的泛化证据来自 B4（跨族真实数据， $r = 0.975$ 、MAPE 8.8%）与 B5（文献数据， $r = 0.910$ 、MAPE 8.0%）。(3) 引入质量项后的广义标度律在 1,536 个联合样本上 $R^2 = 0.990$ 、MAPE 0.66%，表明该模型能够描述这组联合样本；由于其样本组成与经典拟合不同，两者的拟合优度不能直接用于判断质量项是否改善泛化精度。(4) 问题四的 Loss—Benchmark 桥接 R^2 仅 0.26、MAPE 达 67.8%，这是本文误差最大的环节，其成因已在 5.4 节说明（中可比样本的验证集不统一、高可比样本的得分变化幅度过小），因此桥接结果仅用于方向性判定。(5) 问题三优化模型在所有求解点上均满足预算约束（相对残差 $< 10^{-6}$ ），无约束违反。

6.2 灵敏度分析

为考察模型结论对关键输入与假设的稳健性，分别对赋权方案、冲突阈值、正则系数、质量成本函数形式、质量基线口径、上下文长度与算力预算进行扰动分析，结果如表 26 所示。

表 26 灵敏度分析结果

参数/设定变化	输出变化	灵敏度评估
赋权方案：熵权法 → 等权平均 → PCA	域级质量排序一致性 0.679 → 0.679；样本级得分相关 0.854/0.881；得分均值 0.495 → 0.639 → 0.520	中等敏感：整体格局稳定，但领域名次会变化
指标方向：ad_en 按“第 1 类 = 无广告”（正向）→ 若误判为负向	领域质量排序由「arxiv > stackexchange > c4 > commoncrawl > book ≈ wikipedia > github」变为「c4 > commoncrawl > arxiv > stackexchange > book > wikipedia > github」	高度敏感：方向判定必须用实证证据
冲突阈值 τ ：0.5 → 1.0 → 1.5 → 2.0 → 2.5	冲突率 0.670 → 0.402 → 0.223 → 0.121 → 0.067；与独立基准之比 0.93 → 0.84 → 0.77 → 0.77 → 0.86	结论稳健：任一阈值下冲突率均显著低于独立基准
岭正则系数 λ ： $10^{-4} \sim 10^{-1}$	训练 R^2 由 0.6291 降至 0.6238， 检验 R^2 由 0.6187 降至 0.6157	不敏感，估计稳定
质量成本函数：指数型 → 幂函数型 → 对数渐进型 ($C = 10^{19}$)	$Q^* = 0.660 \rightarrow 0.551 \rightarrow 1.000$ ， L^* 差异 < 0.06；质量份额 12.9% → 0.0% → 31.6%	低预算档较敏感
同上，但 $C \geq 10^{22}$	三种函数下 Q^* 均为 1.000， N^* 、 D^* 差异 < 10%	不敏感，结论稳健
质量基线口径：配比加权 $Q_0 = 0.5510 \rightarrow$ 样本均值 0.4952	三档预算下 Q^* ： 0.551/1.000/1.000 → 0.504/1.000/1.000， N^* 变化 < 2%	不敏感
上下文长度： 2,048 → 131,072 tokens (C7 可行取值)	注意力/训练倍数 0.07 → 4.37； N^* 由 6.089B 降至 2.705B；损 失上升 6.0%	高度敏感，存在临界 点 $L_{crit} = 30,000$
算力预算 C ： $10^{19} \rightarrow 10^{24}$ FLOPs	Q^* 由 0.551 升至 1.000； D^*/N^* 由 30.9 升至 76.1；质量份额 0 → 0.407 → 0.016	高度敏感，发生三段 式结构性转移
半合成数据口径：并入 B2 / B8	B2 使 MAPE 升至 33.7%；B8 使 MAPE 升至 133.4% 且预测 低于不可约损失下限	不可并入；已划出可 信度边界

由表 26 可知，本文结论可按稳健程度分为三类：

(1) **高度稳健的结论**：冲突率显著低于独立基准（任一阈值下比值均 < 0.93 ）；岭正则系数不影响配比系数与拟合精度；质量基线口径不影响最优配置；中高预算下“质量拉满”的结论不依赖质量成本函数的具体形式。这些结论可直接用于后续决策。

(2) **成本分界与配置阶段**： $L_{\text{crit}} = 30,000 \text{ tokens}$ 表示注意力与基础训练成本相等，并不意味着最优规模在该点突变。在问题三的基准情景中，首次观察到正质量投入与质量饱和的网格预算分别为 1.78×10^{19} 和 $7.08 \times 10^{19} \text{ FLOPs}$ 。上述数值受扫描分辨率、求解状态及质量成本设定影响，宜作为配置阶段的数值识别结果，而非普遍成立的精确门槛。

(3) **需要谨慎表述的结论**：低预算档（ $C = 10^{19} \text{ FLOPs}$ ）的最优质量对质量成本函数形式高度敏感（ $0.551 \sim 1.000$ ，即从“完全不投资质量”到“质量拉满”），因此该档的具体数值应作为区间而非点值使用；**Loss—Benchmark** 桥接的 R^2 仅 0.26 ，其换算出的“损失改善等价于多少能力分”只具方向意义；领域质量排序对指标方向判定与赋权方案均为中等以上敏感，引用该排序时须同时引述其口径。

综上，除已明确标注的低预算档与桥接环节外，本文模型的资源配置与演进结论对参数扰动均保持稳定，具备可靠性与可解释性。

七、模型的评价

7.1 模型的优点

- **优点 1**：质量评价体系完整且可核验——逐指标给出 **22** 个质量指标的方向判定与语义依据（表 2），其中争议最大的广告字段通过**原文抽查**确认为“第 1 类 = 无广告”的正向指标；对负向指标作补转换、对长度型指标转为中心接近度、对 **8** 个多列表型指标用 **softmax** 期望压缩，逐字段审计出 **19** 处缺失并按中位数填充，并用抽样集与扩展集的域级质量对照（差值约为 0.002 ）证明评分口径可跨集合迁移，从而避免了“方向未统一”这一常见错误。

- **优点 2**：冲突分析给出了可比较的参照系——不仅报告冲突率（ 22.3% ）与 **Kendall** 协同系数（ 0.069 ），还计算了“指标独立”基准（ 28.9% ）并做阈值灵敏度检验（ $\tau \in [0.5, 2.5]$ 下比值恒 < 0.92 ），从而客观得出“指标正相关但一致性不强”的结论，并归纳出三类冲突成因与消解规则，未回避数据中的不一致性。

- **优点 3**：广义标度律的形式设计兼顾物理合理性与兼容性——采用质量缺口项 $C(1-Q)^\gamma$ ，在 $Q = 1$ 时精确退化为经典 **Chinchilla** 形式，且不会在高质量端产生负损失（避免了 $E - CQ^\gamma$ 形式的非物理缺陷）；同时通过四种形式的同口径比较（ R^2 、残差信息评分、内插与外推）择优，并用 **B3** 的独立插值轨迹验证数据项指数（ -0.2805 vs -0.2799 ）。

- **优点 4**：算力成本模型严格遵循赛题公式、不做简化——完整保留质量成本与训练 **token** 数成正比的结构（ $C_Q = D[g(Q) - g(Q_0)]_+$ ）与附录 **B** 规定的三型函数参数，并解析给出临界上下文长度 $L_{\text{crit}} = 6/\eta = 30,000$ 与最优性条件式(28)，用“等效附加参数规模 $\tau(Q)$ ”把质量投入折算为与模型参数量同口径的开销，使结构性转移具有清晰的解析解释。

- **优点 5**：口径界定与证据分层规范——问题四明确给出时间轴、开源许可白名单与模型类型三套口径及筛选漏斗，完成附件 **C8** 的逐任务聚合（**1,860** 个模型、**37** 个子任务维度）并与 **C1** 做秩相关校验，用附件 **C4** 的算力增速与开源占比支撑情景假设；对 **B2/B8** 等口径异常的半合成数据主动作自洽性审计并划出可信度边界（**B8** 最小损失低于模型不可约损失下限）。

7.2 模型的缺点

- **缺点 1:** 配比—损失模型假设线性关系且未含领域交互项，13 个可测域的平均 R^2 仅 0.629，说明仍有约 37% 的损失变异未被配比解释（可能来自随机种子、数据顺序等未观测因素）；**nih_exporter**、**enron_emails**、**europarl**、**philpapers** 四个无损失列的域只能固定于参考配比处理，其影响难以识别；追加混合质量指数后 R^2 增量仅 5×10^{-5} ，虽有明确结论（质量信息已被配比吸收），但也意味着本文无法在线性框架内把 17 域质量评分进一步用于配比优化。

- **缺点 2:** 质量评价的指标方向仍部分依赖语义先验。广告、流畅度两个二分类字段已用原文与域对比完成实证核验，但 **modernbert** 系列的 6 级列表型指标、**qurater** 的 4 级评级等，“级别越高越好”仍来自字段语义而非独立验证；此外熵权法对分布形态敏感（左偏指标获更大权重），灵敏度检验显示改用等权平均后域级排序一致性为 0.679，方向判定若出错更会使排序发生实质变化（见第 6.1 节），说明域级质量排名的部分细节对赋权与方向设定敏感，引用时须同时给出其口径。

- **缺点 3:** 广义标度律的质量项依赖半合成数据标定（**B6/B7**），**B8** 因方向相反且损失低于不可约损失下限而不能使用，**B2**（**Cerebras**）的 **MAPE** 达 33.7%，说明跨数据源的质量效应标定仍不充分；质量可行域受数据支持范围限制在 $[Q_0, 1]$ ，向更低质量的外推缺乏数据支撑。

- **缺点 4:** 问题四的 **Loss—Benchmark** 桥接 R^2 仅 0.26、**MAPE** 达 67.8%，且 **C1** 中评测标准一致的窗口仅约 10 个月（**2024-06** 至 **2025-03**），**2019–2023** 的历史锚点口径不完全一致（已剔除 13 条异常条目），因此前沿预测的外推期约为一致窗口的 1.2 ~ 2.4 倍，预测结果只能作为情景化区间；面板回归中规模与年份仍存在一定共线性，贡献占比对数据口径较敏感（长周期口径 50.5% vs 近端口径规模占比可正可负）。

八、模型的改进与推广

8.1 模型的改进

本文模型可在方法、参数与数据三个层面进一步改进。

方法层面，可将配比—损失的线性混合回归替换为 **Dirichlet** 回归，或引入领域间交互项与稀疏先验（如 **Group Lasso**），以捕捉非线性效应并把 13 个域平均 $R^2 = 0.629$ 中未被解释的约 37% 变异进一步压缩；对未测量域（**nih_exporter** 等四个域）可尝试用域文本统计特征构造代理变量，替代当前“固定于参考配比”的处理；冲突消解可由当前的“多数指标方向裁决”升级为基于潜变量模型（如有序 **probit** 因子模型）的一致性度量，从而给出冲突样本的质量可信度区间而非二值标记。

参数层面，广义标度律的质量缺口项可放宽为更灵活的形式（如 $C(1-Q)^{\gamma_1}D^{-\gamma_2}$ 或质量与数据量的交互项），以检验“质量缺口是否与数据规模耦合”；算力优化模型可进一步纳入数据重复轮次（**epoch**）、稀疏化/量化带来的推理与训练成本差异、以及分阶段课程学习等新决策变量；质量成本函数可在问题三采用的三种形式之外引入由真实清洗流水线标定的经验成本曲线，以缓解低预算档对成本函数形式较敏感的问题。

数据层面，可用更多具备质量标注的公开语料扩充 **B6/B7** 的质量区间（当前外推下限受数据支持范围限制），并尝试从语料元数据（发布时间、来源许可、去重比例）反推质量标签；对附件 **C4** 可通过组织名、参数量与发布时间做模糊匹配，与 **C1** 建立更细粒度的行级连接，从而用真实训练算力直接约束前沿预测；对问题四，若能获得跨评测标准（**v1** 与 **v2**）的校准样本，则可把 **2019–2023** 的历史锚点统一到同一标尺，显著缓解当前“一致窗口仅 10 个月”的外推局限。

8.2 模型的推广

本文提出的“损失函数—成本约束—资源配置”建模框架具有广泛的推广价值。

在工程领域，该框架可直接迁移至算力受限场景下的大模型预训练、微调与蒸馏资源配置决策：式(28)给出的最优性条件与“等效附加参数规模 $\tau(Q)$ ”这一折算量，使得数据治理投入与算力扩张投入可以直接放在同一成本口径下比较，帮助企业以最小算力达到目标能力。

在数据治理领域，本文的质量综合评价与冲突消解模型（含 22 指标的显式方向表与“冲突率—独立基准”对比框架）可用于通用语料清洗、数据筛选与领域配比的动态调整；系数向量余弦相似度 s_{ij} 可描述不同领域作用模式的相似性与差异，为配比分析提供参照；等量替代或联合使用的收益仍需通过配比实验验证。

在行业与政策层面，本文“长周期 **shift-share** 分解 + 近端一致窗口分解”的双重口径方法，可为科研机构评估“堆参数”与“改进算法”两条路线的投入产出、制定算力与数据资源的宏观配置政策提供定量依据；同时本文在方法上刻意区分“可直接使用的稳健结论”“存在临界点的结论”与“需谨慎表述的结论”，这一证据分级范式对涉及多源异构数据的政策评估同样适用。

更进一步，能力前沿的饱和外推方法（**logistic** 曲线外推与结构外推双路线互为校验）可推广至芯片制程、新能源技术、生物医药研发等具有渐进饱和特征的技术演进预测场景；而本文对半合成数据所做的“方向审计 + 不可约损失下限检验”自治性筛查流程，可作为使用半合成/估算数据开展定量建模时的通用质量把关步骤。

参考文献

- [1] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[EB/OL]. 2020. <https://arxiv.org/abs/2001.08361>, 访问日期: 2026-09-25.
- [2] HOFFMANN J, BORGEAUD S, MENSCH A, et al. Training compute-optimal large language models[EB/OL]. 2022. <https://arxiv.org/abs/2203.15556>, 访问日期: 2026-09-25.
- [3] VILLALOBOS P, HO A, SEVILLA J, et al. Will we run out of data? Limits of LLM scaling based on human-generated data[EB/OL]. 2022. <https://arxiv.org/abs/2211.04325>, 访问日期: 2026-09-25.
- [4] ASAI A, HE J, SHAO R, et al. Synthesizing scientific literature with retrieval-augmented language models[J]. Nature, 2026, 650: 857-863. DOI: 10.1038/s41586-025-10072-4.
- [5] Codex, GPT-5.4, OpenAI, 2026-03-05. <https://developers.openai.com/api/docs/models/gpt-5.4>, 访问日期: 2026-09-25.
- [6] Codex, GPT-6 系列, OpenAI, 2026-09-03 (系列首次发布). <https://developers.openai.com/api/docs/changelog>, 访问日期: 2026-09-25.
- [7] WorkBuddy, DeepSeek-V4-Flash, 腾讯(工具)与深度求索(模型), 2026-04-24 (首次公开发布). <https://api-docs.deepseek.com/news/news260424>, 访问日期: 2026-09-25.
- [8] GLM, GLM-5.1, 智谱, 2026-04-07. <https://z.ai/blog/glm-5.1>, 访问日期: 2026-09-25.
- [9] LIU Q, ZHENG X, MUENNIGHOFF N, et al. RegMix: Data mixture as regression for language model pre-training[EB/OL]. 2024. <https://arxiv.org/abs/2407.01492>, 访问日期: 2026-09-25.
- [10] GAO L, BIDERMAN S, BLACK S, et al. The Pile: An 800GB dataset of diverse text for language modeling[EB/OL]. 2020. <https://arxiv.org/abs/2101.00027>, 访问日期: 2026-09-25.
- [11] BIDERMAN S, SCHOELKOPF H, ANTHONY Q G, et al. Pythia: A suite for analyzing large language models across training and scaling[C]. Proceedings of Machine Learning Research, 2023, 202: 2397-2430.
- [12] 第二十三届中国研究生数学建模竞赛 F 题数据说明: 算力约束下提升大语言模型能力的资源配置建模 [R]. 2026.
- [13] XIE S M, PHAM H, DONG X, et al. DoReMi: Optimizing data mixtures speeds up language model pretraining[EB/OL]. 2023. <https://arxiv.org/abs/2305.10429>, 访问日期: 2026-09-25.
- [14] MUENNIGHOFF N, RUSH A M, BARAK B, et al. Scaling data-constrained language models[EB/OL]. 2023. <https://arxiv.org/abs/2305.16264>, 访问日期: 2026-09-25.

附录

附录 A：数据利用清单

按数据说明的要求，列出本文对各附件的实际使用情况，并标注半合成/外推数据的可信度边界，如表 27 所示。

表 27 附件数据利用清单

编号	文件名	性质	是否使用	使用方式与可信度说明
A1	slimpajama_quality_signal_sample	真实	使用	22 指标熵权评分、冲突分析、域级 Q 、原文抽查 (51,230 条全量)
A2	slimpajama_quality_extended/arxiv	真实	使用	扩展集域级 Q 与抽样集对照 (17,523 条全量)
A3	slimpajama_quality_extended/github	真实	使用	扩展集域级 Q 与抽样集对照 (203,752 条全量)
A4	train_mixture_1m	真实	使用	配比—损失岭回归训练集 (512 组)
A5	train_pile_loss_1m	真实	使用	13 域损失标签
A6–A9	test_mixture/loss_1m, 60m	真实	使用	同尺度与跨尺度检验 (各 256 组)
A10–A11	test_mixture/loss_1B	真实	使用	跨尺度检验 (64 组)
A12–A15	est_mixture/loss_10b, 70b	子集/外推	使用	外推尺度因子稳健性 (各 63 组，均标注为外推非观测)
A16	domain_mapping_guide	参考	使用	17 域到质量域跨体系映射 (6 域 direct/near_direct , 11 域 inferred 用全局均值并标明)
A17	regmix_domain_summary	真实	未使用	未用于本文分析
A18	regmix_domain_sample	真实	未使用	未用于本文分析
B1	pythia_training_log_existing	真实	使用	经典标度律主拟合与模型留出验证 (1,176 点)；已说明该附件近乎无观测噪声
B2	cerebras_training_log	半合成	使用	族外验证；结果 MAPE 33.7% ，判为口径差异、仅作定性参考
B3	training_trajectories	插值	使用	轨迹内 D 幂指数验证 (−0.2806 至 −0.2803，拟合值 −0.2799)
B4	scaling_baseline	真实	使用	跨族验证 ($r = 0.975$ 、 MAPE 8.8%)

表 27 附件数据利用清单（续）

编号	文件名	性质	是否使用	使用方式与可信度说明
B5	published_scaling_data	真实	使用	文献验证 ($r = 0.910$ 、 MAPE 8.0%)
B6	supplementary_NQ_experiment	半合成	使用	质量缺口项拟合主数据 (360 点); 仅用于标定质量效应, 不作直接实验观测
B7	supplementary_NQ_experiment_expanded	半合成	使用	新增点开发阶段验证 ($r = 0.991$)
B8	supplementary_NQ_experiment_large	半合成	部分使用	方向审计发现其 Q_{score} 与 B6/B7 反号, 且最小损失低于不可约损失下限, 故不并入拟合, 仅作可信度边界警示
B9	supplementary_large_models	真实	使用	百亿参数以上模型元数据 (参数量、数据量、开源可及性)
B10	supplementary_large_baseline	估算	使用	百亿参数以上外推检验 ($r \approx 1.000$ 、 MAPE 1.0%); 标注为估算值
B11	open_model_family_metadata	真实	未使用	未用于本文分析
B12	pythia_checkpoint_index	真实	未使用	未用于本文分析
C1	leaderboard_cleaned	真实	使用	六维得分、许可、类型、提交日期; 开源筛选后 2,346 条用于面板回归与前沿
C2	leaderboard_enhanced	真实	未使用	C1 的增强替代版, 为避免重复计算未使用
C3	leaderboard_extended_timeseries	混合	使用	2019–2025 长周期分解; 已剔除 13 条自治性异常行, 口径混合性在正文标注
C4	epoch_all_ai_models	真实	使用	训练算力年增速 ($+0.589$ dex/年)、训练数据量、开源权重字段 (Yes 1,325 / No 1,328)
C5	loss_benchmark_bridge	混合	使用	桥接对照 ($n = 43$, $r = -0.502$)
C6	loss_benchmark_bridge_expanded	混合	使用	桥接主用 ($n = 75$), 按 High/Medium 可比性分层使用
C7	model_architecture_metadata	真实	使用	上下文长度可行取值 (2048、4096、8192、32768、131072) 用于问题三敏感性分析
C8	detailed_results/	真实	使用	逐任务聚合 (1,860 个模型成功解析、 37 个子任务维度), 并与 C1 做秩相关校验

表 27 附件数据利用清单（续）

编号	文件名	性质	是否使用	使用方式与可信度说明
C9	data/ (Parquet)	真实	未使用	与 C1 等价，任选其一
C10	pythia_eval_details/	说明	未使用	仅含 README，不可替代 C8

附录 B：半合成与外推数据的标注

按数据说明要求，以下数据为非直接观测，正文中的相关结论均已限定适用范围：

- **半合成数据**：B2（Cerebras训练日志）、B6/B7/B8（NQ 质量实验）。本文在标度律拟合中仅使用 B6（主）与 B7（验证），并在 5.2 节以表格明确其“半合成”性质；B2、B8 经自洽性审计后不并入拟合。
- **外推与估算数据**：A12–A15（10B/70B 损失外推，源自 1M/60M/1B 幂律外推）、B10（百亿参数以上损失估算）。相关结论仅用于稳健性检验，未作为观测证据。
- **插值数据**：B3（Pythia插值轨迹），仅用于轨迹内幕指数的交叉验证。
- **混合口径数据**：C3（跨年评测标准不完全一致）、C5/C6（Loss来源与验证集不完全统一）。前者的异常行已被审计剔除，后者已按可比性等级分层使用。

附录 C：结果文件与核心求解代码

本文的求解结果以 CSV 形式保存在求解/问题一至问题四/结果/ 目录下，主要结果文件如表 28 所示（表中文件名省略“求解/问题 X/结果/”前缀）。

表 28 主要结果文件说明

文件	说明
质量指标熵权.csv	22 指标的方向判定、语义说明、信息熵与熵权
质量信号缺失审计.csv	逐指标字段级缺失计数（A1–A3 全量）
质量冲突与一致性.csv	抽样集/扩展集/全量的冲突率、独立基准与 Kendall W
冲突阈值灵敏度.csv	冲突率随阈值 τ 的变化
抽样集与扩展集域级对照.csv	A1 与 A2/A3 的域级质量对照
质量与损失难度一致性.csv	两套质量口径在 6 个映射域上的排序比较
质量项增量检验.csv	追加混合质量指数后的 R^2 增量
混合系数矩阵.csv、截距.csv	配比—损失岭回归系数与截距
推荐配比调整.csv	有界推荐配比与调整量
问题一_拟合汇总.csv	各损失域的拟合与检验指标
岭正则敏感性.csv	正则系数灵敏度
经典标度律参数.csv	经典标度律参数、拟合与留出验证指标
质量字段方向审计.csv	B6/B7/B8 的组内相关与方向结论
广义标度律形式对比.csv	四种质量项形式的 R^2 与残差信息评分比较
广义标度律分层验证.csv	6 组数据来源的验证结果

表 28 主要结果文件说明 (续)

文件	说明
弹性与替代关系.csv、质量参数替代关系.csv	弹性与替代率
领域替代互补_top.csv	领域效应的相似性与差异
B3 轨迹验证.csv	轨迹内 D 幂指数验证
三档预算最优配置.csv、成本函数对比.csv	三档预算与三型成本函数的优化结果
结构性转移识别.csv	结构性转移门槛
上下文长度敏感性.csv	C7 五档上下文长度下的最优配置
质量基线灵敏度.csv	质量基线口径灵敏度
配比项算力等价.csv	配比优化的算力等价效果
筛选漏斗.csv	时间轴/开源/模型类型三套口径的筛选漏斗
C8 逐任务解析结果.csv	C8 全部模型的任务级原始指标
C8 逐任务聚合.csv、C8 子任务类别汇总.csv	子任务前沿与剩余空间
C8 与 C1 一致性校验.csv	C8 与 C1 的秩相关校验
Loss_Benchmark 映射.csv	分层桥接拟合结果
规模时间分解.csv、规模时间分解_长周期.csv	规模/非规模贡献分解
C3 口径异常行.csv	C3 自洽性审计剔除的记录
前沿预测.csv、前沿预测_结构外推情景.csv	能力前沿预测与情景
C4 宏观趋势.csv、C4 宏观摘要.csv	C4 宏观算力与开源权重证据
求解/广义标度律参数.csv、问题一_关键量.json	跨问共享的接口参数

附录 D：运行环境与核心实现

程序整理、绘图代码编写与结果核对使用 **Codex** 辅助，模型为 **OpenAI** 的 **GPT-5.4** (2026-03-05) 及 **GPT-6** 系列 (2026-09-03 首发) [5, 6]；运行输入、参数及输出以随文提供的源程序和结果文件为准。

程序采用 **Python 3**，依赖 **NumPy**、**pandas**、**SciPy** 与 **Matplotlib**；数据解压和 **JSON** 读取使用 **Python** 标准库。四问程序共同调用求解/_common.py，附件查找以该文件中的数据根目录为准。完整源程序保存在各问目录，下列代码仅摘录核心计算，所需导入、数据加载、全局变量和结果写出均见对应完整文件。代码行号沿用源文件，以便定位。

运行顺序为问题一、问题二、问题三；问题四单独读取附件 **C**，可独立运行。问题一输出质量、配比及关键量，问题二据此标定配比修正并输出广义标度律参数，问题三读取两问的共享文件。输入和输出关系见表 29。

表 29 问题、程序与数据依赖

问题	核心程序	输入	主要输出
一	求解/问题一/ 问题一.py	附件 A	质量评分、回归系数、推荐 配比
二	求解/问题二/ 问题二.py	附件 B、问题一结果	标度律参数、验证指标、配 比修正
三	求解/问题三/ 问题三.py	前两问共享结果、附件 C7	三档配置、预算扫描与敏感 性
四	求解/问题四/ 问题四.py	附件 C	任务聚合、贡献分解与前沿 预测

问题一：质量预处理、综合评分与冲突统计

程序 1: 问题一核心计算

```

76 def _softmax_expected(v):
77     """把有序类别 logits 压缩为 [0,1] 上的归一化期望级别。"""
78     a = np.asarray(v, dtype=float).ravel()
79     if len(a) == 0:
80         return np.nan
81     if len(a) == 1:
82         return float(a[0])
83     a = a - np.nanmax(a)
84     p = np.exp(a); p = p / np.nansum(p)
85     return float(p @ np.linspace(0.0, 1.0, len(a)))

155 def orient_and_normalize(raw):
156     """方向统一 -> 极差归一化（正向缩放、负向取补、长度型转中心接近
    度）。"""
157     oriented = raw.copy()
158     for c in TARGET_COLS:
159         z = np.log1p(np.clip(raw[c].values, 0, None))
160         med = np.median(z); mad = np.median(np.abs(z - med)) + 1e-9
161         oriented[c] = np.exp(-np.abs(z - med) / (2.5 * mad))
162     norm = pd.DataFrame(index=raw.index)
163     for c in QUALITY_COLS:
164         lo, hi = np.nanquantile(oriented[c], [0.01, 0.99])
165         v = np.clip((oriented[c] - lo) / max(hi - lo, 1e-12), 0, 1)
166         norm[c] = 1 - v if c in NEGATIVE_COLS else v
167     return oriented, norm
168
169 def quality_evaluation():
170     raw, meta = load_quality_records()
171     raw = raw.replace([np.inf, -np.inf], np.nan)
172     raw = raw.apply(lambda s: s.fillna(s.median()))
173     _, norm = orient_and_normalize(raw)
174
175     # —— 熵权法（主方案） ——
176     P = (norm.values + 1e-12) / (norm.values.sum(axis=0, keepdims=True)
    + 1e-12)

```

```

177     entropy = -(P * np.log(P)).sum(axis=0) / np.log(len(norm))
178     divergence = np.maximum(1 - entropy, 0)
179     w_entropy = divergence / divergence.sum()

214     def agreement(idx, label):
215         Zs = norm.loc[idx]
216         m, n = Zs.shape                                # m 条文本（对象），n=22 指
标（评价者）
217         rank_sum = np.zeros(m)
218         for c in Zs.columns:
219             rank_sum += stats.rankdata(Zs[c].values, method='average')
220         S = np.sum((rank_sum - rank_sum.mean()) ** 2)
221         W = 12 * S / max(n ** 2 * (m ** 3 - m), 1)
222         Am = (Zs.values - Zs.values.mean(axis=0)) / (Zs.values.std(axis
=0) + 1e-12)
223         iu = np.triu_indices(n, 1)
224         pairdiff = np.abs(Am[:, iu[0]] - Am[:, iu[1]])
225         rate = float((pairdiff > CONFLICT_TAU).mean())
226         rate_free = float(2 * stats.norm.sf(CONFLICT_TAU / np.sqrt(2)))
227         chi2 = n * (m - 1) * W
228         pair_rate = pd.Series((pairdiff > CONFLICT_TAU).mean(axis=0),
229                               index=['%s|%s' % (QUALITY_COLS[i],
QUALITY_COLS[j])
for i, j in zip(*iu)])
230         return {'dataset': label, 'n': m, 'kendall_W': W, 'chi2': chi2,
231                 'p_value': stats.chi2.sf(chi2, m - 1),
232                 'conflict_rate': rate, 'indep_baseline': rate_free,
233                 'conflict_ratio_vs_indep': rate / rate_free}, pair_rate

338 def fit_ridge(X, Y, alpha=1e-3):
339     n, K = X.shape
340     Xc = np.hstack([X, np.ones((n, 1))])
341     reg = alpha * np.eye(K + 1); reg[-1, -1] = 0
342     W = np.linalg.solve(Xc.T @ Xc + reg, Xc.T @ Y)
343     return W[:K], W[-1]
344
345 def predict(X, A, b):
346     return X @ A + b
347
348 def r2(y, yhat):
349     ss_res = np.sum((y - yhat) ** 2, axis=0)
350     ss_tot = np.sum((y - y.mean(axis=0)) ** 2, axis=0)
351     return 1 - ss_res / np.maximum(ss_tot, 1e-12)
352
353 def pearson_col(y, yhat):
354     return np.array([np.corrcoef(y[:, j], yhat[:, j])[0, 1] for j in
range(y.shape[1])])
355
356 A, b = fit_ridge(Xtr, Ytr)
357 r2_tr = r2(Ytr, predict(Xtr, A, b))
358 r2_tel = r2(Ytel, predict(Xtel, A, b))

```

```

434 ref = Xtr.mean(axis=0)
435 w_ref = ref[[DOMAINS.index(d) for d in LOSS_DOMAINS]]
436 w_ref = w_ref / w_ref.sum()
437 unmeas_sum = ref[[DOMAINS.index(u) for u in UNMEASURED]].sum()
438 meas_idx = [DOMAINS.index(d) for d in MEASURED]
439
440 def build(pm):
441     p = np.zeros(17); p[meas_idx] = pm
442     for u in UNMEASURED:
443         p[DOMAINS.index(u)] = ref[DOMAINS.index(u)]
444     return p / p.sum()
445
446 def obj(pm):
447     return float(w_ref @ predict(build(pm)[None, :], A, b)[0])
448
449 p0m = ref[meas_idx] / ref[meas_idx].sum()
450 cons = {'type': 'eq', 'fun': lambda pm: pm.sum() - (1 - unmeas_sum)}
451 res = minimize(obj, p0m, method='SLSQP', bounds=[(0, 1)] * len(MEASURED),
452               , constraints=cons)
453 p_opt = build(res.x)
454 save_csv_safe(pd.DataFrame({'domain': DOMAINS, 'reference_mixture': ref,
455                             'optimal_mixture': p_opt}).sort_values('
456                             optimal_mixture', ascending=False),
457               '最优配比预测.csv')
458 bnds = [(0, 2.5 * ref[i]) for i in meas_idx]
459 res_b = minimize(obj, p0m, method='SLSQP', bounds=bnds, constraints=cons)
460 p_b = build(res_b.x)
461 rec_df = pd.DataFrame({'domain': DOMAINS, 'reference_mixture': ref, '
462                        recommended_mixture': p_b,
463                        'adjustment': p_b - ref}).sort_values('adjustment
464                        ', ascending=False)
465 save_csv_safe(rec_df, '推荐配比调整.csv')
466 print('\n无约束最优加权平均损失 %.4f; 有界推荐 %.4f; 参考配方 %.4f'
467       % (obj(res.x), obj(res_b.x), obj(p0m)))
468 print('有界推荐配比（调整量最大增/减各 5 域）：')
469 print(rec_df.head(5).to_string(index=False))
470 print(rec_df.tail(5).to_string(index=False))

```

问题二：标度律估计、质量方向与边际分析

程序 2: 问题二核心计算

```

43 def classic(par, N, D):
44     E, A, a, B, b = par
45     return E + A * N ** (-a) + B * D ** (-b)
46
47 r0 = least_squares(lambda p: classic(p, N_p, D_p) - L_p, [1.7, .4, .33,
48                 1.2, .28],
49                 bounds=([0, 1e-8, .01, 1e-8, .01], [5, 1e3, 2, 1e3,
50                 2]),
51                 loss='soft_l1', f_scale=.05, max_nfev=40000)
52 E0, A0, a0, B0, b0 = r0.x
53 Lph = classic(r0.x, N_p, D_p)
54 R2_cls = 1 - np.sum((L_p - Lph) ** 2) / np.sum((L_p - L_p.mean()) ** 2)

```

```

53 RMSE_cls = float(np.sqrt(np.mean((L_p - Lph) ** 2)))
54
55 Ns = sorted(pythia.N_params_B.unique())
56 tr_m = pythia[pythia.N_params_B.isin(Ns[:4])]
57 te_m = pythia[pythia.N_params_B.isin(Ns[4:])]
58 rh = least_squares(lambda p: classic(p, tr_m.N_params_B.values, tr_m.
    D_tokens_B.values)
59                      - tr_m.val_loss.values, [1.7, .4, .33, 1.2, .28],
60                      bounds=([0, 1e-8, .01, 1e-8, .01], [5, 1e3, 2, 1e3,
    2])),
61                      loss='soft_l1', f_scale=.05, max_nfev=40000)
62 hp = classic(rh.x, te_m.N_params_B.values, te_m.D_tokens_B.values)
63 ym = te_m.val_loss.values

84 def group_corr(df, qcol='Q_score'):
85     vals, ng = [], 0
86     for _, g in df.groupby(['N_params_B', 'D_tokens_B']):
87         if g[qcol].nunique() >= 3:
88             vals.append(g[qcol].corr(g.val_loss)); ng += 1
89     return float(np.nanmean(vals)), ng
90
91 audit = []
92 for nm, sub, note in [('B6', nq6, '质量主数据'),
93                      ('B7', nq7, '质量扩展数据 (含 B6 重复点)'),
94                      ('B8-calibrated', nq8[nq8.data_type.eq('calibrated
    ')], '大规模矩阵校准段'),
95                      ('B8-extrapolated', nq8[nq8.data_type.eq('
    extrapolated']), '大规模矩阵外推段')]:
96     r, ng = group_corr(sub)
97     audit.append({'dataset': nm, 'n': len(sub), 'n_groups': ng, '
    within_ND_corr': r,
98                  'conclusion': ('Q 越大损失越低 -> 质量指标 (越高越好)
    ' if r < -0.5 else
99                                ('Q 越大损失越高 -> 方向与 B6/B7 相反'
100                                '组内无显著单调关系'))})

116 def g_v1(p, N, D, Q):
117     E, A, a, B, b, C, g = p
118     return E + A * N ** (-a) + B * D ** (-b) + C * np.clip(1 - Q, 0, 1)
    ** g
119
120 def g_v2(p, N, D, Q):
121     E, A, a, B, b, C, g = p
122     return E + A * N ** (-a) + B * (D * np.clip(Q, 1e-6, 1) ** g) ** (-b)
123
124 def g_v4(p, N, D, Q):
125     E, A, a, B, b, C, g = p
126     return E + A * N ** (-a) + B * D ** (-b) + C * np.clip(Q, 1e-6, 1)
    ** (-g)
127
128 def g_v5(p, N, D, Q):
129     E, A, a, B, b, g1, g2 = p
130     return (E + A * (N * np.clip(Q, 1e-6, 1) ** g1) ** (-a)
131            + B * (D * np.clip(Q, 1e-6, 1) ** g2) ** (-b))

```

```

145 for nm, (fn, p0, lo, hi) in FORMS.items():
146     rr = least_squares(lambda p: fn(p, N_all, D_all, Q_all) - L_all, p0,
147                        bounds=(lo, hi), loss='soft_l1', f_scale=.05,
                        max_nfev=80000)
148     hh = fn(rr.x, N_all, D_all, Q_all)
149     R2j = 1 - np.sum((L_all - hh) ** 2) / np.sum((L_all - L_all.mean())
** 2)
150     hq = fn(rr.x, nq6.N_params_B.values, nq6.D_tokens_B.values, nq6.
Q_score.values)
151     R2q = 1 - np.sum((nq6.val_loss.values - hq) ** 2) / \
152         np.sum((nq6.val_loss.values - nq6.val_loss.mean()) ** 2)
153     h7 = fn(rr.x, nq7_new.N_params_B.values, nq7_new.D_tokens_B.values,
nq7_new.Q_score.values)
154     r7 = float(np.corrcoef(nq7_new.val_loss.values, h7)[0, 1])
155     form_rows.append({'形式': nm, '联合R2': R2j, 'B6拟合R2': R2q, 'B7新
增点r': r7,
156                     '参数个数': len(rr.x),
157                     'AIC': len(N_all) * np.log(np.mean((L_all - hh) **
2)) + 2 * len(rr.x)})
158     fit_store[nm] = rr.x
159 sv = pd.DataFrame(form_rows).sort_values('联合R2', ascending=False)
160 save_csv_safe(sv, '广义标度律形式对比.csv')
161 print('\n=== 3. 广义标度律形式对比 ===')
162 print(sv.to_string(index=False))
163
164 best_name = sv.iloc[0]['形式']
165 fn_best = FORMS[best_name][0]
166 rlx = fit_store[best_name]

211 def marg(p, N, D, Q):
212     E_, A_, a_, B_, b_, C_, g_ = p
213     return (-a_ * A_ * N ** (-a_ - 1), -b_ * B_ * D ** (-b_ - 1),
214            -g_ * C_ * np.clip(1 - Q, 1e-9, None) ** (g_ - 1))
215
216 el_rows = []
217 for N_ref, D_ref, Q_ref in [(1., 100., 0.6), (12., 300., 0.6)]:
218     L_ref = float(fn_best(rlx, N_ref, D_ref, Q_ref))
219     dN, dD, dQ = marg(rlx, N_ref, D_ref, Q_ref)
220     sub = abs(dQ) / abs(dN)
221     el_rows.append({'参考点N(B)': N_ref, 'D(B)': D_ref, 'Q': Q_ref, 'L':
L_ref,
222                   '弹性e_N': dN * N_ref / L_ref, '弹性e_D': dD * D_ref
/ L_ref,
223                   '弹性e_Q': dQ * Q_ref / L_ref, '替代率dN/dQ(B)': sub
,
224                   'dQ=0.1等价dN(B)': sub * 0.1})
225 el_df = pd.DataFrame(el_rows)

```

```

248 coef = pd.read_csv(os.path.join(p1_dir, '混合系数矩阵.csv')).set_index('
      training_domain')
249 inter = pd.read_csv(os.path.join(p1_dir, '截距.csv')).set_index('
      loss_domain').intercept
250 mix = pd.read_csv(DATA('train_mixture_lm.csv'))
251 mix_cols = [c for c in mix if c.startswith('train_the_pile_')]
252 domains = [c.replace('train_the_pile_', '') for c in mix_cols]
253 p_ref = mix[mix_cols].mean().to_numpy(float)
254 loss_domains = list(coef.columns)
255 w_ref = np.array([p_ref[domains.index(d)] for d in loss_domains]); w_ref
      /= w_ref.sum()
256
257 def mix_obj(p):
258     return float(w_ref @ (np.asarray(p) @ coef.loc[domains].to_numpy()
259         + inter.loc[loss_domains].to_numpy()))
260
261 ref_obj = mix_obj(p_ref)
262 rec = pd.read_csv(os.path.join(p1_dir, '推荐配比调整.csv')).set_index('
      domain').loc[domains]
263 p_rec = rec.recommended_mixture.to_numpy(float)
264 mix_delta_rec = mix_obj(p_rec) - ref_obj
265 save_csv_safe(pd.DataFrame([{'mixture': '参考配比', '
      predicted_weighted_loss': ref_obj, 'M_p': 0.},
266     {'mixture': '问题一有界推荐', '
      predicted_weighted_loss': mix_obj(p_rec),
267     'M_p': mix_delta_rec}]), '配比项校准.csv')
268
269 Cn = coef.loc[domains].to_numpy()
270 Cc = Cn - Cn.mean(axis=0, keepdims=True)

```

问题三：损失、成本函数与约束优化

程序 3: 问题三核心计算

```

52 def loss(N_abs, D_abs, Q, M_p=0.0):
53     """验证损失：参数以 B 为单位代入问题二标度律，M_p 为配比项修正。"""
54     return (E + A * (N_abs / 1e9) ** (-alpha) + B * (D_abs / 1e9) ** (-
55         beta)
56         + Cq * (1 - Q) ** gamma + M_p)
57 # ===== 1. 附录 B 的三型质量成本函数 =====
58 GB = {
59     '指数型': dict(gamma=1e7, lam=6.0),
60     '幂函数型': dict(gamma=5e9, lam=4.0),
61     '对数渐进型': dict(gamma=2e9, lam=10.0),
62 }
63 def g_of(Q, form):
64     par = GB[form]
65     if form == '指数型':
66         return par['gamma'] * np.exp(par['lam'] * Q)
67     if form == '幂函数型':
68         return par['gamma'] * Q ** par['lam']
69     return par['gamma'] * np.log(1 + par['lam'] * Q)
70
71 def c_quality(D_abs, Q, form):

```

```

72     return D_abs * max(g_of(Q, form) - g_of(Q0, form), 0.0)

90 def total_cost(N_abs, D_abs, Q, L_ctx, form):
91     return 6.0 * N_abs * D_abs + c_quality(D_abs, Q, form) + ETA * N_abs
    * D_abs * L_ctx
92
93 def optimize(C_budget, L_ctx=2048, form='幂函数型', M_p=0.0, n_starts=8,
    Qcap=1.0):
94     """SLSQP 对数参数化联合优化 (N, D, Q)。"""
95     def obj(x):
96         return loss(np.exp(x[0]), np.exp(x[1]), x[2], M_p)
97     def con(x):
98         return C_budget - total_cost(np.exp(x[0]), np.exp(x[1]), x[2],
    L_ctx, form)
99     best = None
100     for k in range(n_starts):
101         frac = (k + 1) / (n_starts + 1)
102         x0 = [np.log(1e9) + 4 * (frac - .5), np.log(1e11) + 4 * (.5 -
    frac),
103             Q0 + (Qcap - Q0) * frac]
104         try:
105             res = minimize(obj, x0, method='SLSQP',
106                           bounds=[(np.log(1e5), np.log(1e15)),
107                                   (np.log(1e6), np.log(1e16)), (Q0,
    Qcap)],
108                               constraints={'type': 'ineq', 'fun': con},
109                               options={'maxiter': 1500, 'ftol': 1e-14})
110         except Exception:
111             continue
112         if res.success and (best is None or res.fun < best.fun):
113             best = res
114     if best is None:
115         raise RuntimeError('优化失败')
116     N_abs, D_abs, Q = np.exp(best.x[0]), np.exp(best.x[1]), best.x[2]
117     c_base = 6.0 * N_abs * D_abs
118     c_qual = c_quality(D_abs, Q, form)
119     c_attn = ETA * N_abs * D_abs * L_ctx
120     return dict(N_B=N_abs / 1e9, D_B=D_abs / 1e9, D_over_N=D_abs / N_abs
    , Q=Q,
121               L=loss(N_abs, D_abs, Q, M_p), c_base=c_base, c_qual=
    c_qual,
122               c_attn=c_attn, c_tot=c_base + c_qual + c_attn,
123               f_base=c_base / C_budget, f_qual=c_qual / C_budget,
124               f_attn=c_attn / C_budget, form=form, L_ctx=L_ctx, C=
    C_budget)

```

问题四：分层桥接、规模时间分解与前沿预测

程序 4: 问题四核心计算

```
153 SUB_PREFIX = {'BBH子任务': 'leaderboard_bbh_', 'MATH子任务': '
    leaderboard_math_',
154               'GPQA子集': 'leaderboard_gpqa_', 'MUSR子任务': '
    leaderboard_musr_' }
155 sub_cols = {}
156 for grp, pre in SUB_PREFIX.items():
157     cols = [c for c in c8.columns if c.startswith(pre) and c.count('_')
    >= 2]
158     cols = [c for c in cols if c not in ('leaderboard_bbh_', '
    leaderboard_musr_',
159                                         'leaderboard_gpqa_', '
    leaderboard_math_hard' )]
160     sub_cols[grp] = cols
161 print(' C8 子任务维度数: ' + ', '.join('%s %d 项' % (k, len(v)) for k,
    v in sub_cols.items()))
162
163 # 子任务前沿与剩余空间（限定在开源筛选后的模型集合上）
164 screened_keys = set(core_o['key'])
165 c8s = c8[c8.key.isin(screened_keys)]
166 sub_rows = []
167 for grp, cols in sub_cols.items():
168     for c in cols:
169         s = pd.to_numeric(c8s[c], errors='coerce').dropna()
170         if len(s) < 10:
171             continue
172         sub_rows.append({'类别': grp, '子任务': c.replace('leaderboard_'
    , ''), '样本数': len(s),
173                        '最优得分': float(s.max()),
174                        '前5%均值': float(s.nlargest(max(1, int(len(s)
    * 0.05))).mean()),
175                        '中位数': float(s.median()),
176                        '剩余空间_%': float((100 - s.max()) / 100 *
    100)})
177 sub_df = pd.DataFrame(sub_rows)

194 br = pd.read_csv(os.path.join(C_DIR, 'loss_benchmark_bridge_expanded.csv
    '))
195 br['cmp'] = np.where(br['Loss_Comparability'].str.startswith('High'), '
    高可比',
196                     '中可比')
197 print('\n=== 3. Loss-Benchmark 桥接（C6 扩展桥接）===')
198 bridge_rows, fits = [], {}
199 for lvl in ['高可比', '中可比', '全样本']:
200     d = br if lvl == '全样本' else br[br.cmp.eq(lvl)]
201     sl, ic = np.polyfit(d.Val_Loss, d.LB_Average, 1)
202     pred = ic + sl * d.Val_Loss
203     fits[lvl] = (sl, ic)
204     bridge_rows.append({'可比性': lvl, 'n': len(d),
205                        'Pearson_r': float(np.corrcoef(d.Val_Loss, d.
    LB_Average)[0, 1]),
206                        'Spearman_rho': float(stats.spearmanr(d.Val_Loss
    , d.LB_Average).statistic),
```

```

207         '斜率': float(sl), '截距': float(ic),
208         'MAPE_%': float(np.mean(np.abs(pred - d.
    LB_Average) / d.LB_Average) * 100),
209         'R2': float(1 - np.sum((d.LB_Average - pred) **
    2)
210         / np.sum((d.LB_Average - d.
    LB_Average.mean()) ** 2)))
211 bridge_df = pd.DataFrame(bridge_rows)
212 save_csv_safe(bridge_df, 'Loss_Benchmark映射.csv')

242 def fit_model(sub, label, fe=True):
243     if fe:
244         Dm = np.column_stack([(sub.t.values == yy).astype(float) for yy
    in years])
245         X = np.column_stack([Dm, sub.logP.values])
246     else:
247         X = np.column_stack([np.ones(len(sub)), sub.logP.values, sub.t.
    values])
248     b, *_ = np.linalg.lstsq(X, sub.avg.values, rcond=None)
249     pred = X @ b
250     R2 = 1 - np.sum((sub.avg.values - pred) ** 2) / \
251         np.sum((sub.avg.values - sub.avg.values.mean()) ** 2)
252     return (b[-1], b[:-1], R2) if fe else (b[1], b[2], R2)
253
254 bP_fe, alpha_t, R2_fe = fit_model(panel, 'FE', True)
255 bP_ols, bt_ols, R2_ols = fit_model(panel, 'OLS', False)
256 panel['alpha_t'] = panel.t.map(dict(zip(years, alpha_t)))
257 save_csv_safe(pd.DataFrame({'Year': [y + 2019 for y in years], '年效应
    alpha_t': alpha_t}),
258               '年份效应.csv')
259 save_csv_safe(panel[['Model', 'P', 'logP', 't', 'avg', 'type_group', '
    Year']],
260               '面板回归数据.csv')

369 def logistic(t, K, r, t0):
370     return K / (1 + np.exp(-r * (t - t0)))
371
372 t_last = float(np.max(t_mon))
373 t_pred = np.array([t_last + 1.0, t_last + 2.0]) # 严格对应未来 12 /
    24 个月
374 try:
375     popt, _ = curve_fit(logistic, t_front, s_front, p0=[55, .8, 3.5],
376                         bounds=([20, .01, 0.5], [100, 5, 8]), maxfev
    =40000)
377     K_fit, r_fit, t0_fit = popt
378     pred_fit = logistic(t_front, *popt)
379     R2_log = 1 - np.sum((s_front - pred_fit) ** 2) / np.sum((s_front -
    s_front.mean()) ** 2)
380 except Exception as e:
381     K_fit, r_fit, t0_fit, R2_log = 52., .3, 3., 0.
382     print('logistic 拟合失败: ', e)
383 s_pred = logistic(t_pred, K_fit, r_fit, t0_fit)
384
385 resid = s_front - logistic(t_front, K_fit, r_fit, t0_fit)
386 rng = np.random.default_rng(42)
387 boot = []

```

```

388 for _ in range(600):
389     s_b = logistic(t_front, K_fit, r_fit, t0_fit) + rng.choice(resid,
390 size=len(resid), replace=True)
391     try:
392         pb, _ = curve_fit(logistic, t_front, s_b, p0=[K_fit, r_fit,
393 t0_fit], maxfev=40000)
394         boot.append(logistic(t_pred, *pb))
395     except Exception:
396         pass
397 boot = np.array(boot)
398 lo, hi = np.percentile(boot, 5, axis=0), np.percentile(boot, 95, axis=0)

399 def logistic_slow(t, K, r, t0, halve_from):
400     te = np.minimum(t, halve_from)
401     return K / (1 + np.exp(-r * (te - t0)))
402 s_slow = logistic_slow(t_pred, K_fit, r_fit, t0_fit, t_pred[0] - 1)
403
404 fut = pd.DataFrame({'t(2019起算年)': t_pred, '对应日历时点':
405 ['%d-%02d' % (2019 + int(np.floor(tt)), int(round((
406 tt % 1) * 12)) + 1)
407 for tt in t_pred],
408 'frontier_pred': s_pred,
409 'CI_low_5%': lo, 'CI_high_95%': hi, '情景_技术增速减
410 半': s_slow})
411 save_csv_safe(fut, '前沿预测.csv')
412
413 # 结构外推:  $F(t+\Delta) = F(t) + [bP \cdot \Delta \log_{10} P + bt] \cdot \Delta$  (把分解式直接用作预测方
414 程)
415 F_last = float(np.max(s_front))
416 scen = []
417 for yrs in [1, 2]:
418     for dlogP, bt_use, lbl in [(0.0, bt_ols, '基准 (前沿模型规模持平, 非
419 规模增速不变)'),
420 (0.0, bt_ols / 2, '算力增长放缓 (非规模增
421 速减半)'),
422 (0.3, bt_ols, '规模继续扩张 (前沿 +0.3
423 dex/年)')]:
424         scen.append({'情景': lbl, '前瞻年数': yrs,
425 'Δlog10P假设': dlogP, 'bt假设(分/年)': bt_use,
426 '结构外推前沿': F_last + (bP_fe * dlogP + bt_use) *
427 yrs})

```